

TARTU ÜLIKOOL
Arvutiteaduse instituut
Informaatika õppekava

Näidisüliõpilane
**Eestikeelse RAG-põhise küsimus-vastus
süsteemi kavandamine**
Bakalaureusetöö (9 EAP)

Juhendaja:
Juhendaja nimi, PhD

Tartu 2026

Eestikeelse RAG-põhise küsimus-vastus süsteemi kavandamine

Lühikokkuvõte:

Käesoleva bakalaureusetöö eesmärk on analüüsida, kuidas kavandada eestikeelne dokumentide põhine küsimus-vastus süsteem, mis kasutab Retrieval-Augmented Generation (RAG) lähenemist ning vähendab suurte keelemodelite hallutsinatsioonide mõju. Töö lähtub probleemist, et üksnes mudeli parameetritesse talletatud teadmistest ei piisa kiiresti muutuvate või organisatsioonispetsiifiliste dokumentide kohta usaldusväärsete vastuste andmiseks. Eriti oluline on see olukordades, kus vastus peab põhinema selgelt tuvastatavatel allikatel ja olema hiljem kontrollitav.

Töö meetodiks on kirjanduse analüüs ja kavandav süntees. Läbi vaadatakse suurte keelemodelite, tihevektorotsingu, mitmekeelsete lausestusmodelite ja RAG-arhitektuuride põhialused ning nende põhjal tuletatakse välja eestikeelse süsteemi jaoks sobivad arhitektuurilised valikud. Eraldi käsitletakse dokumentide tükeldamist, metaandmete säilitamist, hübriidotsingut, allikaviidete näitamist ning süsteemi hindamist.

Töö tulemusena sõnastatakse funktsionaalsed ja mittefunktsionaalsed nõuded eestikeelsele dokumentide põhisele küsimus-vastus süsteemile, pakutakse välja kihiline arhitektuur ning koostatakse hindamisraamistik, mis hõlmab nii otsingukihi, genereerimiskihi kui ka kasutuskogemuse mõõdikuid. Töö järeldab, et eestikeelses kontekstis on praktiline eelistada hübriidset otsingut, mitmekeelset sisuvektorite mudelit, allikapõhist vastusevormingut ja regulaarset teadmuspõhja uuendamist. Selline lahendus ei kõrvalda hallutsinatsioonide riski täielikult, kuid muudab süsteemi läbipaistvamaks, ajakohastatavamaks ja paremini hinnatavaks.

Võtmesõnad: retrieval-augmented generation, suur keelemudel, küsimus-vastus süsteem, infootsing, eesti keel

CERCS: P175 Informaatika, süsteemiteooria

Designing an Estonian RAG-Based Question Answering System

Abstract:

The aim of this bachelor's thesis is to analyse how to design an Estonian document-grounded question answering system that uses Retrieval-Augmented Generation (RAG) while reducing the impact of hallucinations produced by large language models. The work starts from the observation that knowledge stored only in model parameters is insufficient for answering questions about rapidly changing or organisation-specific documents. In such settings, answers must be grounded in identifiable sources and remain auditable.

The thesis uses literature analysis and design-oriented synthesis as its method. It reviews the foundations of large language models, dense retrieval, multilingual sentence embedding models, and RAG architectures, and derives architectural choices that are suitable for an Estonian-language system. Special attention is given to document chunking, metadata preservation, hybrid retrieval, citation-based answer formatting, and system evaluation.

The main outcome of the thesis is a set of functional and non-functional requirements for an Estonian document-grounded question answering system, a layered architecture proposal, and an evaluation framework covering retrieval quality, answer quality, grounding, and usability. The thesis concludes that in the Estonian context it is practical to prefer hybrid retrieval, multilingual embedding models, source-grounded answer generation, and regular knowledge base updates. Such an approach does not eliminate hallucinations entirely, but it makes the system more transparent, maintainable, and measurable.

Keywords: retrieval-augmented generation, large language model, question answering system, information retrieval, Estonian language

CERCS: P175 Informatics, systems theory

Sisukord

1. Sissejuhatus	7
2. Teoreetiline taust.....	9
2.1 Suurte keelemudelite areng	9
2.2 Parameetriline teadmine ja hallutsinatsioonid	10
2.3 Infootsingu peamised lähenemised	10
2.4 Retrieval-Augmented Generation.....	13
2.5 Pikk kontekst, tükeldamine ja konteksti valik	13
2.6 Eestikeelne kontekst.....	14
2.7 Peatüki kokkuvõte	15
3. Seotud tööd	16
3.1 Avatud domeeni küsimus-vastus süsteemid	16
3.2 Retrieval-augmented süsteemid dokumentide ja teadmuspõhjade jaoks	16
3.3 Otsingumudelite hindamine ja nullülekanodega kasutus	17
3.4 Päringu ümberkujundamine ja hüpoteetilised dokumendid	17
3.5 Hallutsinatsioonide vähendamine ja enesekriitilised RAG-lahendused.....	18
3.6 Pikakontekst ja allikaviidetega vastused	18
3.7 Järeldused seotud töödest	18
4. Kasutusjuhtumid ja nõuded	20
4.1 Kasutuskontekst	20
4.2 Sidusrühmad.....	20
4.3 Peamised kasutusjuhtumid.....	21
4.4 Funktsionaalsed nõuded	22
4.5 Mittefunktsionaalsed nõuded.....	22
4.5.1 Keel ja terminoloogia	22
4.5.2 Töökindlus ja latentsus.....	22
4.5.3 Auditijälg	23
4.5.4 Hooldatavus.....	23
4.5.5 Turve ja ligipääsuõigused	23
4.6 Edu kriteeriumid.....	23
4.7 Peatüki kokkuvõte	24
5. Süsteemi arhitektuur.....	25
5.1 Arhitektuuri üldpilt	25

5.2	Dokumentide kogumine ja eeltöötlus	25
5.3	Tükeldamine ja metaandmed.....	26
5.4	Indekseerimine	27
5.5	Päringu analüüs	27
5.6	Hübriidotsing.....	28
5.7	Ümberjärjestamine ja konteksti koostamine	28
5.8	Vastuse genereerimine	29
5.9	Usaldussignaalid ja keeldumismehhanism	29
5.10	Jälgimine ja operatiivne haldus	29
5.11	Peatüki kokkuvõte	30
6.	Hindamisraamistik ja juurutusplaan.....	31
6.1	Miks tuleb hinnata eraldi süsteemi eri kihte.....	31
6.2	Hindamiskorpuse koostamine.....	31
6.3	Otsingukihi mõõdikud	32
6.4	Lõppvastuse hindamine.....	33
6.5	Kasutajatestid.....	33
6.6	Ablatsioonid ja võrdlused	34
6.7	Juurutusplaan.....	34
6.8	Piirangud hindamisel	34
6.9	Peatüki kokkuvõte	35
7.	Arutelu	36
7.1	Miks ei piisa ainult paremast keelemudelist.....	36
7.2	Täpsuse ja latentsuse kompromiss	36
7.3	Eestikeelse konteksti tugevused ja piirangud	37
7.4	Allikapõhisus kui kasutajaliidese küsimus	37
7.5	Õiguslikud ja eetilised küsimused	37
7.6	Millal on kavandatud arhitektuur üleliia keerukas.....	38
7.7	Tulevase töö olulisemad suunad.....	38
7.8	Peatüki kokkuvõte	38
8.	Kokkuvõte.....	40
	Viited.....	42
	Lisad	45
	Lisa 1. Süsteemi nõuete koondtabel.....	45

Lisa 2. Soovituslik hindamiskorpuse struktuur.....	46
Litsents	47

1. Sissejuhatus

Suurte keelemodelite kiire areng on muutnud loomulikus keeles suhtlevad tarkvarasüsteemid tavapäraseks osaks nii õppetöös, ettevõtluses kui ka avalikes teenustes. Transformer-arhitektuuri kasutuselevõtt lõi tehnilise aluse mudelitele, mis suudavad töödelda pikki sisendeid, õppida üldisi keelemustreid ning genereerida veenva sõnastusega vastuseid [1]. Samal ajal on üha selgemaks saanud, et sorav vastus ei võrdu tingimata õige vastusega. Kui mudel vastab organisatsiooni sise-eeskirjade, juhendite või muude muutuvate dokumentide põhjal, on vaja mehhanismi, mis seob vastuse kontrollitava allikaga.

Üks suurte keelemodelite keskseid probleeme on hallutsinatsioon: mudel võib genereerida sisuliselt veenva, kuid allikatega toetamata või lausa vale väite [2]. See risk muutub eriti oluliseks küsimus-vastus süsteemides, mille kasutaja eeldab praktilist ja usaldusväärset infot. Retrieval-Augmented Generation ehk RAG on levinud lähenemine, mille puhul ühendatakse keelemudeli genereerimisvõime välisest teadmuspõhjast otsitud tekstilõikudega [3]. Nii muutub süsteem ajakohastatavamaks: dokumentide muutumisel ei pea tingimata ümber õpetama tervet mudelit, vaid piisab teadmuspõhja uuendamisest.

Käesolev töö keskendub eestikeelsele dokumentide põhisele küsimus-vastus süsteemile. Eesti keele ja väiksema mahuga valdkondlike korpuste tõttu ei ole mõistlik eeldada, et ainult mudeli eeltreenitud teadmistest piisab kvaliteetse teenuse pakkumiseks. Kirjanduse põhjal võib järeldada, et just mitmekeelsed sisuvektorid, läbimõeldud dokumentide tükeldamine, hübriidotsing ning selged vastuse genereerimise reeglid on väiksema ressursiga keele puhul praktiliselt tähtsad arhitektuurilised valikud [4, 5]. Seega on töö peamine fookus mitte üksiku mudeli võrdlemisel, vaid tervikliku süsteemikavandi koostamisel.

Töö eesmärk on analüüsida RAG-lahenduste teaduskirjandust ning selle põhjal kavandada eestikeelse dokumentide põhise küsimus-vastus süsteemi arhitektuur, mis oleks läbipaistev, ajakohastatav ja hinnatav. Eesmärgi täitmiseks püstitatakse kolm uurimisküsimust:

1. Millised RAG-süsteemi komponendid on eestikeelse dokumentide põhise küsimus-vastus lahenduse jaoks kriitilised?
2. Kuidas kavandada süsteem nii, et vastused oleksid seotud konkreetsete allikatega ja teadmuspõhja saaks uuendada ilma keelemudelit ümber õpetamata?
3. Millise hindamisraamistiku abil saab hinnata nii otsingu kvaliteeti, vastuste korrektsust kui ka allikapõhisust?

Metoodiliselt on tegu kavandava ja sünteesiva tööga. Esmalt antakse peatükis 2 ülevaade suurte keelemudelite, hallutsinatsioonide, RAG-lahenduste ning vektorotsingu tehnilisest taustast. Seejärel sõnastatakse peatükis 5 eestikeelse süsteemi nõuded ja pakutakse välja kihiline arhitektuur koos põhjendatud komponentvalikutega. Peatükis 6 kirjeldatakse hindamisraamistikku, käsitletakse peamisi riske ning esitatakse edasise töö suunad. Töö lõpetab peatükk 8, lisades on koondatud nõuete tabel ja soovituslik hindamiskorpuse struktuur.

Töö tulemuseks ei ole valmis tootmiskeskkonnas kasutusele võetud teenus, vaid põhjendatud süsteemikavand. Selline fookus on bakalaureusetöö kontekstis sobiv, sest võimaldab siduda teoreetilise ülevaate praktiliste arhitektuursete otsustega ning jätta järgneva arendustöö jaoks selge lähtealuse.

2. Teoreetiline taust

Käesoleva töö keskmes on küsimus, kuidas ühendada suurte keelemudelite loomuliku keele töötlemise võimekus klassikaliste infootsingu põhimõtetega nii, et kasutaja saaks eestikeelsele küsimusele põhjendatud vastuse. Selleks tuleb mõista vähemalt nelja omavahel seotud valdkonda: suurte keelemudelite arengut, hallutsinatsioonide probleemi, dokumentide otsimise tehnikaid ning Retrieval-Augmented Generation lahenduste kujunemist. Käesolevas peatükis avatakse need teemad järk-järgult ja seotakse need eestikeelse küsimus-vastus süsteemi kontekstiga.

2.1 Suurte keelemudelite areng

Kaasaegsete keelemudelite tehniline lähtekoht on transformer-arhitektuur, mille põhielement on tähelepanumehhanism. Vaswani jt näitasid, et tähelepanu abil on võimalik töödelda järjestikandmeid ilma rekurrentsete võrkude piiranguteta ning säilitada samal ajal võime modelleerida pikki sõltuvusi [1]. See muutis keelemudelite treenimise paremini paralleliseeritavaks ja pani aluse väga suure mastaabiga mudelite arengule.

Transformeri esimesed laialt mõjukad rakendused loomuliku keele töötluses keskendusid representatsioonidele. BERT näitas, et kahesuunaliselt eeltreenitud mudelid võimaldavad luua tugevaid üldkasutatavaid tekstiesitusi mitmesuguste ülesannete jaoks [6]. Hiljem nihkus tähelepanu järjest enam generaatoritele. Brown jt töö GPT-3 kohta demonstreeris, et piisavalt suure parameetrite arvuga autoregressiivne mudel võib täita hulgaliselt ülesandeid üksnes juhiste ja näidete abil, ilma eraldi peenhäälestamiseta [7]. See muutis keelemudelid praktiliseks üldotstarbeliseks liideseks, millele saab anda loomulikus keeles kirjeldatud ülesandeid.

Järgmine oluline samm oli juhiste järgimise parandamine. Ouyang jt näitasid, et inimtagasiside abil õpetatud mudelid on kasutaja eesmärkidega paremini kooskõlas ning annavad kasulikumaid vastuseid kui puhtalt järgmise sõna ennustamise eesmärgil treenitud mudelid [8]. See areng on oluline ka käesoleva töö jaoks. Dokumentide põhine küsimus-vastus süsteem ei vaja lihtsalt teksti genereerivat mudelit, vaid mudelit, mis järgib ranget juhust: vastata ainult etteantud allikate põhjal, viidata kasutatud lõikudele ning tunnistada teadmiste puudumist.

Praktilisest vaatepunktist tähendab suurte keelemudelite areng seda, et süsteemi kasutajaliides võib olla loomuliku keele põhine. Kasutaja ei pea teadma, kuidas dokumente otsitakse, millises indeksis need asuvad või kuidas neid järjestatakse. Samas loob sama areng ka probleemi: mida veenvam on mudeli väljund, seda raskem on kasutajal eristada õigesti põhjendatud vastust oskuslikult sõnastatud veast.

2.2 Parameetiline teadmine ja hallutsinatsioonid

Suur keelemudel talletab eeltreenimise käigus parameetrilist teadmist. See tähendab, et osa keelelistest ja faktilistest seostest on mudeli kaaludes hajusalt esindatud ning seda saab aktiveerida küsimusele vastamisel. Selline teadmine on kasulik üldise maailmateadmise, lauseloome ja mõistete seoste jaoks, kuid sellel on mitu piirangut. Esiteks ei ole parameetiline teadmine kasutaja jaoks läbipaistev. Teiseks ei ole see hõlpsasti ajakohastatav. Kolmandaks ei saa eeldada, et see sisaldab organisatsioonispetsiifilisi või kiiresti muutuvaid andmeid.

Hallutsinatsioonina käsitletakse olukorda, kus mudel genereerib faktiliselt vale, allikatega toetamata või sisendiga vastuolus oleva väite [2]. Probleem ei seisne ainult üksikutes faktivigades, vaid kogu vastuse põhjendatavuses. Kui kasutaja küsib näiteks õppekorralduse, turvapoliitika või sisemise tööjuhendi kohta, siis ei ole oluline üksnes vastuse sõnastus, vaid ka see, kas vastuse taga on konkreetne kehtiv dokument.

Qi jt rõhutavad, et hallutsinatsioonide hindamine on mitmetasandiline: arvesse tuleb võtta nii faktilisust, allikapõhisust, sisendile vastavust kui ka seda, kas süsteem oskab vajadusel keelduda [9]. Sellest vaatenurgast ei saa kvaliteetset küsimus-vastus süsteemi käsitleda ainult generatiivse mudeli probleemina. Vajalik on arhitektuur, mis piirab mudeli loominguilisust seal, kus kasutaja ootab dokumenteeritud vastust.

Tabel 1 võtab kokku põhjuse, miks dokumentide põhise küsimus-vastus süsteemi jaoks ei piisa ainult keelemudelist. Vajalik on ühendada mudeli loomuliku keele võimekus välise teadmuspõhjaga, mida saab hallata, kontrollida ja uuendada.

2.3 Infootsingu peamised lähenemised

Dokumentide põhine küsimus-vastus süsteem peab enne vastuse genereerimist leidma küsimusega seotud tekstilõigud. Selle ülesande lahendamiseks kasutatakse infootsingut. Klassikaline infootsing tugineb leksikaalsetele signaalidele: sõnade kattuvusele, haruldusele ja esinemissagedusele. Praktikas on BM25 tüüpi järjestusmudelid endiselt tugev lähtejoon, sest nad toimivad hästi juhtudel, kus kasutaja kasutab dokumentidega samu termineid, lühendeid või koode.

Leksikaalse otsingu peamine piirang ilmneb siis, kui küsimus ja vastust sisaldav dokument kasutavad eri sõnastust. Näiteks võib kasutaja küsida “Kuidas võtta akadeemilist puhkust?”, kuid dokument räägib “õppetöö katkestamisest mõjuval põhjusel”. Sellistel juhtudel võib märksõnapõhine otsing jääda nõrgaks, kuigi sisuline seos on olemas.

Tabel 1. Parameetrilise teadmise ja välise teadmuspõhja peamised erinevused.

Omadus	Parameetriline teadmine	Väline teadmuspõhi
Uuendatavus	Vajab sageli uut treenimist või peenhäälestamist.	Dokumendi lisamisest või indeksi uuendamisest võib piisata.
Läbipaistvus	Vastuse allikas ei ole otseselt nähtav.	Kasutatud lõigud ja metaandmed saab kasutajale näidata.
Sobivus organisatsioonilistele dokumentidele	Nõrk, sest spetsiifilised teadmised võivad puududa.	Tugev, kui vastavad dokumendid on süsteemi sisestatud.
Risk hallutsineerida	Kõrgem, sest vastus võib tugineda ainult mudeli sisemisele hinnangule.	Madalam, kui süsteem nõuab allikaga toetatud vastust.

Tihevektorotsing püüab seda piirangut ületada, teisendades küsimused ja dokumendilõigud vektorruumi, kus semantiliselt sarnased tekstid paiknevad teineteisele lähemal. Karpukhin jt näitasid, et Dense Passage Retrieval suudab avatud domeeni küsimus-vastus ülesandes ületada tugevaid leksikaalseid lähtejooni [10]. Reimers ja Gurevych pakkusid Sentence-BERTi, mis muutis lausete ja lõikude semantilise võrdlemise praktiliselt teostatavaks [11]. Mitmekeelses kasutuses on oluline, et mudel asetaks sama tähendusega laused eri keeltes sarnasesse ruumi. Selleks on sobivaks näiteks LaBSE [5].

Pelgalt tihevektorotsing ei lahenda siiski kõiki probleeme. Kui küsimus sisaldab täpset dokumendinime, käskluse lühendit või versioonitähist, võib leksikaalne vaste olla semantilisest otsingust usaldusväärsem. Seetõttu on praktikas levinud hübriidotsing, kus ühendatakse

märksõnapõhine ja tihevektoritel põhinev järjestamine. Hübriidsetes süsteemis saab ühelt poolt säilitada terminoloogilise täpsuse ja teiselt poolt katta ümberütlused ning kasutaja loomulikud sõnastusvariandid.

Lisaks esimese astme otsingule kasutatakse sageli ümberjärjestamist ehk reranking'ut. Nogueira ja Cho näitasid, et BERT-põhine passage reranker võib esialgselt leitud kandidaatide seast märkimisväärselt parandada õigete lõikude järjekorda [12]. Teine oluline suund on hilise interaktsiooni mudelid, näiteks ColBERT, mis tasakaalustavad tõhusust ja täpsust, võrreldes küsimust ja dokumenti detailsemalt kui tavaline dual-encoder [13]. Sellised lahendused on eriti huvitavad siis, kui küsimused on mitmetähenduslikud ja vastuse leidmine sõltub peenematest tekstilistest seostest.

Tabel 2. Peamised dokumentide otsimise lähenemised ja nende sobivus.

Lähenemine	Eelis	Tüüpiline piirang
Leksikaalne otsing	Tugev täpsete terminite, koodide ja nimede leidmisel.	Ei taba hästi sünonüüme ega ümberütlusi.
Tihevektorotsing	Tuvastab semantilisi vasteid ka erineva sõnastuse korral.	Võib eksida väga spetsiifilise terminoloogia või versioonimärkide puhul.
Hilise interaktsiooni otsing	Säilitab rohkem tokeni tasandi infot kui lihtne dual-encoder.	Keerukam teostada ja arvutuslikult kulukam.
Reranking	Parandab kandidaatide lõplikku järjestust.	Vajab head esmast kandidaatide valikut ja lisaarvutust.
Hübriidotsing	Ühendab leksikaalse täpsuse ja semantilise paindlikkuse.	Vajab kaalude, filtrite ja järjestusreeglite häälestamist.

Tabel 2 rõhutab, et küsimus-vastus süsteemi otsingukiht ei ole üksik algoritm, vaid tavaliselt mitmest komponendist koosnev toru. Käesolevas töös lähtutakse seetõttu eeldusest, et eestikeelses dokumendikeskkonnas on kõige praktilisem hübriidne lahendus, millele lisandub vähemalt kerge ümberjärjestus.

2.4 Retrieval-Augmented Generation

Retrieval-Augmented Generation ehk RAG ühendab infootsingu ja tekstigeneratsiooni. Lewis jt defineerisid RAG-lähenemise kui mehhanismi, kus generatiivne mudel kasutab vastuse koostamisel välisest mälust leitud dokumente [3]. Süsteemi töövoog on intuiitiivne: kasutaja küsimusele leitakse esialgu sobivad dokumendilõigud, need esitatakse keelemudelile kontekstina ning mudel koostab nende põhjal vastuse.

Oluline on märkida, et RAG ei ole üks konkreetne algoritm, vaid arhitektuuripere. Kõige lihtsamal kujul kasutatakse “naive RAG” lahendust, kus küsimuse jaoks leitakse mõned lõigud ja need paigutatakse otse viibesse. Praktilistes süsteemides lisatakse sellele sageli täiendavaid kihte: päringu ümberkirjutamine, metaandmete põhine filtreerimine, kandidaatide ümberjärjestamine, vastuse kvaliteedi enesehindamine või isegi järelotsing.

Viimastel aastatel on kirjanduses ilmunud mitmeid keerukamaid RAG-mustreid. Gao jt koondavad oma ülevaates mitmeastmelised arhitektuurid, hübriidotsingu, teadmuspõhja iteratiivse kasutamise ning konteksti kontrollimise mehhanismid [4]. Asai jt Self-RAG lisab mudelile võime reflekteerida, millal tuleks veel otsida ja kuidas omaenda väljundit kritiseerida [14]. Yan jt Corrective RAG käsitleb olukorda, kus esialgne otsing ei ole piisavalt kvaliteetne, ning püüab tuvastada, millal tuleb otsingut parandada või laiendada [15]. Need tööd näitavad, et RAG-süsteemi kvaliteet sõltub suurel määral sellest, kui hästi süsteem suudab hinnata omaenda tõendusmaterjali piisavust.

Kasutaja küsimus → päringu analüüs → kandidaatide otsing → ümberjärjestamine ja filtreerimine → konteksti koostamine → vastuse genereerimine → viidete kuvamine → kvaliteedisignaali salvestamine
--

Joonis 1. RAG-lahenduse üldine töövoog.

Joonisel 1 esitatud töövoog rõhutab, et RAG-süsteemis ei piisa ainult otsingust ja genereerimisest. Vajalikud on ka vahekihid, mis filtreerivad, struktureerivad ja hindavad leitud konteksti. Mida rangem on süsteemi nõue näidata põhjendatud vastust, seda tähtsamaks muutuvad need vahekihid.

2.5 Pikk kontekst, tükeldamine ja konteksti valik

Esmapilgul võib tunduda, et RAG-probleemi saab lahendada lihtsalt väga suure kontekstiaknaga mudeli abil: kui mudel suudab lugeda palju teksti korraga, võiks talle anda terve dokumendikogu. Praktikas see lähenemine hästi ei toimi. Esiteks on suure konteksti töötlemine arvutuslikult kallis.

Teiseks ei kasuta mudel pikka konteksti ühtlaselt hästi. Liu jt näitasid, et pikakontekstilised mudelid kalduvad tähelepanuga eelistama sisendi algust ja lõppu ning võivad “kaotada” olulise info keskel asuvates lõikudes [16]. Seda nähtust tuntakse nime all *lost in the middle*.

Seetõttu on dokumentide tükeldamine RAG-süsteemi jaoks keskne projekteerimisotsus. Liiga lühikesed lõigud vähendavad semantilist terviklikkust ja muudavad vastuse jaoks vajaliku konteksti killustatuks. Liiga pikad lõigud suurendavad omakorda müra ja võivad vähendada täpsust, sest ühes lõigus on mitu eri teemat. Praktikas on mõistlik tükeldada dokumente loomulike struktuuriüksuste alusel: peatükid, alapeatükid, lõigud, loetelud või tabeli read. Sageli lisatakse väike kattuvus, et vältida olulise lause katkemist kahe lõigu vahel.

Tükeldamise otsus on seotud ka konteksti valikuga. Kui generaatorile antakse liiga palju lõike, kasvab vastuolude ja dubleerimise oht. Kui antakse liiga vähe lõike, ei pruugi vastuse jaoks piisata tõendusmaterjalist. Seetõttu tuleb otsustada mitte ainult see, kuidas dokumenti lõigata, vaid ka see, mitu lõiku, millises järjekorras ja milliste metaandmetega mudelile esitada. See küsimus mõjutab otseselt vastuse kvaliteeti.

2.6 Eestikeelne kontekst

Eesti keel seab küsimus-vastus süsteemile lisaväljakutseid. Tegemist on morfoloogiliselt rikka keelega, kus sama tüvi võib esineda paljudes käändevormides ja kus liitsõnad kannavad palju semantilist infot. Seetõttu ei saa eeldada, et ingliskeelsete süsteemide jaoks sobivad otsingureeglid või tokeniseerimisotsused töötavad muutmata kujul ka eesti keeles.

Üks võimalik lähtepunkt on keelespetsiifilised mudelid. EstBERT näitab, et eesti keele jaoks eeltreenitud BERT-tüüpi mudelid suudavad tabada keele eripärasid paremini kui täiesti keeleagnostilised lähtejooned [17]. Samal ajal on paljud organisatsioonilised dokumendid osaliselt mitmekeelsed: tekst võib olla eesti keeles, kuid sisaldada ingliskeelseid termineid, tootenimesid või tehnilisi lühendeid. Seetõttu on praktilises süsteemis sageli kasulik kasutada kas tugevat mitmekeelset mudelit või kombineerida keelespetsiifilisi ja mitmekeelseid komponente.

Eestikeelne kontekst toob kaasa ka andmestikulise väljakutse. Võrreldes inglise keelega on avalikult kättesaadavaid suuri hindamiskorpuseid vähem. See tähendab, et süsteemi arendaja peab sageli ise koostama testküsimused, eksperthinnangud ja referentsvastused. Käesolev tähelepanek on oluline kogu töö jaoks: arhitektuur ei saa olla edukas, kui puudub realistlik plaan selle hindamiseks ja hilisemaks parendamiseks.

2.7 Peatüki kokkuvõte

Käesolevas peatükis näidati, et dokumentide põhise küsimus-vastus süsteemi tehniline alus koosneb mitmest kihist. Suured keelemudelid annavad süsteemile loomuliku väljendusvõime ja juhiste järgimise võime. Hallutsinatsioonide probleem muudab aga vajalikuks välise teaduspõhja kasutamise. Infootsing pakub mehhanismi asjakohaste lõikude leidmiseks, RAG-lähenemine seob need lõigud generatiivse mudeli väljundiga ning eestikeelne kontekst lisab vajaduse arvestada väiksema ressursibaasi ja keele struktuuriliste eripäradega.

Sellest teoreetilisest taustast lähtuvalt saab järgmises peatükis vaadelda, milliseid sarnaseid probleeme on teaduskirjanduses juba lahendatud ning milliseid järeldusi saab neist teha eestikeelse süsteemi kavandamiseks.

3. Seotud tööd

Teoreetilise tausta kõrval on oluline vaadata, kuidas sarnaseid probleeme on lahendatud varasemates teadustöödes. Käesoleva töö jaoks on eriti olulised neli suunda: avatud domeeni küsimus-vastus süsteemid, dokumendipõhised assistendid, otsingumudelite hindamine ning hallutsinatsioonide vähendamise meetodid. Need suunad aitavad mõista, millised arhitektuurilised otsused on ennast praktikas õigustanud ja millised probleemid jäävad ka tänapäevaste süsteemide puhul lahendamata.

3.1 Avatud domeeni küsimus-vastus süsteemid

RAG-lahenduste vahetu teaduslik eelkäija on avatud domeeni küsimus-vastus süsteem. Selle eesmärk on vastata kasutaja küsimusele suurest dokumendikogust, enamasti Wikipedia-laadsest korpusest. Karpukhin jt DPR ja Izacard ning Grave generatiivse avatud domeeni küsimus-vastus mudel näitavad, et vastuse kvaliteet sõltub otseselt sellest, kui hästi süsteem toob esile õiged lõigud juba esimeses otsinguetapis [10, 18].

Avatud domeeni ülesannetes on teadmuspõhi suhteliselt ühtlane, suur ja avalik. Organisatsiooniliste dokumentide puhul on olukord teistsugune. Dokumente on vähem, need võivad olla eri vormingutes, nende versioonid muutuvad kiiresti ning kasutaja ootab mitte lihtsalt tõenäolist vastust, vaid kontrollitavat vastust. Sellest hoolimata saab avatud domeeni kirjandusest tuletada kaks olulist järeldust. Esiteks peab otsingukiht olema käsitletud kui süsteemi tuumik, mitte abifunktsioon. Teiseks peab vastuse kvaliteedi hindamisel eristama otsingu- ja genereerimisvigu.

3.2 Retrieval-augmented süsteemid dokumentide ja teadmuspõhjade jaoks

Kui avatud domeeni küsimus-vastus keskendub suurtele üldotstarbelistele korpustele, siis dokumentide põhised assistendid töötavad enamasti piiratud teadmuspõhjaga. Tüüpilised kasutuskohad on siseveebid, juhendibaasid, õppekorraldusdokumendid, klienditoe teadmuskogud ja tehniline dokumentatsioon. Selliste süsteemide eesmärk ei ole demonstreerida mudeli üldteadmist, vaid vähendada kasutaja otsingukulu ja aidata tal jõuda allikani kiiremini kui käsitsi dokumentides surfates.

Kirjanduses on selle probleemiklassi puhul esile kerkinud kolm püsivat mustrit. Esiteks tuleb dokumente käsitleda versioonitundlikult: sama dokument võib olla eri aegadel eri sisuga

ning süsteem peab teadma, milline versioon on kehtiv. Teiseks muutuvad metaandmed sama tähtsaks kui tekst ise, sest kasutaja võib soovida vastust ainult teatud osakonna, kuupäeva või dokumenditüübi piires. Kolmandaks on eriti oluline vastuse allikapõhine vorming. Praktikas ei soovi kasutaja sageli ainult lühikest vastust, vaid ka teavet selle kohta, millisest dokumendist ja millisest jaotisest vastus pärineb.

Sellest seisukohast on dokumentide põhine RAG-süsteem pigem teadmushalduse ja infootsingu hübriid kui puhas generatiivne rakendus. Süsteemi edukus sõltub seega sama palju sisuhaldusest, dokumentide elutsüklist ja ligipääsuõigustest kui keelemudeli valikust.

3.3 Otsingumudelite hindamine ja nullülekandega kasutus

Kuna käesolev töö keskendub eestikeelsele süsteemile, on oluline vaadata töid, mis käsitlevad otsingumudelite üldistuvust väljaspool treeningdomeeni. Thakur jt koostatud BEIR on selles mõttes oluline benchmark, sest see näitab, et ühe andmestiku peal hästi töötav otsingumudel ei pruugi toimida sama hästi väga erineva ülesande või tekstitüübi puhul [19]. See tähelepanek on otseselt rakendatav ka eestikeelse organisatsioonilise dokumentatsiooni puhul: ei saa eeldada, et ingliskeelsete veebitekstide peal häälestatud lahendus töötab muutmata kujul hästi siserikkumiste juhendite või õppekorralduseeskirjade peal.

Sarnast mõtet toetab ka tekstiesituste hindamise kirjandus. Muennighoff jt MTEB rõhutab, et embedding-mudelite kvaliteeti tuleb vaadelda erinevate ülesannete lõikes, mitte ainult ühel kitsal benchmark'il [20]. Selle põhjal saab järeldada, et eestikeelse süsteemi jaoks ei ole mõistlik valida vektorimudelit ainult populaarsuse järgi. Mudeli sobivust tuleb hinnata konkreetse dokumenditüübi, küsimuste laadide ja keelelise segu põhjal.

3.4 Päringu ümberkujundamine ja hüpoteetilised dokumendid

Üks oluline uurimissuund viimaste aastate RAG-süsteemides on päringu parandamine enne otsingut. Kasutaja küsimus ei pruugi olla kujul, mis otsingusüsteemile kõige rohkem kasulik on. Mõnikord on küsimus liiga lühike, sisaldab asesõnu või eeldab konteksti, mis on dokumentides väljendatud teistsuguste terminitega. Seetõttu kasutatakse päringu ümberkirjutamist, laiendamist või isegi hüpoteetilise vastusdokumendi genereerimist.

Gao jt töö HyDE kohta näitab, et nullülekandega tiheotsingus võib kasu olla sellest, kui küsimuse põhjal genereeritakse kõigepealt hüpoteetiline dokument ja otsing viiakse läbi selle esinduse abil [21]. Selline lähenemine võib olla eriti kasulik olukordades, kus kasutaja küsimus on lühike, kuid vastav dokument kasutab märksa formaalsemat stiili. Käesoleva töö seisukohalt ei tähenda

see, et päringu ümberkirjutamine oleks alati vajalik, kuid see näitab, et RAG-lahenduse kvaliteeti saab parandada ka enne otsinguetappi, mitte ainult pärast seda.

3.5 Hallutsinatsioonide vähendamine ja enesekriitilised RAG-lahendused

Traditsiooniline RAG eeldab, et kui süsteem leiab piisavalt head lõigud, suudab keelemudel anda õige vastuse. Seotud tööde põhjal on see eeldus liiga optimistlik. Mudel võib kasutada leitud lõike valikuliselt, tõlgendada neid liiga vabalt või ühendada omavahel vastuolulist infot. Seetõttu on hilisemates töödes keskendutud mehhanismidele, mis kontrollivad, kas kontekst on piisav ja kas mudeli väljund on allikatega kooskõlas.

Self-RAG laiendab süsteemi refleksiivse käitumisega: mudel õpib otsustama, millal tuleks täiendavalt otsida, millal kriitiliselt hinnata omaenda vastust ning millal kasutajale tagasi anda ettevaatlikum tulemus [14]. Corrective RAG lähtub sarnasest ideest, kuid rõhutab otsingutulemuste kvaliteedi hindamist ja vajadusel uue otsingu käivitamist [15]. Mõlemad tööd on käesoleva bakalaureusetöö jaoks olulised mitte sellepärast, et sama keerukat arhitektuuri peaks ilmentingimata kohe rakendama, vaid seetõttu, et nad näitavad selgelt: kvaliteetne RAG-süsteem ei ole lineaarne toru, vaid tagasisidestatud protsess.

3.6 Pikakontekst ja allikaviidetega vastused

Seotud tööde hulka kuuluvad ka uuringud, mis käsitlevad pikka konteksti ja vastuste viidatavust. Liu jt tulemused pikakontekstiga mudelite kohta viitavad sellele, et ainult suuremaks kasvatatud kontekstiaken ei taga paremat põhjendatust [16]. Kui oluline lõik asub konteksti keskel või kui mudelile antud lõigud on omavahel nõrgalt seotud, võib väljund ikkagi kannatada.

Praktiline järeldus on, et kasutajale näidatav vastus peaks olema viidatud. Allikaviited ei ole ainult kasutajamugavus, vaid ka kvaliteedikontrolli instrument. Kui süsteem esitab vastuse koos dokumendi nime, jaotise või lõigu viitega, saab kasutaja vastust kontrollida. Samal ajal saab arendaja tuvastada, kas viga tekkis vales otsingus või vales tõlgenduses. Seotud töödest joonistub seega välja tugev konsensus: allikapõhisus peab olema nähtav, mitte peidetud süsteemi sisemisse töölogisse.

3.7 Järeldused seotud töödest

Seotud tööd toetavad käesoleva töö põhiteesi mitmel tasandil. Avatud domeeni küsimus-vastus kirjandus näitab, et otsingukihi kvaliteet on kriitiline. Nullülekande benchmark'id rõhutavad,

et mudelite headus sõltub kasutuskontekstist. Hallutsinatsioonide vähendamise tööd osutavad, et usaldusväärne RAG-süsteem vajab enesekontrolli ja keeldumismehhanisme. Pikakonteksti käsitlev kirjandus kinnitab, et dokumentide mehaaniline “söötmine” mudelile ei asenda head konteksti valikut.

Nendest järeldustest lähtub ka järgmine peatükk, kus sõnastatakse eestikeelse dokumendipõhise küsimus-vastus süsteemi kasutusjuhtumid ja nõuded. Seotud tööde põhjal saab eeldada, et edukas lahendus peab ühendama hübriidotsingu, allikapõhise vastusevormingun ning hoolikalt läbimõeldud hindamise.

4. Kasutusjuhtumid ja nõuded

Pärast teoreetilise tausta ja seotud tööde ülevaadet saab täpsemalt sõnastada, millist probleemi käesolevas töös kavandatav süsteem lahendab. Nõuete määratlemine on eriti oluline, sest dokumentide põhiseid küsimus-vastus lahendusi saab projekteerida väga erinevate eelduste põhjal. Kui eesmärk on üldine juturobot, piisab enamasti lühikesest vastusest. Kui eesmärk on aga organisatsioonilise teadmuse kättesaadavaks tegemine kontrollitaval viisil, peavad nõuded olema rangemad.

4.1 Kasutuskontekst

Käesolevas töös eeldatakse süsteemi, mille teadmuspõhi koosneb organisatsioonis kasutatavatest tekstidokumentidest. Need võivad olla näiteks õppekorralduse juhendid, sise-eeskirjad, kasutusjuhendid, poliitikad, korduma kippuvate küsimuste vastused või tehnilise toe teadmuskogud. Kasutaja esitab küsimuse loomulikus keeles ja ootab vastust, mis:

1. on sisuliselt korrektne;
2. toetub olemasolevatele dokumentidele;
3. viitab kasutatud allikatele;
4. annab ebapiisava tõendusmaterjali korral ettevaatliku tulemuse.

Selline kasutuskontekst eristub vabast vestlusest. Süsteemi eesmärk ei ole pidada meeldivat dialoogi, vaid vähendada kasutaja ajakulu dokumentide leidmisel ja tõlgendamisel. Seetõttu tuleb süsteemi kvaliteeti hinnata teistsuguste kriteeriumide järgi kui tavapärase juturoboti puhul.

4.2 Sidusrühmad

Nõuete määratlemisel on kasulik eristada erinevaid sidusrühmi, sest nende ootused süsteemile ei ole samad. Käesolevas töös eristatakse nelja põhirühma:

- **Lõppkasutaja**, kes soovib saada kiiresti arusaadava vastuse ja jõuda vajadusel allikani.
- **Sisuomanik**, kes vastutab dokumentide ajakohasuse ja korrektsuse eest.
- **Süsteemi haldur**, kes vastutab indekseerimise, ligipääsuõiguste, logide ja töökindluse eest.
- **Organisatsiooniline vastutaja**, keda huvitavad riskid, vastutuse piirid, andmekaitse ja süsteemi kasutusreeglid.

Lõppkasutaja vaatest on oluline vastuse kiirus ja arusaadavus. Sisuomaniku jaoks on keskne küsimus see, kas süsteem kasutab kehtivaid dokumente ja kas vanad versioonid ei mõjuta vastuseid. Halduri jaoks on kriitilised töökindlus, uuendatavus ja logitavus. Organisatsioonilise vastutaja jaoks on oluline, et süsteem ei kuvaks kasutajale infot, millele tal puudub ligipääs, ega jäta ekslikult muljet, et mudeli toodetud tekst on ametlik otsus.

4.3 Peamised kasutusjuhtumid

Nõuete täpsustamiseks sõnastatakse kolm tüüpilist kasutusjuhtumit.

Kasutusjuhtum 1: otsene faktiküsimus. Kasutaja küsib konkreetse reegli või definitsiooni kohta, näiteks milline on avalduse esitamise tähtaeg või kus asub teatud süsteemi seadistus. Süsteem peab leidma ühe või paar dokumenti, kuvama lühikese vastuse ja lisama täpse viite.

Kasutusjuhtum 2: protseduuriline küsimus. Kasutaja küsib mitme sammuga tegevuse kohta, näiteks kuidas taotleda teenust, muuta õigusi või toimida erandolukorras. Sellisel juhul peab süsteem sünteesima vastuse mitmest dokumendilõigust, kuid säilitama allikaviited.

Kasutusjuhtum 3: vastuseta küsimus. Kasutaja küsib midagi, mida dokumentides ei ole või mida tal ei ole õigus näha. Süsteem peab suutma öelda, et ta ei leidnud piisavalt alust usaldusväärse vastuse andmiseks, ning võimalusel soovitada edasist sammu, näiteks pöördumist vastutava üksuse poole.

Tabel 3. Kasutusjuhtumite võrdlus süsteemi käitumise seisukohalt.

Kasutusjuhtum	Süsteemi põhiülesanne	Ebaõnnestumise peamine risk
Faktiküsimus	Leida üks täpne allikas ja esitada lühike vastus.	Vale või aegunud dokumendi kasutamine.
Protseduuriline küsimus	Ühendada mitu lõiku sidusaks vastuseks.	Osalise või vastuolulise protseduuri esitamine.
Vastuseta küsimus	Tuvastada info puudumine või ligipääsupiirang.	Hallutsineeritud vastus või keelatud info leke.

Tabel 3 näitab, et eri kasutusjuhtumid rõhutavad süsteemi eri omadusi. Faktiküsimused testivad täpset otsingut, protseduurilised küsimused testivad sünteesi ja allikapõhist genereerimist ning vastuseta küsimused testivad süsteemi võimet olla ettevaatlik.

4.4 Funktsionaalsed nõuded

Käesolevas töös tuletatakse funktsionaalsed nõuded nii seotud töödest kui ka kasutusjuhtumitest. Süsteem peab vähemalt:

1. ingestima erinevas vormingus dokumente ja teisendama need ühtsesse indeksitavasse kujusse;
2. säilitama dokumentide metaandmeid, sealhulgas pealkirja, versiooni, dokumenditüübi ja ligipääsuõiguse;
3. looma dokumendilõikude kohta nii leksikaalse kui tihevektoril põhineva indeksi;
4. leidma kasutaja küsimusele asjakohased lõigud;
5. kuvama vastuses kasutatud allikad;
6. oskama ebapiisava alusmaterjali korral vastamisest keelduda;
7. logima süsteemi töö olulised sammud hilisemaks analüüsiks.

Oluline on rõhutada, et “vastuse andmine” ei ole siin ainus funktsionaalne eesmärk. Sama oluline on allika esitamine. Kui süsteem annaks sisuliselt õige, kuid kontrollimatu vastuse, ei täidaks ta täielikult dokumentide põhise assistendi eesmärki.

4.5 Mittefunktsionaalsed nõuded

Lisaks funktsionaalsusele peab süsteem täitma rea mittefunktsionaalseid nõudeid. Need kujundavad lahenduse kasutatavust, töökindlust ja organisatsioonilist sobivust.

4.5.1 Keel ja terminoloogia

Süsteem peab toetama eesti keelt kogu töövoos. See tähendab, et kasutaja võib esitada küsimuse eesti keeles, dokumendid võivad olla valdavalt eesti keeles ning vastus tuleb esitada loomulikus ja grammatiliselt korrektses eesti keeles. Samal ajal tuleb arvestada ingliskeelsete terminite, toodete nimede ja lühenditega. Seega ei tohi süsteemi otsingukiht eeldada rangelt ükskeelset sisendit.

4.5.2 Töökindlus ja latentsus

Süsteem peab olema piisavalt kiire, et kasutaja kogeks seda interaktiivse tööriistana. Liiga aeglane vastus vähendab usaldust ja teeb kasutuskogemuse halvaks, isegi kui vastus ise on kvaliteetne. Samal ajal ei saa latentsuse vähendamine toimuda põhjendatuse arvelt. Seetõttu tuleb

arhitektuuris otsida tasakaalu: osa samme peab olema piisavalt kerge, kuid kõige riskantsemates olukordades peab süsteem olema valmis tegema lisakontrolli.

4.5.3 Auditijälg

Kuna süsteemi vastuseid võidakse kasutada töökorralduses või otsustusprotsessi toetamisel, peab süsteem jätma auditijälje. Vähemalt tuleb salvestada kasutaja küsimus, otsinguga leitud kandidaadid, lõppvastuse aluseks olnud lõigud, kasutatud süsteemiversioon ja ajaline märged. Auditijälg on oluline nii vigade analüüsimiseks kui ka süsteemi usaldusväärsuse tõendamiseks.

4.5.4 Hooldatavus

Dokumendid muutuvad ajas. Seetõttu peab süsteem toetama dokumentide lisamist, eemaldamist ja uuendamist ilma kogu mudeli ümberõppeta. Hooldatavus hõlmab ka seda, et dokumendi muutmisel oleks võimalik uuendada ainult mõjutatud indeksiosi, mitte kogu teadmuspõhja nullist. Mida suurem on dokumentide maht ja muutumise sagedus, seda tähtsamaks see nõue muutub.

4.5.5 Turve ja ligipääsuõigused

Organisatsioonilistes keskkondades ei ole kõik dokumendid avalikud. Süsteem peab arvestama kasutaja õigusi juba otsinguetapis, mitte ainult vastuse kuvamisel. Kui piiratud ligipääsuga dokument pääseb kandidaatide hulka, võib mudel selle sisu osaliselt lekita isegi siis, kui lõppvastuses otsest viidet ei näidata. Seetõttu tuleb ligipääsupiiranguid käsitleda RAG-lahenduse arhitektuuris esimese klassi nõudena.

4.6 Edu kriteeriumid

Kavandatava süsteemi edukust ei saa hinnata ainult ühe mõõdupuu põhjal. Käesolevas töös loetakse süsteemi edukaks, kui see suudab täita järgmised tingimused:

- kasutajale kuvatud vastused on enamasti õiged ja allikatega kooskõlas;
- kasutaja saab vastuse põhjal liikuda tagasi allikadokumendini;
- süsteem ei vasta enesekindlalt küsimustele, mille jaoks tal puudub piisav alus;
- dokumentide uuendamine ei nõua rasket ümberõpet;
- süsteemi toimimist saab logide põhjal hiljem analüüsida.

Need edu kriteeriumid seovad nõuded otseselt hindamisega. Järelikult ei saa nõudeid käsitleda lahus järgnevast arhitektuurist ja hindamisraamistikust; need moodustavad ühe terviku.

4.7 Peatüki kokkuvõte

Käesolevas peatükis sõnastati organisatsioonilise dokumentide põhise küsimus-vastus süsteemi kasutusjuhtumid, sidusrühmad ja peamised nõuded. Selgus, et süsteem peab ühendama kasutusmugavuse, allikapõhisuse, auditijälje, hooldatavuse ja ligipääsuõiguste toetuse. Need nõuded loovad piirangud ja suunised järgmisele peatükile, kus esitatakse detailsem tehniline arhitektuur.

5. Süsteemi arhitektuur

Käesolevas peatükis kirjeldatakse detailsemalt arhitektuuri, mis vastab eelmises peatükis sõnastatud kasutusjuhtumitele ja nõuetele. Kavandatud süsteem on kihiline. Selline jaotus aitab hoida eri vastutusvaldkonnad lahus ning võimaldab hiljem komponente iseseisvalt välja vahetada või täiendada. Samuti aitab kihiline arhitektuur siduda RAG-lahenduse mitte ainult keelemudeli, vaid kogu dokumentide elutsükli, otsingu ja kvaliteedikontrolliga.

5.1 Arhitektuuri üldpilt

Käesolevas töös pakutakse välja seitsmekihiline arhitektuur:

1. dokumentide kogumise kiht;
2. eeltöötluste ja tükeldamise kiht;
3. indekseerimise kiht;
4. päringu mõistmise ja otsingu kiht;
5. ümberjärjestamise ja konteksti valiku kiht;
6. vastuse genereerimise kiht;
7. jälgimise, hindamise ja halduse kiht.

Dokumendid ja metaandmed → puhastus → tükeldamine → leksikaalne indeks + vektorindeks → päringu analüüs → hübriidotsing → reranking → konteksti koostamine → allikapõhine genereerimine → usaldussignaalid, logid ja tagasiside

Joonis 2. Kavandatud süsteemi kihiline töövoog.

Joonisel 2 esitatud töövoog rõhutab kahte põhimõtet. Esiteks tuleb dokumentide eeltöötlus lahutada päringuajast, et suurem osa kulukast tööst tehtaks ette ära. Teiseks peab päringuajal tehtav töö olema mitte ainult kiire, vaid ka kontrollitav. See tähendab, et süsteem peab suutma põhjendada, miks just need lõigud valiti ja miks just selline vastus kuvati.

5.2 Dokumentide kogumine ja eeltöötlus

Arhitektuuri esimene kiht tegeleb dokumentide kogumisega. Allikad võivad tulla failihaldusest, siseveebist, sisuhaldussüsteemist või andmebaasist. Juba selles etapis peab süsteem siduma iga dokumendiga minimaalselt järgmised metaandmed: dokumendi identifikaator, pealkiri, dokumenditüüp, versioon, loomise või jõustumise kuupäev, omanik ning ligipääsuõiguse klass.

Seejärel tuleb dokumendid teisendada ühtsesse tekstikujusse. PDF-ide, HTML-failide ja kontoritarkvara dokumentide puhul ei piisa sageli lihtsalt “toorteksti väljavõtmisest”, sest koos sisuga tuleb säilitada ka struktuur. Pealkirjad, alapealkirjad, nummerdatud loetelud, tabelid ja joonealused märkused võivad kõik mõjutada vastuse kvaliteeti. Kui struktuur hävib, muutub hilisem tükeldamine juhuslikumaks ning allikaviited vähem informatiivseks.

Käesolevas süsteemikavandis on soovitatav säilitada dokumendi hierarhia vähemalt kolmel tasandil: dokument, jaotis ja lõik. Kui dokument sisaldab tabeleid või samm-sammulisi protseduure, võiks neid käsitleda eraldi struktuuriüksustena. Selline käsitus parandab nii otsingu kvaliteeti kui ka allika kuvamist vastuse juures.

5.3 Tükeldamine ja metaandmed

Dokumentide tükeldamine ei ole pelgalt tehniline optimeerimine, vaid üks keskseid kvaliteeditegureid. Liiga väike lõik võib eemaldada olulise konteksti, näiteks jätta välja erandi, tingimuse või eelduse. Liiga suur lõik muudab semantilise signaali hajusaks ja võib põhjustada selle, et otsing leiab teema, kuid mitte täpset vastust sisaldava osa.

Käesolevas töös eelistatakse semantilist tükeldamist, mis järgib dokumendi loomulikku struktuuri. Praktikas tähendab see, et lõikude piirid seatakse pealkirjade, lõikude, loetelupunktide või tabeliridade alusel, mitte ainult kindla tokeniarvu järgi. Vajadusel kasutatakse väikest kattuvust, et säilitada lause või definitsiooni terviklikkus.

Iga tükeldatud üksuse kohta tuleb salvestada vähemalt järgmised väljad:

- dokumendi identifikaator;
- dokumendi nimi;
- jaotise pealkiri;
- lõigu järjekorranumber;
- versioon ja kuupäev;
- ligipääsuõiguse märgis;
- tekstiline sisu;
- vajadusel link algdokumendi täpse asukohani.

Metaandmete säilitamine võimaldab hiljem teha kahte asja, mis on käesoleva süsteemi jaoks üliolulised. Esiteks saab otsingut piirata kasutaja õiguste või dokumenditüübi järgi. Teiseks saab vastuse juures kuvada inimloetava viite, näiteks dokumendi nime ja alapealkirja, mitte ainult anonüümset tekstilõiku.

5.4 Indekseerimine

Pärast tükeldamist tuleb lõigud paigutada indeksitesse. Käesolevas süsteemikavandis kasutatakse kahte põhikomponenti: leksikaalset indeksit ja vektorindeksit. Leksikaalne indeks teenindab täpseid vasteid, samas kui vektorindeks teenindab semantilist lähedust. Tihevektorite puhul on suurte korpusete jaoks mõistlik kasutada HNSW-põhist lähinaabriotsingut [22].

Vektorite loomisel on kaks realistlikku strateegiat. Esimene on kasutada mitmekeelset embedding-mudelit, mis töötab nii eesti kui inglise keele puhul samas ruumis. Teine on kasutada keelespetsiifilisi või domeenisetsiifilisi mudeleid ja lisada nende kõrvale leksikaalne otsing, mis katab terminoloogilised erijuhud. Käesoleva töö seisukohalt on esimene strateegia hooldatavam, sest organisatsiooniliste dokumentide keel on sageli segakeelne.

Indekseerimiskihi juurde kuulub ka versioonihaldus. Kui dokument muutub, tuleb vastavad lõigud indeksis uuendada ja vananenud lõigud eemaldada või märkida mitteaktiivseks. Soovitav on säilitada ajalooline jälg, kuid välistada vanad versioonid vaikimisi otsingust, välja arvatud juhul, kui kasutaja või rakendus küsib ajaloolist infot teadlikult.

5.5 Päringu analüüs

Enne otsingu käivitamist peab süsteem analüüsima kasutaja küsimust. Päringu analüüsi eesmärk ei ole siin keerukas semantiline parsija, vaid praktiline eeltöötlus. Vähemalt tuleks tuvastada:

- kas küsimus on faktiküsimus, protseduuriline küsimus või vastuseta küsimuse kandidaat;
- kas küsimuses leidub konkreetseid filtreid, nagu kuupäev, dokumendinimi, osakond või süsteeminimi;
- kas küsimus vajab ümberkirjutamist, sest see on liiga lühike, ebaselge või eelneva vestluse kontekstist sõltuv.

Päringu analüüs mõjutab otsingut vähemalt kahel viisil. Esiteks saab süsteem määrata, kui palju kandidaate otsida ja kas kasutada agressiivsemat laiendust. Teiseks saab süsteem otsustada, kas hilisem vastus peaks olema lühike faktivastus või struktureeritud sammude loend. Seega ei ole päringu analüüs ainult otsingu täiend, vaid ka vastuse vormi kujundaja.

5.6 Hübriidotsing

Käesolevas töös on keskseks projekteerimisotsuseks hübriidotsing. Leksikaalse ja semantilise otsingu ühendamiseks on mitu võimalust. Lihtsaim on skooride lineaarne kombineerimine:

$$score(d, q) = \alpha \cdot \text{sim}_{\text{dense}}(q, d) + (1 - \alpha) \cdot score_{\text{lex}}(q, d), \quad (1)$$

kus q on päring, d lõik ja α määrab semantilise otsingu kaalu.

Praktilises süsteemis ei pruugi erinevate otsingumoodulite skoorid olla samal skaalal. Seetõttu on sageli mõistlik kasutada järjestuspõhist sulandamist, näiteks Reciprocal Rank Fusion:

$$RRF(d) = \sum_{i=1}^n \frac{1}{k + rank_i(d)}, \quad (2)$$

kus $rank_i(d)$ tähistab dokumendi d kohta saadud kohta i -ndas järjestuses ning k on silumisparameeter. Käesoleva töö jaoks on RRF atraktiivne just seetõttu, et see ei eelda skooride ranget võrreldavust ning toimib hästi olukorras, kus üks järjestus tabab täpseid termineid ja teine semantilisi vasteid.

Hübriidotsingu juures on oluline rõhutada ka filtrite rolli. Kui kasutaja õigused, dokumenditüüp või ajaline kehtivus on teada, tuleb need rakendada enne lõplikku kandidaatide valikut. Mida hiljem filtreid rakendada, seda suurem on risk, et mudel näeb küsimuse jaoks vale või keelatud dokumenti.

5.7 Ümberjärjestamine ja konteksti koostamine

Esimese astme otsing tagastab tavaliselt rohkem kandidaate, kui generaatorile on mõistlik ette anda. Seetõttu tuleb rakendada ümberjärjestamist. Käesolevas töös on soovitatav kasutada kerget BERT-tüüpi või cross-encoder-tüüpi reranker'it, mis hindab täpsemalt, kas konkreetne lõik on konkreetse küsimuse jaoks informatiivne [12].

Ümberjärjestamise järel tuleb moodustada kontekst. Selleks tuleb otsustada:

- mitu lõiku anda generaatorile;
- kas lõigud esitatakse relevantsuse, dokumendi järjekorra või teema alusel;
- kas omavahel naabruses olevad lõigud liidetakse;
- kuidas esitada metaandmed nii, et mudel oskaks viidata allikale.

Siin ei ole universaalset lahendust. Faktiküsimuse jaoks võib piisata kahest kuni kolmest lõigust. Protseduurilise küsimuse jaoks võib olla vaja rohkem, kuid sel juhul tuleb olla eriti ettevaatlik

vastuolude suhtes. Kui kontekst sisaldab sama teema kohta mitut eri versiooni, peab süsteem eelistama kehtivat dokumenti või tunnistama vastuolu.

5.8 Vastuse genereerimine

Generaatorile antav viip peab olema rangelt struktureeritud. Käesolevas süsteemikavandis peaks see vähemalt:

1. ütlema mudelile, et vastata tohib ainult etteantud lõikude põhjal;
2. nõudma allikaviiteid iga olulise väite juures või vastuse lõpus;
3. suunama mudelit vastamisest keelduma, kui kontekst ei ole piisav;
4. määrama soovitud väljundvormi, näiteks lühivastus, loetelu või samm-sammuline juhised.

Kui süsteem kasutab vestlusajalugu, tuleb määrata ka selle roll. Käesoleva töö jaoks on mõistlik käsitleda vestlusajalugu ainult abikontekstina küsimuse ümberkirjutamiseks, mitte töendusmaterjalina. Töendusmaterjal peaks pärinema ikkagi dokumentidest, mitte eelmisest mudeli väljundist. Vastasel juhul tekib oht, et mudel hakkab tsiteerima iseennast.

5.9 Usaldussignaaliid ja keeldumismehhanism

Dokumendipõhise süsteemi jaoks ei piisa sellest, et vastus kõlab usaldusväärset. Vajalik on mehhanism, mis aitab hinnata, kas vastus on piisavalt põhjendatud. Käesolevas süsteemikavandis võiks usaldussignaal kujuneda vähemalt kolmest allikast:

- otsingutulemuste tugevus ja kooskõla;
- ümberjärjestatud lõikude sarnasus küsimusega;
- generaatori sisemine hinnang sellele, kas kontekst on piisav.

Kui need signaalid on nõrgad või vastuolulised, peaks süsteem eelistama keeldumist. Keeldumise sõnum ei tohi olla pelgalt “ma ei tea”, vaid peaks võimalusel selgitama, et süsteem ei leidnud piisavalt tugevat dokumentaalset alust. See suurendab kasutaja usaldust rohkem kui enesekindel, kuid kontrollimatu vastus.

5.10 Jälgimine ja operatiivne haldus

Arhitektuuri viimane kiht ühendab logimise, jälgimise ja süsteemi kvaliteedihalduse. Iga päringu kohta tuleks talletada vähemalt:

- päringu toorvorm ja normaliseeritud vorm;
- leksikaalse ja semantilise otsingu kandidaadid;
- ümberjärjestatud lõplikud lõigud;
- generaatorile antud kontekst;
- lõppvastus koos allikaviidetega;
- latentsus ja veaolukorrad.

Selline logi võimaldab hiljem läbi viia vigade analüüsi. Näiteks saab eristada olukorda, kus õige lõik ei jõudnud üldse kandidaatide hulka, olukorda, kus lõik oli kandidaatide seas, kuid jäi ümberjärjestuses liiga madalale, ja olukorda, kus generaator ignoreeris õiget lõiku. Ilma sellise eristusega muutub süsteemi parandamine juhuslikuks.

5.11 Peatüki kokkuvõte

Käesolevas peatükis kirjeldati detailne arhitektuur, mis lähtub varasemates peatükkides sõnastatud teoreetilisest taustast ja kasutusjuhtumitest. Arhitektuuri keskmes on kihiline töövoog, hübriidotsing, metaandmetega rikastatud tükeldamine, allikapõhine genereerimine ning usaldussignaalidel põhinev keeldumismehhanism. Järgmises peatükis kirjeldatakse, kuidas sellise süsteemi kvaliteeti hinnata ja millise eksperimentaalse raamistikuga oleks võimalik seda edasi arendada.

6. Hindamisraamistik ja juurutusplaan

Kuna käesoleva töö tulemuseks on süsteemikavand, mitte valmis rakendus, tuleb eraldi kirjeldada, kuidas kavandatud lahendust hinnata ja millise plaani alusel seda järk-järgult juurutada. Hindamisraamistik on oluline kahel põhjusel. Esiteks annab see kriteeriumid, mille järgi otsustada, kas arhitektuur täidab oma eesmärgi. Teiseks aitab see ennetada olukorda, kus süsteem küll tundub demoni muljetavaldav, kuid selle tegelikku töökindlust ei ole võimalik tõendada.

6.1 Miks tuleb hinnata eraldi süsteemi eri kihte

RAG-süsteemi puhul ei saa kvaliteeti taandada ühele lõppvastuse mõõdikule. Kui kasutaja saab halva vastuse, võib viga tekkida mitmes eri kohas: küsimus võidi valesti normaliseerida, õigeid lõike ei leitud, ümberjärjestus võis tõsta ette valed kandidaadid või generaator võis ignoreerida õiget lõiku. Seetõttu tuleb süsteemi hinnata vähemalt kolmel tasandil:

1. otsingukihi kvaliteet;
2. vastuse korrektsus ja allikapõhisus;
3. kasutuskogemus ja operatiivne töökindlus.

Selline kihiline hindamine on vajalik ka praktilise arenduse jaoks. Kui kõik vead koondatakse ühe “kvaliteedi” numbri alla, ei selgu, millist komponenti oleks vaja parandada. Kihiline hindamine muudab süsteemi arenduse sihipäraseks.

6.2 Hindamiskorpuse koostamine

Hindamise esimeseks eelduseks on realistlik testkorpus. Eestikeelse organisatsioonilise dokumentatsiooni jaoks ei ole enamasti olemas valmis benchmark'i, mistõttu tuleb testjuhtumid koostada käsitsi. Käesolevas töös soovitatakse moodustada testkorpus vähemalt neljast küsimuse tüübist:

- faktiküsimused;
- protseduuriküsimused;
- mitmest allikast sünteesi nõudvad küsimused;
- vastuseta või ligipääsupiiranguga küsimused.

Iga testjuhtumi kohta tuleks salvestada vähemalt järgmised väljad: küsimus, küsimuse tüüp, oodatud allikad, referentsvastuse põhisisu, võimalikud eksitusallikad ning vajadusel märged, et

õige käitumine on vastamisest keeldumine. Lisas on esitatud soovituslik minimaalne vorm selle korpuse kirjeldamiseks.

6.3 Otsingukihi mõõdikud

Otsingukihi hindamisel on kõige olulisem küsimus, kas õige lõik jõuab üldse kandidaatide hulka. Kui see ei juhtu, ei saa hilisemad kihid enam viga parandada. Seetõttu on mõistlik kasutada standardseid infootsingu mõõdikuid, nagu Hit@k ja Mean Reciprocal Rank (MRR).

Hit@k mõõdab, kas vähemalt üks õige lõik leidis esimese k tulemuse seas. See sobib hästi olukorras, kus süsteem annab generaatorile piiratud hulga kandidaate. **MRR** rõhutab lisaks seda, kui kõrgel kohal esimene õige vaste asub. Kui õige lõik ilmub alles väga madalal positsioonil, võib see olla praktiliselt sama halb kui selle puudumine, sest ümberjärjestus või konteksti kokkupanek ei pruugi seda enam arvesse võtta.

Lisaks automaatmõõdikutele on mõistlik teha eksperthinnangut vähemalt valimi peal. Organisatsiooniliste dokumentide puhul võib olemas olla mitu osaliselt õiget lõiku või olukord, kus kõige informatiivsem lõik ei ole täpselt sama, mille inimene referentsina märkis. Ekspert hinnang aitab vältida liiga jäika benchmark'i.

Tabel 4. Soovitavad mõõdikud süsteemi eri kihtide jaoks.

Kiht	Põhiküsimus	Mõõdikud
Otsing	Kas õige lõik jõudis kandidaatide hulka?	Hit@k, MRR, eksperthinnang
Ümberjärjestus	Kas õiged lõigud tõsteti esiplaanile?	NDCG, Top-k täpsus, eksperthinnang
Vastus	Kas lõppvastus on korrektne ja täielik?	binaarne hinnang, skoor 1–5, faktitäpsus
Allikapõhisus	Kas vastuses esitatud väited on allikatega kooskõlas?	groundedness, viidete täpsus
Kasutatavus	Kas kasutaja saab vastusest aru ja leiab allika üles?	kasutajatest, ülesande aeg, rahulolu
Operatiivsus	Kas süsteem püsib töökindel ja piisavalt kiire?	latentsus, veamäär, logide täielikkus

6.4 Lõppvastuse hindamine

Lõppvastuse hindamisel tuleb eristada vähemalt kolme omadust: korrektsus, täielikkus ja allikapõhisus. Korrektsus tähendab, et vastuses esitatud väited ei ole faktivigadega. Täielikkus tähendab, et vastus ei jäta välja kasutaja küsimuse seisukohast kriitilist tingimust või sammu. Allikapõhisus tähendab, et vastuses toodud väited on tuletatavad just nendest lõikudest, millele süsteem viitab.

Automaatne hindamine võib siin anda osalise pildi, kuid mitte täielikku kindlust. Näiteks võib mudel sõnastada sama mõtte erinevalt kui referentsvastus. Seetõttu on mõistlik kasutada kombineeritud lähenemist: automaatne kontroll lihtsamate faktiküsimuste jaoks ja eksperthinnang keerukamate protseduuriliste või sünteesküsimuste jaoks.

Eriti oluline on hinnata *keeldumiste kvaliteeti*. Kui süsteem ei leia piisavat alust vastamiseks, peab ta oskama seda selgelt öelda. Liiga agressiivne keeldumine muudab süsteemi vähekasulikuks; liiga julge vastamine suurendab hallutsinatsioonide riski. Seetõttu tuleb vastuseta küsimused lisada hindamiskorpusesse teadlikult, mitte käsitleda neid erandina.

6.5 Kasutajatestid

Käesoleva töö kavandatav süsteem on mõeldud inimese töö lihtsustamiseks, seega ei piisa ainult tehnilistest mõõdikutest. Vajalik on hinnata ka kasutuskogemust. Kasutajatestis võiks mõõta vähemalt järgmisi aspekte:

- kui kiiresti leiab kasutaja soovitud info süsteemi abil võrreldes käsitsi otsimisega;
- kas kasutaja peab vastust usaldusväärseks;
- kas kasutaja märkab allikaviiteid ja oskab neid kasutada;
- millistes olukordades kasutaja eelistab ikkagi originaaldokumenti lugeda.

Kasutajatesti eesmärk ei ole ainult rahulolu mõõtmine. Sama oluline on näha, kas süsteem aitab kasutajal teha õige otsuse. Näiteks võib kasutaja hinnata vastust sujuvaks ja abistavaks, kuid ikkagi jätta märkamata kriitilise erandi, kui see oli peidetud viidatud allikasse. Seetõttu peaks kasutajatest sisaldama ülesandeid, millel on kontrollitav õige tulemus.

6.6 Ablatsioonid ja võrdlused

Kui kavandatud süsteemist luuakse prototüüp, on mõistlik hinnata ka seda, milline komponent annab kvaliteedile kõige suurema panuse. Selleks sobivad ablatsioonikatsed, kus eemaldatakse või asendatakse üks komponent korraga. Soovitavad võrdlused on näiteks:

- ainult leksikaalne otsing vs ainult tihevektorotsing vs hübriidotsing;
- ilma ümberjärjestuseta vs ümberjärjestusega lahendus;
- lühikesed lõigud vs semantiliste piiride järgi tükeldatud lõigud;
- allikaviidetega vastus vs viideteta vastus;
- keeldumismehhanismiga lahendus vs alati vastav lahendus.

Ablatsioonide väärtus seisneb selles, et need aitavad vältida arusaama, nagu oleks kogu kvaliteet tingimata ühe mudeli teene. Dokumentide põhises süsteemis võib näiteks selguda, et lõigu pikkus ja metaandmete filtrid mõjutavad tulemust rohkem kui generaatori täpne mudeliversioon.

6.7 Juurutusplaan

Käesoleva töö praktiliseks jätkuks sobib etapiline juurutusplaan. Selline lähenemine vähendab riski ja võimaldab õppida juba enne täielikku kasutuselevõttu.

Etapiline juurutus võimaldab arhitektuuri valideerida enne, kui süsteemile antakse liiga lai vastutus. See on oluline, sest organisatsioonilised RAG-süsteemid mõjutavad kasutaja käitumist. Kui süsteem eksib, ei ole kahju ainult tehniline, vaid võib olla ka protsessiline ja mainealane.

6.8 Piirangud hindamisel

Hindamisraamistikul endal on samuti piirangud. Kui testkorpus koostatakse liiga kitsalt, võib süsteem õppida selle peal hästi toimima, kuid päriskasutuses ebaõnnestuda. Kui eksperthinnanguid on vähe, võivad keerukad piiripealsed juhtumid jääda märkamata. Kui kasutajatestis osalevad ainult tehniliselt kogenud inimesed, ei pruugi tulemused üldistuda tavakasutajale.

Seetõttu tuleb hindamist käsitleda pideva protsessina. Esmane benchmark on vajalik, kuid mitte piisav. Süsteemi logid, kasutajate vabatekstiline tagasiside ja regulaarsed järelanalüüsid peavad kujunema sama oluliseks kui esialgne mõõtmine.

Tabel 5. Soovitatav juurutusplaan kavandatud süsteemile.

Etapp	Eesmärk	Tulemus
1. Korpuse ettevalmistus	Koguda dokumendid, puhastada formaat ja luua metaandmete skeem.	Indekseerimiseks valmis kontrollitud dokumentikogu.
2. Baasprototüüp	Rakendada hübriidotsing ja lihtne genereerimine.	Esmane süsteem sisekatseteks.
3. Hindamisaas	Koostada testkorpus ja mõõta kvaliteeti.	Kvantitatiivne ja kvalitatiivne kvaliteedipilt.
4. Turvakihid	Lisada õigused, logid ja keeldumismehhanismid.	Organisatsiooniliselt sobivam lahendus.
5. Pilootkasutus	Anda süsteem piiratud kasutajarühmale.	Reaalne kasutuspilt ja parendusvajadused.

6.9 Peatüki kokkuvõte

Käesolevas peatükis kirjeldati, kuidas kavandatud süsteemi kvaliteeti hinnata ja millise plaani alusel seda juurutada. Peamine järeldus on, et RAG-süsteemi kvaliteeti tuleb hinnata kihiliselt: eraldi otsingu, ümberjärjestuse, vastuse, allikapõhisuse, kasutatavuse ja operatiivse töökindluse tasandil. Samuti näidati, et realistlik juurutus eeldab etapilist lähenemist, kus tehniline prototüüp, turvakontrollid ja pilootkasutus järgnevad üksteisele kontrollitult.

7. Arutelu

Eelmistes peatükkides kirjeldati teoreetilist tausta, seotud töid, süsteemi nõudeid, arhitektuuri ja hindamisraamistikku. Käesolevas peatükis arutatakse nende valikute laiemat tähendust. Eraldi käsitletakse kvaliteedi ja keerukuse kompromisse, eetilisi ja õiguslikke küsimusi, eestikeelse konteksti spetsiifilisi piiranguid ning seda, milliste eelduste korral on kavandatud lahendus realistlikult rakendatav.

7.1 Miks ei piisa ainult paremast keelemudelist

Üks levinud eksiarvamus generatiivsete süsteemide arendamisel on, et kvaliteediprobleeme saab lahendada lihtsalt suurema või uuema mudeli kasutuselevõtuga. Käesoleva töö analüüs seda ei toeta. Dokumentide põhises küsimus-vastus süsteemis on kvaliteet tugevalt seotud otsingu, metaandmete, ligipääsuõiguste ja konteksti valikuga. Kui süsteem leiab valed lõigud või ei suuda eristada kehtivat dokumenti vananenud versioonist, ei lahenda ka tugevam generaator probleemi.

See järeldus on oluline ka organisatsioonilisele otsustamisele. Kui investeeringud suunatakse ainult keelemudeli litsentsi või arvutusvõimsuse kasvatamisse, kuid tähelepanuta jäävad teadmuspõhja hooldus ja hindamiskorpus, siis paraneb süsteemi väljundi voolavus tõenäoliselt rohkem kui selle usaldusväärsus. Käesoleva töö põhjal tuleks prioriteedid seada teisiti: esmalt korrastada dokumendivoog ja hindamine, seejärel optimeerida generaatorit.

7.2 Täpsuse ja latentsuse kompromiss

Dokumentide põhised süsteemid peavad tasakaalustama kahte eesmärki. Ühelt poolt ootab kasutaja kiiret vastust. Teisalt nõuab allikapõhisus, et süsteem teeks enne vastamist rea kontrollsamme: otsiks kandidaadid, rakendaks filtreid, vajadusel ümberjärjestaks tulemused ja hindaks, kas vastamiseks on piisavalt alust. Mida rohkem kontrolli lisada, seda suurem on latentsus.

Praktiline küsimus ei ole seega see, kuidas teha süsteem võimalikult kiireks, vaid kuidas teha see piisavalt kiireks ilma kvaliteeti põhjendamatult ohverdamata. Käesolevas töös pakutud lahendus lähtub põhimõttest, et odavamad sammud, nagu metaandmefiltrid ja leksikaalne otsing, tuleks teha võimalikult vara. Kallimad sammud, nagu ümberjärjestus või keerukam enesehindamine, tuleks reserveerida juhtudeks, kus küsimus on riskantne, mitmetähenduslik või dokumentaalselt keeruline.

7.3 Eestikeelse konteksti tugevused ja piirangud

Eesti keele kontekst ei ole ainult piirang. Väiksema ja hästi piiritletud dokumendikorpuse puhul võib mõnel juhul olla lihtsam saavutada väga hea praktiline kasu kui massiivse üldise teadmuspõhjaga süsteemis. Kui organisatsioon hoiab oma dokumentatsiooni korrastatult ja metaandmetega rikastatult, võib RAG-lahendus pakkuda märkimisväärset ajavõitu isegi tagasihoidlikuma tehnilise keerukuse juures.

Samas on eestikeelses kontekstis mitu piirangut. Avalikke benchmark'e on vähe, mis teeb mudelite võrdlemise raskemaks. Paljud tugevad embedding- ja reranking-mudelid on optimeeritud inglise keele või suuremate mitmekeelsete andmestike jaoks. Lisaks võib eesti keele rikas morfoloogia põhjustada olukordi, kus leksikaalne ja semantiline otsing annavad teineteisest väga erinevaid signaale. Seetõttu peab süsteemi arendaja olema valmis rohkem eksperimenteerima ja vähem lootma väliste benchmark'ide automaatsele ülekantavusele.

7.4 Allikapõhisus kui kasutajaliidese küsimus

Teoreetiliselt võib süsteem olla allikapõhine ka siis, kui allikad salvestatakse ainult logidesse. Käesoleva töö põhjal ei ole see siiski piisav. Kui kasutaja ei näe, millele vastus tugineb, ei saa ta hinnata selle usaldusväärsust. Seetõttu on allikapõhisus ka kasutajaliidese küsimus. Süsteem peab näitama viiteid kasutajale arusaadavas vormis ning tegema allikad vajadusel klikitavaks või vähemalt selgelt tuvastatavaks.

See tähelepanek muudab RAG-süsteemi olemust. Tegu ei ole ainult mudelitoruga, vaid ka teadmise esitamise viisiga. Süsteemi ülesanne ei ole kasutajalt allikat peita, vaid aidata tal allikani jõuda kiiremini kui traditsioonilise otsingu abil. Parim tulemus ei pruugi seega olla kõige lühem vastus, vaid vastus, mis kombineerib kokkuvõtte ja kontrollitava viite.

7.5 Õiguslikud ja eetilised küsimused

Dokumentide põhise küsimus-vastus süsteemi juurutamisel tuleb arvestada nii autoriõiguse, andmekaitse kui ka vastutuse küsimustega. Kui süsteem töötab piiratud ligipääsuga dokumentidel, peab olema selge, et mudel ei tohi avaldada kasutajale sisu, milleks tal puudub õigus. See tähendab, et ligipääsukontroll tuleb rakendada juba otsingus ja konteksti koostamisel, mitte alles kasutajaliidese.

Teine oluline küsimus on vastutuse piir. Kui kasutaja teeb süsteemi vastuse põhjal otsuse, kas vastutus jääb kasutajale, süsteemi haldurile või dokumendi omanikule? Käesoleva töö põhjal ei

tohiks süsteemi esitleda autoriteetse otsustajana, vaid otsust toetava tööriistana. Just seetõttu on allikaviited ja auditijälg niivõrd tähtsad. Need aitavad säilitada vastutuse läbipaistvust.

Eetiline küsimus on ka kasutaja usaldus. Inimesed kalduvad soravalt sõnastatud süsteeme üle usaldama. Kui süsteem jätab endast mulje kui kõiketeadvast assistendist, suureneb risk, et kasutaja ei kontrolli enam vastust. Käesoleva töö üks järeldusi ongi, et hea süsteem peab olema vajadusel ettevaatlik ja näitama oma ebakindlust. Liigne enesekindlus ei ole siin kasutusmugavus, vaid risk.

7.6 Millal on kavandatud arhitektuur üleliia keerukas

Kuigi käesolev töö pakub välja mitmekihilise arhitektuuri, ei tähenda see, et iga organisatsioon vajab kohe kõiki komponente. Väikese ja stabiilse dokumendikorpuse puhul võib alustada lihtsamast lahendusest: leksikaalne otsing, vektorotsing, piiratud hulk metaandmeid ja rangelt mallistatud vastus. Selline süsteem võib olla täiesti piisav, kui kasutusjuhtumid on kitsad ja risk madal.

Arhitektuuri keerukus peaks seega kasvama koos riskiga. Kui süsteem käsitleb õiguslikult tundlikke, kiiresti muutuvaid või ligipääsupiirangutega dokumente, on ümberjärjestus, keeldumismehhanism ja auditijälg hädavajalikud. Kui eesmärk on aidata kasutajal leida avalikke juhendmaterjale, võib lihtsam lahendus anda parema kulutõhususe.

7.7 Tulevase töö olulisemad suunad

Käesolev töö loob lähtealuse mitmele edasiarendusele. Esimene loogiline suund on prototüübi teostamine reaalsel eestikeelsel dokumendikorpusel. See võimaldaks mõõta, kas hübriidotsing annab tõesti märgatava eelise võrreldes üksikute otsingumoodulitega. Teine oluline suund on keelespetsiifiliste ja mitmekeelsete embedding-mudelite võrdlus. Kolmas suund on kasutajauuring, mis aitaks mõista, millist tüüpi allikaviited ja vastusevormid teevad süsteemi päriselt usaldatavaks.

Lisaks oleks huvitav uurida, kuidas automaatne kvaliteedikontroll saaks toetada sisuomanikke endid. Kui süsteem suudaks tuvastada, et samal teemal leidub teadmuspõhjas vastuolulisi või aegunud dokumente, võiks ta olla mitte ainult vastamise, vaid ka teadmushalduse tööriist.

7.8 Peatüki kokkuvõte

Käesolevas peatükis arutati, millised kompromissid ja piirangud kujundavad dokumentide põhise RAG-süsteemi tegelikku rakendatavust. Peamine järeldus on, et süsteemi edu ei sõltu ainult

keelemudeli kvaliteedist, vaid kogu arhitektuuri, teadmuspõhja ja hindamisprotsessi kooskõlast. Eestikeelne kontekst muudab probleemi korraga nii keerukamaks kui ka huvitavamaks: väiksemad ressursid nõuavad suuremat hoolikust, kuid hästi piiritletud dokumentikorpused loovad võimaluse rajada praktiliselt väga väärtuslikke lahendusi.

8. Kokkuvõte

Käesoleva bakalaureusetöö eesmärk oli analüüsida, kuidas kavandada eestikeelne dokumentide põhine küsimus-vastus süsteem, mis kasutab Retrieval-Augmented Generation lähenemist ning annab kasutajale kontrollitavaid, allikapõhiseid vastuseid. Töö lähtus probleemist, et ainult suurte keelemudelite parameetritesse talletatud teadmine ei ole piisav olukordades, kus vastata tuleb muutuvate, organisatsioonispetsiifiliste või ligipääsupiirangutega dokumentide põhjal.

Töö esimeses pooles avati teoreetiline taust. Näidati, kuidas transformer-arhitektuur pani aluse suurtele keelemudelitele, miks nende sorav väljendusvõime ei kõrvalda hallutsinatsioonide probleemi ning kuidas infootsingu meetodid ja Retrieval-Augmented Generation loovad võimaluse siduda mudeli väljund välise teadmuspõhjaga. Samuti rõhutati, et eestikeelses kontekstis tuleb arvestada nii keele morfoloogiliste eripärade kui ka väiksema avaliku ressursibaasiga.

Seotud tööde analüüs näitas, et RAG-lahenduste kvaliteet sõltub tugevalt otsingukihi kvaliteedist, konteksti valikust ja süsteemi võimest hinnata omaenda tõendusmaterjali piisavust. Avatud domeeni küsimus-vastus süsteemid, nullülekande otsingubenchmark'id ning hallutsinatsioonide vähendamise tööd viitasid kõik samale järeldusele: usaldusväärne lahendus ei saa põhineda ainult tugeval generaatoril, vaid vajab läbimõeldud dokumentide eeltöötlust, hübriidotsingut, allikaviiteid ja keeldumismehhanismi.

Töö teises pooles sõnastati organisatsioonilise dokumentide põhise süsteemi kasutusjuhtumid ja nõuded. Nende põhjal pakuti välja seitsmekihiline arhitektuur, mis hõlmab dokumentide kogumist, tükeldamist, indekseerimist, päringu analüüsi, hübriidotsingut, ümberjärjestamist, allikapõhist genereerimist ning logimist ja haldust. Eriti oluline järeldus oli, et metaandmed ja ligipääsuõigused ei ole kõrvalteema, vaid süsteemi usaldusväärsuse keskne osa.

Lisaks kirjeldati hindamisraamistikku ja juurutusplaani. Töö järeldab, et sellist süsteemi tuleb hinnata kihiliselt: eraldi otsingukihi, ümberjärjestuse, lõppvastuse, allikapõhisuse, kasutatavuse ja operatiivse töökindluse tasandil. Samuti näidati, et praktiline juurutus peaks olema etapiline, alustades korrastatud dokumendikorpusest ja baasprototüübist ning liikudes edasi turvakontrollide, pilootaži ja kasutajatestideni.

Töö peamine järeldus on, et eestikeelse RAG-põhise küsimus-vastus süsteemi kavandamisel tuleb käsitleda probleemi tervikuna. Kvaliteet ei sõltu ainult keelemudelist, vaid sama palju dokumendihaldusest, otsinguarhitektuurist, allikate nähtavusest ja süsteemi võimest öelda ausalt,

millal tal puudub piisav alus vastamiseks. Just selline terviklik vaade loob tugeva lähtepunkti järgmiseks sammuks, milleks on siin kirjeldatud arhitektuuri prototüüpne teostus reaalsel dokumendikorpusel.

Viited

- [1] Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser Ł. ja Polosukhin I. Attention Is All You Need. *Advances in Neural Information Processing Systems* 30. 2017. https://papers.nips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.
- [2] Ji Z., Lee N., Frieske R., Yu T., Su D., Xu Y., Ishii E., Bang Y., Chen D., Dai W., Chan H. S., Madotto A. ja Fung P. Survey of Hallucination in Natural Language Generation. 8. veebr 2022. arXiv: [2202.03629](https://arxiv.org/abs/2202.03629). <https://arxiv.org/abs/2202.03629>.
- [3] Lewis P., Perez E., Piktus A., Petroni F., Karpukhin V., Goyal N., Küttler H., Lewis M., Yih W.-t., Rocktäschel T., Riedel S. ja Kiela D. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems* 33. 2020. https://papers.nips.cc/paper_files/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html.
- [4] Gao Y., Xiong Y., Gao X., Jia K., Pan J., Bi Y., Dai Y., Sun J., Wang M. ja Wang H. Retrieval-Augmented Generation for Large Language Models: A Survey. 18. dets 2023. arXiv: [2312.10997](https://arxiv.org/abs/2312.10997). <https://arxiv.org/abs/2312.10997>.
- [5] Feng F., Yang Y., Cer D., Arivazhagan N. ja Wang W. Language-agnostic BERT Sentence Embedding. *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, mai 2022, lk 878–891. DOI: [10.18653/v1/2022.acl-long.62](https://aclanthology.org/2022.acl-long.62/). <https://aclanthology.org/2022.acl-long.62/>.
- [6] Devlin J., Chang M.-W., Lee K. ja Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, juuni 2019, lk 4171–4186. DOI: [10.18653/v1/N19-1423](https://aclanthology.org/N19-1423/). <https://aclanthology.org/N19-1423/>.
- [7] Brown T. B., Mann B., Ryder N., Subbiah M., Kaplan J., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A., Agarwal S., Herbert-Voss A., Krueger G., Henighan T., Child R., Ramesh A., Ziegler D. M., Wu J., Winter C., Hesse C., Chen M., Sigler E., Litwin M., Gray S., Chess B., Clark J., Berner C., McCandlish S., Radford A., Sutskever I. ja Amodei D. Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems* 33. 2020. <https://arxiv.org/abs/2005.14165>.

- [8] Ouyang L., Wu J., Jiang X., Almeida D., Wainwright C. L., Mishkin P., Zhang C., Agarwal S., Slama K., Ray A., Schulman J., Hilton J., Kelton F., Miller L., Simens M., Askell A., Welinder P., Christiano P., Leike J. ja Lowe R. Training Language Models to Follow Instructions with Human Feedback. 4. märts 2022. arXiv: [2203.02155](https://arxiv.org/abs/2203.02155). <https://arxiv.org/abs/2203.02155>.
- [9] Qi S., He Y. ja Yuan Z. Can We Catch the Elephant? A Survey of the Evolvement of Hallucination Evaluation on Natural Language Generation. 18. apr 2024. arXiv: [2404.12041](https://arxiv.org/abs/2404.12041). <https://arxiv.org/abs/2404.12041>.
- [10] Karpukhin V., Oguz B., Min S., Lewis P., Wu L., Edunov S., Chen D. ja Yih W.-t. Dense Passage Retrieval for Open-Domain Question Answering. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, nov 2020, lk 6769–6781. DOI: [10.18653/v1/2020.emnlp-main.550](https://aclanthology.org/2020.emnlp-main.550/). <https://aclanthology.org/2020.emnlp-main.550/>.
- [11] Reimers N. ja Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Association for Computational Linguistics, nov 2019, lk 3982–3992. DOI: [10.18653/v1/D19-1410](https://aclanthology.org/D19-1410/). <https://aclanthology.org/D19-1410/>.
- [12] Nogueira R. ja Cho K. Passage Re-ranking with BERT. 12. jaan 2019. arXiv: [1901.04085](https://arxiv.org/abs/1901.04085). <https://arxiv.org/abs/1901.04085>.
- [13] Khattab O. ja Zaharia M. ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT. *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2020, lk 39–48. DOI: [10.1145/3397271.3401075](https://arxiv.org/abs/2004.12832). <https://arxiv.org/abs/2004.12832>.
- [14] Asai A., Wu Z., Wang Y., Sil A. ja Hajishirzi H. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. 17. okt 2023. arXiv: [2310.11511](https://arxiv.org/abs/2310.11511). <https://arxiv.org/abs/2310.11511>.
- [15] Yan S.-Q., Gu J.-C., Zhu Y. ja Ling Z.-H. Corrective Retrieval Augmented Generation. 7. okt 2024. arXiv: [2401.15884](https://arxiv.org/abs/2401.15884). <https://arxiv.org/abs/2401.15884>.
- [16] Liu N. F., Lin K., Hewitt J., Paranjape A., Bevilacqua M., Petroni F. ja Liang P. Lost in the Middle: How Language Models Use Long Contexts. 20. nov 2023. arXiv: [2307.03172](https://arxiv.org/abs/2307.03172). <https://arxiv.org/abs/2307.03172>.

- [17] Tanvir H., Kittask C., Eiche S. ja Sirts K. EstBERT: A Pretrained Language-Specific BERT for Estonian. 28. apr 2021. arXiv: [2011.04784](https://arxiv.org/abs/2011.04784). <https://arxiv.org/abs/2011.04784>.
- [18] Izacard G. ja Grave E. Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering. *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume*. Association for Computational Linguistics, apr 2021, lk 874–880. DOI: [10.18653/v1/2021.eacl-main.74](https://doi.org/10.18653/v1/2021.eacl-main.74). <https://aclanthology.org/2021.eacl-main.74/>.
- [19] Thakur N., Reimers N., Rücklé A., Srivastava A. ja Gurevych I. BEIR: A Heterogenous Benchmark for Zero-shot Evaluation of Information Retrieval Models. 21. okt 2021. arXiv: [2104.08663](https://arxiv.org/abs/2104.08663). <https://arxiv.org/abs/2104.08663>.
- [20] Muennighoff N., Tazi N., Magne L. ja Reimers N. MTEB: Massive Text Embedding Benchmark. 19. märts 2023. arXiv: [2210.07316](https://arxiv.org/abs/2210.07316). <https://arxiv.org/abs/2210.07316>.
- [21] Gao L., Ma X., Lin J. ja Callan J. Precise Zero-Shot Dense Retrieval without Relevance Labels. 20. dets 2022. arXiv: [2212.10496](https://arxiv.org/abs/2212.10496). <https://arxiv.org/abs/2212.10496>.
- [22] Malkov Y. A. ja Yashunin D. A. Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42.4 (apr 2020), lk 824–836. DOI: [10.1109/TPAMI.2018.2889473](https://doi.org/10.1109/TPAMI.2018.2889473). <https://arxiv.org/abs/1603.09320>.

Lisad

Lisa 1. Süsteemi nõuete koondtabel

Tabel 6. Kavandatud süsteemi koondnõuded.

Tähis	Tüüp	Kirjeldus
F1	Funktsionaalne	Süsteem peab suutma töödelda erineva struktuuriga dokumente ning säilitama dokumendi pealkirja, jaotise ja versiooni metaandmed.
F2	Funktsionaalne	Süsteem peab leidma kasutaja küsimusele vastamiseks asjakohased lõigud vähemalt ühest dokumendist ning esitama need genereerimiskihile.
F3	Funktsionaalne	Vastus peab sisaldama viiteid kasutatud allikatele või dokumendiosadele.
F4	Funktsionaalne	Kui usaldusväärset allikat ei leita, peab süsteem oskama vastamisest keelduda või selgitada ebapiisavat alusmaterjali.
F5	Funktsionaalne	Süsteem peab võimaldama teadmuspõhja uuendada ilma keelemudelit ümber treenimata.
NF1	Mittefunktsionaalne	Lahendus peab toetama eesti keelt vähemalt kasutaja sisendi, otsingu ja väljundi tasemel.
NF2	Mittefunktsionaalne	Arhitektuur peab olema auditijälge toetav: süsteem peab salvestama päringu, kasutatud allikad ja vastuse versiooni.
NF3	Mittefunktsionaalne	Lahendus peab olema hooldatav, st dokumentide uuendamine ja ümberindekseerimine peab olema automatiseeritav.
NF4	Mittefunktsionaalne	Vastamise latentsus peab jääma kasutaja jaoks mõistlikku vahemikku, et lahendus sobiks interaktiivseks kasutuseks.
NF5	Mittefunktsionaalne	Süsteem peab toetama ligipääsuõiguste ja tundlike dokumentide käsitlemist viisil, mis ei lekita keelatud sisu.

Lisa 2. Soovituslik hindamiskorpuse struktuur

Hindamiskorpus võiks sisaldada vähemalt nelja tüüpi küsimusi:

- **Faktiküsimused**, millel on dokumentides üks üheselt kontrollitav vastus, näiteks kuupäev, nõue või määratlus.
- **Protseduuriküsimused**, kus vastus tuleb koostada mitmest lausest või sammust.
- **Sünteesküsimused**, mis nõuavad mitme dokumendiosa ühendamist üheks koherentseks vastuseks.
- **Vastuseta küsimused**, mille eesmärk on kontrollida, kas süsteem oskab allikate puudumisel keelduda vastamisest.

Praktilise hindamise jaoks on mõistlik kirjeldada iga testjuhtumit järgmiste väljadega:

Tabel 7. Soovituslik ühe testjuhtumi kirjeldus.

Väli	Sisu
Küsimus	Lõppkasutaja esitatav loomuliku keele küsimus.
Kategooria	Fakt, protseduur, süntees või vastuseta küsimus.
Oodatud allikad	Dokumendid või lõigud, mille põhjal õige vastus peab kujunema.
Oodatud vastus	Referentsvastus või vastuse põhisisu.
Hindamiskriteerium	Kas hinnatakse näiteks korrektsust, allikapõhisust, viidete täpsust või keeldumise asjakohasust.

Litsents

Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks

Mina, Näidisüliõpilane, annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) minu loodud teose „Eestikeelse RAG-põhise küsimus-vastus süsteemi kavandamine“, mille juhendaja on Juhendaja nimi, reprodutseerimiseks eesmärgiga seda säilitada, sealhulgas lisada see digitaalarhiivi DSpace kuni autoriõiguse kehtivuse lõppemiseni.

1. Annan Tartu Ülikoolile loa teha ülalmainitud teos üldsusele kättesaadavaks Tartu Ülikooli veebikeskkonna, sealhulgas digitaalarhiivi DSpace kaudu Creative Commons'i litsentsiga CC BY NC ND 3.0, mis lubab autorile viidates teost reprodutseerida, levitada ja üldsusele suunata ning keelab luua tuletatud teost ja kasutada teost ärieesmärgil, kuni autoriõiguse kehtivuse lõppemiseni.
2. Olen teadlik, et nimetatud õigused jäävad alles ka autorile.
3. Kinnitan, et lihtlitsentsi andmisega ei riku ma teiste isikute intellektuaalomandi ega isikuandmete kaitse õigusaktidest tulenevaid õigusi.

/Näidisüliõpilane/

/14. mai 2026/