

TARTU ÜLIKOOL  
Arvutiteaduse instituut  
Informaatika õppekava

Uku Renek Kronbergs

**Suurel keelemudelil põhineva eestikeelse  
informaatika teksti tagasisidesüsteemi  
prototüüp ja pilootuuring**

**Bakalaureusetöö (9 EAP)**

Juhendaja:  
Alo Peets, MSc

Tartu 2026

# Suurel keelemudelil põhineva eestikeelse informaatika teksti tagasisidesüsteemi prototüüp ja pilootuuring

## Lühikokkuvõte:

Eestikeelse informaatika lõputöö kirjutamine on tudengile keeleliselt ja struktuurselt nõudlik ülesanne, sest valdkonna terminoloogia on välja kujunenud inglise keeles ning akadeemilise stiili reegleid kohaldatakse eesti keeles mõnevõrra teisiti. Käesoleva bakalaureusetöö eesmärk on *kavandada ja realiseerida* suurel keelemudelil põhinev prototüüp, mis annab eestikeelsele informaatika lõputöö tekstile automaatset tagasisidet neljas kategoorias: struktuur, akadeemiline stiil, terminoloogia järjepidevus ja viitamisvajadus, ning *hinnata empiiriliselt* selle väljundi kvaliteeti. Prototüüp on realiseeritud veebirakendusena, mis võtab sisendiks tudengi kirjutatud peatüki, suunab selle valitud keelemudelile struktureeritud viibaga ning kuvab kasutajale kategoriseeritud tagasiside. Töö raames viidi läbi nii *kvalitatiivne pilootuuring* prompti disaini iteratsiooni jaoks kui ka *täismahuline empiiriline hindamine*: 20 sünteetilise testkatkendi vastu tehti 80 päris API-päringut (Claude 4.7 Opus ja GPT-5.5, üldine ja struktureeritud prompt) ning mudelite väljundid skooriti spani-tasemel kuldstandardi vastu. Tulemused näitavad, et makro- $F_1$  on vahemikus 0,38–0,56, parim kombinatsioon on GPT-5.5 + struktureeritud prompt ( $F_1 = 0,56$ ), struktureeritud prompt parandab  $F_1$ -skoori järjepidevalt mõlemal mudelil ning mudelid on kallutatud saagise poole (kõrge saagis 0,77–0,93, madalam täpsus 0,27–0,47), st leiavad peaaegu kõik kuldstandardi probleemid, aga lisaks ka palju kandidaate, mida autori koostatud kuldstandard probleemiks ei pidanud. Testkogu katkendid ja kuldstandard on autori juhendamisel LLM-iga koostatud sünteetilised tekstid; üldistus päris üliõpilastöödele eeldab sama metoodika kohaldamist päris katkenditele, mis kuulub jätkukavasse. Töös rõhutatakse, et süsteem on tudengi enda kirjutatud teksti tagasisidevahend, mitte juhendaja ega tekstigeneraator.

**Võtmesõnad:** Suured keelemudelid, eesti keel, akadeemiline tekst, tagasiside, prototüüp, pilootuuring, promptimine

**CERCS:** P175 Informaatika, süsteemiteooria

# Prototype Design and Pilot Study of an LLM-Based Feedback System for Estonian Computer Science Texts

## Abstract:

Writing a computer science thesis in Estonian is linguistically and structurally demanding for a student because the field's terminology has evolved in English and academic style conventions are applied differently in Estonian. The aim of this bachelor's thesis is to *design and implement* a prototype based on a large language model (LLM) that provides automatic feedback on Estonian-language computer science thesis texts in four categories: structure, academic style, terminological consistency, and the need for citation, and to *empirically evaluate* the quality of its output. The prototype is implemented as a web application that takes a student-written chapter as input, sends it to the chosen language model with a structured prompt, and presents categorised feedback to the user. The thesis carries out both a *qualitative pilot study* for prompt design iteration and a *full empirical evaluation*: 80 real API calls were made against 20 synthetic test excerpts (Claude 4.7 Opus and GPT-5.5, both with a generic and a structured prompt), and the model outputs were scored at span level against a gold standard. Results: macro  $F_1$  ranges from 0.38 to 0.56, the best combination is GPT-5.5 + structured prompt ( $F_1 = 0.56$ ); the structured prompt consistently improves  $F_1$  across both models; models are recall-biased (high recall 0.77–0.93, lower precision 0.27–0.47), i.e. they find almost all gold-standard problems but additionally flag many candidates that the author-annotated gold standard did not consider problems. The test corpus excerpts and gold standard are LLM-generated synthetic texts produced under the author's supervision; generalisation to real student theses requires applying the same methodology to real excerpts, which forms part of the follow-up. The thesis emphasises that the system is a feedback tool for text the student has written themselves; it neither replaces the supervisor nor generates the thesis on the student's behalf.

**Keywords:** Large language models, Estonian language, academic text, feedback, prototype, pilot study, prompting

**CERCS:** P175 Informatics, systems theory

# Sisukord

|                                                              |    |
|--------------------------------------------------------------|----|
| 1. Sissejuhatus .....                                        | 6  |
| 2. Taust ja seotud tööd .....                                | 11 |
| 2.1 Suured keelemudelid .....                                | 11 |
| 2.2 LLM-id eesti keeles.....                                 | 12 |
| 2.3 Akadeemilise teksti kvaliteediomadused.....              | 12 |
| 2.3.1 Struktuur .....                                        | 12 |
| 2.3.2 Akadeemiline stiil .....                               | 13 |
| 2.3.3 Terminoloogia järjepidevus.....                        | 13 |
| 2.3.4 Viitamisvajadus .....                                  | 13 |
| 2.4 Promptimine ja struktureeritud viibad .....              | 14 |
| 2.5 Seotud tööd .....                                        | 14 |
| 3. Metoodika .....                                           | 16 |
| 3.1 Uurimisprotsess.....                                     | 16 |
| 3.2 Tagasisidekategoriate operatsionaalne määratlus .....    | 17 |
| 3.3 Mudeli valik .....                                       | 18 |
| 3.4 Promptide disain.....                                    | 19 |
| 3.4.1 Üldine prompt .....                                    | 19 |
| 3.4.2 Struktureeritud prompt.....                            | 20 |
| 3.5 Hindamismetoodika .....                                  | 22 |
| 3.5.1 Testkogu disain .....                                  | 22 |
| 3.5.2 Kuldstandardi koostamise protseduur.....               | 22 |
| 3.5.3 Mõõdikud.....                                          | 23 |
| 3.5.4 Promptide võrdlus.....                                 | 23 |
| 4. Prototüüp .....                                           | 25 |
| 4.1 Nõuded.....                                              | 25 |
| 4.2 Süsteemi arhitektuur.....                                | 25 |
| 4.3 Tehnoloogiavalik .....                                   | 26 |
| 4.4 Promptide implementatsioon ja vastuse järeltöötlus ..... | 26 |
| 4.5 Kasutajaliides.....                                      | 27 |
| 4.6 Eetilised piirangud .....                                | 28 |
| 5. Pilootuuring ja empiiriline hindamine .....               | 31 |
| 5.1 Pilootuuringu metoodika ja valim .....                   | 31 |

|                                                                                      |    |
|--------------------------------------------------------------------------------------|----|
| 5.2 Kvalitatiivsed tähelepanekud kategooriate kaupa.....                             | 32 |
| 5.2.1 Viitamisvajadus .....                                                          | 32 |
| 5.2.2 Struktuur.....                                                                 | 32 |
| 5.2.3 Akadeemiline stiil.....                                                        | 33 |
| 5.2.4 Terminoloogia.....                                                             | 33 |
| 5.3 Üldise ja struktureeritud prompti võrdlus.....                                   | 33 |
| 5.4 Mudelite tundlikkus pilootuuringu tasemel .....                                  | 34 |
| 5.5 Kvalitatiivsed näidisleiud .....                                                 | 34 |
| 5.6 Arutelu ja esialgsed vastused uurimisküsimustele.....                            | 35 |
| 5.7 Pilootuuringu piirangud .....                                                    | 36 |
| 5.8 Empiiriline hindamine sünteetisel testkogul .....                                | 38 |
| 5.8.1 Testkogu ja kuldstandardi koostamine.....                                      | 38 |
| 5.8.2 Päringute teostamine .....                                                     | 39 |
| 5.8.3 Empiirilised tulemused .....                                                   | 39 |
| 5.8.4 Tulemuste arutelu .....                                                        | 40 |
| 5.8.5 Empiirilise hindamise piirangud .....                                          | 42 |
| 5.9 Edasise hindamise jätkukava.....                                                 | 43 |
| 6. Kokkuvõte.....                                                                    | 45 |
| Viited.....                                                                          | 48 |
| Lisad .....                                                                          | 51 |
| Lisa I: Testkogu disain ja kasutatud sünteetiline testkogu.....                      | 51 |
| Lisa II: Struktureeritud prompti täielik tekst.....                                  | 52 |
| Lisa III: Lähtekood ja andmestik.....                                                | 55 |
| Lisa IV: Prototüübi kasutusjuhend.....                                               | 55 |
| Litsents .....                                                                       | 57 |
| Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks..... | 57 |

# 1. Sissejuhatus

Bakalaureusetöö kirjutamine on iga informaatika tudengi õpinguid lõpetav mahukas iseseisev töö, mille puhul hinnatakse nii teaduslikku panust kui ka töö vormistamist ja keelelist kvaliteeti. Tartu Ülikooli arvutiteaduse instituudi nõuetes moodustab vormistamine ligi 25 % lõputöö koondhindest [1], kusjuures suurt rõhku pannakse selgele struktuurile, akadeemilisele stiilile, terminoloogia järjepidevusele ja korrektsele viitamisele. Eestikeelses informaatika lõputöös on need nõuded eriti keerulised täita, sest valdkonna terminoloogia on suuresti arenenud välja inglise keeles ning paljudele mõistetele puudub väljakujunenud eestikeelne vaste või on neid mitu.

Suurte keelemodelite (*ingl. large language model*, edaspidi LLM) viimaste aastate areng on toonud kaasa loomuliku keele töötluse vahendid, mis suudavad analüüsida ja parandada mahukaid tekste märkimisväärse usaldusväärsusega [2–4]. Kui veel mõni aasta tagasi olid sellised vahendid valdavalt ingliskeelsed, siis kaasaegsed mitmekeelsed mudelid nagu Claude 4.7 Opus, GPT-5.5 ja Gemini 2.x suudavad töödelda ka eesti keelt mõistliku kvaliteediga, mida kinnitavad TartuNLP avalikud võrdlused (vt baromeeter [5]). See loob võimaluse rakendada LLM-e tudengite kasuks neil erialadel, kus eestikeelne akadeemiline kirjutamine on traditsiooniliselt olnud keeruline.

Akadeemilises kontekstis on LLM-ide kasutamine samas eetiliselt tundlik teema. Tartu Ülikooli generatiivse tehisarut kasutamise juhend [6] eristab selgelt teksti *loomist* (mis ei ole lõputöös tudengi enda panusena lubatud) ja teksti *tagasisidestamist* (mis on lubatud, kui tudeng saadud soovitusi ise kriitiliselt hindab ja rakendab). Käesolevas töös käsitletav süsteem kuulub üheselt teise kategooriasse: see ei kirjuta lõputööd tudengi eest ega asenda juhendajat, vaid annab tudengi enda kirjutatud tekstile soovituslikku tagasisidet. See eristus on teema akadeemilise vastuvõetavuse jaoks kriitilise tähtsusega ning seda tuleb selgelt rõhutada nii süsteemi kasutajaliideses kui ka tagasiside tekstis endas.

## Töö eesmärk ja ulatus

Käesoleva bakalaureusetöö **eesmärk** on *kavandada ja realiseerida* LLM-il põhinev prototüüp, mis annab eestikeelsele informaatika lõputöö tekstile automaatset tagasisidet struktuuri, akadeemilise stiili, terminoloogia järjepidevuse ja viitamisvajaduse kohta, ning *hinnata* selle väljundi kvaliteeti nii kvalitatiivse pilootuuringu kui ka sünteetilisel testkogul tehtud empiirilise hindamisega.

**Töö ulatus.** Käesoleva töö raames tehti:

1. tagasisidekategoriate operatsionaalne määratlus;
2. kahe promptimisstrateegia (üldine ja struktureeritud) disain;
3. veebipõhise prototüübi realiseerimine, sealhulgas demo-režiim, mis võimaldab süsteemi proovida ilma välise LLM-i API juurdepääsuta;
4. kvalitatiivne pilootuuring väikesel tekstivalimil prompti disaini iteratsiooniks ja mudeli väljundi tüüpiliste mustrite tuvastamiseks;
5. 20-katkendilise sünteetilise testkogu ja kuldstandardi koostamine (autori juhendamisel LLM-iga; vt allpool generatiivse tehisaru deklaratsioon);
6. täismahuline empiiriline hindamine 80 päris API-päringu põhjal (kaks mudelit  $\times$  kaks prompti  $\times$  20 katkendit) koos täpsuse, saagise ja  $F_1$ -skoori arvutamisega iga (mudel  $\times$  promptitüüp  $\times$  kategooria) kombinatsiooni kohta.

**Töö ulatusest on teadlikult välja jäetud:** päris üliõpilastöödel põhinev testkogu (käesolev testkogu on sünteetiline) ning sõltumatu teise annoteerija kaasamine kuldstandardi koostamisse (käesoleva töö kuldstandard on ühe annoteerija ehk autori koostatud). Nende sammude jätkukava on esitatud peatükis 5.9. Selline ulatusepiirang on motiveeritud sellega, et päris üliõpilastöödel kuldstandardi koostamine sõltumatu teise annoteerijaga nõuab eraldi tööd, mis kuulub edasisse töösse (näiteks magistriõppes või avaldatavas artiklis).

## Uurimisküsimused

Käesolev töö käsitleb järgmisi **uurimisküsimusi**, millele annab nii kvalitatiivse pilootuuringu vastused (peatükk 5.6) kui ka kvantitatiivse empiirilise hindamise vastused sünteetilisel testkogul (peatükk 5.8); päris üliõpilastöödel sama meetodika kohaldamine kuulub jätkukavasse (peatükk 5.9):

1. Millise iseloomuga tagasisidet annab tippkvaliteediga LLM eestikeelse informaatika lõputöö tekstile, kui sellele antakse struktureeritud kategoorianõuetega prompt?
2. Millistes tagasisidekategoriates on mudeli väljund kõige usaldusväärsem ning millistes kõige problemaatilisem, ja miks?
3. Kas struktureeritud promptimine annab üldisest promptist süsteemsemat ja kasutuskõlblikumat tagasisidet?

Töö keskne **hüpotees** – mida uurimisküsimus 3 operatsionaliseerib – on, et struktureeritud kategooria- ja skeemipõhine promptimine annab eestikeelse informaatika lõputöö teksti tagasisidestamisel üldisest viibast süsteemsemat ja kasutuskõlblikumat väljundit (vt täpsem sõnastus peatükis 2.4).

Pilootuuringu tähelepanekud ja empiirilised tulemused, mis nendele küsimustele vastavad, on esitatud peatükis 5.

## **Praktiline panus ja piirangud**

Töö praktiline tulemus on lokaalselt käivitatav veebiprototüüp, kus kasutaja saab valida lõputöö peatükitüübi (sissejuhatus, taust, metoodika, tulemused, kokkuvõte), sisestada enda kirjutatud teksti ning saada struktureeritud tagasisidet neljas eelnimetatud kategoorias. Prototüüp on kavandatud nii, et seda saab proovida *demo-režiimis* salvestatud näidisvastustega ilma välise LLM-i API juurdepääsuta, mis muudab töö praktilise tulemuse reprodutseeritavaks minimaalsete eeldustega.

**Töö ei käsitle** LLM-i kasutamist lõputöö *loomiseks*. Süsteem on mõeldud tudengi enda kirjutatud tekstile tagasiside saamiseks ega püüa asendada juhendaja sisulist tagasisidet. Mudeli soovitusel on kasutaja jaoks vaid lähtepunkt – iga soovitusel vastuvõtmine, ümbersõnastamine või tagasilükkamine on tudengi enda otsustada.

## **Töö ülesehitus**

Peatükis 2 esitatakse ülevaade suurte keelemudelite arhitektuurist, eestikeelsest LLM-tugist ja akadeemilise teksti automaatselt tagasisidestamisest, samuti kirjeldatakse seotud töid. Peatükk 3 määratleb tagasisidekategooriad ning kirjeldab prompti disaini põhimõtteid ja hindamismetoodikat. Peatükis 4 kirjeldatakse prototüübi arhitektuuri, tehnoloogilist lahendust ja kasutajaliidese disaini. Peatükk 5 esitab pilootuuringu kvalitatiivsed tähelepanekud, sünteetiliselt testkogul tehtud empiirilise hindamise tulemused ning päris üliõpilastöödel põhineva jätkuhindamise kava. Peatükis 6 antakse kokkuvõtte töö panusest ning visandatakse võimalused edasiseks uurimiseks. Lisas I on esitatud kasutatud sünteetilise testkogu kirjeldus ja kavandatud päris testkogu disain, lisas II struktureeritud prompti täielik tekst, lisas III lähtekoodi ja andmestiku struktuur ning lisas IV prototüübi kasutusjuhend (sealhulgas demo-režiimi käivitamine ilma API-võtmata).



## Generatiivse tehisaru kasutamise deklaratsioon

Käesoleva töö koostamisel on generatiivset tehisaru (peamiselt Anthropic Claude 4.7 Opus mudelit) kasutatud järgmisel kolmel viisil, mille autor selgesõnaliselt deklareerib:

1. **Tekstilise abivahendina** – loetavuse parandamiseks, sõnastuse poleerimiseks ja struktuurinõustamiseks. Kõik sisulised mõtted, töö ulatuse valikud, metoodilised valikud ja järeldused on autori enda otsused. Mudeli ettepanekud on iga kord kriitiliselt üle vaadatud ja vajadusel ümber sõnastatud või kõrvale jäetud.
2. **Hindamise testkogu ja kuldstandardi koostamise abivahendina** – alapeatükis 5.8 esitatud empiirilise hindamise jaoks on 20 testkatkendit (iga ligikaudu 100–160 sõna) ja 42 kuldstandardi annotatsiooni koostatud autori juhendamisel Claude 4.7 Opus mudeliga *interaktiivse vestlusliidese kaudu (Claude Code)*, mitte programmiliste API-päringute kaudu. See ühekordne genereerimisprotsess on metoodiliselt eraldatud alapeatükis 5.8 kirjeldatud hindamispäringutest, mis kasutavad Anthropic ja OpenAI tasulisi API-sid skriptipõhiselt; testkogu ja kuldstandardi koostamine ei toimunud nende API-de kaudu. Tegu ei ole anonüümitud üliõpilastööde katkenditega, vaid sünteetiliste tekstidega, mis on koostatud nii, et katkendid sisaldaksid ette nähtud tüüpilisi probleeme tagasisidekategoriates. See piirang on selgesõnaliselt välja toodud alapeatükis 5.8 ning piirangute jaotises 5.7. Päril üliõpilastööde katkendite kasutamine kuulub jätkukavasse (vt alapeatükk 5.9).
3. **Hinnatavate mudelivastuste tegelike API-päringute kaudu** – alapeatükis 5.8 esitatud  $F_1$ -skoorid on tegelikud empiirilised mõõtmised: iga (katkend  $\times$  promptitüüp  $\times$  mudel) kombinatsiooni jaoks tehti tegelik API-päring Anthropic Claude 4.7 Opus või OpenAI GPT-5.5 mudelile (kokku 80 päringut), salvestati toorvastus repositooriumi kausta `statistika/andmed/paris_vastused/` ning skooriti spani-tasemel kattuvuse järgi kuldstandardi vastu. *Need numbrid kajastavad tegelikku mudelite sooritust* antud sünteetilisel testkogul, kuid nende üldistatavus päril üliõpilastöödele on piiratud, kuna testkogu ise on sünteetiline (vt punkt 2).

Selline kasutus on otseses kooskõlas Tartu Ülikooli generatiivse tehisaru juhendiga [6], mis lubab generatiivse tehisaru kasutamist õppetöös *tingimusel, et selline kasutus on selgesõnaliselt deklareeritud*. Reprodutseerimiseks vajalikud skriptid, salvestatud API-vastused ja andmestik on saadaval töö repositooriumis ( [https://github.com/UkuRenekKronbergs/TI\\_bakalaureusetoo](https://github.com/UkuRenekKronbergs/TI_bakalaureusetoo)) kausta `statistika/`. Lugeja saab seal vaadata, kuidas iga arv tekib (failid

andmestik\_synth.py, paris\_hindamine.py ning vastuste JSON-id alamkaustas  
paris\_vastused/).

## 2. Taust ja seotud tööd

Käesolevas peatükis antakse ülevaade töö tausta moodustavatest valdkondadest. Alapeatükis 2.1 kirjeldatakse suurte keelemudelite arhitektuurset alust ja võimekust. Alapeatükk 2.2 käsitleb LLM-ide võimekust eesti keeles ning sellega seotud kitsaskohti. Alapeatükis 2.3 määratletakse akadeemilise teksti kvaliteediomadused, millele süsteem tagasisidet annab. Alapeatükk 2.4 esitab promptimise põhimõtted, mis on prototüübi disainile aluseks. Lõpuks vaadeldakse alapeatükis 2.5 teksti tagasisidestamise olemasolevaid lahendusi ja akadeemilist kirjandust.

### 2.1 Suured keelemudelid

Suur keelemudel on iseseisva õppega närvivõrk, mis on treenitud massiivsel loomuliku keele andmestikul nii, et ta suudab etteantud tekstiosa põhjal ennustada järgnevat sõna [2, 7]. Tänapäevased mudelid põhinevad *Transformer*-arhitektuuril [7], milles keskne mehhanism on enesetähelepanu (*ingl. self-attention*). See mehhanism võimaldab mudelil iga sõna esituses arvesse võtta kõikide eelnevate (ning mõnedel juhtudel ka järgnevate) sõnade konteksti, mis teeb mudeli pikkade sõltuvuste tuvastamisel oluliselt võimekamaks varem domineerinud rekurrentsetest närvivõrkudest [8].

Mudeli treenimine jaguneb tüüpiliselt kaheks etapiks: eelkoolitus (*ingl. pre-training*) suurtel struktureerimata tekstikorpustel ning järelhäälestus (*ingl. fine-tuning*) konkreetseteks ülesanneteks. Juhiseid järgivate mudelite (nagu GPT, Claude, Gemini) puhul lisandub veel inimtagasiside abil õppimine (*ingl. reinforcement learning from human feedback, RLHF*) [9], mille käigus mudel kohandatakse vastama loomuliku keele juhistele turvaliselt ja kasulikult.

Treeningu mahukus on dramaatiliselt kasvanud. Nii GPT-3 (175 miljardit parameetrit, 2020) [2] kui ka selle järglased on näidanud nähtust, mida on hakatud nimetama *esiletõusvateks võimeteks* (*ingl. emergent abilities*): mudelid lahendavad ülesandeid, mille jaoks neid spetsiaalselt ei treenitud, kui parameetrite arv ja andmemahut ületavad teatud piiri [10]. Just see omadus võimaldab kasutada üht ja sama mudelit nii teksti kokkuvõtmiseks, küsimustele vastamiseks kui ka käesolevas töös käsitletud tagasiside andmiseks.

LLM-ide kasutamisega kaasnevad ka tuntud puudujäägid. Mudelid võivad esitada faktiliselt ekslikke väiteid suure enesekindlusega (*ingl. hallucination*) [11], mille olulisust akadeemilise teksti kontekstis ei saa alahinnata. Lisaks võivad mudelid jäljendada treeningandmetes esinevaid süstemaatilisi kallutatusi ning ühe konkreetse mudeli väljund ei pruugi olla deterministlik – sama prompt võib eri kordadel anda erinevaid tulemusi.

## 2.2 LLM-id eesti keeles

Eesti keel on inglise keelega võrreldes vähese ressursiga keel: kuigi tegu ei ole kõige väiksema kõnelejaskonnaga keelega maailmas, on eestikeelse digitaalse teksti maht oluliselt väiksem ning seetõttu on eesti keele esindatus tüüpilises mitmekeelses treeningkorpuses (näiteks Common Crawl) väga marginaalne. Sellele vaatamata on viimaste põlvkondade üldotstarbelistes mudelites eesti keele kvaliteet märgatavalt paranenud. Tartu Ülikooli loomuliku keele töötluste uurimisrühma (TartuNLP) avalik eesti keele LLM-võrdlusplatvorm (baromeeter) [5] võrdleb nii avatud kui ka kommertsiaalsete mudelite jõudlust eestikeelsetel ülesannetel ning näitab, et tipptasemel mitmekeelsed mudelid (sh Claude 4.x ja GPT-5.5) kuuluvad eesti keele kvaliteedi poolest tippu, kuigi inglise keele võrreldavale tasemele üldjuhul veel alla jäävad.

Lisaks üldotstarbelistele LLM-idele on Eestis arendatud spetsiaalseid eesti keele mudeleid. EstBERT [12] on BERT-arhitektuuril põhinev mudel, mis on eelkoolitatud eestikeelsel korpusel ning sobib selliste klassifitseerimisülesannete jaoks nagu sentiment- ja teemaanalüüs. EstBERT-i kasutamine teksti genereerimist nõudvate ülesannete jaoks on aga piiratud, kuna mudel on arhitektuuriselt enkooder-tüüpi. Eestikeelseid generatiivseid mudeleid on hakatud aktiivselt arendama hiljutiste avatud lähtekoodiga mudelite (näiteks Llama-2 ja Llama-3) baasil – nii on TartuNLP koostanud Llammas-mudeli, mille treenimine ja hindamine on dokumenteeritud Kuulmetsa jt tootes [13, 14] – kuid nende ulatus jääb tippkommertsmodelitele alla.

Praktilises rakenduses tähendab see, et eestikeelse akadeemilise teksti analüüsiks on otstarbekam kasutada tippkvaliteediga mitmekeelseid mudeleid (Claude 4.7 Opus, GPT-5.5) kui spetsialiseeritud avatud mudeleid, kui prioriteediks on kvaliteet, mitte kohaliku andmetöötlemise nõue.

## 2.3 Akadeemilise teksti kvaliteediomadused

Akadeemilise teksti kvaliteet on mitmemõõtmeline. Burstein jt [15] on automaatse esseede hindamise (*ingl. automated essay scoring*, AES) ülevaates eristanud vähemalt järgmisi mõõtmeid: sisuline asjakohasus, organiseeritus, sõnavara, stiili sobivus ja mehaanilised vead. Käesolevas töös on rõhk neljal omadusel, mis on Tartu Ülikooli arvutiteaduse instituudi nõuete [1] kontekstis kõige otsesemalt hinnatavad ja mille puhul automaatne tagasiside on praktilise väärtusega.

### 2.3.1 Struktuur

Lõputöö struktuur peab olema lugejale loogiliselt järgitav. Iga peatükk algab sissejuhatava lõiguga, alampeatükid peavad olema teemaga seotud, peatüki sees on hea kasutada siduvaid

lauseid eri lõikude vahel ning peatüki lõpus võiks olla sünteesilõik. Peatükk ei peaks algama ega lõppema joonise, tabeli ega loeteluga ilma teksti vaheta [1]. Strukturaalsed probleemid hõlmavad seega liiga lühikesi peatükke, sissejuhatava lõigu puudumist, ebaloogilist alampeatükkide järjekorda ja sujumatut lõikudevahelist üleminekut.

### 2.3.2 Akadeemiline stiil

Akadeemiline stiil eestikeelses lõputöös järgib eesti keele head tava ja teadusliku kirjutamise norme. Tüüpilised stiilivead on järgmised: kõnekeelsete väljendite kasutamine (näiteks *tüüp*, *asi*, *teha*); umbisikuline tegumood seal, kus seda ei nõuta, või vastupidine viga; mina-vormi liigne kasutamine; liigselt pikad ja keerulised laused; kvalifitseerimata üldistused (*kõik teavad*, *et...*); inglise keele otsetõlke ilmingud (näiteks *see on tõsi*, *et...* kui konstruktsiooni *it is true that...* otsetõlge). Hyland [16] on rõhutanud, et akadeemiline stiil ei ole pelgalt sõnavara valik, vaid ka selge metadiskursus, mis juhhib lugejat läbi teksti.

### 2.3.3 Terminoloogia järjepidevus

Tehnilises informaatika tekstis on terminoloogiavalik eriti oluline. Sama mõiste kohta tuleks kasutada läbivalt sama terminit (näiteks *andmebaas*, mitte vaheldumisi *andmebaas* ja *baas*; või *lõim*, mitte vaheldumisi *lõim* ja *niit*). Tihti tuleb teha valik kahe võrdselt levinud variandi vahel, näiteks *kasutajaliides* vs *kasutajapind*, *järjend* vs *loend*, *kompileerimine* vs *tõlkimine*. Eesti Keele Instituudi terminisõnastik<sup>1</sup> ja Tartu Ülikooli arvutiteaduse instituudi sõnastikud annavad osa juhiseid, kuid sageli on autoril vaja teha autonoomne valik ning seda valikut järjekindlalt rakendada. Lisaks kerkib küsimus, millal tuua sisse ingliskeelne termin (*kursiivis sulgudes*) ja millal seda enam mitte korrata.

### 2.3.4 Viitamisvajadus

Iga väide, mis ei ole autori enda originaalne mõte ega üldteadmine, vajab viidet allikale. Vastasel juhul on tegu akadeemilise petturlusega. Levinud probleemid on järgmised: viiteta esitatud arvulised väited (*75 % kasutajatest eelistab...*); konkreetne metoodika või algoritm, mille puhul viidet pole esitatud; teiste autorite definitsioonide refereerimine ilma viiteta. LLM-i ülesanne ei ole ise viiteid leida, vaid signaalida, kus viide on tõenäoliselt vajalik – lõpliku otsuse ja kontrolli jätab autor endale.

---

<sup>1</sup> <https://termin.eki.ee/>

## 2.4 Promptimine ja struktureeritud viibad

LLM-i käitumist juhitakse *prompti* ehk viiba abil – see on tekstiline juhis, mille mudel saab koos analüüsitava sisendiga. Viiba kvaliteet mõjutab mudeli väljundit oluliselt. Promptimisstrateegiate ülevaates [17] eristatakse muu hulgas:

- **Nullhetk-promptimine** (*ingl. zero-shot prompting*) – mudelile antakse ainult ülesanne ja sisend, näideteta.
- **Vähehetk-promptimine** (*ingl. few-shot prompting*) – ülesandele lisatakse mõned näited oodatava sisendi-väljundi paari kohta.
- **Mõtteahel-promptimine** (*ingl. chain-of-thought prompting*) – mudelilt küsitakse selgesõnaliselt vahesammude põhjendust enne lõplikku vastust [18].
- **Struktureeritud väljundi nõue** – mudelilt nõutakse väljundit kindlal kujul, näiteks JSON-i, mis lihtsustab automaatset järeltöötlust [19].

Käesolevas töös testitakse kaht promptimisstrateegiat. Mõlemad nõuavad mudelilt sama JSON-skeemiga väljundit, et automaatne järeltöötlus oleks võrreldav. *Üldine (baseline)* prompt esitab mudelile vaid rolli ja minimaalse JSON-skeemi (lisaks neljale tagasisidekategoriale lubatud ka MUU), kuid *ei sisalda* kategooriate definitsioone, näiteid ega täpsustavaid reegleid. *Struktureeritud* prompt määrab täpselt neli kategooriat, esitab iga kategooria kohta vähehetknäiteid ja vastunäiteid, sisaldab mõtteahel-elementi (mudel peab iga tuvastatud probleemi jaoks põhjendama, miks ta seda probleemiks peab) ning sõnastab konservatiivsust suunavaid reegleid. Hüpotees on, et struktureeritud prompt annab täpsemat ja võrreldavamalt väljundit.

## 2.5 Seotud tööd

Automaatse teksti tagasisidestamise valdkond on pikaajaline. Klassikalised süsteemid nagu Criterion [20] ja e-rater [21] on alates 2000. aastatest võimaldanud esseetasemel tagasisidet, kuid on välja töötatud peamiselt inglise keele jaoks. Grammarly [22] on tänapäeva enimkasutatud kommertsiaalne stiili- ja grammatikakontrolli vahend, mille eesti keele tugi on 2026. aasta seisuga endiselt piiratud.

Teadusartiklite kvaliteedi automaatset tagasisidestamist on uuritud süsteemides nagu SciScore [23] ja Paper Robot [24], kuid need keskenduvad meetoodika reprodutseeritavusele ja struktureeritud kontrollnimekirjadele, mitte üldisele stiilile ja terminoloogiale. LLM-ide tulekuga on hakanud ilmuma tööd, mis kasutavad GPT-4 ja Claude'i akadeemiliste kirjutiste

tagasisidestamiseks [25, 26]. Liang jt [25] näitavad, et GPT-4 antud tagasiside teadusartiklitele kattub umbes 30–39 % ulatuses inimretsensentide tagasisidega; see protsent on madalam kui inimretsensentide omavaheline kattuvus, kuid sellele lähedane.

Eestikeelse akadeemilise teksti automaatset tagasisidestamist on uuritud oluliselt vähem. Käesoleva töö raames ei õnnestunud tuvastada avaldatud uurimusi, mis käsitleksid spetsiaalselt eestikeelsete informaatika lõputööde automaatset tagasisidestamist generatiivsete LLM-ide abil. Käesolev töö täidab seda lünka kahel viisil: esiteks rakendab süsteemi spetsiaalselt informaatika lõputöödele, kus tehniline terminoloogia mängib suurt rolli, ja teiseks kasutab generatiivseid LLM-e koos struktureeritud promptiga.

Promptimise mõju kvaliteedile on samuti uuritud. Schulhoff jt [27] on viinud läbi süstemaatilise promptimistehnikate kataloogimise ning näitavad, et struktureeritud promptid annavad tüüpiliselt suuremat täpsust spetsiifilistel ülesannetel. Käesolev töö rakendab seda eestikeelse akadeemilise teksti analüüsile.

Käesoleva töö **teaduslik panus** on seega: (1) struktureeritud LLM-prompti disain eestikeelse informaatika teksti tagasisidestamiseks neljas kategoorias, (2) 20-katkendilise sünteetilise testkogu ja kuldstandardi koostamine koos hindamismetoodikaga ning (3) üldise ja struktureeritud prompti empiiriline võrdlus kahe tippmudeli põhjal, mille tulemused näitavad struktureeritud prompti järjepidevat eelist.

### 3. Metoodika

Käesolev peatükk kirjeldab, kuidas töö eesmärki realiseeritakse. Alapeatükk 3.1 esitatakse uurimisprotsess tervikuna ning eristatakse selgelt, millised sammud on käesoleva töö raames lõpule viidud ja millised on kavandatud jätkukavasse. Alapeatükk 3.2 määratleb tagasisidekategoriad operatsioonalselt. Alapeatükk 3.3 põhjendatakse mudeli valikut. Alapeatükk 3.4 esitab kahe võrreldava prompti disaini. Alapeatükk 3.5 kirjeldatakse hindamismetoodikat ja testkogu disaini, sealhulgas sünteetilisel testkogul tehtud empiirilise hindamise aluseid.

#### 3.1 Uurimisprotsess

Uurimine järgib disainiteaduse (*ingl. design science research*) põhimõtet [28]: identifitseeritakse probleem, projekteeritakse artefakt (käesoleval juhul prototüüp), rakendatakse seda ning hinnatakse rangelt. Hindamise põhjal saab teha järeldusi nii artefakti kui ka selle aluseks olevate disainivalikute kohta.

Töö protsess koosnes järgmistest etappidest:

1. Tagasisidekategoriate operatsioonaalne määratlemine kirjanduse ja TÜ juhendi põhjal.
2. Üldise ja struktureeritud prompti disain.
3. Prototüübi realiseerimine veebirakendusena, mis kutsub välja LLM-i API-d ning toetab salvestatud vastustega demo-režiimi.
4. Testkogu disain ja 20-katkendilise sünteetilise testkogu koostamine eri peatükkitüüpide põhjal.
5. Pilootuuring väikesel tekstivalimil: prototüübi väljundi kvalitatiivne analüüs prompti disaini iteratsiooniks.
6. Sünteetilise testkogu annoteerimine autori koostatud kuldstandardiks; sõltumatu teise annoteeriija kaasamine jäetakse jätkukavasse.
7. Prototüübi käivitamine kogu sünteetilise testkogu vastu mõlema prompti versiooniga ja mõlema mudeliga (Claude 4.7 Opus, GPT-5.5); mudeli väljundi võrdlemine kuldstandardiga ja näitajate (täpsus, saagis,  $F_1$ ) arvutamine iga kategooria kohta eraldi.
8. Üldise ja struktureeritud prompti tulemuste kvantitatiivne võrdlus.



**Käesoleva töö ulatus.** Sammud 1–8 on käesoleva töö raames lõpule viidud *sünteesilisel testkogul*. Teadlikult jäeti välja kaks suuremat sammu: päris üliõpilastöödel põhineva testkogu koostamine ning sõltumatu teise annoteerija kaasamine kuldstandardi koostamisse. Need on kavandatud jätkukavasse (vt alapeatükk 5.9), sest päris tööde katkendite valimine, anonüümimine ja kahekordne annoteerimine nõuavad eraldi aega ning metoodilist kontrolli.

### 3.2 Tagasisidekategoriate operatsioonaalne määratlus

Töös käsitletakse nelja tagasisidekategoriat. Iga kategooria kohta on tabelis 1 esitatud määratlus, näide tüüpilisest probleemist ning probleemi puudumise näide. Need määratlused olid aluseks nii prompti koostamisele kui ka tulevase kuldstandardi annoteerimisreeglitele.

Tabel 1. Tagasisidekategoriate operatsioonalsed määratlused.

| Kategooria                | Tüüpiline probleem                                                                                                                                            | Probleemi puudumise tunnus                                                                  |
|---------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|
| <b>Struktuur</b>          | Peatükk algab kohe alapealkirjaga ilma sissejuhatava lõiguga; lõikude vahel ei ole loogilist üleminekut.                                                      | Iga peatükk algab sissejuhatava lõiguga; alampeatükid on omavahel sujuvalt seotud.          |
| <b>Akadeemiline stiil</b> | Kõnekeel ( <i>tüüp, asi</i> ); liiga pikad laused; mina-vormi liigne kasutamine; otsetõlke ilmingud.                                                          | Kasutatakse neutraalset akadeemilist stiili; lauseehitus on selge.                          |
| <b>Terminoloogia</b>      | Sama mõiste tähistamiseks kasutatakse läbisegi mitut eri terminit ( <i>lõim ja niit</i> ); ingliskeelseid termineid esitatakse ilma esmakasutuse selgitusega. | Terminid on järjepidevad; ingliskeelsed terminid esitatakse esmakasutusel ka eestikeelselt. |
| <b>Viitamisvajadus</b>    | Konkreetsed arvulised või faktilised väited on esitatud ilma viiteta; metoodika kirjeldus on esitatud kui üldteadmised.                                       | Iga väide, mis pole autori enda originaalne mõte, on viidatud.                              |

Kategooriad on disainitud nii, et nad on *vastastikku eristatavad* – ühte sõnastust ei tohiks korraka liigitada kahte kategooriasse. Seda eristatavust kontrolliti pilootuuringus mudeli väljundi käsitsi läbivaatamise käigus ning eristatavus osutus piisavaks; päris testkogu annoteerimises kontrollitakse seda annoteerijatevahelise kokkuleppe abil.

**Pilootuuringust tulenevad määratluste täpsustused.** Pilootuuringus täheldatud näilised valepositiivsed (vt alapeatükk 5.2) viisid kahe määratluse selgesõnalise täpsustuseni, mida rakendatakse nii prompti vastunäidetes kui ka kuldstandardi annoteerimisreeglites:

- *Viitamisvajadus* ei rakendu üldteadmise tasandi väidetele – näiteks levinud protokollide või põhimõistete tutvustamisele –, mille puhul viidet ei oleks ka inimese kirjutatud akadeemilises tekstis oodatud.
- *Akadeemiline stiil* ei märgi probleemiks mina-vormi kasutust kohtades, kus tudeng kirjeldab selgelt enda originaalset panust või metoodilist valikut, kuna Tartu Ülikooli juhend lubab mina-vormi sellises kontekstis.

Need täpsustused on pilootuuringu *tulemus* ning on aluseks empiirilise hindamise ja jätkutöö annoteerimisreeglitele.

### 3.3 Mudeli valik

Töös kasutatakse esmase mudelina Anthropic'i `claude-opus-4-7` mudelit. Valiku tegemise kriteeriumid olid:

- **Eesti keele tugi:** TartuNLP avaliku eesti keele LLM-võrdlusplatvormi (baromeeter) [5] põhjal kuuluvad tipptasemel Claude'i ja GPT mudelid eesti keele kvaliteedi poolest tippmudelite hulka.
- **Pikk kontekstiaken:** 1 000 000 tokenit [29] võimaldab analüüsida kogu lõputöö peatükki korraga ilma sisendi tükeldamiseta.
- **Struktureeritud väljundi tugi:** mudel järgib usaldusväärselt JSON-skeemi kohaseid väljundinõudeid (vt alapeatükk 4.4).
- **Hind ja kättesaadavus:** API-ligipääs on tudengieelarve piires.

Tulemuste üldistatavuse kontrollimiseks kasutati paralleelselt ka OpenAI `gpt-5.5` mudelit, mille tugi on prototüübis realiseeritud. Alapeatükis 5.8 esitatud empiirilise hindamise raames käivitati prototüüp kõikide 20 sünteetilise testkatkendi vastu mõlema mudeli ja mõlema prompti versiooniga (kokku 80 API-päringut). Mõlema uue põlvkonna mudeli (Claude 4.7 Opus ja GPT-5.5) Messages/Chat Completions API ei aktsepteeri enam `temperature`-parameetrit, mistõttu pakkujakihid jätavad selle parameetri päringust automaatselt välja ning kasutatakse mudelite vaikeväärtusi [29, 30].

## 3.4 Promptide disain

Töös võrreldakse kahte prompti varianti: *üldist* ja *struktureeritud*. Mõlemad nõuavad mudelilt sama JSON-skeemiga vastust (et automaatne järeltöötlus oleks võrreldav), kuid erinevad selle poolest, kui palju juhiseid mudelile kategooriate ja oodatava käitumise kohta antakse.

### 3.4.1 Üldine prompt

Üldine prompt on lühike: see annab mudelile rolli ja JSON-skeemi (sealhulgas vabavormilise MUU-kategooria), kuid *ei sisalda* ühegi kategooria definitsiooni, näiteid, vastunäiteid ega kindlushinnangu täpsemat juhust. Seega on üldine prompt funktsionaalselt minimaalne baastase, millele struktureeritud prompt lisab kategooriapõhise sisu:

```
Oled eestikeelse informaatika lõputöö juhendaja abiline. Anna
↪ sisestatud
peatükile tagasisidet selle kvaliteedi kohta. Ole konstruktiivne
↪ ja
konkreetne. Tagasiside peab olema eesti keeles.
```

```
OLULINE: Sa ei kirjuta lõputööd tudengi eest ega sõnasta löike
↪ ümber.
Anna ainult soovituslikku tagasisidet.
```

Vasta JSON-formaadis järgmise skeemi järgi:

```
{
  "leiud": [
    {
      "kategooria": "STRUKTUUR" | "AKADEEMILINE_STIIL"
                  | "TERMINOLOOGIA" | "VIITAMISVAJADUS" | "MUU",
      "tsitaat": "tekstis täpne probleemne kohaviit (kuni 200
↪ tähemärki)",
      "probleem": "lühike kirjeldus, mis selles kohaviites on
↪ valesti",
      "põhjendus": "miks see on probleem",
      "soovitus": "konkreetne soovitus (kuni 200 tähemärki)",
      "kindlus": "kõrge" | "keskmine" | "madal"
    }
  ]
}
```

```
}

Peatüki tüüp: ${peatuki_tyyp}
Peatüki tekst:
"""
${tekst}
"""

Vasta ainult JSON-iga, ilma lisaselgitusega.
```

### 3.4.2 Struktureeritud prompt

Struktureeritud prompt erineb üldisest neljal olulisel viisil: (1) iga tagasisidekategooria täpne määratlus koos vähehetk-näidete ja vastunäidetega, (2) selgesõnaline eetiline meelepea (mudel ei tohi ümber sõnastada), (3) mõtteahel-element (*põhjemendus*-väli, mis nõuab mudelilt enda järelduse põhjendamist enne soovitusi) ja (4) reeglid, mis suunavad mudelit konservatiivsusele (*parem vähem õigeid kui palju valesid*). Kategooria MUU on jäetud välja, nõudes mudelilt nelja täpselt määratletud kategooria kasutamist. Prompti täielik tekst on esitatud lisas II.

Prompti võtmeosad on järgmised:

```
Oled eestikeelse informaatika lõputöö tagasisidesüsteem.
SUL EI OLE LUBATUD lõputööd tudengi eest kirjutada ega ümber
→ sõnastada.

Sa annad ainult soovituslikku tagasisidet tudengi enda kirjutatud
tekstile. Lõpliku otsuse iga soovitusel rakendamise kohta teeb
→ autor.

Sinu ülesanne on tuvastada probleemid täpselt neljas kategoorias:
1. STRUKTUUR
2. AKADEEMILINE_STIIL
3. TERMINOLOOGIA
4. VIITAMISVAJADUS

[Iga kategooria kohta järgnevalt määratlus, näited ja
→ vastunäited]
```

Vasta JSON-formaadis järgmise skeemi järgi:

```
{
  "leiud": [
    {
      "kategooria": "...",
      "tsitaat": "tekstis täpne probleemne kohaviit",
      "probleem": "lühike kirjeldus",
      "põhjendus": "miks see on probleem",
      "soovitus": "konkreetne parandusettepanek",
      "kindlus": "kõrge | keskmine | madal"
    }
  ]
}
```

Kui konkreetsetes kategoorias probleeme ei leita, jäta selle  
↪ kategooria  
kanded vahele. Ära leia probleeme, mida tegelikult pole.

### Põhjendatud disainivalikud.

- **Eetiline meelespea.** Prompti algusesse on paigutatud selge piirang, et mudel ei tohi tudengi eest kirjutada. See on kooskõlas TÜ generatiivse tehisaru juhendiga [6] ning vähendab pilootuuringus täheldatu põhjal tõenäosust, et mudel pakub tudengile valmis ümbersõnastusi.
- **Tsitaadi nõue.** Iga probleemi puhul peab mudel viitama konkreetsele tekstilõigule. See raskendab *halutsineerimist* ja teeb tagasiside auditeeritavaks; pilootuuringus täheldati, et tsitaadi nõue paneb mudeli oma leide täpsemini lokaliseerima.
- **Kindluse hinnang.** Iga leiu kohta nõutav kindlushinnang võimaldab kasutajaliideses madala kindlusega leide visuaalselt eristada ning hindamise käigus uurida, kas kindlus korreleerub leiu tegeliku õigsusega.
- **Põhjenduse nõue.** Mõtteahel-elementidena toimiv *põhjenduse* väli sunnib mudelit oma järeldust kontrollima ning aitab kasutajal otsustada, kas soovitus vastu võtta.

### 3.5 Hindamismetoodika

Käesolev alapeatükk kirjeldab metoodikat, mida rakendati sünteetilisel testkogul tehtud empiirilises hindamises ning mille laiendamine päris üliõpilastööde katkenditele on jätkukava osa. Käesolevas töös on metoodika rakendatud autori koostatud sünteetilise testkogu ja kuldstandardi peal; sõltumatu teise annoteerijaga päris testkogu jääb edasiseks tööks.

#### 3.5.1 Testkogu disain

Päris testkogu on kavandatud koosnema 20 eestikeelse informaatika lõputöö katkendist, kus iga katkendi pikkus on 200–400 sõna. Katkendid valitakse nii, et need katavad erinevaid peatükitüüpe (vt tabel 2). Allikateks on planeeritud kasutada Tartu Ülikooli arvutiteaduse instituudi avalikult kättesaadavaid bakalaureuse- ja magistritöid aastatest 2020–2024; katkendid valitakse nii, et need sisaldavad nii probleeme kui ka korrektseid löike, ning anonüümitakse enne kuldstandardi annoteerimist. Käesolevas töös rakendati sama peatükitüüpide jaotust lühemal, 20-katkendilisel sünteetilisel testkogul; päris testkogu lõplik koostamine ja annoteerimine on jätkukava esimene samm.

Tabel 2. Kavandatud testkogu katkendite jaotus peatükitüübi järgi.

| Peatüki tüüp         | Katkendite arv | Sihtpikkus (sõnu) |
|----------------------|----------------|-------------------|
| Sissejuhatus         | 4              | 250–320           |
| Taust ja seotud tööd | 5              | 280–360           |
| Metoodika            | 4              | 270–330           |
| Tulemused            | 4              | 240–290           |
| Kokkuvõte            | 3              | 230–260           |
| <b>Kokku</b>         | <b>20</b>      | —                 |

#### 3.5.2 Kuldstandardi koostamise protseduur

Käesolevas empiirilises hindamises koostas kuldstandardi autor, märkides iga sünteetilise katkendi puhul probleemse tekstilõigu, kategooria ning lühikese põhjenduse. Jätkukavas tuleks sama protseduuri laiendada kahes etapis: esiteks märgistab autor iseseisvalt iga tuvastatud probleemi, teiseks vaatab teine sõltumatu annoteerija (näiteks teise õppekava tudeng või juhendaja) samad katkendid läbi ning lahkarvamuste korral lepitakse kokku ühises lahenduses. Annoteerijatevahelist kokkulepet mõõdetakse iga kategooria kohta eraldi Coheni  $\kappa$ -ga [31], mis

on kahe annoteerija ja nominaalsete kategooriate puhul konventsionaalne valik. Krippendorffi  $\alpha$  [32] on jäetud reservi juhaks, kui hindamiskava laieneb järgmistes versioonides mitme annoteerijaga skeemiks.

### 3.5.3 Mõõdikud

Mudeli väljundi võrdlemiseks kuldstandardiga kasutatakse standardseid infootsingu mõõdikuid.

Iga kategooria  $c$  puhul:

- **Tõene positiivne** ( $TP_c$ ): mudel tuvastas probleemi, mis on ka kuldstandardis.
- **Vale positiivne** ( $FP_c$ ): mudel tuvastas probleemi, mis ei ole kuldstandardis.
- **Vale negatiivne** ( $FN_c$ ): kuldstandardis on probleem, mida mudel ei tuvastanud.

Sellest järeldatakse järgmised mõõdikud:

$$\text{Täpsus}_c = \frac{TP_c}{TP_c + FP_c} \quad (1)$$

$$\text{Saagis}_c = \frac{TP_c}{TP_c + FN_c} \quad (2)$$

$$F_{1,c} = \frac{2 \cdot \text{Täpsus}_c \cdot \text{Saagis}_c}{\text{Täpsus}_c + \text{Saagis}_c} \quad (3)$$

**Kattuvuse defineerimine.** Kuna mudel ja annoteerija võivad sama probleemi kirjeldada erinevate sõnadega, ei ole võimalik nõuda eksaktset stringivastet. Kattuvust hinnatakse järgmise reegli järgi: mudeli leid loetakse tõseks positiivseks, kui (1) tema osutatud tekstilõik kattub kuldstandardi probleemse lõiguga vähemalt 50 % ulatuses sõnatasemel ning (2) kategooria on sama. 50 % lävi on valitud kooskõlas span-tasemel hindamise levinud tavadega: poole ulatuses kattuv viidatud lõik tagab, et mudel ja annoteerija osutavad samale probleemile, mitte erinevatele probleemidele samas lauses. Kuna lävi ise on disainivalik, kontrollitakse selle robustsust jätkutöös eraldi tundlikkusanalüüsiga, esitades peamised mõõdikud ka 30 % ja 70 % läviga ning jälgides, kas kvalitatiivsed järeldused muutuvad. Kui kategooria erineb, loetakse leid mudeli vaates valepositiivseks ja kuldstandardi vaates valenegatiivseks.

### 3.5.4 Promptide võrdlus

Üldist ja struktureeritud prompti võrreldi, käivitades mudeli kõikide testkogu katkenditega kummagi prompti versioonis. Mõlemad promptid nõuavad sama JSON-skeemiga väljundit ja

kategooriavalikut, mistõttu skoorimine kuldstandardi vastu toimub mõlemal juhul automaatselt, ilma käsitsi vahesammuta. Erinevus, mida hindamine mõõdab, taandub seetõttu sisuliste juhiste mõjule – kas kategooria definitsioonid, näited ja reeglid parandavad mudeli täpsust ja saagist iga kategooria sees – mitte väljundvormingu erinevusele. Kategooria MUU, mida üldine prompt lubab, kuid struktureeritud mitte, käsitatakse skoorimises automaatselt valepositiivsena, kuna see ei vasta ühelegi nelja kategooria kuldstandardi annotatsioonile.



## 4. Prototüüp

Käesolev peatükk kirjeldab loodud prototüüpi. Alapeatükis 4.1 esitatakse süsteemile seatud funktsionaalsed ja mittefunktsionaalsed nõuded. Alapeatükk 4.2 kirjeldab süsteemi arhitektuuri. Alapeatükis 4.3 põhjendatakse tehnoloogiavalikut. Alapeatükk 4.5 kirjeldab kasutajaliidest ning tagasiside esitamise põhimõtteid. Alapeatükis 4.6 käsitletakse süsteemi eetilisi piiranguid ja nende tehnilist realiseerimist. Prototüübi täielik lähtekood on avalikult kättesaadav repositooriumis [https://github.com/UkuRenekKronbergs/TI\\_bakalaureusetoo](https://github.com/UkuRenekKronbergs/TI_bakalaureusetoo); käivitusjuhend on esitatud lisas 6.

### 4.1 Nõuded

Funktsionaalsed nõuded olid järgmised. Süsteem peab võimaldama kasutajal (1) sisestada eestikeelse teksti vabavormiliselt, (2) valida peatükitüübi (sissejuhatus, taust, meetodika, tulemused, kokkuvõte), (3) saada struktureeritud tagasisidet neljas eelmainitud kategoorias, (4) näha iga leiu juures konkreetset probleemset tekstilõiku, soovitusi ja kindlushinnangut, (5) valida üldise ja struktureeritud prompti vahel võrdluseks ning (6) eksportida tagasiside JSON-failina.

Mittefunktsionaalsed nõuded olid järgmised. Süsteem peab (1) töötama ühel tüüpilisel arendaja töömasinal ilma erilise riistvara nõudeta, (2) olema kasutatav tavalise veebibrauseri kaudu, (3) vastama tüüpilisele päringule alla 30 sekundi, (4) hoidma kasutaja teksti kogu töö vältel *ainult* mälus ja mitte kettal püsivalt, (5) edastama teksti välise LLM-i API-le ainult juhul, kui kasutaja on selle valiku teadlikult kinnitanud, ning (6) võimaldama proovikäivitust ka ilma välise LLM-i API juurdepääsuta (näiteks olukorras, kus hindajal pole API-võtit), et töö praktiline tulemus oleks reprodutseeritav minimaalsete eeldustega.

### 4.2 Süsteemi arhitektuur

Prototüüp järgib lihtsat klient-server-arhitektuuri. Arhitektuur on kujutatud joonisel 1. Süsteem koosneb kolmest komponendist: brauseripoolne kasutajaliides (**frontend**), kohalik teenus (**backend**) ja väline LLM-i API. Backend hoiab promptide malle ja vastutab nende sidumise eest sisestatud tekstiga ning JSON-vastuse järeltöötluse eest. Backend on kavandatud kihiliselt nii, et LLM-i pakkuja vahetamine (näiteks Anthropic Claude'ilt OpenAI GPT-le) nõuab muutusi ainult `providers/` kaustas.

Lisaks päris LLM-pakkujatele on backendis sama liidese taga ka *demo-pakkuja*, mis tagastab iga peatükitüübi jaoks varem genereeritud salvestatud näidisvastuse (vt fail `prototuupe/backend/demo_andmed.py`). Demo-pakkuja on vaikevalik, mis võimaldab

süsteemi proovida ja töö praktilist tulemust reprodutseerida ilma Anthropic'i või OpenAI API-võtmega; päris LLM-i kasutamiseks valib kasutaja kasutajaliideses mudeli `claude-opus-4-7` või `gpt-5.5`, mille kasutamine eeldab vastava võtme seadistamist keskkonnamuutujasse.

## Lõputöö Pealkiri


Autori Nimi  
Juhendaja(d)

Õppekava, AASTA



TARTU ÜLIKOOL  
arvutiteaduse instituut

#UniTartuCS



Joonis 1. Süsteemi üldine arhitektuur. Kasutaja sisestab teksti veebiliidesesse, mis saadab selle kohalikule backend-teenusele. Backend valib valitud prompti malli, kombineerib selle tekstiga ning saadab päringu LLM-i API-le. Mudeli vastus dekodeeritakse JSON-iks, valideeritakse skeemi vastu ning kuvatakse kasutajale.

## 4.3 Tehnoloogiavalik

Prototüübi realiseerimisel valiti tehnoloogiad järgmiste põhimõtete alusel: tuntud ja levinud tehnoloogiad (et reprodutseeritavus oleks lihtne), minimaalne lisakulu (*ingl. overhead*) ja kiire arendustsükkel.

## 4.4 Promptide implementatsioon ja vastuse järeltöötlus

Promptid on hoitud eraldi failidena `prototuupe/backend/prompts/ylidine.txt` ja `prototuupe/backend/prompts/struktureeritud.txt`, mis võimaldab neid muuta ilma koodi puudutamata. Sisenditeks olevad muutujad `${peatuki_tyyp}` ja `${tekst}` asendatakse Pythoni `string.Template`’iga, vältides Jinja2-tüüpi malliga kaasnevaid külgmõjusid.

Tabel 3. Prototüübi tehnoloogiline kombinatsioon ja valiku põhjendus.

| Komponent                   | Tehnoloogia                                | Põhjendus                                                                                                     |
|-----------------------------|--------------------------------------------|---------------------------------------------------------------------------------------------------------------|
| <b>Backend</b>              | Python 3.12 +<br>FastAPI                   | Anthropic SDK on Pythonis küps; FastAPI annab automaatselt OpenAPI dokumentatsiooni ja sisendi valideerimise. |
| <b>Frontend</b>             | React 18 +<br>TypeScript +<br>Tailwind CSS | TÜ tudengite seas levinud kombinatsioon; Tailwind võimaldab kiire stiili ilma eraldi CSS-failideta.           |
| <b>LLM-i API</b>            | Anthropic<br>Messages API                  | Claude 4.7 Opuse tugi, struktureeritud väljundi tugi ( <code>tools</code> või prefill-tehnika).               |
| <b>Skeemi valideerimine</b> | Pydantic + JSON<br>Schema                  | Backend valideerib mudeli vastust enne kasutajale saatmist; vea korral palutakse mudelilt parandus.           |
| <b>Pakendamine</b>          | Docker Compose                             | Lihtsustab käitamist; ühes <code>docker compose up</code> käivitub kogu süsteem.                              |

LLM-i päring on tehtud sünkroonse kutsega Anthropic'i SDK kaudu (vt joonis 2). Anthropicil kasutatakse *prefill*-tehnikat: assistendi sõnumi algusesse pannakse avav looksulg `{`, mis sunnib mudelit kohe JSON-vastusele üle minema, vältides selgituslikku sissejuhatust. OpenAI puhul kasutatakse `response_format={"type": "json_object"}` parameetrit. Mudeli vastus läbib JSON-i ekstraktimise (mis lõikab välja esimese tasakaalustatud JSON-objekti, kasutades sulgude arvestust ning stringidest möödumist) ning seejärel valideeritakse Pydantic-mudeli vastu. Kui valideerimine ebaõnnestub, tehakse mudelile järelpäring, mis sisaldab esialgset vastust ja konkreetset veateadet kommentaariga *Palun paranda vastus järgmise skeemi järgi*. Praktikas piisas peaaegu kõikidel juhtudel ühest järelpäringust.

## 4.5 Kasutajaliides

Kasutajaliides koosneb kahest peamisest paneelist (vt joonis 3). Vasakul paneelil saab kasutaja sisestada teksti, valida peatükitüübi rippmenüüst, valida promptitüübi (üldine või struktureeritud) ning käivitada analüüsi. Paremal paneelil kuvatakse mudeli leiud kategooriate kaupa, iga kategooria oma kokkupandava jaotisega. Iga leid on kuvatud kaardina, kus on probleemne tsitaat

(esiletõstetud), lühike kirjeldus, põhjendus, soovitus ning visuaalse värvikoodiga kindlushinnang (kõrge – tumeroheline, keskmine – kollane, madal – hall).

Kasutajaliidese disainivalikutest on olulisemad järgmised. *Probleemse tsitaadi esiletõstmine* algses tekstis aitab kasutajal kohe leida tagasisides viidatud kohta. *Kategooriate kokkupanidavus* võimaldab kasutajal keskenduda ühele kategooriale korraga ning vältida visuaalset ülekoormust juhul, kui leide on palju. *Kindlushinnangu visuaalne kodeerimine* võimaldab kasutajal kiiresti otsustada, milliseid leide tasub esmalt kontrollida.

## 4.6 Eetilised piirangud

Süsteemi disainimisel on otseselt arvestatud sellega, et see ei muutuks tudengi jaoks teksti *loomise* vahendiks. Selle tagamiseks rakendati neli eraldi meetet.

**Promptisisene piirang.** Süsteemi prompti algusesse on paigutatud selge nõue: *Sul ei ole lubatud lõputööd tudengi eest kirjutada ega ümber sõnastada*. See vähendab oluliselt tõenäosust, et mudel pakub valmis ümbersõnastusi.

**Soovitus, mitte ümbersõnastus.** Tagasiside skeemis on soovitus-väli mõeldud lühikese juhise andmiseks (näiteks *lisa enne alapealkirja sissejuhataav lõik, kus kirjeldad alampeatükkide loogilist järjekorda*), mitte tervete tekstilõikude valmis ümberkirjutamiseks. Backend lõikab soovitus-välja sisu 200 tähemärgini, mis muudab valmis ümberkirjutamise tehniliselt ebamugavaks.

**Selge teavitus kasutajaliideseist.** Igas vastuses on tagasiside paneeli päises pidevalt nähtav teade: *See süsteem annab soovituslikku tagasisidet sinu enda kirjutatud tekstile. See ei kirjuta lõputööd sinu eest. Kontrolli iga soovitus ja sõnasta vajadusel ümber*.

**Privaatsus.** Demo-režiimis (vaikevalik) ei lahku kasutaja sisestatud tekst kohalikust masinast: backend tagastab salvestatud näidisvastuse. Kui kasutaja valib mudeliks Claude'i või GPT, saadetakse tekst LLM-i API-le ainult pärast seda, kui ta on kinnitanud konkreetset dialoogiaknas, et ta on sellest teadlik. Kohalik backend ei salvesta sisestatud teksti kettale; logitakse ainult anonüümne sündmus (näitajad: promptitüüp, peatükitüüp, leidude arv kategooriate kaupa) hindamise jaoks.

Need meetmed ei ole täiuslikud – kasutaja võib endiselt prompti muuta või esitada ise ümberkirjutamise palve. Süsteemi roll on aga selgelt määratletud just tagasisidena, mitte loomise vahendina; vastutus konkreetse kasutusviisi eest jääb kasutajale.

```

from anthropic import Anthropic
from pydantic import BaseModel
from typing import Literal

class Leid(BaseModel):
    kategooria: Literal[
        "STRUKTUUR", "AKADEEMILINE_STIIL",
        "TERMINOLOOGIA", "VIITAMISVAJADUS"
    ]
    tsitaat: str
    probleem: str
    põhjendus: str
    soovitus: str
    kindlus: Literal["kõrge", "keskmine", "madal"]

class Vastus(BaseModel):
    leiud: list[Leid]

def kysi_tagasiside(prompt: str, mudel: str = "claude-opus-4-7") ->
    ↪ Vastus:
    klient = Anthropic()
    sonum = klient.messages.create(
        model=mudel,
        max_tokens=4096,
        temperature=0.2,
        messages=[
            {"role": "user", "content": prompt},
            {"role": "assistant", "content": "{}", # prefill
        ],
    )
    toores = "{" + sonum.content[0].text
    json_tekst = ekstraktee_tasakaalustatud_json(toores)
    return Vastus.model_validate_json(json_tekst)

```

Joonis 2. LLM-i kutsumise lihtsustatud Pythoni-kood koos JSON-prefilliga. Tegelikus prototüübis lisanduvad logimise, kordusküsimise (*ingl. retry*) ja vea käsitlemise abstraktsioonid ning eraldi pakujahikid Anthropic, OpenAI ja demo-režiimi salvestatud vastuste jaoks.

Eestikeelse lõputöö tagasisidesüsteem

Tudengi enda kirjutatud teksti automaatne kvaliteedikontroll neljas kategoorias. **Süsteem ei kirjuta lõputööd sinu eest.**

Peatüki tüüp

Sissejuhatus

Prompti tüüp

Struktureeritud prompt

Mudel

Claude 4.7 Opus

Lõputöö peatüki tekst

Bakalaureusetöö kirjutamine on iga informaatika tudengi õpingute lõpus seisev mahukas iseseisev töö, mille puhul hinnatakse võrdselt nii teaduslikku panust kui ka töö vormistamist ja keelelist kvaliteeti.

Tegelikult on see asi päris keeruline, kuna eesti keele terminoloogia on välja kujunenud inglise keeles. Üle 75% lõputöödest sisaldavad terminoloogia probleeme.

Sõnu: 56. Märke: 412.

Analüüsi

Eksportidi JSON

Meelespea: see süsteem annab soovituslikku tagasisidet sinu enda kirjutatud tekstile. See ei kirjuta lõputööd sinu eest. Kontrolli iga soovitus ja sõnasta vajadusel ümber.

Mudel: claude-opus-4-7 - Prompt: struktureeritud - Kestus: 4,3 s - Leide kokku: 3

Akadeemiline stiil (1)

Kõnekeelsete väljendite kasutamine

Kõrge kindlus

„Tegelikult on see asi päris keeruline.“

Põhjendus: Akadeemilises tekstis tuleks vältida kõnekeelseid täitesõnu „tegelikult“ ja „asi“.

Soovitus: Sõnasta lause ümber neutraalsemalt, näiteks: „Selle ülesande täitmine on keerukas, kuna...“.

Viitamisvajadus (1)

Arvuline väide ilma viiteta

Kõrge kindlus

„Üle 75% lõputöödest sisaldavad terminoloogia probleeme.“

Põhjendus: Konkreetne arvuline väide vajab toetust kirjandusallikast.

Soovitus: Lisa viide originaaluuringule või eemalda konkreetne protsent.

Struktuur (1)

Lõikudevahelise ülemineku puudumine

Keskmine kindlus

„... keelelist kvaliteeti. Tegelikult on see asi ...“

Põhjendus: Kahe lõigu vahel puudub sisuline üleminekulause: teema vahetus on järsk.

Soovitus: Lisa ühenduslause, mis selgitab, miks järgnev teema on eelmise jätk.

Joonis 3. Prototüübi kasutajaliidese kuvatõmmis. Vasakul: tekstisisend ja konfiguratsioon (peatükិតüüp, promptitüüp, mudel). Paremal: kategoriseeritud tagasiside, kus iga leid on kuvatud eraldi kaardina koos probleemse tsitaadi, kirjelduse, põhjenduse, soovituse ja kindlushinnanguga (kõrge — roheline, keskmine — kollane).

## 5. Pilootuuring ja empiiriline hindamine

**Peatüki ulatus.** Käesolev peatükk esitab nii *kvalitatiivse pilootuuringu* kui ka *kvantitatiivse empiirilise hindamise* tulemused. Pilootuuring viidi läbi prompti disaini iteratsiooni jooksul väikesel tekstivalimil eesmärgiga (1) veenduda, et prototüüp toodab valideeritava JSON-struktuuriga tagasiside, (2) tuvastada mudeli väljundis esinevad tüüpilised mustrid ning (3) suunata struktureeritud prompti sõnastust. Selle järel viidi läbi täismahuline empiiriline hindamine (alapeatükk 5.8), kus prototüüp käivitati 20 sünteetilise testkatkendi vastu mõlema mudeliga (Claude 4.7 Opus, GPT-5.5) ja mõlema prompti versiooniga (üldine, struktureeritud) – kokku 80 päris API-päringut – ning mudelite väljundid skooriti spani-tasemel kattuvuse järgi autori koostatud kuldstandardi vastu. *Testkogu katkendid ja kuldstandard on autori juhendamisel LLM-i abiga koostatud sünteetilised tekstid*, mitte päris üliõpilastööde katkendid – seda piirangut on selgesõnaliselt arutatud sissejuhatuse generatiivse tehisaru deklaratsioonis. Päris üliõpilastöödel hindamise läbiviimine kuulub alapeatükis 5.9 kirjeldatud jätkukavasse.

Alapeatükis 5.1 kirjeldatakse pilootuuringu metoodikat ja valimit. Alapeatükk 5.2 esitab kvalitatiivsed tähelepanekud kategooriate kaupa. Alapeatükis 5.3 võrreldakse üldist ja struktureeritud prompti illustreerivate näidete kaudu. Alapeatükk 5.4 käsitleb mudelite vahelist tundlikkust pilootuuringu täheldatud tasemel. Alapeatükis 5.5 esitatakse konkreetset näidisleiud. Alapeatükk 5.6 võtab pilootuuringu järeldused kokku ja vastab uurimisküsimustele *pilootuuringu tasemel*. Alapeatükis 5.7 käsitletakse pilootuuringu piiranguid. Alapeatükk 5.8 esitab täismahulise empiirilise hindamise tulemused 80 päris API-päringu põhjal sünteetilisel testkogul, sh täpsuse, saagise ja  $F_1$ -skoori iga (mudel  $\times$  promptitüüp  $\times$  kategooria) kombinatsiooni kohta. Alapeatükk 5.9 sõnastab edasise hindamise jätkukava päris üliõpilastöödel.

### 5.1 Pilootuuringu metoodika ja valim

Pilootuuringu valim koosnes orienteeruvalt 3–5 lühikesest eestikeelsest tekstikatkendist iga viie peatükitüübi kohta (sissejuhatus, taust ja seotud tööd, metoodika, tulemused, kokkuvõte). Katkendid olid kokku ligikaudu paari tunni jooksul kogutud ja ette valmistatud ning sisaldasid nii probleemseid kui ka korrektseid löike. Pilootvalim oli teadlikult väike: selle eesmärk ei olnud kvantitatiivne mõõtmine, vaid prompti disaini iteratsioon ja mudeli väljundi tüüpiliste mustrite tuvastamine. Päris üliõpilastöödel põhinevas, sõltumatu teise annoteerijaga annoteeritud testkogus toimub kvantitatiivne hindamine alles jätkutöö raames.

Iga pilootkatkend analüüsiti prototüübiga mõlema prompti variandiga (üldine ja struktureeritud) ning vähemalt osa katkendeid analüüsiti ka mõlema mudeliga (Claude 4.7 Opus ja GPT-5.5). Saadud väljundid vaadati läbi käsitsi ning märgiti üles järgmised tähelepanekud iga vastuse kohta: (1) kas vastus oli valideeritava JSON-struktuuriga, (2) milliseid kategooriate alla kuuluvaid probleeme mudel tuvastas, (3) milliseid probleeme mudel autori hinnangul korrektselt tuvastas, (4) milliseid probleeme mudel pakkus välja, kuigi need autori hinnangul probleemid ei olnud (*näilised valepositiivsed*), ja (5) millised olid autori hinnangul ilmselt probleemid, kuid mudel jättis need välja (*näilised valenegatiivsed*). Sõna „näiline” kasutatakse teadlikult, sest pilootuuringus oli annoteerijaks autor üksi ning sõltumatut kontrolli ei olnud; need tähelepanekud vajasisid seetõttu kvantitatiivset kontrolli empiirilises hindamises.

Konkreetsed kvantitatiivsed mõõdikud (täpsus, saagis,  $F_1$ ) pilootuuringu raames *ei arvatatud*, kuna valim oli liiga väike statistilise üldistuse jaoks ning konkreetsete numbrite esitamine oleks andnud lugejale eksitava ettekujutuse tulemuste usaldusväärsusest. Alljärgnevad tähelepanekud on seetõttu sõnastatud puhtalt kvalitatiivselt.

## 5.2 Kvalitatiivsed tähelepanekud kategooriate kaupa

### 5.2.1 Viitamisvajadus

Pilootuuringus oli mudel *viitamisvajaduse* kategoorias kõige usaldusväärsem. Mudel tuvastas selgelt lauseid, mis sisaldavad konkreetseid arvulisi väiteid (*75 % projektist...*), kuid mille juures puudub viide allikale. Mudel tuvastas usaldusväärselt ka olukordi, kus konkreetne meetodika või algoritm on esitatud ilma viiteta selle allikale. Näiliste valepositiivsete hulgas täheldati üksikuid juhtumeid, kus mudel nõudis viidet üldteadmisele (näiteks *HTTP on rakenduskihi protokoll*), mille puhul viide pole tegelikult vajalik. See muster on prompti disaini hilisemas iteratsioonis lahendatav vastunäidete täiendamisega, kuid täismahulise hindamise käigus tuleb seda ka kvantitatiivselt mõõta.

### 5.2.2 Struktuur

*Struktuuri* kategoorias täheldati pilootuuringus, et struktureeritud prompt tuvastab järgmised mustrid süsteemsemalt kui üldine prompt: peatüki algus alapealkirjaga ilma sissejuhatava lõiguta; pikk loetelu ilma sissejuhatava lauseta; lõikudevahelise loogilise ülemineku puudumine. Üldine prompt küll tihti nimetas üldsõnaliselt, et „struktuur võiks olla parem”, kuid ei lokaliseerinud probleemi konkreetsete lõikude juurde. Peatükkide pikkuste tasakaalustamatust tuvastas mudel



ainult juhul, kui katkendis oli mitu peatükki esitatud, mis on ootuspärane piirang katkendipõhise hindamise puhul.

### 5.2.3 Akadeemiline stiil

*Akadeemilise stiili* kategoorias tuvastas mudel hästi kõnekeelseid väljendeid (*tüüp, asi, tegelikult*), liigselt pikki lauseid ja umbisikulise tegumoe ebakohast kasutamist. Pilootuuringus täheldati ka, et mudel kaldub mina-vormi probleemiks tõlgendama ka olukordades, kus mina-vormi kasutus oli akadeemiliselt vastuvõetav (näiteks selgelt tudengi enda panust kirjeldavates kohtades, kus mina-vormi kasutus on TÜ juhendi kohaselt pigem soovituslik kui keelatud). See on tähelepanuväärne kallutus, mis sõltub prompti vastunäidete sõnastusest ning mille suurus tuleb täismahulises hindamises kvantitatiivselt mõõta.

### 5.2.4 Terminoloogia

Pilootuuringus näis mudel kõige nõrgem *terminoloogia* järjepidevuse hindamisel. Põhjuseid täheldati vähemalt kaks. Esiteks nõuab terminoloogia järjepidevuse hindamine tervet teksti silmas pidamist – kui katkend on lühike, ei pruugi sama termini erinevad esinemiskorrad mahtuda samasse katkendisse, mistõttu mudel ei „näe” vastuolu. Teiseks ei ole mudel täiesti kursis tiptasemel eestikeelsete arvutiteaduse terminitega: pilootuuringus esitas mudel üksikutel juhtudel valepositiivse leiu, kus väitis, et *lõim* olevat inglise keele *thread* ebakorrektnet tõlge (kuigi tegelikult on *lõim* just kooskõlas Eesti Keele Instituudi sõnastikuga<sup>2</sup>). See piirang on osa põhjusest, miks jätkukavasse on lisatud kategooriapõhise prompti täiendamine välise terminisõnastiku integreerimisega (vt alapeatükk 5.9).

## 5.3 Üldise ja struktureeritud prompti võrdlus

Pilootuuringus võrreldi üldise ja struktureeritud prompti väljundeid samadel katkenditel. Mõlemad promptid nõuavad sama JSON-skeemiga vastust ning kategoriseeritud väljundit, mistõttu vormiline erinevus piirdub kategooriavaliku ulatusega (üldine prompt lubab lisaks neljale põhikategooriale ka kategooria MUU); kategoriseeritud väljundi struktuurne kasu ei ole seetõttu uudne empiiriline leid, vaid mõlema prompti ühine kavandatud omadus. Sisuline erinevus, mida pilootuuring jälgis, taandub kategooria definitsioonide, näidete ja reeglite mõjule mudeli sisutundlikkusele.

---

<sup>2</sup> <https://termin.eki.ee/>

Pilootuuringus täheldati järgmist. Üldise prompti kõige nähtavam puudus näis olevat madalam täpsus: mudel signaleeris rohkem leide kategooriaviite *tasandil*, kuid suurem osa neist olid kas väga üldised tähelepanekud (sageli kategoorias MUU) või kuldstandardi suhtes laiendavad. Struktureeritud prompti kasu täheldati eriti struktuuri ja akadeemilise stiili kategoorias, kus täpsete definitsioonide ja näidete olemasolu paistis mudeli leide kuldstandardiga paremini joondavat; väikseim kasu täheldati terminoloogia kategoorias, kus mudeli põhiline piirang – katkendipõhine kontekst ja eesti keele terminite tundmise lüngad – ei sõltunud prompti sisust. Pilootuuringu raames neid tähelepanekuid arvuliselt ei kvantifitseeritud; täpsuse, saagise ja  $F_1$ -skoori paranemine iga kategooria kohta on esitatud alapeatükis 5.8 täismahulise hindamise tulemustes, kus mõlema prompti väljundid skooritakse sama kuldstandardi vastu. Pilootuuringu tähelepanekud toetavad struktureeritud prompti hüpoteesi esialgselt ja kvalitatiivselt.

## 5.4 Mudelite tundlikkus pilootuuringu tasemel

Pilootuuringu käigus käivitati osa pilootkatkendeid lisaks Claude 4.7 Opusele ka OpenAI gpt-5.5 mudeliga, kasutades sama struktureeritud prompti. Mõlemad mudelid näitasid sellel valimiosal sarnast kategoorilist mustrit – usaldusväärsem viitamisvajaduse ja struktuuri kategoorias, problemaatilisem terminoloogia kategoorias. Lisaks täheldati, et struktureeritud prompti kvalitatiivne eelis üldise ees ilmnes mõlema mudeli puhul samasuguste mustritega. Selle tähelepaneku tugevus on aga valimiosa väiksuse tõttu piiratud: kas prompti struktuuri kasu üldistub mudelite üle, samuti kas mudelite vahel on süstemaatilisi erinevusi (näiteks Claude 4.7 Opuse võimalik eelis eesti keele oskuse poolest), kontrollitakse alapeatükis 5.8, kus mõlemad mudelid skooritakse kogu sünteetilise testkogu vastu.

## 5.5 Kvalitatiivsed näidisleiud

Tabelis 4 on esitatud kolm illustratiivset näidet pilootuuringu mudeli tagasisidest. Esimene näide on selge tõene positiivne (autori hinnangul mudel tuvastas reaalse probleemi), teine näiline valepositiivne (mudel pakkus välja probleemi, mida autor probleemiks ei pidanud) ja kolmas näiline valenegatiivne (autori hinnangul probleem, mida mudel ei tuvastanud).

Lisaks tähelepanekutele konkreetsete leidude kohta täheldati pilootuuringus, et mudeli *kindluse hinnang* kattus suuremas osas autori hinnanguga: kõrge kindlusega leidude hulgas oli autori hinnangul tunduvalt suurem osakaal põhjendatuid kui madala kindlusega leidude hulgas. Kuna pilootuuringus oli anoteerijaks autor üksi, ei luba see tähelepanek veel järeldada, et kindlushinnang korreleerub tegeliku õigsusega – võimalik on ka, et mudel ja autor jagavad

Tabel 4. Pilootuuringus täheldatud illustratiivsed näited mudeli tagasisidest. Tekstid on lühendatud loetavuse huvides; klassifikatsioon (TP/FP/FN) on autori enda hinnang ning vajab jätkutöös sõltumatu teise annoteerija kinnitust.

| Tüüp | Tekst                                                                                           | Mudeli tagasiside                                                                                                               |
|------|-------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------|
| TP   | „Andmebaasi kasutab praegu üle 75 % Eesti suuremate ettevõtetest.”                              | <b>Viitamisvajadus</b> (kindlus: kõrge): konkreetne arvuline väide ilma allikata. Soovitus: lisa viide originaalsele uuringule. |
| FP   | „HTTP on rakenduskihi protokoll, mida kasutatakse veebiliikluse jaoks.”                         | <b>Viitamisvajadus</b> (kindlus: keskmine): mudel nõudis viidet, kuid tegu on üldteadmise.                                      |
| FN   | Tekst kasutab vaheldumisi termineid <i>kompileerimine</i> ja <i>tõlkimine</i> samas tähenduses. | Mudel ei tuvastanud terminoloogilist vastuolu, kuna kaks esinemiskorda olid katkendis kaugel teineteisest.                      |

süsteematiselt kallutusi samade mustrite suhtes. Selle eristamine – kalibreerumine tegeliku õigsuse suhtes vs jagatud kallutus autori ja mudeli vahel – on sõltumatu teise annoteerija kaasamisega jätkuhindamise üks ülesanne.

## 5.6 Arutelu ja esialgsed vastused uurimisküsimustele

Pilootuuring ei võimalda anda uurimisküsimustele lõplikku vastust ega ühtki kvantitatiivset väidet. Kvalitatiivselt pakub pilootuuring siiski järgmist esialgset suunda kolmele uurimisküsimusele:

**Uurimisküsimus 1.** Pilootuuringus oli mudeli antud tagasiside iseloom *kasutuskõlblik*: mudel suutis tuvastada konkreetseid, tsiteeritavaid probleeme nii stiili-, struktuuri- kui ka viitamisvajaduse kategoorias. Tagasiside oli auditeeritav (iga leid sisaldas tsitaati ja põhjendust), eestikeelne ja lokaliseeritud. Pilootuuringu põhjal näib süsteem rakenduskõlblik täiendava tagasisidevahendina; sünteetiliselt testkogul tehtud kvantitatiivne kasutuskõlblikkuse hinnang on esitatud alapeatükis 5.8.

**Uurimisküsimus 2.** Pilootuuringus näis mudel usaldusväärseim *viitamisvajaduse* ja *struktuuri* kategoorias – need on kategooriad, kus probleem on tüüpiliselt lokaalne (üks lause või

lõik) ja seotud selgelt äratuntava mustriga. Kõige problemaatilisem oli mudel *terminoloogia* kategoorias, kus on vaja kogu teksti silmas pidamist ning eesti keele tehnilist terminisõnastikku. Need esialgsed suunad on kooskõlas hüpoteesidega, mis on prompti disaini aluseks; nende kvantitatiivne kontroll on esitatud alapeatükis 5.8.

**Uurimisküsimus 3.** Pilootuuringu põhjal näib struktureeritud promptimine andvat üldisest promptist süsteemsemat tagasisidet enamikus kategooriates ning mõlemal pilootuuringus testitud mudelil samasuguste mustritega. Suurim näiline paranemine täheldati struktuuri kategoorias, väikseim terminoloogia kategoorias, kus mudeli põhilised piirangud ei sõltunud prompti vormist. Tuleb rõhutada, et osa täheldatud erinevusest on prompti disaini kavandatud vormiline omadus (kategoriseeritud JSON-väljund), mitte iseseisev empiiriline leid; sisulise – kattuvuse ja täpsuse – paranemise suurus iga kategooria kohta on esitatud alapeatükis 5.8.

## 5.7 Pilootuuringu piirangud

Pilootuuringul on mitmeid piiranguid, mistõttu peatüki tulemusi tuleb tõlgendada esialgsena ja kvalitatiivselt.

**Pilootuuring on kvalitatiivne.** Käesolev pilootuuring (alapeatükid 5.2–5.5) ei esita iseseisvalt täpsuse, saagise ega  $F_1$ -skoori väärtusi, kuna pilootvalim (3–5 katkendit peatükitüübi kohta) on selliste kvantitatiivsete järelduste jaoks teadlikult liiga väike. Kvantitatiivsed mõõdikud sünteetilisel 20-katkendilisel testkogul on esitatud alapeatükis 5.8; päris üliõpilastöödel kvantitatiivse hindamise läbiviimine kuulub alapeatükis 5.9 kirjeldatud jätkukavasse.

**Valimi suurus.** Pilootuuringus kasutati orienteeruvalt 3–5 katkendit peatükitüübi kohta, mistõttu pilootvalim ei võimalda statistiliselt usaldusväärseid järeldusi. Tüüpilise dispersiooni ja usaldusvahemike hindamiseks on vajalik vähemalt suurema testkogu kasutamine ning ideaalis sõltumatu kordamine.

**Üks annoteerija.** Pilootuuringus oli annoteerijaks autor üksi. Sõltumatut teist annoteerijat ei kaasatud. See võib põhjustada süstemaatilise kallutuse: kui autor on kallutatud teatud probleemide tuvastamisel, peegeldub see ka pilootuuringu kvalitatiivsetesse tähelepanekutesse. Coheni  $\kappa$  [31] arvutamine kahe sõltumatu annoteerija vahel iga kategooria kohta on edasise päris testkogu hindamise üks oluline samm; Krippendorffi  $\alpha$  [32] on reservis mitme annoteerijaga laienduse jaoks.

**Üldise prompti MUU-kategooria.** Üldine prompt lubab mudelil paigutada leiu kategooriasse MUU, mida kuldstandard ei tunne. Skoorimises loetakse MUU-leiud automaatselt valepositiivseteks (vt

alapeatükk 3.4), kuna ühegi kuldstandardi annotatsiooni kategooria pole MUU. See on disainivalik, mis võib üldise prompti täpsust alandada juhul, kui mudel paigutab MUU-kategooriasse leide, mis sisuliselt kuuluksid mõnda neljast põhikategooriast; sellise juhtumi sagedust on võimalik järelhindamises mõõta, käsitsi MUU-leiud nelja kategooriaga sobitades ning vaadates, kas see muudaks üldise prompti tulemust.

**Mudeli versioon.** Tähelepanekud kehtivad konkreetsete mudeliversioonide kohta (Claude 4.7 Opus, GPT-5.5) ja konkreetsete parameetritega (mõlema uue põlvkonna mudeli API ei aktsepteeri enam *temperature*-parameetrit). Mudelite uuendamisel võivad järeldused muutuda; uuemate mudelite eestikeelne tugi tõenäoliselt paraneb, mis nõuab hindamise kordamist.

**Subjektiivsus akadeemilises stiilis.** Akadeemiline stiil pole rangelt määratletav – paljud stiilivalikud on legitiimselt vaieldavad. See on osa põhjusest, miks mõõdik selles kategoorias jääb hindajatevahelise erinevuse poolest teistele alla ka inimese-inimese kokkuleppes (mitte ainult mudeli-inimese kattuvuses).

**Lekete oht.** Päril TÕ lõputööde katkendite kasutamine jätkutöö kuldstandardiks tähendab, et mudel võib treeningandmetes näha samu või sarnaseid tekste. See oht ei ole täielikult välistatav, kuid testkogu katkendid on lühikesed ja kavandatult ümberkirjeldatud, mis vähendab täpselt sama teksti uuesti tuvastamise tõenäosust. Päril testkogu hindamisel tuleks seda ohtu eraldi kontrollida, käivitades osa katkendeid ka pärast neis termini- või sõnastusmuudatuste tegemist ning võrreldes mudeli väljundi muutumist.

**Mudeli väljundi vs kasutajakogemuse hindamine.** Pilootuuringus hinnati ainult mudeli *väljundit* autori vaatest, mitte seda, kuidas süsteem toimib tegelike tudengite kasutusprotsessis (näiteks kasutajaliidese tõhusus, soovitude rakendatavus tegelikus kirjutamisprotsessis, üldine kasutatavus ja kasulikkuse tajumine). Süsteemi praktilise väärtuse hindamine eeldab eraldi kasutatavusuuringut tegelike tudengite osalemisega, mis omakorda nõuab eraldi metoodikat ja eetikakomisjoni nõusolekut; see kuulub seetõttu täiendava jätkukava sammuna käesoleva töö ulatusest välja.

## 5.8 Empiiriline hindamine sünteetilisel testkogul

### ANDMETE STAATUS

Käesoleva alapeatüki F<sub>1</sub>-skoorid on tegelikud empiirilised mõõtmised – kõik arvud pärinevad 80 päris API-päringust Anthropic Claude 4.7 Opus ja OpenAI GPT-5.5 mudelitele. Mudelivastuste toored JSON-id on salvestatud repositooriumi kausta `statistika/andmed/paris_vastused/`, mis võimaldab tulemusel reprodutseerida ja auditeerida. **Testkogu katkendid (20 katkendit) ja kuldstandard (42 annotatsiooni) on aga eraldi protsessina autori juhendamisel Claude 4.7 Opus mudeliga interaktiivse vestlusliidese (Claude Code) kaudu koostatud sünteetilised tekstid** – mitte tasuliste API-päringute kaudu (millega tehti ainult hindamispäringud) ja mitte päris üliõpilastööde katkendid. See piirang on selgesõnaliselt välja toodud sissejuhatuse generatiivse tehisaru deklaratsioonis ning käesoleva alapeatüki piirangute jaotises. Reprodutseerimiseks vajalik kood ja andmed on kaustas `statistika/` (skriptid `andmestik_synth.py` ja `paris_hindamine.py`).

### 5.8.1 Testkogu ja kuldstandardi koostamine

Empiirilises hindamises kasutatav testkogu koosneb 20 sünteetilisest tekstikatkendist, mille jaotus peatükitüübi järgi vastab lisas 6 kavandatud kvoodile (sissejuhatus 4, taust 5, metoodika 4, tulemused 4, kokkuvõte 3). Iga katkendi pikkus on ligikaudu 100–160 sõna, mis on lühem kui lisas 6 päris testkogu jaoks kavandatud 230–360 sõna; lühemat pikkust kasutati teadlikult, sest sünteetilised katkendid on koostatud kategooriapõhise tundlikkuse jaoks (üks-kaks tahtlikult lisatud probleemi katkendi kohta), mitte kogu peatüki realistliku pikkuse jäljendamiseks. Sellega kaasneb piirang, et terminoloogia järjepidevust hindavad probleemid, mis eeldavad sama termini mitut esinemiskorda, mahuvad lühemasse katkendisse väiksema tõenäosusega; seda piirangut on käsitletud kvalitatiivselt alapeatükis 5.2 ja kvantitatiivselt allpool. Katkendid on autori juhendamisel Claude 4.7 Opus mudeliga *interaktiivse vestlusliidese (Claude Code) kaudu* koostatud nii, et nad imiteerivad tüüpilist eestikeelset informaatika lõputöö teksti ja sisaldavad tahtlikult lisatud tüüpilisi probleeme (kõnekeelseid väljendeid, mina-vormi liigseid kasutusi, ingliskeelseid termineid ilma esmakasutuse selgituseta, viiteta arvulisi väiteid jne). See ühekordne genereerimisprotsess on selgelt eraldatud allpool kirjeldatud hindamispäringutest, mis kasutavad tasulisi API-sid skriptipõhiselt. Iga katkendi juurde on koostatud kuldstandard, mis sisaldab kategooriapõhiseid annotatsioone (probleemne tekstivahemik, kategooria, lühike kirjeldus, kindlushinnang); kokku on 42 annotatsiooni. Selline sünteetiline andmestik võimaldab kategooriapõhise tundlikkuse hindamist kontrollitud tingimustes; selle piirang on, et katkendid

ei pruugi täielikult kajastada päris üliõpilastööde mustreid (vt piirangute jaotis allpool ja sissejuhatuse deklaratsioon).

## 5.8.2 Päringute teostamine

Iga (katkend  $\times$  promptitüüp  $\times$  mudel) kombinatsiooni jaoks tehti üks päring vastavale LLM-i API-le: kokku 20 katkendit  $\times$  2 prompti  $\times$  2 mudelit = 80 päringut. Päringud teostati skriptiga `statistika/paris_hindamine.py`, mis kasutab täpselt sama analüüsiprotsessi nagu prototüübi backend (`prototuuup/backend/analyytsija.py`). Iga päringu täielik vastus salvestati JSON-failina, mis võimaldab tulemused reprodutseerida ja auditeerida. Mudelivastuste keskmine kestus oli ligikaudu 28 sekundit, kogu testkomplekt töödeldi umbes 37 minuti jooksul.

Tabelis 5 on esitatud API-päringute tegelik tokenite kulu ja rahaline kogukulu, mis pärinevad vastavalt Anthropic'i ja OpenAI arvelduste paneelidest pärast hindamise lõppu. Summad on USA dollarites, kuna mõlemad pakkujad arveldavad selles vääringus. Kogukulu jäi alla \$4 (ligikaudu 3,6 eurot kursi 1 USD  $\approx$  0,93 EUR juures, mai 2026), mis on oluliselt madalam kui pilootuuringus eeldatud \$10. Seetõttu on hindamise kordamine teostatav ka tudengieelarvega; piirav tegur on inimese annoteeritud kuldstandardi koostamise aeg, mitte arvutuslik mahukus (vt alapeatükk 5.9).

Tabel 5. Empiirilise hindamise tegelik tokenite kulu ja rahaline kogukulu 80 API-päringu kohta (Anthropic'i ja OpenAI arvelduste paneelide andmed pärast hindamise lõppu).

| Mudel           | Päringuid | Sisend-tokeneid | Väljund-tokeneid | Maksumus      |
|-----------------|-----------|-----------------|------------------|---------------|
| Claude 4.7 Opus | 40        | 57 967          | 77 228           | \$2,22        |
| GPT-5.5         | 40        | 34 177          | 49 663           | \$1,66        |
| <b>Kokku</b>    | <b>80</b> | <b>92 144</b>   | <b>126 891</b>   | <b>\$3,88</b> |

Mudelivastuse väljundid skooriti kuldstandardi vastu spani-tasemel kattuvuse järgi: mudeli leid loetakse tõeseks positiivseks, kui (1) kategooria on sama kui kuldstandardis ja (2) mudeli osutatud tekstilõigu ja kuldstandardi probleemse tekstivahemiku sõnatasemel kattuvus on  $\geq 50\%$  (vt alapeatükk 3.5).


## 5.8.3 Empiirilised tulemused

Tabelis 6 on esitatud iga (mudel  $\times$  promptitüüp) kombinatsiooni makrokeskmised mõõdikud üle nelja kategooria.

Tabel 6. Empiirilised makrokeskmised mõõdikud iga (model × promptitüüp) kombinatsiooni kohta. Arvutatud 80 päris API-päringu tulemustest sünteetilise 20-katkendilise testkogu vastu.

| Mudel           | Promptitüüp     | Makro täpsus | Makro saagis | Makro $F_1$ | TP | FP  | FN |
|-----------------|-----------------|--------------|--------------|-------------|----|-----|----|
| Claude 4.7 Opus | struktureeritud | 0,33         | 0,93         | 0,46        | 39 | 79  | 3  |
| Claude 4.7 Opus | üldine          | 0,29         | 0,79         | 0,41        | 34 | 100 | 8  |
| GPT-5.5         | struktureeritud | <b>0,47</b>  | <b>0,77</b>  | <b>0,56</b> | 34 | 39  | 8  |
| GPT-5.5         | üldine          | 0,27         | 0,85         | 0,38        | 33 | 102 | 9  |

Joonis 4 võrdleb empiirilisi makro- $F_1$ -skoore üldise ja struktureeritud prompti vahel kahel mudelil. Joonis 5 esitab sama informatsiooni kategooriate kaupa, mis võimaldab näha, milliste probleemitüüpide puhul modelid on tugevamad või nõrgemad.




Joonis 4. Empiiriline makro- $F_1$  võrdlus üldise ja struktureeritud prompti vahel. GPT-5.5 saavutab struktureeritud prompti puhul kõrgeima skoori (0,56); struktureeritud prompt parandab  $F_1$ -skoori mõlema mudeli puhul.

#### 5.8.4 Tulemuste arutelu

Empiirilised tulemused annavad kvantitatiivsed vastused töö uurimisküsimustele ning toovad esile mitu tähelepanu vääritvat mustrit.

**Struktureeritud prompt parandab  $F_1$ -skoori järjepidevalt.** Mõlema mudeli puhul on struktureeritud prompti makro- $F_1$  kõrgem kui üldise prompti oma: Claude'il +0,05 (0,46 vs





Joonis 5. Empiiriline  $F_1$ -skoor kategooria, mudeli ja promptitüübi kaupa. *Akadeemiline stiil* on järjepidevalt kõige paremini tuvastatav kategooria; *struktuur* on raskeim, eriti üldise prompti puhul (Claude'i  $F_1 = 0,11$ ). *Viitamisvajadus* näitab perfektset saagist ( $S = 1,00$  kolmes neljast kombinatsioonist), kuid madalat täpsust – mudelid leiavad kõik kuldstandardi probleemid, aga lisaks veel palju lisaprobleeme, mida autor probleemiks ei pidanud.

0,41), GPT-5.5-1 +0,19 (0,56 vs 0,38). See toetab töö keskset hüpoteesi (uurimisküsimus 3): *struktureeritud kategooria- ja skeemipõhine promptimine annab eestikeelse akadeemilise teksti tagasisidestamisel süsteemsemat ja kasutuskõlblikumat väljundit.*

**GPT-5.5 + struktureeritud prompt on parim kombinatsioon.** See vastab uurimisküsimusele 2 ootamatu tulemusega: *tippkvaliteediga LLM-id on testkogu tasemel sarnaselt kasutuskõlblikud, kuid GPT-5.5 saavutab struktureeritud prompti puhul Claude'ist oluliselt parema täpsuse.* Erinevus tuleneb peamiselt valepositiivsete arvust: GPT-5.5 struktureeritud prompt esitab 39 FP-d, samas kui Claude'i struktureeritud prompt 79 FP-d – kaks korda rohkem. See on tähelepanuväärne tulemus, kuna sünteetilises pipeline-demonstratsioonis (vt eelmised iteratsioonid repositooriumis: `statistika/synteetiline_hindamine.py`) eeldati Claude'i eelist; päris mõõtmine annab vastupidise tulemuse.

**Mudelid on kallutatud saagise poole.** Kõikides kombinatsioonides on saagis kõrgem kui täpsus, sageli oluliselt. Eriti silmatorkav on viitamisvajaduse kategooria, kus saagis on  $\geq 0,90$  kõikides neljas kombinatsioonis (Claude struktureeritud: 1,00 saagisega, 10 TP ja 25 FP). See tähendab,

et mudelid leiavad peaaegu alati kõik kuldstandardi probleemid, kuid lisaks signaleerivad palju lauseid, mida autori koostatud kuldstandard probleemiks ei pidanud. Praktikas tähendab see, et süsteem on *kandidaatide-leidja*, mille tagasiside vajab kasutaja kriitilist üle vaatamist – see on kooskõlas töö disainivalikuga: süsteem on *tagasisidevahend*, mitte autoriteetne hindaja (vt peatükk 4.6).

**Kategooriate raskus järgneb pilootuuringus täheldatud mustriks, kuid täpsete numbritega.** Akadeemilise stiili  $F_1$  on järjepidevalt kõrgeim (0,52–0,74); struktuuri  $F_1$  on madalaim, eriti üldise prompti puhul (Claude'il 0,11). Terminoloogia jääb vahepeale (0,34–0,52). See vastab uurimisküsimusele 2 päris numbritega: *stiil on kõige usaldusväärsem ja struktuur problemaatilisim* – viimane peamiselt seetõttu, et mudelid signaleerivad palju peeneid struktuuriprobleeme, mida lühike katkend ei vaja.

### 5.8.5 Empiirilise hindamise piirangud

Käesolev empiiriline hindamine annab kvantitatiivseid vastuseid, kuid on mitmel olulisel viisil piiratud.

- **Testkogu on sünteetiline**, mitte päris üliõpilastööde katkenditest koostatud. Katkendid ja kuldstandard on autori juhendamisel LLM-iga koostatud nii, et need imiteerivad tüüpilisi probleeme. Päris üliõpilastöödel võivad probleemid olla peenemad või harvemini esinevad; üldistus päris kasutuskontekstidele on piiratud. Päris töödel hindamine kuulub alapeatükis 5.9 kirjeldatud jätkukavasse.
- **Üks annoteerija (autor)**. Kuldstandard on autori käsitsi koostatud, sõltumatut teist annoteerijat ei kaasatud. Coheni  $\kappa$  [31] arvutamine eeldab teise annoteerija olemasolu ja kuulub jätkukavasse.
- **Vahe „kuldstandardi” ja „mudeli leiu” vahel**. Madalad täpsuse väärtused (0,27–0,47) on osaliselt selle tulemus, et autori koostatud kuldstandard on rangem kui mudeli vaste. Näiteks ühe katkendi puhul märkis kuldstandard 3 probleemi, mudel aga 7–8 – millest osa olid kahtlemata reaalsed probleemid, kuid kategooria-määratlused olid neid spetsiifilisemalt välja jättnud. Selle nähtuse täielik dekomposeerimine („mudel ületuvastab” vs „kuldstandard on alaannoteeritud”) nõuab teise annoteerija kaasamist.
- **Span-tasemel kattuvuse 50 % lävi** on disainivalik, mille tundlikkust ei ole käesolevas hindamises eraldi analüüsitud (vt alapeatükk 3.5 kavandatud tundlikkusanalüüsi).

- **Mudeli versioonide sõltuvus.** Tulemused kehtivad konkreetsete mudelikonfiguratsioonide kohta (Claude 4.7 Opus, GPT-5.5, mõlema puhul vaikeparameetrid – mõlema uue põlvkonna API ei toeta enam `temperature`-parameetri muutmist). Mudelite uuenedes tuleb hindamine korrata.

## 5.9 Edasise hindamise jätkukava

Alapeatükis 5.8 esitatud empiiriline hindamine annab kvantitatiivsed vastused töö uurimisküsimustele *sünteesilisel testkogul*. Edasine hindamine peaks need vastused üldistama päris üliõpilastööde kontekstile. Jätkukava koosneb järgmistest sammudest, milleks prototüüp ja hindamis-pipeline on tehniliselt valmis:

1. *Päris üliõpilastöödel põhinev testkogu koostamine ja anonüümimine* – 20 katkendi valimine TÜ arvutiteaduse instituudi avalikult kättesaadavate bakalaureuse- ja magistratööde hulgast aastatest 2020–2024, järgides lisas 6 esitatud kvoodi-jaotust peatükitüübi järgi. Sünteesilise testkogu asendamine päris katkenditega võimaldab kontrollida, kas alapeatükis 5.8 leitud mustrid (GPT-5.5 struktureeritud parim; mudelite saagise poole kalduvus) üldistuvad.
2. *Kuldstandardi annoteerimine kahe sõltumatu annoteerijaga* – esimene annoteerimisring autori poolt, teine sõltumatu annoteerija poolt; lahkarvamuste lahendamine ning Coheni  $\kappa$  [31] arvutamine iga kategooria kohta. See võimaldab eristada „mudel ületuvastab” vs „kuldstandard on alaannoteeritud- alapeatükis 5.8 esile tõstetud asümmeetria täpsuse ja saagise vahel.
3. *Empiirilise hindamise kordamine päris testkogul* – sama 80-päringuline pipeline (`paris_hindamine.py`) kohaldatakse uuele testkogule. Tulemused võrreldakse alapeatükis 5.8 saadud sünteesiliste mõõtmistega, et hinnata, milline osa numbritest tuleneb mudelite tegelikust käitumisest ja milline sünteesilise testkogu spetsiifikast.
4. *Kindlushinnangu kalibratsioon* – mudeli kindlushinnangu (kõrge/keskmine/madal) ja tegeliku õigsuse vahelise korrelatsiooni mõõtmine. Tekitatud andmestik (kindlus iga TP/FP juures) on juba olemas failis `andmed/paris_klassifikatsioonid.csv`; sõltumatu annoteerija kaasamise järel saab uurida, kas mudel teab, millal ta võib eksida.
5. *Span-tasemel kattuvuse läve tundlikkusanalüüs* –  $F_1$ -skoorid arvutatakse ka 30 % ja 70 % kattuvuse läviga, et kontrollida 50 % läve valiku tundlikkust (vt alapeatükk 3.5).

6. *Kasutatavusuuring tegelike tudengite seas* – süsteemi praktilise väärtuse hindamine eeldab eraldi metoodikat ja eetikakomisjoni nõusolekut. See on alapeatükis 5.7 viidatud edasine samm.

Kuna prototüüp ja hindamis-pipeline on tehniliselt valmis (`paris_hindamine.py` käivitub kogu testkogul ligikaudu 37 minuti jooksul ja tegeliku kogukuluga \$3,88, vt tabel 5), on jätkukava arvutuslikud osad kiired – peamine takistus on päris katkendite koostamiseks ja sõltumatu teise annoteerija kaasamiseks vajaliku aja leidmine.

## 6. Kokkuvõte

Käesoleva bakalaureusetöö eesmärk oli *kavandada ja realiseerida* suurel keelemudelil põhinev prototüüp, mis annab eestikeelsele informaatika lõputöö tekstile automaatset tagasisidet struktuuri, akadeemilise stiili, terminoloogia järjepidevuse ja viitamisvajaduse kohta, ning *hinnata empiiriliselt* selle väljundi kvaliteeti. Prototüüp realiseeriti, seda iteratiivselt täpsustati pilootuuringu käigus ning lõpuks viidi läbi täismahuline empiiriline hindamine 80 päris API-päringu põhjal 20 sünteetilisel testkatkendil. Päris üliõpilastöödel sama metoodika kohaldamine kuulub selgelt sõnastatud jätkukavasse (vt alapeatükk 5.9).

Töö **teoreetilises osas** määratleti operatsioonalselt neli tagasisidekategoriat Tartu Ülikooli arvutiteaduse instituudi nõuete [1] ja kirjanduse põhjal, kavandati kaks promptimisstrateegiat (üldine ja struktureeritud) ning sõnastati hindamismetoodika koos kuldstandardi koostamise protseduuriga. Töö **praktilises osas** loodi veebipõhine prototüüp, mis võimaldab kahe tippmodeli (Claude 4.7 Opus, GPT-5.5) kasutamist eestikeelse teksti analüüsiks ning kuvab tulemused kasutajale kategoriseeritud kujul koos kindlushinnangute ja konkreetsete soovitusetega. Lisaks võimaldab prototüüp *demo-režiimi*, mis tagastab salvestatud näidisvastuse ilma välise API kasutamiseta – see teeb süsteemi reprodutseerimise võimalikuks ilma API võtmeta. Süsteemi disainimisel arvestati läbivalt põhimõtet, et tegu ei ole tudengi eest kirjutamise vahendiga, vaid tagasisidesüsteemiga; see piirang on rakendatud nii promptisiseselt kui ka kasutajaliideses. Töö **empiirilises osas** viidi läbi nii kvalitatiivne pilootuuring kui ka täismahuline kvantitatiivne hindamine 80 päris API-päringu põhjal sünteetilisel 20-katkendilisel testkogul.

**Empiirilised tulemused** (alapeatükk 5.8) annavad uurimisküsimustele 1–3 järgmised vastused:

1. **Mudeli tagasiside iseloom (UK1).** Mõlemad mudelid annavad auditeeritavat, eestikeelset ja lokaliseeritud tagasisidet kõikides neljas kategoorias. Tagasiside on *kasutuskõlblik* kandidaatide-leidja tasemel, kuid vajab kasutaja kriitilist üle vaatamist, kuna mudelid on saagise poole kallutatud (vt punkt 3).
2. **Kategooriate raskus (UK2).** Akadeemilise stiili kategoorias on  $F_1$  järjepidevalt kõrgeim (0,52–0,74); struktuuri kategoorias kõige madalam, eriti üldise prompti puhul (Claude'il 0,11); terminoloogia ja viitamisvajadus jäävad vahepeale (0,34–0,60). See vastab pilootuuringu kvalitatiivsetele tähelepanekutele konkreetsete numbritega.
3. **Promptitüübi mõju (UK3).** Struktureeritud prompt parandab makro  $F_1$ -skoori järjepidevalt mõlemal mudelil: Claude'il +0,05 (0,46 vs 0,41), GPT-5.5-l +0,19 (0,56

vs 0,38). Seega kinnitavad empiirilised tulemused töö keskset hüpoteesi struktureeritud promptimise eelisest. *Tähelepanek*: parim kombinatsioon empiirilises hindamises on GPT-5.5 + struktureeritud prompt ( $F_1 = 0,56$ ), mitte Claude, mille *täpsus* on madalam, kuna ta esitab rohkem valepositiivseid leide.

Empiirilised tulemused toovad ka esile, et tippkvaliteediga LLM-id on *kallutatud saagise poole*: kõikides kombinatsioonides on saagis vahemikus 0,77–0,93 ja täpsus vahemikus 0,27–0,47, st mudelid leiavad peaaegu kõik kuldstandardi probleemid, aga lisaks ka palju kandidaate, mida autori koostatud kuldstandard probleemiks ei pidanud. See on praktiline leid: süsteem on *kandidaatide-leidja*, mille tagasiside vajab kasutaja kriitilist üle vaatamist, mis on kooskõlas töö disainivalikuga.

**Töö panus** on järgmine. Esiteks pakub töö struktureeritud LLM-prompti disaini konkreetse rakenduse eestikeelse informaatika teksti tagasisidestamiseks ning näitab *empiiriliselt*, et see disain parandab  $F_1$ -skoori järjepidevalt mõlema testitud mudeli puhul. Teiseks pakub töö kategooriapõhise empiirilise võrdluse Claude 4.7 Opus ja GPT-5.5 mudelite vahel eestikeelse akadeemilise teksti tagasisidestamisel – valdkonnas, kus avaldatud kvantitatiivseid võrdlusi pole varem dokumenteeritud. Kolmandaks toob töö nähtavale, kus on praeguste LLM-ide piirangud: madal täpsus tuleneb mudelite saagise poole kalduvusest, mis on praktilise kasutuse jaoks oluline disainikaalutus. Lisaks panustab töö avatud, reprodutseeritava demo-režiimiga prototüübi, mida saab käivitada ilma välise API juurdepääsuta, ning täielikult dokumenteeritud hindamis-pipeline'i (`statistika/paris_hindamine.py`), mida saab uuesti rakendada päris üliõpilastöödel.

**Töö piirangud** on käsitletud peatükis 5.7; olulisemad on järgnevad.

- *Testkogu on sünteetiline* (autori juhendamisel LLM-iga koostatud), mitte päris üliõpilastööde katkenditest. Üldistus päris kasutuskontekstile eeldab sama metoodika kohaldamist päris katkenditele.
- *Ühe annoteerija (autor) kasutamine* – mudeli ja autori jagatud süstemaatilisi kallutusi pole võimalik praegustest andmetest eristada. Coheni  $\kappa$  [31] arvutamine eeldab teise annoteerija olemasolu.
- *Madalad täpsuse väärtused* (0,27–0,47) on osaliselt selle tulemus, et autori koostatud kuldstandard on rangem kui mudelite vaikevaste; selle nähtuse täielik dekomposeerimine (*mudel ületuvastab vs kuldstandard on alaannoteeritud*) nõuab samuti teise annoteerija kaasamist.

Kõiki kolme piirangut käsitletakse jätkukavas selge edasise sammuna.

**Edasise töö suunad.** Olulisuse järjekorras: (1) sama 80-päringulise hindamise kordamine *päris üliõpilastööde katkenditel* 20-katkendilisel testkogul, mis valitakse TÜ arvutiteaduse instituudi avalikult kättesaadavate tööde hulgast; (2) sõltumatu teise annoteerija kaasamine kogu testkogu põhjal ning Coheni  $\kappa$  arvutamine iga kategooria kohta eraldi; (3) testkogu suurendamine 100 või enama katkendini statistilise usaldatavuse hindamiseks; (4) kategooriapõhise prompti edasine täpsustamine (näiteks eraldi promptid iga kategooria kohta), eriti madala täpsuse käsitlemiseks; (5) terminoloogia kategooria täiendamine eestikeelse arvutiteaduse terminisõnastiku integreerimisega välise tööriistana; (6) prototüübi kasutatavusuuring tegelike TÜ tudengite seas, et hinnata süsteemi praktilist väärtust; (7) avatud lähtekoodi mudelite (näiteks Llammas [13]) tulemuste hindamine, kui prioriteediks on andmete kohalik töötlemine ilma välismaiste API-deta.

Kokkuvõttes näitab käesolev töö empiiriliselt, et tippkvaliteediga LLM-id on jõudmas tasemele, kus nende abil saab anda eestikeelsele akadeemilisele tehnilisele tekstile praktiliselt kasutuskõlblikku tagasisidet – struktureeritud promptimine parandab  $F_1$ -skoori järjepidevalt ning GPT-5.5 + struktureeritud prompt saavutab makro- $F_1 = 0,56$ . Süsteemi roll on aga selgelt täiendav, mitte asendav: lõputöö autoriks jääb tudeng ning juhendaja sisuline tagasiside on endiselt asendamatu.

## Viited

- [1] Tartu Ülikooli arvutiteaduse instituut. Tartu Ülikooli arvutiteaduse instituudis kaitsvate lõputööde nõuded ja hindamine. Juhenddokument. 2024. <https://cs.ut.ee/et/sisu/loputood-e-tahtajad-ja-juhendid> (15.02.2026).
- [2] Brown T. B., Mann B., Ryder N., Subbiah M., Kaplan J., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A. jt. Language models are few-shot learners. *Advances in Neural Information Processing Systems*. Kd 33. 2020, lk 1877–1901. <https://arxiv.org/abs/2005.14165>.
- [3] OpenAI. GPT-4 technical report. Tehniline aruanne. OpenAI, 2023. DOI: [10.48550/arXiv.2303.08774](https://arxiv.org/abs/2303.08774). <https://arxiv.org/abs/2303.08774>.
- [4] Anthropic. The Claude 3 Model Family: Opus, Sonnet, Haiku. Tehniline aruanne. 2024. [https://www-cdn.anthropic.com/de8ba9b01c9ab7cbabf5c33b80b7bbc618857627/Model\\_Card\\_Claude\\_3.pdf](https://www-cdn.anthropic.com/de8ba9b01c9ab7cbabf5c33b80b7bbc618857627/Model_Card_Claude_3.pdf).
- [5] TartuNLP. Baromeeter: eesti keele suurte keelemudelite võrdlusplatvorm. Tartu Ülikooli arvutiteaduse instituut. 2025. <https://baromeeter.tartunlp.ai/> (11.05.2026).
- [6] Tartu Ülikool. Generatiivse tehisaru kasutamine õppes ja teadustöös: Tartu Ülikooli juhend. Juhenddokument. 2024. <https://ut.ee/et/sisu/tehisintellekt-tartu-ulikoolis> (15.02.2026).
- [7] Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser Ł. ja Polosukhin I. Attention is all you need. *Advances in Neural Information Processing Systems*. Kd 30. 2017, lk 5998–6008. <https://papers.nips.cc/paper/7181-attention-is-all-you-need>.
- [8] Hochreiter S. ja Schmidhuber J. Long short-term memory. *Neural Computation* 9.8 (1997), lk 1735–1780. DOI: [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).
- [9] Ouyang L., Wu J., Jiang X., Almeida D., Wainwright C. L., Mishkin P., Zhang C., Agarwal S., Slama K., Ray A. jt. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*. Kd 35. 2022, lk 27730–27744. <https://arxiv.org/abs/2203.02155>.
- [10] Wei J., Tay Y., Bommasani R., Raffel C., Zoph B., Borgeaud S., Yogatama D., Bosma M., Zhou D., Metzler D., Chi E. H., Hashimoto T., Vinyals O., Liang P., Dean J. ja Fedus W. Emergent abilities of large language models. *Transactions on Machine Learning Research* (2022). <https://arxiv.org/abs/2206.07682>.



- [11] Ji Z., Lee N., Frieske R., Yu T., Su D., Xu Y., Ishii E., Bang Y. J., Madotto A. ja Fung P. Survey of hallucination in natural language generation. *ACM Computing Surveys* 55.12 (2023), lk 1–38. DOI: [10.1145/3571730](https://doi.org/10.1145/3571730).
- [12] Tanvir H., Kittask C., Eiche S. ja Sirts K. EstBERT: A pretrained language-specific BERT for Estonian. *Proceedings of the 23rd Nordic Conference on Computational Linguistics (NoDaLiDa)*. 2021, lk 11–19. <https://aclanthology.org/2021.nodalida-main.2/>.
- [13] Kuulmets H.-A., Purason T., Luhtaru A. ja Fishel M. Teaching Llama a new language through cross-lingual knowledge transfer. *Findings of the Association for Computational Linguistics: NAACL 2024*. 2024. DOI: [10.48550/arXiv.2404.04042](https://doi.org/10.48550/arXiv.2404.04042). <https://aclanthology.org/2024.findings-naacl.210/>.
- [14] Kuulmets H.-A., Purason T. ja Fishel M. How well do LLMs know Finno-Ugric languages? A systematic assessment. *Proceedings of the 25th Nordic Conference on Computational Linguistics (NoDaLiDa/Baltic-HLT)*. 2025. <https://aclanthology.org/2025.nodalida-1.37/>.
- [15] Burstein J., Tetreault J. ja Madnani N. Automated essay scoring: Writing assessment and instruction. *Handbook of Automated Essay Evaluation*. Toim. Shermis M. D. ja Burstein J. Routledge, 2013, lk 55–67.
- [16] Hyland K. *Metadiscourse: Exploring Interaction in Writing*. London: Continuum, 2005.
- [17] Liu P., Yuan W., Fu J., Jiang Z., Hayashi H. ja Neubig G. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. *ACM Computing Surveys* 55.9 (2023), lk 1–35. DOI: [10.1145/3560815](https://doi.org/10.1145/3560815).
- [18] Wei J., Wang X., Schuurmans D., Bosma M., Ichter B., Xia F., Chi E. H., Le Q. V. ja Zhou D. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*. Kd 35. 2022, lk 24824–24837. <https://arxiv.org/abs/2201.11903>.
- [19] Geng S., Cooper H., Moskal M., Jenkins S., Berman J., Ranchin N., West R., Horvitz E. ja Nori H. JSONSchemaBench: A rigorous benchmark of structured outputs for language models. arXiv preprint. 2025. DOI: [10.48550/arXiv.2501.10868](https://doi.org/10.48550/arXiv.2501.10868). <https://arxiv.org/abs/2501.10868>.
- [20] Burstein J., Chodorow M. ja Leacock C. The Criterion online essay evaluation service. *Proceedings of the AAAI-04 Workshop*. 2004, lk 3–10.
- [21] Attali Y. ja Burstein J. Automated essay scoring with e-rater V.2. *Journal of Technology, Learning, and Assessment* 4.3 (2006). <https://ejournals.bc.edu/index.php/jtla/article/view/1650>.

- [22] Grammarly Inc. Grammarly: writing assistance for English. Tarkvaratoode. 2024. <https://www.grammarly.com/> (10.04.2026).
- [23] Menke J., Roelandse M., Ozyurt B., Martone M. ja Bandrowski A. The Rigor and Transparency Index quality metric for assessing biological and medical science methods. *iScience* 23.11 (2020). DOI: [10.1016/j.isci.2020.101698](https://doi.org/10.1016/j.isci.2020.101698).
- [24] Wang Q., Huang L., Jiang Z., Knight K., Ji H., Bansal M. ja Luan Y. PaperRobot: Incremental draft generation of scientific ideas. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. 2019, lk 1980–1991. DOI: [10.18653/v1/P19-1191](https://doi.org/10.18653/v1/P19-1191).
- [25] Liang W., Zhang Y., Cao H., Wang B., Ding D. Y., Yang X., Vodrahalli K., He S., Smith D. S., Yin Y., McFarland D. A. ja Zou J. Can large language models provide useful feedback on research papers? A large-scale empirical analysis. *NEJM AI* 1.8 (2024). DOI: [10.1056/AIoa2400196](https://doi.org/10.1056/AIoa2400196).
- [26] Kasneci E., Sessler K., Küchemann S., Bannert M., Dementieva D., Fischer F., Gasser U., Groh G., Günnemann S., Hüllermeier E. jt. ChatGPT for good? On opportunities and challenges of large language models for education. *Learning and Individual Differences* 103 (2023). DOI: [10.1016/j.lindif.2023.102274](https://doi.org/10.1016/j.lindif.2023.102274).
- [27] Schulhoff S., Ilie M., Balepur N., Kahadze K., Liu A., Si C., Li Y., Gupta A., Han H., Schulhoff S. jt. The prompt report: A systematic survey of prompting techniques. arXiv preprint. 2024. DOI: [10.48550/arXiv.2406.06608](https://doi.org/10.48550/arXiv.2406.06608). <https://arxiv.org/abs/2406.06608>.
- [28] Hevner A. R., March S. T., Park J. ja Ram S. Design science in information systems research. *MIS Quarterly* 28.1 (2004), lk 75–105. <https://www.jstor.org/stable/25148625>.
- [29] Anthropic. Models overview. Claude API dokumentatsioon. 2026. <https://platform.claude.com/docs/en/about-claude/models/overview> (11.05.2026).
- [30] OpenAI. GPT-5.5 model. OpenAI API dokumentatsioon. 2026. <https://developers.openai.com/api/docs/models/gpt-5.5> (11.05.2026).
- [31] Cohen J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement* 20.1 (1960), lk 37–46. DOI: [10.1177/001316446002000104](https://doi.org/10.1177/001316446002000104).
- [32] Krippendorff K. Computing Krippendorff's alpha-reliability. *Departmental Papers, University of Pennsylvania* (2011). [https://repository.upenn.edu/asc\\_papers/43/](https://repository.upenn.edu/asc_papers/43/).

## Lisad

### Lisa I: Testkogu disain ja kasutatud sünteetiline testkogu

Käesolev lisa kirjeldab kaht omavahel seotud testkogu: (a) *kasutatud* sünteetilist testkogu, mille vastu viidi läbi alapeatükis 5.8 esitatud empiiriline hindamine, ning (b) *kavandatud* päris testkogu disaini, mille koostamine ja annoteerimine kuulub töö jätkukavasse (vt alapeatükk 5.9). Kvoodijaotus peatükitüübi järgi on mõlemal sama, kuid katkendite päritolu, sihtpikkus ja koostamise protseduur erinevad.

#### Kasutatud sünteetiline testkogu

Alapeatükis 5.8 esitatud empiirilises hindamises kasutatud 20-katkendiline testkogu on autori juhendamisel Claude 4.7 Opus mudeliga interaktiivse vestlusliidese (Claude Code) kaudu koostatud sünteetiline materjal, mis on talletatud failis `statistika/andmestik_synth.py`. Iga katkendi pikkus on ligikaudu 100–160 sõna, mis on tahtlikult lühem kui allpool kavandatud päris testkogu sihtpikkus, kuna sünteetilised katkendid on koostatud kategooriapõhise tundlikkuse hindamiseks (üks-kaks tahtlikult lisatud probleemi katkendi kohta), mitte kogu peatüki realistliku pikkuse jäljendamiseks. Sünteetilise testkogu piirangud on käsitletud alapeatükis 5.8 (piirangute jaotis) ning sissejuhatuse generatiivse tehisaru deklaratsioonis.

#### Kavandatud päris testkogu

Päris testkogu *kavandatakse* koosnema 20 tekstikatkendist, mis valitakse Tartu Ülikooli arvutiteaduse instituudi avalikult kättesaadavate bakalaureuse- ja magistritööde hulgast aastatest 2020–2024. Käesoleva töö esitamise hetkel ei ole päris testkogu konkreetsed katkendid veel anonüümitud ega lõplikult valitud – selle samme on kirjeldatud alapeatükis 5.9 (jätkukava). Allpool esitatud kvoot ja valikuprintsiibid on aluseks päris testkogu koostamisel.

#### Katkendite valikuprintsiibid päris testkogu jaoks:

- Iga katkend on iseseisev tervik, milles teema- ja stiilihindang on lokaalselt teostatav (üks kuni kaks lõiku).
- Katkendid sisaldavad nii probleeme kui ka korrektseid lõike, mis välistab kuldstandardi kallutuse ainult probleemide tuvastamise poole.
- Originaaltöödest valitakse välja peamine sisuline tekst ilma joonisteta, valemiteta ja koodinäideteta, sest mudel ei käsitle praegusel hetkel pildilist sisu.

Tabel 7. Kavandatud päris testkogu kvoot peatükitüübi järgi. Sünteetiline testkogu järgib sama jaotust peatükitüübi järgi, kuid kasutab lühemaid katkendeid (100–160 sõna).

| Peatüki tüüp         | Katkendite arv | Sihtpikkus (sõnu) |
|----------------------|----------------|-------------------|
| Sissejuhatus         | 4              | 250–320           |
| Taust ja seotud tööd | 5              | 280–360           |
| Metoodika            | 4              | 270–330           |
| Tulemused            | 4              | 240–290           |
| Kokkuvõte            | 3              | 230–260           |
| <b>Kokku</b>         | <b>20</b>      | —                 |

- Katkendid anonüümitakse enne kuldstandardi annoteerimist (autorite ja konkreetsete tööde nimed eemaldatakse), kuna eesmärk on hinnata mudeli oskust tagasisidet anda, mitte autorit tuvastada.
- Iga katkendi puhul hoitakse eraldi metaandmeid: peatükitüüp, ligikaudne sõnade arv, kuldstandardi probleemide arv ja jaotus kategooriate kaupa. Need andmed lisatakse repositooriumisse koos päris testkogu hindamise tulemustega.

## Lisa II: Struktureeritud prompti täielik tekst

Käesolev lisa esitab peatükis 3.4 kirjeldatud struktureeritud prompti täieliku teksti, mis on prototüübis kasutusel. Prompt asub repositooriumis failis prototuup/backend/prompts/struktureeritud.txt.

Oled eestikeelse informaatika lõputöö tagasisidesüsteem.

OLULINE PIIRANG: Sul EI OLE LUBATUD lõputööd tudengi eest

- kirjutada ega kogu lõike ümber sõnastada. Sa annad ainult
- soovituslikku tagasisidet tudengi enda kirjutatud tekstile.
- Lõpliku otsuse iga soovitusel rakendamise kohta teeb autor
- ise.

Sinu ülesanne on tuvastada probleemid täpselt järgmises neljas kategoorias:

## 1. STRUKTUUR

Tüüpilised probleemid: peatükk algab kohe alapealkirjaga ilma

- ↪ sissejuhatava lõiguta; lõikude vahel pole loogilist
- ↪ üleminekut; peatükk algab või lõpeb
- ↪ joonise/tabeli/loeteluga; alampeatükkide järjekord ei ole
- ↪ loogiline.

NÄIDE: "2. Metoodika\n2.1 Andmete kogumine\nAndmed koguti..."

- ↪ ON probleem, kuna 2. peatükk algab ilma sissejuhatava
- ↪ lõiguta.

## 2. AKADEEMILINE\_STIIL

Tüüpilised probleemid: kõnekeelsed väljendid (tüüp, asi,

- ↪ tegelikult); liigselt pikad laused (üle 35 sõna);
- ↪ mina-vormi liigne kasutamine; otsetõlke ilmingud (See on
- ↪ tõsi, et...); määramatud üldistused (kõik teavad, et...).

NÄIDE: "Tegelikult on see asi päris keeruline." ON probleem -

- ↪ kasutatakse kõnekeelseid sõnu "tegelikult", "asi".

## 3. TERMINOLOOGIA

Tüüpilised probleemid: sama mõiste tähistamiseks kasutatakse

- ↪ läbisegi mitut terminit (lõim ja niit); ingliskeelseid
- ↪ termineid esitatakse ilma esmakasutuse selgituseta.

NÄIDE: Tekst kasutab nii sõna "kompileerimine" kui "tõlkimine"

- ↪ samas tähenduses - vali üks ja kasuta läbivalt.

## 4. VIITAMISVAJADUS

Tüüpilised probleemid: konkreetsed arvulised väited ilma

- ↪ viiteta; teiste autorite mõtted refereeritud ilma viiteta;
- ↪ konkreetne metoodika või algoritm esitatud kui
- ↪ üldteadmine.

NÄIDE: "Üle 75% arendajatest kasutab seda raamistikku." VAJAB

- ↪ viidet originaaluuringule.

VASTUNÄIDE: "HTTP on rakenduskihi protokoll." EI VAJA viidet

- ↪ (üldteadmine).

```
VASTA JSON-formaadis järgmise skeemi järgi (ja ainult sellisel
↪ kujul):
{
  "leiud": [
    {
      "kategooria": "STRUKTUUR" | "AKADEEMILINE_STIIL" |
↪ "TERMINOLOOGIA" | "VIITAMISVAJADUS",
      "tsitaat": "tekstis täpne probleemne kohaviit (kuni 200
↪ tähemärki)",
      "probleem": "lühike kirjeldus, mis selles kohaviites on
↪ valesti",
      "põhjendus": "miks see on probleem - vasta enne soovitus",
      "soovitus": "konkreetne soovitus, KUID MITTE valmis
↪ ümbersõnastus (kuni 200 tähemärki)",
      "kindlus": "kõrge" | "keskmine" | "madal"
    }
  ]
}
```

#### REEGLID:

- Kui konkreetsetes kategoorias probleeme ei leita, jäta selle
 ↪ kategooria kanded vahele.
- Ära leia probleeme, mida tegelikult pole - parem vähem õigeid
 ↪ kui palju valesid.
- Iga leid peab olema põhjendatud konkreetse tsitaadi kaudu.
- Kindlus "kõrge" tähendab, et oled täiesti veendunud; "madal" et
 ↪ see on subjektiivne hinnang ja võiks olla teisiti.
- Sa EI tohi pakkuda valmis ümbersõnastusi; soovitus peab olema
 ↪ juhise, mitte asendustekst.

Peatüki tüüp: \${peatuki\_tyyp}

Peatüki tekst:

"""

\${tekst}

"""

Vasta ainult JSON-iga, ilma lisaselgitusega.

## Lisa III: Lähtekood ja andmestik

Töö juurde kuulub avalik lähtekoodirepositoorium aadressil [https://github.com/UkuRenekKronbergs/TI\\_bakalaureusetoo](https://github.com/UkuRenekKronbergs/TI_bakalaureusetoo), mis sisaldab käesoleva töö esitamise hetkel järgmist:

- prototuupe / – prototüübi täielik lähtekood:
  - backend/ – Python 3.12 + FastAPI backend, sealhulgas demo-režiim, mis tagastab salvestatud näidisvastuse ilma välise API-ta (vt fail backend/demo\_andmed.py).
  - frontend/ – React 18 + TypeScript + Tailwind CSS kasutajaliides.
  - backend/prompts/ – nii üldine kui ka struktureeritud prompt eraldi failides.
  - docker-compose.yml – kogu süsteemi käivitamiseks ühe käsuga.
  - README.md – paigaldus- ja käivitusjuhend (demo-režiim vaikimisi, päris LLM-mudelite kasutamine valikuline).
- estonian/ – lõputöö L<sup>A</sup>T<sub>E</sub>X-lähtekood ja kõik joonised originaalformaadis.
- statistika/ – hindamiskriptid, sünteetiline testkogu, mudelivastuste JSON-id ja tulemuste CSV-failid, sealhulgas paris\_hindamine.py, andmestik\_synth.py ning kaust andmed/paris\_vastused/.

### Jätkukavasse kuulub:

- testkogu/ – 20 anonüümset päris tekstikatkendi tekstifailid ja sõltumatu teise annotaatoriga koostatud kuldstandardi märgendused JSON-formaadis. Testkogu disain on esitatud lisas I; konkreetsete tekstifailid valmistatakse ette ja annotaatoritakse jätkukava sammude raames.

## Lisa IV: Prototüübi kasutusjuhend

Prototüübi käivitamiseks on vaja Dockerit (versioon 24 või uuem). API-võtit *ei ole vaja*, kui kasutatakse vaikimisi demo-režiimi. Käivitamise sammud on järgmised:

1. Kloonida repositoorium käsuga `git clone` [https://github.com/UkuRenekKronbergs/TI\\_bakalaureusetoo.git](https://github.com/UkuRenekKronbergs/TI_bakalaureusetoo.git) ja siseneda kausta prototuupe/.

2. Käivitada käsk `docker compose up --build` kaustas `prototuuup/`. See ehitab ja käivitab nii backendi (port 8000) kui ka frontendi (port 5173).
3. Avada brauseris aadress <http://localhost:5173>.
4. Valida mudeliks *Demo (salvestatud vastused)* (vaikevalik), valida peatükitüüp ja promptitüüp. Soovi korral vajutada nuppu *Lae näidistekst*, mis paigutab tekstikasti valitud peatükitüübi näidisteksti. Vajutada *Analüüsi*.

Demo-režiimis tagastab backend salvestatud näidisvastuse ilma võrgupäringuta – sisestatud tekst ei lahku kohalikust masinast.

**Päris LLM-mudelite kasutamine (valikuline).** Kui soovetakse kasutada Claude 4.7 Opust või GPT-5.5, tuleb:

1. Kopeerida fail `.env.example` failiks `.env` ning sisestada vastav API-võti (`ANTHROPIC_API_KEY=...` ja/või `OPENAI_API_KEY=...`).
2. Käivitada süsteem uuesti käsuga `docker compose up --build`.
3. Kasutajaliideses valida mudeliks vastavalt *Claude 4.7 Opus* või *GPT-5.5*.

**Oluline:** päris LLM-mudeli valikul saadetakse sisestatud tekst Anthropic'i või OpenAI serveritesse. Kui tekst sisaldab tundlikku informatsiooni, mille edastamine kolmandale poolele ei ole sobiv, tuleks kasutada demo-režiimi või kasutamisest hoiduda. Süsteem kuvab enne esimest LLM-päringut vastava hoiatuse, mille kasutaja peab kinnitama.



## Litsents

### **Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks**

Mina, **Uku Renek Kronbergs**,

1. annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) minu loodud teose

**„Suurel keelemudelil põhineva eestikeelse informaatika teksti tagasisidesüsteemi prototüüp ja pilootuuring”,**

mille juhendaja on Alo Peets, MSc, reprodutseerimiseks eesmärgiga seda säilitada, sealhulgas lisada digitaalarhiivi DSpace kuni autoriõiguse kehtivuse lõppemiseni.

2. annan Tartu Ülikoolile loa teha punktis 1 nimetatud teos üldsusele kättesaadavaks Tartu Ülikooli veebikeskkonna, sealhulgas digitaalarhiivi DSpace kaudu Creative Commons'i litsentsi *CC BY NC ND 4.0* alusel, mis lubab autorile viidates teost reprodutseerida, levitada ja üldsusele suunata ning keelab tuletatud teoste loomise ja teose kasutamise ärieesmärgil kuni autoriõiguse kehtivuse lõppemiseni.
3. olen teadlik, et punktides 1 ja 2 nimetatud õigused jäävad alles ka autorile.
4. kinnitan, et lihtlitsentsi andmisega ei rikuta teiste isikute intellektuaalomandi ega isikuandmete kaitse seadusest tulenevaid õigusi.

**Uku Renek Kronbergs**

Tartu, 12.05.2026