

TARTU ÜLIKOOL
Arvutiteaduse instituut
Informaatika õppekava

Uku Renek Kronbergs

**Teostatavusuuring: Tehisintellekti abil
eestikeelse tehnilise informaatika alase
lõputöö genereerimine**

Bakalaureusetöö (9 EAP)

Juhendaja:
Alo Peets, MSc

Tartu 2026

Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine

Lühikokkuvõte:

Käesolev bakalaureusetöö uurib tehisintellekti (TI) rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Töös võrreldakse nelja juhtivat suurt keelemudelit koos vastavate agentsete tööriistadega – Google Gemini 3.1 Pro (Antigravity), OpenAI GPT-5.4 (ChatGPT Codex laiendus Visual Studio Code'is), Anthropic Claude Sonnet 4.6 (Cowork) ning Anthropic Claude Opus 4.6 (Cowork) – nende võimekuse osas luua struktureeritud, akadeemiliselt korrektset ja sisuliselt väärtuslikku eestikeelset teksti. Kõigi kombinatsioonide puhul kasutati ühte ja sama lühikest eestikeelset viibet, mis palus luua LaTeX-vormingus terviklik bakalaureusetöö, mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele, valida ise informaatikaga seotud teema ning kasutada töökausta paigutatud UniTartuCS malli. Cowork on sama ettevõtte toodetud Claude Code'ist eraldiseisev agentne tööriist. Genereeritud tekstide kvaliteeti hinnati struktuuri, keelelise korrektsuse (kirjavigade tiheduse), viidete hulga ja kontrollitavuse, eestikeelse akadeemilise stiili (anglitsismide ja esimese isiku asesõnade kasutuse) ning mahu põhjal. Eksperimendi tulemused paljastasid kombinatsioonide vahel olulisi erinevusi. Claude Opus 4.6 + Cowork genereeris 61-leheküljelise eestikeelse lõputöö paroolihalduri teemal. Claude Sonnet 4.6 + Cowork genereeris 40-leheküljelise eestikeelse lõputöö TI-põhise lõputöö genereerimise teemal. GPT-5.4 keeldus tavapärase ChatGPT vestlusliidese kaudu täielikku tööd kirjutamast, kuid Codex laiendusega õnnestus tal genereerida 47-leheküljeline eestikeelne töö RAG-põhise küsimus-vastus süsteemi teemal. Gemini 3.1 Pro + Antigravity genereeris 39-leheküljelise eestikeelse töö generatiivse TI mõjust programmeerimisele, mille empiiriline osa oli täielikult fabritseeritud. Tulemused näitavad, et mudel-tööriista kombinatsioonide suutlikkus erineb drastiliselt nii ülesandest arusaamise, keelevaliku, ortograafilise täpsuse kui ka juhiste järgimise osas. Töö annab soovitusel TI tööriistade efektiivseks kasutamiseks lõputöö kirjutamise protsessis ning kaardistab valdkonnad, kus inimese panus on endiselt asendamatu.

Võtmesõnad: tehisintellekt, keelemudelid, lõputöö genereerimine, eesti keel, teostatavusuuring, Cowork, Claude Code

CERCS: P170 Arvutiteadus, arvutusmeetodid, süsteemid, juhtimine (automaatjuhtimisteooria)

Feasibility Study: Generating an Estonian-Language Technical Computer Science Thesis Using Artificial Intelligence

Abstract:

This bachelor's thesis investigates the feasibility of applying artificial intelligence (AI) to generate an Estonian-language technical computer science thesis. The study compares four leading large language models paired with corresponding agentic tools – Google Gemini 3.1 Pro (Antigravity), OpenAI GPT-5.4 (ChatGPT chat interface and ChatGPT Codex VS Code extension), Anthropic Claude Sonnet 4.6 (Cowork), and Anthropic Claude Opus 4.6 (Cowork) – in terms of their ability to produce structured, academically correct, and substantively valuable Estonian-language text. A single short Estonian-language user prompt was used for every combination, instructing the model to produce a complete LaTeX-formatted bachelor's thesis meeting the requirements of the University of Tartu's Institute of Computer Science, to choose a computer-science-related topic itself, and to use the UniTartuCS LaTeX template placed in the working directory. Cowork is a separate Anthropic product from Claude Code. Output quality was assessed using structure, orthographic accuracy, the number and verifiability of citations, Estonian academic style (anglicism and first-person pronoun usage), and document length. The experiment revealed significant differences between combinations. Claude Opus 4.6 + Cowork produced a 61-page Estonian-language thesis on a password manager. Claude Sonnet 4.6 + Cowork produced a 40-page Estonian-language thesis on AI-based thesis generation. GPT-5.4 declined to write a full thesis via the standard ChatGPT chat interface, but via the Codex extension succeeded in generating a 47-page Estonian-language thesis on a RAG-based question-answering system. Gemini 3.1 Pro + Antigravity generated a 39-page Estonian-language thesis on the impact of generative AI on programming, whose empirical part was wholly fabricated. Results demonstrate that model-tool combinations differ drastically in task comprehension, language selection, orthographic accuracy, and instruction adherence. The thesis provides recommendations for the effective use of AI tools in the thesis writing process and maps areas where human contribution remains irreplaceable.

Keywords: artificial intelligence, language models, thesis generation, Estonian language, feasibility study, Cowork, Claude Code

CERCS: P170 Computer science, numerical analysis, systems, control

Sisukord

1. Sissejuhatus	7
2. Taust ja kirjanduse ülevaade	9
2.1 Suurte keelemudelite areng	9
2.2 Eesti keele töötlemine keelemudelites	10
2.3 TI akadeemilises kirjutamises	11
2.4 Tartu Ülikooli lõputööde nõuded	12
3. Metoodika	13
3.1 Mudelite ja tööriistade valiku kriteeriumid	13
3.2 Eksperimendi ülesehitus	14
3.3 Hindamiskriteeriumid	16
4. TI mudelite võrdlus	17
4.1 Google Gemini 3.1 Pro	17
4.1.1 Tehniline ülevaade	17
4.1.2 Hinnastamine	17
4.1.3 Eesti keele tugi	18
4.2 OpenAI GPT-5.4	18
4.2.1 Tehniline ülevaade	18
4.2.2 Hinnastamine	18
4.2.3 Eesti keele tugi	19
4.3 Anthropic Claude Sonnet 4.6	20
4.3.1 Tehniline ülevaade	20
4.3.2 Hinnastamine	20
4.3.3 Eesti keele tugi	20
4.4 Anthropic Claude Opus 4.6	21
4.4.1 Tehniline ülevaade	21
4.4.2 Hinnastamine	21
4.4.3 Eesti keele tugi	22
4.5 Mudelite koondvõrdlus	22
4.6 Mõtlemismudelite võrdlus	23
5. Eksperiment ja tulemused	24
5.1 Eksperimendi ülesehitus	24
5.2 Claude Sonnet 4.6 (Cowork): terviklik eestikeelne lõputöö	24

5.3 GPT-5.4 (vestlusliides ja Codex): liidesest sõltuv käitumine	25
5.4 Gemini 3.1 Pro (Antigravity): mahukas, kuid fabritseeritud lõputöö.....	26
5.5 Claude Opus 4.6 (Cowork): terviklik tehniline lõputöö.....	27
5.6 Kombinatsioonikäitumise üldised järeldused	28
5.7 Kirjavigade analüüs.....	29
5.8 Mahu ja struktuuri analüüs.....	31
5.9 Viidete kvantitatiivne analüüs.....	32
5.10 Anglitsismid ja eesti keele puhtus	33
5.11 Akadeemilise stiili indikaatorid	34
5.12 Hinnangu stabiilsus ja subjektiivsus	35
6. Arutelu	36
6.1 TI tugevused lõputöö kirjutamisel	36
6.2 TI puudujäägid ja piirangud	37
6.3 Hinnakujundus ja majanduslik teostatavus	39
6.4 Eesti keele korrektuur ja toimetamine	40
6.5 Soovitused TI tööriista valikuks.....	41
6.6 Tööriistad, mida vältida.....	42
6.7 Eetilised kaalutlused ja akadeemiline ausus.....	43
6.8 Tulevikuväljavaated	43
7. Agentsed TI tööriistad lõputöö genereerimisel	46
7.1 Claude Code'i ülevaade	46
7.2 Claude Code'i võrdlus tavapärase vestlusliidesega	46
7.3 Soovitused lõputöö genereerimiseks Claude Code'iga.....	46
7.3.1 Projekti ettevalmistamine	47
7.3.2 Genereerimise töövoog	48
7.3.3 Parimad praktikad.....	48
7.4 Alternatiivne agentne tööriist: Google Antigravity	49
7.5 Alternatiivne agentne tööriist: ChatGPT Codex Visual Studio Code'is.....	49
7.6 Claude Code'i piirangud	50
7.7 Juhtumiuuring: paroolihalduri lõputöö Cowork'i ja Opus 4.6-ga	50
7.7.1 Genereerimisprotsess.....	51
7.7.2 Genereeritud töö omadused.....	51
7.7.3 Järeldused juhtumiuuringust.....	51

7.8 Käesoleva bakalaureusetöö enda kirjutamise töövoog	52
7.8.1 Kasutatud TI tööriist ja mudel	52
7.8.2 Etapp 1: algne ühe kasutajaviibega katse sisukorra kavandamiseks	53
7.8.3 Etapp 2: iteratiivne kirjutamine ja toimetamine	53
7.8.4 Allikate otsimine ja bibliograafia haldamine	54
7.8.5 Kvantitatiivse analüüsi ja andmete kogumise töövoog	55
7.8.6 Kompileerimine, vormistuse kontroll ja kvaliteedi hindamine	55
7.8.7 Versioonihaldus GitHubi abil	56
7.8.8 Rollijaotus autori ja TI vahel	57
7.8.9 Piirangud ja saadud kogemused	57
7.8.10 Erinevus peaeksperimendi töövoost	59
8. Kokkuvõte.....	60
Viited.....	63
Lisad	68
I. Eksperimendis kasutatud prompt.....	68
II. Genereeritud tööde failid.....	69
III. Tervikliku lõputöö genereerimise näited	70
Litsents	74

1. Sissejuhatus

Suured keelemudelid (*Large Language Models*, LLM) on kahe-kolme aasta jooksul liikunud tehnoloogiaentusiastide mänguasjast igapäevaseks töövahendiks, mida kasutatakse tõsisemate tekstide koostamisel nii ettevõtetes kui ka kõrgkoolides [1]. OpenAI GPT-seeria, Google'i Gemini ning Anthropicu Claude'i mudelid suudavad tänaseks koostada sidusat akadeemilist teksti, toimetada olemasolevaid dokumente ja genereerida ka pikemaid struktureeritud kirjalikke töid [2, 3]. Väiksemate keelte – sealhulgas eesti keele – puhul on mudelite kvaliteet aga ebaühtlasem ning selle süstemaatiline hindamine on seni jäänud tagasihoidlikuks [4, 5].

Bakalaureusetöö on Tartu Ülikooli arvutiteaduse instituudis (ATI) esimene suurem iseseisev akadeemiline kirjatöö, mille üliõpilane peab vormistama kehtestatud juhendi kohaselt [6]. Töö valmimine nõuab tavaliselt ühe semestri, mille käigus tuleb süveneda kirjandusse, kirjeldada metoodikat, esitada tulemused ja järgida akadeemilist stiili. Üliõpilaste seas on viimastel aastatel laialdaselt levinud TI mudelite kasutamine lõputöö kirjutamise abivahendina, kuid senised juhendid ja uurimused ei anna selget pilti sellest, kui usaldusväärselt TI mudelid sellise ülesandega eesti keeles toime tulevad [7, 8]. See küsimus on nii praktiliselt oluline (üliõpilane vajab tõenduspõhist otsust tööriista valikul) kui ka akadeemiliselt oluline (juhendajad ja ülikoolid peavad kujundama selgeid reegleid TI kasutamiseks).

Käesoleva bakalaureusetöö eesmärk on eksploratiivselt hinnata, kas ja kuidas tuleksid kaasaegsed TI mudelid koos tänapäevaste agentsete tööriistadega toime eestikeelse tehnilise informaatika lõputöö genereerimisega. Töö keskendub järgmistele uurimisküsimustele:

1. Millised kaasaegsete TI mudelite ja agentsete tööriistade kombinatsioonid tulevad toime mahukate eestikeelsete akadeemiliste tekstide genereerimisega?
2. Kuidas erinevad nende kombinatsioonide väljundid, kui kõigile antakse üks ja sama lühike kasutajaviibe – kas ja kuidas erinevad need mudel-tööriista paarid ülesande, keelevaliku ja iseseisvalt valitud teema tajumisel?
3. Millistes lõputöö osades suudab TI pakkuda tõhusat abi ning kus on inimese panus endiselt asendamatu?
4. Millised on TI-põhise tekstigenerereerimise praktilised piirangud, sealhulgas hinnapoliitika, kontekstiajna piirangud ja keelelised puudujäägid?

Uurimuse läbiviimiseks valiti neli juhtivat suurt keelemudelit – Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ning Anthropic Claude Opus 4.6 – ja neli nende kasutamise viisi: Gemini 3.1 Pro koos Google'i Antigravity agentse keskkonnaga, GPT-5.4 nii tavapärase ChatGPT vestlusliidese kui ka ChatGPT Codex laienduse (Visual Studio Code'is) kaudu ning Claude Sonnet 4.6 ja Opus 4.6 koos Anthropicu Cowork agentse tööriistaga (Cowork on sama ettevõtte toodetud Claude Code'ist eraldiseisev agentne tööriist). Igale mudel-tööriista kombinatsioonile anti üks ja sama lühike eestikeelne kasutajaviibe, mis palus mudelil genereerida LaTeX-vormingus terviklik bakalaureusetöö Tartu Ülikooli arvutiteaduse instituudi nõuetele vastavalt, valida ise informaatikaga seotud teema ning kasutada töökausta paigutatud UniTartuCS LaTeX-malli. Iteratiivseid järelküsimusi, peatükkide kaupa juhendamist ega juhendite või näidistööde eraldi sisestamist konteksti ei kasutatud; kogu mudelitele antud juhised mahutasid ühte lühikesse viipesse. Genereeritud tervikdokumentide kvaliteeti hinnati mitme kriteeriumi alusel, sealhulgas struktuuri, kirjavigade tiheduse, viidete hulga ja kontrollitavuse, eestikeelse akadeemilise stiili (anglitsismid, esimese isiku asesõnade kasutus) ning mahu põhjal. Kuna iga kombinatsiooni kohta tehti vaid üks jook, on saadud tulemusi käsitletud eksploratiivselt; suurte keelemudelite mitteterministlikkuse tõttu võivad korduskatsed anda erinevaid tulemusi ning järeldused ei pretendeeri üldistatavusele kogu mudeli võimekusele (vt peatükk 6.2).

Töö on struktureeritud järgmiselt. Peatükk 2 annab ülevaate suurte keelemudelite arengust, eesti keele töötlemise väljakutsetest ning varasematest uurimustest TI kasutamisest akadeemilises kirjutamises. Peatükk 3 kirjeldab uurimuse metoodikat, sealhulgas mudelite valiku kriteeriume, ühe kasutajaviibega agentse eksperimendi ülesehitust ja hindamiskriteeriumeid. Peatükk 4 esitab valitud mudelite detailse võrdluse, hõlmates nende tehnilist arhitektuuri, hinnastamist ja eesti keele tuge. Peatükk 5 kirjeldab läbiviidud eksperimenti ja selle tulemusi – tervikliku bakalaureusetöö genereerimise katset ühe kasutajaviibega, mis paljastas mudel-tööriista kombinatsioonide vahel põhimõttelisi erinevusi juhiste järgimisel, teemavalikul ja keelevalikul. Peatükk 6 sisaldab arutelu tulemuste üle, sealhulgas TI kasutamise praktilised soovitused, piirangud ja tulevikuväljavaated. Peatükk 7 kirjeldab Claude Code'i agentset tööriista ja sellega sarnast Anthropicu toodet Cowork ning esitab praktilised soovitused lõputöö genereerimiseks. Peatükk 8 võtab töö tulemused kokku.

2. Taust ja kirjanduse ülevaade

Käesolev peatükk annab ülevaate suurte keelemodelite arengust, eesti keele töötlemise spetsiifikast ning varasematest uurimustest tehisintellekti kasutamisest akadeemilises tekstiloomes.

2.1 Suurte keelemodelite areng

Suurte keelemodelite ajalugu ulatub tagasi 2017. aastasse, mil Vaswani et al. avaldasid transformeri arhitektuuri [9]. See murdepunkt pani aluse kõigile kaasaegsetele keelemodelitele. Esimesed märkimisväärsed keelemudelid, nagu BERT [10] ja GPT-2 [11], demonstreerisid, et suuremahuline eeltreenimine võimaldab mudelitel omandada laialdasi keelelisi teadmisi.

GPT-3 ilmumine 2020. aastal [2] tõi kaasa paradigmuuutuse, näidates, et 175 miljardi parameetriga mudel suudab täita mitmesuguseid ülesandeid ilma spetsiifilise peenhäälestamiseta (*fine-tuning*). Sellest ajast on mudelid kiiresti arenenud nii suuruse, arhitektuuri kui ka võimekuse poolest.

2025.–2026. aasta on olnud eriti viljakas periood. OpenAI avaldas GPT-5.4 mudeli, mis pakub kuni 1 000 000 tokeni kontekstiakent ning ühendab teksti, pildi ja heli töötlemise ühtsesse multimodaalsesse arhitektuuri [12]. Google tõi turule Gemini mudeliperekonna, mille uusim versioon Gemini 3.1 Pro pakub kuni miljoni tokeni pikkust kontekstiakent [13]. Anthropic arendas välja Claude mudeliperekonna, mille Sonnet 4.6 versioon paistab silma eriti tugeva analüütilise võimekuse, parandatud kodeerimise ja juhiste järgimise võimete ning pikaajalise konteksti haldamisega [14]. Sama perekonna tippmudel Opus 4.6 [15] pakub veelgi sügavamat arutlusvõimekust ja on kasutatav Anthropicu agentsete tööriistade Claude Code [16] ja Cowork kaudu, mis võimaldavad mudelil iseseisvalt faile lugeda, kirjutada ja projekte hallata.

Eraldi väärib mainimist nn mõtlemismodelite (*reasoning models*) areng. OpenAI o3 ja GPT-5.4 Pro mudelid [17] kasutavad ahelpõhjendamist (*chain-of-thought reasoning*), et parandada keerulisemate ülesannete lahendamist. Google DeepMind on samuti arendanud Gemini mudelite mõtlemisversioone. Need mudelid on eriti kasulikud keeruliste struktureeritud tekstide loomisel, kus on vaja järgida mitmeid reegleid üheaegselt.

2.2 Eesti keele töötlemine keelemudelites

Eesti keel kuulub soome-ugri keelkonda ja on morfoloogiliselt rikas keel 14 käändega ning keerulise sõnamoodustussüsteemiga [18]. See eripära teeb eesti keele töötlemise keelemudelite jaoks oluliselt keerulisemaks kui näiteks inglise keele puhul.

Suurte keelemudelite eesti keele oskus sõltub eelkõige treeningandmete mahust ja kvaliteedist. Common Crawl andmestikus, mida enamik mudeleid kasutab, moodustab eesti keel väga väikese osa – hinnanguliselt alla 0,1% kogumandmetest [19]. See tähendab, et mudelite eesti keele oskus on oluliselt nõrgem kui inglise keele puhul.

Tartu Ülikooli keeletehnoloogia uurimisrühm on teinud märkimisväärsed tööd eesti keele ressursside ja tööriistade arendamisel. EstBERT [20] on eesti keelele kohandatud BERT mudel, mis on treenitud eestikeelsel tekstikorpusel. Samuti on arendatud mitmesuguseid eesti keele töötlemise tööriistu, nagu morfoloogiline analüsaator ja süntaktiline parser [21]. Hiljutine EstLLM projekt [5] on teinud olulisi edusamme suurte keelemudelite eesti keele võimekuse parandamisel, kasutades jätkutreenimist (*continued pretraining*) ja järeltreenimist (*post-training*) mitmekeelsete mudelite baasil. Uurimus näitas, et spetsialiseeritud treeninguga saab eesti keele kvaliteeti oluliselt tõsta, ilma et mudeli üldine arutlusvõimekus kannataks.

Mitmekeelsete mudelite arendamise seisukohast väärib esiletõstmist Aya mudel [22], mis on juhendipõhiselt peenhäälestatud avatud lähtekoodiga keelemudel, mis toetab 101 keelt, sealhulgas mitmeid väikese ressursiga keeli. Aya ületas mT0 ja BLOOMZ mudeleid enamikus ülesannetes, demonstreerides, et sihipärase mitmekeelse peenhäälestamisega on võimalik oluliselt parandada väikeste keelte kvaliteeti. Kuulmets et al. [4] süstemaatiline hindamine näitas, et soome-ugri keelte, sealhulgas eesti keele, tugi avatud keelemudelites on viimastel aastatel kiiresti paranenud, kuid jääb endiselt inglise keelest oluliselt maha. Suurte keelemudelite puhul on eesti keele kvaliteet viimase kahe aasta jooksul märgatavalt paranenud. Kui varasemad GPT-3-põhised mudelid tegid eesti keeles sageli lihtsalt märgatavaid grammatilisi vigu, siis GPT-5.4, Gemini 3.1 Pro ja Claude Sonnet 4.6 suudavad luua grammatiliselt suures osas korrektset eesti keelt. Siiski esineb endiselt probleeme tehnilise terminoloogiaga, akadeemilise stiiliga ning pikematel tekstidel keelelise järjepidevuse hoidmisega. Kiil [23] on Tartu Ülikooli bakalaureusetöös võrrelnud suuri keelemudeleid eesti bioloogiaolümpiaadi küsimuste põhjal. Parim mudel saavutas 85,35% täpsuse, mis on võrreldav olümpiaadiosalejate tipptulemusega. See kinnitab mudelite kasvavat võimekust ka eestikeelsetes ainespetsiifilistes ülesannetes.

2.3 TI akadeemilises kirjutamises

Tehisintellekti kasutamine akadeemilises kirjutamises on muutunud laialdaselt arutatavaks teemaks. Liang et al. [1] leidsid, et TI-genereeritud teksti osakaal teadusartiklites on märkimisväärselt kasvanud, eriti arvutiteaduse ja meditsiini valdkonnas. See tõstatab küsimusi akadeemilise aususe, originaalsuse ja kvaliteedikontrolli kohta.

Mitmed ülikoolid, sealhulgas Tartu Ülikool, on kehtestanud juhised TI kasutamiseks akadeemilises töös [6]. Üldiselt on lubatud kasutada TI-d abivahendina, kuid üliõpilane peab selgelt märkima, millises ulatuses ja millisel eesmärgil TI-d kasutati. Lõputöö ei tohi olla sisuliselt TI-genereeritud, vaid üliõpilane peab demonstreerima iseseisvat analüütilist mõtlemist.

Rodafinos [8] rõhutab, et generatiivsete TI tööriistade vastutustundlik integreerimine akadeemilisse kirjutamisse on hädavajalik, tuues esile nii efektiivsuse kasvu kui ka kvaliteedi paranemise, kuid rõhutades samas TI väljundite kontrollimise ja inimese kriitilise järelevalve säilitamise vajadust. Lund et al. [7] leidsid 401 USA üliõpilase küsitluses, et tudengite eetilised veendumused – mitte institutsionaalsed poliitikad – on tugevaim ennustaja TI kasutamise tajumisel akadeemilise väärkäitumisena.

Varasemad uurimused on näidanud, et TI mudelid on eriti kasulikud järgmistes akadeemilise kirjutamise aspektides:

- **Teksti struktureerimine** – TI suudab luua hästi struktureeritud tekstikavandeid ja peatükkide ülesehitust [24].
- **Kirjanduse ülevaade** – mudelid suudavad kokku võtta ja sünteesida olemasolevat kirjandust, kuigi allikate täpsus vajab kontrollimist [25].
- **Keeleline toimetamine** – TI on efektiivne grammatika-, stiili- ja sõnastusparanduste tegemisel [26].
- **Tõlkimine** – mudelid suudavad pakkuda rahuldava kvaliteediga tõlkeid akadeemilisest tekstist [27].

Samas on tuvastatud olulisi puudujääke:

- **Hallutsinatsioonid** – mudelid võivad genereerida faktiliselt valesid väiteid või olematud viiteid [28]. Mugaanyi et al. [29] leidsid, et ChatGPT genereeritud viidetest olid 72,7% loodusteadustes ja 76,6% humanitaarteadustes küll olemasolevad, kuid DOI-de täpsus oli vaid 32,7% ja 8,5% vastavalt. Chelli et al. [30] näitasid, et GPT-3.5, GPT-4 ja

Bard hallutsineerisid viiteid vastavalt 39,6%, 28,6% ja 91,4% juhtudest. Kim et al. [31] tuvastasid, et hallutsinatsioonimäärad on geograafiliselt ebavõrdsed – madalama sissetulekuga riikide kontekstis ületas DOI hallutsinatsioonimäär 80%.

- **Sisuline sügavus** – TI-genereeritud tekstid kipuvad olema pealiskaudsed ja kordavad üldtuntud seisukohti [32].
- **Originaalsus** – mudelid ei loo uusi teadmisi, vaid kombineerivad olemasolevat informatsiooni [33].
- **Väikeste keelte spetsiifika** – eesti keele ja teiste väikeste keelte puhul on kvaliteet oluliselt madalam [34].

2.4 Tartu Ülikooli lõputööde nõuded

Tartu Ülikooli arvutiteaduse instituudi (ATI) lõputööde juhend [6] sätestab nõuded nii töö struktuurile, vormistusele kui ka sisule. ATI juhendi kohaselt on bakalaureusetöö tüüpiline maht ilma lisadeta ligikaudu 20 lehekülge; loodus- ja täppisteaduste valdkonna (LOTE) üldjuhend [35] lubab bakalaureusetöö mahuks ilma lisadeta 20–50 lehekülge. Töö peab sisaldama sissejuhatust, kirjanduse ülevaadet, metoodika kirjeldust, tulemuste esitlust, arutelu ja kokkuvõtet.

Vormistuse osas näeb ATI juhend ette kirjasuuruse 12 pt ning reavahe 1,0–1,5 ja soovitab seriifidega kirja (nt Times New Roman) [6]. UniTartuCS LaTeX-mall, mida käesolev töö kasutab, rakendab neist piiridest ühtse variandi (konkreetne kirjatüüp ja reavahe on määratud malli poolt). Viitamissüsteem peab olema ühtlane ja vastama valitud stiilile (IEEE, ACM, APA vms), joonised ja tabelid peavad olema nummerdatud ja viidatud tekstis.

LOTE lõputööde juhend [35] lisab täiendavaid nõudeid seoses TI kasutamisega: üliõpilane peab lõputöös deklareerima, milliseid TI vahendeid ta kasutas, millises töö osas ja millises ulatuses. See nõue on eriti asjakohane käesoleva uurimuse kontekstis, kus TI kasutamine on töö enda uurimisobjekt.

3. Metoodika

Käesolev peatükk kirjeldab uurimuse metoodikat, sealhulgas TI mudelite ja agentsete tööriistade valiku kriteeriume, eksperimendi ülesehitust, ühe kasutajaviibega (*single-prompt*) lähenemise sisu ning hindamiskriteeriumeid.

Terminoloogilise täpsuse huvides tuleb märkida, et kuigi ingliskeelses kirjanduses kasutatakse sageli sõna *one-shot*, tähendab see masinõppes üldjuhul olukorda, kus mudelile antakse üks näidislahendus. Käesolevas uurimuses näidiseid ei esitata – mudelile antakse vaid üks lühike kasutajaviibe ilma näideteta, mis on pigem *zero-shot*- või täpsemalt *single-prompt*-lähenemine agentse töövoos raames. Sisemiselt võib mudel agentse tööriista abil teha mitu sammu (failide lugemine, kirjutamine, L^AT_EX kompileerimine, vigade parandamine); “ühe kasutajaviibe” tähistab siin üksnes kasutajapoolset suhtlust mudeliga.

3.1 Mudelite ja tööriistade valiku kriteeriumid

Uurimuse jaoks mudelite valimisel lähtuti järgmistest kriteeriumidest:

1. **Eesti keele tugi** – mudel peab suutma genereerida grammatiliselt korrektset eesti keelt ning mõistma eestikeelset sisendit.
2. **Kontekstiakna suurus** – bakalaureusetöö genereerimine eeldab mahuka konteksti (juhendid, varasemalt genereeritud osad, L^AT_EX mall) töötlemist, mistõttu on vajalik piisavalt suur kontekstiaken.
3. **Kättesaadavus ja dokumentatsioon** – mudel peab olema kättesaadav API kaudu või veebirakendusena ning omama piisavat dokumentatsiooni.
4. **Hind** – mudeli kasutamine peab olema majanduslikult mõistlik üliõpilase jaoks.
5. **Ajakohasus** – mudel peab olema üks uuemaid versioone (2025–2026).

Nende kriteeriumide alusel valiti neli mudelit: Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ning Anthropic Claude Opus 4.6. Opus 4.6 lisati võrdlusse kui sama mudeliperekonna võimekaim mudel, et hinnata mudeli suuruse mõju genereeritud teksti kvaliteedile. Valiku põhjendused on esitatud peatükis 4.

Kuna käesolev eksperiment nõudis failisüsteemi ligipääsu ja L^AT_EX kompileerimist, ei saanud mudeleid kasutada puhta vestlusliidese kaudu. Iga mudeli kohta kasutati selle mudeli pakkuja ametlikku või laialt kasutatavat agentset tööriista: Claude Sonnet 4.6 ja Opus 4.6 puhul

Anthropicu Cowork, Gemini 3.1 Pro puhul Google'i Antigravity ning GPT-5.4 puhul ChatGPT Codex laiendus Visual Studio Code'is. Lisaks testiti GPT-5.4 puhul võrdluseks ka tavapärasest ChatGPT vestlusliidest. Oluline on rõhutada, et eksperimendis võrreldud üksusteks ei ole niivõrd “mudelid iseenesest”, kuivõrd *mudeli ja agentse tööriista kombinatsioonid*. Seetõttu tuleb tulemusi tõlgendada konkreetsete mudel-tööriista paaride, mitte puhaste mudelivõimekuste näitajatena – süsteemijuhised, faililigipääs, automaatne kompileerimine ja liidese ohutuspoliitika erinevad tööriistade lõikes ning mõjutavad väljundit. Seda piirangut on täiendavalt käsitletud peatükis 6.2.

3.2 Eksperimendi ülesehitus

Uurimus piirdus ühe eksperimendiga: igale mudel-tööriista kombinatsioonile anti üks ja sama lühike eestikeelne kasutajaviibe ning lasti agentsel töövool genereerida terviklik bakalaureusetöö ilma järelküsimumste, iteratiivse suunamise või peatükkide kaupa juhendamisetä. Selline ühe kasutajaviibega lähenemine valiti teadlikult kahel põhjusel. Esimene põhjus on see, et lähenemine kajastab kõige ausamalt seda, kuidas keelemudelit kasutaks üliõpilane, kes soovib lõputöö kirjutamist TI-le täielikult delegeerida – see on stsenaarium, mida akadeemilise aususe kontekstis on oluline hinnata. Teine põhjus on see, et identne minimaalne sisend võimaldab nelja mudel-tööriista kombinatsiooni väljundeid kõige otsesemalt võrrelda, kuna ühtegi kombinatsiooni ei eelistata täiendava konteksti, viibeinseneeria (*prompt engineering*) ega iteratiivse parandamise kaudu. Kuna iga kombinatsiooni kohta tehti üks jooks, on saadud näitajad eksploratiivsed – need iseloomustavad konkreetset katset, mitte üldist mudelivõimekust; mitteterministlikkusest ja agentsete tööriistade varieeruvusest tulenevate piirangute põhjalikumat käsitlust vt peatükist 6.2.

Kasutatud viibe. Kõigile mudelitele anti järgmine eestikeelne viibe (täistekst on esitatud lisas I):

“Sa oled kogenud akadeemiline kirjutaja. Loo täielik bakalaureusetöö LaTeX-vormingus (lisisin töökausta vajaliku malli), mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele. Teema peab olema informaatikaga seotud ja vali ise. Autor on Uku Renek Kronbergs ja juhendaja Alo Peets (MSc).”

Viibe on teadlikult lühike ja sisaldab vaid kolme sisulist piirangut: (1) väljund peab olema LaTeX-vormingus ja kasutama töökaustas olevat UniTartuCS malli; (2) töö peab vastama Tartu Ülikooli arvutiteaduse instituudi nõuetele; (3) teema peab olema informaatikaga seotud, kuid konkreetse teemavaliku teeb mudel ise. Autori ja juhendaja nimed anti tiitellehe täitmiseks. Ülikooli lõputööde juhendeid (TÜ ATI ega LOTE juhendit), varasemaid näidistöid ega muud

täiendavat konteksti viipesse ei lisatud – mudel pidi toetuma ainult oma eelteadmistele selle kohta, mida Tartu Ülikooli arvutiteaduse bakalaureusetöö sisaldama peaks.

Agentsete tööriistade kasutamine. Kuna viibe nõuab LaTeX-malli kasutamist, mitu faili ja kompileeritavat väljundit, ei saanud eksperimenti läbi viia puhta vestlusliidese kaudu, kus mudel ei suuda ise failisüsteemile ligi pääseda. Seetõttu kasutati iga mudeliga sellele mudelile omast agentset töövoogu:

- **Claude Sonnet 4.6** ja **Claude Opus 4.6** – Anthropicu *Cowork* agentne tööriist (mitte segi ajada sama ettevõtte eraldi tootega Claude Code, vt peatükk 7), mis suudab lugeda, kirjutada ja kompileerida projekti $\text{\LaTeX}$ faile otse failisüsteemis.
- **Google Gemini 3.1 Pro** – Google'i *Antigravity* agentne arenduskeskkond, mis pakub funktsionaalselt sarnast võimekust (vt peatükk 7.4).
- **OpenAI GPT-5.4** – mudelit katsetati kahes stsenaariumis: tavapärase ChatGPT vestlusliidese kaudu ning *ChatGPT Codex* laiendusega Visual Studio Code'is (vt peatükk 7.5).

Kõigi nelja mudeli puhul piirduti ühe viipega – pärast viipe esitamist ei antud mudelile täiendavaid juhiseid, ei parandatud genereeritud teksti ega palutud mudelil varasemaid valikuid üle vaadata. Kui mudel ise tegi agentse tööriista raames mitu sisemist sammu (failide loomine, kompileerimine, vigade parandamine), loeti see üheks genereerimistsükliks, kuna kogu töövoog algatas sama algviibe.

Genereeritud väljundid. Eksperimenti tulemusena valmisid neli PDF-failiks kompileeritud bakalaureusetööd (vt peatükk 5):

- `Sonnet_4.6_Cowork.pdf` – 40 lk, eesti keeles;
- `Opus_4.6_Cowork.pdf` – 61 lk, eesti keeles;
- `Gemini_3.1_Pro_Antigravity.pdf` – 39 lk, eesti keeles;
- `GPT_5.4_Visual_Studio_Codex.pdf` – 47 lk, eesti keeles.

Lisaks salvestati GPT-5.4 tavapärase vestlusliidese kaudu saadud keelduv väljund (8-leheküljeline ingliskeelne teostatavusjuhend) võrdluseks.

3.3 Hindamiskriteeriumid

Kuna eksperiment tootis neli tervikdokumenti, keskenduti hindamisel kvantitatiivselt mõõdetavatele tunnustele, mida on võimalik genereeritud PDF-idest objektiivselt tuletada. Need täiendavad töö autori kvalitatiivset üldhinnangut ning vähendavad ühe hindaja subjektiivsusest tulenevat moonutust. Tabelis 1 on esitatud hindamisraamistik.

Tabel 1. Hindamiskriteeriumide raamistik

Kriteerium	Kirjeldus	Hindamisviis
Struktuur ja teemale vastavus	Kas töö järgib bakalaureusetöö ülesehitust (tiitelleht, kokkuvõte, sissejuhatus, peatükid, kokkuvõte, viited) ning kas valitud teema on informaatikaga seotud	Kvalitatiivne kirjeldus
Maht	Lehekülgede arv, sõnade arv ja sõnade tihedus lehekülje kohta	Kvantitatiivne mõõtmine
Keeleline korrektsus	Kirjavigade koguarv ja tihedus lehekülje kohta	Kvantitatiivne loendamine
Viidete kvaliteet	Unikaalsete allikate arv, in-text tsitaatide arv, tsitaatide tihedus lehekülje kohta ning hallutsineeritud viidete hinnanguline osakaal	Kvantitatiivne loendamine + kontroll
Akadeemiline stiil	Ülakomaga anglitsismide arv, arvutiteaduse ingliskeelsete terminite kasutus ning esimese isiku asesõnade esinemine	Kvantitatiivne loendamine
Juhiste järgimine	Väljundkeel (eesti/inglise), L ^A T _E X-vormingu kasutamine, UniTartuCS malli rakendamine, tiitellehe andmed	Binaarne/kvalitatiivne kontroll

Iga kriteeriumi kvantitatiivsed mõõtmised teostati genereeritud PDF-failidest teksti ekstraheerimise teel, jättes välja tiitellehe, kirjanduse loendi ning koodinäited juhtudel, kus see oli metoodiliselt põhjendatud. Kirjavigade loendamisest jäeti välja kontekstis korrektsed, kuid stiililiselt ebaõnnestunud laused, samuti vead, mis ilmsid üksnes PDF-ist teksti ekstraheerimise kodeeringuarterfaktidena. Hindamise viis läbi käesoleva bakalaureusetöö autor (informaatika üliõpilane). Subjektiivsuse vähendamiseks vaatas autor iga genereeritud dokumendi läbi mitmel korral eri aegadel ning lõplikud kvalitatiivsed hinnangud kujunesid nende iteratsioonide põhjal. Ühe hindaja kasutamise piirangut on täpsemalt käsitletud peatükis 6.

4. TI mudelite võrdlus

Käesolev peatükk esitab nelja valitud TI mudeli detailse võrdluse, hõlmates nende tehnilist arhitektuuri, võimekust, hinnastamist ja eesti keele tuge.

4.1 Google Gemini 3.1 Pro

Google Gemini 3.1 Pro on Google DeepMind'i arendatud multimodaalne keelemudel, mis avaldati 2026. aasta veebruaris [13]. Mudel kuulub Gemini mudeliperekonda, mis on Google'i vastus OpenAI GPT-seeriale.

4.1.1 Tehniline ülevaade

Gemini 3.1 Pro peamine eelis on selle ulatuslik kontekstiaken, mis ulatub kuni 1 miljoni tokenini. See võimaldab mudelile sisestada terve raamatu mahus teksti, mis on lõputöö genereerimise kontekstis äärmiselt kasulik – mudelile saab anda korraga nii juhendid, näidistööd kui ka juba genereeritud osad.

Gemini 3.1 Pro on natiivne mõtlemismudel (*thinking model*), mis tähendab, et mudel kasutab sisemist ahelpõhendamist enne vastuse andmist. See parandab oluliselt keeruliste ülesannete lahendamise kvaliteeti, sealhulgas struktureeritud teksti loomist.

4.1.2 Hinnastamine

Gemini 3.1 Pro kasutamine API kaudu (seisuga märts 2026, hinnad esitatud USA dollarites vastavalt Google'i ametlikule hinnakirjale [36]):

- Sisendtokenid: \$2,00 / 1M tokenit (kuni 200K pikkuste päringute puhul)
- Sisendtokenid: \$4,00 / 1M tokenit (üle 200K pikkuste päringute puhul)
- Väljundtokenid: \$12,00 / 1M tokenit (kuni 200K pikkuste päringute puhul)
- Väljundtokenid: \$18,00 / 1M tokenit (üle 200K pikkuste päringute puhul)

Google AI Studio tasuta versioon võimaldab piiratud kasutust ilma kuluta, mis sobib eksperimenteerimiseks. Hinnanguliselt vajab 40-leheküljelise lõputöö genereerimine ca 500 000 väljundtokenit ja ca 2 000 000 sisendtokenit, mis annab puhta API tokenite baashinnanguks ca \$10–16. Agentse tööriista iteratsioonid (korduv failide lugemine ja kirjutamine) tõstavad tegelikku kogukulu oluliselt; täielik kuluarvestus on esitatud peatükis 6.3.

4.1.3 Eesti keele tugi

Gemini 3.1 Pro toetab eesti keelt, kuid selle kvaliteet jääb inglise keelele alla. Meie testides ilmnes, et mudel suudab luua grammatiliselt üldiselt korrektset eesti keelt, kuid esineb probleeme:

- Käändelõppude vead, eriti pikemates lausetes;
- Tehniline terminoloogia on kohati ebajärjekindel (nt vahetab “keelemudel” ja “keelemudel”, “suurandmed” ja “big data” vahel);
- Akadeemiline stiil kaldub olema liiga vaba, meenutades pigem blogipostitust;
- Tervikliku lõputöö genereerimisel kaldus mudel etteantud teemast kõrvale, genereerides töö teistsuguse teema kohta (vt peatükk 5.1).

4.2 OpenAI GPT-5.4

OpenAI GPT-5.4 on OpenAI juhtiv multimodaalne mudel, mis avaldati 2025. aasta detsembris ning mida on pidevalt täiendatud [12]. Mudel ühendab teksti, pildi ja heli töötlemise ühtsesse arhitektuuri.

4.2.1 Tehniline ülevaade

GPT-5.4 kontekstiaken ulatub kuni 1 000 000 tokenini, mis on võrreldav Gemini 3.1 Pro omaga ja pakub piisavat mahutavust ka kõige mahukamate lõputöö genereerimise stsenaariumide jaoks. OpenAI positsioneerib GPT-5.4 mudelina, mis on optimeeritud professionaalseks tööks parandatud arutluskäigu, tööriistade kasutamise ja dokumentide töövoogudega.

Märkimisväärne on GPT-5.4 kasutuse tugev liidese- ja kontekstisõltuvus: käesoleva uurimuse katsetes keeldus mudel ChatGPT vestlusliidese kaudu genereerimast terviklikku lõputööd, viidates akadeemilise aususe piirangutele (vt peatükk 5.1), pakkudes selle asemel teostatavusjuhendit inglise keeles. Sama mudel andis aga ChatGPT Codex laienduse kaudu tervikliku eestikeelse 47-leheküljelise väljundi. See kontrast viitab sellele, et käitumist ei määra ainult mudeli aluskoolitus, vaid ka konkreetse liidese süsteemijuhised ja ohutuspoliitika. Bianchi et al. [37] on dokumenteerinud sarnast “liialdatud ohutuskäitumist”, kus ohutuskoolitusega mudelid keelduvad ka täiesti ohututest ülesannetest, mis pealiskaudselt sarnanevad potentsiaalselt kahjulikele.

4.2.2 Hinnastamine

GPT-5.4 hinnastamine API kaudu (seisuga märts 2026, hinnad esitatud USA dollarites vastavalt OpenAI ametlikule hinnakirjale [38]):

- Sisendtokenid: \$2,50 / 1M tokenit
- Väljundtokenid: \$15,00 / 1M tokenit
- Vahemälus (*cached*) sisendtokenid: \$0,25 / 1M tokenit

ChatGPT Plus tellimus (\$20/kuu) võimaldab piiratud kasutust veebirakenduse kaudu ning katab ka Codex laienduse kasutuse. Puhta API tokenite baashinnanguks 40-leheküljelise töö puhul saab hinnata ca \$10–15; agentse tööriistaga (nt Codex) tegelik kogukulu on kõrgem (vt peatükk 6.3).

GPT-5.4 Pro mudeli hinnastamine on oluliselt kallim:

- Sisendtokenid: \$15,00 / 1M tokenit
- Väljundtokenid: \$120,00 / 1M tokenit

See teeb GPT-5.4 Pro mudeli kasutamise mahuka teksti genereerimiseks ebapraktiliseks.

4.2.3 Eesti keele tugi

GPT-5.4 eesti keele tugi on käesolevas eksperimendis ilmnenu käitumise põhjal piisavalt tugev, et toota terviklikku mahukat eestikeelset akadeemilist teksti – Codex laienduse kaudu genereeritud 47-leheküljeline töö sisaldas vaid ühte kirjaviga (vt peatükk 5.7). ChatGPT vestlusliidese kaudu tehtud katses valis mudel aga sama eestikeelse viipe korral väljundkeeleks inglise keele ja esitas vastuse nõuandva teostatavusjuhendina. See vastuolu viitab sellele, et keelevalik sõltub käesolevas katses pigem liidese süsteemijuhistest ja ohutuspoliitikast kui mudeli aluskeelevõimekusest, mistõttu järgnevas võrdluses käsitletakse vestlusliidese tulemust peamiselt liidese, mitte mudeli keeleliste oskuste näitajana:

- Grammatiliselt korrektne eesti keel nii lühikestes kui ka pikkades (47 lk) tekstides, kui kasutatakse agentset liidest;
- Tendents kasutada ingliskeelseid termineid seal, kus eestikeelne vaste on olemas;
- ChatGPT vestlusliidese kaudu tervikliku töö genereerimisest keeldumine ja inglise keelele üleminek, mis on tõlgendatav liidese, mitte mudeli omadusena;
- Viidete genereerimisel esineb hallutsinatsioone (olematud artiklid ja autorid).

4.3 Anthropic Claude Sonnet 4.6

Anthropic Claude Sonnet 4.6 on Anthropicu arendatud keelemudel, mis avaldati 2026. aasta veebruaris [14]. Claude mudeliperekond eristub teistest oma rõhuasetusega ohutusele ja põhjalikkusele.

4.3.1 Tehniline ülevaade

Claude Sonnet 4.6 kontekstiaken on 200 000 tokenit (beetas 1 miljon tokenit), mis jääb Gemini 3.1 Pro ja GPT-5.4 vahele. Mudeli peamine tugevus on pikaajalise konteksti efektiivne kasutamine – uuringud on näidanud, et Claude suudab kontekstiakna lõpust informatsiooni sama hästi kasutada kui algusest [14].

Anthropic pakub ka Claude'i pikendatud mõtlemisrežiimi, kus mudel kasutab kuni 128 000 tokenit sisemiseks arutluseks (sama piir kehtib ka GPT-5.4 ja Claude Opus 4.6 puhul). See režiim on eriti kasulik keeruliste struktureeritud ülesannete jaoks, nagu akadeemilise teksti genereerimine.

Claude'i eristab teistest mudelitest ka tema võimekus järgida detailseid juhiseid ja stiilireegleid. Meie testides näitas Claude kõige paremat tulemust juhendipõhise genereerimise ülesannetes, kus mudelile anti ette konkreetseid struktuuri nõuded.

4.3.2 Hinnastamine

Claude Sonnet 4.6 hinnastamine API kaudu (seisuga märts 2026, hinnad esitatud USA dollarites vastavalt Anthropicu ametlikule hinnakirjale [39]):

- Sisendtokenid: \$3,00 / 1M tokenit
- Väljundtokenid: \$15,00 / 1M tokenit
- Vahemälus sisendtokenid: \$0,30 / 1M tokenit
- Vahemälus kirjutamine: \$3,75 / 1M tokenit

Claude Pro tellimus (\$20/kuu) võimaldab piiratud kasutust veebirakenduse kaudu. Puhta API tokenite baashinnanguks 40-leheküljelise töö puhul saab hinnata ca \$10–18; Cowork'i agentse töövoo iteratsioonidega tegelik kogukulu on kõrgem (vt peatükk 6.3).

4.3.3 Eesti keele tugi

Claude Sonnet 4.6 eesti keele tugi on hea, kuid mõningate eripäradega:

- Mudel järgib eesti keele grammatikareegleid üldiselt hästi;

- Akadeemiline stiil on lähedane akadeemilises kirjutamises soovitud;
- Siiski esineb kohati ülemäärast keerukust lauseehituses, mis muudab teksti raskesti loetavaks;
- Tehniline terminoloogia on ühtlasem kui teistel mudelitel.

4.4 Anthropic Claude Opus 4.6

Anthropic Claude Opus 4.6 on käesoleva uurimuse eksperimendi läbiviimise ajal (märts 2026) Anthropicu kõige võimekam üldotstarbeline keelemudel, mis avaldati 2026. aasta veebruaris [15]. Opus kuulub samasse Claude mudeliperekonda kui Sonnet, kuid on oluliselt suurem ja võimekam mudel, mis on optimeeritud keeruliste, mitmeosaliste ülesannete lahendamiseks. Tuleb märkida, et mudeliperekond areneb kiiresti – pärast käesoleva eksperimendi läbiviimist on Anthropic avaldanud uuemaid Opus-versioone (sh Opus 4.7), mille baashinnastus on Opus 4.6-ga võrreldav, kuid mida käesolev töö võrdlusesse ei hõlmanud.

4.4.1 Tehniline ülevaade

Claude Opus 4.6 kontekstiaken on 1M tokenit, kuid mudeli peamine eelis seisneb suuremas parameetrite arvus ja sügavamas arutlusvõimekuses. Opus mudelid on Anthropicu mudeliperekonna tipptasemel, pakkudes kõige paremat tulemust keerulistes struktureeritud ülesannetes, nagu pikaajaline teksti genereerimine, koodi kirjutamine ja mitmesammuline probleemilahendus [15].

4.4.2 Hinnastamine

Claude Opus 4.6 hinnastamine API kaudu (sisuga märts 2026, hinnad esitatud USA dollarites vastavalt Anthropicu ametlikule hinnakirjale [39]):

- Sisendtokenid: \$15,00 / 1M tokenit
- Väljundtokenid: \$75,00 / 1M tokenit
- Vahemälus sisendtokenid: \$1,50 / 1M tokenit
- Vahemälus kirjutamine: \$18,75 / 1M tokenit

Opus 4.6 on oluliselt kallim kui Sonnet 4.6 – väljundtokenid on 5 korda kallimad. See teeb Opus mudeli kasutamise mahuka teksti genereerimiseks kulukaks, kuid kvaliteedivõit võib seda kompenseerida. Puhta API tokenite baashinnanguks 40-leheküljelise töö puhul saab hinnata ca

\$55–85; Cowork'i agentse tööriistaga iteratsioonide tegelik kogukulu on oluliselt kõrgem (vt peatükk 6.3).

Claude Max tellimus (\$100–200/kuu) võimaldab Opus mudeli piiratud kasutust veebirakenduse ja Anthropicu agentsete tööriistade (Claude Code, Cowork) kaudu.

4.4.3 Eesti keele tugi

Claude Opus 4.6 eesti keele tugi oli selles eksperimendis (Cowork'i kaudu kasutatud kombinatsioonis) nelja testitud kombinatsiooni seas parim:

- Grammatiliselt korrektne eesti keel ka pikkades ja keerulistes lausetes;
- Akadeemiline stiil on võrreldav emakeelt kirjutava omaga;
- Tehniline terminoloogia on ühtlane ja korrektne;
- Suutis genereerida tervikliku 61-leheküljelise eestikeelse lõputöö (vt peatükk 5.1);
- Lauseehitus oli kõige loomulikum võrreldes teiste kombinatsioonidega.

4.5 Mudelite koondvõrdlus

Tabelis 2 on esitatud nelja mudeli koondvõrdlus peamiste parameetrite lõikes.

Tabel 2. TI mudelite koondvõrdlus

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Kontekstiaken	1M	1M	200K (1M beetas)	1M
Max väljund	64 000	128 000	128 000	128 000
Mõtlemisrežiim	Jah (natiivne)	Jah (Pro eraldi)	Jah (pikendatud)	Jah (pikendatud)
Sisend \$/1M tok	\$2,00–4,00	\$2,50	\$3,00	\$15,00
Väljund \$/1M tok	\$12,00–18,00	\$15,00	\$15,00	\$75,00
Eesti keele kvaliteet	Hea	Väga hea	Väga hea	Suurepärane
Akad. stiil	Rahuldav	Hea	Väga hea	Suurepärane
Viidete kvaliteet	Rahuldav	Rahuldav	Hea	Hea

Tabelist on näha, et Gemini 3.1 Pro + Antigravity kombinatsioon andis selles katses keskmiselt kõige nõrgemad tulemused. GPT-5.4 pakub ühtlast eesti keele kvaliteeti (kui seda kasutatakse

Codex-laienduse kaudu) ja on hinna poolest konkurentsivõimeline. Claude Sonnet 4.6 + Cowork kombinatsioon eristus akadeemilise stiili ja juhiste järgimise poolest. Claude Opus 4.6 + Cowork kombinatsioon saavutas käesolevas katses kõige kõrgema kvaliteedi nii eesti keele, akadeemilise stiili kui ka sisulise sügavuse osas, kuid on oluliselt kallim kui teised kombinatsioonid. Kuna iga kombinatsiooni kohta tehti üks jooks, on tabelis esitatud hinnangud eksploratiivsed (vt piirangute arutelu peatükis 6.2).

4.6 Mõtlemismudelite võrdlus

Eraldi väärrib tähelepanu mõtlemismudelite (*thinking/reasoning models*) mõju genereeritud teksti kvaliteedile. Mõtlemismudelid kasutavad sisemist ahelpõhjendamist, mis võtab lisaaega ja -ressursse, kuid parandab keerulisemate ülesannete tulemust. Ji et al. [40] on eksperimentaalselt näidanud, et ahelpõhjendamise strateegia parandab oluliselt nii teksti genereerimise kvaliteeti kui ka viidete täpsust, mis on eriti oluline akadeemilise teksti kontekstis.

Käesoleva uurimuse peaeksperiment (vt peatükk 5) piirdus ühe kasutajaviibega tervikliku töö genereerimisega ega hõlmanud süstemaatilist mõtlemisrežiimi kvantitatiivset võrdlust. Autori mitteformaalsete kõrvalkatsete põhjal ilmnes, et mõtlemisrežiimi kasutamine:

- parandas teksti loogilist struktureerimist ja vähendas sisulisi vasturääkivusi;
- parandas viidete asjakohasust, kuigi hallutsinatsioonid esines endiselt;
- suurendas genereerimise aega ja kulusid mitmekordselt.

Need tähelepanekud on esialgsed ja vajavad edaspidi süstemaatilist võrdlust. Mõtlemisrežiimi kasutamine on siiski soovituslik eriti sissejuhatuse, metoodika ja arutelu peatükkide genereerimisel, kus on vaja loogilist ja sidusat argumentatsiooni.

5. Eksperiment ja tulemused

Käesolev peatükk kirjeldab läbiviidud eksperimenti, esitab nelja mudeli genereeritud bakalaureusetööde tulemused ning analüüsib nende kvaliteeti erinevatest aspektidest lähtuvalt.

5.1 Eksperimendi ülesehitus

Eksperimendis paluti igal mudel-tööriista kombinatsioonil genereerida terviklik bakalaureusetöö informaatika valdkonnast ühe kasutajaviibega, ilma järelküsimumste ega iteratiivse suunamiseta. Mudelitele anti identne lühike eestikeelne viibe (vt peatükk 3.2 ja lisa I), mis palus mudelil luua LaTeX-vormingus bakalaureusetöö, mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele, kasutades töökausta paigutatud UniTartuCS malli. Konkreetset teemapealkirja ette ei antud – mudel pidi ise valima informaatikaga seotud teema. Autori (Uku Renek Kronbergs) ja juhendaja (Alo Peets, MSc) nimed anti tiitellehe täitmiseks.

Viibe on teadlikult lühike, kuna üks uurimisküsimumstest on, kuidas mudel-tööriista kombinatsioonid reageerivad minimaalsele juhisele ning kas nad suudavad iseseisvalt valida sobiva teema, keele ja struktuuri. Kuna ülesanne nõuab failihaldust, mitme $\text{\LaTeX}$ faili loomist ja kompileerimist, kasutati iga mudeliga agentset töövoogu. Sonnet 4.6 ja Opus 4.6 puhul kasutati Anthropicu Coworkööriista (mis on sama ettevõtte Claude Code'ist eraldiseisev toode, vt peatükk 7), Gemini 3.1 Pro puhul Google'i Antigravity ning GPT-5.4 puhul ChatGPT Codex laiendust Visual Studio Code'is. GPT-5.4 puhul testiti lisaks ka tavapärasest ChatGPT vestlusliidest, mis andis oluliselt erineva tulemuse.

Tulemused olid kombinatsioonide lõikes drastiliselt erinevad, nagu nähtub tabelist 3. Oluline tõlgenduslik märkus: järgnevas analüüsis tuleb tulemusi vaadelda mudeli ja agentse tööriista paaride, mitte puhaste mudelivõimekuste näitajatena – iga jooks tehti üks kord, mistõttu näitajad on eksploratiivsed ja võivad kordusjooksudel erineda.

5.2 Claude Sonnet 4.6 (Cowork): terviklik eestikeelne lõputöö

Claude Sonnet 4.6 + Cowork kombinatsioon genereeris 40-leheküljelise eestikeelse dokumendi, mis järgis bakalaureusetöö struktuuri. Kombinatsioon valis teemaks TI-põhise lõputöö genereerimise – teema, mis ühtib käesoleva bakalaureusetöö teemaga. Töö sisaldas detailseid hindamistabeleid, promptide näiteid lisades ning TI kasutamise deklaratsiooni. Akadeemiline stiil oli tugev ja töö järgis LaTeX-malli korrektset. Peamised puudused olid mõned hallutsineeritud viited (ca 20%), kohati keeruline lauseehitus ning 13 tuvastatud kirjaviga kogu töö peale (vt

Tabel 3. Tervikliku lõputöö genereerimise tulemuste koondülevaade

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Väljundkeel	Eesti	Eesti (Codex) / ingl. (chat)	Eesti	Eesti
Maht (lehekülgi)	39	47 (Codex) / 8 (chat)	40	61
Valitud teema	GenAI ja algajad progr.	RAG-põhine QA-süsteem (Codex); keeldumine (chat)	TI lõputöö gener.	Paroolihaldur
Struktuur	Lõputöö vormis	Lõputöö (Codex) / juhend (chat)	Lõputöö vormis	Lõputöö vormis
Agentne tööriist	Antigravity	Codex VS Code'is	Cowork	Cowork
Viited	9, ca 25% halluts.	22, ca 20% halluts.	17, ca 20% halluts.	35, ca 15% halluts.
Akad. stiil	Hea	Hea (Codex)	Väga hea	Suurepärane

peatükk 5.7), millest mõned asusid nähtaval kohal – näiteks alapealkirjas kaks korda esinenud *Masskiijutamine*.

5.3 GPT-5.4 (vestlusliides ja Codex): liidesest sõltuv käitumine

GPT-5.4 tulem erines teistest fundamentaalselt, kusjuures erinevus ei tulenenud mitte mudelist, vaid liidesest, mille kaudu mudelit kasutati. Tavapärase ChatGPT vestlusliidese kaudu keeldus mudel genereerimast terviklikku lõputööd, viidates otseselt akadeemilise aususe piirangutele. Väljundis selgitati, et täieliku bakalaureusetöö kirjutamine tudengi eest oleks vastuolus Tartu Ülikooli akadeemilise aususe reeglitega. Selle asemel pakkus GPT-5.4 välja 8-leheküljelise ingliskeelse teostatavusjuhendi (*feasibility guide*), mis sisaldas mudelivaliku soovitusi, eksperimendi disaini raamistikku, hindamismetoodikat ja $\LaTeX$ malli juhiseid. Kuigi juhend oli sisuliselt kvaliteetne ja viited olid kontrollitavad, ei vastanud see ülesande püstitusele: väljund oli inglise, mitte eesti keeles, ja vormilt pigem nõuandev memo kui akadeemiline lõputöö. See käitumine viitab sellele, et ChatGPT vestlusliidese süsteemijuhised ja ohutuspoliitika tõlgendavad “tervikliku bakalaureusetöö genereerimine” tüüpi ülesandeid vaikumisi akadeemilise

aususe piirangu alla kuuluvana ning eelistavad sellistes olukordades keeldumist või nõuandvat vastust.

Täiendav katse OpenAI ChatGPT Codex laiendusega Visual Studio Code'i keskkonnas andis aga identsest viiest hoolimata oluliselt erineva tulemuse. Sama GPT-5.4 mudel suutis agentse tööriista kaudu genereerida visuaalselt teiste kombinatsioonide väljunditega sarnase tervikliku 47-leheküljelise eestikeelse dokumendi teemal “Eestikeelse RAG-põhise küsimus-vastus süsteemi kavandamine” (vt peatükk 7.5). See erinevus näitab, et agentne töövoog muudab ülesande konteksti ja tööjaotust – ülesanne jaotub väiksemateks faili- ja kompileerimispõhisteks sammudeks ning liidese süsteemijuhised ja ohutuspoliitika on erinevad – mistõttu sama mudel käitub erinevas liideses erinevalt. Sellest ei tohi järeldada, et GPT-5.4 *ei toeta* eesti keelt tervikliku teksti genereerimisel: Codex-väljund on eestikeelne, mahukas ja ortograafiliselt äärmiselt täpne. Vestlusliidese keeldumine on seega pigem liidese ja selle ohutuskonteksti, mitte mudeli keelelise võimekuse näitaja. Codex laienduse kaudu genereeritud töö oli ortograafilise täpsuse poolest silmapaistev: kogu töö peale tuvastati vaid üks kirjaviga (*vastusevormingun* õige *vastusevormingu* asemel), mis oli nelja kombinatsiooni seas parim tulemus (vt peatükk 5.7).

5.4 Gemini 3.1 Pro (Antigravity): mahukas, kuid fabritseeritud lõputöö

Gemini 3.1 Pro + Antigravity kombinatsioon genereeris 39-leheküljelise eestikeelse bakalaureusetöö teemal “Generatiivse tehisintellekti mõju tarkvaraarenduse produktiivsusele algajate programmeerijate seas”. Kombinatsioon valis iseseisvalt informaatika valdkonnast aktuaalse ja hästi piiritletud uurimisteema, mis käsitles suurte keelemudelite mõju programmeerimise õppimisele.

Genereeritud töö oli struktuuraalselt terviklik ja sisaldas kõiki nõutud komponente: eesti- ja ingliskeelne kokkuvõte, sisukord, sissejuhatus uurimisküsimustega, taust ja kirjandusülevaade (Transformer-arhitektuur, kognitiivne koormus, *over-reliance*), metoodika (väidetavalt kvaasi-eksperimentaalne disain 30 tudengiga, kes fiktiivsete kirjelduste kohaselt töötasid Tartumaa IT-ettevõtetes nagu Nortal, Playtech ja Datafox), tulemused (t-testid, statistilised tabelid), kokkuvõte ja viis lisa. Lisad olid ka hästi esitatud: React.js koodiredaktori komponent (ca 150 rida), PostgreSQL andmebaasi skeem (5 tabelit), Pandas/SciPy andmeanalüüsi skript (ca 160 rida) ning tudengite koodinäited koos vigade analüüsiga.

Töö tugevused olid järgmised:

- Akadeemilise struktuuriga hästi arvestatud: uurimisküsimused, hüpoteesid, statistilised testid;
- Eesti keele kvaliteet oli üldiselt arusaadav, kuigi esines mõningaid terminoloogilisi ebajärjekindlusi;
- Viited (9 allikat) kasutasid reaalsete teadlaste nimesid (Becker, Kazemitabaar, Vaswani jt);
- Koodinäited lisades olid funktsionaalsed ja loogiliselt kirjutatud;
- Töö maht (39 lehekülge) vastas bakalaureusetöö nõuetele.

Peamised puudused olid siiski olulised, kusjuures esimene neist ei ole käsitletav tavapärase kvaliteedipuudusena, vaid akadeemilise väärkasutuse kõrge riskiga juhtumina:

- **Fabritseeritud empiiriline uurimus.** Kombinatsioon loetles 30 tudengiga kvaasi-eksperimenti, sealhulgas osalejate jaotuse katse- ja kontrollrühmadeks, konkreetseid statistilised testid (t-test, Cohen'i *d*), numbrilised tulemused ning Tartumaa IT-ettevõtete kirjeldused. Seda uurimust tegelikult ei toimunud – tudengeid, nende koode, katsekeskkonda ega statistilisi tulemusi ei eksisteeri. Välja mõeldi nii empiirilised andmed kui ka reaalsete Eesti ettevõtete nimede kasutamine. Lugeja, kes ei kontrolli andmeid, saab äärmiselt veenva, kuid tegelikkuses olematu uuringu.
- Viidete kontrollitavust vajab eraldi auditeerimist – kuigi autorite nimed on reaalsed, olid ca 25% viidetest hallutsineeritud (olematud artiklid või valed avaldamisandmed);
- Eesti keele ortograafiline täpsus oli nelja kombinatsiooni seas kõige nõrgem – töös tuvastati 28 selget kirjaviga, sealhulgas tavasõnade valed vormid (*struktuure*, *kordinaadid*, *konfliktide*), mittesõnad (*teoosiab*, *Tehisintsistendi*) ning valede tähtedega asendatud täpitähed (vt peatükk 5.7);
- Antigravity tööriist oli vajalik käesolevas katses saadud tulemuseni jõudmiseks – autori varasemad mitteametlikud katsed ilma agentse tööriistata andsid oluliselt nõrgema tulemuse.

5.5 Claude Opus 4.6 (Cowork): terviklik tehniline lõputöö

Claude Opus 4.6 + Cowork kombinatsioon andis selles eksperimentis kõige ulatuslikuma ja kvaliteetsema väljundi – 61-leheküljelise eestikeelse bakalaureusetöö teemal “Turvalise

paroolihalduri veebirakenduse arendamine”. Cowork’i agentne tööriist (vt peatükk 7) võimaldas mudelil otse kirjutada L^AT_EX faile, hallata viiteid ja kompileerida dokumenti.

Genereeritud töö sisaldas terviklikku tehnilist arhitektuuri (nullteadmise põhimõte, AES-256-GCM krüpteering, Argon2id võtmetuletamine) ning täielikku React/TypeScript kasutajaliidest ja Node.js/Express taustarakendust. Lisaks *väärtis* töö, et rakendus läbis 149 automatiseeritud testi, OWASP Top 10 vastavuse analüüsi ning süsteemi kasutatavuse skaala (SUS) hindamise skooriga 77,0, ja et turvaaudit ei tuvastanud ühtegi kriitilist turvaauku. Olulise metoodilise märkusena tuleb rõhutada, et käesoleva eksperimendi autor ei teostanud nende testide, auditi ega kasutajauuringu iseseisvat läbiviimist – need näitajad on kirjas Opus 4.6 + Cowork kombinatsiooni enda genereeritud väljundis ning kuuluvad samasse kategooriasse empiiriliste väidetega, mida TI-loodud töödes tuleb inimese poolt eraldi kontrollida (vrd Gemini 3.1 Pro fabritseeritud eksperiment alapeatükis 5.4). Opus 4.6 kirjeldatud arhitektuur ja koodinäited olid siiski tunduvalt detailsemad ja sisemiselt sidusamad kui Gemini 3.1 Pro töös esitatud statistilised tulemused.

Opus 4.6 + Cowork tulemuse peamised erinevused võrreldes Sonnet 4.6 + Cowork tulemusega:

- Oluliselt suurem maht (61 vs 40 lehekülge), mis viitab sügavamale sisulisele käsitlelusele;
- Tehniline detailsus oli kõrgem – töö sisaldas konkreetseid koodi- ja arhitektuurinäiteid;
- Eesti keele kvaliteet oli ühtlasem ja loomulikum ka pikemas tekstis – kogu 61-leheküljelise töö peale tuvastati vaid 5 kirjaviga (peamiselt pärisnimedes, nagu *Carnegei* ja *Californiya*), mis teeb kirjavigade tiheduseks 0,08 viga lehekülje kohta (vt peatükk 5.7);
- Viidete hallutsineerimise määr oli madalam (ca 15% võrreldes Sonnet 4.6 ca 20%).

5.6 Kombinatsioonikäitumise üldised järeldused

Tervikliku lõputöö genereerimise eksperiment tõi esile neli fundamentaalselt erinevat käitumismustrit, mis iseloomustasid konkreetseid mudel-tööriista kombinatsioone:

1. **Selles katses suurepärane tulemus** (Claude Opus 4.6 + Cowork): kombinatsioon genereeris kõige mahukama (61 lk) ja tehniliselt sügavaima eestikeelse lõputöö, valides teemaks paroolihalduri arendamise.
2. **Selles katses tugev tulemus** (Claude Sonnet 4.6 + Cowork): kombinatsioon genereeris mahuka ja struktureeritud väljundi (40 lk), valides teemaks TI-põhise lõputöö genereerimise.

3. **Selles katses tugev tulemus, kuid fabritseeritud empiirikaga** (Gemini 3.1 Pro + Antigravity): kombinatsioon genereeris tervikliku ja hästi struktureeritud töö (39 lk) koos veenva, kuid fabritseeritud eksperimendiga, valides teemaks GenAI mõju algajate programmeerijate produktiivsusele.
4. **Liidesesõltuv käitumine** (GPT-5.4): tavapärase ChatGPT vestlusliidese kaudu keeldus mudel ülesannet täitmast akadeemilise aususe põhjendusel ja andis selle asemel 8-leheküljelise ingliskeelse teostatavusjuhendi; ChatGPT Codex laiendusega Visual Studio Code'is genereeris aga sama mudel sama viiega tervikliku 47-leheküljelise eestikeelse dokumendi (vt peatükk 7.5). See erinevus on järgneva arutelu keskne leid ja illustreerib seda, et liidese süsteemijuhised, ohutuspoliitika ja kasutuskontekst mõjutavad väljundit sama mudeli puhul oluliselt.

Eriti tähelepanuväärne on agentsete tööriistade ja liideste mõju tulemusele. Nii Cwork (Opus 4.6 ja Sonnet 4.6 puhul), Google'i Antigravity (Gemini 3.1 Pro puhul) kui ka ChatGPT Codex (GPT-5.4 puhul) andsid oluliselt erineva tulemuse kui puhas vestlusliides – seda kinnitas kõige ilmekamalt GPT-5.4 kahe stsenaariumi vastandlik tulemus. Kõik kombinatsioonid valisid iseseisvalt erineva informaatikateema, mis näitab, kui erinevalt samale lühikesele viipele reageeritakse. Isegi kõige edukamad tulemused (Opus 4.6 + Cwork, GPT-5.4 + Codex ja Gemini 3.1 Pro + Antigravity) vajasis inimese järeltöötlust: viidete kontrolli, terminoloogia ühtlustamise ja fabritseeritud andmete tuvastamise osas. Kuna iga kombinatsiooni kohta tehti vaid üks jook, ei saa ühe jooku põhjal väita, et üks mudel on üldiselt parem kui teine – saab väita üksnes, et selles eksploratiivses katses andis konkreetne mudel-tööriista kombinatsioon konkreetse tulemuse. Genereeritud tööde väljavõtted on esitatud lisas III.

5.7 Kirjavigade analüüs

Eesti keele kvaliteedi täpsemaks hindamiseks vaadati eraldi üle iga genereeritud lõputöö kirjavead – see tähendab ortograafilised näpukad, valed tähed, puuduvad või liigsed tähed, sõnade valed vormid ning pärisnimede vead. Analüüsist jäeti välja kontekstis korrektsed, kuid stiililiselt ebaõnnestunud laused, samuti vead, mis ilmnesid üksnes PDF-ist teksti ekstraheerimise kodeeringuartefaktidena. Tabelis 4 on esitatud kirjavigade koondarv iga töö kohta ning arvestuslik tihedus lehekülje kohta.

Tulemused näitavad nelja mudeli vahel märkimisväärselt erinevust eesti keele ortograafilise täpsuse osas. GPT-5.4 Codex laienduse kaudu genereeritud töös tuvastati kogu 47-leheküljelise

Tabel 4. Genereeritud tervikliku lõputöö kirjavigade koondarv

Mudel	Maht (lk)	Kirjavigade arv	Kirjavigu lk kohta	Hinnang
Gemini 3.1 Pro (Antigravity)	39	28	0,72	Nõrk
Claude Sonnet 4.6 (Cowork)	40	13	0,33	Keskmine
Claude Opus 4.6 (Cowork)	61	5	0,08	Hea
GPT-5.4 (Codex)	47	1	0,02	Väga hea

dokumendi peale vaid üks selge kirjaviga (*vastusevormingun* õige *vastusevormingu* asemel). Claude Opus 4.6 töös esinesid peamised vead pärisnimedes (*Carnegei*, *Californiya*, *kanada* suurtähe puudumine) ning kahes tavasõnas (*juhusiku*, *stsenaariumm*), kokku viis juhtumit 61 lehekülje peale.

Claude Sonnet 4.6 töös leidis ortograafiliselt problemaatilisi sõnu rohkem: alapealkirjas kaks korda esinenud *Masskijutamine* (õige *Masskirjutamine*), lühendite tabelis *märkimisviis*, ning veel mitu üksikut näpukat (*kommertsiaalsed*, *rakenuste*, *kasutusscenaariumide*, *verstapostverstapost*). Osa vigadest asus eriti nähtaval kohal – näiteks alapealkirjas või lühendite tabelis – mis vähendab töö esmamuljet.

Kõige rohkem kirjavigu sisaldas Gemini 3.1 Pro genereeritud töö, kus 39 lehekülje kohta tuvastati 28 selget kirjaviga. Vead jagunesid nelja põhikategooriasse. Levinuima kategooria moodustasid puuduvate või vahetatud tähtedega tavasõnad (*strukuure*, *kordinaadid*, *vektoorruumi*, *konfiktide*, *sepsifiliste*, *paering*, *paringud*, *uenit*, *ekponentvõimendi*, *hariduteadusele*). Teise rühma kuulusid valede tähtedega asendatud täpitähed (*Öleksin* õige *Oleksin* asemel, *Üsaldan* õige *Usaldan* asemel, *Över-Reliance*, *moita*). Kolmandana esinesid moodustatud mittesõnad (*teoosiab*, *esitlustuppu*, *Tehisintsistendi*, *algasestatud*). Neljanda kategooriana paistis silma ingliskeelse konventsiooniga termini *biljonite* kasutamine eesti keeles sobiva *miljardite* asemel. Lisaks esines üks pärisnime viga (*Düning-Krugi* õige *Dunning-Krugi* asemel).

Kirjavigade tihedus korreleerus hästi üldise kvaliteedihinnanguga: kõige madalamat kirjaviga lehekülje kohta näitas GPT-5.4 (agentse tööriista kaudu) ning Claude Opus 4.6. Gemini 3.1 Pro suurem vigade arv viitab, et Antigravity tööriist aitas küll mahtu ja struktuuri parandada, kuid ei suutnud täielikult kompenseerida mudeli nõrgemat eesti keele ortograafiat. See tulemus rõhutab, et automaatse korrektuuri tööriista (nt *aspell*, *hunspell*, *JVKS*) või täiendava keelelise

toimetamise etapp on TI-ga genereeritud tekstide puhul vältimatu – eriti mudelite korral, mille treeningandmetes on eesti keele osakaal väiksem.

5.8 Mahu ja struktuuri analüüs

Lisaks kirjavigadele uuriti iga genereeritud töö mahtu ja sisemist struktuuri. Mahu hindamiseks loeti kokku kogu PDF-failist eraldatud sõnad (sealhulgas tekst, tabelite sisu, lisad ja viited) ning arvutati välja sõnade arv lehekülje kohta. Struktuuri hindamiseks loendati nummerdatud alapeatükkide, tabelite, jooniste ja koodinäidete arv kogu töös. Tulemused on esitatud tabelis 5.

Tabel 5. Genereeritud tööde maht ja struktuurielemendid

Mudel	Lk	Sõnu	Sõnu/lk	Alapt.	Tab.	Joon.
Gemini 3.1 Pro	39	7 230	185	17	2	0
GPT-5.4 (Codex)	47	9 669	206	40	8	2
Claude Sonnet 4.6	40	9 739	243	24	12	2
Claude Opus 4.6	61	10 749	176	25	11	3

Andmetest joonistuvad välja mitmed huvitavad mustrid. Kõige suurema mahu (10 749 sõna) genereeris ootuspäraselt Claude Opus 4.6, mille väljund hõlmas ka kõige rohkem jooniseid (3) ning kompaktselt jaotatud sisu (176 sõna lehekülje kohta – madalaim näitaja, mis tuleneb suuremast hulgast koodinäidetest, tabelitest ja diagrammidest). Claude Sonnet 4.6 paistis silma kõige tihedama tekstilise sisuga (243 sõna lehekülje kohta) ning sisaldas kõige rohkem tabelleid (12). GPT-5.4 (Codex) genereeris kõige granulaarsema struktuuriga töö – 40 alapeatükki 47 lehekülje peale, mis viitab põhjalikule sisujaotusele. Gemini 3.1 Pro maht oli väikseim (7 230 sõna), kõige vähemate alapeatükkidega (17), mis viitab pinnapealsemale käsitlusele.

Eraldi tasub märkida, et Gemini 3.1 Pro töös ei kasutatud ühtegi joonist (ainult tabelleid ja koodinäiteid), mis on bakalaureusetöö kontekstis ebatavaline – enamik tehnilisi lõputöid sisaldab arhitektuuriskeeme või andmevoo diagramme. Sonnet 4.6 ja Gemini 3.1 Pro eelistasid suuremas mahus koodinäidete (Listings) lisamist (vastavalt 7 ja 5 koodinäidet), samas kui Opus 4.6 ja GPT-5.4 integreerisid koodinäited tihedamalt teksti sisse, ilma neid eraldi nummerdatud koodinäidete plokkidena vormistamata.

5.9 Viidete kvantitatiivne analüüs

Akadeemilise töö üks olulisi kvaliteedinäitajaid on viidete kasutamise tihedus ja allikate hulk. Iga töö kohta loeti kokku kasutatud viidete koguarv (kirjanduse loendis esitatud unikaalsed allikad), tekstis tehtud tsitaatide arv ($[N]$ tüüpi viidete esinemiskorrad enne kirjanduse loendit) ning arvutati tsitaatide tihedus lehekülje kohta. Tulemused on esitatud tabelis 6.

Tabel 6. Genereeritud tööde viidete analüüs

Mudel	Unikaalseid viiteid	In-text tsitaate	Tsitaate lk kohta	Tsitaadi/viite suhe
Gemini 3.1 Pro	9	13	0,33	1,44
Claude Sonnet 4.6	17	23	0,58	1,35
GPT-5.4 (Codex)	22	28	0,60	1,27
Claude Opus 4.6	35	45	0,74	1,29

Tulemused näitavad, et Claude Opus 4.6 lisas kõige rohkem viiteid (35 unikaalset allikat ja 45 in-text tsitaati), saavutades ka kõrgeima tsitaaditiheduse 0,74 tsitaati lehekülje kohta. See vastab paroolihalduri valdkonna iseloomule, kus on vaja viidata krüptograafilistele standarditele (NIST, IETF RFC), turvauuringutele ja olemasolevatele lahendustele. GPT-5.4 (22 viidet) ja Claude Sonnet 4.6 (17 viidet) jäid keskmisesse vahemikku. Gemini 3.1 Pro paistis silma väikseima viidete arvuga (9 unikaalset allikat 39 lehekülje peale), mis on bakalaureusetöö kontekstis tagasihoidlik – tüüpilistes arvutiteaduse bakalaureusetöodes on allikate arv sageli kõrgem kui kümme, eriti kirjanduse ülevaadet sisaldavate tööde puhul. See näitaja kinnitab üldist tähelepanekut, et Gemini 3.1 Pro genereeritud töö oli pigem mahukas-fabritseeritud kui allikatega põhjendatud.

Tsitaadi/viite suhe (in-text tsitaate jagatud unikaalsete allikate arvuga) näitab, mitu korda iga allikat keskmiselt korduvalt kasutati. Kõik mudelid jäid 1,27–1,44 vahemikku, mis viitab sellele, et enamikku allikaid kasutati tekstis vaid 1–2 korda. See on bakalaureusetööde puhul tüüpiline näitaja. Oluline on siiski rõhutada, et see analüüs ei hinda viidete *sisulist* korrektsust ega kontrollitavust – osa viidetest olid hallutsineeritud, eriti Sonnet 4.6 (ca 20%) ja Opus 4.6 (ca 15%) töödes.

5.10 Anglitsismid ja eesti keele puhtus

Eestikeelse akadeemilise teksti üks kvaliteedinäitajaid on tõlkimata jäetud või eesti keele konventsioonidest erinevate ingliskeelsete terminite vähene esinemine. Tartu Ülikooli ATI lõputööde juhend [6] rõhutab, et “firmade, toodete ja programmide nimed ei ole terminid” ning võõrkeelsed erialaterminid tuleks esimesel esinemisel tuua koos eestikeelse vaste ja kursiivis originaaliga. Selle põhjal on käesolevas analüüsis oluline eristada kolme erinevat tüüpi ingliskeelseid sõnu:

1. **Vältimatud valdkonnaspetsiifilised tehnilised terminid** – rahvusvaheliselt juurdunud standardi- või spetsifikatsiooniterminid, millel puudub ühtne ja üheselt arusaadav eestikeelne vaste (nt *salt*, *nonce*, *hash*, *token*, *RAG*, *transformer*). Need esinevad ka Eesti arvutiteaduse erialases kirjanduses ning nende säilitamine originaalkujul koos eestikeelse selgitusega on üldiselt aktsepteeritud.
2. **Toote-, firma- ja tehnoloogianimed** – nt *Google*, *Claude Code*, *Cowork*, *Antigravity*, *OWASP*. Juhendi järgi ei ole need sisuliselt terminid ega anglitsismid, vaid pärisnimed ning ülakoma kasutamine käändelõppude eraldamiseks (*Google'i*) on kooskõlas eesti keele konventsiooniga.
3. **Välditavad inglismõjud** – arvutiteaduse ingliskeelsed sõnad, millel on juurdunud eestikeelne vaste ja mis seetõttu on stiilivalikuna tõlgitavad (nt *prompt*, *pipeline*, *benchmark*, *over-reliance*, *feature branch* ilma selgituseta). Need on kitsamas tähenduses “anglitsismid”, mille hulk iseloomustab kõige otsesemalt eestikeelse stiili puhtust.

Käesoleva analüüsi raames loendati esialgselt ülakomaga käändelõppudega vormistatud ingliskeelsed sõnad ja arvutiteaduse tehnilised terminid eristamata, ilma neid kolme kategooriasse süstemaatiliselt jaotamata; tulemused sellisel kujul on esitatud tabelis 7. Analüüsist jäeti välja koodinäited ja kirjanduse loend.

Mõõdiku piirang ja tõlgendus. Tabeli 7 “Anglitsismide/lk” näitaja koondab eeltoodud kolme kategooriat üheks arvuks ning on seetõttu tõlgenduslikult ebatäpne – see karistab ühtmoodi nii välditavaid inglismõjusid kui ka vältimatuid standardtermineid ja pärisnimesid. Praktikas tähendab see, et valdkonnas, kus standardsed terminid on originaalkujul (krüptograafia, standardid, turvalisus), tõuseb mõõdik, kuigi tekst järgib aktsepteeritud akadeemilist konventsiooni. Claude Opus 4.6 + Cowork kombinatsiooni suhteliselt kõrge CS-anglitsismide arv (25) tuleneb suures osas just sellistest vältimatutest terminitest: *salt*, *nonce*, *hash*, *token*, *AES-256-*

Tabel 7. Genereeritud tööde anglitsismide analüüs (kategooriad eristamata)

Mudel+tööriist	Ülakomaga anglitsisme	CS-anglitsisme tekstis	Anglitsisme/lk
Claude Sonnet 4.6 + Cowork	4	1	0,13
GPT-5.4 + Codex	9	11	0,43
Claude Opus 4.6 + Cowork	5	25	0,49
Gemini 3.1 Pro + Antigravity	7	22	0,74

GCM, Argon2id on IETF/NIST standardites kinnistunud ega oma üheseid eestikeelseid vasteid, mida paroolihalduri kontekstis kasutatakse. Claude Sonnet 4.6 + Cowork TI-teema vältis seda probleemi osaliselt, kuna selle valdkonna terminoloogias on eesti keeles juba mitmeid kinnistunud vasteid. Gemini 3.1 Pro + Antigravity kasutab anglitsisme kõige rohkem (0,74/lk), sealhulgas paralleelselt nii eesti- kui ingliskeelseid vasteid (näiteks *äärejuht* (*ingl. edge case*)). Täpsem kolmekategooriline loendus, mis eristaks välditavaid inglismõjusid vältimatutest terminitest ja pärisnimedest, annaks täpsema pildi ja on edasiste uurimuste oluline meetodiline täiendus; käesoleva töö tulemusi tuleks tõlgendada seda piirangut arvestades.

5.11 Akadeemilise stiili indikaatorid

Eestikeelses akadeemilises kirjutamises eelistatakse umbisikulist stiili (passiivi ja umbisikulist tegumoodi) ning välditakse esimese isiku ainsuse (*ma, mina*) ja mitmuse (*me, meie*) kasutamist. Iga genereeritud töö puhul loendati esimese isiku asesõnade (*ma, mina, me, meie, meil, meid, minu*) esinemine peamises tekstis (välja arvatud litsents ja autorluse kinnitus). Tulemused on esitatud tabelis 8.

Tabel 8. Esimese isiku asesõnade kasutus genereeritud töödes

Mudel	Esimese isiku asesõnu	Hinnang
Claude Opus 4.6	0	Suurepärase
GPT-5.4 (Codex)	2	Suurepärase
Claude Sonnet 4.6	2	Suurepärase
Gemini 3.1 Pro	4	Hea

Kõik neli mudelit järgisid eestikeelset akadeemilist stiili väga hästi: esimese isiku asesõnu kasutati minimaalselt (0–4 esinemist kogu töö peale). Claude Opus 4.6 ei kasutanud ühtegi esimese isiku asesõna terve 61-leheküljelise töö peale, mis on ideaalne tulemus. Gemini 3.1 Pro neli esinemist on samuti vastuvõetav, kuid mõnevõrra kõrgem teistest. See näitab, et tänapäevased suured keelemudelid on eesti akadeemilise stiili konventsioonid hästi õppinud, mis on kooskõlas peatükis 6.1 esitatud üldise hinnanguga TI mudelite akadeemilise stiili oskusele.

5.12 Hinnangu stabiilsus ja subjektiivsus

Kuna hindamise viis läbi üks hindaja (autor), ei olnud võimalik mõõta hindajatevahelist kooskõla. Subjektiivsuse vähendamiseks tugineti võimalikult palju kvantitatiivselt mõõdetavatele tunnustele (kirjavigade arv, lehekülgede ja sõnade arv, viidete arv, anglitsismide arv, esimese isiku asesõnade arv), mille korral ühe hindaja otsustusruum on piiratud ja mille tulemused on põhimõtteliselt reprodutseeritavad. Kvalitatiivsete hinnangute osas (näiteks teksti sisuline sügavus ja akadeemiline stiil) vaatas autor iga teksti läbi mitmel korral eri aegadel. Ühe hindajaga uurimisülesehituse piiranguid on käsitletud peatükis 6.

6. Arutelu

Käesolev peatükk arutleb eksperimendi tulemuste üle laiemas kontekstis, käsitleb TI kasutamise praktilisi aspekte, piiranguid ja annab soovitusi.

6.1 TI tugevused lõputöö kirjutamisel

Eksperimendi tulemused kinnitavad, et kaasaegsed TI mudelid koos agentsete tööriistadega suudavad pakkuda märkimisväärset abi lõputöö kirjutamise protsessis. Selle katse jooksul demonstreeris Claude Opus 4.6 + Cowork kombinatsioon eriti veenvalt, et tiptasemel mudel koos agentse tööriistaga suudab genereerida tervikliku 61-leheküljelise eestikeelse lõputöö ka ühe kasutajaviibega ilma iteratiivse suunamiseta. Peamised tugevused jagunevad järgmiselt.

Struktureerimine ja kavandamine. TI mudelid on eriti tugevad teksti struktureerimisel. Kõik neli testitud kombinatsiooni (arvestades GPT-5.4 Codex-laienduse kaudu saadud tulemust) suutsid luua loogilise ja akadeemilistele nõuetele vastava peatükkide jaotuse ainuüksi ühe kasutajaviibega. Eriti kasulik on TI kasutamine töö algfaasis, kui üliõpilane vajab abi sisukorra ja peatükkide ülesehituse kavandamisel. Mudelid suudavad vaid minimaalse juhise põhjal luua detailse sisukorra koos soovitusliku leheküljemahuga iga peatüki jaoks.

Mustandi loomine. TI suudab genereerida tekstimustandeid, mis on piisavalt hea kvaliteediga, et neid edasi töödelda. See kiirendab kirjutamisprotsessi oluliselt, kuna üliõpilane ei pea alustama tühjalt lehelt, vaid saab toimetada ja täiendada olemasolevat teksti. Esialgse kasutuskogemuse põhjal võib TI mustandi kasutamine säästa hinnanguliselt 50–80% kirjutamisele kuluvast ajast, kuigi täpse ajavõidu mõõtmine vajab edaspidi süstemaatilisi kasutajakatseid.

Keeleline toimetamine. Kõik neli mudelit suudavad efektiivselt teostada keelelist toimetamist – parandada grammatikavigu, parandada lauseehitust ja ühtlustada stiili. See on eriti väärtuslik eesti keele kontekstis, kus spetsiifilisi akadeemilise toimetamise teenuseid on vähe.

LaTeX-vormindamine. Oluline praktiline eelis on mudelite võimekus genereerida teksti otse LaTeX-vormingus, mis hõlmab korrektset viitamissüntaksit, tabeleid, jooniste viiteid ja matemaatilisi valemeid. See säästab üliõpilasele märkimisväärset vormistusaega. Võrdluseks, Microsoft Wordi puhul peab üliõpilane vormistuse – stiilid, ristviited, pealkirjade numeratsioon ja bibliograafia – enamasti käsitsi seadistama, kuna TI mudelid ei saa .docx faili sisemist struktuuri samamoodi manipuleerida nagu tekstipõhist L^AT_EX lähtekoodi. See teeb Wordi TI-toetatud akadeemilise kirjutamise kontekstis oluliselt aeganõudvamaks ja veaohhtikumaks valikuks.

6.2 TI puudujäägid ja piirangud

Vaatamata edusammudele on TI mudelitel lõputöö kirjutamise kontekstis endiselt olulised puudujäägid. Järgnevate puuduste loetelu kõrval tuleb rõhutada kahte käesoleva uurimuse metoodilist piirangut, mis mõjutavad tulemuste tõlgendust. Esimene on see, et eksperimendis võrreldi tegelikult *mudeli ja agentse tööriista kombinatsioone*, mitte mudeleid iseenesest; erinevused tulemustes võivad olla tingitud mitte ainult mudeli võimekusest, vaid ka liidese süsteemijuhistest, ohutuspoliitikast, faililigipääsust ja agentse töövoogu ülesehitusest. Teine piirang on see, et iga kombinatsiooni kohta tehti vaid üks jook. Keelemudelid on mitteterministlikud ning agentsed tööriistad võivad samast viipest anda eri jooksudel erinevaid tulemusi (näiteks valida teise teema, teise keele, erineva mahuga teksti). Seetõttu ei saa ühe jooksu põhjal tugevalt väita, et üks mudel on üldiselt parem kui teine – saab üksnes väita, et selles eksploratiivses katses andis konkreetne mudel-tööriista kombinatsioon konkreetse tulemuse. Süstemaatiline hinnang nõuaks iga kombinatsiooni kohta vähemalt mitut kordusjooksu ning suuremat valimit; see on käesoleva töö edasise uurimistöö üks olulisemaid soovitusi.

Viidete usaldusväärsus. Kõige tõsisem probleem on viidete hallutsineerimine. Kõigi mudelite genereeritud lõputöös esines olematuid allikaid. Gemini 3.1 Pro hallutsineeris viiteid ca 25% juhtudest, GPT-5.4 ca 20%, Claude Sonnet 4.6 ca 20% ja Claude Opus 4.6 ca 15% juhtudest. Kuigi Opus 4.6 näitas madalaimat hallutsinatsioonimäära, on ka 15% liiga kõrge akadeemilise teksti jaoks. Need tulemused on kooskõlas varasemate uurimustega. Chelli et al. [30] tuvastasid GPT-4 hallutsinatsioonimääraks 28,6%, mis on lähedane meie GPT-5.4 tulemusele. See viitab sellele, et vaatamata mudelite arengule pole viidete hallutsineerimise probleem täielikult lahendatud. Mugaanyi et al. [29] leidsid samuti, et DOI-de täpsus on valdkonniti väga erinev (loodusteadustes 32,7% vs humanitaarteadustes 8,5%), mis viitab sellele, et arvutiteaduse valdkonnas võivad tulemused olla mõnevõrra paremad. Kim et al. [31] on näidanud, et hallutsinatsioonid on eriti levinud väiksemate keelte ja madalama sissetulekuga riikide kontekstis, mis on asjakohane ka eesti keele puhul. See tähendab, et iga TI-genereeritud viide tuleb inimese poolt kontrollida. Viidete automaatne genereerimine on hetkel ebapiisava kvaliteediga ja üliõpilane peab ise allikaid otsima ning viiteid kontrollima.

Sisuline sügavus. TI-genereeritud tekstid kipuvad olema pealiskaudsed. Mudelid kordavad üldtuntud seisukohti, kuid ei suuda luua originaalset analüüsi ega teha uudseid järeldusi. See on eriti problemaatiline tulemuste arutelu puhul, kus eeldatakse, et autor demonstreerib kriitilist mõtlemist ja seob tulemused laiemas kontekstis kokku.

Eesti keele tehniline terminoloogia. Kuigi mudelite eesti keele oskus on oluliselt paranenud, esineb endiselt probleeme tehnilise terminoloogiaga. Mudelid kasutavad kohati ebaühtlast terminoloogiat (vahetavad eesti- ja ingliskeelsete terminite vahel) ning mõnikord loovad valesid termineid. Näiteks genereeriti juurdunud termini “süvaõpe” asemel “süvaõppimine” või kasutati sõna “treenima” asemel “koolitama”, mis ei vasta arvutiteaduse valdkonnas juurdunud eesti keelsele terminoloogiale. Barbu et al. [41] on samuti täheldanud, et keelemudelid vajavad eesti keele spetsiifika jaoks täiendavat kohandamist, mis viitab laiemale probleemile väikeste keelte tehnilistel kasutusjuhtudel.

Kontekstiakna piirangud. Kuigi kontekstiaknad on oluliselt suurenenud, on need endiselt piiratud. 25-leheküljelise bakalaureusetöö tekst (ca 80 000–100 000 tähemärki ehk ca 40 000–50 000 tokenit) mahub küll kontekstiaknasse, kuid kui lisada juhendid, näidistööd ja varasemalt genereeritud osad, on kontekstiakna efektiivne kasutamine endiselt kriitiline.

Juhiste järgimise ebaühtlus ning liidese ja agentsete tööriistade mõju. Eksperiment (tervikliku lõputöö genereerimine ühe kasutajaviibega) tõi esile neli fundamentaalselt erinevat kombinatsioonikäitumist, mis väärivad eraldi arutelu. GPT-5.4 keeldumine ChatGPT vestlusliideses terviklikku tööd kirjutamast ja inglise keelele üleminek viitab sellele, et vestlusliidese süsteemijuhised ja ohutuspoliitika tõlgendavad sellist ülesannet akadeemilise aususe piirangu alla kuuluvana. Bianchi et al. [37] on kirjeldanud sarnast nähtust kui “liialdatud ohutuskäitumist” (*exaggerated safety behaviour*), kus mudelid keelduvad täiesti ohututest ülesannetest, mis pealiskaudselt sarnanevad ohtlikele. See on arendaja seisukohast vastutustundlik, kuid praktikas piirav – liides ei pruugi eristada uurimuslikku eesmärki (kus TI-genereeritud tekst on uurimisobjekt) isiklikust akadeemilisest petmisest. Täiendav katse ChatGPT Codex laiendusega Visual Studio Code’is (vt peatükk 7.5) näitas, et sama mudeli käitumine oli teises liideses sisuliselt erinev – GPT-5.4 genereeris Codex-laiendusega tervikliku, teiste kombinatsioonide väljunditega visuaalselt sarnase dokumendi. Selle kontrasti kõige loomulikum seletus ei ole, et agentne tööriist “ületab” ohutuspiirangud, vaid et liides muudab ülesande konteksti ja tööjaotust: töö toimub arenduskeskkonnas, ülesanne jaotub väiksemateks faili- ja kompileerimispõhisteks sammudeks ning kehtivad teised süsteemijuhised. Seega ei paranda agentsed tööriistad mitte ainult genereerimise kvaliteeti, vaid kujundavad oluliselt ka käitumist ülesande täitmisel. Oluline on, et seda leidu ei tõlgendataks kui õpetust, kuidas ohutuskoolitusest mööda minna – see on pigem märk sellest, et “keelemudeli käitumine” on tegelikult mudeli, liidese, süsteemijuhiste ja ohutuspoliitika koosmõju.

Gemini 3.1 Pro + Antigravity kombinatsioon genereeris 39-leheküljelise töö, mis oli struktuuralselt ja vormiliselt veenev, kuid sisaldas täielikult väljamõeldud eksperimenti – kombinatsioon fabritseeris 30 tudengiga kvantitatiivse uuringu koos statistiliste testide, koodinäidete ja andmebaasiskeemidega ning kasutas Eesti ettevõtete nimesid ilma nende tegeliku osaluseta. See ei ole lihtsalt kvaliteedipuudus, vaid akadeemilise väärkasutuse kõrge riskiga juhtum: mudel lõi veenva empiirilise uuringu, mida tegelikult ei toimunud, ning lugeja, kes andmeid ei kontrolli, saab tõestuspõhise väljanägemisega, kuid tegelikkuses olematu uurimuse. Kogemata võidakse selline väljund kaitsmisele esitada kui päris empiiriline töö, mis oleks selge akadeemilise aususe rikkumine. Ilma agentse tööriistata olid autori varasemad mitteametlikud katsed Geminiga oluliselt nõrgemad. Claude Sonnet 4.6 + Cowork kombinatsiooni edukas toimetulek tervikliku töö genereerimisel osutab kombinatsiooni tugevusele struktureeritud juhiste järgimisel. Claude Opus 4.6 + Cowork kombinatsioon tootis selles katses veel mahukama ja tehniliselt sügavama lõputöö, mis viitab sellele, et suurema mudeli ja Cowork'i koosmõju andis praktikas parema tulemuse.

Hindamismetoodika piirangud. Oluline piirang käesolevas uurimuses on asjaolu, et hindamise viis läbi ainult üks hindaja (töö autor). See tähendab, et hindajatevahelise kooskõla mõõtmine ei olnud võimalik ja subjektiivsus on paratamatult suurem kui mitme sõltumatu hindaja kaasamisel. Subjektiivsuse vähendamiseks kasutati iga teksti korduvat hindamist eri aegadel, kuid see ei asenda sõltumatuid hindajaid. Eriti subjektiivsetes kriteeriumides (akadeemiline stiil, praktiline väärtus) võivad ühe hindaja hinnangud kalduda süstemaatiliselt ühes suunas. Edaspidistes uurimustes tuleks tulemuste kinnitamiseks kaasata mitu sõltumatut hindajat, sealhulgas valdkonna õppejõud ja teised üliõpilased.

6.3 Hinnakujundus ja majanduslik teostatavus

Tabelis 9 on esitatud hinnanguline kuluarvestus 25-leheküljelise bakalaureusetöö genereerimiseks iga mudeliga.

Hinnad on esitatud USA dollarites vastavalt mudelite pakkujate 2026. aasta märtsi ametlikele hinnakirjadele [36, 38, 39]; euros väljendatuna on summad sõltuvad kasutatavast valuutakursist.

Alternatiivina saab kasutada kuutellimusi: ChatGPT Plus ja Claude Pro mõlemad maksavad \$20/kuu, Google AI Studio tasuta versioon võimaldab piiratud kasutust. Praktikas tähendab see, et üliõpilane saab 1–2 kuu tellimuse hinnaga (ca \$20–40) teostada põhilised genereerimiskatsetused, eeldusel et mahupiiranguid ei ületata.

Tabel 9. Bakalaureusetöö genereerimise hinnanguline kuluarvestus

Kulukomponent	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Sisendtokenid (ca 2M)	\$4,00–8,00	\$5,00	\$6,00	\$30,00
Väljundtokenid (ca 300K)	\$3,60–5,40	\$4,50	\$4,50	\$22,50
Agentse tööriista sisend/väljundkorrad	mitmekordne	mitmekordne	mitmekordne	mitmekordne
Eeldatav hind	\$23–38	\$25–32	\$32–42	\$160–220

Kokkuvõttes on TI kasutamise majanduslik kulu lõputöö kirjutamisel Sonnet-klassi mudelitega mõistlik – \$23–42 API kaudu või \$20–40 kuutellimuse kaudu. Claude Opus 4.6 on oluliselt kallim (\$160–220 API kaudu), kuid Claude Max tellimus (\$100–200/kuu) võimaldab piiratud kasutust. Sonnet-klassi mudelid on endiselt oluliselt odavamad kui professionaalse toimetaja teenus, mis võib bakalaureusetöö puhul maksta mitusada eurot.

6.4 Eesti keele korrektuur ja toimetamine

Eraldi väärrib tähelepanu TI mudelite kasutamine eestikeelse teksti korrektuuri ja toimetamise tööriistana. See on üks valdkondi, kus TI pakub kõige suuremat praktilist väärtust.

Järgmised hinnangud põhinevad autori mitteformaalsetel katsetel, mis jäid peaeksperimenti raamistikust välja ning mille täpsem metoodika vajab edaspidi süstemaatilist vormistamist. Need on esitatud suunavate tähelepanekutena.

Grammatikakontroll. Kõik neli mudelit suudavad tuvastada ja parandada enamiku grammatikavigadest eesti keeles. Claude Opus 4.6 oli kõige täpsem, tuvastades enamiku sisestatud vigadest; Sonnet 4.6 ja GPT-5.4 tuvastasid enamiku, kuid jätsid osa keerulisemaid vigu märkamata; Gemini 3.1 Pro tulemus oli nõrgim, jättes tuvastamata ka lihtsamaid morfoloogiavigu.

Stiilikontroll. Mudelid suudavad hinnata teksti vastavust akadeemilisele stiilile ja pakkuda parandusettepanekuid. See hõlmab liiga vaba keele tuvastamist, passiivi kasutamise soovitusi ja liigsete korduste märkamist. Claude Sonnet 4.6 oli selles osas kõige põhjalikum, pakkudes detailsemaid selgitusi paranduste kohta.

Terminoloogiakontroll. Mudelid suudavad kontrollida tehnilise terminoloogia ühtlust ja korrektsust, kuid siin on täpsus oluliselt madalam kui grammatikakontrollis. Terminoloogilist kontrolli ei saa täielikult TI-le delegeerida ja valdkonnaspetsiifiline inimekspertis on endiselt vajalik.

Soovitus. TI-põhine korrektuur on kõige efektiivsem, kui seda kasutatakse kahes etapis:

1. Esmalt laseb üliõpilane TI-l teksti üle vaadata ja parandusettepanekud teha;
2. Seejärel vaatab üliõpilane parandused üle ja otsustab, millised neist aktsepteerida;
3. Lõpuks saab üliõpilane teha käsitsi täiendavaid parandusi, mida TI ei tuvastanud ja vajadusel alustada esimesest punktist uuesti.

Sellist kolmeetapilist protsessi kasutades saab oluliselt parandada teksti keelelist kvaliteeti, ilma et tekiks oht TI soovitude pimesi järgimiseks.

6.5 Soovitused TI tööriista valikuks

Eksperimendi tulemuste ja praktiliste kogemuste põhjal saab anda järgmised soovitused.

Selle katse kõrgeim kvaliteet: Claude Opus 4.6 koos Cowork'iga. Käesolev eksperiment näitas, et Claude Opus 4.6 + Cowork kombinatsioon (Cowork on sama ettevõtte Claude Code'ist eraldiseisev toode) saavutas selles katses kõrgeima kvaliteedi eestikeelse akadeemilise teksti genereerimisel. Kombinatsioon ületas teisi keelelise korrektsuse, akadeemilise stiili ja sisulise sügavuse poolest. Peamine puudus on oluliselt kõrgem hind. Kuna iga kombinatsiooni kohta tehti vaid üks jook ja keelemudelid on mitteterministlikud, tuleb seda soovitus võtta eksploratiivse viitena, mitte lõpliku kvaliteedipingerea kinnitusena.

Parim hinna-kvaliteedi suhe: Claude Sonnet 4.6 koos Cowork'iga. Claude Sonnet 4.6 + Cowork kombinatsioon on kõige sobivam valik piiratud eelarvega üliõpilase jaoks. Kombinatsioon paistis silma akadeemilise stiili, juhiste järgimise ja teksti struktureerimise poolest ning on oluliselt soodsam kui Opus. Pikendatud mõtlemisrežiim parandab keerulisemate peatükkide kvaliteeti.

Lühikeste lõikude jaoks: GPT-5.4. GPT-5.4 sobib hästi lühikeste tekstilõikude genereerimiseks ja keelelise korrektuuri jaoks. Kui soov on genereerida tervikdokumenti, siis ChatGPT vestlusliidese süsteemijuhised ja ohutuspoliitika võivad selle blokeerida või suunata ingliskeelsele väljundile, samas kui ChatGPT Codex laiendus Visual Studio Code'is andis

käesolevas katses sama viipega tervikliku eestikeelse dokumendi (vt peatükk 7.5). ChatGPT Plus tellimus (\$20/kuu) on majanduslikult mõistlik ja katab ka Codex laienduse kasutuse.

Ideaalne töövoog. Käesoleva töö kogemus näitab, et kõige parema tulemuse andis Cowork'i agentne tööriist koos Opus või Sonnet mudeliga.

6.6 Tööriistad, mida vältida

Lisaks peaksperimendis osalenud nelja mudeli võrdlusele testis autor lühemate mitteformaalsete katsete raames ka mõnda teist tööriista, mida lõputöö kirjutamise abivahendina ei saa soovitada, vaatamata nende laialdasele kättesaadavusele üliõpilastele. Järgmised hinnangud ei põhine käesoleva uurimuse formaalsel võrdlusel, vaid autori praktilisel kasutuskogemusel ning nende arendajate avalikul dokumentatsioonil.

Perplexity ei sobi mahukate ülesannete jaoks. Perplexity on TI-põhine otsingumootor, mis pakub juurdepääsu erinevatele mudelitele (sh Claude, GPT ja teised). Kuigi Perplexity sobib hästi üksikute küsimuste esitamiseks ja lühikeste vastuste saamiseks, ilmnes testimisel oluline puudus: kõikidel mudelitel on Perplexity kaudu kasutades oluliselt väiksem kontekstiaken kui otse API või vestlusliidese kaudu. Perplexity veebi- ja mobiilirakenduses on otsese sisendi piiranguks vaikimisi ca 8 000 tokenit päringu kohta [42], mis on oluliselt vähem kui samade mudelite natiivsed kontekstiaknad (nt Claude'i 200K või Gemini 1M tokenit). See tähendab, et eraldi lühikeste promptidena saab küll normaalselt töötada. Mahukamate tekstide genereerimisel või pikema vestluse konteksti hoidmisel (nt tervikliku peatüki kirjutamine koos eelnevate osade kontekstiga) jääb kontekstiaknast aga puudu. Lisaks on täheldatud, et pikema konteksti puhul hakkab Perplexity varasemaid vestluse osi kärpima või kompressseerima, mille tagajärjel vastused lakkavad viitamast varem kokkulepitud tingimustele ja piirangutele [42]. Seetõttu ei sobi Perplexity lõputöö genereerimise tööriistaks, kus on vajalik suur ja järjepidev kontekst.

GitHub Copilot Pro ei sobi akadeemilise teksti genereerimiseks. GitHub Copilot Pro, mida Tartu Ülikool pakub üliõpilastele tasuta GitHub Education programmi kaudu, on mõeldud eelkõige koodi kirjutamise abivahendiks [43]. GitHubi enda dokumentatsiooni kohaselt on Copilot Chat mõeldud ainult kodeerimisega seotud päringutele ning juhiste piiramine kodeerimisülesannetega parandab mudeli väljundi kvaliteeti [44]. Lõputöö genereerimise kontekstis osutus see aga ebapiisavaks. Copilot'i mudelid tundusid oluliselt "laisemad" – nad kippusid andma lühikesi, pealiskaudseid vastuseid ja vältisid pikemate akadeemiliste tekstilõikude genereerimist. Nguyen ja Nadi [45] on oma empiirilises uurimuses näidanud, et

Copilot'i soovitusel on tähemärkide pikkuse piirang, mis takistab pikema väljundi genereerimist, ning keerulisemate ülesannete korral langeb soovitude kvaliteet märgatavalt. Lisaks rakendab GitHub Copilot'ile päringupõhiseid limiite (*rate limits*), mis piiravad kasutamise intensiivsust [46]. Kokkuvõttes on tööriist optimeeritud lühikeste koodilõikude ja kooditäienduste jaoks, mitte terviklike akadeemiliste tekstide loomiseks. Seetõttu ei saa GitHub Copilot Pro-d soovitada lõputöö kirjutamise abivahendina, vaatamata sellele, et see on üliõpilastele tasuta kättesaadav.

6.7 Eetilised kaalutlused ja akadeemiline ausus

TI kasutamine lõputöö kirjutamisel tõstatab olulisi eetilisi küsimusi. Tartu Ülikooli akadeemilise aususe reeglid [6] nõuavad, et üliõpilane:

- deklareerib kõik TI vahendid, mida ta kasutab;
- märgib, millises töö osas ja millises ulatuses TI-d kasutati;
- tagab, et töö peegeldab tema isiklikku akadeemilist arengut ja analüütilist mõtlemist.

Rodafinos [8] rõhutab, et ülikoolid peaksid TI kasutamise keelustamise asemel lõimima TI-kirjaoskuse õppekavadesse ja kehtestama selged eetilise kasutamise poliitikad. Lund et al. [7] leidsid, et tudengid ei käsitle TI kasutamist kirjutamisel tavalise plagiaadi laiendusena, vaid eraldiseisva akadeemilise käitumise kategooriana, mis nõuab eraldi eetilist raamistikku.

On oluline rõhutada, et käesolev töö ei propageeri lõputöö TI abil “kirjutamist”, vaid uurib TI kasutamist *abivahendina* kirjutamisprotsessis. Nii nagu õigekirjakontroll ei kirjuta teksti üliõpilase eest, ei tohiks ka TI-põhine tekstigenerereerimine asendada üliõpilase isiklikku panust. TI-d tuleks käsitleda kui tööriista, mis aitab struktureerida mõtteid, luua mustandeid ja parandada keelekasutust.

6.8 Tulevikuväljavaated

TI mudelite areng on kiire ja käesoleva töö tulemused peegeldavad 2025–2026. aasta seisuga. Lähitulevikus on oodata järgmisi arenguid:

- **Eesti keele kvaliteedi paranemine** – uuemate mudelite (nt oodatav GPT-6, Gemini 4.0) treeningandmetes on eesti keele osakaal tõenäoliselt suurem, mis parandab keelelist kvaliteeti. EstLLM projekti [5] tulemused näitavad, et spetsialiseeritud jätkutreenimine võib eesti keele kvaliteeti märkimisväärselt tõsta ka olemasolevates mudelites.

- **Agentsed akadeemilised tööriistad** – Claude Code'i, Cowork'i, Google'i Antigravity ja OpenAI ChatGPT Codex laienduse laadsed agentsed tööriistad, mis suudavad iseseisvalt faile hallata, kompileerida ja projekti struktureerida, muutuvad tõenäoliselt akadeemilise kirjutamise standardtööriistadeks. Meie eksperiment kinnitas, et agentne töövoog parandab oluliselt genereerimise kvaliteeti kõigi testitud mudelite puhul – nii Opus 4.6 ja Sonnet 4.6 (Cowork), Gemini 3.1 Pro (Antigravity) kui ka GPT-5.4 (Codex) puhul.
- **Viidete kvaliteedi paranemine** – RAG (Retrieval-Augmented Generation) süsteemide areng peaks parandama viidete täpsust ja vähendama hallutsinatsioone. Kresevic et al. [47] on näidanud, et RAG-raamistik koos struktureeritud konteksti ja promptide disainiga parandas GPT-4 Turbo täpsust 43%-lt 99%-le, mis demonstreerib selle lähenemise potentsiaali ka akadeemilises kontekstis. Ji et al. [40] leidsid, et ahelapõhjamise (*chain-of-thought*) kasutamine parandas oluliselt viidete kvaliteeti teksti genereerimisel.
- **Kontekstiakende suurenemine** – kontekstiaknad kasvavad jätkuvalt, mis võimaldab mudelitele sisestada üha rohkem infot korraga.
- **Spetsialiseeritud akadeemilised mudelid** – lähiaastatel on tõenäoline spetsiaalselt akadeemiliseks kirjutamiseks kohandatud mudelite (nt eesti keelele ja Tartu Ülikooli stiilile peenhäälestatud variandid) ilmumine, mis võiksid ühendada üldmudelite võimekuse valdkonnaspetsiifiliste teadmistega ning vähendada hallutsinatsioonide osakaalu.
- **TI-genereeritud sisu tuvastamine ja integreerimine õppekavasse** – ülikoolide ja kirjastuste poolt kasutusele võetavad TI-detekteerimise tööriistad arenevad paralleelselt genereerimistööriistadega, samas kui akadeemilised institutsioonid liiguvad TI keelustamiselt selle läbipaistva integreerimise suunas. See nõuab uusi hindamismetoodikaid, mis keskenduvad üliõpilase sisulisele panusele ja mõtteprotsessile, mitte ainult lõpptulemusele.
- **Multimodaalsed võimed akadeemilises tekstis** – tulevased mudelid suudavad tõenäoliselt genereerida mitte ainult teksti, vaid ka akadeemiliselt kvaliteetseid jooniseid, diagramme ja visualiseerimisi otse L^AT_EX-ühilduvas vormingus (nt TikZ või PGFPlots koodi), mis vähendab hetkel veel märkimisväärtet käsitsitööd jooniste loomisel.

Käesolev uurimus piirdus neljast mudelist ja kolmest agentsest tööriistast koosneva võrdlusega 2025–2026. aasta seisuga. Arvestades TI valdkonna arengutempot, kus uusi mudeleid avaldatakse mitu korda aastas, tuleks sarnaseid teostatavusuuringuid korrata regulaarselt, et hinnata, kuidas

ülnimetatud arengud tegelikult realiseeruvad ja millised käesoleva töö järeldest jäävad kehtima ka uuema põlvkonna mudelite puhul.

7. Agentsed TI tööriistad lõputöö genereerimisel

Käesolev peatükk kirjeldab Claude Code'i kui agentset TI tööriista, mis võimaldab terviklike akadeemiliste tööde genereerimist otse arenduskeskkonnas. Peatükk annab ülevaate tööriista arhitektuurist, töövoogudest ning esitab praktilised soovitused lõputöö genereerimiseks. Lisaks esitatakse juhtumiuuring Opus 4.6 mudeliga, milles kasutati Anthropicu teist agentset tööriista Cowork, mis on Claude Code'iga sarnase ülesehituse ja töövoogudega, kuid neist eraldiseisev toode.

7.1 Claude Code'i ülevaade

Claude Code on Anthropicu arendatud agentne kodeerimis- ja tekstiloomise tööriist, mis töötab Claude'i äpi kaudu või käsurealiidese (CLI) kaudu ning integreerub otse arenduskeskkondadesse nagu Visual Studio Code [16]. Erinevalt tavalistest vestlusliidese-põhistest TI tööriistadest (nt ChatGPT veebiliides, Claude.ai) pakub Claude Code agentset töövoogu: tööriist saab iseseisvalt lugeda ja kirjutada faile, käivitada käsurea käske, otsida veebist informatsiooni ning hallata projekti failisüsteemi. Claude Code'i peamised eelised akadeemilise teksti genereerimisel:

- **Otsene failisüsteemi juurdepääs** – tööriist saab lugeda olemasolevaid $\text{\LaTeX}$ faile, juhendeid ja näidistöid otse failisüsteemist, ilma et kasutaja peaks neid käsitsi kopeerima vestlusaknasse.
- **Iteratiivne genereerimine** – tööriist saab genereerida teksti, kontrollida tulemust ja teha parandusi mitme iteratsiooni jooksul ühe sessiooni raames.
- **$\text{\LaTeX}$ kompileerimine** – tööriist saab käivitada $\text{\LaTeX}$ kompileerimist ja kontrollida, kas genereeritud kood kompileerub vigadeta.
- **Viidete haldamine** – tööriist saab hallata BibTeX/BibLaTeX viidete faile, lisada uusi viiteid ja kontrollida viidete formaadi korrektsust.

7.2 Claude Code'i võrdlus tavapärase vestlusliidesega

Tabelis 10 on esitatud võrdlus Claude Code'i ja tavapärase vestlusliidese (nt Claude.ai, ChatGPT) vahel lõputöö genereerimise kontekstis.

7.3 Soovitused lõputöö genereerimiseks Claude Code'iga

Käesoleva uurimuse praktiliste kogemuste põhjal, sealhulgas Opus 4.6 mudeliga Cowork'i kaudu genereeritud paroolihalduri lõputöö (vt peatükk 7.7), saab anda järgmised soovitused

Tabel 10. Claude Code'i võrdlus tavapärase vestlusliidesega lõputöö genereerimisel

Aspekt	Vestlusliides	Claude Code
Konteksti sisestamine	Käsitsi kopeerimine	Automaatne failide lugemine
Väljundi salvestamine	Käsitsi kopeerimine	Otsene faili kirjutamine
L ^A T _E X kontroll	Puudub	Automaatne kompileerimine
Viidete haldus	Käsitsi	Automaatne BibTeX haldus
Mitme faili töötlemine	Viis faili korraga	Kõik failid korraga
Iteratsiooni kiirus	Aeglane (kopeeri-kleebi)	Kiire (automaatne)
Projekti struktuur	Kasutaja haldab	Tööriist haldab

Claude Code'i kasutamiseks lõputöö genereerimisel. Samad soovitusel kehtivad suures osas ka Cowork'i kohta, kuna tööriistad on ülesehituselt sarnased.

7.3.1 Projekti ettevalmistamine

1. **Kasuta L^AT_EX malli algusest peale.** Paigalda ülikooli L^AT_EX mall (nt UniTartuCS) projektikausta enne genereerimise alustamist. Claude Code suudab malli struktuuri automaatselt tuvastada ja järgida.
2. **Lisa juhendid projektikausta.** Kopeeri lõputöö juhendid (TÜ ATI juhend, LOTE juhend) tekstifailidena projektikausta. Claude Code saab neid automaatselt lugeda kontekstina.
3. **Lisa näidistööd.** Paiguta 2–3 hästi hinnatud varasema lõputöö PDF-failid projektikausta. Need annavad mudelile konkreetse ettekujutuse oodatavast kvaliteedist ja stiilist.
4. **Loo CLAUDE.md konfiguratsioonifail.** Projekti juurkausta loodav CLAUDE.md fail sisaldab püsivaid juhiseid, mida Claude Code järgib igas sessioonis. Sinna tasub kirjutada:
 - oodatav keel (eesti keel);
 - akadeemiline stiil ja toon;
 - terminoloogia eelistused;
 - viitamisstiil (nt IEEE numeric);
 - peatükkide struktuur ja maht.

7.3.2 Genereerimise töövoog

Soovitame järgmist samm-sammulist töövoogu:

1. **Genereeri sisukord ja struktuur.** Alusta sisukorra ja peatükkide ülesehituse genereerimisega. Anna mudelile ette teema, uurimisküsimused ja mahunõuded. Kontrolli ja kinnita struktuur enne edasi liikumist.
2. **Genereeri peatükid järjest.** Genereeri iga peatükk eraldi, alustades sissejuhatusest. Iga järgmise peatüki genereerimisel on eelnevad peatükid kontekstis, mis tagab sidususe.
3. **Genereeri tabelid ja joonised eraldi.** Tabelite ja jooniste $\text{\LaTeX}$ kood on keerulisem ja vajab eraldi tähelepanu. Genereeri need eraldi sammuna ja kontrolli visuaalset tulemust.
4. **Lisa viited ise või tee põhjalikku kontrolli neile.** Ära lase mudelil viiteid “välja mõelda”. Kui soovid, et viited oleksid väga tõenäoliselt korrektsed, siis järgi seda malli:
 - otsi ise allikaid;
 - lisa leitud allikate andmed BibTeX faili;
 - palu mudelil viiteid tekstis kasutada ainult olemasolevatest allikatest.
5. **Kompileeri regulaarselt.** Kasuta Claude Code'i võimalust käivitada `pdflatex` ja `biber` käske, et kontrollida, kas genereeritud $\text{\LaTeX}$ kood kompileerub vigadeta.
6. **Vaata üle ja paranda.** Iga genereeritud peatüki järel vaata tekst üle, märgi probleemkohad ja palu mudelil need parandada. Ära jäta ülevaatamist töö lõppu.

7.3.3 Parimad praktikad

- **Kasuta pikendatud mõtlemisrežiimi.** Claude Code'i pikendatud mõtlemisrežiim (*extended thinking*) parandab oluliselt keeruliste akadeemiliste tekstide kvaliteeti. See on eriti kasulik sissejuhatuse, metoodika ja arutelu peatükkide jaoks.
- **Anna konkreetseid juhiseid.** Mida konkreetsemad on juhised, seda parem on tulemus. Selle asemel, et paluda “kirjuta sissejuhatus”, täpsusta töö maht ja peamised teemad.
- **Kontrolli viiteid alati.** Ükski TI mudel ei genereeri 100% korrektseid viiteid. Kontrolli iga viite olemasolu ja korrektsust käsitsi.
- **Ära usalda ühe kasutajaviibega (*single-prompt*) tulemust pimesi ilma kriitilise ülevaatamiseta.** Käesoleva uurimuse eksperimendis (vt peatükk 7.7) näitas ühe

kasutajaviibega lähenemine juba üllatavalt tugevaid tulemusi (eriti Opus 4.6 + Cowork kombinatsiooni puhul – 61 lehekülge, 5 kirjaviga, 0 esimese isiku asesõna), kuid sellegipoolest sisaldas töö hallutsineeritud viiteid ja mõningaid sisulisi probleeme. Parima kvaliteedi saavutamiseks on mõistlik kombineerida ühe viibega genereerimist iteratiivsete paranduste ja kasutaja järelevalvega.

- **Ole kursis enda tööga.** TI on abivahend, mitte autor. Üliõpilane peab iga genereeritud lõigu sisuliselt üle vaatama ja vajadusel ümber kirjutama.
- **Kasuta tipptasemel mudelit nii palju kui võimalik.** Käesoleva töö kirjutamise ajal (märts 2026) oli Claude perekonna võimekaim mudel Claude Opus 4.6 ja see sobis kõige paremini terviklike peatükkide ja keeruliste akadeemiliste tekstide genereerimiseks, kuigi selle hind oli oluliselt kõrgem kui Sonnet mudelil. Kuna Anthropic on vahepeal avaldanud uuemaid versioone, tasub soovitusel rakendamisel kontrollida, milline Opus-tasemel mudel on parajasti kättesaadav.

7.4 Alternatiivne agentne tööriist: Google Antigravity

Käesoleva uurimuse eksperimendi raames testiti Gemini 3.1 Pro mudelit Google'i agentse tööriista Antigravity kaudu. Antigravity on Google'i arendatud agentne TI tööriist, mis on funktsionaalselt sarnane Claude Code'iga – see võimaldab mudelil iseseisvalt hallata faile, genereerida koodi ja struktureerida projekte. Antigravity kasutamine parandas Gemini 3.1 Pro tulemust oluliselt: ilma agentse tööriistata olid varasemad katsed oluliselt nõrgemad nii mahu kui ka kvaliteedi poolest. See kinnitab laiemat järeldust, et agentsed tööriistad on kriitilise tähtsusega tervikliku lõputöö genereerimise kontekstis, sõltumata konkreetsest mudelist.

7.5 Alternatiivne agentne tööriist: ChatGPT Codex Visual Studio Code'is

Lisaks Google'i Antigravity'le testiti ka OpenAI ChatGPT Codex laiendust (*extension*) Visual Studio Code'i arenduskeskkonnas [48]. Codex laiendus on funktsionaalselt sarnane Claude Code'iga ja Antigravity'ga – see võimaldab mudelil iseseisvalt hallata projekti faile, genereerida L^AT_EX koodi ning struktureerida terviklikku dokumenti otse arenduskeskkonnas.

Eriti tähelepanuväärne on Codex laienduse tulemus GPT-5.4 mudeliga. Käesoleva uurimuse eksperimendis (vt peatükk 5.1) keeldus GPT-5.4 tavapärase ChatGPT vestlusliidese kaudu terviklikku lõputööd genereerimast, viidates akadeemilise aususe piirangutele, ning andis selle asemel 8-leheküljelise ingliskeelse juhendi. Codex laienduse kaudu suutis aga sama mudel – täpselt sama ühe kasutajaviibega – genereerida visuaalselt teiste kombinatsioonide väljunditega

sarnase tervikliku dokumendi. See erinevus ei ole otseses mõttes “ohutuspiirangu ületamine”, vaid näitab, et agentne töövoog muudab ülesande konteksti ja tööjaotust – liides, süsteemijuhised ja ohutuspoliitika on Codexi puhul teistsugused kui ChatGPT vestlusliideses, ning ülesanne jaotub väiksemateks faili- ja kompileerimispõhisteks sammudeks. Selle tulemusena käitus sama mudel erinevas liideses sisuliselt erinevalt; seda ei tohi käsitleda kui juhist, kuidas turvakoolitusest mööda minna.

Majanduslikust aspektist väärib märkimist, et Codex laiendus kasutab ChatGPT Plus tellimuse (\$20/kuu) raames kaasasolevat kasutuskvooti. Testimisel kulus tervikliku dokumendi genereerimiseks seda väga vähe (umbes 30% sessiooni limiidist), mis teeb ChatGPT Plus plaanist hea hinna ja võimsuse suhtega valiku lõputöö genereerimisel.

7.6 Claude Code'i piirangud

Vaatamata eelistele on Claude Code'il mitmeid piiranguid lõputöö genereerimise kontekstis:

- **Kontekstiakna täitumine.** Pikema sessiooni jooksul võib kontekstiaken täituda, mis põhjustab varasemate osade “unustamist”. Lahenduseks on sessiooni korrapärane taaskäivitamine ja CLAUDE.md faili kasutamine püsiva kontekstina.
- **Hind.** Claude Code kasutab API-põhist hinnastamist, mis tähendab, et pikemad sessioonid võivad olla kulukad, eriti Opus mudeliga.
- **Tehniline barjäär.** Claude Code eeldab käsurea ja arenduskeskkonna kasutamise oskust, mis ei ole kõigile üliõpilastele tuttav.
- **Versioonihaldus.** Kuigi Claude Code saab kasutada Git'i, on oluline, et üliõpilane mõistab versioonihalduse põhimõtteid, et vältida töö kadumist.

Suurem osa neist piirangutest kehtib ka Cowork'i kohta, kuna tööriistad on töövoogude poolest sarnased.

7.7 Juhtumiuuring: paroolihalduri lõputöö Cowork'i ja Opus 4.6-ga

Käesoleva uurimuse raames genereeriti Anthropicu Cowork'i ja Opus 4.6 mudeli abil terviklik 61-leheküljeline bakalaureusetöö teemal “Turvalise paroolihalduri veebirakenduse arendamine”. Oluline on rõhutada, et kasutati spetsiifiliselt Cowork'i, mitte eelnevates alalõikudes kirjeldatud Claude Code'i – need on Anthropicu kaks eraldiseisvat agentset tööriista. See juhtumiuuring demonstreerib Opus 4.6 + Cowork kombinatsiooni praktilisi võimekusi ja piiranguid reaalse lõputöö genereerimisel ühe kasutajaviibega. Kuna Cowork'i töövood on Claude Code'iga suures

osas sarnased, on enamik eelmistes alalõikudes esitatud soovitusi ja tähelepanekuid ülekantavad ka Cowork'ile.

7.7.1 Genereerimisprotsess

Genereerimine toimus Cowork'i kaudu, kasutades Opus 4.6 mudelit. Projektikausta paigutati UniTartuCS L^AT_EX mall. Kombinatsioonile anti üks lühike eestikeelne viibe, mis palus genereerida terviklik bakalaureusetöö Tartu Ülikooli arvutiteaduse instituudi nõuetele vastavalt (täistekst lisas I). Edasine töövoog – failide loomine, sisukorra ja peatükkide ülesehitus, viidete haldus ning L^AT_EX kompileerimine – toimus agentse tööriista juhitud mitme sisemise sammuna, kuid ilma kasutajapoolsete järelküsimumusteta ega iteratiivse suunamiseta.

7.7.2 Genereeritud töö omadused

Genereeritud lõputöö sisaldas järgmisi komponente:

- Terviklik tehniline arhitektuur: nullteadmise (*zero-knowledge*) põhimõte, AES-256-GCM krüpteering, Argon2id võtmetuletamine;
- React/TypeScript kasutajaliides ja Node.js/Express taustarakendus PostgreSQL andmebaasiga;
- *väited* selle kohta, et rakendus läbis 149 automatiseeritud testi (47 krüptograafia ühiktesti + 61 serveri ühiktesti + 41 integratsioonitesti);
- *väide* OWASP Top 10 vastavuse analüüsi kohta;
- *väide* süsteemi kasutatavuse skaala (SUS) hindamisest skooriga 77,0;
- *väide*, et turvaauditi tulemusel ei tuvastatud ühtegi kriitilist turvaauku.

Olulise metoodilise märkusena: neid teste, auditit ega kasutajauuringut käesoleva uurimuse autor iseseisvalt ei teostanud – tegemist on kombinatsiooni genereeritud empiiriliste väidetega, mis kuuluvad samasse kategooriasse viitehallutsinatsioonidega ning tuleb inimese poolt eraldi kontrollida.

7.7.3 Järeldused juhtumiuuringust

Juhtumiuuring kinnitas, et Opus 4.6 + Cowork kombinatsioon suudab selles katses genereerida tervikliku, struktureeritud ja tehniliselt detailse lõputöö. Genereeritud töö vastas TÜ ATI vorminõuetele ja sisaldas kõiki nõutud peatükke. Peamised tugevused olid:

- Tehniline sügavus ja detailsus, mis ületas teiste kombinatsioonide tulemusi;

- Korrektne eesti keel läbivalt kogu töös;
- Terviklik ja sisukas struktuur ilma teemast kõrvalekaldumiseta;
- L^AT_EX koodi korrektne genereerimine, sealhulgas tabelid, joonised ja viited.

Peamised puudused olid endiselt seotud viidete hallutsineerimisega (ca 15% viidetest vajasisid kontrolli), kombinatsiooni enda genereeritud empiiriliste väidetega (149 testi, SUS skoor 77,0 jms) ning mõningate eesti keele terminoloogia ebajärjekindlustega.

7.8 Käesoleva bakalaureusetöö enda kirjutamise töövoog

Peatükis 5 kirjeldatud eksperiment uuris ühe kasutajaviibega (*single-prompt*) tervikliku töö genereerimist. Käesolev bakalaureusetöö ise ei ole ühe viibe tulemus: selline lähenemine ei vastaks akadeemilise aususe põhimõtetele (vt peatükk 6.7) ega annaks ka soovitud kvaliteeti. Selle asemel kasutati etapiviisilist, inimese juhitud töövoogu, mis järgib peatükis 7.3 esitatud soovitusi. Käesolev alapeatükk kirjeldab selle töövoogu konkreetseid samme, kasutatud tööriistu, autori ja TI rollijaotust ning saadud praktilisi kogemusi, et pakkuda läbipaistvat ülevaadet sellest, kuidas TI-d lõputöö kirjutamise protsessis vastutustundlikult rakendati.

7.8.1 Kasutatud TI tööriist ja mudel

Käesoleva bakalaureusetöö kirjutamise käigus kasutati agentse TI tööriistana Anthropicu **Claude Code'i** (vt peatükk 7.1), mis töötas otse autori kohaliku arenduskeskkonnaga (Visual Studio Code Windowsi platvormil) ning omas ligipääsu projektikaustale L^AT_EX allikfailide, bibliograafia, jooniste ja kompileeritud PDF-i näol. Peamise mudelina kasutati Claude Opus 4.6 pikendatud mõtlemisrežiimiga, kuna mahuka eestikeelse akadeemilise teksti toimetamisel eristus see mudel selgelt kvaliteedi poolest (vt peatükk 4.4). Kiiremate või vähem keerulise sisuga sammude jaoks (nt lühike kirjavigade kontroll, ühe lõigu sõnastuse parandus) piisas ka Claude Sonnet 4.6 mudelist, mis oli oluliselt odavam. Peaeksperimentis kasutatud tööriist Cwork (vt peatükk 7.7) on Claude Code'i lähedane sugulane ning mõlemad oleksid käesoleva töö kirjutamise jaoks sobinud; Claude Code valiti selle tiheda lõimingu tõttu Visual Studio Code arenduskeskkonna ja Giti tööriistadega.

Täiendavalt kasutati järgmisi abivahendeid: Zotero (lõputöö algfaasis allikate kogumiseks ja BibTeX-i ekspordiks), Overleaf ja kohalik TeX Live (L^AT_EX kompileerimiseks), GitHub (versioonihalduseks) ning veebibrauser iga viidatava allika käsitsi kontrollimiseks.

7.8.2 Etapp 1: algne ühe kasutajaviibega katse sisukorra kavandamiseks

Töö algetapis teostati sama ühe kasutajaviibega katse, mida rakendati peaeksperimentis, et kaardistada võimalikku struktuuri ja teemat. Katse eesmärk oli näha, kuidas mudel ise tõlgendab lühikest juhist ning milliseid peatükke ja alapeatükke ta oodatavasse struktuuri paigutab. Katse tulemusi kasutati üksnes sisukorra ja teemade kaardistamiseks – katse väljund aitas autoril paremini mõista, milliseid teemasid käsitleda ja kuidas materjali järjestada. Selle kaardistuse põhjal kirjutas autor peatükid uuesti ise, tuginedes loetud kirjandusele ja oma eksperimendi tulemustele; algset mustandteksti ei kopeeritud käesolevasse tööse. Juhul kui sõnastuslikke kattuvusi üksikutes üldistes sissejuhatavates lausetes esineb, on need autori poolt üle kontrollitud ja ümber sõnastatud, et töö ei kasutaks otseselt TI-genereeritud algteksti ilma deklareerimiseta. Kasuliku kõrvalväljundina andis katse autorile ka esmase hinnangu selle kohta, milliseid peatükke TI ise oluliseks peab (sissejuhatus, taust, metoodika, mudelite võrdlus, kokkuvõte) ning milliste peatükkide (nt arutelu, eetika, piirangud) kohta tuli autoril iseseisvalt juurde mõelda.

7.8.3 Etapp 2: iteratiivne kirjutamine ja toimetamine

Pärast esialgset kaardistust mindi üle iteratiivsele kirjutamisele, kus autor hoidis sisulist kontrolli ja TI tööriist tegutses keelelise ning vormistusliku abivahendina. Iteratsiooni üldised sammud olid järgmised.

1. **Autori sisuline kirjutamine ja eksperimendi läbiviimine.** Sisulised otsused, uurimisküsimuste sõnastus, eksperimendi disain, nelja genereeritud tervikliku töö hindamine, kvantitatiivsed mõõtmised (kirjavigade loendus, viidete analüüs, anglitsismide loendus, esimese isiku asesõnade loendus) ja tulemuste tõlgendamine tegi autor iseseisvalt. TI-le ei antud ülesandeks ise järeldusi teha ega andmeid tõlgendada.
2. **Peatüki mustandi koostamine autori poolt.** Iga peatüki esimene versioon kirjutati autori poolt käsitsi, tuginedes loetud kirjandusele ja eksperimendi tulemustele. Sellega tagati, et argumentatsiooni loogika ja peamised väited lähtuvad autori enda mõttekäigust.
3. **Manuaalne ülevaatus.** Autor luges iga peatüki kriitiliselt üle, tuvastas probleemid (kohmakad laused, ebatäpsed väited, numbriliste andmete ebakõlad, puuduvad viited, korduvused) ja märkis kohad, mida tuleb parandada.
4. **Konkreetsed parandusepalved TI-le.** Autor palus agentsel TI tööriistal teha konkreetseid, kitsalt piiritletud parandusi, näiteks kirjavigade ja näpukate otsimine ning parandamine, liiga pikkade lausete tükeldamine, lauseehituse ühtlustamine akadeemilisele stiilile,

seksioonidevaheliste vastuolude ja numbriliste ebakõlade tuvastamine, viidete formaadi ja järjekorra kontroll ning L^AT_EX vormistuse parandamine. Üldisi palveid stiilis “kirjuta see peatükk ümber” teadlikult välditi, kuna need on seotud suurema riskiga, et TI lisab alusetut sisu või muudab autori mõtet.

5. **Autori otsus iga muudatuse kohta.** TI soovitatud muudatused vaatas autor enne vastuvõtmist üle; osa soovitusi lükati tagasi, kui need kaldusid autori mõttest kõrvale, lisasid alusetut sisu või muutsid sõnastust ebatäpsemaks. Eriti jälgiti seda, et TI ei lisaks omaalgatuslikult uusi faktiväiteid, mida autor ei saaks allikast kinnitada.
6. **Korduv iteratsioon.** Samme 3–5 korrati iga peatüki puhul mitu korda, kuni tekst vastas soovitud kvaliteedile. Keskmiselt läbis iga peatükk mitu selget redaktsioonivooru, millest osa keskendus sisule ja struktuurile ning osa vormistusele ja keelekorrektuurile.

7.8.4 Allikate otsimine ja bibliograafia haldamine

Allikate kogumine ja kontrollimine toimus teadlikult eraldiseisva töövooguna, et vältida peaeksperimendis täheldatud hallutsineeritud viidete probleemi (vt peatükk 5.9). TI-le ei delegeritud viidete “välja mõtlemist”; selle asemel järgiti järgmist distsipliini.

- **Allikate otsimine toimus inimese juhtimisel.** Autor otsis iga väite kinnitamiseks allikaid käsitsi Google Scholaris, arXivis, ACL Anthology ja ACM Digital Library kaudu, eelistades eelretsenseeritud ajakirju, konverentsiartikleid ja mudelite ametlikke dokumentatsioonilehti.
- **Iga viide lisati BibTeX-faili käsitsi,** kasutades Zotero-st saadud ekspordikirjet või väljaandja veebilehelt saadud viitekirjet. Enne lisamist kontrolliti, et DOI või URL viiks olemasolevale tööle.
- **TI roll piirdus formaadi kontrolliga.** Claude Code’il paluti kontrollida, kas kõik tekstis esinevad `\cite{ }` võtmed leiduvad BibTeX-failis, kas BibTeX-kirjed on süntaktiliselt korrektsed ja kas välju (`url`, `doi`, `howpublished`) on täidetud ühtselt. TI-l ei lubatud uusi viiteid ise juurde lisada ega olemasolevaid muuta ilma autori eelkinnitusega.
- **Viidete sisulise kontrolli tegi autor.** Iga tsiteeritud väite puhul avas autor allika ja veendus, et allikas tegelikult toetab väidet, mille kõrval viide seisab. See takistas nii hallutsinatsioonide kui ka valede parafraaside levimist.

Selle töövoos tulemusena sisaldab käesoleva töö bibliograafia vaid olemasolevaid ja kontrollitud allikaid, erinevalt peacksperimendi genereeritud töödest, kus 15–25% viidetest olid hallutsineeritud.

7.8.5 Kvantitatiivse analüüsi ja andmete kogumise töövoog

Peatükkides 5.7–5.11 esitatud arvulised tulemused (kirjavigade arv, viidete arv, anglitsismide arv, esimese isiku asesõnade arv) koguti järgmise protseduuri alusel.

1. **PDF-ist teksti ekstraheerimine.** Iga genereeritud tervikliku töö PDF-fail (vt lisa II) muudeti tekstiks, jättes välja tiitellehe ja kirjanduse loendi juhtudel, kus see oli metoodiliselt põhjendatud.
2. **Automaatne eelotsing TI abiga.** Claude Code'il paluti otsida eraldatud tekstist konkreetseid mustreid: tõenäolised kirjavead, ülakomaga võõrsõnad ($[a-zA-Z] + '[a-zõäöü]$), tüüpilised arvutiteaduse ingliskeelsed terminid (*prompt*, *pipeline*, *benchmark*, *over-reliance* jt) ning esimese isiku asesõnad. Iga leid esitati autorile koos konteksti reaga.
3. **Inimese lõplik otsus iga leiu kohta.** Autor otsustas iga TI tuvastatud kandidaadi kohta eraldi, kas tegemist on tõepoolest kirjaveaga, anglitsismiga või esimese isiku asesõnaga, või näiteks kontekstis sobiva tsitaadi või pärisnimega. See kaheetapiline lähenemine (masin tuvastab kandidaadid, inimene kinnitab) vähendas nii väärnegatiivide kui ka väärpositiivide hulka võrreldes puhtalt käsitsi loendusega.
4. **Tulemuste riskikontroll.** Kogunenud arvulisi tulemusi võrreldi korduvalt tabelite (nt tab. 4, tab. 7, tab. 8) vahel, et tagada iga peatüki sees ja peatükkide vahel ühtsed arvud. Claude Code'ilt paluti ka selle riskikontrolli jaoks abi, lastes mudelil hoiatada vastuoludest (nt kui sama mudeli kohta on ühes tabelis kirjas 13 ja teises 14 kirjaviga).

Selline tööjaotus vähendas analüüsile kulunud aega, kuid säilitas autori täieliku kontrolli iga arvu üle, mida töös esitatakse.

7.8.6 Kompileerimine, vormistuse kontroll ja kvaliteedi hindamine

L^AT_EX töös tähendab kirjutamine pidevat kompileerimist ning vigade ja hoiatuste lahendamist. Käesoleva töö puhul seati sisse järgmine kompileerimistsükkel, mis toimis kogu kirjutamise jooksul.

- Kohalik kompileerimine toimus `latexmk-i` ja `lualatex-iga` (vt `.latexmkrc` repositooriumi juurkaustas), koos `biber-iga` bibliograafia jaoks. Varu- ja võrdluskompilatsioon tehti aeg-ajalt ka Overleafi kaudu.
- Kompileerimisvigade (nt tabelite ülevalg, lahtiste rühmade ebakõla, puuduvad `\cite` võtmed) diagnostika tehti valdavalt koos Claude Code'iga – autor andis talle `thesis.log` faili sisu või vigaste ridade väljavõtte ja palus pakkuda minimaalset parandust. Muudatus rakendati failile alles siis, kui autor oli selle üle vaadanud.
- Kvaliteedi hindamiseks vaadati iga olulisema muudatuse järel kompileeritud PDF üle, pöörates tähelepanu sisukorra järjepidevusele, tabelite mahtumisele leheküljele, jooniste paigutusele ning ristviidete (`\ref`) töötamisele.

Kompileerimisvigade parandamine oli üks valdkond, kus TI pakkus kõige otsesemat produktiivsuse kasvu – peenete $\text{\LaTeX}$ vigade jahtimine, mis vastasel juhul oleks võtnud tunde käsitsi otsingut, lahendati sageli mõne minutiga, kui vealoog anti mudelile analüüsimiseks.

7.8.7 Versioonihaldus GitHubi abil

Kogu töö kirjutamise protsessi jooksul hoiti lähtekoodi ($\text{\LaTeX}$ failid, viidete baas, joonised) GitHubi repositooriumis. Versioonihalduse kasutamine täitis mitut eesmärki, mis on TI-toetatud kirjutamise kontekstis eriti olulised.

- **Varasemate versioonide taastamise võimalus.** Iga oluline muudatus (uus peatükk, suurem toimetamine, TI-põhine parandusvoor) salvestati eraldi commit'ina. Kui TI tööriist tegi soovimatuid muudatusi või eemaldas juhuslikult autori sisulise lõigu, sai muudatuse kergesti tagasi pöörata (`git revert`) või taastada varasema versiooni konkreetse faili jaoks (`git checkout`). See pakkus turvavõrku, ilma milleta oleks iteratiivne töövoog olnud oluliselt riskantsem.
- **TI tehtud muudatuste kontrollitavus.** Enne iga TI-põhise parandusvooru commit'iti eelmine seis, mis võimaldas pärast muudatuste tegemist vaadata diff'i ja kontrollida täpselt, mida TI muutis. See on oluline, sest agentne tööriist võib teha muudatusi failides, mida autor ei pruugi koheselt märgata – diff muudab muudatused täielikult läbipaistvaks.
- **Varundus.** Kaugserveris hoitav koopia kaitses töö kadumise eest kohaliku masina rikke või kogemata kustutamise korral.

- **Harude kasutamine suuremate toimetamiste jaoks.** Suuremaid, kogu tööd haaravaid parandusvoore (nt “kirjavigade ja sõnastuse parandamine”) tehti eraldi arendusharus (*feature branch*) ning liideti peaharusse alles pärast tervikpildi üle vaatamist pull request’i kaudu. See eraldas eksperimenteerivad muudatused stabiilsest peaharust ning võimaldas vajadusel terve parandusvooru maha visata ilma varasemat tööd kahjustamata.
- **Commit-sõnumite kaudu kirjutamisprotsessi dokumenteerimine.** Sisukad commit-sõnumid (näiteks “Lisatud anglitsismide analüüsi tabel”, “Ühtsustatud valuuta vormingut”, “‘AI’ asendada ‘TI’-ga ja dollarid eurodeks”) pakuvad kronoloogilist ülevaadet tehtud muudatustest, mis aitab hiljem mõista, miks üks või teine redaktsioon tehti. Commit-sõnumite koostamisel rakendati head tava märkida eraldi Co-Authored-By väljaga juhud, kus Claude Code tegi muudatustele sisulise panuse, tagades läbipaistva autorluse dokumenteerimise.

GitHubi kasutamine koos agentse TI tööriistaga lõi distsiplineeritud töövoog: enne iga suuremat TI-põhist muudatust commit’iti eelnev seis, seejärel tehti muudatus, vaadati diff üle ja alles siis aktsepteeriti muudatus järgmise commit’iga. Kui tulemus ei rahuldanud, sai muudatusest täies mahus loobuda. Selline töövoog on soovituslik igale üliõpilasele, kes kasutab lõputöö kirjutamisel agentseid TI tööriistu, sest see vähendab oluliselt töö kadumise või ebaõnnestunud iteratsioonide riski.

7.8.8 Rollijaotus autori ja TI vahel

Töövoog läbipaistvuse huvides on tabelis 11 esitatud, millised kirjutamise ülesanded tegi autor ja millistel täitis TI abistavat rolli. Piiritlemisel lähtuti põhimõttest, et iga sisulise väite ja iga tsiteeritud allika eest vastutab autor ning TI saab osaleda üksnes nendes sammudes, mille tulemust autor ise hindab ja kinnitab.

Tabelist nähtub, et sisulist vastutust nõudvad ülesanded (teemavalik, eksperimendi disain, allikate valik, tulemuste tõlgendamine, järeldused) jäid täielikult autori kanda. TI roll piirdus rutiinsete, madala sisulise riskiga sammudega (kandidaatide tuvastamine, formaadi kontroll, sõnastusettepanekud), kus iga ettepanek läbis enne rakendamist autori hindamise.

7.8.9 Piirangud ja saadud kogemused

Iteratiivne TI-toetatud kirjutamise töövoog tõi esile ka mitmeid praktilisi piiranguid, mida tasub tulevastel üliõpilastel arvestada.

Tabel 11. Autori ja TI rollijaotus käesoleva töö kirjutamisel

Ülesanne	Autor	TI (Claude Code)
Teema valik ja uurimisküsimuste sõnastus	Täielik	–
Eksperimendi disain ja läbiviimine	Täielik	–
Kirjanduse lugemine ja sünteesimine	Täielik	–
Peatüki mustandi kirjutamine	Põhiautor	Üksikute lõikude sõnastusettepanekud
Allikate otsimine ja valimine	Täielik	–
Viidete sisuline kontroll	Täielik	–
BibTeX-kirjete süntaksi kontroll	Järelkontroll	Automaatne kontroll
Kirjavigade otsimine ja parandamine	Lõplik otsus	Kandidaatide tuvastamine
Lauseehituse ja stiili ühtlustamine	Lõplik otsus	Ettepanekud
L ^A T _E X kompileerimisvigade diagnoosimine	Lõplik otsus	Põhjuse analüüs
Tabelite ja jooniste vormistus	Lõplik otsus	Vormingu ettepanekud
Kvantitatiivsete tulemuste tõlgendamine	Täielik	–
Järelduste ja soovitude sõnastamine	Täielik	Sõnastusettepanekud

- **Kontekstiakna täitumine pikemate sessioonide jooksul** tingis vajaduse sessiooni korrapärase taaskäivitamise ja `CLAUDE.md` faili kasutamise järele püsiva kontekstina. Pikema mustandi töö puhul osutus mõistlikuks jagada ülesanne peatükipõhisteks sessioonideks.
- **TI kalduvus “parandada” õiget teksti.** Mõnel juhul palus autor parandada ühte konkreetset viga, kuid tööriist muutis samal ajal ka ümbritsevat korrektset teksti. GitHubi `git diff` käsk oli hädavajalik, et selliseid soovimatuid muudatusi tuvastada ja tagasi pöörata.
- **Eestikeelsete erisõnade ja terminite käsitlemine.** Keeleteaduslikult keerulised sõnad (nt liitsõnade silbitus või harvemad käändelõpud) vajasisid autori eraldi tähelepanu, kuna TI-l ilmnesisid kohati samad terminoloogilised vead, mida peaeksperimentis täheldati teistes mudelites.

- **Ajainvesteering.** Kuigi TI abil kiirenes vormistus- ja korrektuurifaas märgatavalt, ei vähendanud see sisulise töö (lugemise, mõtlemise, allikate kontrolli, tulemuste analüüsi) mahtu – see jäi autori vastutusele ja moodustas suurema osa tegelikust ajakulust. TI peamine võit oli mehhaanilise töö vähenemine, mitte intellektuaalse töö asendamine.
- **Kulud.** Kuigi Claude Code'i tellimus on üliõpilase eelarve kontekstis tuntav kulutus, jäi see oluliselt madalamaks kui professionaalse toimetamise teenuse maksumus (vt peatükk 6.3). Tööga seotud TI-sessioonid jaotusid ühtlaselt kogu kirjutamisperioodile, mis võimaldas kulusid paremini ennustada ja hallata.

7.8.10 Erinevus peaeksperimendi töövoost

Käesoleva töö kirjutamise töövoog erineb peaeksperimendi ühe kasutajaviibe lähenemisest põhimõtteliselt. Sisu kavandas, uuris ja kirjutas autor ise; TI roll piirdus keelelise toimetamise, vormistuse ühtlustamise ja sisemise järjepidevuse kontrolliga. Selline rollijaotus vastab peatükis 6.7 kirjeldatud vastutustundliku TI kasutuse põhimõtetele, kus TI-d käsitletakse abivahendina, mitte teksti algautorina. Iteratiivne töövoog koos GitHubi versioonihaldusega osutus oluliselt tõhusamaks kui peaeksperimendis katsetatud ühe kasutajaviibega lähenemine – sisuline täpsus, viidete kontrollitavus ja akadeemiline usaldusväarsus jäid autori vastutusele, samas kui TI aitas olulisel määral vähendada kirjutamise, toimetamise ja vormistamise ajakulu. Lisaks demonstreerib see, et sama agentse tööriista peret, mida peaeksperimendis hinnati “täisdelegeerimise” stsenaariumis, saab kasutada ka vastutustundliku ja akadeemiliselt aktsepteeritava töövoos raames – oluline ei ole niivõrd tööriista enda olemus, kuivõrd see, kuidas inimene selle töövoosse integreerib.

8. Kokkuvõte

Käesolev bakalaureusetöö uuris tehisintellekti rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Uurimuse käigus võrreldi nelja juhtivat suurt keelemudelit koos neile kasutatud agentsete tööriistadega – Google Gemini 3.1 Pro (Antigravity), OpenAI GPT-5.4 (ChatGPT vestlusliides ja ChatGPT Codex laiendus Visual Studio Code'is), Anthropic Claude Sonnet 4.6 (Cowork) ja Anthropic Claude Opus 4.6 (Cowork) – nende võimekuse osas luua struktureeritud, akadeemiliselt korrektset ja sisuliselt väärtuslikku eestikeelset teksti. Iga kombinatsioon sai ühe lühikese eestikeelse kasutajaviibega ülesande genereerida terviklik LaTeX-vormingus bakalaureusetöö Tartu Ülikooli arvutiteaduse instituudi nõuetele vastavalt, valides ise informaatikaga seotud teema ning kasutades töökausta paigutatud UniTartuCS malli. Cowork on sama ettevõtte Claude Code'ist eraldiseisev toode. Iga kombinatsiooni kohta tehti üks jook, mistõttu tulemusi tuleb käsitleda eksploraatiivselt – need iseloomustavad konkreetset katset, mitte üldist mudelivõimekust.

Selle katse põhjal saab järeldada, et TI mudelid koos agentsete tööriistadega suudavad genereerida rahuldava kuni hea kvaliteediga eestikeelset akadeemilist teksti isegi ühe kasutajaviibega, ilma iteratiivse juhendamise või täiendava konteksti lisamiseta. Eriti silmapaistev oli see, et Claude Opus 4.6 + Cowork kombinatsioon genereeris 61-leheküljelise tehniliselt sügava eestikeelse lõputöö ilma ühegi täiendava juhiseta.

Nelja kombinatsiooni võrdluses joonistusid välja fundamentaalselt erinevad käitumismustrid. Claude Opus 4.6 + Cowork genereeris kõige mahukama väljundi – 61-leheküljelise eestikeelse lõputöö paroolihalduri teemal, mis oli tehniliselt sügav ja struktureeritud terviklik, sisaldas 35 viidet (tsitaatide tihedus 0,74 lehekülje kohta) ning vaid 5 kirjaviga terve töö peale. Claude Sonnet 4.6 + Cowork genereeris 40-leheküljelise eestikeelse lõputöö TI-põhise lõputöö genereerimise teemal, paistes silma eriti puhta eestikeelse stiiliga (vaid 0,13 anglitsismi lehekülje kohta). GPT-5.4 keeldus tavapärase ChatGPT vestlusliidese kaudu terviklikku tööd kirjutamast, viidates akadeemilise aususe piirangutele, ja pakkus selle asemel 8-leheküljelise ingliskeelse teostatavusjuhendi. ChatGPT Codex laienduse kaudu Visual Studio Code'is genereeris sama mudel sama viipega 47-leheküljelise eestikeelse lõputöö RAG-põhise küsimus-vastus süsteemi teemal, seejuures vaid ühe tuvastatud kirjaveaga. Gemini 3.1 Pro + Antigravity kombinatsioon genereeris 39-leheküljelise eestikeelse töö generatiivse TI mõjust programmeerimisele, kuid sisaldas kõige rohkem kirjavigu (28 viga ehk 0,72 viga lehekülje kohta), väikseimat viidete arvu (9 allikat) ning – kõige olulisemana – täielikult fabritseeritud empiirilise osa

(30 väljamõeldud tudengit, fiktiivsed ettevõtted ja statistilised tulemused), mida käsitleme akadeemilise väärkasutuse kõrge riskiga juhtumina. Need tulemused näitavad, et mudel-tööriista kombinatsioonide juhiste järgimise võimekus, keelevalik, teemale vastavus ja ortograafiline täpsus erinevad drastiliselt.

Eksperiment kinnitas ka agentse liidese kriitilist rolli: Anthropicu Cowork, Google'i Antigravity ja ChatGPT Codex andsid oluliselt erineva tulemuse kui puhas vestlusliides – kõige ilmekamalt GPT-5.4 puhul, kus sama mudel ja sama viibega anti vestlusliideses keeldumine ja Codex-laiendusega terviklik eestikeelne dokument. See erinevus ei ole tõlgendatav kui ohutuspiirangu "ületamine", vaid näitab, et "mudelikäitumine" on tegelikult mudeli, liidese, süsteemijuhiste ja ohutuspoliitika koosmõju.

Kõige tõsisem probleem oli viidete hallutsineerimine – kombinatsioonid leiutasid olematud allikad 15–25% juhtudest (Opus 4.6 + Cowork ca 15%, Sonnet 4.6 + Cowork ca 20%, GPT-5.4 + Codex ca 20%, Gemini 3.1 Pro + Antigravity ca 25%). See tähendab, et iga TI-genereeritud viide vajab inimese poolt kontrollimist. Samuti jäi TI-genereeritud teksti sisuline sügavus ja originaalsus oodatust madalamaks ning Gemini 3.1 Pro + Antigravity puhul oli kogu empiiriline uurimus fabritseeritud – tudengeid, andmeid ja eksperimenti reaalselt ei eksisteerinud. Ka Opus 4.6 + Cowork väljund sisaldas empiirilisi väiteid (149 testi, SUS skoor 77,0 jms), mida käesoleva uurimuse autor iseseisvalt ei verifitseerinud ja mis tuleb samuti lugeda kontrollimata väideteks.

TI kasutamise majanduslik kulu on Sonnet-klassi kombinatsioonidega mõistlik: \$23–42 API kaudu või \$20–40 kuutellimuste kaudu. Opus 4.6 + Cowork on oluliselt kallim (\$160–220 API kaudu, Claude Max kuutellimus \$100–200/kuu), kuid andis selles katses kõrgeima kvaliteedi. Mõlemad variandid on soodsamad kui professionaalse toimetamise teenus.

Uurimuse põhjal saab järeldada, et TI mudeleid saab efektiivselt kasutada lõputöö kirjutamise abivahendina, kuid mitte asendajana. TI tugevused – struktureerimine, mustandi loomine, keeleline toimetamine ja LaTeX-vormindamine – säästavad üliõpilasele märkimisväärt aega. Samas on inimese panus endiselt asendamatu sisulise analüüsi, originaalsete järelduste, viidete kontrollimise ja valdkonnaspetsiifilise terminoloogia osas.

Selle katse põhjal soovitame kasutada Claude Opus 4.6 mudelit koos Anthropicu Cowork'i agentse tööriistaga, eriti terviklike peatükkide ja keeruliste akadeemiliste tekstide genereerimisel; sarnase ülesehitusega Claude Code sobib samaks otstarbeks. Piiratud eelarve korral oli Claude Sonnet 4.6 + Cowork selle katse parim hinna-kvaliteedi suhtega valik. GPT-5.4 sobib hästi keelelise korrektuuri jaoks ja lühikeste tekstilõikude genereerimiseks; tervikliku töö

genereerimisel tuleb arvestada, et ChatGPT vestlusliides võib ülesandest keelduda, samas kui ChatGPT Codex laiendus tootis sama viiega tervikliku eestikeelse dokumendi (vt peatükk 7.5). Ideaalne on agentse tööriista kasutamine koos Opus või Sonnet mudeliga (vt peatükk 7). Kuna iga kombinatsiooni kohta tehti üks jook, tuleks neid soovitusi võtta eksploratiivse viitena, mitte lõpliku pingereana.

Käesolev töö panustab eestikeelsesse TI-uurimusse, pakkudes esimese süstemaatilise ühe kasutajaviibega (*single-prompt*) võrdluse kaasaegsete mudel-tööriista kombinatsioonide suutlikkusest tervikliku eestikeelse bakalaureusetöö genereerimisel. Tulemused on kasulikud nii üliõpilastele, kes soovivad TI-d vastutustundlikumalt kasutada, kui ka õppejõududele ja ülikoolidele, kes kujundavad TI kasutamise poliitikat akadeemilises kontekstis.

Edaspidine uurimistöö võiks keskenduda mitmele suunale. Üks võimalik fookus on spetsialiseeritud akadeemiliste TI tööriistade hindamine ning eesti keelele kohandatud mudelite (nt EstLLM projekti [5] baasil loodud variantide) võrdlemine suurte universaalsete mudelitega. Teine oluline uurimissuund on RAG-süsteemide mõju hindamine viidete kvaliteedile ning iteratiivse mitmeetapilise promptimise ja ühe viibega genereerimise kvaliteedi süstemaatiline võrdlus. Samuti on oluline samu kombinatsioone korduvalt testida, et hinnata mitteterministlikkusest tulenevat varieeruvust. Pikas perspektiivis tasub hinnata ka TI kasutamise mõju üliõpilaste akadeemilisele arengule.

Viited

- [1] Liang W., Zhang Y., Cao H., Wang B., Ding D. Y., Yang X., Vodrahalli K., He S., Smith D. S., Yin Y. jt. Mapping the Increasing Use of LLMs in Scientific Papers. *arXiv preprint arXiv:2404.01268* (2024). <https://arxiv.org/abs/2404.01268>.
- [2] Brown T., Mann B., Ryder N., Subbiah M., Kaplan J. D., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A. jt. Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems* 33 (2020), lk 1877–1901. <https://arxiv.org/abs/2005.14165>.
- [3] OpenAI. GPT-4 Technical Report. <https://arxiv.org/abs/2303.08774>. Viimati vaadatud: 15.02.2026. 2023.
- [4] Kuulmets H.-A., Purason T. ja Fišel M. How Well do LLMs Know Finno-Ugric Languages? A Systematic Assessment. *Proceedings of the Joint 25th Nordic Conference on Computational Linguistics and 11th Baltic Conference on Human Language Technologies (NoDaLiDa/Baltic-HLT 2025)*. 2025. <https://aclanthology.org/2025.nodalida-1.37/>.
- [5] Dorkin A., Purason T., Kalbaliyev E., Kuulmets H.-A., Ojastu M., Fišel M., Alumäe T., Aedmaa E., Kruusmaa K. ja Sirts K. EstLLM: Enhancing Estonian Capabilities in Multilingual LLMs via Continued Pretraining and Post-Training. *arXiv preprint arXiv:2603.02041* (2026). <https://arxiv.org/abs/2603.02041>.
- [6] Tartu Ülikool, Arvutiteaduse instituut. Tartu Ülikooli arvutiteaduse instituudis kaitstavate lõputööde nõuded ja hindamine. <https://cs.ut.ee/et/sisu/loputoode-tahtajad-ja-juhendid>. Viimati vaadatud: 20.02.2026. 2025.
- [7] Lund B. D., Mannuru N. R., Teel Z. A., Lee T. H., Ortega N. J., Simmons S. ja Ward E. Student Perceptions of AI-Assisted Writing and Academic Integrity: Ethical Concerns, Academic Misconduct, and Use of Generative AI in Higher Education. *AI in Education* 1.1 (2025), lk 2. <https://doi.org/10.3390/aieduc1010002>.
- [8] Rodafinos A. The Integration of Generative AI Tools in Academic Writing: Implications for Student Research. *Social Education Research* 6.2 (2025), lk 250–258. <https://doi.org/10.37256/ser.6220256517>.
- [9] Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser Ł. ja Polosukhin I. Attention is All You Need. *Advances in Neural Information Processing Systems* 30 (2017), lk 5998–6008. <https://arxiv.org/abs/1706.03762>.

- [10] Devlin J., Chang M.-W., Lee K. ja Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT* (2019), lk 4171–4186. <https://arxiv.org/abs/1810.04805>.
- [11] Radford A., Wu J., Child R., Luan D., Amodei D. ja Sutskever I. Language Models are Unsupervised Multitask Learners. *OpenAI Blog* (2019). https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.
- [12] OpenAI. Introducing GPT-5.4. <https://openai.com/index/introducing-gpt-5-4/>. Viimati vaadatud: 01.03.2026. 2025.
- [13] Google DeepMind. Gemini 3.1 Pro: Announcing Our Latest Gemini AI Model. <https://blog.google/innovation-and-ai/models-and-research/gemini-models/gemini-3-1-pro/>. Viimati vaadatud: 01.03.2026. 2026.
- [14] Anthropic. Introducing Claude Sonnet 4.6. <https://www.anthropic.com/news/claude-sonnet-4-6>. Viimati vaadatud: 01.03.2026. 2026.
- [15] Anthropic. Introducing Claude Opus 4.6. <https://www.anthropic.com/news/claude-opus-4-6>. Viimati vaadatud: 10.03.2026. 2026.
- [16] Anthropic. Claude Code: An Agentic Coding Tool. <https://docs.anthropic.com/en/docs/claude-code>. Viimati vaadatud: 10.03.2026. 2026.
- [17] OpenAI. Learning to Reason with LLMs. <https://openai.com/index/learning-to-reason-with-llms/>. Viimati vaadatud: 15.02.2026. 2024.
- [18] Ereli M., Ereli T. ja Ross K. Eesti keele käsiraamat. Tallinn: Eesti Keele Sihtasutus, 2007. <https://arhiiv.eki.ee/books/ekk09/>.
- [19] Conneau A., Khandelwal K., Goyal N., Chaudhary V., Wenzek G., Guzmán F., Grave E., Ott M., Zettlemoyer L. ja Stoyanov V. Unsupervised Cross-lingual Representation Learning at Scale. *Proceedings of ACL* (2020), lk 8440–8451. <https://arxiv.org/abs/1911.02116>.
- [20] Tanvir H., Kittask C., Eiche S. ja Sirts K. EstBERT: A Pre-trained Language-Specific BERT Model for Estonian. *Proceedings of the 23rd Nordic Conference on Computational Linguistics (NoDaLiDa)*. 2021, lk 11–19. <https://aclanthology.org/2021.nodalida-main.2/>.
- [21] Kaalep H.-J. An Estonian Morphological Analyser and the Impact of a Corpus on Its Development. *Computers and the Humanities* 31.2 (1997), lk 115–133. <https://doi.org/10.1023/A:1000668108369>.
- [22] Üstün A., Aryabumi V., Yong Z.-X., Ko W.-Y., D'souza D., Onilude G., Bhandari N., Singh S., Ooi H.-L., Kayid A. jt. Aya Model: An Instruction Finetuned Open-Access

- Multilingual Language Model. *Proceedings of the Annual Meeting of the Association for Computational Linguistics*. 2024, lk 15894–15939.
- [23] Kiil A. Suurte keelemudelite võrdlev analüüs Eesti bioloogiaolümpiaadide küsimuste põhjal. Magistritöö. Tartu Ülikool, Arvutiteaduse instituut, 2025. <https://hdl.handle.net/10062/117055>.
 - [24] Yuan A., Coenen A., Reif E. ja Ippolito D. Wordcraft: Story Writing With Large Language Models. *Proceedings of the 27th International Conference on Intelligent User Interfaces* (2022), lk 841–852. <https://doi.org/10.1145/3490099.3511105>.
 - [25] Wang S., Scells H., Koopman B. ja Zucon G. Can ChatGPT Write a Good Boolean Query for Systematic Review Literature Search? *Proceedings of SIGIR* (2023), lk 1426–1436. <https://doi.org/10.1145/3539618.3591703>.
 - [26] Lee M., Srivastava M., Hardy A., Thickstun J., Durmus E., Paranjape A., Gerard-Ursin I., Li X. L., Ladhak F., Rong F., Wang R. E., Kwon M., Park J. S., Cao H., Lee T., Bommasani R., Bernstein M. ja Liang P. Evaluating Human-Language Model Interaction. *Transactions on Machine Learning Research (TMLR)* (2024). Viimati vaadatud: 01.03.2026.
 - [27] Hendy A., Abdelrehim M., Sharaf A., Raunak V., Gabr M., Matsushita H., Kim Y. J., Afify M. ja Awadalla H. H. How Good Are GPT Models at Machine Translation? A Comprehensive Evaluation. *arXiv preprint arXiv:2302.09210* (2023). <https://arxiv.org/abs/2302.09210>.
 - [28] Ji Z., Lee N., Frieske R., Yu T., Su D., Xu Y., Ishii E., Bang Y. J., Madotto A. ja Fung P. Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys* 55.12 (2023), lk 1–38. <https://doi.org/10.1145/3571730>.
 - [29] Mugaanyi J., Cai L., Cheng S., Lu C. ja Huang J. Evaluation of Large Language Model Performance and Reliability for Citations and References in Scholarly Writing: Cross-Disciplinary Study. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/52935>.
 - [30] Chelli M., Descamps J., Lavoué V., Trojani C., Azar M., Deckert M., Raynier J.-L., Clowez G., Boileau P. ja Ruetsch-Chelli C. Hallucination Rates and Reference Accuracy of ChatGPT and Bard for Systematic Reviews: Comparative Analysis. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/53164>.
 - [31] Kim E., Kipchumba F. ja Min S. Geographic Variation in LLM DOI Fabrication: Cross-Country Analysis of Citation Accuracy Across Four Large Language Models. *Publications* (2025). <https://doi.org/10.3390/publications13020020>.

- [32] Doshi A. R. ja Hauser O. P. Generative AI Enhances Individual Creativity but Reduces the Collective Diversity of Novel Content. *Science Advances* 10.28 (2024). <https://doi.org/10.1126/sciadv.adn5290>.
- [33] Bender E. M., Gebru T., McMillan-Major A. ja Shmitchell S. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of FAccT* (2021), lk 610–623. <https://doi.org/10.1145/3442188.3445922>.
- [34] Tuulik M., Vainik E., Prangel J., Langemets M., Aedmaa E., Koppel K. ja Risberg L. Tähenduste seletamine leksikograafias: kuivõrd on abi suurtest keelemudelitest? *Eesti ja soome-ugri keeleteaduse ajakiri. Journal of Estonian and Finno-Ugric Linguistics* 16.2 (2025). Viimati vaadatud: 01.03.2026. <https://ojs.utlib.ee/index.php/jeful/article/view/24835>.
- [35] Tartu Ülikool, Loodus- ja täppisteaduste valdkond. Loodus- ja täppisteaduste valdkonna lõputööde juhend. <https://reaalteadused.ut.ee/et/loputoode-juhendid>. Viimati vaadatud: 20.02.2026. 2025.
- [36] Google. Gemini API Pricing. <https://ai.google.dev/gemini-api/docs/pricing>. Viimati vaadatud: 24.04.2026. 2026.
- [37] Bianchi F., Suzgun M., Attanasio G., Röttger P., Jurafsky D., Hashimoto T. ja Zou J. Safety-Tuned LLaMAs: Lessons From Improving the Safety of Large Language Models that Follow Instructions. *arXiv preprint arXiv:2309.07875* (2023). <https://arxiv.org/abs/2309.07875>.
- [38] OpenAI. API Pricing. <https://openai.com/api/pricing/>. Viimati vaadatud: 24.04.2026. 2026.
- [39] Anthropic. Claude API Pricing. <https://www.anthropic.com/pricing>. Viimati vaadatud: 24.04.2026. 2026.
- [40] Ji B., Liu H., Du M. ja Ng S.-K. Chain-of-Thought Improves Text Generation with Citations in Large Language Models. *Proceedings of the AAAI Conference on Artificial Intelligence*. Kd 38. 16. 2024, lk 18345–18353. <https://doi.org/10.1609/aaai.v38i16.29794>.
- [41] Barbu E., Muru M.-L. ja Malva S. M. Improving Estonian Text Simplification through Pretrained Language Models and Custom Datasets. *arXiv preprint arXiv:2501.15624* (2025). <https://arxiv.org/abs/2501.15624>.

- [42] DataStudios. Perplexity AI Context Window: Token Limits, Memory Policy, and 2025 Rules. <https://www.datastudios.org/post/perplexity-ai-context-window-token-limits-memory-policy-and-2025-rules>. Viimati vaadatud: 14.03.2026. 2025.
- [43] GitHub. About Individual GitHub Copilot Plans and Benefits. <https://docs.github.com/en/copilot/concepts/billing/individual-plans>. Viimati vaadatud: 14.03.2026. 2026.
- [44] GitHub. Responsible Use of GitHub Copilot Chat in Your IDE. <https://docs.github.com/en/copilot/responsible-use-of-github-copilot-features/responsible-use-of-github-copilot-chat-in-your-ide>. Viimati vaadatud: 14.03.2026. 2026.
- [45] Nguyen N. ja Nadi S. An Empirical Evaluation of GitHub Copilot's Code Suggestions. *Proceedings of the 19th International Conference on Mining Software Repositories (MSR)*. 2022, lk 1–5. <https://doi.org/10.1145/3524842.3528470>.
- [46] GitHub. Rate Limits for GitHub Copilot. <https://docs.github.com/en/copilot/concepts/rate-limits>. Viimati vaadatud: 14.03.2026. 2026.
- [47] Kresevic S., Giuffrè M., Ajčević M., Accardo A., Crocè L. ja Shung D. Optimization of Hepatological Clinical Guidelines Interpretation by Large Language Models: A Retrieval Augmented Generation-Based Framework. *NPJ Digital Medicine* 7 (2024). <https://doi.org/10.1038/s41746-024-01076-x>.
- [48] OpenAI. Codex: OpenAI's Coding Agent in ChatGPT. <https://openai.com/index/introducing-codex/>. Viimati vaadatud: 16.03.2026. 2025.

Lisad

I. Eksperimendis kasutatud prompt

Käesoleva uurimuse eksperimendis kasutati kõigi nelja mudel-tööriista kombinatsiooni puhul üht ja sama lühikest eestikeelset viibet ehk ühe kasutajaviibega (*single-prompt*) lähenemist. Viibet ei muudetud ega iteratiivselt täiendatud. Täisviibe oli järgmine:

“Sa oled kogenud akadeemiline kirjutaja. Loo täielik bakalaureusetöö LaTeX-vormingus (lisisin töökausta vajaliku malli), mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele. Teema peab olema informaatikaga seotud ja vali ise. Autor on Uku Renek Kronbergs ja juhendaja Alo Peets (MSc).”

Viipe sisulised elemendid:

- **Mudeli roll** – “kogenud akadeemiline kirjutaja” kui üldine stiiliviide.
- **Ülesanne** – täieliku bakalaureusetöö loomine.
- **Vorm** – LaTeX-vorming koos viitega töökausta paigutatud UniTartuCS mallile.
- **Nõue** – vastavus Tartu Ülikooli arvutiteaduse instituudi nõuetele.
- **Teema** – informaatikaga seotud, valitakse mudeli poolt iseseisvalt.
- **Tiitellehe andmed** – autor Uku Renek Kronbergs, juhendaja Alo Peets (MSc).

Viibesse ei lisatud:

- TÜ ATI ega LOTE lõputööde juhendite teksti;
- varasemate bakalaureusetööde näiteid;
- detailseid juhiseid peatükkide struktuuri, mahu või sisu kohta;
- viitamisstiili juhiseid;
- keelelisi korrektuureegleid.

Sellise minimaalse viipe eesmärk oli hinnata, kuidas mudelid interpreteerivad võimalikult lühikest juhust ning millistele eelteadmistele nad toetuvad eestikeelse akadeemilise lõputöö loomisel.

II. Genereeritud tööde failid

Eksperimendi tulemusena valmisid järgmised PDF-failid. Failid on kaasas käesoleva lõputöö lähtematerjalidega ning nende muutumatuse kontrollimiseks on allpool esitatud SHA-256 räsid. Kõik failid on saadaval töö avalikus GitHub-repositooriumis (https://github.com/UkuRenekKronbergs/bakalaureusetoo_isiklik, alamkaust Genereeritud lõputööd/) ning lõputöö lähtematerjalide pakettis.

- `Sonnet_4.6_Cowork.pdf` – Claude Sonnet 4.6 + Cowork kombinatsiooni genereeritud 40-leheküljeline eestikeelne lõputöö TI-põhise lõputöö genereerimise teemal.
- `Opus_4.6_Cowork.pdf` – Claude Opus 4.6 + Cowork kombinatsiooni genereeritud 61-leheküljeline eestikeelne lõputöö paroolihalduri teemal.
- `Gemini_3.1_Pro_Antigravity.pdf` – Gemini 3.1 Pro + Antigravity kombinatsiooni genereeritud 39-leheküljeline eestikeelne lõputöö GenAI mõjust algajate programmeerijate produktiivsusele.
- `GPT_5.4_Visual_Studio_Codex.pdf` – GPT-5.4 + ChatGPT Codex (VS Code) kombinatsiooni genereeritud 47-leheküljeline eestikeelne lõputöö RAG-põhise küsimus-vastus süsteemi teemal.

Genereeritud PDF-failide SHA-256 räsid autentsuse kontrollimiseks:

`Sonnet_4.6_Cowork.pdf`

```
1429db13cc7ba2c16c888b857a88e56d  
a5a30821c61fdc3d029e9821ea409fdd
```

`Opus_4.6_Cowork.pdf`

```
982440f59df317164e94834a7aa9607e  
af851aaf3411754cd6af2b3e0584433b
```

`Gemini_3.1_Pro_Antigravity.pdf`

```
eafe3da2a623443a50bd9e61ceb5efb3  
4f7444b54247c735f80d03988e0a886b
```

`GPT_5.4_Visual_Studio_Codex.pdf`

```
4894baef65b7e4ecb404356ea9014607  
8310d3b2dfc09e376d3fbd3bbec8a20f
```

Kõik neli PDF-faili genereeriti eksperimendi raames 2026. aasta märtsis. Retsensendi või kaitsmiskomisjoni liige saab iga PDF-faili autentsust kontrollida, laadides faili alla eelnimetatud repositooriumist ning arvutades SHA-256 räsi (nt `sha256sum` käsuga); saadud väärtus peab kattuma ülaltoodud 64-tähemärgilise räsi (ülemine ja alumine rida kokku).

III. Tervikliku lõputöö genereerimise näited

Järgnevalt on esitatud väljavõtted eksperimendis genereeritud terviklikest lõputöödest. Iga mudeli väljundist on toodud sissejuhatuse algus, et illustreerida erinevusi keeles, stiilis ja teemale vastavuses.

III.1 Claude Sonnet 4.6 (Cowork) – sissejuhatuse väljavõte (40 lk)

Tehisintellekti (TI) kiire areng viimastel aastatel on toonud kaasa põhjalikud muutused paljudes eluvaldkondades, sealhulgas hariduses ja akadeemilises kirjutamises. Suurte keelemudelite (Large Language Models, LLM) nagu OpenAI GPT-seeria, Google Gemini ja Anthropic Claude võimekus genereerida inimkeelset teksti on saavutanud taseme, mis sunnib ümber hindama traditsioonilisi arusaamu teksti loomisest, toimetamisest ja kvaliteedikontrollist. Eriti aktuaalne on küsimus, mil määral suudavad need mudelid toime tulla väiksemate keelte, nagu eesti keel, ning spetsiifiliste akadeemiliste nõuetega.

[...] Käesoleva bakalaureusetöö eesmärk on uurida tehisintellekti rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel.

Hinnang: Töö järgib Tartu Ülikooli struktuurinõudeid ja on eestikeelne, akadeemilises stiilis. Sisaldab 17 viidet, millest märkimisväärne osa on hallutsineeritud (ca 20%). Peamine puudus: mõned viited on hallutsineeritud ning lauseehitus on kohati ülemääraselt keerukas. Huvitav kokkusattumus: mudel valis teemaks TI-põhise lõputöö genereerimise, mis ühtib käesoleva bakalaureusetöö teemaga.

III.2 GPT-5.4 (vestlusliides) – väljundi väljavõte (8 lk, teostatavusjuhend)

“A complete, submission-ready bachelor’s thesis written end-to-end on your behalf is not something I can produce. That would materially enable academic misconduct (submitting work largely authored by a third party). What I can provide—aligned with the University of Tartu’s own principles for using generative AI in coursework—is a deep-research ‘thesis kit’: a rigorously sourced background review, a defensible experimental design, an evaluation rubric, and a UniTartuCS-template-aligned

LaTeX project skeleton with chapter-by-chapter writing prompts and clearly marked placeholders that you must complete, verify, and take responsibility for.”

Hinnang: GPT-5.4 keeldus ülesannet täitmast ja valis väljundkeeleks inglise keele. Pakkus selle asemel teostatavusjuhendit, mis sisaldas mudelivaliku soovitusi, eksperimendi disaini raamistikku ja LaTeX malli juhiseid. Viited on verifitseeritud ja sisukad. Akadeemilise aususe teadlikkus on silmapaistvalt tugev. Sama mudel sama promptiga Codex-laienduse kaudu Visual Studio Code’is genereeris aga tervikliku 47-leheküljelise eestikeelse töö – vt III.3.

III.3 GPT-5.4 (Codex VS Code’is) – sissejuhatuse väljavõte (47 lk)

Käesolevas bakalaureusetöös kavandatakse eestikeelse RAG-põhise küsimus-vastus süsteemi kontseptsioon ja prototüüp. Süsteemi keskmes on retriiveri ja keelemudeli integreeritud arhitektuur, mis võimaldab leida asjakohased dokumendilõigud ja genereerida nende põhjal eestikeelseid vastuseid.

Hinnang: Sama mudel ja sama prompt kui vestlusliideses, kuid agentse töövoos kaudu andis täiesti erineva tulemuse. Keelevalik eesti keel, struktuur vastab bakalaureusetöö vormile, ortograafiline täpsus silmapaistvalt kõrge (vaid 1 kirjaviga kogu töö peale). Viited (22 unikaalset) on suures osas kontrollitavad.

III.4 Gemini 3.1 Pro (Antigravity) – sissejuhatuse väljavõte (39 lk)

“Generatiivse tehisintellekti (GenAI) ja suurte keelemudelite (LLM), nagu OpenAI GPT-seeria, Anthropic Claude ja spetsiifiliste koodiassistentide (GitHub Copilot, Cursor) tormiline areng ja kättesaadavus on toonud kaasa ajaloolise paradigma muutuse globaalses tarkvaraarenduses.”

“Käesoleva ulatusliku uurimuse peamine eesmärk on lahti mõtestada ja dekonstrueerida tehisintellekti tegelik, mitmetahuline ja sageli vastuoluline mõju tarkvaraarenduse produktiivsusele.”

Hinnang: Gemini 3.1 Pro + Antigravity kombinatsioon genereeris vormiliselt korrektse töö generatiivse TI mõjust tarkvaraarendusele – väidetavalt Tartumaa IT-ettevõtete (nt Nortal, Playtech, Datafox) algajate programmeerijate näitel. Kuigi teema on informaatikaga seotud ja seega viipele vastav, on kogu selles kirjeldatud empiiriline osa – 30 tudengiga kvaasi-eksperiment, testikeskkond, statistilised tulemused ning kohalike ettevõtete osalus – fabritseeritud: reaalseid tudengeid, katseid ega andmeid ei eksisteeri ja ettevõtete nimed on lisatud ilma nende kinnitusega.

Eestikeelne tekst on ladus, kuid sisaldab kõige rohkem kirjavigu (28) kogu võrdluses. Seda juhtumit käsitletakse töös akadeemilise väärkasutuse kõrge riskiga juhtumina (vt peatükk 5.4).

III.5 Claude Opus 4.6 (Cowork) – sissejuhatuse väljavõte (61 lk)

Paroolide turvaline haldamine on kaasaegse digiühiskonna üks fundamentaalsemaid väljakutseid. Keskmise internetikasutaja haldab kümneid kuni sadu kontosid erinevates veebiteenustes, mis loob vajaduse usaldusväärse ja kasutajasõbraliku paroolihaldussüsteemi järele. Kuigi turukitsenduste tõttu domineerivad valdkonda suletud lähtekoodiga kommertslahendused nagu 1Password, LastPass ja Bitwarden, jääb avatud ja läbipaistev alternatiiv, mis pakub nullteadmise (zero-knowledge) arhitektuuri koos kaasaegse krüptograafilise kaitsetasemega, endiselt aktuaalseks uurimisteenaks.

Käesoleva bakalaureusetöö eesmärk on projekteerida ja arendada turvaline paroolihalduri veebirakendus, mis rakendab nullteadmise arhitektuuri, kasutades AES-256-GCM krüpteeringut ja Argon2id võtmetuletamist. [...]

Hinnang: Opus 4.6 + Cowork kombinatsioon genereeris kõige mahukama ja tehniliselt sügavaima töö. 61-leheküljeline lõputöö sisaldas terviklikku tehnilist arhitektuuri ja koodinäiteid; lisaks väitis töö, et rakendus läbis 149 automatiseeritud testi, OWASP Top 10 analüüsi ja SUS kasutatavusuuringu (skoor 77,0). Neid teste, auditit ega kasutajauuringut ei teostanud käesoleva uurimuse autor iseseisvalt – tegemist on kombinatsiooni enda genereeritud empiiriliste väidetega, mis tuleb inimese poolt kontrollida samamoodi nagu viited. Eestikeelne akadeemiline stiil oli läbivalt suurepärase (0 esimese isiku asesõna terve töö peale). Struktuur vastas TÜ nõuetele. Viidete hallutsineerimise määr oli madalaim (ca 15%). Peamine eelis teiste kombinatsioonide ees: tehniline detailsus, $\LaTeX$ koodi otsene genereerimine failidesse ja võime hallata terviklikku projektistruktuuri.

III.6 Genereeritud tööde võrdlev kokkuvõte

Tabel 12. Tervikliku lõputöö genereerimise koondvõrdlus

Kriteerium	Gemini 3.1 Pro + Antigravity	GPT-5.4 + Codex	Claude Sonnet 4.6 + Cowork	Claude Opus 4.6 + Cowork
Keel	Eesti	Eesti	Eesti	Eesti
Maht	39 lk	47 lk	40 lk	61 lk
Valitud teema	GenAI ja progr.	RAG QA-süsteem	TI lõputöö gener.	Paroolihaldur
Struktuur	Lõputöö	Lõputöö	Lõputöö	Lõputöö
Kirjavigu (kogu töö peale)	28	1	13	5
Unikaalseid viiteid	9	22	17	35
Esimese isiku asesõnu	4	2	2	0
Praktiline kasutus alus põhjana	Madal (fabritseeritud empiirika)	Kõrge	Kõrge	Väga kõrge (kontrollimata empiiriliste väidetega)

Litsents

Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks

Mina, Uku Renek Kronbergs,

1. annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) minu loodud teose

“Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine”,

mille juhendaja on Alo Peets (MSc),

reprodutseerimiseks eesmärgiga seda säilitada, sealhulgas lisada digitaalarhiivi DSpace kuni autoriõiguse kehtivuse lõppemiseni.

2. Annan Tartu Ülikoolile loa teha punktis 1 nimetatud teos üldsusele kättesaadavaks Tartu Ülikooli veebikeskkonna, sealhulgas digitaalarhiivi DSpace kaudu Creative Commons'i litsentsiga CC BY NC ND 3.0, mis lubab autorile viidates teost reprodutseerida, levitada ja üldsusele suunata ning keelab luua tuletatud teost ja kasutada teost ärieesmärgil, kuni autoriõiguse kehtivuse lõppemiseni.
3. Olen teadlik, et punktides 1 ja 2 nimetatud õigused jäävad alles ka autorile.
4. Kinnitan, et lihtlitsentsi andmisega ei riku ma teiste isikute intellektuaalomandi ega isikuandmete kaitse õigusaktidest tulenevaid õigusi.

Uku Renek Kronbergs

[kuupäev]