

TARTU ÜLIKOOL
Arvutiteaduse instituut
Informaatika õppekava

Uku Renek Kronbergs

**Teostatavusuuring: Tehisintellekti abil
eestikeelse tehnilise informaatika alase
lõputöö genereerimine**

Bakalaureusetöö (9 EAP)

Juhendaja:
Alo Peets, MSc

Tartu 2026

Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine

Lühikokkuvõte:

Käesolev bakalaureusetöö uurib tehisintellekti (TI) rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Töös võrreldakse nelja suurt keelemudelit koos agentsete tööriistadega: Google Gemini 3.1 Pro koos Antigravityga, OpenAI GPT-5.4 koos ChatGPT Codexi Visual Studio Code'i laiendusega ning Anthropic Claude Sonnet 4.6 ja Claude Opus 4.6 koos Coworkiga. Igale kombinatsioonile anti sama lühike eestikeelne viip, mis palus luua UniTartuCS mallil põhineva L^AT_EX-vormingus bakalaureusetöö, valida ise informaatikaga seotud teema ning järgida Tartu Ülikooli arvutiteaduse instituudi nõudeid. Kuna iga kombinatsiooni kohta tehti üks jooks, käsitletakse tulemusi eksploratiivselt. Väljundeid hinnati struktuuri, mahu, kirjavigade, viidete kontrollitavuse, eestikeelse akadeemilise stiili ja juhiste järgimise põhjal. Tulemused näitavad, et agentsed tööriistad võimaldavad mudelitel luua vormilt terviklikke eestikeelseid lõputöid, kuid kvaliteet, liidesesõltuvus ja riskid erinevad märkimisväärselt. Selles katses andis üldiselt tugevaima väljundi Claude Opus 4.6 + Cowork, samas kui GPT-5.4 + Codex eristus väga väheste kirjavigade ja kontrollitavate viidetega. Gemini 3.1 Pro + Antigravity töö näitas kõige selgemalt vormilise veenvuse ohtu, sest sisaldas täielikult fabritseeritud empiirilist osa. Peamised probleemid olid hallutsineeritud viited, kontrollimata empiirilised väited ja vähene sisuline originaalsus. Töö järeldab, et TI sobib lõputöö kirjutamisel abivahendiks, kuid mitte iseseisvaks autoriks.

Võtmesõnad: tehisintellekt, keelemudelid, lõputöö genereerimine, eesti keel, teostatavusuuring

CERCS: P170 Arvutiteadus

Feasibility Study: Generating an Estonian-Language Technical Computer Science Thesis Using Artificial Intelligence

Abstract:

This bachelor's thesis investigates the feasibility of using artificial intelligence (AI) to generate an Estonian-language technical computer science thesis. The study compares four large language models paired with agentic tools: Google Gemini 3.1 Pro with Antigravity, OpenAI GPT-5.4 with the ChatGPT Codex extension for Visual Studio Code, and Anthropic Claude Sonnet 4.6 and Claude Opus 4.6 with Cowork. Each combination received the same short Estonian-language prompt asking it to produce a $\text{\LaTeX}$ -formatted bachelor's thesis using the UniTartuCS template, choose its own computer-science-related topic, and follow the requirements of the University of Tartu's Institute of Computer Science. Because each combination was run only once, the results are treated as exploratory. The outputs were assessed by structure, length, orthographic accuracy, citation verifiability, Estonian academic style, and instruction following. The results show that agentic tools can help models produce formally complete Estonian-language theses, but quality, interface dependence, and risks vary substantially. In this experiment, Claude Opus 4.6 + Cowork produced the strongest overall output, while GPT-5.4 + Codex stood out for very few spelling errors and fully verifiable citations. The Gemini 3.1 Pro + Antigravity output most clearly demonstrated the risk of formal plausibility, as it contained a wholly fabricated empirical section. The main limitations were hallucinated citations, unverified empirical claims, and limited substantive originality. The thesis concludes that AI is useful as an assistive tool in thesis writing, but not as an independent author.

Keywords: artificial intelligence, language models, thesis generation, Estonian language, feasibility study

CERCS: P170 Computer science

Sisukord

1. Sissejuhatus	6
2. Taust ja kirjanduse ülevaade.....	9
2.1 Suurte keelemudelite areng.....	9
2.2 Eesti keele töötlemine keelemudelites	9
2.3 TI akadeemilises kirjutamises.....	10
3. Metoodika	13
3.1 Mudelite ja tööriistade valiku kriteeriumid.....	13
3.2 Eksperimendi ülesehitus.....	14
3.3 Hindamiskriteeriumid	16
4. TI mudelite võrdlus	18
4.1 Google Gemini 3.1 Pro	18
4.2 OpenAI GPT-5.4.....	18
4.3 Anthropic Claude Sonnet 4.6.....	19
4.4 Anthropic Claude Opus 4.6.....	19
4.5 Mudelite koondvõrdlus	20
5. Eksperiment ja tulemused.....	23
5.1 Eksperimendi ülesehitus.....	23
5.2 Claude Sonnet 4.6 (Cowork).....	24
5.3 GPT-5.4 (Codex)	25
5.4 Gemini 3.1 Pro (Antigravity).....	26
5.5 Claude Opus 4.6 (Cowork)	28
5.6 Kirjavigade ja keeleliste vigade analüüs	29
5.7 Mahu ja struktuuri analüüs.....	31
5.8 Viidete kvantitatiivne analüüs.....	32
5.9 Akadeemiline stiil.....	33
6. Käesoleva bakalaureusetöö enda kirjutamise töövoog	34
6.1 Kasutatud TI tööriist ja mudel	34
6.2 Etapp 1: algne ühe kasutajaviibaga katse sisukorra kavandamiseks	35
6.3 Etapp 2: iteratiivne kirjutamine ja toimetamine	35
6.4 Allikate otsimine ja bibliograafia haldamine.....	36
6.5 Kvantitatiivse analüüsi ja andmete kogumise töövoog.....	37
6.6 Kompileerimine, vormistuse kontroll ja kvaliteedi hindamine.....	37

6.7	Versioonihaldus GitHubi abil	38
6.8	Rollijaotus autori ja TI vahel	38
6.9	Piirangud ja saadud kogemused	39
7.	Arutelu	41
7.1	TI tugevused lõputöö kirjutamisel	41
7.2	TI puudujäägid ja piirangud	42
7.3	Hinnakujundus ja majanduslik teostatavus	43
7.4	Eesti keele korrektuur ja toimetamine	45
7.5	Soovitused TI tööriista valikuks	46
7.6	Soovitused lõputöö genereerimiseks agentsete TI tööriistadega	46
7.6.1	Genereerimise töövoog	46
7.6.2	Parimad praktikad	47
7.7	Tööriistad, mida vältida	48
7.8	Tulevikuväljavaated	49
8.	Kokkuvõte.....	51
	Viited.....	53
	Lisad	58
	I. Eksperimendis kasutatud viip	58
	II. Eksperimendis genereeritud väljundfailid	59
	III. Genereeritud väljundite näited.....	59
	Litsents	64

1. Sissejuhatus

Suured keelemudelid (*Large Language Models*, LLM) on viimaste aastate jooksul liikunud nišikasutusest igapäevaseks töövahendiks, mida kasutatakse tekstide koostamisel, toimetamisel ja struktureerimisel nii ettevõtetes kui ka kõrgkoolides [1]. OpenAI GPT-seeria, Google'i Gemini ning Anthropicu Claude'i mudelid suudavad koostada sidusat akadeemilist teksti, toimetada olemasolevaid dokumente ja genereerida pikemaid struktureeritud kirjalikke töid [2, 3]. Väiksemate keelte, sealhulgas eesti keele, puhul on mudelite kvaliteet ja usaldusväärsus siiski ebaühtlasemad ning nende süstemaatiline hindamine on seni jäänud tagasihoidlikuks [4, 5].

Bakalaureusetöö on Tartu Ülikooli arvutiteaduse instituudis (ATI) esimene suurem iseseisev akadeemiline kirjatöö, mille üliõpilane peab vormistama kehtestatud juhendi kohaselt [6]. Töö valmimine nõuab tavaliselt ühte semestrit, mille käigus tuleb süveneda kirjandusse, kirjeldada meetodikat, esitada tulemused ja järgida akadeemilist stiili. Üliõpilaste seas on viimastel aastatel laialdaselt levinud TI mudelite kasutamine lõputöö kirjutamise abivahendina, kuid senised juhendid ja uurimused ei anna selget pilti sellest, kui usaldusväärselt TI mudelid sellise ülesandega eesti keeles toime tulevad [7, 8]. Eriti oluline on eristada vormiliselt veenvat teksti sisuliselt kontrollitud akadeemilisest tööst: lõputöö puhul ei piisa korrektsest struktuurist ja ladusast keelest, kui viited, andmed või empiirilised väited ei ole kontrollitavad.

Käesoleva bakalaureusetöö eesmärk on hinnata, kas ja millistel tingimustel suudavad kaasaegsed TI mudelid koos tänapäevaste agentsete tööriistadega genereerida eestikeelse tehnilise informaatika lõputöö. Töö ei käsitle mudeleid ainult isoleeritud tekstigeneraatoritena, vaid konkreetsete mudel-tööriista paaridena, sest agentne liides, failisüsteemi ligipääs, kompileerimisvõimekus ja süsteemijuhised mõjutavad lõpptulemust. Töö keskendub järgmistele uurimisküsimustele:

1. Millised kaasaegsete TI mudelite ja agentsete tööriistade kombinatsioonid suudavad luua vormilt tervikliku eestikeelse akadeemilise lõputöö?
2. Kuidas erinevad nende kombinatsioonide väljundid sama lühikese eestikeelse kasutajaviiba korral struktuuri, mahu, keele, viidete, teemavaliku ja juhiste järgimise lõikes?
3. Kuidas mõjutavad kasutusliides ja agentne failipõhine töövoog genereeritud töö kvaliteeti, ülesande tõlgendamist ja akadeemilise aususe piiranguid?

4. Millistes lõputöö kirjutamise etappides suudab TI pakkuda tõhusat abi ning kus on inimese panus endiselt asendamatu?
5. Millised on TI-põhise tekstigenerereerimise praktilised piirangud, sealhulgas hinnakujundus, konteksti haldamine, keelelised puudujäägid, viidete hallutsineerimine ja kontrollimata empiirilised väited?

Eelnevate uurimuste [1, 9, 10] ja autori ettevalmistavate katsete põhjal eeldati, et kõik valitud mudel-tööriista kombinatsioonid suudavad luua vormiliselt veenva eestikeelse tervikteksti, kuid sisulises kvaliteedis, viidete kontrollitavuses ja empiiriliste väidete usaldusväärsuses ilmneksid olulised erinevused. Samuti eeldati, et viidete hallutsineerimine ja fabritseeritud väited jäävad oluliseks akadeemilise aususe riskiks ka 2025. ja 2026. aasta juhtivate keelemudelite puhul.

Uurimuse läbiviimiseks valiti neli suurt keelemudelit koos agentsete tööriistadega: Google Gemini 3.1 Pro koos Antigravityga, OpenAI GPT-5.4 koos ChatGPT Codexi Visual Studio Code'i laiendusega ning Anthropic Claude Sonnet 4.6 ja Claude Opus 4.6 koos Coworkiga. Igale mudel-tööriista kombinatsioonile anti sama lühike eestikeelne viip, mis palus genereerida UniTartuCS malli kasutava $\text{\LaTeX}$ -vormingus bakalaureusetöö. Mudelitele ei antud täiendavaid juhendeid, näidistöid ega iteratiivseid paranduspalveid. Kuna iga kombinatsiooni kohta tehti üks jooks, käsitletakse tulemusi eksploratiivse hinnanguna konkreetsetele töövoogudele, mitte lõpliku mudelite paremusjärjestusena. Väljundeid hinnati struktuuri, mahu, keele- ja kirjavigade, viidete kontrollitavuse, eestikeelse akadeemilise stiili ja juhiste järgimise alusel. Lisaks kirjeldab töö eraldi käesoleva bakalaureusetöö enda kirjutamise töövoogu, et eristada ühe kasutajaviibaga delegerimise stsenaariumi inimese juhitud ja kontrollitud TI kasutusest.

Töö on struktureeritud järgmiselt. Peatükk 2 annab ülevaate suurte keelemudelite arengust, eesti keele töötlemise väljakutsetest ning varasematest uurimustest TI kasutamisest akadeemilises kirjutamises. Peatükk 3 kirjeldab uurimuse metoodikat ja hindamisraamistikku. Peatükk 4 võrdleb valitud mudeleid tehniliste parameetrite, kuluaspektide ja eesti keele toe lõikes. Peatükk 5 esitab ühe kasutajaviibaga genereerimise tulemused. Peatükk 6 kirjeldab käesoleva bakalaureusetöö enda kirjutamise töövoogu ning autori ja TI rollijaotust. Peatükk 7 tõlgendab tulemusi, käsitleb piiranguid ja annab soovitusi. Peatükk 8 võtab töö tulemused kokku.

Töö lõpus on kolm lisa. Lisa 8 esitab eksperimendis kasutatud eestikeelse kasutajaviiba täisteksti ja selle sisuliste elementide analüüsi. Lisa 8 loetleb eksperimendi tulemusena salvestatud PDF-failid (neli tervikut bakalaureusetööd ning üks võrdluseks salvestatud GPT-5.4 vestlusliidese

teostatavusjuhend) koos lehekülgede arvu, mudel-tööriista kombinatsiooni ja teemaga. Lisa 8 sisaldab iga väljundi sissejuhatuse väljavõtteid ja autori lühihinnangut.

Käesoleva bakalaureusetöö enda kirjutamisel kasutati TI tööriistu peamiselt vormistuslike ja keeleliste abivahenditena: Anthropic Claude Code'i (Claude Opus 4.6 ja 4.7 mudelitega) keelelise toimetuse, kirjavigade otsimise, L^AT_EX-vormistuse ja kompileerimisvigade diagnoosimise jaoks. Lisaks OpenAI ChatGPT Codexi (GPT-5.5 mudeliga) täiendava keelelise korrektuuri jaoks. Iga TI-põhine muudatus läbis enne aktsepteerimist autori ülevaatused ning sisulised otsused, allikate valik, eksperimendi disain ja tulemuste tõlgendamine jäid autori vastutusele. Töövoo ja rollijaotuse täpsem kirjeldus on esitatud peatükis 6.

2. Taust ja kirjanduse ülevaade

Käesolev peatükk annab ülevaate suurte keelemodelite arengust, eesti keele töötlemise spetsiifikast ning varasematest uurimustest tehisintellekti kasutamisest akadeemilises tekstiloomes.

2.1 Suurte keelemodelite areng

Suurte keelemodelite arengu nurgakiviks oli 2017. aastal Vaswani et al. avaldatud transformeri arhitektuur [11], millele tuginesid esimesed märkimisväärsed keelemudelid nagu BERT [12] ja GPT-2 [13]. GPT-3 ilmumine 2020. aastal [2] tõi kaasa paradigmuuutuse, näidates, et 175 miljardi parameetriga mudel suudab täita mitmesuguseid ülesandeid ilma spetsiifilise peenhäälestamiseta (*fine-tuning*). Sellest ajast on mudelid kiiresti arenenud nii suuruse, arhitektuuri kui ka võimekuse poolest.

2.2 Eesti keele töötlemine keelemudelites

Eesti keel kuulub soome-ugri keelkonda ja on morfoloogiliselt rikas keel 14 käändega ning keerulise sõnamoodustuse süsteemiga [14]. See eripära teeb eesti keele töötlemise keelemudelite jaoks oluliselt keerulisemaks kui näiteks inglise keele puhul.

Suurte keelemodelite eesti keele oskus sõltub muu hulgas treeningandmete mahust ja kvaliteedist. Common Crawl'i 2026. aasta statistika järgi moodustas eesti keel HTML-lehtede põhikeelena viimastes crawl'ides ligikaudu 0,14%, samal ajal kui inglise keele osakaal oli üle 40% [15]. LLM-ide treeninguks puhastatud CulturaX andmestikus on vahe samas suurusjärgus: eesti keelt on 8,8 miljardit tokenit ehk 0,14%, inglise keelt aga 2,85 triljonit tokenit ehk 45,13% [16].

Tartu Ülikooli keeletehnoloogia uurimisrühm on teinud märkimisväärsed tööd eesti keele ressursside ja tööriistade arendamisel. EstBERT [17] on eesti keelele kohandatud BERT mudel, mis on treenitud eestikeelse tekstikorpusel. Hiljutine EstLLM projekt [5] on teinud olulisi edusamme suurte keelemodelite eesti keele võimekuse parandamisel, kasutades jätkutreenimist (*continued pretraining*) ja järeltreenimist (*post-training*) mitmekeelsete mudelite baasil. Uurimus näitas, et spetsialiseeritud treeninguga saab eesti keele kvaliteeti oluliselt tõsta, ilma et mudeli üldine arutlusvõimekus kannataks.

Mitmekeelsete mudelite arendamise seisukohast väärib esiletõstmist Aya mudel [18], mis on juhendipõhiselt peenhäälestatud avatud lähtekoodiga keelemudel, mis toetab 101 keelt, sealhulgas mitmeid väikese ressursiga keeli. Aya ületas mT0 ja BLOOMZ mudeleid enamikus

ülesannetes, demonstreerides, et sihipärase mitmekeelse peenhäälestamisega on võimalik oluliselt parandada väikeste keelte kvaliteeti. Kuulmets et al. [4] süstemaatiline hindamine näitas, et soome-ugri keelte, sealhulgas eesti keele, tugi avatud keelemudelites on viimastel aastatel kiiresti paranenud, kuid jääb endiselt inglise keelest oluliselt maha. Suurte keelemodelite puhul on ka eesti keele kvaliteet viimase kahe aasta jooksul märgatavalt paranenud. Kui varasemad GPT-3-põhised mudelid tegid eesti keeles sageli lihtsalt märgatavaid grammatilisi vigu, siis GPT-5.4, Gemini 3.1 Pro, Claude Sonnet 4.6 ja Claude Opus 4.6 suudavad luua grammatiliselt suures osas korrektset eesti keelt. Siiski esineb endiselt probleeme tehnilise terminoloogiaga, akadeemilise stiiliga ning pikematel tekstidel keelelise järjepidevuse hoidmisega. Kiil [19] on Tartu Ülikooli bakalaureusetöös võrrelnud suuri keelemudeleid eesti bioloogiaolümpiaadi küsimuste põhjal. Parim mudel saavutas 85,35% täpsuse, mis on võrreldav olümpiaadiosalejate tipptulemusega. See kinnitab mudelite kasvavat võimekust ka eestikeelsetes ainespetsiifilistes ülesannetes.

2.3 TI akadeemilises kirjutamises

Tehisintellekti kasutamine akadeemilises kirjutamises on muutunud väga aktuaalseks teemaks. Liang et al. [1] leidsid, et TI-genereeritud teksti osakaal teadusartiklites on märkimisväärselt kasvanud, eriti arvutiteaduse ja meditsiini valdkonnas. See tõstatab küsimusi akadeemilise aususe, originaalsuse ja kvaliteedikontrolli kohta.

Mitmed ülikoolid, sealhulgas Tartu Ülikool, on kehtestanud juhised TI kasutamiseks akadeemilises töös [6]. Üldiselt on lubatud kasutada TI-d abivahendina, kuid üliõpilane peab selgelt märkima, millises ulatuses ja millisel eesmärgil TI kasutati. Lõputöö ei tohi olla sisuliselt TI-genereeritud, vaid üliõpilane peab demonstreerima iseseisvat analüütilist mõtlemist.

Rodafinos [8] rõhutab, et generatiivsete TI tööriistade vastutustundlik integreerimine akadeemilisse kirjutamisse on hädavajalik, tuues esile nii efektiivsuse kasvu kui ka kvaliteedi paranemise, kuid rõhutades samas TI väljundite kontrollimise ja inimese järelevalve säilitamise vajadust. Lund et al. [7] leidsid 401 USA üliõpilase küsitluses, et tudengite eetilised veendumused, mitte institutsionaalsed poliitikad, on tugevaim ennustaja TI kasutamise tajumisel akadeemilise väärkäitumisena.

Varasemad uurimused on näidanud, et TI mudelid on eriti kasulikud järgmistes akadeemilise kirjutamise aspektides:

- **Teksti struktureerimine** – mudelid aitavad koostada tekstikavandeid, peatükkide ülesehitust ja kavandipõhist mustandit; Lee et al. [20] näitasid, et eksplitsiitsed kavandid parandavad eri LLM-ide loodud tekstide kvaliteeti.
- **Kirjanduse ülevaade** – mudelid suudavad toetada kirjanduse kogumist, organiseerimist, kokkuvõtmist ja sünteesimist, kuigi allikate täpsus vajab kontrollimist [21, 22].
- **Keeleline toimetamine** – ChatGPT, Claude'i, Gemini ja Copiloti tüüpi tööriistad võivad aidata grammatika, sõnastuse, sidususe ja loetavuse parandamisel, kuid nende väljund ei ole inimtoimetajaga samaväärselt usaldusväärne [23].
- **Tõlkimine** – GPT-, Claude'i, Gemini ja DeepSeeki tüüpi mudelid suudavad pakkuda kasutatava kvaliteediga tõlkeid akadeemilisest ja tehnilisest tekstist, kuid valdkonnaspetsiifiline järeltoimetamine jääb vajalikuks [24].

Samas on tuvastatud olulisi puudujääke:

- **Hallutsinatsioonid** – mudelid võivad genereerida faktiliselt valesid väiteid või olematuid viiteid. Mugaanyi et al. [9] leidsid, et ChatGPT 3.5 genereeritud viidetest olid 72,7% loodusteadustes ja 76,6% humanitaarteadustes küll olemasolevad, kuid DOI-de ehk digitaalsete objektiidentifikaatorite (*Digital Object Identifier*) täpsus oli vaid 32,7% ja 8,5% vastavalt. Uuemad hindamised näitavad, et probleem püsib ka kirjanduse ülevaate koostamise ja veebipõhiste agentsete töövoogude puhul: Tang et al. [21] tuvastasid hallutsineeritud viiteid ka arenenud mudelite loodud kirjandusülevaadetes ning Rao ja Callison-Burch [25] hindasid GPT-5, Claude Sonnet 4.6 ja Gemini 3 Flashi veebipõhiseid väljundeid ning leidsid, et loodud BibTeX-kirjetest olid täielikult korrektsed vaid 50,9% (üldine täpsus oli 83,6%). Kim et al. [10] tuvastasid lisaks, et hallutsinatsioonimäärad on geograafiliselt ebavõrdsed – madalama sissetulekuga riikide kontekstis ületas DOI hallutsinatsioonimäär 80%.
- **Sisuline sügavus** – TI-genereeritud tekstid kipuvad olema pealiskaudsed ja väga üldistavad. Peters ja Chin-Yee [26] näitasid 4900 teaduskokkuvõtte põhjal, et ChatGPT-4o, ChatGPT-4.5, DeepSeek, LLaMA 3.3 70B ja Claude 3.7 Sonnet kaldusid teadustulemusi üleüldistama; DeepSeek, ChatGPT-4o ja LLaMA 3.3 70B puhul esines seda 26–73% juhtudest.
- **Originaalsus** – keelemudelid ei loo iseseisvalt uusi teadmisi, vaid kombineerivad olemasolevat informatsiooni. Doshi ja Hauser [27] leidsid, et generatiivne TI võib

suurendada üksiku teksti loomingulisust, kuid vähendada samal ajal tekstikorpuse mitmekesisust. See toetab varasemat kriitikat mudelite tulemusliku olemuse kohta [28].

- **Väikeste keelte spetsiifika** – eesti keele ja teiste väikeste keelte puhul on kvaliteet ebaühtlasem kui inglise keeles. Kuulmets et al. [4] näitasid, et soome-ugri keelte tugi avatud keelemudelites on paranenud, kuid jääb suurtest keeltest korralikult maha. Lillepalu ja Alumäe [29] rõhutavad emakeelsete eesti keele testide vajalikkust ning EstLLM projekt [5] näitab, et eesti keele kvaliteet paraneb märgatavalt alles sihipärase jätkutreenimise ja järeltreenimisega.

Need TI mudelite üldised tugevused ja puudujäägid kujundavad taustaraamistiku, mille suhtes käesolev töö hindab konkreetsete mudel-tööriista kombinatsioonide käitumist eestikeelse lõputöö genereerimisel. Empiiriline võrdlus ja selle tulemused on esitatud peatükis 5, eelnenud metoodilised valikud aga peatükis 3.

3. Metoodika

Käesolev peatükk kirjeldab uurimuse metoodikat, sealhulgas TI mudelite ja agentsete tööriistade valiku kriteeriume, eksperimendi ülesehitust, ühe kasutajaviibaga (*single-prompt*) lähenemise sisu ning hindamiskriteeriumeid.

Terminoloogilise täpsuse huvides tuleb märkida, et käesolev katse ei ole *one-shot*-lähenemine selle tavapärasel masinõppe tähenduses, sest mudelile ei antud ühtegi näidislahendust. Mudelile anti üks lühike kasutajaviip ilma näideteta – seetõttu on viiba sisu mõttes täpsem kirjeldada katset kui ühe kasutajaviibaga *zero-shot* ehk *single-turn zero-shot prompting* lähenemist. Samas ei olnud kõik katsed täielikult mälukontekstist isoleeritud: kuna kasutatud tööriistade või kasutajakonto püsiv mälu võis säilitada varasemate katsete kohta infot, tuleb tulemusi käsitleda mitte rangelt sõltumatute *clean-context* katsetena, vaid praktilise kasutusolukorra simulatsioonina. Agentse tööriista sees võis mudel teha mitu sammu, näiteks faile lugeda, kirjutada, L^AT_EX-i kompileerida ja vigu parandada, kuid kasutajapoolne sekkumine piirdus ühe algse viibaga.

3.1 Mudelite ja tööriistade valiku kriteeriumid

Uurimuse jaoks mudelite valimisel lähtuti järgmistest kriteeriumidest:

1. **Eesti keele tugi** – mudel peab suutma genereerida grammatiliselt korrektset eesti keelt ning mõistma eestikeelset sisendit.
2. **Kontekstiakna suurus** – bakalaureusetöö genereerimine eeldab mahuka konteksti (juhendid, varasemalt genereeritud osad, L^AT_EX mall) töötlemist, mistõttu on vajalik piisavalt suur kontekstiaken.
3. **Agentsus ja dokumentatsioon** – mudel-tööriista kombinatsioon peab võimaldama agentset töövoogu ning omama piisavat dokumentatsiooni. Agentsuse all mõistetakse siin võimet täita kasutaja eesmärgi mitmes järjestikuses sammus, kasutades vajadusel tööriistu ja failisüsteemi: lugeda olemasolevaid faile, luua või muuta L^AT_EX faile, käivitada kompileerimist ning parandada tekkinud vigu ilma iga sammu jaoks eraldi kasutajaviipa vajamata.
4. **Väljundi kvaliteet** – mudel peab suutma genereerida akadeemilisele tekstile omast stiili, struktuuri ja sisu, mis vastab Tartu Ülikooli bakalaureusetöö nõuetele.
5. **Väljundi järjepidevus** – mudel peab suutma hoida järjepidevat stiili, teemat ja struktuuri kogu töö ulatuses, mis on eriti oluline pikemate tekstide puhul.

6. **Hallutsinatsioonide tase** – mudel peab suutma genereerida võimalikult vähe faktivigu ja olematuid viiteid, mis on akadeemilises tekstis eriti problemaatiline.

7. **Hind** – mudeli kasutamine peab olema majanduslikult mõistlik üliõpilase jaoks.

Nende kriteeriumide alusel valiti neli mudelit: Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ning Anthropic Claude Opus 4.6. Opus 4.6 lisati võrdlusse kui sama mudeliperekonna võimekaim mudel, et hinnata mudeli suuruse mõju genereeritud teksti kvaliteedile. Valiku põhjendused on esitatud peatükis 4.

Lisaks valitud mudelitele testis autor ettevalmistavas faasis ka teisi keelemudeleid, sealhulgas xAI Grok 4.1 ja Moonshot AI Kimi 2.5. Samuti katsetati valitud mudelite kasutamist erinevates keskkondades ja tööriistades, näiteks Google AI Studios, Claude'i veebiliideses, ChatGPT veebiliideses ja Google Gemini veebiliideses. Need eelkatsed näitasid, et sama mudeli käitumine sõltub oluliselt kasutatavast liidest ja sellest, kas tööriist võimaldab agentset failipõhist töövoogu. Grok 4.1 ja Kimi 2.5 jäeti peaaeksperimenti võrdlusest välja, kuna autor ei suutnud erinevate viibavariantidega saada nendelt ülesandele vastavat väljundit. Genereeritud tekstide vormistus oli järjekindlalt ebakorrekne ning väljund ei vastanud bakalaureusetöö struktuurile. Seetõttu keskenduti neljale eelnimetatud mudelile ja nende tööriistadele, mis suutsid tervikliku ja kompilleeruva lõputöö genereerida.

Kuna käesolev eksperiment nõudis failisüsteemi ligipääsu ja L^AT_EX kompileerimist, ei saanud mudeleid kasutada puhta vestlusliidese kaudu. Iga mudeli kohta kasutati selle mudeli pakkuja ametlikku või laialt kasutatavat agentset tööriista: Claude Sonnet 4.6 ja Opus 4.6 puhul Anthropicu Claude Cowork, Gemini 3.1 Pro puhul Google'i Antigravity ning GPT-5.4 puhul ChatGPT Codexi Visual Studio Code'i laiendust. Oluline on rõhutada, et eksperimentis võrreldud üksused ei ole niivõrd “mudelid iseenesest”, vaid rohkem *mudeli ja agentse tööriista kombinatsioonid*. Seetõttu tuleb tulemusi tõlgendada konkreetsete mudel-tööriista paaride, mitte puhaste mudeli võimekuste näitajatena – süsteemijuhised, faili ligipääs, automaatne kompileerimine ja liidese ohutuspoliitika erinevad tööriistade lõikes ning mõjutavad väljundit. Seda piirangut on täiendavalt käsitletud peatükis 7.2.

3.2 Eksperimenti ülesehitus

Uurimus piirdus ühe eksperimentiga: igale mudel-tööriista kombinatsioonile anti üks ja sama lühike eestikeelne kasutajaviip ning lasti agentsel töövool genereerida terviklik bakalaureusetöö ilma järelküsimate, iteratiivse suunamise või peatükkide kaupa juhendamiset. Selline ühe

kasutajaviibaga lähenemine valiti teadlikult kahel põhjusel. Esimene põhjus on see, et lähenemine kajastab kõige ausamalt seda, kuidas keelemudelit kasutaks üliõpilane, kes soovib lõputöö kirjutamist TI-le täielikult delegeerida – see on stsenaarium, mida akadeemilise aususe kontekstis on oluline hinnata. Teine põhjus on see, et identne minimaalne sisend võimaldab nelja mudel-tööriista kombinatsiooni väljundeid kõige otsesemalt võrrelda, kuna ühtegi kombinatsiooni ei eelistata täiendava konteksti, viipade disaini (*prompt engineering*) ega iteratiivse parandamise kaudu. Kuna iga kombinatsiooni kohta tehti üks jook, on saadud näitajad eksploratiivsed – need iseloomustavad konkreetset katset, mitte üldist mudelivõimekust.

Kasutatud viip. Kõigile mudelitele anti järgmine eestikeelne viip (täistekst on esitatud lisas I):

“Sa oled kogenud akadeemiline kirjutaja. Loo täielik bakalaureusetöö LaTeX-vormingus (lisasin töökausta vajaliku malli), mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele. Teema peab olema informaatikaga seotud ja vali ise. Autor on Uku Renek Kronbergs ja juhendaja Alo Peets (MSc).”

Viip on teadlikult lühike ja sisaldab vaid kolme sisulist piirangut: (1) väljund peab olema LaTeX-vormingus ja kasutama töökaustas olevat UniTartuCS malli; (2) töö peab vastama Tartu Ülikooli arvutiteaduse instituudi nõuetele; (3) teema peab olema informaatikaga seotud, kuid konkreetse teemavaliku teeb mudel ise. Autori ja juhendaja nimed anti tiitellehe täitmiseks. Ülikooli lõputööde juhendeid (TÜ ATI ega LOTE juhendit), varasemaid näidistöid ega muud täiendavat konteksti viibasse ei lisatud.

Agentsete tööriistade kasutamine. Kuna viip nõuab LaTeX-malli kasutamist, mitme faili haldamist ja kompileeritavat väljundit, ei saanud eksperimenti läbi viia puhta vestlusliidese kaudu, kus mudel ei suuda ise failisüsteemile ligi pääseda. Veebipõhistes vestlusliideses piiravad sellist ülesannet ka failide koguse limiidid: Gemini Apps lubab samas viibas üles laadida kuni 10 toetatud faili, erandina ühe koodikausta või GitHubi repositooriumi kuni 5000 failiga [30]. Claude'i chat lubab kuni 20 faili vestluse kohta [31] ChatGPT piirab tavapäraseid ChatGPT üleslaadimisi kuni 80 faili kolme tunni jooksul või tasuta kontol 3 faili päevas [32]. See oli üks põhjustest, et miks kasutati iga mudeliga sellele omast agentset töövoogu:

- **Claude Sonnet 4.6** ja **Claude Opus 4.6** – Anthropicu *Cowork* agentne tööriist (mitte segi ajada sama ettevõtte eraldi tootega Claude Code), mis suudab lugeda, kirjutada ja kompileerida projekti L^AT_EX faile otse failisüsteemis.

- **Google Gemini 3.1 Pro** – Google'i *Antigravity* agentne arenduskeskkond, mis pakub funktsionaalselt sarnast võimekust.
- **OpenAI GPT-5.4** – OpenAI *ChatGPT Codex* laiendusega Visual Studio Code'is.

Kõigi nelja mudeli puhul piirduti ühe viibaga – pärast viiba esitamist ei antud mudelile täiendavaid juhiseid, ei parandatud genereeritud teksti ega palutud mudelil varasemaid valikuid üle vaadata. Kui mudel ise tegi agentse tööriista raames mitu sisemist sammu (failide loomine, kompileerimine, vigade parandamine), loeti see üheks genereerimistsükliks, kuna kogu töövoog algatas sama algviip.

Metoodika eelkatsed. Peaeksperimendi metoodika täpsustamiseks tegi autor enne lõpliku eksperimendi läbiviimist ulatuslikke ettevalmistavaid katseid, et leida sobivaim viip, töövoog ja agentsete tööriistade seadistus. Kokku genereeris autor näidis-lõputöid ligikaudu 25 korda, varieerides selleks viiba sõnastust, malli kasutust ja töövoogu. Lõpliku eksperimendi metoodika valiti nende eelkatsete põhjal kui kõige järjepidevama väljundi andev variant. Eelkatsed hõlmasid muu hulgas katsetusi ilma UniTartuCS LaTeX-mallita – ilma mallita jäi väljundi vormistus järjekindlalt ebakorrektses, mistõttu mall jäi viiba lahutamatuks osaks. Ebaõnnestunud eelkatsete üks korduv probleem oli ka väljundi keelevalik: peatükkide pealkirjad olid üldjuhul inglise keeles ning osa põhitekstist genereeriti samuti inglise keeles, kuigi kasutajaviip ise oli eestikeelne. Samuti testis autor alguses lõputöö genereerimist peatükkide kaupa (mudelilt paluti esmalt sissejuhatus, seejärel taust peatükk jne), kuid jõudis kiiresti järeldusele, et terve töö korraga genereerimine ja sellele järgnev iteratiivne käsitsi täiendamine annab oluliselt parema tulemuse nii teksti järjepideva stiili kui ka ajakulu poolest. Käesolevas eksperimendis kasutati selle järelduse põhjal terve lõputöö korraga genereerimist. Mudelite ja tööriistade võrdluse huvides hilisemat iteratiivset suunamist eksperimendi raames ei rakendatud.

Genereeritud väljundid. Eksperimendi tulemusena valis autor neli PDF-failiks kompileeritud bakalaureusetööd (vt peatükk 5); lisaks salvestati GPT-5.4 tavapärase vestlusliidese kaudu saadud keelduv väljund (8-leheküljeline ingliskeelne teostatavusjuhend) võrdluseks. Failide nimekiri koos lehekülgede arvu ja temaga on esitatud lisas 8.

3.3 Hindamiskriteeriumid

Kuna eksperiment tootis neli tervikdokumenti, keskenduti hindamisel kvantitatiivselt mõõdetavatele tunnustele, mida on võimalik genereeritud PDF-idest objektiivselt tuletada. Need

täiendavad töö autori kvalitatiivset üldhinnangut ning vähendavad ühe hindaja subjektiivsusest tulenevat moonutust. Tabelis 1 on esitatud hindamisraamistik.

Tabel 1. Hindamiskriteeriumide raamistik

Kriteerium	Kirjeldus	Hindamisviis
Struktuur ja teemale vastavus	Kas töö järgib bakalaureusetöö ülesehitust (tiitelleht, kokkuvõte, sissejuhatus, peatükid, kokkuvõte, viited) ning kas valitud teema on informaatikaga seotud	Kvalitatiivne kirjeldus
Maht	Lehekülgede arv, sõnade arv ja sõnade tihedus lehekülje kohta	Kvantitatiivne mõõtmine
Keeleline korrektsus	Kirjavigade koguarv ja tihedus lehekülje kohta	Kvantitatiivne loendamine
Viidete kvaliteet	Unikaalsete allikate arv, in-text tsitaatide arv, tsitaatide tihedus lehekülje kohta ning hallutsineeritud viidete hinnanguline osakaal	Kvantitatiivne loendamine + kontroll
Akadeemiline stiil	Ülakomaga anglitsismide arv, arvutiteaduse ingliskeelsete terminite kasutus ning esimese isiku asesõnade esinemine	Kvantitatiivne loendamine
Juhiste järgimine	Väljundkeel (eesti/inglise), L ^A T _E X-vormingu kasutamine, UniTartuCS malli rakendamine, tiitellehe andmed	Binaarne/kvalitatiivne kontroll

Iga kriteeriumi kvantitatiivsed mõõtmised teostati genereeritud PDF-failidest teksti ekstraheerimise teel, jättes välja tiitellehe, kirjanduse loendi ning koodinäited juhtudel, kus see oli meetodiliselt põhjendatud. Hindamise viis läbi käesoleva bakalaureusetöö autor. Ühe hindaja kasutamise piirangut on täpsemalt käsitletud peatükis 7.

Käesolev töö ei sisalda eksplitsiitset kontrollgruppi – ei inimkirjutatud bakalaureusetöö võrdluspunkti ega mudelite mitteagentset baasväljundit (peale GPT-5.4 vestlusliidese erandi, vt peatükk 5.3). Valitud uurimisruum on neli mudel-tööriista kombinatsiooni sama lühikese eestikeelse viiba korral ning eesmärk on neid omavahel võrrelda, mitte hinnata absoluutse bakalaureusetöö kvaliteediläve suhtes. Kontrollgrupi puudumisest tulenevat üldistamispiirangut on käsitletud peatükis 7.2.

4. TI mudelite võrdlus

Käesolev peatükk esitab nelja valitud TI mudeli võrdluse, keskendudes nende tehnilistele parameetritele, agentse töövoos jaoks olulistele omadustele ja kulule. Mudelite koondvõrdlus on esitatud kolme tabelina alapeatükis 4.5: tabel 2 võrdleb tehnilisi parameetreid, tabel 3 võrdleb API hinnakirja näitajaid ning tabel 4 võrdleb lõppkasutaja kuutellimusi. Järgnevad hinnad on kõik Eestis kehtestatud 24% käibemaksuga ja Eesti hinnastusega.

4.1 Google Gemini 3.1 Pro

Google Gemini 3.1 Pro on Google DeepMind'i arendatud multimodaalne keelemudel, mis avaldati 2026. aasta veebruaris [33]. Antud mudel kuulub Gemini mudeliperekonda.

Gemini 3.1 Pro mudelil on kontekstiaken 1 miljon tokenit. Lisaks on Gemini 3.1 Pro natiivne mõtlemismudel (*thinking model*), mis tähendab, et mudel kasutab sisemist ahelpõhjamist enne vastuse andmist; see parandab oluliselt keeruliste ülesannete lahendamise kvaliteeti, sealhulgas struktureeritud teksti loomist.

Kuluaspektist oli Gemini 3.1 Pro API baasmäärade poolest üks soodsamaid võrreldud mudeleid (vt tabel 3). Sisendhind on astmeline ja sõltub konkreetse päringus kasutatava konteksti pikkusest – lühema konteksti puhul (kuni 200 000 tokenit) on sisendhind ca €2,12/MTok ja väljundi hind ca €12,70/MTok, pikema konteksti puhul vastavalt €4,23/MTok ja €19,05/MTok. Lõppkasutajale pakub Google API kõrval ka kuutellimusi: Google AI Studio Plus (7,99€), Google AI Pro (Gemini Advanced) hinnaga €21,99 kuus ja Google AI Ultra (274,99€); üksikasjad on koondatud tabelis 4. Kuna agentne töövoog võib sama faili mitu korda lugeda, kirjutada ja kompileerida, käsitletakse tegelikku kogukulu koondina peatükis 7.3.

4.2 OpenAI GPT-5.4

OpenAI GPT-5.4 on OpenAI juhtiv multimodaalne mudel, mis avaldati 2026. aasta märtsis [34].

GPT-5.4 API kontekstiaken on 1,05 miljonit tokenit; Codexis kirjeldab OpenAI 1M kontekstiakent eksperimentaalse toena ning standardpiiranguna 272K tokenit. Mudel pakub ka mõtlemisrežiimi (*reasoning*), mille intensiivsust saab reguleerida (madal/keskmine/kõrge, väga kõrge), võimaldades kasutajal valida kiiruse ja kvaliteedi vahel.

Kuluaspektist paiknes GPT-5.4 API baasmäärade poolest Sonnet 4.6-ga samasse suurusjärku (vt tabel 3): sisend €2,64/MTok ja väljund €15,87/MTok. Lisaks pakub OpenAI Pakett-API-d (*Batch API*), mis annab asünkroonsete päringute eest ligikaudu 50% allahindlust, kuid pole

interaktiivse agentse töövoo jaoks kasutatav, kuna vastuse ooteaeg võib ulatuda mitme tunnini. Kuutellimustena pakub OpenAI ChatGPT Go (ca €8), ChatGPT Plus (ca €23) ja ChatGPT Pro (ca €229).

4.3 Anthropic Claude Sonnet 4.6

Anthropic Claude Sonnet 4.6 on Anthropicu arendatud keelemudel, mis avaldati 2026. aasta veebruaris [35]. Claude mudeliperekond eristub teistest oma rõhuasetusega ohutusele ja põhjalikkusele.

Claude Sonnet 4.6 kontekstiaken on 200 000 tokenit (API kaudu eraldi 1M tokeni režiim, mida autor ei kasutanud), mis on neljast võrreldud keelemudelist kõige väiksem.

Kuluaspektist oli Claude Sonnet 4.6 API baasmääradega võrreldav GPT-5.4 ja Gemini 3.1 Pro-ga (vt tabel 3): sisend €3,17/MTok ja väljund €15,87/MTok. Kuutellimuste osas pakub Anthropic Eesti regioonis kolme taset: Claude Pro (€22), Claude Max 5× (€106) ja Claude Max 20× (€212).

4.4 Anthropic Claude Opus 4.6

Claude Opus 4.6 on Anthropicu kõige võimekam keelemudel, mis avaldati 2026. aasta veebruaris [36]. Opus kuulub samasse Claude mudeliperekonda kui Sonnet, kuid on oluliselt võimekam mudel. Claude Opus 4.6 kontekstiaken on 1M tokenit, kuid mudeli peamine eelis seisneb paremates agentse töö hindamistulemustes ja sügavamas arutlusvõimekuses.

Opus 4.6 jagab Sonnet 4.6-ga samu agenteid omadusi – pikendatud mõtlemisrežiim, tööriistakasutus, arvutikasutus, selgesõnaline promptide vahemälustamine ning teksti-, pildi- ja PDF-sisendi tugi. Suurema kontekstiakna tõttu (1M vs Sonnet'i 200K) sobib Opus paremini juhtudel, kus tervet projekti tuleb hoida samaaegselt mudeli kontekstis – näiteks kui agentne tööriist loeb iga sammu juures kõiki olemasolevaid $\text{\LaTeX}$ -faile uuesti.

Kuluaspektist oli Claude Opus 4.6 võrreldud mudelitest kõige kallim (vt tabel 3) – sisend €5,29/MTok ja väljund €26,45/MTok ehk ligikaudu 1,7 korda kallim sisendi ja väljundi pealt kui Sonnet 4.6, kuid sellega kaasnes ka kõige parem väljund. Kuutellimustega pakub Anthropic Opus 4.6-le sama Pro/Max 5×/Max 20× tasemestruktuuri kui Sonnet'ile (vt tabel 4), kuid kuna Opus tarbib päringu kohta rohkem ressursi, on Opus 4.6 mõistlikuks praktiliseks kasutuseks reeglina vaja vähemalt Max 5× tellimust. Selle kompromissi praktiline tõlgendus on esitatud peatükis 7.3.

4.5 Mudelite koondvõrdlus

Tabelites 2, 3 ja 4 on esitatud nelja mudeli koondvõrdlus, mis on jagatud kolme ossa loetavuse huvides: tehnilised parameetrid, API hinnakiri ning lõppkasutaja kuutellimused. Tabeli 2 read tuginevad mudelite pakkuja ametlikele tooteteadele [33–36] ning tabelite 3 ja 4 read tuginevad 2026. aasta mai ametlikele hinnakirjadele [37–39]. API hinnad on pakkuja poolt avaldatud USA dollarites tabelis 3 ja need on teisendatud eurodesse 2026. aasta mai vahetuskursi alusel ($1 \text{ EUR} = 1,17 \text{ USD}$ ehk $1 \text{ USD} \approx 0,853 \text{ EUR}$). Kõik hinnad sisaldavad Eesti 24% käibemaksu.

Tabel 2. TI mudelite tehniliste parameetrite võrdlus

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Avaldatud	02/2026	03/2026	02/2026	02/2026
Kontekstiaken	1M	272K (1,05M API)	200K (1M API)	1M
Max väljund (tokenites)	64 000	128 000	128 000	128 000
Mõtlemisrežiim	Jah (natiivne)	Jah (reguleeritav)	Jah (pikendatud)	Jah (pikendatud)
Max mõtlemise tokenid	natiivne	128 000	64 000	64 000
Sisendmodaalsused	Tekst, pilt, heli, video	Tekst, pilt, heli	Tekst, pilt, PDF	Tekst, pilt, PDF
Tööriistakasutus	Jah	Jah	Jah	Jah

Tabel 3. TI mudelite API hinnakirja võrdlus (EUR 1M tokeni kohta, koos 24% käibemaksuga)

Hinnakomponent	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Sisend (tavahind)	€2,12–4,23	€2,64	€3,17	€5,29
Sisend (vahemälust loetud)	€0,21–0,42	€0,26	€0,32	€0,53
Väljund	€12,70–19,05	€15,87	€15,87	€26,45

Lisaks API-le pakuvad kõik kolm pakkujat lõppkasutajatele kuutellimusi, mis võimaldavad fikseeritud kuumaksu eest mudelit kasutada vestlusliideses ja sageli ka agentses tööriistas (Codex, Cowork, Antigravity). Tellimuste koondvõrdlus on esitatud tabelis 4.

Tabel 4. Lõppkasutaja kuutellimused Eesti regioonis (EUR/kuu, koos 24% käibemaksuga)

Pakkuja	Tellimus	Hind/kuu	Olulisemad piirangud ja juurdepääs
Google	Google AI Studio Plus	€7,99	Piiratud Gemini 3.1 Pro ja AI Studio kasutus
Google	Google AI Pro (Gemini Advanced)	€21,99	Gemini 3.1 Pro vestlusliideses; piiratud Antigravity kasutus
Google	Google AI Ultra	€274,99	Kõrgeimad Gemini 3.1 Pro, AI Studio ja Antigravity limiidid; 30 TB salvestusruumi
OpenAI	ChatGPT Go	ca €8	GPT-5.3 Instant laiendatud kasutusega; rohkem faile, pildiloomet ja mälu kui tasuta plaanis
OpenAI	ChatGPT Plus	ca €23	GPT-5.4 piiratud kasutusega; Codex laienduse piiratud kvoot
OpenAI	ChatGPT Pro	ca €229	GPT-5.4 oluliselt suuremate kasutuspiirangutega; kõrgem mõtlemisrežiimi intensiivsus
Anthropic	Claude Pro	ca €22	Sonnet 4.6 + Opus 4.6 piiratud; Cowork piiratud kvoodiga
Anthropic	Claude Max 5×	ca €106	5× Pro plaani kasutuspiirangud; laiem Opus 4.6 ligipääs
Anthropic	Claude Max 20×	ca €212	20× Pro plaani kasutuspiirangud; täielik Opus 4.6 ligipääs

Tabelitest 2–4 on näha, et neli võrreldud mudelit erinevad nii tehniliste parameetrite, API hinnakirja kui ka kuutellimuste poolest märgatavalt. Gemini 3.1 Pro paistab silma kõige soodsamate API baasmäärade ja suure kontekstiaknaga, Sonnet 4.6 kõige väiksema kontekstiaknaga, GPT-5.4 keskmise hinnataseme ja Opus 4.6 kõrgeima väljundhinnaga.

Tellimuste hinnad algavad 8€-st kuni ca 275€-ni kuus. Neid tuleb arvesse võtta, et otsustada, et milline mudel sobib mis stsenaariumi jaoks. Ühe lühikese viibaga väljundi genereerimine on API kaudu suhteliselt odav iga mudeli puhul, kuid pikemate iteratiivsete agentsete sessioonide kogukulu sõltub eelkõige konteksti pikkusest ja iteratsioonide arvust. Eksperimendi käigus mõõdetud kulud ja nende praktiline tõlgendus on esitatud peatükis 7.3.

5. Eksperiment ja tulemused

Käesolev peatükk kirjeldab läbiviidud eksperimenti, esitab nelja mudeli genereeritud bakalaureusetööde tulemused ning analüüsib nende kvaliteeti erinevatest aspektidest lähtuvalt.

5.1 Eksperimendi ülesehitus

Eksperimendis paluti igal mudel-tööriista kombinatsioonil genereerida terviklik bakalaureusetöö informaatika valdkonnast ühe kasutajaviibaga, ilma järelküsimate ega iteratiivse suunamiseta. Mudelitele anti identne lühike eestikeelne viip (vt peatükk 3.2 ja lisa I), mis palus mudelil luua LaTeX-vormingus bakalaureusetöö, mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele, kasutades töökausta paigutatud UniTartuCS malli. Konkreetset teemapealkirja ette ei antud – mudel pidi ise valima informaatikaga seotud teema. Autori (Uku Renek Kronbergs) ja juhendaja (Alo Peets, MSc) nimed anti tiitellehe täitmiseks.

Viip on teadlikult lühike, kuna üks uurimisküsimustest on, kuidas mudel-tööriista kombinatsioonid reageerivad minimaalsele juhisele ning kas nad suudavad iseseisvalt valida sobiva teema, keele ja struktuuri. Kuna ülesanne nõuab failihaldust, mitme $\text{\LaTeX}$ faili loomist ja kompileerimist, kasutati iga mudeliga agentset töövoogu. Sonnet 4.6 ja Opus 4.6 puhul kasutati Anthropicu Cowork'i, Gemini 3.1 Pro puhul Google'i Antigravity ning GPT-5.4 ChatGPT Codex laiendust Visual Studio Code'is.

Tulemused olid kombinatsioonide lõikes drastiliselt erinevad, nagu on näha tabelist 5. Oluline tõlgenduslik märkus veelkord: järgnevas analüüsis tuleb tulemusi vaadelda mudeli ja agentse tööriista paaride, mitte puhaste mudeli võimekuste näitajatena – iga jook tehti üks kord, mistõttu näitajad on eksploratiivsed ja võivad kordusjooksudel drastiliselt erineda.

Tabel 5. Tervikliku lõputöö genereerimise tulemuste koondülevaade

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Väljundkeel	Eesti	Eesti	Eesti	Eesti
Maht (lehekülgi)	39	47	40	61
Valitud teema	GenAI ja algajad progr.	RAG-põhine QA-süsteem	LLM koodiülevaatuses	Paroolihaldur
Struktuur	Lõputöö vormis	Lõputöö vormis	Lõputöö vormis	Lõputöö vormis
Agentne tööriist	Antigravity	Codex VS Code'is	Cowork	Cowork
Viited	9, 1 viga (11%)	22, 0 viga (0%)	23, 5 viga (22%)	35, 2 viga (6%)
Akad. stiil	Hea	Hea	Väga hea	Suurepärase

Järgnevad alapeatükid esitavad iga mudel-tööriista kombinatsiooni kohta detailse kvalitatiivse hinnangu, alustades Claude Sonnet 4.6 + Cowork tulemusest, seejärel GPT-5.4, Gemini 3.1 Pro ja Claude Opus 4.6 väljundeid. Numbrilised koondtulemused on koondatud alapeatükkidesse 5.6–5.9.

5.2 Claude Sonnet 4.6 (Cowork)

Claude Sonnet 4.6 + Cowork kombinatsioon genereeris 40-leheküljelise eestikeelse dokumendi, mis järgis bakalaureusetöö struktuuri. Kombinatsioon valis teemaks “Suurkeelemudelite kasutamine automaatses koodiülevaatuses” – empiirilise võrdluse GPT-4, Claude 3 Opuse ja Code Llama 70B vahel, mis põhines väidetavalt 120-st koodifragmendist koosneval testkogumil neljas veakategoorias (loogilised vead, turvaaugud, jõudlusprobleemid, stiilirikkumised) Pythoni ja Java keeles. Töö sisaldas detailseid hindamistabeleid täpsuse, saagise ja F1-mõõdiku numbritega ning kõigi mudelite kohta esitatud konkreetsete numbrid (nt GPT-4 üldine F1 = 82,5%, Claude 3 Opus 77,9%, Code Llama 70B 70,0%). Sarnaselt Gemini 3.1 Pro fabritseeritud uuringule (vt alapeatükk 5.4) on ka neid empiirilisi näitajaid tulnud käsitleda kontrollimata väidetena, kuna ühtegi sellist kontrollitud katset käesoleva uurimuse autor läbi ei viinud. Akadeemiline stiil oli tugev ja töö järgis LaTeX-malli korrektselt. Olulise vorminguveana paistis silma ka asjaolu, et tiitellehel kasutas mudel autorinime kärbitud kujul (“Uku Renek”), juhendaja nimena kohatäidet (“Prof. Vanem Juhendaja, PhD”) ning aastana “2025” (mitte 2026).

Peamised puudused olid hallutsineeritud viited (5 viga 23-st 22%), kohati keeruline lauseehitus ning 37 keele- ja kirjaviga kogu töö peale (vt peatükk 5.6), sealhulgas terminoloogilised eksimused (*finantreenimine*, *looduskeel*), näpukad (*deviatsiooonid*, *annotatsiooonid*) ja sõnavormivead (*hallutsinesid*). Viidete hallutsinatsioonid olid huvitavad: artiklite pealkirjad ja arXiv-identifikaatorid olid enamasti korrektsed, kuid mudel “täitis” autoriloendeid välja mõeldud nimedega. Näiteks paberis “Towards Automating Code Review Activities” (ICSE 2021) olid loetletud autorid “Tufano M., Ni S. Y., Chromik S., Brunner R., Svyatkovskiy A., Clement C. B., Sundaresan N.”, samas kui tegelikud autorid on Rosalia Tufano, Luca Pascarella, Michele Tufano, Denys Poshyvanyk ja Gabriele Bavota. Teises näites (“Impact of Code Language Models on Automated Program Repair”, arXiv:2302.05020) loetles mudel autorid “Jiang J., Huang L., Liu Z., Lo D., Xia X.”, kuid tegelikud autorid on Nan Jiang, Kevin Liu, Thibaud Lutellier ja Lin Tan. Kõige tähelepanuväärsem juhtum oli viide “JITBot” (Pornprasit ja Tantithamthavorn, ASE 2022), kus mudel kombineeris kahe eri paberi metaandmed: JITBot eksisteerib, kuid ASE 2020 ja täiesti teiste autoritega; Pornprasit ja Tantithamthavorn kirjutasid hoopis paberi nimega “JITLine” (MSR 2021).

5.3 GPT-5.4 (Codex)

GPT-5.4 tulem erines teistest fundamentaalselt, kusjuures erinevus ei tulenenud mitte mudelist, vaid liidesest, mille kaudu mudelit kasutati. Tavapärase ChatGPT vestlusliidese kaudu keeldus mudel genereerimast terviklikku lõputööd, viidates otseselt akadeemilise aususe piirangutele. Väljundis selgitati, et täieliku bakalaureusetöö kirjutamine tudengi eest oleks vastuolus Tartu Ülikooli akadeemilise aususe reeglitega. Selle asemel pakkus GPT-5.4 välja 8-leheküljelise ingliskeelse teostatavusjuhendi (*feasibility guide*), mis sisaldas mudelivaliku soovitusi, eksperimendi disaini raamistikku, hindamismetoodikat ja $\text{\LaTeX}$ malli juhiseid. Kuigi juhend oli sisuliselt kvaliteetne ja viited olid kontrollitavad, ei vastanud see ülesande püstitusele: väljund oli inglise, mitte eesti keeles, ja vormilt pigem nõuandev memo kui akadeemiline lõputöö. See käitumine viitab sellele, et ChatGPT vestlusliidese süsteemijuhised ja ohutuspoliitika tõlgendavad “tervikliku bakalaureusetöö genereerimine” tüüpi ülesandeid vaikumisi akadeemilise aususe piirangu alla kuuluvana ning eelistavad sellistes olukordades keeldumist või nõuandvat vastust.

Täiendav katse OpenAI ChatGPT Codex laiendusega Visual Studio Code’i keskkonnas andis aga identsest viibast hoolimata oluliselt erineva tulemuse. Sama GPT-5.4 mudel suutis agentse tööriista kaudu genereerida visuaalselt teiste kombinatsioonide väljunditega sarnase tervikliku 47-

leheküljelise eestikeelse dokumendi teemal “Eestikeelse RAG-põhise küsimus-vastus süsteemi kavandamine”. See erinevus näitab, et agentne töövoog muudab ülesande konteksti ja tööjaotust – ülesanne jaotub väiksemateks faili- ja kompileerimispõhisteks sammudeks ning liidese süsteemijuhised ja ohutuspoliitika on erinevad. Ehk sama mudel käitub erinevas liideses väga erinevalt. Codex laienduse kaudu genereeritud töö oli ortograafilise täpsuse poolest silmapaistev: kogu töö peale tuvastati kolm unikaalset kirjaviga (*vastusevormingun, lekita, dokumentikorpused*), mis oli nelja kombinatsiooni seas parim tulemus (vt peatükk 5.6). Lisaks oli see ainus kombinatsioon, mille kõik 22 viidet (peamiselt arXiv- ja ACL Anthology paberid) olid täielikult kontrollitavad ja korrektsete metaandmetega – ühtegi hallutsineeritud autorit, pealkirja ega aastat ei tuvastatud.

Olulise akadeemilise aususe näitajana paistab silma ka asjaolu, et Codex-laiendusega genereeritud töö ei kasutanud tiitellehel, litsentsis ega allkirjas viibas etteantud autori (Uku Renek Kronbergs) ega juhendaja (Alo Peets, MSc) nime, vaid kohatäidet *Näidisüliõpilane* ja *Juhendaja nimi, PhD*. See viitab sellele, et ka agentse töövoog kaudu säilitas mudel teatava ettevaatuse, vältides reaalse isiku nime alla allakirjastatud akadeemilise teksti otsest tootmist.

5.4 Gemini 3.1 Pro (Antigravity)

Gemini 3.1 Pro + Antigravity kombinatsioon genereeris 39-leheküljelise eestikeelse bakalaureusetöö teemal “Generatiivse tehisintellekti mõju tarkvaraarenduse produktiivsusele algajate programmeerijate seas”. Kombinatsioon valis iseseisvalt informaatika valdkonnast aktuaalse ja hästi piiritletud uurimisteema, mis käsitles suurte keelemudelite mõju programmeerimise õppimisele.

Genereeritud töö oli struktuuraalselt terviklik ja sisaldas kõiki nõutud komponente. Tausta- ja kirjandusülevaate peatükk sisaldas transformer-arhitektuuri, kognitiivse koormuse ning *over-reliance*’i käsitlelust. Metoodikas oli väidetavalt 2026. aasta märtsis Tartu Ülikooli Delta õppehoone arvutiklassis läbi viidud kvaasi-eksperimentaalne katse 30 informaatika esmakursuslasega: 16 meest ja 14 naist vanuses 18–22 aastat, kes jagati 15-liikmeliseks katse- ja kontrollrühmaks ning kasutasid Tartu Ülikooli HPC klastris jooksutatud lokaalset LLaMA-3-8B-Instruct mudelit. Lisad olid ka hästi esitatud: tagasisideküsimustik, React.js koodiredaktori komponent (ca 150 rida), PostgreSQL andmebaasi skeem (5 tabelit), Pandas/SciPy andmeanalüüsi skript (ca 160 rida) ning tudengite koodinäited koos vigade analüüsiga.

Töö tugevused olid järgmised:

- Akadeemilise struktuuriga hästi arvestatud: uurimisküsimused, hüpoteesid, statistilised testid;
- Eesti keele kvaliteet oli üldiselt hea, kuigi esines mõningaid terminoloogilisi ebajärjekindlusi;
- Viited (9 allikat) kasutasid reaalse teadlaste nimesid (Becker, Kazemitabaar, Vaswani jt), aga lingid olid puudu.
- Koodinäited lisades olid funktsionaalsed ja loogiliselt kirjutatud;
- Töö maht (39 lehekülge) vastas bakalaureusetöö nõuetele.

Peamised puudused olid siiski suured, kusjuures esimene neist ei ole käsitletav tavapärase kvaliteedipuudusena, vaid akadeemilise väärkasutuse kõrge riskiga juhtumina:

- **Fabritseeritud empiiriline uurimus.** Kombinatsioon esitas väidetavalt 2026. aasta märtsis Tartu Ülikooli Delta õppehoones läbi viidud kvaasi-eksperimenti 30 informaatikatudengiga, sealhulgas osalejate jaotuse 15-liikmeliseks katse- ja kontrollrühmaks, konkreetset Welch'i t-testid ja standardhälbed, numbrilised tulemused (näiteks Ülesande 1 puhul katsegrupi 14,2 vs kontrollgrupi 27,5 minutit, $p < 0,001$; testide läbivuse osas 64% vs 82%) ning kirjeldatud testikeskkonna tehnilise arhitektuuri (React/TypeScript klient Monaco Editor'i baasil, Node.js/Express server, Docker liivakast koodi käivitamiseks ning kohaliku LLaMA-3-8B-Instruct mudeli kasutamine TÜ HPC klastris). Seda uurimust tegelikult ei toimunud – tudengeid, nende koode, katsekeskkonda ega statistilisi tulemusi ei eksisteeri. Lugeja, kes ei kontrolli andmeid, saab äärmiselt veenva, kuid tegelikkuses olematu uuringu.
- Viidete kontrolli järgi olid 9-st viitest 8 täielikult korrektsed ning ühel juhul oli vale 6. autor (viide [1] Becker jt 2023 “Programming Is Hard” loetles autorina “Reeves E. A.”, kuigi tegelik 6. autor on Eddie Antonio Santos – Brent N. Reeves on hoopis seotud paberiga “It’s Weird That it Knows What I Want”). Hallutsineerimismäär oli seega ca 11%.
- Eesti keele ortograafiline täpsus oli selgelt probleemne – töös tuvastati 24 unikaalset kirjaviga, sealhulgas tavasõnade valed vormid (*struktuure*, *kordinaadid*, *konfliktide*), mittesõnad (*teoosiab*, *Tehisintsistendi*) ning valede tähtedega asendatud täpitähed ja nimed (vt peatükk 5.6);

- Antigravity tööriist oli vajalik käesolevas katses saadud tulemuseni jõudmiseks – autori varasemad katsed ilma agentse tööriistata andsid oluliselt nõrgema tulemuse.

Need puudused – eriti fabritseeritud empiiriline osa – ilmestavad keskset tähelepanekut, et vormiliselt veenev TI-genereeritud akadeemiline tekst ei tähenda automaatselt sisuliselt usaldusväärset tööd ning inimese põhjalik järelkontroll on hädavajalik isegi siis, kui väljund järgib lõputöö struktuuri ja akadeemilist stiili.

5.5 Claude Opus 4.6 (Cowork)

Claude Opus 4.6 + Cowork kombinatsioon andis selles eksperimendis kõige ulatuslikuma ja kvaliteetsema väljundi – 61-leheküljelise eestikeelse bakalaureusetöö teemal “Turvalise paroolihalduri veebirakenduse arendamine”. Cowork’i agentne tööriist võimaldas mudelil otse kirjutada $\text{\LaTeX}$ faile, hallata viiteid ja kompileerida dokumenti.

Genereeritud töö sisaldas terviklikku tehnilist arhitektuuri (nullteadmise põhimõte, AES-256-GCM krüpteering, Argon2id võtmetuletamine) ning täielikku React/TypeScript kasutajaliidest ja Node.js/Express taustarakendust. Lisaks *väärtis* töö, et rakendus läbis 149 automatiseeritud testi, OWASP Top 10 vastavuse analüüsi ning süsteemi kasutatavuse skaala (SUS) hindamise skooriga 77,0, ja et turvaaudit ei tuvastanud ühtegi kriitilist turvaauku. Olulise metoodilise märkusena tuleb rõhutada, et käesoleva eksperimendi autor ei teostanud nende testide, auditi ega kasutajauuringu iseseisvat läbiviimist – need näitajad on kirjas Opus 4.6 + Cowork kombinatsiooni enda genereeritud väljundis ning kuuluvad samasse kategooriasse empiiriliste väidetega, mida TI-loodud töödes tuleb inimese poolt eraldi kontrollida (vrd Gemini 3.1 Pro fabritseeritud eksperiment alapeatükis 5.4). Opus 4.6 kirjeldatud arhitektuur ja koodinäited olid siiski tunduvalt detailsemad ja sisemiselt sidusamad kui Gemini 3.1 Pro töös esitatud statistilised tulemused. Vormingulise piiranguna paistis silma asjaolu, et kolm kavandatud joonisekohta (süsteemi arhitektuur, andmebaasi ER-diagramm ja võtmetuletuse skeem) on PDF-is jäetud kohatäidetena – jooniste asemel on “*Siia tuleb arhitektuuridiagramm...*” tüüpi tekstid –, mis viitab sellele, et agentne tööriist suutis küll kavandada jooniste paigutuse ja kirjeldada nende sisu, kuid ei loonud tegelikke graafilisi diagramme.

Opus 4.6 + Cowork tulemuse peamised erinevused võrreldes Sonnet 4.6 + Cowork tulemusega:

- Oluliselt suurem maht (61 vs 40 lehekülge), mis viitab sügavamale sisulisele käsitlesele;
- Tehniline detailsus oli kõrgem – töö sisaldas konkreetseid koodi- ja arhitektuurinäiteid;

- Eesti keele kvaliteet oli ühtlasem ja loomulikum ka pikemas tekstis – kogu 61-leheküljelise töö peale tuvastati 15 unikaalset keele- ja kirjaviga (näiteks *Carnegei, Californiya, taaskasutatavarteks, mälusest*), mis teeb kirjavigade tiheduseks 0,25 viga lehekülje kohta (vt peatükk 5.6);
- Viidete hallutsineerimise määr oli oluliselt madalam: 35-st viitest oli 33 täielikult korrektsed, kahes oli väike metaandmete viga (Hunt 2019 viites oli URL-i kuju vigane ning Gosney 2019 viites oli pealkirjas ekslikult “GTX 1080 Ti” samas kui viidatud GitHub-i gist sisaldab “GTX 1080” (ilma Ti) eelarvustuste tulemusi 2016. aastast). Hallutsineerimismäär oli seega 6% võrreldes Sonnet 4.6 22%-ga, kusjuures Sonnet’i puhul olid vead sisulisemad (välja mõeldud autorid), samas kui Opus’e vead olid puhtalt metaandmete tasemel.

Eriti tähelepanuväärne on agentsete tööriistade ja liideste mõju tulemusele. Nii Cowork (Opus 4.6 ja Sonnet 4.6 puhul), Google’i Antigravity (Gemini 3.1 Pro puhul) kui ka ChatGPT Codex (GPT-5.4 puhul) andsid oluliselt erineva tulemuse kui puhas vestlusliides – seda kinnitas kõige ilmekamalt GPT-5.4 kahe stsenaariumi vastandlik tulemus. Kõik kombinatsioonid valisid iseseisvalt erineva informaatikateema, mis näitab, kui erinevalt samale lühikesele viibale reageeritakse. Isegi kõige edukamad tulemused (Opus 4.6 + Cowork, GPT-5.4 + Codex ja Gemini 3.1 Pro + Antigravity) vajasid inimese järeltööstlust: viidete kontrolli, terminoloogia ühtlustamise ja fabritseeritud andmete tuvastamise osas. Kuna iga kombinatsiooni kohta tehti vaid üks jook, ei saa ühe jooku põhjal väita, et üks mudel on üldiselt parem kui teine – saab väita üksnes, et selles eksploratiivses katses andis konkreetne mudel-tööriista kombinatsioon konkreetse tulemuse. Genereeritud tööde väljavõtted on esitatud lisas III.


5.6 Kirjavigade ja keeleliste vigade analüüs

Eesti keele kvaliteedi täpsemaks hindamiseks vaadati eraldi üle iga genereeritud lõputöö keele- ja kirjavead – see tähendab ortograafilised näpukad, valed tähed, puuduvad või liigsed tähed, sõnade valed vormid, terminoloogilised väärvormid ning pärisnimede vead. Analüüsist jäeti välja kontekstis korrektsed, kuid stiililiselt ebaõnnestunud laused, samuti vead, mis ilmnesisid üksnes PDF-ist teksti ekstraheerimise kodeeringuarterfaktidena. Sama vormi kordumine mitmel leheküljel loeti üheks unikaalseks leiuks, mitte iga esinemiskord eraldi. Tabelis 6 on esitatud vigade koondarv iga töö kohta ning arvestuslik tihedus lehekülje kohta.

Tulemused näitavad nelja mudeli vahel märkimisväärselt erinevust eesti keele täpsuse osas. GPT-5.4 Codex laienduse kaudu genereeritud töös tuvastati kogu 47-leheküljelise dokumendi

Tabel 6. Genereeritud tervikliku lõputöö keele- ja kirjavigade koondarv

Mudel	Maht (lk)	Keele- ja kirjavigade arv	Vigu lk kohta
Gemini 3.1 Pro (Antigravity)	39	24	0,62
Claude Sonnet 4.6 (Cowork)	40	37	0,93
Claude Opus 4.6 (Cowork)	61	15	0,25
GPT-5.4 (Codex)	47	3	0,06



Joonis 1. Keele- ja kirjavigade tihedus genereeritud töödes.

peale kolm selget kirjaviga: *vastusevormingun*, *lekita* ja *dokumentikorpused*. See jäi nelja kombinatsiooni madalaimaks veamääraks.

Claude Opus 4.6 töös tuvastati 61 lehekülje peale 15 keele- ja kirjaviga. Lisaks pärisnimede vigadele (*Carnegei*, *Californiya*) esines tavasõnade ja liitvormide eksimusi, näiteks *taaskasutatavarteks*, *juhusiku*, *mälusest*, *konteineriena*, *mõneseundi* ja *stsenaariumm*. Opuse veamäär jäi siiski madalaks, sest töö oli võrdluse kõige mahukam.

Claude Sonnet 4.6 töös oli kõige suurem unikaalsete keeleliste vigade koondarv: 37 leidu 40 lehekülje kohta. Vead olid muhtoliselt mitmekesised. Korduvad topelttähed avaldusid sõnades *deviatsiooonid*, *annotatsiooonid* ja *genereeritud*; lühitähed olid puudu või asendunud vormides *Eeltrenimine*, *kategoriad*, *kodele treenitud* ja *suurkeelmudeli*. Lisaks esines terminoloogilisi või tõlkevaldkonna eksimusi, näiteks *finantreenimine*, *looduskeel*, *informeerimise taastamine* ja *kaksikeliigsust*. Mõned vead olid pigem sõnavaliku- või grammatikavead, näiteks *kasumlikkusest* õige *kasulikkusest* asemel ning *tööriistad ületas* õige *tööriistad ületasid* asemel.

Gemini 3.1 Pro genereeritud töös tuvastati 39 lehekülje kohta 24 unikaalset kirjaviga. Vead jagunesid mitmesse põhikategooriasse. Levinuima kategooria moodustasid puuduvate või vahetatud tähtedega tavasõnad (*struktuure, kordinaadid, vektorruumi, konfliktide, sepsifiliste, uenit, ekponentvõimendi, hariduteadusele*). Teise rühma kuulusid valede tähtedega asendatud täpitähed või häälikud (*narvivõrgu, moita*). Kolmandana esinesid moodustatud mittesõnad või tugevalt vigased vormid (*teoosiab, Tehisintsistendi, algasestatud, vetiaknakujuline*). Lisaks esines pärisnime viga *Düning-Krugi* õige *Dunningi-Krugi* asemel.

Kokkuvõttes näitas madalaimat veatihedust GPT-5.4 agentse tööriista kaudu, sellele järgnes Claude Opus 4.6. Sonnet 4.6 suurem koondarv tulenes osaliselt sellest, et loendisse arvestati lisaks ortograafilistele näpukatele ka terminoloogilisi ja sõnavormivigu. Gemini 3.1 Pro puhul oli probleem teistsugune: vigu oli vähem kui Sonneti koondloendis, kuid need olid sagedamini silmatorkavad ortograafilised vead ja mittesõnad. See tulemus rõhutab, et automaatse korrektuuri tööriista (nt `aspell`, `hunspell`, `JVKS`) või täiendava keelelise toimetamise etapp on TI-ga genereeritud tekstide puhul vältimatu – eriti mudelite korral, mille treeningandmetes on eesti keele osakaal väiksem.

5.7 Mahu ja struktuuri analüüs

Lisaks keele- ja kirjavigadele uuriti iga genereeritud töö mahtu ja sisemist struktuuri. Mahu hindamiseks loeti kokku kogu PDF-failist eraldatud sõnad (sealhulgas tekst, tabelite sisu, lisad ja viited) ning arvutati välja sõnade arv lehekülje kohta. Struktuuri hindamiseks loendati nummerdatud alapeatükkide, tabelite, tegelike jooniste ja koodinäidete arv kogu töös. Jooniste kohatäitjaid, mille asemel oli PDF-is vaid tekstiline märkus joonise lisamiseks, joonistena ei arvestatud. Tulemused on esitatud tabelis 7.

Tabel 7. Genereeritud tööde maht ja struktuurilemendid

Mudel	Lk	Sõnu	Sõnu/lk	Alapt.	Tab.	Joon.
Gemini 3.1 Pro	39	7 230	185	20	2	0
GPT-5.4 (Codex)	47	9 669	206	49	7	2
Claude Sonnet 4.6	40	8 085	202	32	7	0
Claude Opus 4.6	61	10 749	176	27	11	0

Andmetest joonistuvad välja mitmed huvitavad mustrid. Kõige suurema mahu (10 749 sõna) genereeris ootuspäraselt Claude Opus 4.6, mille sisu oli samas kõige kompaktsemalt jaotatud

(176 sõna lehekülje kohta – madalaim näitaja, mis tuleneb suuremast hulgast koodinäidetest, tabelitest ja jooniste kohatäiteplokkidest). Tihedaim tekstiline sisu oli GPT-5.4 (Codex) ja Claude Sonnet 4.6 töödes (vastavalt 206 ja 202 sõna lehekülje kohta). Ainsa tegelike joonistega tööna eristus GPT-5.4 (Codex), milles oli 2 joonist. Kõige granulaarsema struktuuriga töö genereeris samuti GPT-5.4 (Codex) – 49 alapeatükki 47 lehekülje peale –, kus iga alapeatükk käsitles selgelt eristatud arhitektuurilist või hindamistasandi küsimust. Gemini 3.1 Pro maht oli väikseim (7 230 sõna) ja sõnatihedus mõõdukas (185 sõna lehekülje kohta), mis koos jooniste puudumisega viitab pinnapealsemale käsitlusele.

Eraldi tasub märkida, et Gemini 3.1 Pro, Claude Sonnet 4.6 ja Claude Opus 4.6 töödes ei olnud ühtegi päriselt genereeritud joonist, mis on bakalaureusetöö kontekstis ebatavaline – enamik tehnilisi lõputöid sisaldab arhitektuuriskeeme või andmevoo diagramme. Opus 4.6 kavandas küll kolm joonisekohta (süsteemi arhitektuur, andmebaasi ER-diagramm ja võtmetuletuse skeem), kuid jättis need PDF-is kohatäideteks. Sonnet 4.6 ja Gemini 3.1 Pro eelistasid suuremas mahus koodinäidete (Listings) lisamist (vastavalt 7 ja 5 koodinäidet), samas kui Opus 4.6 integreeris koodinäited tihedamalt teksti sisse, ilma neid eraldi nummerdatud koodinäidete plokkidena vormistamata. GPT-5.4 (Codex) töös koodinäiteid praktiliselt ei esinenud – tegu oli puhtalt kontseptuaalse RAG-süsteemi arhitektuurilise kavandiga.

5.8 Viidete kvantitatiivne analüüs

Akadeemilise töö üks olulisi kvaliteedinäitajaid on viidete kasutamise tihedus ja allikate hulk. Iga töö kohta loeti kokku kasutatud viidete koguarv (kirjanduse loendis esitatud unikaalsed allikad), tekstisiseste viidete arv ($[N]$ tüüpi viidete esinemiskorrad enne kirjanduse loendit) ning arvutati tekstisiseste viidete tihedus lehekülje kohta. Tulemused on esitatud tabelis 8.

Tabel 8. Genereeritud tööde viidete analüüs

Mudel	Unikaalseid viiteid	Tekstisiseseid viiteid	Viiteid lk kohta	Viite/allika suhe
Gemini 3.1 Pro	9	13	0,33	1,44
Claude Sonnet 4.6	23	54	1,35	2,35
GPT-5.4 (Codex)	22	28	0,60	1,27
Claude Opus 4.6	35	45	0,74	1,29

Tulemused näitavad, et Claude Opus 4.6 kasutas kõige rohkem unikaalseid allikaid (35), mis vastab paroolihalduri valdkonna iseloomule, kus on vaja viidata krüptograafilistele standarditele (NIST, IETF RFC), turvauuringutele ja olemasolevatele lahendustele. Tekstisest viidete arvu ja tiheduse poolest eristus aga Claude Sonnet 4.6: 40-leheküljelises töös esines 54 tekstisest viidet, mis teeb 1,35 viidet lehekülje kohta. GPT-5.4 (22 unikaalset allikat) ja Claude Sonnet 4.6 (23 unikaalset allikat) jäid allikate hulga poolest keskmisesse vahemikku. Gemini 3.1 Pro paistis silma väikseima viidete arvuga (9 unikaalset allikat 39 lehekülje peale), mis on bakalaureusetöö kontekstis tagasihoidlik – tüüpilistes arvutiteaduse bakalaureusetöös on allikate arv sageli kõrgem kui kümme, eriti kirjanduse ülevaadet sisaldavate tööde puhul. See näitaja kinnitab üldist tähelepanekut, et Gemini 3.1 Pro genereeritud töö oli pigem mahukas, kuid vähese allikatoega.

Viite/allika suhe (tekstisest viidete arv jagatud unikaalsete allikate arvuga) näitab, mitu korda iga allikat keskmiselt kasutati. Gemini 3.1 Pro, GPT-5.4 ja Claude Opus 4.6 jäid 1,27–1,44 vahemikku, mis viitab sellele, et enamikku allikaid kasutati tekstis vaid 1–2 korda. Claude Sonnet 4.6 eristus kõrgema suhtarvuga 2,35, mis tähendab, et samu allikaid kasutati tekstis märksa korduvamalt. Oluline on siiski rõhutada, et see analüüs ei hinda viidete *sisulist* korrektsust ega kontrollitavust – osa viidetest olid hallutsineeritud, eriti Sonnet 4.6 (ca 22%) ja Opus 4.6 (ca 6%) töös.

5.9 Akadeemiline stiil

Eestikeelse akadeemilise teksti üks kvaliteedinäitajaid on tõlkimata jäetud või eesti keele konventsioonidest erinevate ingliskeelsete terminite vähene esinemine ja umbisikulise stiili järgimine. Ülakomaga vormistatud ingliskeelsete sõnade hulk varieerus mudelite lõikes (Sonnet 4.6 + Cowork: 5; GPT-5.4 + Codex: 4; Opus 4.6 + Cowork: 3; Gemini 3.1 Pro + Antigravity: 6), kuid sellesse näitajasse mahuvad ühtmoodi nii välditavad inglismõjud (*prompt*, *pipeline*) kui ka vältimatud valdkonnaspetsiifilised standarditerminid (*salt*, *nonce*, *hash*, *AES-256-GCM*, *Argon2id*) ja toote- või firmanimed (*Google*, *Cowork*). Seetõttu on koondnäitaja tõlgenduslikult ebatäpne ning täpsem kolmekategooriline loendus jääb edasiste uurimuste metoodiliseks täienduseks. Esimese isiku asesõnade (*ma*, *mina*, *me*, *meie*, *meil*, *meid*, *minu*) loenduses järgisid kõik neli mudelit umbisikulist stiili väga hästi: Opus 4.6, Sonnet 4.6 ja GPT-5.4 ei kasutanud peamises tekstis ühtegi esimese isiku asesõna ning Gemini 3.1 Pro töös tuvastati vaid üks selline esinemisjuht. See näitab, et tänapäeva suured keelemudelid on eesti akadeemilise stiili konventsioonid hästi ära õppinud.

6. Käesoleva bakalaureusetöö enda kirjutamise töövoog

Peatükis 5 kirjeldatud eksperiment uuris ühe kasutajaviibaga (*single-prompt*) tervikliku töö genereerimist. Käesolev bakalaureusetöö ise ei ole ühe viiba tulemus: selline lähenemine ei vastaks akadeemilise aususe põhimõtetele ega annaks ka soovitud kvaliteeti. Selle asemel kasutati etapiviisilist, inimese juhitud töövoogu, mis järgib peatükis 7.6 esitatud soovitusi. Käesolev peatükk kirjeldab selle töövoogu konkreetseid samme, kasutatud tööriistu, autori ja TI rollijaotust ning saadud praktilisi kogemusi, et pakkuda läbipaistvat ülevaadet sellest, kuidas TI-d lõputöö kirjutamise protsessis vastutustundlikult rakendati.

6.1 Kasutatud TI tööriist ja mudel

Käesoleva bakalaureusetöö kirjutamise käigus kasutati agentse TI tööriistana Anthropicu **Claude Code**'i – agentset kodeerimis- ja tekstiloomise tööriista, mis integreerub otse arenduskeskkondadesse nagu Visual Studio Code [40] ning erinevalt vestlusliidese-põhistest tööriistadest saab iseseisvalt lugeda ja kirjutada faile, käivitada käsurea käsked ning hallata projekti failisüsteemi. Tööriist töötas otse autori kohaliku arenduskeskkonnaga (Visual Studio Code Windowsi platvormil) ning omas ligipääsu projektikaustale $\text{\LaTeX}$ allikfailide, bibliograafia, jooniste ja kompileeritud PDF-i näol. Peamise mudelina kasutati Claude Opus 4.6 maksimaalse mõtlemisrežiimiga. Peaeksperimentis kasutatud tööriist Cwork (vt peatükk 5.5) on Claude Code'i lähedane sugulane, aga töö itereerimisel oleks see olnud palju ebaefektiivsem. Claude Code valiti selle tiheda lõimingu tõttu Visual Studio Code arenduskeskkonnaga ja Giti tööriistadega.

Claude Code'i oli töö kirjutamise ajal võimalik kasutada nii Visual Studio Code laiendusena kui ka eraldiseisva tööluarakendusena. Autori praktilise kogemuse põhjal olid vastused tööluarakenduse kaudu otse kasutades märgatavalt kiiremad kui VS Code laienduse kaudu – sama mudeli ja sama päringu puhul reageeris tööluarakendus tajutavalt kohesemalt, mis oli eriti märgatav pikemate parandusvoorude ja kompileerimistsüklite puhul. Seetõttu kasutati pikematele parandusvoorudele Claude Code'i tööluarakendust, samas kui VS Code laiendus jäi kasutusse siis, kui samas sessioonis oli vaja otse toimetada koodi või $\text{\LaTeX}$ vorminduse üksikasju arenduskeskkonnas.

Lisaks Claude Code'ile kasutati töö kirjutamise ja hilisema kontrollimise käigus Visual Studio Code'i keskkonnas OpenAI ChatGPT Codex laiendust [41]. Codexiga kasutati GPT-5.5 mudelit

peamiselt kirjavigade otsimiseks ja sõnastuse parandamiseks. Töö hilisemas toimetamisfaasis kasutati ka Claude Opus 4.7 mudelit [42] samaks otstarbeks.

Täiendavalt kasutati järgmisi abivahendeid: Visual Studio Code'i töökeskkonda, Git'i ja GitHubi versioonihalduseks, TeX Live'i koos `latexmk`, `lualatex` ja `biber` tööriistadega $\text{\LaTeX}$ kompileerimiseks, töö algaasis Overleafi ning Zotero ekspordikirjeid BibTeX-kirjete koostamisel.

6.2 Etapp 1: algne ühe kasutajaviibaga katse sisukorra kavandamiseks

Töö algetapis teostati sama ühe kasutajaviibaga katse, mida rakendati peaeksperimendis, et kaardistada võimalikku struktuuri ja teemade jaotust. Katse väljundit kasutati üksnes kavandamise abina: see aitas näha, milliseid peatükke mudel ise oluliseks peab, kuid peatükid kirjutati hiljem uuesti autori poolt, tuginedes loetud kirjandusele ja eksperimendi tulemustele.

6.3 Etapp 2: iteratiivne kirjutamine ja toimetamine

Pärast esialgset kaardistust mindi üle iteratiivsele kirjutamisele, kus autor hoidis sisulist kontrolli ja TI tööriist tegutses keelelise ning vormistusliku abivahendina. Iteratsiooni üldised sammud olid järgmised.

1. **Autori sisuline kirjutamine ja eksperimendi läbiviimine.** Sisulised otsused, uurimisküsimuste sõnastus, eksperimendi disain, nelja genereeritud tervikliku töö hindamine, kvantitatiivsete mõõtmiste lõplik kinnitamine (kirjavigade loendus, viidete analüüs, anglitsismide loendus, esimese isiku asesõnade loendus) ja tulemuste tõlgendamine jäid autori vastutusele.
2. **Peatüki mustandi koostamine autori poolt.** Iga peatüki esimene versioon kirjutati autori poolt käsitsi, tuginedes loetud kirjandusele ja eksperimendi tulemustele. Sellega tagati, et argumentatsiooni loogika ja peamised väited lähtuvad autori enda mõttekäigust.
3. **Manuaalne ülevaatus.** Autor luges iga peatüki kriitiliselt üle, tuvastas probleemid (kohmakad laused, ebatäpsed väited, numbriliste andmete ebakõlad, puuduvad viited, korduvused) ja märkis kohad, mida tuleb parandada.
4. **Konkreetsed parandusepalved TI-le.** Autor palus agentsel TI tööriistal teha konkreetseid, kitsalt piiritletud parandusi: tükeldada liiga pikki lauseid, ühtlustada lauseehitust, kontrollida viidete formaati ja järjekorda ning parandada $\text{\LaTeX}$ vormistust. Töö hilisemas faasis lasti antud töö üle vaadata mitmel keelemudelil, et leida kirja- ja vormistusvigu.

5. **Autori otsus iga muudatuse kohta.** TI soovitatud muudatused vaatas autor enne vastuvõtmist üle. Eriti jälgiti seda, et TI ei lisaks uusi faktiväiteid, mida autor ei saaks allikast kinnitada.
6. **Korduv iteratsioon.** Samme 3–5 korrati iga peatüki puhul mitu korda, kuni tekst vastas soovitud kvaliteedile. Keskmiselt läbis iga peatükk mitu selget redaktsioonivooru, millest osa keskendus sisule ja struktuurile ning osa vormistusele ja keelekorrekтуurile.

Selline iteratiivne tsüklil oli aluseks iga peatüki valmimisele ning hoidis autori sisulise kirjutamise ja TI keelelise toimetamise selgelt eraldi etappidena. Eraldi väljakutse oli sellise töövoogu puhul allikate kogumine ja kontrollimine, mida käsitleb järgmine alapeatükk.

6.4 Allikate otsimine ja bibliograafia haldamine

Allikate kogumine ja kontrollimine toimus teadlikult eraldiseisva töövooguna, et vältida peaeksperimendis täheldatud hallutsineeritud viidete probleemi (vt peatükk 5.8). TI-le ei delegeeritud viidete “välja mõtlemist”; selle asemel järgiti järgmist distsipliini.

- **Allikate otsimine toimus inimese juhtimisel.** Autor otsis iga väite kinnitamiseks allikaid käsitsi Google Scholaris, arXivis, ACL Anthology ja ACM Digital Library kaudu, eelistades eelretsenseeritud ajakirju, konverentsiartikleid ja mudelite ametlikke dokumentatsioonilehti.
- **Iga viide lisati BibTeX-faili käsitsi,** kasutades Zotero saadud ekspordikirjet või väljaandja veebilehelt saadud viitekirjet. Enne lisamist kontrolliti, et DOI või URL viiks olemasolevale tööle.
- **TI roll piirdus formaadi kontrolliga.** Claude Code’il paluti kontrollida, kas kõik tekstis esinevad `\cite{}` võtmed leiduvad BibTeX-failis, kas BibTeX-kirjed on süntaktiliselt korrektsed ja kas välju (`url`, `doi`, `howpublished`) on täidetud ühtselt.
- **Viidete sisulise kontrolli tegi autor.** Iga tsiteeritud väite puhul avas autor allika ja veendus, et allikas tegelikult toetab väidet, mille kõrval viide seisab. See takistas nii hallutsinatsioonide kui ka valede parafraside levimist.

Selle töövoogu tulemusena sisaldab käesoleva töö bibliograafia vaid olemasolevaid ja kontrollitud allikaid, erinevalt peaeksperimendi genereeritud töödest, kus 0–22% viidetest olid hallutsineeritud (kõige levinumalt välja mõeldud autorid või kombineeritud metaandmed kahest eri paberist).

6.5 Kvantitatiivse analüüsi ja andmete kogumise töövoog

Peatükkides 5.6–5.9 esitatud arvulised tulemused (keele- ja kirjavigade arv, viidete arv, anglitsismide arv, esimese isiku asesõnade arv) koguti järgmise protseduuri alusel.

1. **PDF-ist teksti ekstraheerimine.** Iga genereeritud tervikliku töö PDF-fail (vt lisa II) muudeti tekstiks, jättes välja tiitellehe ja kirjanduse loendi juhtudel, kus see oli metoodiliselt põhjendatud.
2. **Automaatne eelotsing TI abiga.** Claude Code'il paluti otsida eraldatud tekstist konkreetseid mustreid: tõenäolised kirjavead, ülakomaga võõrsõnad ($[a-zA-Z] + '[a-z\tilde{o}\tilde{a}\tilde{o}\tilde{u}]$), tüüpilised arvutiteaduse ingliskeelsed terminid (*prompt*, *pipeline*, *benchmark*, *over-reliance* jt) ning esimese isiku asesõnad. Iga leid esitati autorile koos konteksti reaga.
3. **Inimese lõplik otsus iga leiu kohta.** Autor otsustas iga TI tuvastatud kandidaadi kohta eraldi, kas tegemist on tõepoolest kirjaveaga, anglitsismiga või esimese isiku asesõnaga, või näiteks kontekstis sobiva tsitaadi või pärisnimega. See kaheetapiline lähenemine (masin tuvastab kandidaadid, inimene kinnitab) vähendas nii väärnegatiivide kui ka väärpositiivide hulka võrreldes puhtalt käsitsi loendusega.
4. **Tulemuste sidususe kontroll tabelite vahel.** Kogunenud arvulisi tulemusi võrreldi korduvalt tabelite (nt tab. 6, tab. 8) vahel, et tagada iga peatüki sees ja peatükkide vahel ühtsed arvud. Claude Code'ilt paluti ka selle kontrolli jaoks abi, lastes mudelil hoiatada vastuoludest (nt kui sama mudeli kohta on eri tabelites erinev veaarv).

Selline tööjaotus vähendas analüüsile kulunud aega, kuid säilitas autori täieliku kontrolli iga arvu üle, mida töös esitatakse.

6.6 Kompileerimine, vormistuse kontroll ja kvaliteedi hindamine

L^AT_EX töös tähendab kirjutamine pidevat kompileerimist ning vigade ja hoiatuste lahendamist. Käesoleva töö puhul seati sisse järgmine kompileerimistsükkel, mis toimis kogu kirjutamise jooksul.

- Kohalik kompileerimine toimus `latexmk`-i abil, mis käivitas `lualatex`-i (vt `.latexmkrc` repositooriumi juurkaustas); bibliograafia koostamiseks kasutati `biber`it. Varu- ja võrdluskompileerimist tehti aeg-ajalt ka `Overleaf`i kaudu.
- Kompileerimisvigade (nt tabelite üleulatumine lehekülje piiridest, lahtiste rühmade ebakõla, puuduvad `\cite` võtmed) diagnostika tehti valdavalt koos Claude Code'iga

- autor andis tööriistale `thesis.log` faili sisu või vigaste ridade väljavõtte ja palus pakkuda minimaalset parandust. Muudatus rakendati failile alles siis, kui autor oli selle üle vaadanud.
- Kvaliteedi hindamiseks vaadati iga olulisema muudatuse järel kompileeritud PDF üle, pöörates tähelepanu sisukorra järjepidevusele, tabelite mahtumisele leheküljele, jooniste paigutusele ning ristviidete (`\ref`) töötamisele.

Kompileerimisvigade parandamine oli üks valdkond, kus TI pakkus kõige otsesemat produktiivsuse kasvu – peenete $\LaTeX$ vigade otsimine, mis vastasel juhul oleks võtnud tunde käsitsi tööd, lahendati sageli mõne minutiga, kui logifail anti mudelile analüüsimiseks.

6.7 Versioonihaldus GitHubi abil

Kogu töö kirjutamise protsessi jooksul hoiti lähtefaili GitHubi repositooriumis, mis on kaitsmise ajaks tehtud avalikuks aadressil https://github.com/UkuRenekKronbergs/bakalaureusetoo_isi_klik. Versioonihalduse keskne väärtus TI-toetatud kirjutamise kontekstis oli võimalus iga TI-põhise muudatuse järel vaadata `git diff` väljundit ja kontrollida täpselt, mida agentne tööriist muutis – see muutis muudatused läbipaistvaks ja võimaldas vajadusel soovimatud muudatused tagasi pöörata. Suuremaid parandusvoore tehti eraldi arendusharus (*feature branch*) ja liideti peaharusse alles pärast tervikpildi ülevaatus. Selline distsipliin (enne TI-põhist muudatust commit, seejärel muudatus, seejärel diff'i ülevaatus) on soovituslik igale üliõpilasele, kes kasutab lõputöö kirjutamisel agentseid TI tööriistu.

6.8 Rollijaotus autori ja TI vahel

Töövoo läbipaistvuse huvides on tabelis 9 esitatud, millised kirjutamise ülesanded tegi autor ja millistel täitis TI abistavat rolli. Piiritlemisel lähtuti põhimõttest, et iga sisulise väite ja iga tsiteeritud allika eest vastutab autor ning TI saab osaleda üksnes nendes sammudes, mille tulemust autor ise hindab ja kinnitab.

Tabelist nähtub, et sisulist vastutust nõudvad ülesanded (teemavalik, eksperimendi disain, allikate valik, tulemuste tõlgendamine, järeldused) jäid täielikult autori kanda. TI roll piirdus rutiinsete, madala sisulise riskiga sammudega (kirjavigade kandidaatide tuvastamine, vormingu kontroll, sõnastusettepanekud), kus iga ettepanek läbis enne rakendamist autori ülevaatus.

Tabel 9. Autori ja TI rollijaotus käesoleva töö kirjutamisel

Ülesanne	Autor	TI tööriistad
Teema valik ja uurimisküsimuste sõnastus	Täielik	–
Eksperimendi disain ja läbiviimine	Täielik	–
Kirjanduse lugemine ja sünteesimine	Täielik	–
Peatüki mustandi kirjutamine	Põhiautor	Üksikute lõikude sõnastusettepanekud
Allikate otsimine ja valimine	Täielik	–
Viidete sisuline kontroll	Täielik	–
BibTeX-kirjete süntaksi kontroll	Lõplik otsus	Automaatne kontroll
Kirjavigade otsimine ja parandamine	Lõplik otsus	Kandidaatide tuvastamine
Lauseehituse ja stiili ühtlustamine	Lõplik otsus	Ettepanekud
L ^A T _E X kompileerimisvigade diagnoosimine	Lõplik otsus	Põhjuse analüüs
Tabelite ja jooniste vormistus	Lõplik otsus	Vormingu ettepanekud
Kvantitatiivsete tulemuste tõlgendamine	Täielik	–
Järelduste ja soovitude sõnastamine	Täielik	Sõnastusettepanekud

6.9 Piirangud ja saadud kogemused

Iteratiivne TI-toetatud kirjutamise töövoog tõi esile ka mitmeid praktilisi piiranguid, mida tasub tulevastel üliõpilastel arvestada.

- **Kontekstiakna täitumine pikemate sessioonide jooksul** tingis vajaduse sessiooni korrapärase taaskäivitamise ja `CLAUDE.md` faili kasutamise järele püsiva kontekstina. Pikema mustandi töö puhul osutus mõistlikuks jagada ülesanne peatükipõhisteks sessioonideks.
- **TI kalduvus “parandada” õiget teksti.** Mõnel juhul palus autor parandada ühte konkreetset viga, kuid tööriist muutis samal ajal ka ümbritsevat korrektset teksti. GitHubi `git diff` käsk oli hädavajalik, et selliseid soovimatuid muudatusi tuvastada ja tagasi õigeks muuta.

- **Eestikeelsete erisõnade ja terminite käsitlemine.** Keeleteaduslikult keerulised sõnad (nt liitsõnade silbitus või harvemad käändelõpud) vajasisid autori eraldi tähelepanu, kuna ilmnesisid kohati samad terminoloogilised vead, mida peaeksperimendis täheldati ka teistes mudelites.
- **Ajainvesteering.** Kuigi TI abil kiirenes vormistus- ja korrektuurifaas märgatavalt, ei vähendanud see sisulise töö (lugemise, mõtlemise, allikate kontrolli, tulemuste analüüsi) mahtu. See jäi autori vastutada ja moodustas suurema osa tegelikust ajakulust. TI peamine võit oli mehhaanilise töö vähendamine, mitte intellektuaalse töö asendamine.
- **Kulud.** TI-teenuste tellimused moodustasid üliõpilase eelarves tuntava, kuid professionaalse toimetamise teenusega võrreldes siiski väiksema kulu (vt peatükk 7.3). Läbipaistvuse huvides tuleb märkida, et autor kulutas kogu uurimisperioodi jooksul erinevate TI-teenuste tellimustele ligikaudu 360 € omavahendeid. See summa kattis nii peaeksperimendi läbiviimist kui ka käesoleva töö kirjutamise abivahendeid.

Kokkuvõttes osutus inimese juhitud iteratiivne töövoog koos agentse TI tööriistaga praktiliselt sobivaks ka piiratud eelarvega üliõpilase jaoks, eeldusel et TI tööriistu kasutatakse selgelt piiritletud abivahenditena, iga sisuline väide ja viide jääb autori vastutusele ning versioonihaldus dokumenteerib läbipaistvalt iga TI-põhise muudatuse. Käesoleva töövoogi põhjal tehtud üldisemad tähelepanekud ja praktilised soovitusid on koondatud peatükki 7.

7. Arutelu

Käesolev peatükk arutleb eksperimendi tulemuste üle laiemas kontekstis, käsitleb TI kasutamise praktilisi aspekte, piiranguid ja annab soovitusi.

7.1 TI tugevused lõputöö kirjutamisel

Eksperimendi tulemused kinnitavad, et kaasaegsed TI mudelid koos agentsete tööriistadega suudavad pakkuda märkimisväärset abi lõputöö kirjutamise protsessis. Selle katse jooksul demonstreeris Claude Opus 4.6 + Cowork kombinatsioon eriti veenvalt, et tipptasemel mudel koos agentse tööriistaga suudab genereerida tervikliku 61-leheküljelise eestikeelse lõputöö ka ühe kasutajaviibaga ilma iteratiivse suunamiseta. Peamised tugevused jagunevad järgmiselt.

Struktureerimine ja kavandamine. TI mudelid on eriti tugevad teksti struktureerimisel. Kõik neli testitud kombinatsiooni (arvestades GPT-5.4 Codex-laienduse kaudu saadud tulemust) suutsid luua loogilise ja akadeemilistele nõuetele vastava peatükkide jaotuse ainuüksi ühe kasutajaviibaga. Eriti kasulik on TI kasutamine töö algfaasis, kui üliõpilane vajab abi sisukorra ja peatükkide ülesehituse kavandamisel. Mudelid suudavad vaid minimaalse juhise põhjal luua detailse sisukorra koos soovitusliku leheküljemahuga iga peatüki jaoks.

Mustandi loomine. TI suudab genereerida tekstimustandeid, mis on piisavalt hea kvaliteediga, et neid edasi töödelda. See kiirendab kirjutamisprotsessi oluliselt, kuna üliõpilane ei pea alustama tühjalt lehelt, vaid saab toimetada ja täiendada olemasolevat teksti. Esialgse kasutuskogemuse põhjal võib TI mustandi kasutamine säästa hinnanguliselt 50–80% kirjutamisele kuluvast ajast, kuigi täpse ajavõidu mõõtmine vajab edaspidi süstemaatilisi kasutajakatseid.

Keeleline toimetamine. Kõik neli mudelit suudavad keelelist toimetamist toetada – parandada grammatikavigu, lauseehitust ja ühtlustada stiili, kuid täpsus erineb mudeliti. See on eriti väärtuslik eesti keele kontekstis, kus spetsiifilisi akadeemilise toimetamise teenuseid on vähe.

LaTeX-vormindamine. Oluline praktiline eelis on mudelite võimekus genereerida teksti otse LaTeX-vormingus, mis hõlmab korrektset viitamissüntaksit, tabeleid, jooniste viiteid ja matemaatilisi valemeid. See säästab üliõpilasele märkimisväärset vormistusaega. Võrdluseks, Microsoft Wordi puhul peab üliõpilane vormistuse – stiilid, ristviited, pealkirjade numeratsioon ja bibliograafia – enamasti käsitsi seadistama, kuna TI mudelid ei saa .docx faili sisemist struktuuri samamoodi manipuleerida nagu tekstipõhist L^AT_EX lähtekoodi. See teeb Wordi TI-toetatud akadeemilise kirjutamise kontekstis oluliselt aeganõudvamaks ja veaohhtikumaks valikuks.

7.2 TI puudujäägid ja piirangud

Vaatamata edusammudele on TI mudelitel lõputöö kirjutamise kontekstis endiselt olulised puudujäägid. Tulemuste tõlgendamisel tuleb eriti arvestada kolme metoodilist piirangut: eksperimendis võrreldi *mudeli ja agentse tööriista kombinatsioone*, mitte mudeleid isoleeritult; iga kombinatsiooni kohta tehti vaid üks jook; ning eksplitsiitset kontrollgruppi – ei inimkirjutatud lõputöö võrdluspunkti ega mudelite mitteagentset baasväljundit (peale GPT-5.4 vestlusliidese erandi) – ei kasutatud. Seetõttu näitavad tulemused konkreetsete töövoogude käitumist selles katses, mitte lõplikku mudelite üldist paremusjärjestust ega kvaliteeti absoluutse bakalaureusetöö läve suhtes. Süstemaatiline hinnang nõuaks iga kombinatsiooni kohta mitut kordusjooksu, suuremat valimit ja inimkirjutatud lõputöö kontrollvõrdlust.

Viidete usaldusväärsus. Üks tõsisemaid probleeme on viidete hallutsineerimine, kuid katsetulemused näitavad, et hallutsineerimismäärad varieeruvad mudelite vahel oluliselt. Käesolevas eksperimendis verifitseeris töö autor iga viite käsitsi, kontrollides, kas allikas tegelikult eksisteerib ning kas pealkiri, autorid, väljaandmise aasta ja URL/DOI vastavad tegelikkusele. Tulemused olid järgmised: GPT-5.4 + Codex 0% (kõik 22 viidet täielikult korrektsed), Opus 4.6 + Cwork 6% (35-st 2 viidet väikese metaandmete veaga), Gemini 3.1 Pro + Antigravity 11% (9-st 1 viide vale autoriga) ning Sonnet 4.6 + Cwork 22% (23-st 5 viidet välja mõeldud autoriloendiga). Sonnet 4.6 hallutsinatsioonimuster oli huvitav – artiklite pealkirjad ja arXiv-identifikaatorid olid valdavalt korrektsed, kuid mudel “täitis” autoriloendeid välja mõeldud nimedega või kombineeris kahe eri paberi metaandmed (näiteks viide “JITBot” Pornprasi ja Tantithamthavorn 2022, kus tegelikult oli paber “JITLine” MSR 2021 või JITBot ASE 2020 hoopis teiste autoritega). Need tulemused on kooskõlas varasemate uurimustega: Chelli et al. [43] tuvastasid GPT-4 hallutsinatsioonimääraks 28,6%; Mugaanyi et al. [9] leidsid, et DOI-de täpsus on valdkonniti väga erinev (loodusteadustes 32,7% vs humanitaarteadustes 8,5%), mis viitab sellele, et arvutiteaduse valdkonnas võivad tulemused olla mõnevõrra paremad. Kim et al. [10] on näidanud, et hallutsinatsioonid on eriti levinud väiksemate keelte kontekstis. Iga TI-genereeritud viide tuleb seega inimese poolt kontrollida – ka madala üldise hallutsinatsioonimääraga mudelite puhul, sest pealkirja olemasolu ei tähenda, et autorid või muud metaandmed oleksid samuti korrektsed.

Sisuline sügavus. TI-genereeritud tekstid kipuvad olema pealiskaudsed. Mudelid kordavad üldtuntud seisukohti, kuid ei suuda luua originaalset analüüsi ega teha uudseid järeldusi. See on

eriti problemaatiline tulemuste arutelu puhul, kus eeldatakse, et autor demonstreerib kriitilist mõtlemist ja seob tulemused laiemas kontekstiga kokku.

Eesti keele tehniline terminoloogia. Kuigi mudelite eesti keele oskus on oluliselt paranenud, esineb endiselt probleeme tehnilise terminoloogiaga. Mudelid kasutavad kohati ebaühtlast terminoloogiat (vahetavad eesti- ja ingliskeelsete terminite vahel) ning mõnikord loovad valesid termineid. Näiteks kasutati sõna “treenima” asemel “koolitama”, mis ei vasta arvutiteaduse valdkonnas juurdunud eestikeelsele terminoloogiale. Barbu et al. [44] on samuti täheldanud, et keelemudelid vajavad eesti keele spetsiifika jaoks täiendavat kohandamist, mis viitab laiemale probleemile väikeste keelte tehnilistel kasutusjuhtudel.

Kontekstiakna piirangud. Kuigi kontekstiaknad on oluliselt suurenenud, on need endiselt piiratud. 25-leheküljelise bakalaureusetöö tekst (ca 80 000–100 000 tähemärki ehk ca 40 000–50 000 tokenit) mahub küll kontekstiaknasse, kuid kui lisada juhendid, näidistööd ja varasemalt genereeritud osad, on kontekstiakna efektiivne kasutamine endiselt kriitiline.

Juhiste järgimise ebaühtlus ning liidese ja agentsete tööriistade mõju. Peatükis 5 kirjeldatud tulemused näitavad, et sama mudel võib eri liideses käituda sisuliselt erinevalt. GPT-5.4 vestlusliidese keeldumine ja Codex-laienduse kaudu õnnestunud failipõhine genereerimine viitavad sellele, et väljundit ei määra ainult alusmudel, vaid ka süsteemijuhised, ohutuspoliitika ja töövoo ülesehitus. Bianchi et al. [45] kirjeldatud “liialdatud ohutuskäitumine” aitab seda nähtust tõlgendada: liides võib uurimusliku ülesande tõlgendada akadeemilise väärkasutuse riskina. Agentne tööriist ei tähenda seejuures ohutuspiirangutest möödumist, vaid teistsugust ülesande konteksti, kus töö jaotub väiksemateks faili- ja kompileerimispõhisteks sammudeks.


Sama oluline on eristada vormilist veenvust sisulisest usaldusväärsusest. Gemini 3.1 Pro + Antigravity töö näitas kõige selgemalt, et korrektselt vormistatud ja statistiliste tabelitega tekst võib sisaldada täielikult fabritseeritud empiirikat. Opus 4.6 + Cowork andis selles katses tugevama ja tehniliselt sügavama väljundi, kuid ka seal tuli kontrollimata testitulemusi ja viiteid käsitleda riskina. Seega ei piisa agentse tööriista edukast L^AT_EX-vormistusest – sisulise vastutuse, andmete olemasolu ja viidete kontroll peab jääma veel inimese teha.

7.3 Hinnakujundus ja majanduslik teostatavus

Tabelis 10 on esitatud hinnanguline kuluarvestus 25-leheküljelise bakalaureusetöö genereerimiseks iga mudeliga.

Tabel 10. Bakalaureusetöö genereerimise hinnanguline kuluarvestus (EUR, koos 24% käibemaksuga)

Kulukomponent	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Sisendtokenid (ca 2M)	€4,23–8,47	€5,29	€6,35	€10,58
Väljundtokenid (ca 300K)	€3,81–5,71	€4,76	€4,76	€7,93
Agentse tööriista sisend/väljundkorrad	mitmekordne	mitmekordne	mitmekordne	mitmekordne
Eeldatav hind	€25–40	€26–33	€33–45	€56–74



Joonis 2. Bakalaureusetöö genereerimise eeldatava hinna vahemik mudelite lõikes.

Hinnad on esitatud eurodes, lähtudes mudelite pakkujate 2026. aasta mai ametlikest USD-hinnakirjadest [37–39] ja teisendatud kursi 1 EUR = 1,17 USD järgi (vt peatükk 4.5). Esitatud summad sisaldavad Eesti standardset 24% käibemaksu, mis vastab eraisikust üliõpilase tegelikule kulule.

Kuutellimused muudavad kulupildi mõnevõrra teistsuguseks: ChatGPT Plus ja Claude Pro maksavad Eesti regioonis ca €22–23 kuus (koos käibemaksuga), Google AI Pro €21,99 kuus (vt tabel 4). Praktikas saab üliõpilane teha põhilise töö 1–2 kuu tellimuse hinnaga, kui mahupiiranguid ei ületata (eeldusel, et ei soovita väga pikki sessioone järjest teha).

Kokkuvõttes on TI kasutamise majanduslik kulu Sonnet-klassi kombinatsioonidega mõistlik (€33–45 ühe lõputöö kohta), samas kui Opus-klassi mudeli kasutamine on ligikaudu 1,7 korda kallim (€56–74). Kõik testitud TI-variandid jäävad siiski üldjuhul odavamaks kui professionaalse toimetaja teenus, mis võib bakalaureusetöö puhul maksta mitusada eurot.

7.4 Eesti keele korrektuur ja toimetamine

Eraldi väärib tähelepanu TI mudelite kasutamine eestikeelse teksti korrektuuri ja toimetamise tööriistana. See on üks valdkondi, kus TI pakub kõige suuremat praktilist väärtust.

Järgmised hinnangud põhinevad autori mitteformaalsetel katsetel, mis jäid peaeksperimenti raamistikust välja ning mille täpsem metoodika vajab edaspidi süstemaatilist vormistamist. Need on esitatud suunavate tähelepanekutena.

Grammatikakontroll. Kõik neli mudelit suudavad tuvastada ja parandada enamiku grammatikavigadest eesti keeles. Claude Opus 4.6 oli kõige täpsem, tuvastades enamiku sisestatud vigadest; Sonnet 4.6 ja GPT-5.4 tuvastasid palju, kuid jätsid osa keerulisemaid vigu märkamata; Gemini 3.1 Pro tulemus oli nõrgim, jättes tuvastamata ka lihtsamaid morfoloogiavigu.

Stiilikontroll. Mudelid suudavad hinnata teksti vastavust akadeemilisele stiilile ja pakkuda parandusettepanekuid. See hõlmab liiga vaba keele tuvastamist, passiivi kasutamise soovitusi ja liigsete korduste märkamist. Claude Opus 4.6 oli selles osas kõige põhjalikum, pakkudes detailsemaid selgitusi paranduste kohta.

Terminoloogiakontroll. Mudelid suudavad kontrollida tehnilise terminoloogia ühtlust ja korrektsust, kuid siin on täpsus oluliselt madalam kui grammatikakontrollis. Terminoloogilist

kontrolli ei saa täielikult TI-le delegeerida ja valdkonnaspetsiifiline inimekspertiis on endiselt vajalik.

7.5 Soovitused TI tööriista valikuks

Eksperimendi tulemuste ja praktiliste kogemuste põhjal saab anda järgmised soovitused.

Selle katse kõrgeim üldkvaliteet: Claude Opus 4.6 koos Cowork'iga. Käesolev eksperiment näitas, et Claude Opus 4.6 + Cowork kombinatsioon saavutas selles katses kõrgeima üldkvaliteedi eestikeelse akadeemilise teksti genereerimisel. Kombinatsioon eristus teistest terviklikkuse, akadeemilise stiili, tehnilise detailsuse ja sisulise sügavuse poolest, kuigi madalaim kirjavigade arv oli GPT-5.4 + Codexi väljundis. Peamine puudus on oluliselt kõrgem hind. Kuna iga kombinatsiooni kohta tehti vaid üks jooks ja keelemudelid on mitteterministlikud, tuleb seda soovitust võtta eksploratiivse viitena, mitte lõpliku kvaliteedipingerea kinnituseks.

Parim hinna-kvaliteedi suhe: Claude Sonnet 4.6 koos Cowork'iga. Claude Sonnet 4.6 + Cowork kombinatsioon on kõige sobivam valik piiratud eelarvega üliõpilase jaoks. Kombinatsioon paistis silma akadeemilise stiili, juhiste järgimise ja teksti struktureerimise poolest ning on oluliselt soodsam kui Opus. Pikendatud mõtlemisrežiim parandab keerulisemate peatükkide kvaliteeti.

Lühikeste lõikude jaoks: GPT-5.4. GPT-5.4 sobib hästi lühikeste tekstilõikude genereerimiseks ja keelelise korrektuuri jaoks. Kui soov on genereerida tervikdokumenti, siis ChatGPT vestlusliidese süsteemijuhised ja ohutuspoliitika võivad selle blokeerida või suunata ingliskeelsele väljundile, samas kui ChatGPT Codex laiendus Visual Studio Code'is andis käesolevas katses sama viibaga tervikliku eestikeelse dokumendi (vt peatükk 5.3).

7.6 Soovitused lõputöö genereerimiseks agentsete TI tööriistadega

Käesoleva uurimuse praktiliste kogemuste põhjal, sealhulgas Opus 4.6 mudeliga Cowork'i kaudu genereeritud paroolihalduri lõputöö (vt peatükk 5.5), saab anda järgmised soovitused agentsete TI tööriistade kasutamiseks lõputöö genereerimisel. Siin peetakse silmas tööriistu, mis suudavad projekti faile lugeda ja muuta, käsurea kāske käivitada ning L^AT_EX-projekti struktuuri järgida.

7.6.1 Genereerimise töövoog

Soovitame järgmist samm-sammulist töövoogu:

1. **Kasuta L^AT_EX malli algusest peale.** Paigalda ülikooli L^AT_EX mall (nt UniTartuCS) projektikausta enne genereerimise alustamist. Failipõhise ligipääsuga agentne tööriist saab seejärel malli struktuuri tuvastada ja järgida.
2. **Genereeri sisukord ja struktuur.** Alusta sisukorra ja peatükkide ülesehituse genereerimisega. Anna mudelile ette teema, uurimisküsimused ja mahunõuded. Kontrolli ja kinnita struktuur enne edasi liikumist.
3. **Genereeri peatükid järjest.** Genereeri iga peatükk eraldi, alustades sissejuhatusest. Iga järgmise peatüki genereerimisel on eelnevad peatükid kontekstis, mis tagab sidususe.
4. **Genereeri tabelid ja joonised eraldi.** Tabelite ja jooniste L^AT_EX kood on keerulisem ja vajab eraldi tähelepanu. Genereeri need eraldi sammuna ja kontrolli visuaalset tulemust.
5. **Lisa viited ise või kontrolli neid põhjalikult.** Ära lase mudelil viiteid “välja mõelda”. Viidete hallutsineerimise riski vähendamiseks järgi seda malli:
 - otsi ise allikaid;
 - lisa leitud allikate andmed BibTeX faili;
 - palu mudelil viiteid tekstis kasutada ainult olemasolevatest allikatest.
6. **Kompileeri regulaarselt.** Kasuta tööriista või arenduskeskkonna võimalust käivitada `pdflatex` ja `biber` käske, et kontrollida, kas genereeritud L^AT_EX kood kompileerub vigadeta.
7. **Vaata üle ja paranda.** Iga genereeritud peatüki järel vaata tekst üle, märgi probleemkohad ja palu mudelil need parandada. Ära jäta ülevaatamist töö lõppu.

7.6.2 Parimad praktikad

- **Kasuta võimaluse korral pikendatud mõtlemisrežiimi.** Pikendatud mõtlemisrežiim või sellele vastav sügavama arutluse seadistus (*extended thinking*) võib parandada keeruliste akadeemiliste tekstide kvaliteeti. See on eriti kasulik sissejuhatuse, metoodika ja arutelu peatükkide jaoks.
- **Anna konkreetseid juhiseid.** Mida konkreetsemad on juhised, seda parem on tulemus. Selle asemel, et paluda “kirjuta sissejuhatuse”, täpsusta töö maht ja peamised teemad.
- **Kontrolli viiteid alati.** Ükski TI mudel ei genereeri 100% korrektseid viiteid alati. Kontrolli iga viite olemasolu ja korrektsust käsitsi.

- **Ära usalda ühe kasutajaviibaga (*single-prompt*) tulemust pimesi ilma kriitilise ülevaatamiseta.** Käesoleva uurimuse eksperimendis andis see lähenemine mõnel juhul tugeva vormilise tulemuse, kuid sisaldas endiselt hallutsineeritud viiteid ja kontrollimata empiirilisi väiteid (vt peatükk 5). Parima kvaliteedi saavutamiseks on mõistlik kombineerida ühe viibaga genereerimist iteratiivsete paranduste ja kasutaja ülevaatustega.
- **Ole kursis enda tööga.** TI on abivahend, mitte autor. Üliõpilane peab iga genereeritud lõigu sisuliselt üle vaatama ja vajadusel ümber kirjutama.
- **Kasuta keeruliste peatükkide jaoks tugevamat mudelit.** Keerukamate peatükkide, näiteks metoodika ja arutelu, genereerimiseks või põhjalikuks toimetamiseks tasub valida hetkel kättesaadav tugevam arutlusmudel. Lihtsamate korrektuuri- ja vormistusülesannete jaoks piisab sageli odavamast või kiiremini vastavast mudelist. Kuna mudeliperekonnad muutuvad kiiresti, tasub soovitusel rakendamisel kontrollida, millised keelemudelid on praegu kättesaadavad.

7.7 Tööriistad, mida vältida

Lisaks peaeksperimendis osalenud nelja mudeli võrdlusele testis autor lühemate mitteformaalsete katsete raames ka mõnda teist tööriista, mida lõputöö kirjutamise abivahendina ei saa soovitada, vaatamata nende laialdasele kättesaadavusele üliõpilastele. Järgmised hinnangud ei põhine käesoleva uurimuse formaalsel võrdlusel, vaid autori praktilisel kasutuskogemusel ning nende arendajate avalikul dokumentatsioonil.

Perplexity ei sobi mahukate kirjutamisülesannete põhitööriistaks. Perplexity on eelkõige TI-põhine otsingu- ja vastamissüsteem, mis sobib hästi üksikküsimuste, allikate esmase leidmise ja lühikeste kokkuvõtete jaoks. Lõputöö tervikpeatükkide genereerimisel ilmnes aga piirang: Perplexity kasutuskogemus ei ole samaväärne alusmudeli otse kasutamisega. Perplexity ametlik API-dokumentatsioon eristab otsingukonteksti suurust mudeli kontekstiaknast: otsingukontekst määrab, kui palju veebist leitud infot päringusse kaasatakse, samas kui kontekstiaken määrab maksimaalse tokenite hulga, mida mudel ühe päringu käigus töödelda saab [46]. Agent API toetab küll eri pakkujate mudeleid [47], kuid Perplexity otsingupõhine töövoog rakendab lisaks otsingu, tsiteerimise, kulude ja päringu töötlemise piiranguid. Autori veebiliidese katsetes ei olnud võimalik pikemat töömustandit sama järjepidevalt kontekstis hoida nagu mudelite natiivsetes või failipõhistes agentsetes keskkondades. Ka DataStudioli ülevaade rõhutab, et

Perplexity failide ja vestluste puhul ei lisata kogu materjali automaatselt vastuse koostamise hetkel mudeli konteksti, vaid süsteem valib ja lisab aktiivsesse päringusse ainult asjakohaseid lõike [48]. Seetõttu võib pikema vestluse või suurema dokumendimaterjali korral kaduda osa varem kokkulepitud tingimustest, struktuurist või piirangutest. Kokkuvõttes sobib Perplexity hästi infootsinguks ja lühikeste küsimuste lahendamiseks, kuid mitte lõputöö genereerimise põhitööriistaks, kus on vaja mahukat, püsivat ja täpselt kontrollitavat projektikonteksti.

GitHub Copilot Pro ei sobi akadeemilise teksti genereerimiseks. GitHub Copilot Pro, mida Tartu Ülikool pakub üliõpilastele tasuta GitHub Education programmi kaudu, on mõeldud eelkõige koodi kirjutamise abivahendiks [49]. GitHubi enda dokumentatsiooni kohaselt on Copilot Chat mõeldud ainult kodeerimisega seotud päringutele ning juhiste piiramine kodeerimisülesannetega parandab mudeli väljundi kvaliteeti [50]. Lõputöö genereerimise kontekstis osutus see aga ebapiisavaks. Copilot'i mudelid tundusid oluliselt "laisemad" – nad kippusid andma lühikesi, pealiskaudseid vastuseid ja vältisid pikemate akadeemiliste tekstilõikude genereerimist. Nguyen ja Nadi [51] on oma empiirilises uurimuses näidanud, et Copilot'i soovitusel on tähemärkide pikkuse piirang, mis takistab pikema väljundi genereerimist, ning keerulisemate ülesannete korral langeb soovitude kvaliteet märgatavalt. Lisaks rakendab GitHub Copilot'ile päringupõhiseid limiite (*rate limits*), mis piiravad kasutamise intensiivsust [52]. Kokkuvõttes on tööriist optimeeritud lühikeste koodilõikude ja kooditäienduste jaoks, mitte terviklike akadeemiliste tekstide loomiseks. Seetõttu ei saa GitHub Copilot Pro-d soovitada lõputöö kirjutamise abivahendina, vaatamata sellele, et see on üliõpilastele tasuta kättesaadav.

7.8 Tulevikuväljavaated

TI mudelite ja neid ümbritsevate tööriistade areng on kiire ning käesoleva töö tulemused peegeldavad 2025–2026. aasta seisuga. Lähitulevikus on tõenäoliselt olulised järgmised arengusuunad:

- **Eesti keele toe sihipärane parandamine** – eesti keele kvaliteedi paranemine ei sõltu ainult sellest, kui suur osa üldmudelite treeningandmetest on eestikeelne. Olulisemaks võivad osutuda kvaliteetsemad eestikeelsed terminibaasid, jätkutreenimine ja väikeste keelte jaoks kohandatud hindamismetoodikad. EstLLM projekti [5] tulemused näitavad, et spetsialiseeritud jätkutreenimine võib eesti keele kvaliteeti märkimisväärselt tõsta ka olemasolevates mudelites.

- **Agentsete akadeemiliste töövoogude levik** – Claude Code'i, Cowork'i, Google'i Antigravity ja OpenAI ChatGPT Codex laienduse laadsed tööriistad näitavad, et akadeemilise kirjutamise tugi liigub vestlusaknast üha enam projektipõhisesse keskkonda. Sellise töövoogu väärtus ei seisne ainult teksti genereerimises, vaid ka failide haldamises, L^AT_EX-koodi parandamises, kompileerimisvigade diagnoosimises ja viidete tehnilises kontrollis. Käesolev eksperiment näitas, et agentne töövoog parandas genereerimise kvaliteeti kõigi testitud mudelite puhul.
- **Konteksti haldamise paranemine** – kontekstiaknad võivad jätkuvalt suurened, kuid ainult suurem tokenite arv ei taga paremat akadeemilist tulemust. Sama oluline on see, kuidas tööriist valib, kokku võtab ja säilitab varasemaid töö osi, allikaid, juhendeid ja kasutaja parandusi. Seetõttu muutub tõenäoliselt olulisemaks projektimälu, otsingupõhise konteksti ja failipõhise töövoogu kvaliteet.
- **Valdkonnaspetsiifilised akadeemilised abivahendid** – lähiaastatel võib kasvada tööriistade hulk, mis on kohandatud konkreetsete erialade, viitamisstiilide, ülikoolide juhendite või keelte jaoks. Sellised süsteemid ei pea tingimata olema eraldi suured mudelid; sama eesmärki võivad täita ka üldmudelid koos kontrollitud allikabaasi, terminiloendi, mallide ja automaatsete kvaliteedikontrollidega.
- **TI kasutamise läbipaistvam integreerimine õppetöösse** – akadeemilised institutsioonid liiguvad tõenäoliselt pelgalt keelamise ja tuvastamise loogikalt TI kasutuse läbipaistva kirjeldamise ning hindamise suunas. See nõuab hindamismetoodikaid, mis keskenduvad üliõpilase sisulisele panusele, allikakriitikale ja tööprotsessi dokumenteerimisele, mitte ainult lõpptulemuse vormilisele sarnasusele TI-genereeritud tekstiga.

Käesolev uurimus piirdus neljast mudelist ja kolmest agentsest tööriistast koosneva võrdlusega 2025–2026. aasta seisuga. Arvestades TI valdkonna arengutempot, kus uusi mudeleid avaldatakse mitu korda aastas, tuleks sarnaseid teostatavusuuringuid korrata regulaarselt. See võimaldaks hinnata, kuidas ülalnimetatud arengud tegelikult realiseeruvad ja millised käesoleva töö järeldustest jäävad kehtima ka uuema põlvkonna mudelite puhul.

8. Kokkuvõte

Käesolev bakalaureusetöö uuris tehisintellekti (TI) rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Selleks võrreldi nelja suurt keelemudelit koos agentsete tööriistadega: Google Gemini 3.1 Pro koos Antigravityga, OpenAI GPT-5.4 koos ChatGPT Codexi Visual Studio Code'i laiendusega ning Anthropic Claude Sonnet 4.6 ja Claude Opus 4.6 koos Coworkiga. Kõigile kombinatsioonidele anti sama lühike eestikeelne viip, mis palus luua UniTartuCS malli kasutava tervikliku L^AT_EX-vormingus bakalaureusetöö ja valida ise informaatikaga seotud teema. Kuna iga kombinatsiooni kohta tehti üks jook, tuleb tulemusi käsitleda eksploratiivse hinnanguna konkreetsetele mudel-tööriista paaridele, mitte lõpliku mudelite paremusjärjestusena.

Katse näitas, et agentsed tööriistad võimaldavad suurtel keelemudelitel luua vormilt terviklikke eestikeelseid akadeemilisi dokumente ka minimaalse juhendamisega. Kõik neli kombinatsiooni suutsid koostada bakalaureusetöö struktuuriga väljundi, kuid need erinesid märgatavalt mahu, keelelise täpsuse, viidete kontrollitavuse, sisulise sügavuse ja akadeemilise väärkasutuse riski poolest. Selles katses andis kõige terviklikuma ja tehniliselt detailsema tulemuse Claude Opus 4.6 + Cowork, samas kui GPT-5.4 + Codex eristus madalaima kirjavigade arvu ja täielikult kontrollitavate viidetega. Claude Sonnet 4.6 + Cowork oli praktiliselt tugev ja hinnalt taskukohasem valik, kuid selle viidetes esines enim metaandmete hallutsinatsioone. Gemini 3.1 Pro + Antigravity näitas kõige selgemalt, et vormiliselt usutav töö võib sisaldada täielikult fabritseeritud empiirilist osa.

Üks olulisemaid järeldusi on, et tulemust ei määra ainult alusmudel, vaid ka liides ja agentne töövoog. GPT-5.4 tavapärane vestlusliides keeldus terviklikku lõputööd genereerimast ning pakkus selle asemel akadeemilise aususe piirangutega kooskõlas olevat teostatavusjuhendit. Sama mudel ChatGPT Codexi failipõhises töövoos genereeris aga tervikliku eestikeelse lõputöö. See näitab, et süsteemijuhised, ohutuspoliitika, faili ligipääs, kompileerimisvõimekus ja töövoogu ülesehitus mõjutavad väljundit vähemalt sama tugevalt kui mudeli üldine keeleline võimekus.

Kõige tõsisemad riskid olid viidete hallutsineerimine ja kontrollimata empiiriliste väidete esitamine. Genereeritud töödes esines olematuid või valede metaandmetega allikaid, väljamõeldud osalejaid, statistilisi tulemusi, testiraporteid ja auditeid. Eriti ohtlik on see, et sellised väited võivad olla vormiliselt väga veenvad: tabelid, p-väärtused, arhitektuurikirjeldused ja koodinäited jätavad mulje läbiviidud uurimusest ka siis, kui andmeid tegelikult ei eksisteeri.

Seetõttu ei saa TI loodud akadeemilist teksti käsitleda usaldusväärse lõppversioonina enne, kui inimene on kontrollinud allikaid, metoodikat, andmeid, tulemusi ja järeldusi.

Töö enda kirjutamise kogemus kinnitas sama järeldust praktilisel tasandil. Käesolev bakalaureusetöö ei valminud ühe viibaga, vaid inimese juhitud iteratiivses töövoos: autor sõnastas uurimisküsimused, kavandas ja viis läbi eksperimendi, kontrollis viited, kogus ja tõlgendas kvantitatiivsed tulemused ning tegi lõplikud sisulised otsused. TI tööriistu kasutati abistavalt peamiselt sõnastuse, keelelise korrektuuri, L^AT_EX-vormistuse, kompileerimisvigade diagnoosimise ja vigade otsimise jaoks. Versioonihaldus GitHubis osutus seejuures oluliseks kaitsemehhanismiks, sest iga suuremat TI-põhist muudatust sai diff'ina kontrollida ja vajadusel tagasi pöörata.

Majanduslikult on TI kasutamine bakalaureusetöö toetava tööriistana üliõpilase jaoks realistlik, eriti Sonnet-klassi mudelite ja kuutellimuste korral. Opus-klassi mudel andis selles katses küll tugevama üldtulemuse, kuid selle kasutamine on kallim. Kulu ei tohiks siiski olla peamine otsustuskriteerium. Olulisem on töövoog, kus mudelile antakse kitsalt piiritletud ülesandeid, olemasolevad allikad lisatakse käsitsi kontrollitud bibliograafiasse, muudatusi jälgitakse versioonihalduse abil ning empiirilisi tulemusi ei lasta mudelil iseseisvalt välja mõelda.

Uurimuse põhjal saab järeldada, et TI sobib lõputöö kirjutamisel abivahendiks, kuid mitte asendajaks ega iseseisvaks autoriks. TI tugevused on struktuuri kavandamine, mustandi loomine, keeleline toimetamine, L^AT_EX-vormindus ja tehniliste vigade kiire diagnoosimine. Inimese panus jääb asendamatuks uurimisküsimuste sõnastamisel, kirjanduse sisulisel mõtestamisel, metoodika kavandamisel, andmete ja viidete kontrollimisel ning originaalsete järelduste tegemisel. Vastutustundlik TI kasutamine ei tähenda töö delegeerimist mudelile, vaid tööprotsessi läbipaistvat ja kontrollitud täiendamist.

Edaspidine uurimistöö võiks keskenduda korduskatsetele, kus iga mudel-tööriista kombinatsiooni jooksutatakse mitu korda ning hinnatakse tulemuste varieeruvust. Samuti vajavad uurimist spetsialiseeritud akadeemilised TI tööriistad, eesti keelele kohandatud mudelid, RAG-süsteemide mõju viidete kvaliteedile ning automaatsed kontrollimehhanismid, mis suudaksid tuvastada fabritseeritud empiirilisi väiteid.

Viited

- [1] Liang W., Zhang Y., Wu Z., Lepp H., Ji W., Zhao X., Cao H., Liu S., He S., Huang Z., Yang D., Potts C., Manning C. D. ja Zou J. Y. Mapping the Increasing Use of LLMs in Scientific Papers. *arXiv preprint arXiv:2404.01268* (2024). <https://arxiv.org/abs/2404.01268>.
- [2] Brown T., Mann B., Ryder N., Subbiah M., Kaplan J. D., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A. jt. Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems* 33 (2020), lk 1877–1901. <https://arxiv.org/abs/2005.14165>.
- [3] OpenAI. GPT-4 Technical Report. <https://arxiv.org/abs/2303.08774>. Viimati vaadatud: 15.02.2026. 2023.
- [4] Kuulmets H.-A., Purason T. ja Fišel M. How Well do LLMs Know Finno-Ugric Languages? A Systematic Assessment. *Proceedings of the Joint 25th Nordic Conference on Computational Linguistics and 11th Baltic Conference on Human Language Technologies (NoDaLiDa/Baltic-HLT 2025)*. 2025. <https://aclanthology.org/2025.nodalida-1.37/>.
- [5] Dorkin A., Purason T., Kalbaliyev E., Kuulmets H.-A., Ojastu M., Fišel M., Alumäe T., Aedmaa E., Kruusmaa K. ja Sirts K. EstLLM: Enhancing Estonian Capabilities in Multilingual LLMs via Continued Pretraining and Post-Training. *arXiv preprint arXiv:2603.02041* (2026). <https://arxiv.org/abs/2603.02041>.
- [6] Tartu Ülikool, Arvutiteaduse instituut. Tartu Ülikooli arvutiteaduse instituudis kaitstavate lõputööde nõuded ja hindamine. https://cs.ut.ee/sites/default/files/2026-02/2026_02_03_%20ATI_loputoode_nouded_ja_hindamiskriteeriumid.docx.pdf. Kinnitatud 03.02.2026; viimati vaadatud: 30.04.2026. 2026.
- [7] Lund B. D., Mannuru N. R., Teel Z. A., Lee T. H., Ortega N. J., Simmons S. ja Ward E. Student Perceptions of AI-Assisted Writing and Academic Integrity: Ethical Concerns, Academic Misconduct, and Use of Generative AI in Higher Education. *AI in Education* 1.1 (2025), lk 2. <https://doi.org/10.3390/aieduc1010002>.
- [8] Rodafinos A. The Integration of Generative AI Tools in Academic Writing: Implications for Student Research. *Social Education Research* 6.2 (2025), lk 250–258. <https://doi.org/10.37256/ser.6220256517>.
- [9] Mugaanyi J., Cai L., Cheng S., Lu C. ja Huang J. Evaluation of Large Language Model Performance and Reliability for Citations and References in Scholarly Writing: Cross-

- Disciplinary Study. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/52935>.
- [10] Kim E., Kipchumba F. ja Min S. Geographic Variation in LLM DOI Fabrication: Cross-Country Analysis of Citation Accuracy Across Four Large Language Models. *Publications* 13.4 (2025), lk 49. DOI: [10.3390/publications13040049](https://doi.org/10.3390/publications13040049). <https://doi.org/10.3390/publications13040049>.
 - [11] Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser Ł. ja Polosukhin I. Attention is All You Need. *Advances in Neural Information Processing Systems* 30 (2017), lk 5998–6008. <https://arxiv.org/abs/1706.03762>.
 - [12] Devlin J., Chang M.-W., Lee K. ja Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT* (2019), lk 4171–4186. <https://arxiv.org/abs/1810.04805>.
 - [13] Radford A., Wu J., Child R., Luan D., Amodei D. ja Sutskever I. Language Models are Unsupervised Multitask Learners. *OpenAI Blog* (2019). https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.
 - [14] Erelt M., Erelt T. ja Ross K. Eesti keele käsiraamat. Tallinn: Eesti Keele Sihtasutus, 2007. <https://arhiiv.eki.ee/books/ekk09/>.
 - [15] Common Crawl Foundation. Statistics of Common Crawl Monthly Archives: Distribution of Languages. <https://commoncrawl.github.io/cc-crawl-statistics/plots/languages>. Viimati vaadatud: 30.04.2026. 2026.
 - [16] Nguyen T., Nguyen C. V., Lai V. D., Man H., Ngo N. T., Deroncourt F., Rossi R. A. ja Nguyen T. H. CulturaX: A Cleaned, Enormous, and Multilingual Dataset for Large Language Models in 167 Languages. *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. 2024, lk 4226–4237. <https://aclanthology.org/2024.lrec-main.377>.
 - [17] Tanvir H., Kittask C., Eiche S. ja Sirts K. EstBERT: A Pretrained Language-Specific BERT for Estonian. *Proceedings of the 23rd Nordic Conference on Computational Linguistics (NoDaLiDa)*. 2021, lk 11–19. <https://aclanthology.org/2021.nodalida-main.2/>.
 - [18] Üstün A., Aryabumi V., Yong Z., Ko W.-Y., D'souza D., Onilude G., Bhandari N., Singh S., Ooi H.-L., Kayid A. jt. Aya Model: An Instruction Finetuned Open-Access Multilingual Language Model. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational

- Linguistics, 2024, lk 15894–15939. DOI: [10.18653/v1/2024.acl-long.845](https://doi.org/10.18653/v1/2024.acl-long.845). <https://aclanthology.org/2024.acl-long.845/>.
- [19] Kiil A. Suurte keelemudelite võrdlev analüüs Eesti bioloogiaolümpiaadide küsimuste põhjal. Magistritöö. Tartu Ülikool, Arvutiteaduse instituut, 2025. <https://hdl.handle.net/10062/117055>.
- [20] Lee Y., Ka S., Son B., Kang P. ja Kang J. Navigating the Path of Writing: Outline-guided Text Generation with Large Language Models. *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 3: Industry Track)*. Albuquerque, New Mexico: Association for Computational Linguistics, 2025, lk 233–250. DOI: [10.18653/v1/2025.naacl-industry.20](https://doi.org/10.18653/v1/2025.naacl-industry.20). <https://aclanthology.org/2025.naacl-industry.20/>.
- [21] Tang X., Duan X. ja Cai Z. Large Language Models for Automated Literature Review: An Evaluation of Reference Generation, Abstract Writing, and Review Composition. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*. Suzhou, China: Association for Computational Linguistics, 2025, lk 1602–1617. DOI: [10.18653/v1/2025.emnlp-main.83](https://doi.org/10.18653/v1/2025.emnlp-main.83). <https://aclanthology.org/2025.emnlp-main.83/>.
- [22] Usher M. ja Amzalag M. From Prompt to Polished: Exploring Student–Chatbot Interactions for Academic Writing Assistance. *Education Sciences* 15.3 (2025), lk 329. DOI: [10.3390/educsci15030329](https://doi.org/10.3390/educsci15030329). <https://doi.org/10.3390/educsci15030329>.
- [23] Nadra S. ja Purdy J. P. Is GenAI a Good Editor of Academic Writing? *Computers and Composition* 80, 102993 (2026). DOI: [10.1016/j.compcom.2026.102993](https://doi.org/10.1016/j.compcom.2026.102993). <https://doi.org/10.1016/j.compcom.2026.102993>.
- [24] Pinto M. M., Araújo E. E. R., Rahhal Z., Stanbouly D. ja Grillo R. AI-Assisted Translation in Oral and Maxillofacial Surgery: A Comparative Evaluation. *Journal of Stomatology, Oral and Maxillofacial Surgery* 127.3, 102717 (2026). DOI: [10.1016/j.jormas.2026.102717](https://doi.org/10.1016/j.jormas.2026.102717). <https://doi.org/10.1016/j.jormas.2026.102717>.
- [25] Rao D. ja Callison-Burch C. BibTeX Citation Hallucinations in Scientific Publishing Agents: Evaluation and Mitigation. *arXiv preprint arXiv:2604.03159* (2026). DOI: [10.48550/arXiv.2604.03159](https://doi.org/10.48550/arXiv.2604.03159). <https://arxiv.org/abs/2604.03159>.
- [26] Peters U. ja Chin-Yee B. Generalization Bias in Large Language Model Summarization of Scientific Research. *Royal Society Open Science* 12.4 (2025), lk 241776. DOI: [10.1098/rsos.241776](https://doi.org/10.1098/rsos.241776). <https://doi.org/10.1098/rsos.241776>.

- [27] Doshi A. R. ja Hauser O. P. Generative AI Enhances Individual Creativity but Reduces the Collective Diversity of Novel Content. *Science Advances* 10.28 (2024). <https://doi.org/10.1126/sciadv.adn5290>.
- [28] Bender E. M., Gebru T., McMillan-Major A. ja Shmitchell S. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of FAccT* (2021), lk 610–623. <https://doi.org/10.1145/3442188.3445922>.
- [29] Lillepalu H. G. ja Alumäe T. Estonian Native Large Language Model Benchmark. *arXiv preprint arXiv:2510.21193* (2025). Viimati muudetud 19.02.2026; vastu võetud konverentsile LREC 2026. <https://arxiv.org/abs/2510.21193>.
- [30] Google. Upload and Analyse Files in Gemini Apps. <https://support.google.com/gemini/answer/14903178>. Viimati vaadatud: 02.05.2026. 2026.
- [31] Anthropic. Upload Files to Claude. <https://support.claude.com/en/articles/8241126-upload-files-to-claude>. Viimati vaadatud: 02.05.2026. 2026.
- [32] OpenAI. File Uploads FAQ. <https://help.openai.com/en/articles/8555545-file-uploads-faq>. Viimati vaadatud: 02.05.2026. 2026.
- [33] Google DeepMind. Gemini 3.1 Pro: A smarter model for your most complex tasks. <https://blog.google/innovation-and-ai/models-and-research/gemini-models/gemini-3-1-pro/>. Viimati vaadatud: 01.03.2026. 2026.
- [34] OpenAI. Introducing GPT-5.4. <https://openai.com/index/introducing-gpt-5-4/>. Avaldatud 05.03.2026; viimati vaadatud: 07.05.2026. 2026.
- [35] Anthropic. Introducing Claude Sonnet 4.6. <https://www.anthropic.com/news/claude-sonnet-4-6>. Viimati vaadatud: 01.03.2026. 2026.
- [36] Anthropic. Introducing Claude Opus 4.6. <https://www.anthropic.com/news/claude-opus-4-6>. Viimati vaadatud: 10.03.2026. 2026.
- [37] OpenAI. API Pricing. <https://openai.com/api/pricing/>. Viimati vaadatud: 24.04.2026. 2026.
- [38] Anthropic. Claude API Pricing. <https://www.anthropic.com/pricing>. Viimati vaadatud: 24.04.2026. 2026.
- [39] Google. Gemini API Pricing. <https://ai.google.dev/gemini-api/docs/pricing>. Viimati vaadatud: 24.04.2026. 2026.
- [40] Anthropic. Claude Code: An Agentic Coding Tool. <https://docs.anthropic.com/en/docs/claude-code>. Viimati vaadatud: 10.03.2026. 2026.

- [41] OpenAI. Introducing Codex. <https://openai.com/index/introducing-codex/>. Viimati vaadatud: 16.03.2026. 2025.
- [42] Anthropic. Introducing Claude Opus 4.7. <https://www.anthropic.com/news/claude-opus-4-7>. Viimati vaadatud: 30.04.2026. 2026.
- [43] Chelli M., Descamps J., Lavoué V., Trojani C., Azar M., Deckert M., Raynier J.-L., Clowez G., Boileau P. ja Ruetsch-Chelli C. Hallucination Rates and Reference Accuracy of ChatGPT and Bard for Systematic Reviews: Comparative Analysis. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/53164>.
- [44] Barbu E., Muru M.-L. ja Malva S. M. Improving Estonian Text Simplification through Pretrained Language Models and Custom Datasets. *arXiv preprint arXiv:2501.15624* (2025). <https://arxiv.org/abs/2501.15624>.
- [45] Bianchi F., Suzgun M., Attanasio G., Röttger P., Jurafsky D., Hashimoto T. ja Zou J. Safety-Tuned LLaMAs: Lessons From Improving the Safety of Large Language Models that Follow Instructions. *arXiv preprint arXiv:2309.07875* (2023). <https://arxiv.org/abs/2309.07875>.
- [46] Perplexity. Pricing. <https://docs.perplexity.ai/docs/getting-started/pricing>. Viimati vaadatud: 30.04.2026. 2026.
- [47] Perplexity. Models. <https://docs.perplexity.ai/docs/agent-api/models>. Viimati vaadatud: 30.04.2026. 2026.
- [48] DataStudios. Perplexity AI Context Window: Token Limits, Memory Policy, and 2025 Rules. <https://www.datastudios.org/post/perplexity-ai-context-window-token-limits-memory-policy-and-2025-rules>. Viimati vaadatud: 14.03.2026. 2025.
- [49] GitHub. About Individual GitHub Copilot Plans and Benefits. <https://docs.github.com/en/copilot/concepts/billing/individual-plans>. Viimati vaadatud: 14.03.2026. 2026.
- [50] GitHub. Responsible use of GitHub Copilot Chat in your IDE. <https://docs.github.com/en/copilot/responsible-use/chat-in-your-ide>. Viimati vaadatud: 30.04.2026. 2026.
- [51] Nguyen N. ja Nadi S. An Empirical Evaluation of GitHub Copilot's Code Suggestions. *Proceedings of the 19th International Conference on Mining Software Repositories (MSR)*. 2022, lk 1–5. <https://doi.org/10.1145/3524842.3528470>.
- [52] GitHub. Usage limits for GitHub Copilot. <https://docs.github.com/en/copilot/concepts/usage-limits>. Viimati vaadatud: 30.04.2026. 2026.

Lisad

I. Eksperimendis kasutatud viip

Käesoleva uurimuse eksperimendis kasutati kõigi nelja mudel-tööriista kombinatsiooni puhul üht ja sama lühikest eestikeelset viipa ehk ühe kasutajaviibaga (*single-prompt*) lähenemist. Viipa ei muudetud ega iteratiivselt täiendatud. Täielik viip oli järgmine:

“Sa oled kogenud akadeemiline kirjutaja. Loo täielik bakalaureusetöö LaTeX-vormingus (lisasin töökausta vajaliku malli), mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele. Teema peab olema informaatikaga seotud ja vali ise. Autor on Uku Renek Kronbergs ja juhendaja Alo Peets (MSc).”

Viiba sisulised elemendid:

- **Mudeli roll** – “kogenud akadeemiline kirjutaja” kui üldine stiiliviide.
- **Ülesanne** – täieliku bakalaureusetöö loomine.
- **Vorm** – L^AT_EX-vorming koos viitega töökausta paigutatud UniTartuCS mallile.
- **Nõue** – vastavus Tartu Ülikooli arvutiteaduse instituudi nõuetele.
- **Teema** – informaatikaga seotud; konkreetse teema valib mudel ise.
- **Tiitellehe andmed** – autor Uku Renek Kronbergs, juhendaja Alo Peets (MSc).

Viibasse ei lisatud:

- TÜ ATI ega LOTE lõputööde juhendite teksti;
- varasemate bakalaureusetööde näiteid;
- detailseid juhiseid peatükkide struktuuri, mahu või sisu kohta;
- viitamisstiili juhiseid;
- keelelisi korrektuureegleid.

Sellise minimaalse viiba eesmärk oli hinnata, kuidas mudelid interpreteerivad võimalikult lühikest juhust ning millistele eelteadmistele nad toetuvad eestikeelse akadeemilise lõputöö loomisel.

II. Eksperimendis genereeritud väljundfailid

Eksperimendi tulemusena salvestati iga agentse mudel-tööriista kombinatsiooni kohta üks PDF-failiks kompileeritud lõputöö. Need failid paiknevad töö avalikus GitHubi repositooriumis (https://github.com/UkuRenekKronbergs/bakalaureusetoo_isiklik) kaustas Genereeritud lõputööd.

- Gemini_3.1_Pro_Antigravity.pdf – Gemini 3.1 Pro + Antigravity; 39 lk; teema: GenAI ja algajad programmeerijad.
- GPT_5.4_Visual_Studio_Codex.pdf – GPT-5.4 + Codex VS Code'is; 47 lk; teema: RAG-põhine küsimus-vastus süsteem.
- Sonnet_4.6_Cowork.pdf – Claude Sonnet 4.6 + Cowork; 40 lk; teema: LLM-id koodiülevaatuses.
- Opus_4.6_Cowork.pdf – Claude Opus 4.6 + Cowork; 61 lk; teema: turvaline paroolihaldur.

GPT-5.4 tavapärase vestlusliidese kaudu saadud keelduv 8-leheküljeline teostatavusjuhend ei kuulunud nelja tervikliku PDF-lõputöö hulka, kuid selle väljavõte on võrdluse huvides esitatud lisas III.2.

III. Genereeritud väljundite näited

Järgnevalt on esitatud väljavõtted eksperimendi väljunditest. Nelja tervikliku PDF-lõputöö puhul on toodud sissejuhatuse algus, et illustreerida erinevusi keeles, stiilis ja teemale vastavuses. GPT-5.4 tavapärase vestlusliidese puhul on toodud keeldumise väljavõte, sest see väljund ei olnud terviklik lõputöö, vaid teostatavusjuhend.

III.1 Claude Sonnet 4.6 (Cowork) – sissejuhatuse väljavõte (40 lk)

“Kaasaegne tarkvaraarendus on olemuselt meeskonnatöö. Isegi suurima kogemusega programmeerijad teevad vigu, ning keerukad süsteemid sisaldavad sageli turvaauke, jõudlusprobleeme või loogilisi vigu, mida üks inimene ei suuda leida.”

“Käesoleva bakalaureusetöö peamine eesmärk on hinnata suurkeelemudelite sobivust automaatse koodiülevaatus tööriistadena ning võrrelda eri mudeleid nende tulemuslikkuse alusel. Töö käigus viiakse läbi empiiriline katse, milles

kolme LLM-i — GPT-4, Claude 3 Opus ja Code Llama 70B — rakendatakse 120 koodifragmendi analüüsimiseks.”

Hinnang: terviklik eestikeelne lõputöö Tartu Ülikooli struktuuriga. Peamised puudused olid hallutsineeritud viited (5 viga 23-st), kontrollimata empiirilised väited ning suurim kirjavigade arv (37). Detailne analüüs peatükis 5.2.

III.2 GPT-5.4 (vestlusliides) – väljundi väljavõte (8 lk, teostatavusjuhend)

“A complete, submission-ready bachelor’s thesis written end-to-end on your behalf is not something I can produce. That would materially enable academic misconduct (submitting work largely authored by a third party). What I can provide—aligned with the University of Tartu’s own principles for using generative AI in coursework—is a deep-research ‘thesis kit’: a rigorously sourced background review, a defensible experimental design, an evaluation rubric, and a UniTartuCS-template-aligned LaTeX project skeleton with chapter-by-chapter writing prompts and clearly marked placeholders that you must complete, verify, and take responsibility for.”

Hinnang: GPT-5.4 keeldus ülesannet täitmast ja valis väljundkeeleks inglise keele, pakkudes selle asemel teostatavusjuhendi. Sama mudel genereeris sama viibaga Codex-laienduse kaudu tervikliku eestikeelse töö (vt lisa III.3). Detailne analüüs peatükis 5.3.

III.3 GPT-5.4 (Codex VS Code’is) – sissejuhatuse väljavõte (47 lk)

“Suurte keelemudelite kiire areng on muutnud loomulikus keeles suhtlevad tarkvarasüsteemid tavapäraseks osaks nii õppetöös, ettevõtluses kui ka avalikes teenustes. [...] Käesolev töö keskendub eestikeelsele dokumentide põhisele küsimus-vastus süsteemile.”

“Töö eesmärk on analüüsida RAG-lahenduste teaduskirjandust ning selle põhjal kavandada eestikeelse dokumentide põhise küsimus-vastus süsteemi arhitektuur, mis oleks läbipaistev, ajakohastatav ja hinnatav.”

Hinnang: agentse töövoos kaudu eestikeelne ja struktureeritud lõputöö, ortograafiliselt parim tulemus (3 kirjaviga) ja ainus kombinatsioon, kus kõik 22 viidet olid kontrollitavad. Mudel kasutas tiitellehel kohatäiteid (Näidisüliõpilane, Juhendaja nimi, PhD) etteantud nimede asemel. Detailne analüüs peatükis 5.3.

III.4 Gemini 3.1 Pro (Antigravity) – sissejuhatuse väljavõte (39 lk)

“Tarkvaraarenduse valdkond on viimaste aastate jooksul teinud läbi märkimisväärse arengutõuke tänu erinevate tehisintellekti vormide laialdasele levikule ja kättesaadavusele. Üha enam integreeritakse generatiivset tehisintellekti (GenAI) igapäevastesse tööriistadesse ja arenduskeskkondadesse (IDE).”

“Käesoleva bakalaureusetöö eesmärk on just selle andmelünga osaline täitmine kohalikus kontekstis. Töö keskendub Eesti informaatikaliõpilastele ja püüab selgitada välja, kuidas täpselt mõjutab lokaalse tehisintellekti viipeassistendi kasutamine algaja programmeerija produktiivsust esimesel õppeaastal.”

Hinnang: vormiliselt korrektne töö, mille empiiriline osa (väidetav 30 informaatikatudengiga kvaasi-eksperiment Tartu Ülikoolis koos statistiliste tulemustega) on täielikult fabritseeritud. Tekst sisaldab 24 unikaalset kirjaviga. Käsitletakse töös akadeemilise väärkasutuse kõrge riskiga juhtumina (vt peatükk 5.4).

III.5 Claude Opus 4.6 (Cowork) – sissejuhatuse väljavõte (61 lk)

“Tänapäeva digimaailmas on igapäevaelu lahutamatult seotud veebiteenustega. Inimesed kasutavad regulaarselt kümneid, sageli isegi sadu erinevaid platvorme — alates e-postist ja sotsiaalmeediast kuni pangateenuste ja tervishoiuportaalideni.”

“Käesoleva bakalaureusetöö eesmärk on kavandada ja arendada turvaline paroolihalduri veebirakendus, mis põhineb null-teadmise arhitektuuril. Rakendus kasutab kaasaegseid krüptograafilisi algoritme — AES-256-GCM sümmeetrilist krüpteerimist ja Argon2id võtmetuletust — ning on loodud avatud lähtekoodina, et tagada läbipaistvus ja auditeeritavus.”

Hinnang: Opus 4.6 + Cowork kombinatsioon genereeris kõige mahukama ja tehniliselt sügavaima töö. 61-leheküljeline lõputöö sisaldas terviklikku tehnilist arhitektuuri ja koodinäiteid; lisaks väitis töö, et rakendus läbis 149 automatiseeritud testi, OWASP Top 10 analüüsi ja SUS kasutatavusuuringu (skoor 77,0). Neid teste, auditit ega kasutajauuringut ei teostanud käesoleva uurimuse autor iseseisvalt – tegemist on kombinatsiooni enda genereeritud empiiriliste väidetega, mis tuleb inimese poolt kontrollida samamoodi nagu viited. Eestikeelne akadeemiline stiil oli läbivalt suurepärase (0 esimese isiku asesõna terve töö peale); loendis tuvastati 15 unikaalset keele- ja kirjaviga. Struktuur vastas TÜ nõuetele. 35-st viitest 33 olid täielikult korrektsed; 2 viites (6%) oli väike metaandmete viga (URL-i kuju ning pealkirja/aasta ebatäpsus). Peamine

eelis teiste kombinatsioonide ees: tehniline detailsus, $\text{\LaTeX}$ koodi otsene genereerimine failidesse ja võime hallata terviklikku projektistruktuuri.

III.6 Genereeritud tööde võrdlev kokkuvõte

Tabel 11. Tervikliku lõputöö genereerimise koondvõrdlus

Kriteerium	Gemini 3.1 Pro + Antigravity	GPT-5.4 + Codex	Claude Sonnet 4.6 + Cowork	Claude Opus 4.6 + Cowork
Valitud teema	GenAI ja progr.	RAG QA-süsteem	LLM koodiülevaatuses	Paroolihaldur
Maht	39 lk	47 lk	40 lk	61 lk
Sõnu (sõnu/lk)	7 230 (185/lk)	9 669 (206/lk)	8 085 (202/lk)	10 749 (176/lk)
Alapeatükke	20	49	32	27
Tabeleid	2	7	7	11
Jooniseid	0	2	0	0
Keele- ja kirjavigu (vigu/lk)	24 (0,62/lk)	3 (0,06/lk)	37 (0,93/lk)	15 (0,25/lk)
Unikaalseid viiteid	9	22	23	35
Tekstisisesid viiteid (viiteid/lk)	13 (0,33/lk)	28 (0,60/lk)	54 (1,35/lk)	45 (0,74/lk)
Hallutsineeritud viiteid	1 (11%)	0 (0%)	5 (22%)	2 (6%)
Anglitsisme (anglitsisme/lk)	28 (0,72/lk)	15 (0,32/lk)	6 (0,15/lk)	28 (0,46/lk)
Esimese isiku asesõnu	1	0	0	0

Tabelist 11 nähtub, et kõik neli mudel-tööriista kombinatsiooni järgisid lõputöö üldist vormi, kuid erinesid mahu, viidete kvaliteedi, kirjavigade tiheduse ning anglitsismide kasutuse poolest oluliselt. Iga näitaja sisuline tõlgendus, sellest tulenevad järeldused ja kombinatsioonide võrdlev hinnang on esitatud peatükis 5.

Litsents

Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks

Mina, Uku Renek Kronbergs,

1. annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) minu loodud teose

“Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine”,

mille juhendaja on Alo Peets (MSc),

reprodutseerimiseks eesmärgiga seda säilitada, sealhulgas lisada digitaalarhiivi DSpace kuni autoriõiguse kehtivuse lõppemiseni.

2. Annan Tartu Ülikoolile loa teha punktis 1 nimetatud teos üldsusele kättesaadavaks Tartu Ülikooli veebikeskkonna, sealhulgas digitaalarhiivi DSpace kaudu Creative Commons'i litsentsiga CC BY NC ND 3.0, mis lubab autorile viidates teost reprodutseerida, levitada ja üldsusele suunata ning keelab luua tuletatud teost ja kasutada teost ärieesmärgil, kuni autoriõiguse kehtivuse lõppemiseni.
3. Olen teadlik, et punktides 1 ja 2 nimetatud õigused jäävad alles ka autorile.
4. Kinnitan, et lihtlitsentsi andmisega ei riku ma teiste isikute intellektuaalomandi ega isikuandmete kaitse õigusaktidest tulenevaid õigusi.

Uku Renek Kronbergs

[kuupäev]