

TARTU ÜLIKOOL
Arvutiteaduse instituut
Informaatika õppekava

Uku Renek Kronbergs

**Teostatavusuuring: Tehisintellekti abil
eestikeelse tehnilise informaatika alase
lõputöö genereerimine**

Bakalaureusetöö (9 EAP)

Juhendaja:
Alo Peets, MSc

Tartu 2026

Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine

Lühikokkuvõte:

Käesolev bakalaureusetöö uurib tehisintellekti (TI) rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Töös võrreldakse nelja suurt keelemudelit koos agentsete tööriistadega: Google Gemini 3.1 Pro koos Antigravityga, OpenAI GPT-5.4 koos ChatGPT Codexi Visual Studio Code'i laiendusega ning Anthropic Claude Sonnet 4.6 ja Claude Opus 4.6 koos Coworkiga. Igale kombinatsioonile anti sama lühike eestikeelne viip, mis palus luua UniTartuCS mallil põhineva L^AT_EX-vormingus bakalaureusetöö, valida ise informaatikaga seotud teema ning järgida Tartu Ülikooli arvutiteaduse instituudi nõudeid. Kuna iga kombinatsiooni kohta tehti üks jooks, käsitletakse tulemusi eksploratiivselt. Väljundeid hinnati struktuuri, mahu, kirjavigade, viidete kontrollitavuse, eestikeelse akadeemilise stiili ja juhiste järgimise põhjal. Tulemused näitavad, et agentsed tööriistad võimaldavad mudelitel luua vormilt terviklikke eestikeelseid lõputöid, kuid kvaliteet, liidesesõltuvus ja riskid erinevad märkimisväärselt. Läbi viidud katsetes andis üldiselt tugevaima väljundi Claude Opus 4.6 + Cowork, samas kui GPT-5.4 + Codex eristus väga väheste kirjavigade ja kontrollitavate viidetega. Gemini 3.1 Pro + Antigravity töö näitas kõige selgemalt vormilise veenvuse ohtu, sest sisaldas täielikult fabritseeritud empiirilist osa. Peamised probleemid olid hallutsineeritud viited, kontrollimata empiirilised väited ja vähene sisuline originaalsus. Töös järeldatakse, et TI sobib lõputöö kirjutamisel abivahendiks, kuid mitte iseseisvaks autoriks. Täiendava juhtumiuuringuna viidi läbi ühe tööpäeva pikkune iteratiivne seanss uuema mudelipõlvkonnaga Claude Opus 4.7 + Claude Code'iga, mis näitas, et aktiivse kasutaja juhendamise korral on saavutatav 57-leheküljeline töö koos kompileeritava lähtekoodi, korrektsete viidete ja keelelise ühtlusega.

Võttesõnad: tehisintellekt, keelemudelid, lõputöö genereerimine, eesti keel, teostatavusuuring

CERCS: P170 Arvutiteadus

Feasibility Study: Generating an Estonian-Language Technical Computer Science Thesis Using Artificial Intelligence

Abstract:

This bachelor's thesis investigates the feasibility of using artificial intelligence (AI) to generate an Estonian-language technical computer science thesis. The study compares four large language models paired with agentic tools: Google Gemini 3.1 Pro with Antigravity, OpenAI GPT-5.4 with the ChatGPT Codex extension for Visual Studio Code, and Anthropic Claude Sonnet 4.6 and Claude Opus 4.6 with Cowork. Each combination received the same short Estonian-language prompt asking it to produce a $\text{\LaTeX}$ -formatted bachelor's thesis using the UniTartuCS template, choose its own computer-science-related topic, and follow the requirements of the University of Tartu's Institute of Computer Science. Because each combination was run only once, the results are treated as exploratory. The outputs were assessed by structure, length, orthographic accuracy, citation verifiability, Estonian academic style, and instruction following. The results show that agentic tools can help models produce formally complete Estonian-language theses, but quality, interface dependence, and risks vary substantially. In this experiment, Claude Opus 4.6 + Cowork produced the strongest overall output, while GPT-5.4 + Codex stood out for very few spelling errors and fully verifiable citations. The Gemini 3.1 Pro + Antigravity output most clearly demonstrated the risk of formal plausibility, as it contained a wholly fabricated empirical section. The main limitations were hallucinated citations, unverified empirical claims, and limited substantive originality. The thesis concludes that AI is useful as an assistive tool in thesis writing, but not as an independent author. As an additional case study, a one-working-day iterative session was conducted with the newer Claude Opus 4.7 + Claude Code combination, showing that under active user guidance a 57-page work with compilable source code, correct citations, and consistent language is achievable.

Keywords: artificial intelligence, language models, thesis generation, Estonian language, feasibility study

CERCS: P170 Computer science

Sisukord

1. Sissejuhatus

Suured keelemudelid (*Large Language Models*, LLM) on viimaste aastate jooksul liikunud nišikasutusest igapäevaseks töövahendiks, mida kasutatakse tekstide koostamisel, toimetamisel ja struktureerimisel nii ettevõtetes kui ka kõrgkoolides [1]. OpenAI GPT-seeria, Google'i Gemini ning Anthropicu Claude'i mudelid suudavad koostada sidusaid akadeemilisi tekste, toimetada olemasolevaid dokumente ja genereerida pikemaid struktureeritud kirjalikke töid [2, 3]. Väiksemate keelte, sealhulgas eesti keele, puhul on mudelite kvaliteet ja usaldusväärsus siiski ebaühtlasemad ning nende süstemaatiline hindamine on seni jäänud tagasihoidlikuks [4, 5].

Bakalaureusetöö on Tartu Ülikooli arvutiteaduse instituudis (ATI) esimene suurem iseseisev akadeemiline kirjatöö, mille üliõpilane peab vormistama kehtestatud juhendi kohaselt [6]. Töö valmimine nõuab tavaliselt ühte semestrit, mille käigus tuleb süveneda kirjandusse, kirjeldada metoodikat, esitada tulemused ja järgida akadeemilist stiili. Üliõpilaste seas on viimastel aastatel laialdaselt levinud TI mudelite kasutamine lõputöö kirjutamise abivahendina, kuid senised juhendid ja uurimused ei anna selget pilti sellest, kui usaldusväärselt TI mudelid sellise ülesandega eesti keeles toime tulevad [7, 8]. Eriti oluline on eristada vormiliselt veenvat teksti sisuliselt kontrollitud akadeemilisest tööst: lõputöö puhul ei piisa korrektsest struktuurist ja ladusast keelest, kui viited, andmed või empiirilised väited ei ole kontrollitavad.

Käesoleva bakalaureusetöö eesmärk on hinnata, kas ja millistel tingimustel suudavad kaasaegsed TI mudelid koos tänapäevaste agentsete tööriistadega genereerida eestikeelse tehnilise informaatika lõputöö. Töö ei käsitle mudeleid ainult isoleeritud tekstigeneraatoritena, vaid konkreetsete mudel-tööriista paaridena, sest agentne liides, failisüsteemi ligipääs, kompileerimisvõimekus ja süsteemijuhised mõjutavad lõpptulemust. Töö keskendub järgmistele uurimisküsimustele:

1. Millised kaasaegsete TI mudelite ja agentsete tööriistade kombinatsioonid suudavad luua vormilt tervikliku eestikeelse akadeemilise lõputöö?
2. Kuidas erinevad nende kombinatsioonide väljundid sama lühikese eestikeelse kasutajaviiba korral struktuuri, mahu, keele, viidete, teemavaliku ja juhiste järgimise lõikes?
3. Kuidas mõjutavad kasutajaliides ja agentne failipõhine töövoog genereeritud töö kvaliteeti, ülesande tõlgendamist ja akadeemilise aususe piiranguid?
4. Millistes lõputöö kirjutamise etappides suudab TI pakkuda tõhusat abi ning kus on inimese panus endiselt asendamatu?

5. Millised on TI-põhise tekstigenereerimise praktilised piirangud, sealhulgas hinnakujundus, konteksti haldamine, keelelised puudujäägid, viidete hallutsineerimine ja kontrollimata empiirilised väited?

Eelnevate uurimuste [1, 9, 10] ja autori ettevalmistavate katsete põhjal eeldati, et kõik valitud mudel-tööriista kombinatsioonid suudavad luua vormiliselt veenva eestikeelse tervikteksti, kuid sisulises kvaliteedis, viidete kontrollitavuses ja empiiriliste väidete usaldusväärsuses kaheldi. Samuti eeldati, et viidete hallutsineerimine ja väljamõeldud väited jäävad oluliseks akadeemilise aususe riskiks ka 2025. ja 2026. aasta juhtivate keelemudelite puhul.

Uurimuse jaoks valiti neli suurt keelemudelit koos agentsete tööriistadega: Google Gemini 3.1 Pro koos Antigravity keskkonnaga, OpenAI GPT-5.4 koos ChatGPT Codexi laiendusega arenduskeskkonnale Visual Studio Code (edaspidi VS Code) ning Anthropic Claude Sonnet 4.6 ja Claude Opus 4.6 koos Coworkiga. Igale mudel-tööriista kombinatsioonile anti sama lühike eestikeelne viip, mis palus genereerida UniTartuCS malli kasutava L^AT_EX-vormingus bakalaureusetöö. Mudelitele ei antud täiendavaid juhendeid, näidistöid ega iteratiivseid paranduspalveid. Kuna iga kombinatsiooni kohta tehti üks jooks, käsitletakse tulemusi eksploratiivse hinnanguna konkreetsetele töövoogudele, mitte lõpliku mudelite paremusjärjestusena. Väljundeid hinnati struktuuri, mahu, keele- ja kirjavigade, viidete kontrollitavuse, eestikeelse akadeemilise stiili ja juhiste järgimise alusel. Põhieksperimendi täiendusena tehti eraldi iteratiivne juhtumiuuring uuema mudeliga Claude Opus 4.7 koos Claude Code'iga (ligikaudu kaheksa tundi aktiivset kasutajajuhendamist) (vt peatükk ??). Lisaks kirjeldatakse bakalaureusetöö kirjutamise töövoogu, et eristada ühe kasutajaviibaga genereerimise stsenaariumi inimese juhitud ja kontrollitud TI kasutusest.

Töö on struktureeritud järgmiselt. Peatükk ?? annab ülevaate suurte keelemudelite arengust, eesti keele töötlemise väljakutsetest ning varasematest uurimustest TI kasutamisest akadeemilises kirjutamises. Peatükk ?? kirjeldab uurimuse metoodikat ja hindamisraamistikku. Peatükk ?? võrdleb valitud mudeleid tehniliste parameetrite, kuluspektide ja eesti keele toe lõikes. Peatükk ?? esitab ühe kasutajaviibaga ja hiljem iteratiivselt genereeritud lõputöö tulemused. Peatükk ?? kirjeldab käesoleva bakalaureusetöö kirjutamise töövoogu ning autori ja TI rollijaotust. Peatükk ?? tõlgendab tulemusi, käsitleb piiranguid ja annab soovitusi. Peatükk ?? võtab töö tulemused kokku.

Töö lõpus on kolm lisa. Lisa ?? esitab eksperimendis kasutatud eestikeelse kasutajaviiba täisteksti ja selle sisuliste elementide analüüsi. Lisa ?? loetleb eksperimendi tulemusena salvestatud PDF-

failid (neli bakalaureusetööd) koos lehekülgede arvuga, mudel-tööriista kombinatsiooniga ja teemaga. Lisa ?? sisaldab iga väljundi sissejuhatuse väljavõtteid ja autori lühihinnangut.

Käesoleva bakalaureusetöö kirjutamisel kasutati TI tööriistu peamiselt vormistuslike ja keeleliste abivahenditena: Anthropic Claude Code'i (Claude Opus 4.6 ja 4.7 mudelitega) keelelise toimetamise, kirjavigade otsimise, L^AT_EX-vormistuse ja kompileerimisvigade diagnoosimise jaoks. Täiendava keelelise korrektuuri jaoks kasutati lisaks OpenAI ChatGPT Codexit (GPT-5.5 mudeliga). Iga TI-põhine muudatus läbis enne aktsepteerimist autori ülevaatuse ning sisulised otsused, allikate valik, eksperimendi disain ja tulemuste tõlgendamine jäid autori vastutusele. Töövoo ja rollijaotuse täpsem kirjeldus on esitatud peatükis ??.

2. Taust ja kirjanduse ülevaade

Käesolev peatükk annab ülevaate suurte keelemodelite arengust, eesti keele töötlemise spetsiifikast ning varasematest uurimustest tehisintellekti kasutamisest akadeemilises tekstiloomes.

2.1 Suurte keelemodelite areng

Suurte keelemodelite arengu nurgakiviks oli 2017. aastal Vaswani jt avaldatud transformeri arhitektuur [11], millele tuginesid esimesed märkimisväärsed keelemudelid, näiteks BERT [12] ja GPT-2 [13]. GPT-3 ilmumine 2020. aastal [2] tõi kaasa paradigmuuutuse, näidates, et 175 miljardi parameetriga mudel suudab täita mitmesuguseid ülesandeid ilma spetsiifilise peenhäälestamiseta (*fine-tuning*). Viimase viie aasta jooksul on mudelid kiiresti arenenud nii suuruse, arhitektuuri kui ka võimekuse poolest.

2.2 Eesti keele töötlemine keelemudelites

Eesti keel kuulub soome-ugri keelkonda ja on morfoloogiliselt rikas keel 14 käändega ning keerulise sõnamoodustuse süsteemiga [14]. See eripära teeb eesti keele töötlemise keelemodelite jaoks oluliselt keerulisemaks kui näiteks inglise keele puhul.

Suurte keelemodelite eesti keele oskus sõltub ka treeningandmete mahust ja kvaliteedist. Common Crawl 2026. aasta statistika järgi moodustas eesti keel HTML-lehtede põhikeelena viimastes (2026. aasta) veebikogumites ligikaudu 0,14%, samal ajal kui inglise keele osakaal oli üle 40% [15]. LLM-ide treeninguks puhastatud CulturaXi andmestikus on vahe samas suurusjärgus: eesti keelt on 8,8 miljardit tokenit ehk 0,14%, inglise keelt aga 2,85 triljonit tokenit ehk 45,13% [16].

Tartu Ülikooli keeletehnoloogia uurimisrühm on teinud märkimisväärsed tööd eesti keele ressursside ja tööriistade arendamisel. EstBERT [17] on eesti keelele kohandatud BERT-mudel, mis on treenitud eestikeelse tekstikorpusel. Hiljutine EstLLM projekt [5] on teinud olulisi edusamme suurte keelemodelite eesti keele võimekuse parandamisel, kasutades jätkutreenimist (*continued pretraining*) ja järeltreenimist (*post-training*) mitmekeelsete mudelite baasil. Uurimus näitas, et spetsialiseeritud treeninguga saab eesti keele kvaliteeti oluliselt tõsta, ilma et mudeli üldine arutlusvõimekus kannataks.

Mitmekeelsete mudelite arendamise seisukohast väärib esiletõstmist Aya mudel [18], mis on juhendipõhiselt peenhäälestatud avatud lähtekoodiga keelemudel ja toetab 101 keelt, sealhulgas

mitmeid väikese ressursiga keeli. Aya ületas mT0 ja BLOOMZ mudeleid enamikus ülesannetes, demonstreerides, et sihipärase mitmekeelse peenhäälestamisega on võimalik oluliselt parandada väikeste keelte kvaliteeti. Kuulmets jt [4] süstemaatiline hindamine näitas, et soome-ugri keelte, sealhulgas eesti keele, tugi avatud keelemudelites on viimastel aastatel kiiresti paranenud, kuid jääb endiselt inglise keelest oluliselt maha. Suurte keelemudelite puhul on ka eesti keele kvaliteet viimase kahe aasta jooksul märgatavalt paranenud. Kui varasemad GPT-3-põhised mudelid tegid eesti keeles sageli selgelt märgatavaid grammatilisi vigu, siis GPT-5.4, Gemini 3.1 Pro, Claude Sonnet 4.6 ja Claude Opus 4.6 suudavad luua grammatiliselt suures osas korrektset eestikeelset teksti. Siiski esineb endiselt probleeme tehnilise terminoloogi, akadeemilise stiili ning pikemates tekstides keelelise järjepidevuse hoidmisega. Kiil [19] on Tartu Ülikooli bakalaureusetöös võrrelnud suuri keelemodeleid eesti bioloogiaolümpiaadi küsimuste põhjal. Parim mudel saavutas 85,35% täpsuse, mis on võrreldav olümpiaadiosalejate tiptulemusega. Eelnev kinnitab mudelite kasvavat võimekust ka eestikeelsetes ainespetsiifilistes ülesannetes.

2.3 TI akadeemilises kirjutamises

Tehisintellekti kasutamine akadeemilises kirjutamises on muutunud väga aktuaalseks teemaks. Liang jt [1] leidsid, et TI-genereeritud teksti osakaal teadusartiklites on märkimisväärselt kasvanud, eriti arvutiteaduse ja meditsiini valdkonnas. See tõstatab küsimusi akadeemilise aususe, originaalsuse ja kvaliteedikontrolli kohta.

Mitmed ülikoolid, sealhulgas Tartu Ülikool, on kehtestanud juhised TI kasutamiseks akadeemilises töös [6, 20]. Üldiselt on lubatud kasutada TI-d abivahendina, kuid üliõpilane peab selgelt märkima, millises ulatuses ja millisel eesmärgil TI kasutati. Lõputöö ei tohi olla sisuliselt TI-genereeritud ja üliõpilane peab demonstreerima iseseisvat analüütilist mõtlemist.

Rodafinos [8] rõhutab, et generatiivsete TI tööriistade vastutustundlik integreerimine akadeemilisse kirjutamisse on hädavajalik, tuues esile nii efektiivsuse kasvu kui ka kvaliteedi paranemise. Samal ajal rõhutades TI väljundite kontrollimise ja inimese järelevalve säilitamise vajadusele. Lund jt [7] leidsid 401 USA üliõpilase küsitluses, et tudengite eetilised veendumused, mitte institutsionaalsed poliitikad, on tugevaim ennustaja TI kasutamise tajumisel akadeemilise väärkäitumisena.

Varasemad uurimused on näidanud, et TI mudelid on eriti kasulikud järgmistes akadeemilise kirjutamise aspektides:

- **Teksti struktureerimine** – mudelid aitavad koostada tekstikavandeid, peatükkide ülesehitust ja kavandipõhist mustandit; Lee jt [21] näitasid, et eksplitsiitsed kavandid parandavad eri LLM-ide loodud tekstide kvaliteeti.
- **Kirjanduse ülevaade** – mudelid suudavad toetada kirjanduse kogumist, organiseerimist, kokkuvõtmist ja sünteesimist, kuigi allikate täpsus vajab kontrollimist [22, 23].
- **Keeleline toimetamine** – ChatGPT, Claude'i, Gemini ja Copiloti tüüpi tööriistad võivad aidata grammatika, sõnastuse, sidususe ja loetavuse parandamisel, kuid nende väljund ei ole inimtoimetajaga usaldusväärsusega võrreldav [24].
- **Tõlkimine** – GPT-, Claude'i, Gemini ja DeepSeeki tüüpi mudelid suudavad pakkuda kasutatava kvaliteediga tõlkeid akadeemilisest ja tehnilisest tekstist, kuid valdkonnaspetsiifiline järeltoimetamine jääb vajalikuks [25].

Samas on tuvastatud olulisi puudujääke:

- **Hallutsinatsioonid** – mudelid võivad genereerida faktiliselt valesid väiteid või olematuid viiteid. Mugaanyi jt [9] leidsid, et ChatGPT 3.5 genereeritud viidetest olid 72,7% loodusteadustes ja 76,6% humanitaarteadustes küll olemasolevad, kuid DOI-de ehk digitaalsete objektiidentifikaatorite (*Digital Object Identifier*) täpsus oli vaid vastavalt 32,7% ja 8,5%. Uuemad hindamised näitavad, et probleem püsib ka kirjanduse ülevaate koostamise ja veebipõhiste agentsete töövoogude puhul: Tang jt [22] tuvastasid hallutsineeritud viiteid ka arenenud mudelite loodud kirjandusülevaadetes ning Rao ja Callison-Burch [26] hindasid GPT-5, Claude Sonnet 4.6 ja Gemini 3 Flashi veebipõhiseid väljundeid ning leidsid, et loodud BibTeX-kirjetest olid täielikult korrektsed vaid 50,9% (üldine täpsus oli 83,6%). Kim jt [10] tuvastasid lisaks, et hallutsinatsioonimäär on geograafiliselt ebavõrdsed – madalama sissetulekuga riikide kontekstis ületas DOI-de hallutsinatsioonimäär 80%.
- **Sisuline sügavus** – TI-genereeritud tekstid kipuvad olema pealiskaudsed ja väga üldistavad. Peters ja Chin-Yee [27] näitasid 4900 teaduskokkuvõtte põhjal, et ChatGPT-4o, ChatGPT-4.5, DeepSeek, LLaMA 3.3 70B ja Claude 3.7 Sonnet kaldusid teadustulemusi üle üldistama; DeepSeek, ChatGPT-4o ja LLaMA 3.3 70B puhul esines seda 26–73% juhtudest.
- **Originaalsus** – keelemudelid ei loo iseseisvalt uusi teadmisi, vaid kombineerivad olemasolevat informatsiooni. Doshi ja Hauser [28] leidsid, et generatiivne TI võib

suurendada üksiku teksti loomingulisust, kuid samal ajal vähendada tekstikorpuse mitmekesisust. See toetab varasemat kriitikat mudelite tuletusliku olemuse kohta [29].

- **Väikeste keelte spetsiifika** – eesti keele ja teiste väikeste keelte puhul on kvaliteet ebaühtlasem kui inglise keeles. Kuulmets jt [4] näitasid, et soome-ugri keelte tugi avatud keelemudelites on paranenud, kuid jääb suurtest keeltest märgatavalt maha. Lillepalu ja Alumäe [30] rõhutavad eesti keelele kohandatud testide vajalikkust ning EstLLM projekt [5] näitab, et eesti keele kvaliteet paraneb märgatavalt alles sihipärase jätkutreenimise ja järeltreenimisega.

Need TI mudelite üldised tugevused ja puudujäägid kujundavad taustaraamistiku, mille suhtes käesolev töö hindab konkreetsete mudel-tööriista kombinatsioonide käitumist eestikeelse lõputöö genereerimisel. Empiiriline võrdlus ja selle tulemused on esitatud peatükis ??, eelnenud metoodilised valikud peatükis ??.

3. Metoodika

Käesolev peatükk kirjeldab uurimuse metoodikat, sealhulgas TI mudelite ja agentsete tööriistade valiku kriteeriume, eksperimendi ülesehitust, ühe kasutajaviibaga (*single-prompt*) lähenemise sisu ning hindamiskriteeriume.

Terminoloogilise täpsuse huvides tuleb märkida, et käesolev katse ei ole *one-shot*-lähenemine selle tavapärasest masinõppe tähenduses, sest mudelile ei antud ühtegi näidislahendust. Mudelile anti üks lühike kasutajaviip ilma näideteta – seetõttu on viiba sisu mõttes täpsem kirjeldada katset kui ühe kasutajaviibaga *zero-shot*-lähenemist (*single-turn zero-shot prompting*). Samas ei olnud kõik katsed täielikult mälukontekstist isoleeritud: kuna kasutatud tööriistade või kasutajakonto püsiv mälu võis säilitada varasemate katsete kohta infot, tuleb tulemusi käsitleda mitte rangelt sõltumatute *clean-context*-katsetena, vaid praktilise kasutusolukorra simulatsioonina. Agentse tööriista töö käigus võis mudel teha mitu sammu, näiteks faile lugeda, kirjutada, $\text{\LaTeX}$ -i kompileerida ja vigu parandada, kuid kasutajapoolne sekkumine piirdus ühe algse viibaga.

3.1 Mudelite ja tööriistade valiku kriteeriumid

Uurimuse jaoks mudelite valimisel lähtuti järgmistest kriteeriumidest:

1. **Eesti keele tugi** – mudel peab suutma genereerida grammatiliselt korrektset eesti keelt ning mõistma eestikeelset sisendit.
2. **Kontekstiakna suurus** – bakalaureusetöö genereerimine eeldab mahuka konteksti (juhendid, varem genereeritud osad, $\text{\LaTeX}$ -mall) töötlemist, mistõttu on vajalik piisavalt suur kontekstiaken.
3. **Agentsus ja dokumentatsioon** – mudel-tööriista kombinatsioon peab võimaldama agentset töövoogu ning selle kohta peab olema piisavalt dokumentatsiooni. Agentsuse all mõistetakse siin võimet täita kasutaja eesmärki mitmes järjestikuses sammus, kasutades vajadusel tööriistu ja failisüsteemi: lugeda olemasolevaid faile, luua või muuta $\text{\LaTeX}$ -faile, käivitada kompileerimist ning parandada tekkinud vigu ilma iga sammu jaoks eraldi kasutajaviipa vajamata.
4. **Väljundi kvaliteet** – mudel peab suutma genereerida akadeemilisele tekstile omast stiili, struktuuri ja sisu, mis vastab Tartu Ülikooli bakalaureusetöö nõuetele.
5. **Väljundi järjepidevus** – mudel peab suutma hoida järjepidevat stiili, teemat ja struktuuri kogu töö ulatuses, mis on eriti oluline pikemate tekstide puhul.

6. **Hallutsinatsioonide tase** – mudel peab suutma genereerida võimalikult vähe faktivigu ja olematuid viiteid, mis on akadeemilises tekstis eriti problemaatiline.

7. **Hind** – mudeli kasutamine peab olema majanduslikult mõistlik üliõpilase jaoks.

Nende kriteeriumide alusel valiti neli mudelit: Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ning Anthropic Claude Opus 4.6. Opus 4.6 lisati võrdlusse kui sama mudeliperekonna võimekaim mudel, et hinnata mudeli suuruse mõju genereeritud teksti kvaliteedile. Valiku põhjendused on esitatud peatükis ??.

Lisaks valitud mudelitele testis autor ettevalmistavas faasis ka teisi keelemudeleid, sealhulgas xAI Grok 4.1 ja Moonshot AI Kimi 2.5. Samuti katsetati valitud mudelite kasutamist erinevates keskkondades ja tööriistades, näiteks Google AI Studios, Claude'i veebiliideses, ChatGPT veebiliideses ja Google Gemini veebiliideses. Need eelkatsed näitasid, et sama mudeli käitumine sõltub oluliselt kasutatavast liidesest ja sellest, kas tööriist võimaldab agentset failipõhist töövoogu. Grok 4.1 ja Kimi 2.5 jäeti põhieksperimenti võrdlusest välja, kuna autor ei suutnud erinevate viibavariantidega saada neilt ülesandele vastavat väljundit. Genereeritud tekstide vormistus oli järjekindlalt ebakorrekne ning väljund ei vastanud bakalaureusetöö struktuurile. Seetõttu keskenduti neljale eelnimetatud mudelile ja nende tööriistadele, mis suutsid tervikliku ja kompilleeruva lõputöö genereerida.

Kuna eksperiment nõudis failisüsteemi ligipääsu ja L^AT_EX-i kompileerimist, ei saanud mudeleid kasutada üksnes vestlusliidese kaudu. Iga mudeli kohta kasutati selle mudeli pakkuja ametlikku või laialt kasutatavat agentset tööriista: Claude Sonnet 4.6 ja Opus 4.6 puhul Anthropicu Claude Cwork, Gemini 3.1 Pro puhul Google'i Antigravity ning GPT-5.4 puhul ChatGPT Codexi Visual Studio Code'i laiendust. Oluline on rõhutada, et eksperimentis võrreldud üksused ei ole niivõrd “mudelid iseenesest”, vaid pigem *mudeli ja agentse tööriista kombinatsioonid*. Seetõttu tuleb tulemusi tõlgendada konkreetsete mudel-tööriista paaride, mitte puhaste mudeli võimekuste näitajana – süsteemijuhised, failidele ligipääs, automaatne kompileerimine ja liidese ohutuspoliitika erinevad tööriistade lõikes ning mõjutavad väljundit. Seda piirangut on täiendavalt käsitletud peatükis ??.

3.2 Eksperimenti ülesehitus

Uurimus piirdus ühe eksperimentiga: igale mudel-tööriista kombinatsioonile anti üks ja sama lühike eestikeelne kasutajaviip ning lasti agentsel tööriistal genereerida terviklik bakalaureusetöö ilma järelküsimate, iteratiivse suunamise või peatükkide kaupa juhendamiseta. Selline ühe

kasutajaviibaga lähenemine valiti teadlikult kahel põhjusel. Esimene põhjus on see, et lähenemine kajastab kõige ausamalt seda, kuidas keelemudelit kasutaks üliõpilane, kes soovib lõputöö kirjutamist TI-le täielikult delegeerida – see on stsenaarium, mida akadeemilise aususe kontekstis on oluline hinnata. Teine põhjus on see, et identne minimaalne sisend võimaldab nelja mudel-tööriista kombinatsiooni väljundeid kõige otsesemalt võrrelda, kuna ühtegi kombinatsiooni ei eelistata täiendava konteksti, viibadisaini (*prompt engineering*) ega iteratiivse parandamise kaudu. Kuna iga kombinatsiooni kohta tehti üks jooks, on saadud näitajad eksploratiivsed – need iseloomustavad konkreetset katset, mitte üldist mudelivõimekust.

Kasutatud viip. Kõigile mudelitele anti järgmine eestikeelne viip (täistekst on esitatud lisas ??):

“Sa oled kogenud akadeemiline kirjutaja. Loo täielik bakalaureusetöö LaTeX-vormingus (lisisin töökausta vajaliku malli), mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele. Teema peab olema informaatikaga seotud ja vali ise. Autor on Uku Renek Kronbergs ja juhendaja Alo Peets (MSc).”


Viip on teadlikult lühike ja sisaldab vaid kolme sisulist piirangut: (1) väljund peab olema L^AT_EX-vormingus ja kasutama töökaustas olevat UniTartuCS malli; (2) töö peab vastama Tartu Ülikooli arvutiteaduse instituudi nõuetele; (3) teema peab olema informaatikaga seotud, kuid konkreetse teemavaliku teeb mudel ise. Autori ja juhendaja nimed anti tiitellehe täitmiseks. Ülikooli lõputööde juhendeid (TÜ ATI ega LOTE juhendit), varasemaid näidistöid ega muud täiendavat konteksti viibasse ei lisatud.

Agentsete tööriistade kasutamine. Kuna viip nõuab L^AT_EX-malli kasutamist, mitme faili haldamist ja kompileeritavat väljundit, ei saanud eksperimenti läbi viia üksnes vestlusliidese kaudu, kus mudel ei suuda ise failisüsteemile ligi pääseda. Veebipõhistes vestlusliideses piiravad sellist ülesannet ka failide arvu limiidid: Gemini Apps lubab samas viibas üles laadida kuni 10 toetatud faili, erandina ühe koodikausta või GitHubi repositooriumi kuni 5000 failiga [31]. Claude'i vestlusliides lubab kuni 20 faili vestluse kohta [32]. ChatGPT piirab tavapäraseid ChatGPT üleslaadimisi kuni 80 failini kolme tunni jooksul või tasuta kontrol 3 failini päevas [33]. See oli üks põhjustest, miks kasutati iga mudeliga sellele omast agentset töövoogu:

- **Claude Sonnet 4.6** ja **Claude Opus 4.6** – Anthropicu *Cowork* agentne tööriist (mitte segi ajada sama ettevõtte eraldi tootega Claude Code), mis suudab lugeda, kirjutada ja kompileerida projekti L^AT_EX-faile otse failisüsteemis.

- **Google Gemini 3.1 Pro** – Google’i *Antigravity* agentne arenduskeskkond, mis pakub funktsionaalselt sarnast võimekust.
- **OpenAI GPT-5.4** – OpenAI *ChatGPT Codex* laiendusega Visual Studio Code’is.

Mudelite ja agentsete tööriistade omavaheline vastavus on koondatud joonisel ???. Joonis illustreerib, et iga mudelit kasutati selle pakkuja oma agentse tööriista kaudu, mis pääses ligi samale ühisele L^AT_EX-projektifailile (UniTartuCS mall koos viibaga) ning genereeris sealt iseseisva PDF-väljundi.



Joonis 1. Mudel-tööriista kombinatsioonide seos põhieksperimendis. Iga mudel sai sama eestikeelse viiba koos UniTartuCS L^AT_EX-malliga oma agentse tööriista kaudu ning genereeris ühe tervikliku PDF-väljundi.

Kõigi nelja mudeli puhul piirduti ühe viibaga – pärast viiba esitamist ei antud mudelile täiendavaid juhiseid, ei parandatud genereeritud teksti ega palutud mudelil varasemaid valikuid üle vaadata. Kui mudel ise tegi agentse tööriista raames mitu sisemist sammu (failide loomine, kompileerimine, vigade parandamine), loeti see üheks genereerimistsükliks, kuna kogu töövoog algatas sama algviip.

Metoodika eelkatsed. Põhieksperimendi metoodika täpsustamiseks tegi autor enne lõpliku eksperimendi läbiviimist ulatuslikke ettevalmistavaid katseid, et leida sobivaim viip, töövoog ja agentsete tööriistade seadistus. Kokku genereeris autor näidislõputöid ligikaudu 25 korda, varieerides selleks viiba sõnastust, malli kasutust ja töövoogu. Lõpliku eksperimendi metoodika valiti nende eelkatsete põhjal kui kõige järjepidevama väljundi andev variant. Eelkatsed hõlmasid ka katsetusi ilma UniTartuCS L^AT_EX-mallita – ilma mallita jäi väljundi vormistus järjekindlalt

ebakorrektselt, mistõttu mall jäi viiba lahutamatuks osaks. Ebaõnnestunud eelkatsete üks korduv probleem oli ka väljundi keelevalik: peatükkide pealkirjad olid üldjuhul inglise keeles ning osa põhitekstist genereeriti samuti inglise keeles, kuigi kasutajaviip ise oli eestikeelne. Samuti testis autor alguses lõputöö genereerimist peatükkide kaupa (mudelitelt paluti esmalt sissejuhatus, seejärel taustapeatükk jne), kuid jõudis kiiresti järeldusele, et terve töö korraga genereerimine ja sellele järgnev iteratiivne täiendamine annab oluliselt parema tulemuse nii teksti järjepideva stiili kui ka ajakulu poolest. Käesolevas eksperimendis kasutati selle järelduse põhjal terve lõputöö korraga genereerimist. Mudelite ja tööriistade võrdluse huvides hilisemat iteratiivset suunamist eksperimendi raames ei rakendatud.

Genereeritud väljundid. Eksperimendi tulemusena valis autor neli PDF-failiks kompileeritud bakalaureusetööd (vt peatükk ??); lisaks salvestati GPT-5.4 tavapärase vestlusliidese kaudu saadud keelduva väljundi katkend võrdluseks. Failide nimekiri koos lehekülgede arvu ja teemaga on esitatud lisas ??.

3.3 Hindamiskriteeriumid

Eksperiment tootis neli tervikdokumenti, mistõttu hindamisel keskenduti kvantitatiivselt mõõdetavatele tunnustele, mida on võimalik genereeritud PDF-idest objektiivselt mõõta. Eelnev vähendab ka ühe hindaja subjektiivsusest tulenevat moonutust. Tabelis ?? on esitatud hindamisraamistik.

Iga kriteeriumi kvantitatiivsed mõõtmised tehti genereeritud PDF-failidest teksti ekstraheerimise teel, jättes välja tiitellehe, kirjanduse loendi ning koodinäited juhtudel, kus see oli meetodiliselt põhjendatud. Hindamise tegi käesoleva bakalaureusetöö autor. Ühe hindaja kasutamise piirangut on täpsemalt käsitletud peatükis ??.

Käesolev töö ei sisalda eksplitsiitset kontrollrühma – puudub nii inimkirjutatud bakalaureusetöö võrdluspunkt kui ka mudelite mitteagentne baasväljund (peale GPT-5.4 vestlusliidese katkendi, vt peatükk ??). Kontrollrühma puudumisest tulenevat üldistamist on käsitletud peatükis ??.

Tabel 1. Hindamiskriteeriumide raamistik

Kriteerium	Kirjeldus	Hindamisviis
Struktuur ja teemale vastavus	Kas töö järgib bakalaureusetöö ülesehitust (tiitelleht, kokkuvõte, sissejuhatus, peatükid, kokkuvõte, viited) ning kas valitud teema on informaatikaga seotud	Kvalitatiivne kirjeldus
Maht	Lehekülgede arv, sõnade arv ja sõnade tihedus lehekülje kohta	Kvantitatiivne mõõtmine
Keeleline korrektsus	Kirjavigade koguarv ja tihedus lehekülje kohta	Kvantitatiivne loendamine
Viidete kvaliteet	Unikaalsete allikate arv, tekstisiseste viidete arv, viidete tihedus lehekülje kohta ning hallutsineeritud viidete hinnanguline osakaal	Kvantitatiivne loendamine + kontroll
Akadeemiline stiil	Ülalomaga anglitsismide arv, arvutiteaduse ingliskeelsete terminite kasutus ning esimese isiku asesõnade esinemine	Kvantitatiivne loendamine
Juhiste järgimine	Väljundkeel (eesti/inglise), L ^A T _E X-vormingu kasutamine, UniTartuCS malli rakendamine, tiitellehe andmed	Binaarne/kvalitatiivne kontroll

4. TI mudelite võrdlus

Käesolev peatükk esitab nelja valitud TI mudeli võrdluse, keskendudes nende tehnilistele parameetritele, agentse töövoogu jaoks olulistele omadustele ja kulule. Mudelite koondvõrdlus on esitatud kolme tabelina alapeatükis ???: tabel ?? võrdleb tehnilisi parameetreid, tabel ?? võrdleb API hinnakirja näitajaid ning tabel ?? võrdleb lõppkasutaja kuutellimusi. Kõik järgnevad hinnad sisaldavad Eestis kehtivat 24% käibemaksu ja lähtuvad Eesti hinnastusest.

4.1 Google Gemini 3.1 Pro

Google Gemini 3.1 Pro on Google DeepMindi arendatud multimodaalne keelemudel, mis avaldati 2026. aasta veebruaris [34]. See mudel kuulub Gemini mudeliperekonda. Gemini 3.1 Pro kontekstiaken 1 miljon tokenit. Lisaks on Gemini 3.1 Pro natiivne mõtlemismudel (*thinking model*), mis tähendab, et mudel kasutab sisemist ahelpõhjustamist enne vastuse andmist; see parandab oluliselt keeruliste ülesannete lahendamise kvaliteeti, sealhulgas struktureeritud teksti loomist.

Kuluaspektist oli Gemini 3.1 Pro API baasmäärade poolest üks soodsamaid võrreldud mudeleid (vt tabel ??). Sisendhind on astmeline ja sõltub konkreetse päringu kasutatava konteksti pikkusest – lühema konteksti puhul (kuni 200 000 tokenit) on sisendhind ligikaudu 2,12 €/MTok ja väljundi hind ligikaudu 12,70 €/MTok, pikema konteksti puhul vastavalt 4,23 €/MTok ja 19,05 €/MTok. Lõppkasutajale pakub Google API kõrval ka kuutellimusi: Google AI Plus (7,99 €), Google AI Pro (Gemini Advanced) hinnaga 21,99 € kuus ja Google AI Ultra (274,99 €); üksikasjad on koondatud tabelis ??. Kuna agentne töövoog võib sama faili mitu korda lugeda, kirjutada ja kompileerida, käsitletakse tegelikku kogukulu lisauuringu koondina peatükis ??.

4.2 OpenAI GPT-5.4

OpenAI GPT-5.4 on OpenAI juhtiv multimodaalne mudel, mis avaldati 2026. aasta märtsis [35]. GPT-5.4 API kontekstiaken on 1,05 miljonit tokenit; Codexis kirjeldab OpenAI 1M kontekstiakent eksperimentaalse toena ning standardpiiranguna 272K tokenit. Mudel pakub ka mõtlemisrežiimi (*reasoning*), mille intensiivsust saab reguleerida (madal/keskmine/kõrge, väga kõrge), võimaldades kasutajal valida kiiruse ja kvaliteedi vahel.

Hinnastuses paiknes GPT-5.4 API baasmäärade poolest Sonnet 4.6-ga samasse suurusjärku (vt tabel ??): sisend 2,64 €/MTok ja väljund 15,87 €/MTok. Lisaks teistele mudelitele, pakub OpenAI Batch API-t, mis annab asünkroonsete päringute eest ligikaudu 50% allahindlust, kuid ei ole agentse töövoogu jaoks kasutatav, kuna vastuse ooteaeg võib ulatuda mitme tunnini.

Kuutellimustena pakub OpenAI ChatGPT Go (8 €), ChatGPT Plus (23 €) ja ChatGPT Pro (alates 103 €).

4.3 Anthropic Claude Sonnet 4.6

Anthropic Claude Sonnet 4.6 on Anthropicu arendatud keelemudel, mis avaldati 2026. aasta veebruaris [36]. Claude'i mudeliperekond eristub teistest oma rõhuasetusega ohutusele ja põhjalikkusele. Claude Sonnet 4.6 kontekstiaken on 200 000 tokenit (API kaudu 1M tokenit, mida autor ei kasutanud), mis on neljast võrreldud keelemudelist kõige väiksem.

Claude Sonnet 4.6 API hind on võrreldav GPT-5.4 ja Gemini 3.1 Pro-ga (vt tabel ??): sisend 3,17 €/MTok ja väljund 15,87 €/MTok. Kuutellimuste osas pakub Anthropic Eesti regioonis kolme taset: Claude Pro (22 €), Claude Max 5× (106 €) ja Claude Max 20× (212 €).

4.4 Anthropic Claude Opus 4.6

Claude Opus 4.6 on Anthropicu kõige võimekam keelemudel, mis avaldati 2026. aasta veebruaris [37]. Opus kuulub samasse Claude mudeliperekonda kui Sonnet, kuid on oluliselt võimekam mudel. Claude Opus 4.6 kontekstiaken on 1M tokenit, kuid mudeli peamine eelis seisneb paremates agentse töö hindamistulemustes ja sügavamas arutlusvõimekuses. Opus 4.6 jagab Sonnet 4.6-ga samu agentseid omadusi – pikendatud mõtlemisrežiim, tööriistakasutus, arvutikasutus, viipade selgesõnaline vahemälustamine ning teksti-, pildi- ja PDF-sisendi tugi. Suurema kontekstiakna tõttu (1M vs Sonneti 200K) sobib Opus paremini juhtudel, kus tervet projekti tuleb hoida samaaegselt mudeli kontekstis – näiteks kui agentne tööriist loeb iga sammu juures kõiki olemasolevaid L^AT_EX-faile uuesti.

Claude Opus 4.6 on võrreldud mudelitest kõige kallim (vt tabel ??) – sisend 5,29 €/MTok ja väljund 26,45 €/MTok ehk ligikaudu 1,7 korda kallim sisendi ja väljundi hind kui Sonnet 4.6 oma, kuid sellega kaasnes ka parim väljund. Kuutellimustega pakub Anthropic Opus 4.6-le sama Pro/Max 5×/Max 20× tasemestruktuuri kui Sonnetile (vt tabel ??), kuid kuna Opus tarbib päringu kohta rohkem ressursi, on selle mõistlikuks praktiliseks kasutuseks reeglina vaja vähemalt Max 5× tellimust. Selle kompromissi praktiline tõlgendus on esitatud peatükis ??.

4.5 Mudelite koondvõrdlus

Tabelites ??, ?? ja ?? on esitatud nelja mudeli koondvõrdlus, mis on jagatud kolme ossa loetavuse huvides: tehnilised parameetrid, API hinnakiri ning lõppkasutaja kuutellimused. Tabeli ?? read tuginevad mudelite pakkujate ametlikele tooteteadele [34–37] ning tabelite ?? ja ?? read

tuginevad 2026. aasta mai ametlikele hinnakirjadele [38–40]. API hinnad on pakkujate poolt avaldatud USA dollarites tabelis ?? ja need on teisendatud eurodesse 2026. aasta mai vahetuskursi alusel (1 EUR = 1,17 USD ehk 1 USD $\approx$ 0,853 EUR). Kõik hinnad sisaldavad Eesti 24% käibemaksu.

Tabel 2. TI mudelite tehniliste parameetrite võrdlus

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Avaldatud	02/2026	03/2026	02/2026	02/2026
Kontekstiaken	1M	272K (1,05M API)	200K (1M API)	1M
Maks. väljund (tokenites)	64 000	128 000	128 000	128 000
Mõtlemisrežiim	Jah (natiivne)	Jah (reguleeritav)	Jah (pikendatud)	Jah (pikendatud)
Maks. mõtlemistokenid	natiivne	128 000	64 000	64 000
Sisendmodaalsused	Tekst, pilt, heli, video	Tekst, pilt, heli	Tekst, pilt, PDF	Tekst, pilt, PDF
Tööriistakasutus	Jah	Jah	Jah	Jah

Tabel 3. TI mudelite API hinnakirja võrdlus (EUR 1M tokeni kohta)

Hinnakomponent	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Sisend (tavahind)	2,12–4,23 €	2,64 €	3,17 €	5,29 €
Sisend (vahemälust loetud)	0,21–0,42 €	0,26 €	0,32 €	0,53 €
Väljund	12,70–19,05 €	15,87 €	15,87 €	26,45 €

Lisaks API-le pakuvad kõik kolm pakkujat lõppkasutajatele kuutellimusi, mis võimaldavad fikseeritud kuumaksu eest mudelit kasutada vestlusliideses ja ka agentsete tööriistadega keskkonnas (Codex, Cowork, Antigravity). Tellimuste koondvõrdlus on esitatud tabelis ??.

Tabelitest ??–?? on näha, et neli võrreldud mudelit erinevad nii tehniliste parameetrite, API hinnakirja kui ka kuutellimuste poolest märgatavalt. Gemini 3.1 Pro paistab silma

Tabel 4. Lõppkasutaja kuutellimused Eesti regioonis (EUR/kuu)

Pakkuja	Tellimus	Hind/kuu	Olulisemad piirangud ja juurdepääs
Google	Google AI Plus	7,99 €	Piiratud Gemini 3.1 Pro ja AI Studio kasutus
Google	Google AI Pro (Gemini Advanced)	21,99 €	Gemini 3.1 Pro vestlusliideses; piisav Antigravity kasutus
Google	Google AI Ultra	274,99 €	Kõrgeimad Gemini 3.1 Pro, AI Studio ja Antigravity limiidid
OpenAI	ChatGPT Go	8 €	GPT-5.3 Instant laiendatud kasutusega; suurem faililimiit ja mälu kui tasuta plaanis
OpenAI	ChatGPT Plus	23 €	GPT-5.4 piiratud kasutusega; Codexi laienduse piisav kvoot
OpenAI	ChatGPT Pro	229 €	GPT-5.4 oluliselt suurem kasutuskvoot; võimsam mõtlemisrežiim
Anthropic	Claude Pro	22 €	Sonnet 4.6 + Opus 4.6 piiratult; Cowork ja Code piiratud kvoodiga
Anthropic	Claude Max 5×	106 €	5× Pro plaani kasutuspiirangud; täiesti piisav Opus 4.6 ligipääs
Anthropic	Claude Max 20×	212 €	20× Pro plaani kasutuspiirangud; täielik Opus 4.6 ligipääs

kõige soodsamate API baasmäärade ja suure kontekstiaknaga, Sonnet 4.6 kõige väiksema kontekstiaknaga, GPT-5.4 keskmise hinnataseme ja Opus 4.6 kõrgeima väljundhinnaga. Tellimuste hinnad jäävad vahemikku 8–275 € kuus. Neid tuleb arvesse võtta, et otsustada, milline mudel sobib konkreetsele stsenaariumi. Ühe lühikese viibaga väljundi genereerimine on API kaudu suhteliselt odav iga mudeli puhul, kuid pikemate iteratiivsete agentsete sessioonide kogukulu sõltub eelkõige konteksti pikkusest ja iteratsioonide arvust.

5. Eksperimendid ja tulemused

Käesolevas peatükis kirjeldatakse läbiviidud eksperimente ja nende tulemusi, keskendudes nelja keelemudeli genereeritud bakalaureusetööde võrdlevale analüüsile. Lisaks esitatakse iteratiivse juhtumiuuringu käigus tehtud tähelepanekud, mille põhjal hinnatakse, kuidas juhendamise ja paranduste korduv rakendamine mõjutab lõpptulemuse kvaliteeti.

5.1 Tulemuste koondülevaade

Eksperimendis paluti igal mudel-tööriista kombinatsioonil genereerida ühe kasutajaviibaga terviklik bakalaureusetöö informaatika valdkonnast, ilma järelküsimate ega iteratiivse suunamiseta. Mudelitele anti identne lühike eestikeelne viip (vt peatükk ?? ja lisa ??), mis palus mudelil luua Tartu Ülikooli arvutiteaduse instituudi nõuetele vastava L^AT_EX-vormingus bakalaureusetöö, kasutades töökausta paigutatud UniTartuCS malli. Konkreetset temapealkirja ette ei antud – mudel pidi ise valima informaatikaga seotud teema. Autori (Uku Renek Kronbergs) ja juhendaja (Alo Peets, MSc) nimed anti tiitellehe ja litsentsi täitmiseks (ainult autori nimi).

Viip on teadlikult lühike, et lisaks teada saada, kuidas mudel-tööriista kombinatsioonid reageerivad minimaalsele juhisele ning kas nad suudavad iseseisvalt valida sobiva teema, keele ja struktuuri. Kuna ülesanne nõuab failihaldust, mitme L^AT_EX-faili loomist ja kompileerimist, kasutati iga mudeliga agentset töövoogu. Sonnet 4.6 ja Opus 4.6 puhul kasutati Anthropicu Ceworki, Gemini 3.1 Pro mudeliga Google'i Antigravityt ning GPT-5.4 puhul ChatGPT Codexi laiendust Visual Studio Code'is.

Tulemused olid kombinatsioonide lõikes märgatavalt erinevad, nagu on näha tabelist ?. Oluline tõlgenduslik märkus veel kord: järgnevas analüüsis tuleb tulemusi vaadelda mudeli ja agentse tööriista paaride, mitte puhaste mudeli võimekuste näitajatena – iga jooks tehti üks kord, mistõttu näitajad on eksploratiivsed ja võivad kordusjooksudel olulisel määral erineda.

Tabel 5. Tervikliku lõputöö genereerimise tulemuste koondülevaade

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Väljundkeel	Eesti	Eesti	Eesti	Eesti
Maht (lehekülgi)	39	47	40	61
Valitud teema	GenAI ja algajad progr.	RAG-põhine QA-süsteem	LLM koodiülevaatuses	Paroolihaldur
Struktuur	Lõputöö vormis	Lõputöö vormis	Lõputöö vormis	Lõputöö vormis
Agentne tööriist	Antigravity	Codex VS Code'is	Cowork	Cowork
Viited	9, 1 viga (11%)	22, 0 viga (0%)	23, 5 viga (22%)	35, 2 viga (6%)

Järgnevad alapeatükid esitavad iga mudel-tööriista kombinatsiooni kohta detailse kvalitatiivse hinnangu, alustades Claude Sonnet 4.6 + Coworki tulemusest ning jätkates GPT-5.4 + Codexi, Gemini 3.1 Pro + Antigravity ja Claude Opus 4.6 + Coworki väljunditega. Numbrilised koondtulemused on esitatud alapeatükkides 5.6–5.9.

5.2 Claude Sonnet 4.6 (Cowork)

Claude Sonnet 4.6 + Coworki kombinatsioon genereeris 40-leheküljelise eestikeelse dokumendi, mis järgis bakalaureusetöö struktuuri. Kombinatsioon valis teemaks “Suurkeelemodelite kasutamine automaatses koodiülevaatuses” – empiirilise võrdluse GPT-4, Claude 3 Opuse ja Code Llama 70B vahel, mis põhines väidetavalt 120 koodifragmendist koosneval testkogumil neljas veakategoorias (loogilised vead, turvaaugud, jõudlusprobleemid, stiilirikkumised) Pythoni ja Java keeles. Töö sisaldas detailseid hindamistabeleid täpsuse, saagise ja F1-mõõdiku numbritega ning kõigi mudelite kohta konkreetseid numbreid (nt GPT-4 üldine F1 = 82,5%, Claude 3 Opus 77,9%, Code Llama 70B 70,0%). Sarnaselt Gemini 3.1 Pro fabritseeritud uuringuga (vt alapeatükk ??) tuleb ka neid empiirilisi näitajaid käsitleda kontrollimata väidetena, kuna käesoleva uurimuse autor ei viinud läbi ühtegi sellist kontrollitud katset. Akadeemiline stiil oli tugev ja töö järgis L^AT_EX-malli korrektsesti. Olulise vorminguveana paistis silma ka asjaolu, et tiitellehel kasutas mudel autorinime kärbitud kujul (“Uku Renek”), juhendaja nime asemel kohataidet (“Prof. Vanem Juhendaja, PhD”) ning aastana “2025” (mitte 2026).

Peamised puudused olid hallutsineeritud viited (5 viga 23-st ehk umbes 22%), kohati keeruline lauseehitus ning 37 keele- ja kirjaviga kogu töö ulatuses (vt peatükk ??), sealhulgas terminoloogilised eksimused (*finantreenimine*, *looduskeel*), näpukad (*deviatsiooonid*, *annotatsiooonid*) ja sõnavormivead (*hallutsinesid*). Viidete hallutsinatsioonid olid tähelepanuväärsed: artiklite pealkirjad ja arXiv-identifikaatorid olid enamasti korrektsed, kuid mudel “täitis” autoriloendeid väljamõeldud nimedega. Näiteks paberis “Towards Automating Code Review Activities” (ICSE 2021) olid loetletud autorid “Tufano M., Ni S. Y., Chromik S., Brunner R., Svyatkovskiy A., Clement C. B., Sundaresan N.”, samas kui tegelikud autorid on Rosalia Tufano, Luca Pascarella, Michele Tufano, Denys Poshyvanyk ja Gabriele Bavota. Teises näites (“Impact of Code Language Models on Automated Program Repair”, arXiv:2302.05020) loetles mudel autorid “Jiang J., Huang L., Liu Z., Lo D., Xia X.”, kuid tegelikud autorid on Nan Jiang, Kevin Liu, Thibaud Lutellier ja Lin Tan. Kõige tähelepanuväärsem juhtum oli viide “JITBot” (Pornprasit ja Tantithamthavorn, ASE 2022), kus mudel kombineeris kahe eri paberi metaandmed: JITBot eksisteerib, kuid ASE 2020 ja täiesti teiste autoritega; Pornprasit ja Tantithamthavorn kirjutasid hoopis paberi nimega “JITLine” (MSR 2021).

5.3 GPT-5.4 (Codex)

GPT-5.4 tulemus erines teistest põhimõtteliselt, kusjuures erinevus ei tulenenud mitte mudelist, vaid liidesest, mille kaudu mudelit kasutati. Tavapärase ChatGPT vestlusliidese kaudu keeldus mudel genereerimast terviklikku lõputööd, viidates otseselt akadeemilise aususe piirangutele. Väljundis selgitati, et täieliku bakalaureusetöö kirjutamine tudengi eest oleks vastuolus Tartu Ülikooli akadeemilise aususe reeglitega. Selle asemel pakkus GPT-5.4 välja 8-leheküljelise ingliskeelse teostatavusjuhendi (*feasibility guide*), mis sisaldas mudelivaliku soovitusi, eksperimendi disaini raamistikku, hindamismetoodikat ja L^AT_EX-malli juhiseid. Kuigi juhend oli sisuliselt kvaliteetne ja viited olid kontrollitavad, ei vastanud see ülesande püstitusele: väljund oli inglise, mitte eesti keeles, ja vormilt pigem nõuandev memo kui akadeemiline lõputöö. See käitumine viitab sellele, et ChatGPT vestlusliidese süsteemijuhised ja ohutuspoliitika tõlgendavad “tervikliku bakalaureusetöö genereerimise” tüüpi ülesandeid vaikumisi akadeemilise aususe piirangu alla kuuluvana ning eelistavad sellistes olukordades keeldumist või nõuandvat vastust.

Täiendav katse OpenAI ChatGPT Codexi laiendusega Visual Studio Code'i keskkonnas andis aga identsest viibast hoolimata oluliselt erineva tulemuse. Sama GPT-5.4 mudel suutis agentse tööriista kaudu genereerida visuaalselt teiste kombinatsioonide väljunditega sarnase tervikliku

47-leheküljelise eestikeelse dokumendi teemal “Eestikeelse RAG-põhise küsimus-vastuse süsteemi kavandamine”. See erinevus näitab, et agentne töövoog muudab ülesande konteksti ja tööjaotust – ülesanne jaotub väiksemateks faili- ja kompileerimispõhisteks sammudeks ning liidese süsteemijuhised ja ohutuspoliitika on erinevad. Teisisõnu käitus sama mudel erinevates liidestest väga erinevalt. Codexi laienduse kaudu genereeritud töö oli ortograafilise täpsuse poolest silmapaistev: kogu töö ulatuses tuvastati kolm unikaalset kirjaviga (*vastusevormingun, lekita, dokumentikorpused*), mis oli nelja kombinatsiooni seas parim tulemus (vt peatükk ??). Lisaks oli see ainus kombinatsioon, mille kõik 22 viidet (peamiselt arXiv- ja ACL Anthology paberid) olid täielikult kontrollitavad ja korrektsete metaandmetega – ühtegi hallutsineeritud autorit, pealkirja ega aastat ei tuvastatud.

Olulise akadeemilise aususe näitajana paistab silma ka asjaolu, et Codex-laiendusega genereeritud töö ei kasutanud tiitellehel, litsentsis ega allkirjas viibas etteantud autori (Uku Renek Kronbergs) ega juhendaja (Alo Peets, MSc) nime, vaid kohataidet *Näidisüliõpilane* ja *Juhendaja nimi, PhD*. See viitab sellele, et ka agentse töövoogu kaudu säilitas mudel suuure ettevaatlikuse.

5.4 Gemini 3.1 Pro (Antigravity)

Gemini 3.1 Pro + Antigravity kombinatsioon genereeris 39-leheküljelise eestikeelse bakalaureusetöö teemal “Generatiivse tehisintellekti mõju tarkvaraarenduse produktiivsusele algajate programmeerijate seas”. Kombinatsioon valis iseseisvalt informaatika valdkonnast aktuaalse ja hästi piiritletud uurimisteema, mis käsitles suurte keelemudelite mõju programmeerimise õppimisele.

Genereeritud töö oli struktuuralselt terviklik ja sisaldas kõiki nõutud komponente. Tausta- ja kirjandusülevaate peatükk sisaldas transformer-arhitektuuri, kognitiivse koormuse ning *over-reliance*’i käsitlust. Metoodikas oli väidetavalt 2026. aasta märtsis Tartu Ülikooli Delta õppehoone arvutiklassis tehtud kvaasi-eksperimentaalne katse 30 informaatika esmakursuslasega: 16 meest ja 14 naist vanuses 18–22 aastat, kes jagati 15-liikmeliseks katse- ja kontrollrühmaks ning kasutasid Tartu Ülikooli HPC klastris jooksutatud lokaalset LLaMA-3-8B-Instruct mudelit. Lisad olid ka hästi esitatud: tagasisideküsimustik, React.js koodiredaktori komponent (ca 150 rida), PostgreSQL andmebaasi skeem (5 tabelit), Pandas/SciPy andmeanalüüsi skript (ca 160 rida) ning tudengite koodinäited koos vigade analüüsiga.

Töö tugevused olid järgmised:

- Akadeemilise struktuuriga hästi arvestatud: uurimisküsimused, hüpoteesid, statistilised testid;
- Eesti keele kvaliteet oli üldiselt hea, kuigi esines mõningaid terminoloogilisi ebajärjekindlusi;
- Viited (9 allikat) kasutasid reaalse teadlaste nimesid (Becker, Kazemitabaar, Vaswani jt), aga lingid olid puudu;
- Koodinäited lisades olid funktsionaalsed ja loogiliselt kirjutatud;
- Töö maht (39 lehekülge) vastas bakalaureusetöö nõuetele.

Peamised puudused olid siiski suured, kusjuures esimene neist ei ole käsitletav tavapärase kvaliteedipuudusena, vaid akadeemilise väärkasutuse kõrge riskiga juhtumina:

- **Fabritseeritud empiiriline uurimus.** Kombinatsioon esitas väidetavalt 2026. aasta märtsis Tartu Ülikooli Delta õppehoones läbi viidud kvaasi-eksperimenti 30 informaatikatudengiga, sealhulgas osalejate jaotuse 15-liikmeliseks katse- ja kontrollrühmaks, konkreetseid Welch'i t-testid ja standardhälbed, numbrilised tulemused (näiteks Ülesande 1 puhul katsegrupi 14,2 vs kontrollgrupi 27,5 minutit, $p < 0,001$; testide läbivuse osas 64% vs 82%) ning kirjeldatud testikeskkonna tehnilise arhitektuuri (React/TypeScript klient Monaco Editor'i baasil, Node.js/Express server, Docker liivakast koodi käivitamiseks ning kohaliku LLaMA-3-8B-Instruct mudeli kasutamine TÜ HPC klastris). Seda uurimust tegelikult ei toimunud – tudengeid, nende koode, katsekeskkonda ega statistilisi tulemusi ei eksisteeri. Lugeja, kes ei kontrolli andmeid, saab äärmiselt veenva, kuid tegelikkuses olematu uuringu.
- Viidete kontrolli järgi olid 9-st viitest 8 täielikult korrektsed ning ühel juhul oli vale 6. autor (viide [1] Becker jt 2023 “Programming Is Hard” loetles autorina “Reeves E. A.”, kuigi tegelik 6. autor on Eddie Antonio Santos – Brent N. Reeves on hoopis seotud paberiga “It’s Weird That it Knows What I Want”). Hallutsineerimismäär oli seega ca 11%.
- Eesti keele ortograafiline täpsus oli selgelt probleemne – töös tuvastati 24 unikaalset kirjaviga, sealhulgas sõnade valed vormid (*struktuure*, *kordinaadid*, *konfliktide*), mittesõnad (*teoosiab*, *Tehisintsistendi*) ning valede tähtedega asendatud täpitähed ja nimed (vt peatükk ??);

Need puudused – eriti fabritseeritud empiiriline osa – ilmestavad kesksel tähelepanekul, et vormiliselt veenev TI-genereeritud akadeemiline tekst ei tähenda automaatselt sisuliselt usaldusväärset tööd ning inimese põhjalik järelkontroll on hädavajalik isegi siis, kui väljund järgib lõputöö struktuuri ja akadeemilist stiili.

5.5 Claude Opus 4.6 (Cowork)

Claude Opus 4.6 + Coworki kombinatsioon andis selles eksperimendis kõige ulatuslikuma ja kvaliteetsema väljundi – 61-leheküljelise eestikeelse bakalaureusetöö teemal “Turvalise paroolihalduri veebirakenduse arendamine”. Coworki agentne tööriist võimaldas mudelil otse kirjutada $\text{\LaTeX}$ -faile, hallata viiteid ja kompileerida dokumenti.

Genereeritud töö sisaldas terviklikku tehnilist arhitektuuri (nullteadmise põhimõte, AES-256-GCM krüpteering, Argon2id võtmetuletamine) ning täielikku React/TypeScripti kasutajaliidest ja Node.js/Expressi taustarakendust. Lisaks väitis töö, et rakendus läbis 149 automatiseeritud testi, OWASP Top 10 vastavuse analüüsi ja süsteemi kasutatavuse skaala (SUS) hindamise skooriga 77,0 ning et turvaaudit ei tuvastanud ühtegi kriitilist turvaauku. Olulise metoodilise märkusena tuleb rõhutada, et käesoleva eksperimendi autor ei teinud ise neid teste, auditit ega kasutajauuringut – need näitajad on kirjas Opus 4.6 + Coworki kombinatsiooni enda genereeritud väljundis. Opus 4.6 loodud töös kirjeldatud arhitektuur ja koodinäited olid siiski tunduvalt detailsemad ja sidusamad kui Gemini 3.1 Pro töös esitatud statistilised tulemused. Vormingulise piiranguna paistis silma asjaolu, et kolm kavandatud joonisekohta (süsteemi arhitektuur, andmebaasi ER-diagramm ja võtmetuletuse skeem) jäeti PDF-is kohatäideteks – jooniste asemel on “*Siia tuleb arhitektuuridiagramm...*” tüüpi tekstid –, mis viitab sellele, et agentne tööriist suutis küll kavandada jooniste paigutuse ja kirjeldada nende sisu, kuid ei loonud tegelikke graafilisi diagramme.

Opus 4.6 + Coworki tulemuse peamised erinevused võrreldes Sonnet 4.6 + Coworki tulemusega:

- Oluliselt suurem maht (61 vs 40 lehekülge), mis viitab sügavamale sisulisele käsitlemisele;
- Tehniline detailsus oli kõrgem – töö sisaldas konkreetseid koodi- ja arhitektuurinäiteid;
- Eesti keele kvaliteet oli ühtlasem ja loomulikum ka pikemas tekstis – kogu 61-leheküljelise töö ulatuses tuvastati 15 unikaalset keele- ja kirjaviga (näiteks *Carnegei*, *Californiya*, *taaskasutatavarteks*, *mälusest*), mis teeb kirjavigade tiheduseks 0,25 viga lehekülje kohta (vt peatükk ??);

- Viidete hallutsineerimise määr oli oluliselt madalam: 35-st viitest oli 33 täielikult korrektsed, kahes oli väike metaandmete viga (Hunti 2019. aasta viites oli URL-i kuju vigane ning Gosney 2019. aasta viites oli pealkirjas ekslikult “GTX 1080 Ti”, samas kui viidatud GitHubi gist sisaldab “GTX 1080” (ilma Ti) eelarvustuste tulemusi 2016. aastast). Hallutsineerimismäär oli seega 6%, võrreldes Sonnet 4.6 22%-ga, kusjuures Sonneti puhul olid vead sisulisemad (väljamõeldud autorid), samas kui Opuse vead olid puhtalt metaandmete tasemel.


Eriti tähelepanuväärne on agentsete tööriistade ja liideste mõju tulemusele. Nii Cwork (Opus 4.6 ja Sonnet 4.6 puhul), Google'i Antigravity (Gemini 3.1 Pro puhul) kui ka ChatGPT Codex (GPT-5.4 puhul) andsid oluliselt erineva tulemuse kui puhas vestlusliides – seda kinnitas kõige ilmekamalt GPT-5.4 kahe stsenaariumi vastandlik tulemus. Kõik kombinatsioonid valisid iseseisvalt erineva informaatikateema, mis näitab, kui erinevalt samale lühikesele viibale reageeritakse. Isegi kõige edukamad tulemused (Opus 4.6 + Cwork, GPT-5.4 + Codex ja Gemini 3.1 Pro + Antigravity) vajasis inimese järeltööstlust: viidete kontrollimist, terminoloogia ühtlustamist ja fabritseeritud andmete tuvastamist. Kuna iga kombinatsiooni kohta tehti vaid üks jook, ei saa ühe jooku põhjal väita, et üks mudel on üldiselt parem kui teine – saab väita üksnes, et selles eksploriatiivses katses andis konkreetne mudel-tööriista kombinatsioon konkreetse tulemuse. Genereeritud tööde väljavõtted on esitatud lisas ??.

5.6 Kirjavigade ja keeleliste vigade analüüs

Eesti keele kvaliteedi täpsemaks hindamiseks vaadati eraldi üle iga genereeritud lõputöö keele- ja kirjavead – see tähendab ortograafilised hooletusvead, valed tähed, puuduvad või liigsed tähed, sõnade valed vormid, terminoloogilised väärvormid ning pärisnimede vead. Sama vea kordumine mitmel leheküljel loeti üheks unikaalseks leiuks, mitte iga esinemiskord eraldi. Tabelis ?? on esitatud vigade koondarv iga töö kohta ning arvestuslik tihedus lehekülje kohta.

Tabel 6. Genereeritud tervikliku lõputöö keele- ja kirjavigade koondarv

Mudel	Maht (lk)	Keele- ja kirjavigade arv	Vigu lk kohta
Gemini 3.1 Pro (Antigravity)	39	24	0,62
Claude Sonnet 4.6 (Cwork)	40	37	0,93
Claude Opus 4.6 (Cwork)	61	15	0,25
GPT-5.4 (Codex)	47	3	0,06



Joonis 2. Keele- ja kirjavigade tihedus genereeritud töödes.

Tulemused näitavad nelja mudeli vahel märkimisväärt erinevust eesti keele täpsuses. GPT-5.4 Codexi laienduse kaudu genereeritud töös tuvastati kogu 47-leheküljelise dokumendi peale kolm selget kirjaviga: *vastusevormingun*, *lekita* ja *dokumentikorpused*. See jäi nelja kombinatsiooni madalaimaks veamääraks.

Claude Opus 4.6 töös tuvastati 61 lehekülje peale 15 keele- ja kirjaviga. Lisaks pärisnimede vigadele (*Carnegei*, *Californiya*) esines tavasõnade ja liitvormide eksimusi, näiteks *taaskasutatavarteks*, *juhusiku*, *mälusest*, *konteineriena*, *mõnesekundi* ja *stsenaariumm*. Opuse veamäär jäi siiski madalaks, sest töö oli võrdluses kõige mahukam.

Claude Sonnet 4.6 töös oli kõige suurem unikaalsete keeleliste vigade koondarv: 37 leidu 40 lehekülje kohta. Vead olid mustrikselt mitmekesised. Korduvad topelttähed (rohkem kui kaks sama tähte järjest) avaldusid sõnades *deviatsiooonid*, *annotatsiooonid* ja *genereeeritud*; tähed olid puudu või asendunud vormides *Eeltrenimine*, *kategoriad*, *kodile treenitud* ja *suurkeelmudeli*. Lisaks esines terminoloogilisi või tõlkevaldkonna eksimusi, näiteks *finantreenimine*, *looduskeel*, *informeerimise taastamine* ja *kaksikeliigsust*. Mõned vead olid pigem sõnavaliku- või grammatikavead, näiteks *kasumlikkusest* õige *kasulikkusest* asemel ning *tööriistad ületas* õige *tööriistad ületasid* asemel.

Gemini 3.1 Pro genereeritud töös tuvastati 39 lehekülje kohta 24 unikaalset kirjaviga. Vead jagunesid mitmesse põhikategooriasse. Levinuima kategooria moodustasid puuduvate või vahetatud tähtedega sõnad (*strukuure*, *kordinaadid*, *vektoorruumi*, *konfliktide*, *sepsifüliste*, *uenit*, *ekponentvõimendi*, *hariduteadusele*). Teise rühma kuulusid valede tähtedega asendatud täpitähed

või häälikud (*narvivõrgu, moita*). Kolmandana esinesid moodustatud vigased vormid (*teoosiab, Tehisintsistendi, algasestatud, vetiaknakujuline*). Lisaks esines pärisnime viga *Düning-Krugi* õige *Dunningi-Krugi* asemel.

Kokkuvõttes näitas madalaimat veatihedust GPT-5.4 agentse tööriista kaudu, sellele järgnes Claude Opus 4.6. Sonnet 4.6 suurem koondarv tulenes osaliselt sellest, et loendisse arvestati lisaks ortograafilistele näpukatele ka terminoloogilisi ja sõnavormivigu. Gemini 3.1 Pro puhul oli probleem teistsugune: vigu oli vähem kui Sonneti koondloendis, kuid need olid sagedamini silmatorkavad ortograafilised vead ja mittesõnad. See tulemus rõhutab, et inimese keelelise toimetamise etapp on TI-ga genereeritud tekstide puhul veel vältimatu (ühe viibaga bakalaureusetöö genereerimisel).

5.7 Mahu ja struktuuri analüüs

Lisaks keele- ja kirjavigadele uuriti iga genereeritud töö mahtu ja sisemist struktuuri. Mahu hindamiseks loeti kokku kogu PDF-failist eraldatud sõnad (sealhulgas tekst, tabelite sisu, lisad ja viited) ning arvutati välja sõnade arv lehekülje kohta. Struktuuri hindamiseks loendati nummerdatud alapeatükkide, tabelite, tegelike jooniste ja koodinäidete arv kogu töös. Jooniste kohatäitjaid, mille asemel oli PDF-is vaid tekstiline märkus joonise lisamiseks, joonistena ei arvestatud. Tulemused on esitatud tabelis ??.

Tabel 7. Genereeritud tööde maht ja struktuurielemendid

Mudel	Lk	Sõnu	Sõnu/lk	Alapt.	Tab.	Joon.
Gemini 3.1 Pro	39	7 230	185	20	2	0
GPT-5.4 (Codex)	47	9 669	206	49	7	2
Claude Sonnet 4.6	40	8 085	202	32	7	0
Claude Opus 4.6	61	10 749	176	27	11	0

Kõige suurema mahu (10 749 sõna) genereeris Claude Opus 4.6, mille sisu oli samas kõige kompaktsemalt jaotatud (176 sõna lehekülje kohta – madalaim näitaja, mis tuleneb suuremast hulgast koodinäidetest, tabelitest ja jooniste kohatäiteplokkidest). Tihedaim tekstiline sisu oli GPT-5.4 ja Sonnet 4.6 töödes (vastavalt 206 ja 202 sõna lehekülje kohta). Ainsa tegelike joonistega tööna eristus GPT-5.4 (Codex), milles oli 2 lihtsamat joonist. Kõige üksikasjalikuma struktuuriga töö genereeris samuti GPT-5.4 – 49 alapeatükki 47 lehekülje kohta. Gemini 3.1 Pro

maht oli väikseim (7 230 sõna) ja sõnatihedus mõõdukas (185 sõna lehekülje kohta), mis koos jooniste puudumisega viitab pinnapealsemale käsitlusele.

Gemini 3.1 Pro, Claude Sonnet 4.6 ja Claude Opus 4.6 töödes ei olnud ühtegi päriselt genereeritud joonist, mis on bakalaureusetöö kontekstis ebatavaline – enamik tehnilisi lõputöid sisaldab arhitektuuriskeeme või andmevoo diagramme. Opus 4.6 kavandas küll kolm joonisekohta (süsteemi arhitektuur, andmebaasi ER-diagramm ja võtmetuletuse skeem), kuid jättis need PDF-is kohatäideteks. Sonnet 4.6 ja Gemini 3.1 Pro eelistasid suuremas mahus koodinäidete lisamist, samas kui Opus 4.6 integreeris koodinäited tihedamalt teksti sisse. GPT-5.4 töös koodinäiteid praktiliselt ei esinenud – tegu oli puhtalt kontseptuaalse RAG-süsteemi arhitektuurilise kavandiga.

5.8 Viidete kvantitatiivne analüüs

Akadeemilise töö üks olulisi kvaliteedinäitajaid on viidete kasutamise tihedus ja allikate arv. Iga töö kohta loeti kokku kasutatud viidete koguarv (kirjanduse loendis esitatud unikaalsed allikad), tekstisest viidete arv ($[N]$ tüüpi viidete esinemiskorrad enne kirjanduse loendit) ning arvutati tekstisest viidete tihedus lehekülje kohta. Tulemused on esitatud tabelis ??.

Tabel 8. Genereeritud tööde viidete analüüs

Mudel	Unikaalseid viiteid	Tekstisest viiteid	Viiteid lk kohta	Viite/allika suhe
Gemini 3.1 Pro	9	13	0,33	1,44
Claude Sonnet 4.6	23	54	1,35	2,35
GPT-5.4 (Codex)	22	28	0,60	1,27
Claude Opus 4.6	35	45	0,74	1,29

Tulemused näitavad, et Claude Opus 4.6 kasutas kõige rohkem unikaalseid allikaid (35), mis vastab paroolihalduri valdkonna iseloomule, kus on vaja viidata krüptograafilistele standarditele (NIST, IETF RFC), turvauuringutele ja olemasolevatele lahendustele. Tekstisest viidete arvu ja tiheduse poolest eristus aga Claude Sonnet 4.6: 40-leheküljelises töös esines 54 tekstisest viidet, mis teeb 1,35 viidet lehekülje kohta. GPT-5.4 (22 unikaalset allikat) ja Claude Sonnet 4.6 (23 unikaalset allikat) jäid allikate hulga poolest keskele. Gemini 3.1 Pro paistis silma väikseima viidete arvuga (9 unikaalset allikat 39 lehekülje peale), mis on bakalaureusetöö kontekstis

tagasihoidlik. See näitaja kinnitab üldist tähelepanekut, et Gemini 3.1 Pro genereeritud töö vähese allikatoega.

Viite/allika suhe (tekstisest viidete arv jagatud unikaalsete allikate arvuga) näitab, mitu korda iga allikat keskmiselt kasutati. Gemini 3.1 Pro, GPT-5.4 ja Claude Opus 4.6 jäid 1,27–1,44 vahemikku, mis tähendab seda, et enamus allikaid kasutati tekstis vaid 1–2 korda. Claude Sonnet 4.6 eristus kõrgema suhtarvuga 2,35. Oluline on siiski rõhutada, et see analüüs ei hinda viidete *sisulist* korrektsust ega kontrollitavust – osa viidetest olid hallutsineeritud, eriti Sonnet 4.6 (ca 22%) ja Opus 4.6 (ca 6%) töödes.

5.9 Akadeemiline stiil

Eestikeelse akadeemilise teksti üks kvaliteedinäitajaid on tõlkimata jäetud või eesti keele konventsioonidest erinevate ingliskeelsete terminite vähene esinemine ja umbisikulise stiili järgimine. Ülakomaga vormistatud ingliskeelsete sõnade hulk varieerus mudelite lõikes (Sonnet 4.6 + Cowork: 5; GPT-5.4 + Codex: 4; Opus 4.6 + Cowork: 3; Gemini 3.1 Pro + Antigravity: 6), kuid sellesse näitajasse mahuvad ühtmoodi nii välditavad inglismõjud (*prompt, pipeline*) kui ka vältimatud valdkonnaspetsiifilised standardterminid (*salt, nonce, hash, AES-256-GCM, Argon2id*) ja toote- või firmanimed (*Google, Cowork*). Seetõttu on koondnäitaja tõlgenduslikult ebatäpne ning täpsem kolmekategooriline loendus jääb edasiste uurimuste metoodiliseks täienduseks. Esimese isiku asesõnade (*ma, mina, me, meie, meil, meid, minu*) loenduses järgisid kõik neli mudelit umbisikulist stiili väga hästi: Opus 4.6, Sonnet 4.6 ja GPT-5.4 ei kasutanud tekstis ühtegi esimese isiku asesõna ning Gemini 3.1 Pro töös tuvastati vaid üks selline juht. See näitab, et tänapäeva suured keelemudelid on eesti keele akadeemilise stiili konventsioonid hästi ära õppinud.

5.10 Iteratiivne juhtumiuuring: Claude Opus 4.7 koos Claude Code'iga

Käesolev alapeatükk kirjeldab eraldi juhtumiuuringut, mis on alapeatükkides ??–?? esitatud nelja kombinatsiooni võrdlusest metoodiliselt selgelt eristatav. Selle eesmärk on anda võrdluspunkt, et milline tulemus on saavutatav siis, kui kasutaja on aktiivselt töövoogu suunamas pikema iteratiivse seansi vältel, mitte ei piirdu ühe lühikese viibaga. Töövoo täielik vestlusajalugu ja kõik vahesammud on avalikult kättesaadavad autori GitHubi repositooriumis https://github.com/UkuRenekKronbergs/TI_bakalaureusetoo, mis võimaldab iga sammu eraldi kontrollida.

5.10.1 Töövoo ülesehitus ja erinevused põhieksperimendist

Genereerimiseks kasutati Anthropicu mudelit `claude-opus-4-7` koos pikendatud 1 miljoni tokeni pikkuse kontekstiaknaga ning agentse tööriistana Claude'i rakenduses olevat Claude Code'i, mis võimaldab mudelil otse projektifaile lugeda, luua ja muuta ning käsurea kāske käivitada. Töö valmis ühe tööpäeva (ligikaudu kaheksa tunni, aga mitte ühe sessioonina) jooksul autori aktiivsel juhendamisel. Kasutaja andis mudelile vahekāske, lūkkas tagasi ebasobivaid lahendusi, palus konkreetseid täiendusi (näiteks pilootuuringu metoodika täpsustamist) ning kontrollis vahepealseid kompileerimistulemusi. Täiendava abivahendina kasutati keelekontrolliks ja sõnastuse parandamiseks OpenAI GPT-5.5 mudelit ChatGPT Codexi laienduse kaudu, millega lasti Opus 4.7 genereeritud tekst üle vaadata ja sõnastust ühtlustada. Mõlemat mudelit kasutati suurima kättesaadava arutlussügavusega (Opus 4.7 puhul *max* ja GPT-5.5 puhul Codexi extra-high arutlusrežiim), et maksimeerida väljundi kvaliteeti ja mitmekesisust. Antud uhtumiuuringu puhul kaasnes sellega väga suur tokenikasutus: Claude Code'i seansis loeti vahemälust ligikaudu 403,0 miljonit tokenit, loodi 8,15 miljonit vahemälutokenit ja genereeriti 2,03 miljonit väljundtokenit; GPT-5.5 korrektuur lisas veel 38,7 miljonit sisendtokenit ja 0,33 miljonit väljundtokenit. Ametlike API-hindade põhjal oleks sellise mahuga töövoog maksnud ligikaudu 371 € koos käibemaksuga (vt alapeatükk ??; hinnakirjad: [38, 39]).

Oluline metoodiline täpsustus on see, et autor ei teinud käesoleva juhtumi vältel ühtegi käsitsi parandust ei L^AT_EX-lähtekoodis ega ka koodifailides – kogu tekst, vormistus ja parandused tehti mudelitele antud käsude kaudu. Lähim käsitsi toimetamisele tegevus oli vahekāsk Opus 4.7-le, kus autor osutas konkreetsele defektile (näiteks vigased tabeli legendid, joonisealune kirjeldus või vorminduslik ebaühtlus) ja palus mudelil seda parandada. Selline ranguse aste oli teadlik metoodiline valik, et juhtumi tulemus peegeldaks võimalikult selgelt mudeli ja agentse tööriista koostööst saadavat ülempiiri piiratud aja jooksul.

Erinevus alapeatükis ?? kirjeldatud ühe kasutajaviibaga (*single-turn zero-shot*) eksperimendist on suur. Esiteks ei vasta töö protokoll ülejäänud nelja kombinatsiooni omale, kuna käesolevas juhtumiuuringus oli viipasi väga palju rohkem kui üks ja kasutaja sekkus protsessi pidevalt. Teiseks kasutati uuemat mudelipõlvkonda (Opus 4.7 ja keeletoimetuseks GPT-5.5), mida põhieksperimendi ajal veel saadaval ei olnud. Seetõttu ei kaasata seda juhtumit tabelisse ?? ega keele- ja kirjavigade tihedusvõrdlusesse (tabel ??), vaid esitatakse eraldi näitena, et mis on iteratiivse töövoog korral saavutatav.

5.10.2 Valitud teema ja töö sisu

Mudel valis koostöös autoriga teemaks “Suurel keelemudelil põhineva eestikeelse informaatika teksti tagasisidesüsteemi prototüüp ja pilootuuring”. Valitud teema on tugevalt iseviitav: TI-genereeritud lõputöö, mis kirjeldab TI-põhise süsteemi loomist eestikeelse akadeemilise teksti tagasisidestamiseks neljas kategoorias (struktuur, akadeemiline stiil, terminoloogia järjepidevus ja viitamisvajadus).

Genereeritud töö maht oli 57 lehekülge ning struktuur järgis bakalaureusetöö ülesehitust: sissejuhatus koos generatiivse tehisintellekti kasutamise deklaratsiooniga, taust ja seotud tööd, metoodika, prototüübi peatükk, pilootuuringu ja empiirilise hindamise peatükk, kokkuvõte, viited ja neli lisa. Lisaks tekstidokumendile sisaldab repositoorium tegelikku Pythoni ja TypeScripti lähtekoodi: `prototuuup/backend/` kausta FastAPI-l põhinev taustarakendus, `prototuuup/frontend/` kausta React 18 + TypeScript + Tailwind CSS kasutajaliides ning `statistika/` kausta hindamisskriptid (`andmestik_synth.py`, `paris_hindamine.py`) ja salvestatud API-vastused. Käivitamiseks on ette nähtud `docker compose up` käsk; demo-režiim töötab ilma välise API-võtmeta, mis muudab tulemuse reprodutseerimise lihtsaks.

5.10.3 Genereeritud empiirilise osa kvaliteet

Genereeritud töö empiirilises osas (peatükk 5.8) koostati 20 katkendist koosnev sünteetiline testkogu (kategooriapõhise jaotusega: sissejuhatus 4, taust 5, metoodika 4, tulemused 4, kokkuvõte 3) ning 42 kuldstandardi annotatsiooni. Selle vastu tehti 80 tegelikku API-päringut Claude Opus 4.7 ja GPT-5.5 mudelitele, kasutades üldist ja struktureeritud viiba versiooni. Mudelivastused skooriti tekstivahemiku tasemel kattuvuse järgi kuldstandardi vastu. Genereeritud töös esitati makrokeskmiseks F1-skooriks 0,38–0,56, parima tulemuse sai GPT-5.5 koos struktureeritud viibaga (täpsus 0,47, saagis 0,77, $F1 = 0,56$). Kogu hindamise rahaline kulu oli 3,88 USA dollarit ja kogukestuseks 37 minutit.

Erinevalt alapeatükis ?? käsitletud Gemini 3.1 Pro tööst – kus väidetav empiiriline uurimus (30 üliõpilast Delta hoones) oli täielikult fabritseeritud – on käesolevas töös empiirilise hindamise tehniline taristu olevat tegelikult olemas: hindamisskriptid, salvestatud JSON-vastused ja andmestiku kood on repositooriumis kontrollitavad.

Olulise positiivse erinevusena rõhutab töö ise korduvalt, et testkogu selgesõnaliselt sünteetiline ehk need ei ole päris üliõpilastööde katkendid, vaid Claude Opus 4.7 genereerisin need ise (API-päringud ja vastused ning nende analüüs on kõik päris).

5.10.4 Vorm, viited ja keele kvaliteet

Viidete loendis on 32 unikaalset allikat, mille hulgas kõik kontrollitavad allikad (Vaswani jt 2017 Attention Is All You Need, Brown jt 2020 GPT-3, Wei jt 2022 emergent abilities, Ouyang jt 2022 RLHF, Tanvir jt 2021 EstBERT, Kuulmets jt 2024–2025 Llammas-i tööd, Cohen 1960, Krippendorff 2011 jt) on autorite, pealkirjade ja avaldamisaastate poolest korrektsed. Üks viitamisviga siiski esines: Tartu Ülikooli tehisintellekti-teemalise juhendi puhul vastas sisu viidatud allikale, kuid URL oli vale või aegunud. Erinevalt Gemini 3.1 Pro tööst (alapeatükk ??) ei tuvastatud fabritseeritud autoriloendeid ning erinevalt Sonnet 4.6 tööst (alapeatükk ??) ei kombineeritud erinevate artiklite metaandmeid.

Keeleline kvaliteet on iteratiivses seansis selgelt parem kui ühe viiba kombinatsioonidel: 57 lehekülje peale tuvastas autor üksikuid kirjavigu. See on võrreldav kõige täpsema ühe viiba tulemusega (GPT-5.4 + Codex, 0,06 viga lehekülje kohta, vt tabel ??). Akadeemiline stiil on järjepidevalt umbisikuline ning terminoloogia (mudel, viip, kontekstiaken, kuldstandard, viitamisvajadus, saagis) on kogu töö ulatuses ühtlane.

5.10.5 Juhtumi tõlgendus

Käesolev juhtumiuuring näitab, et kui kasutaja võtab aktiivse rolli ja iteratiivne tööseanss kestab ühe tööpäeva, on tipptasemel mudeli (Opus 4.7) ning failipõhise agentse tööriista (Claude Code) abil võimalik genereerida lõputöö, mis (1) sisaldab tegelikku, kompileeritavat lähtekoodi, mitte ainult selle kirjeldust, (2) deklareerib selgesõnaliselt enda TI-kasutuse ja piirangud ning (3) hoiab keelelise ja stiililise ühtluse 57 lehekülje ulatuses.

Praktilise järeldusena täiendab käesolev juhtum peatükis ?? antud soovitusi: kõige usaldusväärsem tulemus eestikeelse informaatika lõputöö genereerimisel saavutatakse mitte ühe pika viiba, vaid lühematest sammudest koosneva juhitud iteratsiooni kaudu, kus kasutaja kontrollib iga vahetulemust, suunab teemavalikut ja palub vajadusel mudelilt konkreetseid täiendusi. Ka selle töövoos juures jääb empiiriliste väidete ja viidete sõltumatu kontroll endiselt inimese ülesandeks.

6. Käesoleva bakalaureusetöö kirjutamise töövoog

Peatükis ?? kirjeldatud eksperiment uuris ühe kasutajaviibaga (*single-prompt*) tervikliku töö genereerimist. Käesolev bakalaureusetöö ise ei ole ühe viiba tulemus: selline lähenemine ei vastaks akadeemilise aususe põhimõtetele ega annaks ka soovitud kvaliteeti. Selle asemel kasutati etapiviisilist, inimese juhitud töövoogu, mis järgib peatükis ?? esitatud soovitusi. Käesolev peatükk kirjeldab selle töövoogu konkreetseid samme, kasutatud tööriistu, autori ja TI rollijaotust ning saadud praktilisi kogemusi, et pakkuda läbipaistvat ülevaadet sellest, kuidas TI-d lõputöö kirjutamise protsessis vastutustundlikult rakendati.

6.1 Kasutatud TI tööriist ja mudel

Käesoleva bakalaureusetöö kirjutamise käigus kasutati agentse TI tööriistana Anthropicu **Claude Code**'i – agentset kodeerimis- ja tekstiloomise tööriista, mis integreerub otse arenduskeskkondadesse nagu VS Code [41] ning saab erinevalt vestlusliidesepõhistest tööriistadest iseseisvalt lugeda ja kirjutada faile, käivitada käsurea kāske ning hallata projekti failisüsteemi. Tööriist töötas autori kohalikus arenduskeskkonnas (VS Code Windowsis) ning sellel oli ligipääs projektikaustale $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ -allikfailide, bibliograafia, jooniste ja kompileeritud PDF-i näol. Peamise mudelina kasutati Claude Opus 4.6 maksimaalse mõtlemisrežiimiga. Kirjutamiseks valiti seega Claude Code, mitte põhieksperimendis kasutatud Cowork (vt peatükk ??). Cowork on sama tootja lähedase ülesehitusega tööriist, kuid see on suunatud pigem vestluspõhisele ühe ülesande täitmisele ning oleks pikema iteratiivse toimetamise jaoks olnud ebaefektiivsem. Claude Code seevastu pakub tihedat lõimingut VS Code'i arenduskeskkonna ja Giti tööriistadega, mis sobib paremini paljudest sammudest koosneva iteratiivse töövooga.

Claude Code'i oli töö kirjutamise ajal võimalik kasutada nii Visual Studio Code'i laiendusena kui ka eraldiseisva tööluarakendusena. Autori praktilise kogemuse põhjal olid vastused tööluarakendust kasutades märgatavalt kiiremad kui VS Code'i laienduse kaudu – sama mudeli ja sama päringu puhul reageeris tööluarakendus tajutavalt kohesemalt, mis oli eriti märgatav pikemate parandusvoorude ja kompileerimistsüklite puhul. Seetõttu kasutati pikemateks parandusvoorudeks Claude Code'i tööluarakendust, samas kui VS Code'i laiendus jäi kasutusse siis, kui samas sessioonis oli vaja otse toimetada koodi või $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ -vorminduse üksikasju arenduskeskkonnas.

Lisaks Claude Code'ile kasutati töö kirjutamise ja hilisema kontrollimise käigus Visual Studio Code'i keskkonnas OpenAI ChatGPT Codexi laiendust [42]. Codexiga kasutati GPT-5.5 mudelit

peamiselt kirjavigade otsimiseks ja sõnastuse parandamiseks. Töö hilisemas toimetamisfaasis kasutati samaks otstarbeks ka Claude Opus 4.7 mudelit [43].

Täiendavalt kasutati järgmisi abivahendeid: Visual Studio Code'i töökeskkonda, Giti ja GitHubi versioonihalduseks, TeX Live'i koos `latexmk`, `lualatex` ja `biber` tööriistadega $\LaTeX$ -i kompileerimiseks, töö algfaasis Overleafi ning Zotero ekspordikirjeid BibTeX-kirjete koostamisel.

6.2 Etapp 1: algne ühe kasutajaviibaga katse sisukorra kavandamiseks

Töö algetapis tehti sama ühe kasutajaviibaga katse, mida rakendati põhieksperimendis, et kaardistada võimalikku struktuuri ja teemade jaotust. Katse väljundit kasutati üksnes kavandamise abina: see aitas näha, milliseid peatükke mudel ise oluliseks peab, kuid peatükid kirjutas autor hiljem uuesti, tuginedes loetud kirjandusele ja eksperimendi tulemustele.

6.3 Etapp 2: iteratiivne kirjutamine ja toimetamine


Pärast esialgset kaardistust mindi üle iteratiivsele kirjutamisele, kus autor hoidis sisulist kontrolli ja TI tööriist tegutses keelelise ning vormistusliku abivahendina. Iteratsiooni üldised sammud olid järgmised.

1. **Autori sisuline kirjutamine ja eksperimendi läbiviimine.** Sisulised otsused, uurimisküsimuste sõnastus, eksperimendi disain, nelja genereeritud tervikliku töö hindamine, kvantitatiivsete mõõtmiste lõplik kinnitamine (kirjavigade loendus, viidete analüüs, anglitsismide loendus, esimese isiku asesõnade loendus) ja tulemuste tõlgendamine jäid autori vastutusele.
2. **Peatüki mustandi koostamine.** Iga peatüki esimese versiooni kirjutas autor käsitsi, tuginedes loetud kirjandusele ja eksperimendi tulemustele. Sellega tagati, et argumentatsiooni loogika ja peamised väited lähtuvad autori enda mõttekäigust.
3. **Manuaalne ülevaatus.** Autor luges iga peatüki kriitiliselt üle, tuvastas probleemid (kohmakad laused, ebatäpsed väited, numbriliste andmete ebakõlad, puuduvad viited, korduvused) ja märkis kohad, mida tuleb parandada.
4. **Konkreetsed parandusepalved TI-le.** Autor palus agentsel TI tööriistal teha konkreetseid, kitsalt piiritletud parandusi: tükeldada liiga pikki lauseid, ühtlustada lauseehitust, kontrollida viidete formaati ja järjekorda ning parandada $\LaTeX$ -vormistust. Töö hilisemas faasis lasti käesolev töö mitmel keelemudelil üle vaadata, et leida kirja- ja vormistusvigu.

5. **Autori otsus iga muudatuse kohta.** TI soovitatud muudatused vaatas autor enne vastuvõtmist üle. Eriti jälgiti seda, et TI ei lisaks uusi faktiväiteid, mida autor ei saaks allikast kinnitada.

6. **Korduv iteratsioon.** Samme 3–5 korrati iga peatüki puhul mitu korda, kuni tekst vastas soovitud kvaliteedile. Keskmiselt läbis iga peatükk mitu selget redaktsioonivooru.

Iteratiivne tsükkel oli aluseks iga peatüki valmimisele ning hoidis autori sisulise kirjutamise ja TI keelelise toimetamise selgelt eraldi etappidena. Üldvaade töövoog etappidest ja autori-TI rollijaotusest iga sammu juures on esitatud joonisel ??.



Joonis 3. Käesoleva töö kirjutamise iteratiivne töövoog. Sisuline kirjutamine ja otsused jäid autorile (sinine), TI tööriist täitis piiritletud abistavaid samme (roheline), iga muudatus läbis autori ülevaatus (oranž) ning kõik muudatused dokumenteeriti versioonihalduses (punane).

Eraldi väljakutse oli sellise töövoog puhul allikate kogumine ja kontrollimine, mida käsitleb järgmine alapeatükk.

6.4 Allikate otsimine ja bibliograafia haldamine

Allikate kogumine ja kontrollimine toimus teadlikult eraldiseisva töövoona, et vältida põhieksperimendis täheldatud hallutsineeritud viidete probleemi (vt peatükk ??). TI-le ei delegeeritud viidete “välja mõtlemist”, vaid allikatöö järgis järgmist distsipliini.

- **Allikate otsimine toimus inimese juhtimisel.** Autor otsis iga väite kinnitamiseks allikaid käsitsi Google Scholaris, arXivis, ACL Anthology ja ACM Digital Library kaudu, eelistades eelretsenseeritud ajakirju, konverentsiartikleid ja mudelite ametlikke dokumentatsioonilehti.
- **Iga viide lisati BibTeX-faili käsitsi,** kasutades Zoteroist saadud ekspordikirjet või väljaandja veebilehelt saadud viitekirjet.
- **TI roll piirdus formaadi kontrolliga.** Claude Code'il paluti kontrollida, kas kõik tekstis esinevad `\cite{}` võtmed leiduvad BibTeX-failis, kas BibTeX-kirjed on süntaktiliselt korrektsed ja kas välju (`url`, `doi`, `howpublished`) on täidetud ühtselt.

Kirjeldatud töövoogu tulemusena sisaldab käesoleva töö bibliograafia vaid olemasolevaid ja kontrollitud allikaid, erinevalt põhieksperimendi genereeritud töödest, kus 0–22% viidetest olid hallutsineeritud (kõige sagedamini väljamõeldud autorid või kahest eri paberist kombineeritud metaandmed).

6.5 Kvantitatiivse analüüsi ja andmete kogumise töövoog

Peatükkides ??–?? esitatud arvulised tulemused (keeles- ja kirjavigade arv, viidete arv, anglitsismide arv, esimese isiku asesõnade arv) koguti järgmise protseduuri alusel.

1. **PDF-ist teksti ekstraheerimine.** Iga genereeritud tervikliku töö PDF-fail (vt lisa ??) muudeti tekstiks, jättes välja tiitellehe ja kirjanduse loendi juhtudel, kus see oli metoodiliselt põhjendatud.
2. **Automaatne eelotsing TI abiga.** Claude Code'il paluti otsida eraldatud tekstist konkreetseid mustreid: tõenäolised kirjavead, ülakomaga võõrsõnad (`[a-zA-Z]+'[a-zA-Zöäöü]`), tüüpilised arvutiteaduse ingliskeelsed terminid (*prompt*, *pipeline*, *benchmark*, *over-reliance* jt) ning esimese isiku asesõnad. Iga leid esitati autorile koos konteksti reaga.
3. **Inimese lõplik otsus iga leiu kohta.** Autor otsustas iga TI tuvastatud kandidaadi kohta eraldi, kas tegemist on tõepoolest kirjaveaga, anglitsismiga või esimese isiku asesõnaga, või näiteks kontekstis sobiva tsitaadi või pärisnimega. See kaheetapiline lähenemine (masin

tuvastab kandidaadid, inimene kinnitab) vähendas nii väärnegatiivide kui ka väärpositiivide hulka võrreldes puhtalt käsitsi loendusega. Lisaks vaatas autor käsitsi kiirelt üle kõik tekstid, et leida TI poolt märkamata vead.

Kirjeldatud tööjaotus vähendas analüüsile kulunud aega, kuid säilitas autori piisava kontrolli iga arvu üle, mida töös esitatakse.

6.6 Kompileerimine, vormistuse kontroll ja kvaliteedi hindamine

L^AT_EX-töös tähendab kirjutamine pidevat kompileerimist ning vigade ja hoiatuste lahendamist. Käesoleva töö puhul seati sisse järgmine kompileerimistsükkel, mis toimis kogu kirjutamise jooksul.

- Kohalik kompileerimine toimus `latexmk`-i abil, mis käivitas `lualatex`-i (vt `.latexmkrc` repositooriumi juurkaustas); bibliograafia koostamiseks kasutati `biber`it.
- Kompileerimisvigade (nt tabelite üleulatumine lehekülje piiridest, lahtiste rühmade ebakõla, puuduvad `\cite`-võtmed) diagnostika tehti valdavalt koos Claude Code'iga – autor andis tööriistale `thesis.log` faili sisu või vigaste ridade väljavõtte ja palus parandust. Muudatus rakendati failile alles siis, kui autor oli selle üle vaadanud.
- Kvaliteedi hindamiseks vaadati iga olulisema muudatuse järel kompileeritud PDF üle, pöörates tähelepanu jooniste paigutusele ning ristviidete (`\ref`) töötamisele.

Kompileerimisvigade parandamine oli üks valdkond, kus TI pakkus väga kõrgeid produktiivsuse kasvu – peenete L^AT_EX vigade otsimine lahendati sageli mõne minuti või sekundiga, kui logifail või weakood anti mudelile analüüsimiseks.

6.7 Versioonihaldus GitHubi abil

Kogu kirjutamisprotsessi jooksul hoiti lähtefailid GitHubi repositooriumis (v.a. algusfaasis), mis on tehtud avalikuks aadressil https://github.com/UkuRenekKronbergs/bakalaureusetoo_isiklik. Versioonihalduse keskne väärtus TI-toetatud kirjutamise kontekstis oli võimalus iga TI-põhise muudatuse järel vaadata `git diff` väljundit ja kontrollida täpselt, mida agentne tööriist muutis. See tegi muudatused läbipaistvaks ja võimaldas vajadusel soovimatuid tegevusi tagasi pöörata.

6.8 Rollijaotus autori ja TI vahel

Töövoo läbipaistvuse huvides on tabelis ?? esitatud, millised kirjutamise ülesanded tegi autor ja millistel täitis TI abistavat rolli. Piiritlemisel lähtuti põhimõttest, et iga sisulise väite ja iga

tsiteeritud allika eest vastutab autor ning TI saab osaleda üksnes nendes sammudes, mille tulemust autor ise hindab ja kinnitab.

Tabel 9. Autori ja TI rollijaotus käesoleva töö kirjutamisel

Ülesanne	Autor	TI tööriistad
Teema valik ja uurimisküsimuste sõnastus	Täielik	–
Eksperimendi disain ja läbiviimine	Täielik	–
Kirjanduse lugemine ja sünteesimine	Täielik	–
Peatüki mustandi kirjutamine	Põhiautor	Üksikute lõikude sõnastusettepanekud
Allikate otsimine ja valimine	Täielik	–
Viidete sisuline kontroll	Täielik	–
BibTeX-kirjete süntaksi kontroll	Lõplik otsus	Automaatne kontroll
Kirjavigade otsimine ja parandamine	Lõplik otsus	Kandidaatide tuvastamine
Lauseehituse ja stiili ühtlustamine	Lõplik otsus	Ettepanekud
L ^A T _E X kompileerimisvigade diagnoosimine	Lõplik otsus	Põhjuse analüüs
Tabelite ja jooniste vormistus	Lõplik otsus	Vormingu ettepanekud
Kvantitatiivsete tulemuste tõlgendamine	Täielik	–
Järelduste ja soovitude sõnastamine	Täielik	Sõnastusettepanekud

Tabelist nähtub, et sisulist vastutust nõudvad ülesanded (teemavalik, eksperimendi disain, allikate valik, tulemuste tõlgendamine, järeldused) jäid täielikult autori kanda. TI roll piirdus rutiinsete, madala sisulise riskiga sammudega, kus iga ettepanek läbis enne rakendamist autori ülevaatuse.

6.9 Piirangud ja saadud kogemused

Iteratiivne TI-toetatud kirjutamise töövoog tõi esile ka mitmeid praktilisi piiranguid, mida tasub tulevastel üliõpilastel arvestada.

- **Kontekstiakna täitumine pikemate sessioonide jooksul** tingis vajaduse tööseansse korrapäraselt tihendada või uue teha. Pikema mustandi puhul osutus mõistlikuks jagada ülesanne peatükipõhisteks sessioonideks.

- **TI kalduvus “parandada” õiget teksti.** Mõnel juhul palus autor parandada ühte konkreetset viga, kuid tööriist muutis samal ajal ka ümbritsevat korrektset teksti. GitHubi `git diff` käsk oli hädavajalik, et selliseid soovimatuid muudatusi tuvastada ja vajadusel tagasi pöörata.
- **Eestikeelsete erisõnade ja terminite käsitus.** Keeleteaduslikult keerulised sõnad (nt liitsõnade silbitus või harvemad käändelõpud) vajasisid autori eraldi tähelepanu, kuna ilmnesisid kohati samad terminoloogilised vead, mida põhieksperimendis täheldati ka teistes mudelites..
- **Kulud.** TI-teenuste tellimused moodustasid üliõpilase eelarves tuntava, kuid professionaalse toimetamise teenusega võrreldes siiski väiksema kulu (vt peatükk ??). Läbipaistvuse huvides tuleb märkida, et autor kulutas kogu uurimisperioodi jooksul erinevate TI-teenuste tellimustele ligikaudu 360 € oma vahendeid. Nimetatud summa kattis nii põhieksperimendi läbiviimist, käesoleva töö kirjutamise abivahendeid kui ka peatükis ?? kirjeldatud iteratiivset juhtumiuuringut Claude Opus 4.7 ja Claude Code’iga.

Kokkuvõttes osutus inimese juhitud iteratiivne töövoog koos agentse TI tööriistaga praktiliselt sobivaks ka piiratud, eeldusel et TI tööriistu kasutatakse selgelt piiritletud abivahenditena, iga sisuline väide ja viide jääb autori vastutusele ning versioonihaldus dokumenteerib läbipaistvalt iga TI-põhise muudatuse. Käesoleva töövoog põhjal tehtud üldisemad tähelepanekud ja praktilised soovitused on koondatud peatükki ??.

7. Arutelu

Käesolev peatükk käsitleb eksperimendi tulemusi, analüüsib TI kasutamise praktilisi pooli ja piiranguid ning annab soovitusi.

7.1 TI tugevused lõputöö kirjutamisel

Experimendi tulemused kinnitavad, et kaasaegsed TI mudelid koos agentsete tööriistadega suudavad pakkuda märkimisväärset abi lõputöö kirjutamise protsessis. Käesoleva uurimuse katsetes demonstreeris Claude Opus 4.6 + Coworki kombinatsioon eriti veenvalt, et tipptasemel mudel koos agentse tööriistaga suudab genereerida tervikliku 61-leheküljelise eestikeelse lõputöö isegi ühe kasutajaviibaga. Peatükis ?? esitatud iteratiivne juhtumiuuring uuema mudeliga Claude Opus 4.7 + Claude Code näitas omakorda, et kui kasutaja juhendamine on aktiivne ja seanss kestab ühe tööpäeva, tõuseb saavutatav kvaliteet märgatavalt. Valminud 57-leheküljeline töö sisaldas tegelikku, kompileeritavat Pythoni ja TypeScripti lähtekoodi, 32 kontrollitavat viidet. Peamised tugevused jagunevad järgmiselt.

Struktureerimine ja kavandamine. TI mudelid on eriti tugevad teksti struktureerimisel. Kõik neli testitud kombinatsiooni (arvestades GPT-5.4 Codex-laienduse kaudu saadud tulemust) suutsid luua loogilise ja akadeemilistele nõuetele vastava peatükkide jaotuse ainuüksi ühe kasutajaviibaga. Eriti kasulik on TI kasutamine töö algfaasis, kui üliõpilane vajab abi sisukorra ja peatükkide ülesehituse kavandamisel. Mudelid suudavad vaid minimaalse juhise põhjal luua detailse sisukorra koos soovitusliku leheküljemahuga iga peatüki jaoks.

Mustandi loomine. TI suudab genereerida tekstimustandeid, mis on piisavalt hea kvaliteediga, et neid edasi töödelda. See kiirendab kirjutamisprotsessi oluliselt, kuna üliõpilane ei pea alustama tühjalt lehelt, vaid saab toimetada ja täiendada olemasolevat teksti.

Keeleline toimetamine. Kõik neli mudelit suudavad keelelist toimetamist toetada – parandada grammatikavigu, lauseehitust ja ühtlustada stiili, kuid täpsus erineb mudeliti. See on eriti väärtuslik eesti keele kontekstis, kus spetsiifilisi akadeemilise toimetamise teenuseid on vähe.

L^AT_EX-vormindamine. Oluline praktiline eelis on mudelite võimekus genereerida teksti otse L^AT_EX-vormingus, mis hõlmab korrektset viitamissüntaksit, tabeleid, jooniste viiteid ja matemaatilisi valemeid. See säästab üliõpilasele märkimisväärset vormistusaega. Võrdluseks, Microsoft Wordi puhul peab üliõpilane vormistuse – stiilid, ristviited, pealkirjade numeratsioon ja bibliograafia – enamasti käsitsi seadistama.

7.2 TI puudujäägid ja piirangud

Vaatamata edusammudele on TI mudelitel lõputöö kirjutamise kontekstis endiselt olulised puudujäägid. Tulemuste tõlgendamisel tuleb eriti arvestada kolme metoodilist piirangut: eksperimendis võrreldi *mudeli ja agentse tööriista kombinatsioone*, mitte mudeleid isoleeritult; iga kombinatsiooni kohta tehti vaid üks jook; ning eksplitsiitset kontrollrühma ei kasutatud. Puudus nii inimkirjutatud lõputöö võrdluspunkt kui ka mudelite mitteagentne baasväljund (peale GPT-5.4 vestlusliidese erandi katkend). Süstemaatiline hinnang nõuaks iga kombinatsiooni kohta mitut kordusjooksu, suuremat valimit ja inimkirjutatud lõputöö kontrollvõrdlust.

Viidete usaldusväärsus. Üks tõsisemaid probleeme on viidete hallutsineerimine, kuid katsetulemused näitavad, et hallutsineerimismäärad varieeruvad mudelite vahel oluliselt. Käesolevas eksperimendis kontrollis töö autor iga viidet käsitsi, et veenduda, kas allikas tegelikult eksisteerib ning kas pealkiri, autorid, väljaandmise aasta ja URL/DOI vastavad tegelikkusele. Tulemused olid järgmised: GPT-5.4 + Codex 0% (kõik 22 viidet täielikult korrektsed), Opus 4.6 + Cwork 6% (35-st 2 viidet väikese metaandmete veaga), Gemini 3.1 Pro + Antigravity 11% (9-st 1 viide vale autoriga) ning Sonnet 4.6 + Cwork 22% (23-st 5 viidet väljamõeldud autoriloendiga). Sonnet 4.6 hallutsinatsioonide muster oli tähelepanuväärne – artiklite pealkirjad ja arXiv-identifikaatorid olid valdavalt korrektsed, kuid mudel “täitis” autoriloendeid väljamõeldud nimedega või kombineeris kahe eri artikli metaandmed (näiteks viide “JITBot” Pornprasit ja Tantithamthavorn 2022, kus tegelikult oli paber “JITLine” MSR 2021 või JITBot ASE 2020 hoopis teiste autoritega). Need tulemused on kooskõlas varasemate uurimustega: Chelli jt [44] tuvastasid GPT-4 hallutsinatsioonimääraks 28,6%; Mugaanyi jt [9] leidsid, et DOI-de täpsus on valdkonniti väga erinev (loodusteadustes 32,7% vs humanitaarteadustes 8,5%), mis viitab sellele, et arvutiteaduse valdkonnas võivad tulemused olla mõnevõrra paremad. Kim jt [10] on näidanud, et hallutsinatsioonid on eriti levinud väiksemate keelte kontekstis. Iga TI-genereeritud viidet peab seega kontrollima inimene – ka madala üldise hallutsinatsioonimääraga mudelite puhul, sest pealkirja olemasolu ei tähenda, et autorid või muud metaandmed oleksid samuti korrektsed.

Sisuline sügavus. TI-genereeritud tekstid kipuvad olema pealiskaudsed. Mudelid kordavad üldtuntud seisukohti, kuid ei suuda luua originaalset analüüsi ega teha uudseid järeldusi. See on eriti problemaatiline tulemuste arutelu puhul, kus eeldatakse, et autor demonstreerib kriitilist mõtlemist ja seostab tulemused laiemaga kontekstiga.

Eesti keele tehniline terminoloogia. Kuigi mudelite eesti keele oskus on oluliselt paranenud, esineb endiselt probleeme tehnilise terminoloogiaga. Mudelid kasutavad kohati ebaühtlast

terminoloogiat (vahetavad eesti- ja ingliskeelsete terminite vahel) ning mõnikord loovad ebatäpseid termineid. Näiteks kasutati sõna “treenima” asemel “koolitama”, mis ei vasta arvutiteaduse valdkonnas juurdunud eestikeelsele terminoloogiale. Barbu jt [45] on samuti täheldanud, et keelemudelid vajavad eesti keele spetsiifika jaoks täiendavat kohandamist, mis viitab laiemale probleemile väikeste keelte tehniliste kasutusjuhtude puhul.

Kontekstiakna piirangud. Kuigi kontekstiaknad on oluliselt suurenenud, seavad need pikemate tööde puhul endiselt praktilisi piire. 25-leheküljelise bakalaureusetöö tekst (ligikaudu 80 000–100 000 tähemärki ehk 40 000–50 000 tokenit) mahub küll kontekstiaknasse, kuid kui lisada juhendid, näidistööd ja varem genereeritud osad, on konteksti efektiivne haldamine endiselt kriitiline.

Juhiste järgimise ebaühtlus ning liidese ja agentsete tööriistade mõju. Peatükis ?? kirjeldatud tulemused näitavad, et sama mudel võib eri liideses käituda sisuliselt erinevalt. GPT-5.4 vestlusliidese keeldumine ja Codex-laienduse kaudu õnnestunud failipõhine genereerimine viitavad sellele, et väljundit ei määra ainult alusmudel, vaid ka süsteemijuhised, ohutuspoliitika ja töövoo ülesehitus. Bianchi jt [46] kirjeldatud “liialdatud ohutuskäitumine” aitab seda nähtust tõlgendada: liides võib uurimusliku ülesande tõlgendada akadeemilise väärkasutuse riskina. Agentne tööriist ei tähenda seejuures ohutuspriirangutest möödumist, vaid teistsugust ülesande konteksti, kus töö jaotub väiksemateks faili- ja kompileerimispõhisteks sammudeks.

Sama oluline on eristada vormilist veenvust sisulisest usaldusväärsusest. Gemini 3.1 Pro + Antigravity töö näitas kõige selgemalt, et korrektselt vormistatud ja statistiliste tabelitega tekst võib sisaldada täielikult väljamõeldud empiirikat. Opus 4.6 + Cwork andis selles katses tugevama ja tehniliselt sügavama väljundi, kuid ka seal tuli kontrollimata testitulemusi ja viiteid käsitleda riskina. Seega ei piisa agentse tööriista edukast $\text{\LaTeX}$ -vormistusest – sisuline vastutus, andmete olemasolu ja viidete kontrollimine peavad jääma inimese kanda.

7.3 Hinnakujundus ja majanduslik teostatavus

Kuluarvestus piirdub peatükis ?? kirjeldatud iteratiivse juhtumiuuringuga (Claude Opus 4.7 + Claude Code), kuna ainult selle töövoo tokenikasutust mõõdeti. Põhieksperimendi nelja ühe viiba kombinatsiooni tokenitarvet eraldi ei jälgitud, mistõttu nende kohta konkreetseid kuluhinnanguid ei saa esitada. Ametlikud baashinnakirjad on esitatud peatükis ?? (tabel ??).

Iteratiivse juhtumiuuringu mõõdetud tokenikasutus jagunes järgmiselt. Claude Code (Opus 4.7) tööriistas registreeriti seansi vältel ligikaudu 5,7 tuhat vahemälust välja jäänud sisendtokenit, 8,15

Tabel 10. Iteratiivse juhtumiuuringu (Opus 4.7 + Claude Code) hüpoteetiline pay-as-you-go API-kulu komponentide kaupa, kui kuutellimuse asemel oleks kasutatud ametlikku API-d (EUR, koos 24% käibemaksuga)

Komponent	API-kulu
Claude Code (Opus 4.7) – põhigenereerimine	322 €
Codex (GPT-5.5) – keelekorrekatuur ja sõnastuse ühtlustamine	46 €
Hindamise 80 API-päringut	4 €
Kokku	371 €

miljonit vahemälu loomise tokenit, 403,0 miljonit vahemälust loetud sisendtokenit ja 2,03 miljonit väljundtokenit. Anthropicu Opus 4.7 standardhinnakirja järgi (sisend 5 USD/MTok, vahemälu kirjutamine 6,25 USD/MTok, vahemälust lugemine 0,50 USD/MTok, väljund 25 USD/MTok) oleks see vastanud ligikaudu 303 USD-le ehk käibemaksuga 322 €-le. Paralleelselt kasutati keelekorrektuuri ja sõnastuse ühtlustamise jaoks OpenAI ChatGPT Codexi laienduse kaudu GPT-5.5 mudelit kogumahas 38,7 miljonit sisendtokenit (millest 35,7 M oli vahemälust loetud) ja 0,33 M väljundtokenit, mille API-kulu OpenAI GPT-5.5 lühikese konteksti hinnakirja järgi (sisend 5 USD/MTok, vahemälust loetud sisend 0,50 USD/MTok, väljund 30 USD/MTok) oleks olnud ligikaudu 43 USD ehk käibemaksuga 46 €. Lisaks tehti peatükis ?? kirjeldatud 80 hindamis-API-päringut (kogukulu 3,88 USD ehk umbes 4 € käibemaksuga). Komponentid kokku liites oleks kogu iteratiivse juhtumiuuringu API-kulu olnud umbes 350 USD ehk Eestis ligikaudu 371 € käibemaksuga. Suur osa sellest summast tuleneb vahemälu korduvlugemisest agentse failipõhise töövoo vältel, mistõttu sama kasutuse katmine kuutellimuse raames jääb üliõpilase jaoks sadu eurosid soodsamaks.

Kuutellimused muudavad kulupildi oluliselt teistsuguseks: ChatGPT Plus ja Claude Pro maksavad Eesti regioonis ligikaudu 22–23 € kuus (koos käibemaksuga), Google AI Pro 21,99 € kuus (vt tabel ??). Praktikas saab üliõpilane teha põhilise töö ühe kuni kahe kuu tellimuse hinnaga, kui mahupiiranguid ei ületata (ei tehta väga pikki sessioone järjest). Ka iteratiivne juhtumiuuring tehti käesolevas töös olemasolevate Claude Max 5× ja ChatGPT Pro kuutellimuste raames, mistõttu tegelik täiendav kulu oli marginaalne: 3,30 € kulus Claude Opus 4.7 ja GPT-5.5 mudelitele tehtud API-päringute eest, et saada iteratiivselt genereeritud lõputöösse

reaalseid andmeid. Kokkuvõttes näitab iteratiivse juhtumiuuringu API-kulu (ligikaudu 371 €), et kuutellimus on selles olukorras oluliselt soodsam kui API-põhine kasutus.

7.4 Eesti keele korrektuur ja toimetamine

Eraldi väärib tähelepanu TI mudelite kasutamine eestikeelse teksti korrektuuri ja toimetamise tööriistana. See on üks valdkondi, kus TI pakub kõige suuremat praktilist väärtust.

Järgmised hinnangud põhinevad autori mitteformaalsetel katsetel, mis jäid põhieksperimenti raamistikust välja ning mille täpsem metoodika vajab edaspidi süstemaatilist vormistamist. Need on esitatud suunavate tähelepanekutena.

Grammatikakontroll. Kõik neli mudelit suudavad tuvastada ja parandada enamiku grammatikavigadest eesti keeles. GPT-5.4 oli kõige täpsem, tuvastades enamiku sisestatud vigadest; Opus 4.6 ja Sonnet 4.6 tuvastasid palju, kuid jätsid osa keerulisemaid vigu märkamata; Gemini 3.1 Pro tulemus oli nõrgim, jättes tuvastamata ka lihtsamaid morfoloogiavigu.

Stiilikontroll. Mudelid suudavad hinnata teksti vastavust akadeemilisele stiilile ja pakkuda parandusettepanekuid. See hõlmab liiga vaba keele tuvastamist, passiivi kasutamise soovitusi ja liigsete korduste märkamist.

Terminoloogiakontroll. Mudelid suudavad kontrollida tehnilise terminoloogia ühtlust ja korrektsust, kuid siin on täpsus oluliselt madalam kui grammatikakontrollis. Terminoloogilist kontrolli ei saa täielikult TI-le delegeerida – valdkonnaspetsiifiline inimekspertiis on endiselt vajalik.

7.5 Soovitused TI tööriista valikuks

Eksperimenti ja iteratiivse juhtumiuuringu tulemuste ning praktiliste kogemuste põhjal saab anda järgmised soovitused.

Parim tulemus: iteratiivne töövoog Claude Opus 4.7 koos Claude Code'iga. Peatükis ?? kirjeldatud juhtumiuuring näitas, et kui kasutaja võtab aktiivse rolli ja seanss kestab ühe tööpäeva (ligikaudu kaheksa tundi), suudab Opus 4.7 + Claude Code'i kombinatsioon genereerida 57-leheküljelise lõputöö koos tegeliku kompileeritava Pythoni ja TypeScripti lähtekoodiga. Tulemus on ortograafilise täpsuse, viidete usaldusväärsuse ja sisulise terviklikkuse poolest mõõdetavalt parem kui kõigi nelja ühe viiba kombinatsiooni tulemus.

Ühe viibaga tugevaim üldtulemus: Claude Opus 4.6 koos Coworkiga. Käesolev eksperiment näitas, et ühe kasutajaviibaga genereerimisel eristus Claude Opus 4.6 + Coworki kombinatsioon

teistest olulisel määral terviklikkuse, akadeemilise stiili, tehnilise detailsuse ja sisulise sügavuse poolest, kuigi väikseim kirjavigade arv oli GPT-5.4 + Codexi väljundis. Peamine puudus on märgatavalt kõrgem hind. Kuna iga kombinatsiooni kohta tehti vaid üks jookss ja keelemudelid on mitteterministlikud, tuleb seda soovitus käsitada eksploratiivse viitena, mitte lõpliku üldhinnanguna.

Kombineeritud praktika. Iteratiivse juhtumiuuringu praktilise kogemuse põhjal tasub kaaluda tööjaotust mitme mudeli vahel: mahukamateks sisulisteks ja struktuurseteks ülesanneteks kasutada tugevaimat kättesaadavat arutlusmudelit (käesolevas töös Opus 4.7 koos Claude Code'iga), keelekorrektuuriks ja kirjavigade otsimiseks aga odavamad ja kiiremad mudelit (käesolevas töös GPT-5.5 Codexi laienduse kaudu).

Autori maksimaalne kuutellimuse soovitus: ChatGPT Plus ja Claude Max 5× paralleelselt. Üliõpilasele, kes soovib käesolevas töös kirjeldatud iteratiivset tööjaotust kahe pakkuja tugevamate mudelite vahel täismahus rakendada, soovitab autor kasutada paralleelselt ChatGPT Plusi (23 €/kuu) ja Claude Max 5× (106 €/kuu) tellimust ehk kokku 129 €/kuu (vt tabel ??). ChatGPT Plus annab piisava kasutuspiirangu korral ligipääsu GPT-5.5-le ja Codex-laiendusele keelekorrektuuri ning lühemate ülesannete jaoks. Claude Max 5× võimaldab Opus 4.7 ja Claude Code'i töövoo pikemaid sessioone, ilma et kvoodipiiranguid sageli ületataks. Töö autor ei kasutanud kordagi üle 60% Claude Max 5× sessioonilimiidist ega üle 15% ChatGPT Pro omast.

Autori minimaalne kuutellimuse soovitus: ChatGPT Plus ja Claude Pro. Piiratud eelarvega üliõpilasele piisab käesoleva uurimuse kogemuse põhjal paralleelsetest ChatGPT Plusi (23 €/kuu) ja Claude Pro (22 €/kuu) tellimustest ehk kokku 45 €/kuu (vt tabel ??). Selle kooslusega saab teha kogu põhilise iteratiivse kirjutamis- ja toimetamistöö, kuigi pikemate sessioonide jooksul võivad mahupiirangud ette tulla.

Kuutellimus on API-st oluliselt soodsam. Käesoleva töö hinnakujunduse võrdlus (vt peatükk ??) ja autori kasutuskogemus näitavad, et kuutellimusega töötamine on enamiku üliõpilaste jaoks API kasutamisest mitmekordselt odavam. Kuutellimus annab fikseeritud ja prognoositava kuukulu (käesoleva töö soovitatud koosluste vahemikus 45–129 €/kuu), samas kui sama mahuga iteratiivse töövoo katmine API kaudu võib maksta sõltuvalt mudelist ja konteksti pikkusest mitusada eurot ning eeldab pidevat kuluseiret.

7.6 Soovitused lõputöö genereerimiseks agentsete TI tööriistadega

Käesoleva uurimuse praktiliste kogemuste põhjal saab anda järgmised soovitused agentsete TI tööriistade kasutamiseks lõputöö genereerimisel.

7.6.1 Parimad praktikad

- **Kasuta võimaluse korral pikendatud mõtlemisrežiimi.** Pikendatud mõtlemisrežiim või muu sügavama arutluse seadistus (*extended thinking*) võib parandada keeruliste akadeemiliste tekstide kvaliteeti. Sügavam arutlus on eriti kasulik sissejuhatuse, metoodika ja arutelu peatükkide jaoks.
- **Anna konkreetseid juhiseid.** Mida konkreetsemad on juhised, seda parem on tulemus. Üldise palve “kirjuta sissejuhatus” asemel täpsusta töö maht ja peamised teemad.
- **Kontrolli viiteid alati.** Ükski TI mudel ei genereeri alati 100% korrektseid viiteid. Kontrolli iga viite olemasolu ja korrektsust käsitsi.
- **Ole oma tööga kursis.** TI on abivahend, mitte autor. Üliõpilane peab iga genereeritud lõigu sisuliselt üle vaatama ja vajadusel ümber kirjutama.
- **Kasuta keeruliste peatükkide jaoks tugevamat mudelit.** Keerukamate peatükkide, näiteks metoodika ja arutelu, genereerimiseks või põhjalikuks toimetamiseks tasub valida parajasti kättesaadav tugevam arutlusmudel. Lihtsamate korrektuuri- ja vormistusülesannete jaoks piisab sageli odavamast või kiiremast mudelist. Kuna mudeliperekonnad muutuvad kiiresti, tasub soovitusel rakendamisel kontrollida, millised keelemudelid on parajasti kättesaadavad.

TI ei korva üliõpilase sisulist tööd allikate, metoodika ja järelduste osas, kuid võimaldab korrektuuri- ja vormistustööd vähema mehaanilise töö ja ajakuluga teha.

7.7 Tööriistad, mida vältida

Lisaks põhieksperimendis osalenud nelja mudeli võrdlusele testis autor lühemate mitteformaalsete katsete raames ka mõningaid teisi tööriistu, mida lõputöö kirjutamise abivahendina ei saa soovitada. Järgmised hinnangud ei põhine käesoleva uurimuse formaalsel võrdlusel, vaid autori praktilisel kasutuskogemusel ning nende arendajate avalikul dokumentatsioonil.

Perplexity ei sobi mahukate kirjutamisülesannete põhitööriistaks. Perplexity on eelkõige TI-põhine otsingu- ja vastamissüsteem, mis sobib hästi üksikküsimuste, allikate esmase

leidmise ja lühikeste kokkuvõtete jaoks. Lõputöö tervikpeatükkide genereerimisel ilmnes aga piirang: Perplexity kasutuskogemus ei ole samaväärne alusmodeli otse kasutamisega. Perplexity ametlik API-dokumentatsioon eristab otsingukonteksti suurust mudeli kontekstiaknast: otsingukontekst määrab, kui palju veebist leitud infot päringusse kaasatakse, samas kui kontekstiaken määrab maksimaalse tokenite hulga, mida mudel ühe päringu käigus töödelda saab [47]. Perplexity Agent API toetab küll eri pakujate mudeleid [48], kuid otsingupõhine töövoog lisab otsingu, tsiteerimise, kulude ja päringu töötlemise piirangud. Autori katsetes veebiliidesega ei olnud võimalik pikemat töömustandit sama järjepidevalt kontekstis hoida nagu mudelite natiivsetes või failipõhistes agentsetes keskkondades. Ka DataStudioli ülevaade rõhutab, et Perplexity failide ja vestluste puhul ei lisata kogu materjali automaatselt vastuse koostamise hetkel mudeli konteksti, vaid süsteem valib ja lisab aktiivsesse päringusse ainult asjakohaseid lõike [49]. Sellisest valikulisest kontekstist tulenevalt võib pikema vestluse või suurema dokumendimaterjali korral kaduda osa varem kokkulepitud tingimustest, struktuurist või piirangutest. Kokkuvõttes sobib Perplexity hästi infootsinguks ja lühikeste küsimuste lahendamiseks, kuid mitte lõputöö genereerimise põhitööriistaks, kus on vaja mahukat, püsivat ja täpselt kontrollitavat projektikonteksti.

GitHub Copilot Pro ei sobi akadeemilise teksti genereerimiseks. GitHub Copilot Pro, mida Tartu Ülikool pakub üliõpilastele tasuta GitHub Educationi programmi kaudu, on mõeldud eelkõige koodi kirjutamise abivahendiks [50]. GitHubi enda dokumentatsiooni kohaselt on Copilot Chat mõeldud ainult kodeerimisega seotud päringutele ning juhiste piiramine kodeerimisülesannetega parandab mudeli väljundi kvaliteeti [51]. Lõputöö genereerimise kontekstis osutus kodeerimisele orienteeritud Copilot aga ebapiisavaks. Autori katsetes andsid Copiloti mudelid lühikesi ja pealiskaudseid vastuseid ning vältisid pikemate akadeemiliste tekstilõikude genereerimist. Nguyen ja Nadi [52] on oma empiirilises uurimuses näidanud, et Copiloti soovitusel on tähelepanekude pikkuse piirang, mis takistab pikema väljundi genereerimist, ning keerulisemate ülesannete korral langeb soovitude kvaliteet märgatavalt. Lisaks rakendab GitHub Copilotile päringupõhiseid limiite (*rate limits*), mis piiravad kasutamise intensiivsust [53]. Kokkuvõttes on tööriist optimeeritud lühikeste koodilõikude ja kooditäienduste jaoks, mitte terviklike akadeemiliste tekstide loomiseks. Eeltoodud piirangute tõttu ei saa GitHub Copilot Pro-d soovitada lõputöö kirjutamise abivahendina, hoolimata üliõpilastele tasuta kättesaadavusest.

7.8 Tulevikuväljavaated

TI mudelite ja nendega seotud tööriistade areng on kiire ning käesoleva töö tulemused peegeldavad 2025–2026. aasta seisuga. Lähitulevikus on tõenäoliselt olulised järgmised arengusuunad:

- **Eesti keele toe sihipärane parandamine** – eesti keele kvaliteedi paranemine ei sõltu ainult sellest, kui suur osa üldmudelite treeningandmetest on eestikeelne. Olulisemaks võivad osutuda kvaliteetsemad eestikeelsed terminibaasid, jätkutreenimine ja väikeste keelte jaoks kohandatud hindamismetoodikad. EstLLM-i projekti [5] tulemused näitavad, et spetsialiseeritud jätkutreenimine võib eesti keele kvaliteeti märkimisväärselt tõsta ka olemasolevates mudelites.
- **Agentsete akadeemiliste töövoogude levik** – sellised tööriistad nagu Claude Code, Cwork, Google Antigravity ja OpenAI ChatGPT Codex näitavad, et akadeemilise kirjutamise tugi liigub vestlusaknast üha enam projektipõhisesse keskkonda. Sellise töövoogu väärtus ei seisne ainult teksti genereerimises, vaid ka failide haldamises, $\text{L}^{\text{T}}\text{E}^{\text{X}}$ -koodi parandamises, kompileerimisvigade diagnoosimises ja viidete tehnilises kontrollis. Käesolev eksperiment näitas, et agentne töövoog parandas genereerimise kvaliteeti kõigi testitud mudelite puhul.
- **Konteksti haldamise paranemine** – kontekstiaknad võivad jätkuvalt suurened, kuid ainult suurem tokenite arv ei taga paremat akadeemilist tulemust. Sama oluline on see, kuidas tööriist valib, kokku võtab ja säilitab varasemaid tööosi, allikaid, juhendeid ja kasutaja parandusi. Seetõttu muutub tõenäoliselt olulisemaks projektimälu, otsingupõhise konteksti ja failipõhise töövoogu kvaliteet.
- **Valdkonnaspetsiifilised akadeemilised abivahendid** – lähiaastatel võib kasvada tööriistade hulk, mis on kohandatud konkreetsete erialade, viitamisstiilide, ülikoolide juhendite või keelte jaoks. Sellised süsteemid ei pea tingimata olema eraldi suured mudelid; sama eesmärgi võivad täita ka üldmudelid koos kontrollitud allikabaasi, terminiloendi, mallide ja automaatsete kvaliteedikontrollidega.
- **TI kasutamise läbipaistvuse integreerimine õppetöösse** – akadeemilised institutsioonid liiguvad tõenäoliselt pelgalt keelamise ja tuvastamise loogikalt TI kasutuse läbipaistva kirjeldamise ning hindamise suunas. See nõuab hindamismetoodikaid, mis keskenduvad

üliõpilase sisulisele panusele, allikakriitikale ja tööprotsessi dokumenteerimisele, mitte ainult lõpptulemuse vormilisele sarnasusele TI-genereeritud tekstiga.

Käesolev uurimus piirdus nelja mudeli ja kolme agentse tööriista võrdlusega 2025–2026. aasta seisuga. Arvestades TI valdkonna arengutempot, kus uusi mudeleid avaldatakse mitu korda aastas, tuleks sarnaseid teostatavusuuringuid korrata regulaarselt. See võimaldaks hinnata, kuidas eespool nimetatud arengud tegelikult realiseeruvad ja millised käesoleva töö järeldustest jäävad kehtima ka uuema põlvkonna mudelite puhul.

8. Kokkuvõte

Käesolev bakalaureusetöö uuris tehisintellekti (TI) rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Selleks võrreldi nelja suurt keelemudelit koos agentsete tööriistadega: Google Gemini 3.1 Pro koos Antigravityga, OpenAI GPT-5.4 koos ChatGPT Codexi Visual Studio Code'i laiendusega ning Anthropic Claude Sonnet 4.6 ja Claude Opus 4.6 koos Coworkiga. Kõigile kombinatsioonidele anti sama lühike eestikeelne viip, mis palus luua UniTartuCS malli kasutava tervikliku L^AT_EX-vormingus bakalaureusetöö ja valida ise informaatikaga seotud teema. Kuna iga kombinatsiooni kohta tehti üks jooks, tuleb tulemusi käsitleda eksploratiivse hinnanguna konkreetsetele mudel-tööriista paaridele, mitte lõpliku mudelite paremusjärjestusena.

Katse näitas, et agentsed tööriistad võimaldavad suurtel keelemudelitel luua vormilt terviklikke eestikeelseid akadeemilisi dokumente ka minimaalse juhendamisega. Kõik neli kombinatsiooni suutsid koostada bakalaureusetöö struktuuriga väljundi, kuid need erinesid märgatavalt mahu, keelelise täpsuse, viidete kontrollitavuse, sisulise sügavuse ja akadeemilise väärkasutuse riski poolest. Käesolevas lõputöös tehtud katsetes andis kõige terviklikuma ja tehniliselt detailsema tulemuse Claude Opus 4.6 + Cowork, samas kui GPT-5.4 + Codex eristus madalaima kirjavigade arvu ja täielikult kontrollitavate viidetega. Claude Sonnet 4.6 + Cowork oli praktiliselt tugev ja hinnalt taskukohasem valik, kuid selle viidetes esines enim metaandmete hallutsinatsioone. Gemini 3.1 Pro + Antigravity näitas kõige selgemalt, et vormiliselt usutav töö võib sisaldada täielikult fabritseeritud empiirilist osa. Põhieksperimenti täiendusena tehti eraldi iteratiivne juhtumiuuring uuema mudeliga Claude Opus 4.7 koos Claude Code'iga ühe tööpäeva (ligikaudu kaheksa tunni) jooksul (vt peatükk ??): tulemuseks oli reaalse andmetega 57-leheküljeline töö koos tegeliku Pythoni ja TypeScripti lähtekoodiga ning 32 kontrollitava viitega. See näitab, et aktiivse kasutajajuhendamise korral on iteratiivse töövoogu kvaliteet oluliselt parem kui ühe viiba kombinatsioonidel.

Üks olulisemaid järeldusi on, et tulemust ei määra ainult alusmudel, vaid ka liides ja agentne töövoog. GPT-5.4 tavapärane vestlusliides keeldus terviklikku lõputööd genereerimast ning pakkus selle asemel akadeemilise aususe piirangutega kooskõlas olevat teostatavusjuhendit. Sama mudel ChatGPT Codexi failipõhises töövoos genereeris aga tervikliku eestikeelse lõputöö. See näitab, et süsteemijuhised, ohutuspoliitika, faili ligipääs, kompileerimisvõimekus ja töövoogu ülesehitus mõjutavad väljundit vähemalt sama tugevalt kui mudeli üldine keeleline võimekus.

Kõige tõsisemad riskid olid viidete hallutsineerimine ja kontrollimata empiiriliste väidete esitamine. Genereeritud töödes esines olematuid või valede metaandmetega allikaid, väljamõeldud osalejaid, statistilisi tulemusi, testiraporteid ja auditeid. Eriti ohtlik on see, et sellised väited võivad olla vormiliselt väga veenvad: tabelid, p-väärtused, arhitektuurikirjeldused ja koodinäited jätavad mulje tehtud uurimusest ka siis, kui andmeid tegelikult ei eksisteeri. Seetõttu ei saa TI loodud akadeemilist teksti käsitleda usaldusväärse lõppversioonina enne, kui inimene on kontrollinud allikaid, metoodikat, andmeid, tulemusi ja järeldusi.

Antud töö kirjutamise kogemus kinnitas sama järeldust praktilisel tasandil. Käesolev bakalaureusetöö ei valminud ühe viibaga, vaid inimese juhitud iteratiivses töövoos: autor sõnastas uurimisküsimused, kavandas eksperimendi, viis selle läbi, kontrollis viiteid, kogus ja tõlgendas kvantitatiivsed tulemused ning tegi lõplikud sisulised otsused. TI tööriistu kasutati abistavalt peamiselt sõnastuse, keelelise korrektuuri, L^AT_EX-vormistuse, kompileerimisvigade diagnoosimise ja vigade otsimise jaoks. Versioonihaldus GitHubis osutus seejuures oluliseks kaitsemehhanismiks, sest iga TI-põhist muudatust sai diff'ina kontrollida ja vajadusel tagasi pöörata.

Majanduslikult on TI kasutamine bakalaureusetöö toetava tööriistana üliõpilase jaoks realistlik, eriti Sonnet-klassi mudelite ja kuutellimuste korral. Opus-klassi mudel andis selles katses küll tugevama üldtulemuse, kuid selle kasutamine on kallim. Kulu ei tohiks siiski olla peamine otsustuskriteerium. Olulisem on töövoog, kus mudelile antakse kitsalt piiritletud ülesandeid, olemasolevad allikad lisatakse käsitsi kontrollitud bibliograafiasse, muudatusi jälgitakse versioonihalduse abil ning empiirilisi tulemusi ei lasta mudelil iseseisvalt välja mõelda.

Uurimuse põhjal saab järeldada, et TI sobib lõputöö kirjutamisel abivahendiks, kuid mitte asendajaks ega iseseisvaks autoriks. TI tugevused on struktuuri kavandamine, mustandi loomine, keeleline toimetamine, L^AT_EX-vormindus ja tehniliste vigade kiire diagnoosimine. Inimese panus jääb asendamatuks uurimisküsimuste sõnastamisel, kirjanduse sisulisel mõtestamisel, metoodika kavandamisel, andmete ja viidete kontrollimisel ning originaalsete järelduste tegemisel. Vastutustundlik TI kasutamine ei tähenda töö delegeerimist mudelile, vaid tööprotsessi läbipaistvat ja kontrollitud täiendamist.

Edaspidine uurimistöö võiks keskenduda korduskatsetele, kus iga mudel-tööriista kombinatsiooni jooksutatakse mitu korda ning hinnatakse tulemuste varieeruvust. Samuti vajavad uurimist spetsialiseeritud akadeemilised TI tööriistad, eesti keelele kohandatud mudelid, RAG-süsteemide

mõju viidete kvaliteedile ning automaatsed kontrollimehhanismid, mis suudaksid tuvastada fabritseeritud empiirilisi väiteid.

Viited

- [1] Liang W., Zhang Y., Wu Z., Lepp H., Ji W., Zhao X., Cao H., Liu S., He S., Huang Z., Yang D., Potts C., Manning C. D. ja Zou J. Y. Mapping the Increasing Use of LLMs in Scientific Papers. *arXiv preprint arXiv:2404.01268* (2024). <https://arxiv.org/abs/2404.01268>.
- [2] Brown T., Mann B., Ryder N., Subbiah M., Kaplan J. D., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A. jt. Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems* 33 (2020), lk 1877–1901. <https://arxiv.org/abs/2005.14165>.
- [3] OpenAI. GPT-4 Technical Report. <https://arxiv.org/abs/2303.08774>. Viimati vaadatud: 15.02.2026. 2023.
- [4] Kuulmets H.-A., Purason T. ja Fišel M. How Well do LLMs Know Finno-Ugric Languages? A Systematic Assessment. *Proceedings of the Joint 25th Nordic Conference on Computational Linguistics and 11th Baltic Conference on Human Language Technologies (NoDaLiDa/Baltic-HLT 2025)*. 2025. <https://aclanthology.org/2025.nodalida-1.37/>.
- [5] Dorkin A., Purason T., Kalbaliyev E., Kuulmets H.-A., Ojastu M., Fišel M., Alumäe T., Aedmaa E., Kruusmaa K. ja Sirts K. EstLLM: Enhancing Estonian Capabilities in Multilingual LLMs via Continued Pretraining and Post-Training. *arXiv preprint arXiv:2603.02041* (2026). <https://arxiv.org/abs/2603.02041>.
- [6] Tartu Ülikool, Arvutiteaduse instituut. Tartu Ülikooli arvutiteaduse instituudis kaitstavate lõputööde nõuded ja hindamine. https://cs.ut.ee/sites/default/files/2026-02/2026_02_03_%20ATI_loputoode_nouded_ja_hindamiskriteeriumid.docx.pdf. Kinnitatud 03.02.2026; viimati vaadatud: 30.04.2026. 2026.
- [7] Lund B. D., Mannuru N. R., Teel Z. A., Lee T. H., Ortega N. J., Simmons S. ja Ward E. Student Perceptions of AI-Assisted Writing and Academic Integrity: Ethical Concerns, Academic Misconduct, and Use of Generative AI in Higher Education. *AI in Education* 1.1 (2025), lk 2. <https://doi.org/10.3390/aieduc1010002>.
- [8] Rodafinos A. The Integration of Generative AI Tools in Academic Writing: Implications for Student Research. *Social Education Research* 6.2 (2025), lk 250–258. <https://doi.org/10.37256/ser.6220256517>.
- [9] Mugaanyi J., Cai L., Cheng S., Lu C. ja Huang J. Evaluation of Large Language Model Performance and Reliability for Citations and References in Scholarly Writing: Cross-

- Disciplinary Study. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/52935>.
- [10] Kim E., Kipchumba F. ja Min S. Geographic Variation in LLM DOI Fabrication: Cross-Country Analysis of Citation Accuracy Across Four Large Language Models. *Publications* 13.4 (2025), lk 49. DOI: [10.3390/publications13040049](https://doi.org/10.3390/publications13040049). <https://doi.org/10.3390/publications13040049>.
 - [11] Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser Ł. ja Polosukhin I. Attention is All You Need. *Advances in Neural Information Processing Systems* 30 (2017), lk 5998–6008. <https://arxiv.org/abs/1706.03762>.
 - [12] Devlin J., Chang M.-W., Lee K. ja Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT* (2019), lk 4171–4186. <https://arxiv.org/abs/1810.04805>.
 - [13] Radford A., Wu J., Child R., Luan D., Amodei D. ja Sutskever I. Language Models are Unsupervised Multitask Learners. *OpenAI Blog* (2019). https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.
 - [14] Erelt M., Erelt T. ja Ross K. Eesti keele käsiraamat. Tallinn: Eesti Keele Sihtasutus, 2007. <https://arhiiv.eki.ee/books/ekk09/>.
 - [15] Common Crawl Foundation. Statistics of Common Crawl Monthly Archives: Distribution of Languages. <https://commoncrawl.github.io/cc-crawl-statistics/plots/languages>. Viimati vaadatud: 30.04.2026. 2026.
 - [16] Nguyen T., Nguyen C. V., Lai V. D., Man H., Ngo N. T., Deroncourt F., Rossi R. A. ja Nguyen T. H. CulturaX: A Cleaned, Enormous, and Multilingual Dataset for Large Language Models in 167 Languages. *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. 2024, lk 4226–4237. <https://aclanthology.org/2024.lrec-main.377>.
 - [17] Tanvir H., Kittask C., Eiche S. ja Sirts K. EstBERT: A Pretrained Language-Specific BERT for Estonian. *Proceedings of the 23rd Nordic Conference on Computational Linguistics (NoDaLiDa)*. 2021, lk 11–19. <https://aclanthology.org/2021.nodalida-main.2/>.
 - [18] Üstün A., Aryabumi V., Yong Z., Ko W.-Y., D'souza D., Onilude G., Bhandari N., Singh S., Ooi H.-L., Kayid A. jt. Aya Model: An Instruction Finetuned Open-Access Multilingual Language Model. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational

- Linguistics, 2024, lk 15894–15939. DOI: [10.18653/v1/2024.acl-long.845](https://doi.org/10.18653/v1/2024.acl-long.845). <https://aclanthology.org/2024.acl-long.845/>.
- [19] Kiil A. Suurte keelemudelite võrdlev analüüs Eesti bioloogiaolümpiaadide küsimuste põhjal. Magistritöö. Tartu Ülikool, Arvutiteaduse instituut, 2025. <https://hdl.handle.net/10062/117055>.
- [20] Tartu Ülikool, Arvutiteaduse instituut. Selgitused tehisaru kasutamise kohta lõputöodes. <https://cs.ut.ee/sites/default/files/2026-04/Selgitused%20tehisaru%20kasutamise%20kohta%201%C3%B5put%C3%B6%C3%B6des%20APR2026.pdf>. Aprill 2026; viimati vaadatud: 13.05.2026. 2026.
- [21] Lee Y., Ka S., Son B., Kang P. ja Kang J. Navigating the Path of Writing: Outline-guided Text Generation with Large Language Models. *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 3: Industry Track)*. Albuquerque, New Mexico: Association for Computational Linguistics, 2025, lk 233–250. DOI: [10.18653/v1/2025.naacl-industry.20](https://doi.org/10.18653/v1/2025.naacl-industry.20). <https://aclanthology.org/2025.naacl-industry.20/>.
- [22] Tang X., Duan X. ja Cai Z. Large Language Models for Automated Literature Review: An Evaluation of Reference Generation, Abstract Writing, and Review Composition. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*. Suzhou, China: Association for Computational Linguistics, 2025, lk 1602–1617. DOI: [10.18653/v1/2025.emnlp-main.83](https://doi.org/10.18653/v1/2025.emnlp-main.83). <https://aclanthology.org/2025.emnlp-main.83/>.
- [23] Usher M. ja Amzalag M. From Prompt to Polished: Exploring Student–Chatbot Interactions for Academic Writing Assistance. *Education Sciences* 15.3 (2025), lk 329. DOI: [10.3390/educsci15030329](https://doi.org/10.3390/educsci15030329). <https://doi.org/10.3390/educsci15030329>.
- [24] Nadra S. ja Purdy J. P. Is GenAI a Good Editor of Academic Writing? *Computers and Composition* 80, 102993 (2026). DOI: [10.1016/j.compcom.2026.102993](https://doi.org/10.1016/j.compcom.2026.102993). <https://doi.org/10.1016/j.compcom.2026.102993>.
- [25] Pinto M. M., Araújo E. E. R., Rahhal Z., Stanbouly D. ja Grillo R. AI-Assisted Translation in Oral and Maxillofacial Surgery: A Comparative Evaluation. *Journal of Stomatology, Oral and Maxillofacial Surgery* 127.3, 102717 (2026). DOI: [10.1016/j.jormas.2026.102717](https://doi.org/10.1016/j.jormas.2026.102717). <https://doi.org/10.1016/j.jormas.2026.102717>.

- [26] Rao D. ja Callison-Burch C. BibTeX Citation Hallucinations in Scientific Publishing Agents: Evaluation and Mitigation. *arXiv preprint arXiv:2604.03159* (2026). DOI: [10.48550/arXiv.2604.03159](https://doi.org/10.48550/arXiv.2604.03159). <https://arxiv.org/abs/2604.03159>.
- [27] Peters U. ja Chin-Yee B. Generalization Bias in Large Language Model Summarization of Scientific Research. *Royal Society Open Science* 12.4 (2025), lk 241776. DOI: [10.1098/rsos.241776](https://doi.org/10.1098/rsos.241776). <https://doi.org/10.1098/rsos.241776>.
- [28] Doshi A. R. ja Hauser O. P. Generative AI Enhances Individual Creativity but Reduces the Collective Diversity of Novel Content. *Science Advances* 10.28 (2024). <https://doi.org/10.1126/sciadv.adn5290>.
- [29] Bender E. M., Gebru T., McMillan-Major A. ja Shmitchell S. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of FAccT* (2021), lk 610–623. <https://doi.org/10.1145/3442188.3445922>.
- [30] Lillepalu H. G. ja Alumäe T. Estonian Native Large Language Model Benchmark. *arXiv preprint arXiv:2510.21193* (2025). Viimati muudetud 19.02.2026; vastu võetud konverentsile LREC 2026. <https://arxiv.org/abs/2510.21193>.
- [31] Google. Upload and Analyse Files in Gemini Apps. <https://support.google.com/gemini/answer/14903178>. Viimati vaadatud: 02.05.2026. 2026.
- [32] Anthropic. Upload Files to Claude. <https://support.claude.com/en/articles/8241126-upload-files-to-claude>. Viimati vaadatud: 02.05.2026. 2026.
- [33] OpenAI. File Uploads FAQ. <https://help.openai.com/en/articles/8555545-file-uploads-faq>. Viimati vaadatud: 02.05.2026. 2026.
- [34] Google DeepMind. Gemini 3.1 Pro: A smarter model for your most complex tasks. <https://blog.google/innovation-and-ai/models-and-research/gemini-models/gemini-3-1-pro/>. Viimati vaadatud: 01.03.2026. 2026.
- [35] OpenAI. Introducing GPT-5.4. <https://openai.com/index/introducing-gpt-5-4/>. Avaldatud 05.03.2026; viimati vaadatud: 07.05.2026. 2026.
- [36] Anthropic. Introducing Claude Sonnet 4.6. <https://www.anthropic.com/news/claude-sonnet-4-6>. Viimati vaadatud: 01.03.2026. 2026.
- [37] Anthropic. Introducing Claude Opus 4.6. <https://www.anthropic.com/news/claude-opus-4-6>. Viimati vaadatud: 10.03.2026. 2026.
- [38] OpenAI. API Pricing. <https://openai.com/api/pricing/>. Viimati vaadatud: 24.04.2026. 2026.

- [39] Anthropic. Claude API Pricing. <https://www.anthropic.com/pricing>. Viimati vaadatud: 24.04.2026. 2026.
- [40] Google. Gemini API Pricing. <https://ai.google.dev/gemini-api/docs/pricing>. Viimati vaadatud: 24.04.2026. 2026.
- [41] Anthropic. Claude Code: An Agentic Coding Tool. <https://docs.anthropic.com/en/docs/claude-code>. Viimati vaadatud: 10.03.2026. 2026.
- [42] OpenAI. Introducing Codex. <https://openai.com/index/introducing-codex/>. Viimati vaadatud: 16.03.2026. 2025.
- [43] Anthropic. Introducing Claude Opus 4.7. <https://www.anthropic.com/news/claude-opus-4-7>. Viimati vaadatud: 30.04.2026. 2026.
- [44] Chelli M., Descamps J., Lavoué V., Trojani C., Azar M., Deckert M., Raynier J.-L., Clowez G., Boileau P. ja Ruetsch-Chelli C. Hallucination Rates and Reference Accuracy of ChatGPT and Bard for Systematic Reviews: Comparative Analysis. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/53164>.
- [45] Barbu E., Muru M.-L. ja Malva S. M. Improving Estonian Text Simplification through Pretrained Language Models and Custom Datasets. *arXiv preprint arXiv:2501.15624* (2025). <https://arxiv.org/abs/2501.15624>.
- [46] Bianchi F., Suzgun M., Attanasio G., Röttger P., Jurafsky D., Hashimoto T. ja Zou J. Safety-Tuned LLaMAs: Lessons From Improving the Safety of Large Language Models that Follow Instructions. *arXiv preprint arXiv:2309.07875* (2023). <https://arxiv.org/abs/2309.07875>.
- [47] Perplexity. Pricing. <https://docs.perplexity.ai/docs/getting-started/pricing>. Viimati vaadatud: 30.04.2026. 2026.
- [48] Perplexity. Models. <https://docs.perplexity.ai/docs/agent-api/models>. Viimati vaadatud: 30.04.2026. 2026.
- [49] DataStudios. Perplexity AI Context Window: Token Limits, Memory Policy, and 2025 Rules. <https://www.datastudios.org/post/perplexity-ai-context-window-token-limits-memory-policy-and-2025-rules>. Viimati vaadatud: 14.03.2026. 2025.
- [50] GitHub. About Individual GitHub Copilot Plans and Benefits. <https://docs.github.com/en/copilot/concepts/billing/individual-plans>. Viimati vaadatud: 14.03.2026. 2026.
- [51] GitHub. Responsible use of GitHub Copilot Chat in your IDE. <https://docs.github.com/en/copilot/responsible-use/chat-in-your-ide>. Viimati vaadatud: 30.04.2026. 2026.

- [52] Nguyen N. ja Nadi S. An Empirical Evaluation of GitHub Copilot's Code Suggestions. *Proceedings of the 19th International Conference on Mining Software Repositories (MSR)*. 2022, lk 1–5. <https://doi.org/10.1145/3524842.3528470>.
- [53] GitHub. Usage limits for GitHub Copilot. <https://docs.github.com/en/copilot/concepts/usage-limits>. Viimati vaadatud: 30.04.2026. 2026.

Lisad

I. Eksperimendis kasutatud viip

Käesoleva uurimuse eksperimendis kasutati kõigi nelja mudel-tööriista kombinatsiooni puhul üht ja sama lühikest eestikeelset viipa ehk ühe kasutajaviibaga (*single-prompt*) lähenemist. Viipa ei muudetud ega iteratiivselt täiendatud. Täielik viip oli järgmine:

“Sa oled kogenud akadeemiline kirjutaja. Loo täielik bakalaureusetöö LaTeX-vormingus (lisasin töökausta vajaliku malli), mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele. Teema peab olema informaatikaga seotud ja vali ise. Autor on Uku Renek Kronbergs ja juhendaja Alo Peets (MSc).”

Viiba sisulised elemendid:

- **Mudeli roll** – “kogenud akadeemiline kirjutaja” kui üldine stiiliviide.
- **Ülesanne** – täieliku bakalaureusetöö loomine.
- **Vorm** – L^AT_EX-vorming koos viitega töökausta paigutatud UniTartuCS mallile.
- **Nõue** – vastavus Tartu Ülikooli arvutiteaduse instituudi nõuetele.
- **Teema** – informaatikaga seotud; konkreetse teema valib mudel ise.
- **Tiitellehe andmed** – autor Uku Renek Kronbergs, juhendaja Alo Peets (MSc).

Viibasse ei lisatud:

- TÜ ATI ega LOTE lõputööde juhendite teksti;
- varasemate bakalaureusetööde näiteid;
- detailseid juhiseid peatükkide struktuuri, mahu või sisu kohta;
- viitamisstiili juhiseid;
- keelelisi korrektuureegleid.

Sellise minimaalse viiba eesmärk oli hinnata, kuidas mudelid interpreteerivad võimalikult lühikest juhust ning millistele eelteadmistele nad toetuvad eestikeelse akadeemilise lõputöö loomisel.

II. Eksperimendis genereeritud väljundfailid

Eksperimendi tulemusena salvestati iga agentse mudel-tööriista kombinatsiooni kohta üks PDF-failiks kompileeritud lõputöö. Need failid paiknevad töö avalikus GitHubi repositooriumis (https://github.com/UkuRenekKronbergs/bakalaureusetoo_isiklik) kaustas Genereeritud lõputööd.

- Gemini_3.1_Pro_Antigravity.pdf – Gemini 3.1 Pro + Antigravity; 39 lk; teema: GenAI ja algajad programmeerijad.
- GPT_5.4_Visual_Studio_Codex.pdf – GPT-5.4 + Codex VS Code'is; 47 lk; teema: RAG-põhine küsimus-vastuse süsteem.
- Sonnet_4.6_Cowork.pdf – Claude Sonnet 4.6 + Cowork; 40 lk; teema: LLM-id koodiülevaatuses.
- Opus_4.6_Cowork.pdf – Claude Opus 4.6 + Cowork; 61 lk; teema: turvaline paroolihaldur.
- Opus_{4.7}Code_{it}paev_itereeritudpdf – ClaudeOpus4.7 + ClaudeCode, iteratiivnetvoog; 57lk; teema : Suurelkeelemudelilphinevaeestikeelseinformaatika

GPT-5.4 tavapärase vestlusliidese kaudu saadud keelduv 8-leheküljeline teostatavusjuhend ei kuulunud nelja tervikliku PDF-lõputöö hulka, kuid selle väljavõte on võrdluse huvides esitatud lisas ?? alajaotuses III.2.

III. Genereeritud väljundite näited

Järgnevalt on esitatud väljavõtted eksperimendi väljunditest. Nelja tervikliku PDF-lõputöö puhul on toodud sissejuhatuse algus, et illustreerida erinevusi keeles, stiilis ja teemale vastavuses. GPT-5.4 tavapärase vestlusliidese puhul on toodud keeldumise väljavõte, sest see väljund ei olnud terviklik lõputöö, vaid teostatavusjuhend.

III.1 Claude Sonnet 4.6 (Cowork) – sissejuhatuse väljavõte (40 lk)

“Kaasaegne tarkvaraarendus on olemuselt meeskonnatöö. Isegi suurima kogemusega programmeerijad teevad vigu, ning keerukad süsteemid sisaldavad sageli turvaauke, jõudlusprobleeme või loogilisi vigu, mida üks inimene ei suuda leida.”

“Käesoleva bakalaureusetöö peamine eesmärk on hinnata suurkeelemudelite sobivust automaatse koodiülevaatuse tööriistadena ning võrrelda eri mudeleid nende tulemuslikkuse alusel. Töö käigus viiakse läbi empiiriline katse, milles kolme LLM-i — GPT-4, Claude 3 Opus ja Code Llama 70B — rakendatakse 120 koodifragmendi analüüsimiseks.”

Hinnang: terviklik eestikeelne lõputöö Tartu Ülikooli struktuuriga. Peamised puudused olid hallutsineeritud viited (5 viga 23-st), kontrollimata empiirilised väited ning suurim kirjavigade arv (37). Detailne analüüs peatükis ??.

III.2 GPT-5.4 (vestlusliides) – väljundi väljavõte (8 lk, teostatavusjuhend)

“A complete, submission-ready bachelor’s thesis written end-to-end on your behalf is not something I can produce. That would materially enable academic misconduct (submitting work largely authored by a third party). What I can provide—aligned with the University of Tartu’s own principles for using generative AI in coursework—is a deep-research ‘thesis kit’: a rigorously sourced background review, a defensible experimental design, an evaluation rubric, and a UniTartuCS-template-aligned LaTeX project skeleton with chapter-by-chapter writing prompts and clearly marked placeholders that you must complete, verify, and take responsibility for.”

Hinnang: GPT-5.4 keeldus ülesannet täitmast ja valis väljundkeeleks inglise keele, pakkudes selle asemel teostatavusjuhendi. Sama mudel genereeris sama viibaga Codex-laienduse kaudu tervikliku eestikeelse töö (vt lisa ?? alajaotus III.3). Detailne analüüs peatükis ??.

III.3 GPT-5.4 (Codex VS Code’is) – sissejuhatuse väljavõte (47 lk)

“Suurte keelemudelite kiire areng on muutnud loomulikus keeles suhtlevad tarkvarasüsteemid tavapäraseks osaks nii õppetöös, ettevõtluses kui ka avalikes teenustes. [...] Käesolev töö keskendub eestikeelsele dokumentide põhisele küsimus-vastus süsteemile.”

“Töö eesmärk on analüüsida RAG-lahenduste teaduskirjandust ning selle põhjal kavandada eestikeelse dokumentide põhise küsimus-vastus süsteemi arhitektuur, mis oleks läbipaistev, ajakohastatav ja hinnatav.”

Hinnang: agentse töövoos kaudu eestikeelne ja struktureeritud lõputöö, ortograafiliselt parim tulemus (3 kirjaviga) ja ainus kombinatsioon, kus kõik 22 viidet olid kontrollitavad. Mudel

kasutas tiitellehel kohatäiteid (Näidisüliõpilane, Juhendaja nimi, PhD) etteantud nimede asemel. Detailne analüüs peatükis ??.

III.4 Gemini 3.1 Pro (Antigravity) – sissejuhatuse väljavõte (39 lk)

“Tarkvaraarenduse valdkond on viimaste aastate jooksul teinud läbi märkimisväärse arengutõuke tänu erinevate tehisintellekti vormide laialdasele levikule ja kättesaadavusele. Üha enam integreeritakse generatiivset tehisintellekti (GenAI) igapäevastesse tööriistadesse ja arenduskeskkondadesse (IDE).”

“Käesoleva bakalaureusetöö eesmärk on just selle andmelünga osaline täitmine kohalikus kontekstis. Töö keskendub Eesti informaatikaliõpilastele ja püüab selgitada välja, kuidas täpselt mõjutab lokaalse tehisintellekti viipeassistendi kasutamine algaja programmeerija produktiivsust esimesel õppeaastal.”

Hinnang: vormiliselt korrektne töö, mille empiiriline osa (väidetav 30 informaatikatudengiga kvaasi-eksperiment Tartu Ülikoolis koos statistiliste tulemustega) on täielikult väljamõeldud. Tekst sisaldab 24 unikaalset kirjaviga. Töös käsitletakse seda akadeemilise väärkasutuse kõrge riskiga juhtumina (vt peatükk ??).

III.5 Claude Opus 4.6 (Cowork) – sissejuhatuse väljavõte (61 lk)

“Tänapäeva digimaailmas on igapäevaelu lahutamatult seotud veebiteenustega. Inimesed kasutavad regulaarselt kümneid, sageli isegi sadu erinevaid platvorme — alates e-postist ja sotsiaalmeediast kuni pangateenuste ja tervishoiuportaalideni.”

“Käesoleva bakalaureusetöö eesmärk on kavandada ja arendada turvaline paroolihalduri veebirakendus, mis põhineb null-teadmise arhitektuuril. Rakendus kasutab kaasaegseid krüptograafilisi algoritme — AES-256-GCM sümmeetrilist krüpteerimist ja Argon2id võtmetuletust — ning on loodud avatud lähtekoodina, et tagada läbipaistvus ja auditeeritavus.”

Hinnang: Opus 4.6 + Coworki kombinatsioon genereeris kõige mahukama ja tehniliselt sügavaima töö. 61-leheküljeline lõputöö sisaldas terviklikku tehnilist arhitektuuri ja koodinäiteid; lisaks väitis töö, et rakendus läbis 149 automatiseeritud testi, OWASP Top 10 analüüsi ja SUS kasutatavusuuringu (skoor 77,0). Neid teste, auditit ega kasutajauuringut ei valideerinud töö autor. Eestikeelne akadeemiline stiil oli läbivalt suurepärase (0 esimese isiku asesõna terve töö peale); loendis tuvastati 15 unikaalset keele- ja kirjaviga. Struktuur vastas TÜ nõuetele. 35-st viitest 33 olid täielikult korrektsed; 2 viites (6%) oli väike metaandmete viga (URL-i kuju

ning pealkirja/aasta ebatäpsus). Peamine eelis teiste kombinatsioonide ees: tehniline detailsus, $\text{\LaTeX}$ -koodi otsene genereerimine failidesse ja võime hallata terviklikku projektistruktuuri.

III.6 Genereeritud tööde võrdlev kokkuvõte

Tabel 11. Tervikliku lõputöö genereerimise koondvõrdlus

Kriteerium	Gemini 3.1 Pro + Antigravity	GPT-5.4 + Codex	Claude Sonnet 4.6 + Cowork	Claude Opus 4.6 + Cowork
Valitud teema	GenAI ja progr.	RAG QA-süsteem	LLM koodiülevaatuses	Paroolihaldur
Maht	39 lk	47 lk	40 lk	61 lk
Sõnu (sõnu/lk)	7 230 (185/lk)	9 669 (206/lk)	8 085 (202/lk)	10 749 (176/lk)
Alapeatükke	20	49	32	27
Tabeleid	2	7	7	11
Jooniseid	0	2	0	0
Keele- ja kirjavigu (vigu/lk)	24 (0,62/lk)	3 (0,06/lk)	37 (0,93/lk)	15 (0,25/lk)
Unikaalseid viiteid	9	22	23	35
Tekstisiseid viiteid (viiteid/lk)	13 (0,33/lk)	28 (0,60/lk)	54 (1,35/lk)	45 (0,74/lk)
Hallutsineeritud viiteid	1 (11%)	0 (0%)	5 (22%)	2 (6%)
Anglitsisme (anglitsisme/lk)	28 (0,72/lk)	15 (0,32/lk)	6 (0,15/lk)	28 (0,46/lk)
Esimese isiku asesõnu	1	0	0	0

Tabelist ?? nähtub, et kõik neli mudel-tööriista kombinatsiooni järgisid lõputöö üldist vormi, kuid erinesid mahu, viidete kvaliteedi, kirjavigade tiheduse ning anglitsismide kasutuse poolest oluliselt. Iga näitaja sisuline tõlgendus, sellest tulenevad järeldused ja kombinatsioonide võrdlev hinnang on esitatud peatükis ??.

Litsents

Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks

Mina, Uku Renek Kronbergs,

1. annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) minu loodud teose

“Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine”,

mille juhendaja on Alo Peets (MSc),

reprodutseerimiseks eesmärgiga seda säilitada, sealhulgas lisada digitaalarhiivi DSpace kuni autoriõiguse kehtivuse lõppemiseni.

2. Annan Tartu Ülikoolile loa teha punktis 1 nimetatud teos üldsusele kättesaadavaks Tartu Ülikooli veebikeskkonna, sealhulgas digitaalarhiivi DSpace kaudu Creative Commons'i litsentsiga CC BY NC ND 3.0, mis lubab autorile viidates teost reprodutseerida, levitada ja üldsusele suunata ning keelab luua tuletatud teost ja kasutada teost ärieesmärgil, kuni autoriõiguse kehtivuse lõppemiseni.
3. Olen teadlik, et punktides 1 ja 2 nimetatud õigused jäävad alles ka autorile.
4. Kinnitan, et lihtlitsentsi andmisega ei riku ma teiste isikute intellektuaalomandi ega isikuandmete kaitse õigusaktidest tulenevaid õigusi.

Uku Renek Kronbergs

14.05.2026