

TARTU ÜLIKOOL
Arvutiteaduse instituut
Informaatika õppekava

Uku Renek Kronbergs

**Teostatavusuuring: Tehisintellekti abil
eestikeelse tehnilise informaatika alase
lõputöö genereerimine**

Bakalaureusetöö (9 EAP)

Juhendaja:
Alo Peets, MSc

Tartu 2026

Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine

Lühikokkuvõte:

Käesolev bakalaureusetöö uurib tehisintellekti (AI) rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Töös võrreldakse nelja juhtivat suurt keelemudelit – Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ning Anthropic Claude Opus 4.6 – nende võimekuse osas luua struktureeritud, akadeemiliselt korrektset ja sisuliselt väärtuslikku eestikeelset teksti. Opus 4.6 puhul kasutati lisaks Claude Code'i agentset tööriista. Uurimuse käigus sisestati mudelitele Tartu Ülikooli arvutiteaduse instituudi (ATI) ja Loodus- ja täppisteaduste valdkonna (LOTE) lõputööde juhendid ning varasemate heade näidistööde fragmendid, mille põhjal katsetati nii lõputöö erinevate osade genereerimist kui ka tervikliku lõputöö koostamist. Genereeritud tekstide kvaliteeti hinnati struktuuri, keelelise korrektsuse, tehnilise täpsuse ja akadeemilise stiili alusel. Tervikliku lõputöö genereerimise eksperimendi tulemused paljastasid mudelite vahel olulisi erinevusi: Claude Opus 4.6 genereeris Claude Code'i kaudu 61-leheküljelise eestikeelse lõputöö paroolihalduri teemal; Claude Sonnet 4.6 genereeris täieliku 40-leheküljelise eestikeelse lõputöö korrektset teemal; GPT-5.4 keeldus täielikku tööd kirjutamast, pakkudes selle asemel 8-leheküljelise ingliskeelse teostatavusjuhendi; Gemini 3.1 Pro genereeris Antigravity tööriista kaudu 39-leheküljelise eestikeelse töö, kuid vale teema kohta. Tulemused näitavad, et AI mudelite suutlikkus erineb drastiliselt nii ülesandest arusaamise, keelevaliku kui ka juhiste järgimise osas. Töö annab soovitusel AI tööriistade efektiivseks kasutamiseks lõputöö kirjutamise protsessis ning kaardistab valdkonnad, kus inimese panus on endiselt asendamatu.

Võtmesõnad: tehisintellekt, keelemudelid, lõputöö genereerimine, eesti keel, teostatavusuuring, Claude Code

CERCS: P170 Arvutiteadus, arvutusmeetodid, süsteemid, juhtimine (automaatjuhtimisteooria)

Feasibility Study: Generating an Estonian-Language Technical Computer Science Thesis Using Artificial Intelligence

Abstract:

This bachelor's thesis investigates the feasibility of applying artificial intelligence (AI) to generate an Estonian-language technical computer science thesis. The study compares four leading large language models – Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6, and Anthropic Claude Opus 4.6 – in terms of their ability to produce structured, academically correct, and substantively valuable Estonian-language text. For Opus 4.6, the agentic Claude Code tool was additionally used. During the research, models were provided with the thesis guidelines of the University of Tartu's Institute of Computer Science (ICS) and the Faculty of Science and Technology (LOTE), along with fragments of previously well-evaluated theses, to test both individual thesis component generation and full thesis composition. The full thesis generation experiment revealed significant differences between models: Claude Opus 4.6 produced, via Claude Code, a 61-page Estonian-language thesis on a password manager; Claude Sonnet 4.6 produced a complete 40-page Estonian-language thesis on the correct topic; GPT-5.4 declined to write a full thesis, instead offering an 8-page English-language feasibility guide; Gemini 3.1 Pro, via the Antigravity tool, generated a 39-page Estonian-language thesis but on an incorrect topic. Results demonstrate that AI model capabilities differ drastically in task comprehension, language selection, and instruction adherence. The thesis provides recommendations for the effective use of AI tools in the thesis writing process and maps areas where human contribution remains irreplaceable.

Keywords: artificial intelligence, language models, thesis generation, Estonian language, feasibility study, Claude Code

CERCS: P170 Computer science, numerical analysis, systems, control

Sisukord

1. Sissejuhatus	7
2. Taust ja kirjanduse ülevaade	9
2.1 Suurte keelemudelite areng	9
2.2 Eesti keele töötlemine keelemudelites	10
2.3 AI akadeemilises kirjutamises	11
2.4 Tartu Ülikooli lõputööde nõuded	12
3. Metoodika	13
3.1 Mudelite valiku kriteeriumid	13
3.2 Eksperimentide ülesehitus	13
3.3 Sisendi ettevalmistamine ja promptide disain	14
3.4 Hindamiskriteeriumid	15
4. AI mudelite võrdlus	17
4.1 Google Gemini 3.1 Pro	17
4.1.1 Tehniline ülevaade	17
4.1.2 Hinnastamine	17
4.1.3 Eesti keele tugi	17
4.2 OpenAI GPT-5.4	18
4.2.1 Tehniline ülevaade	18
4.2.2 Hinnastamine	18
4.2.3 Eesti keele tugi	19
4.3 Anthropic Claude Sonnet 4.6	19
4.3.1 Tehniline ülevaade	19
4.3.2 Hinnastamine	20
4.3.3 Eesti keele tugi	20
4.4 Anthropic Claude Opus 4.6	20
4.4.1 Tehniline ülevaade	20
4.4.2 Hinnastamine	21
4.4.3 Eesti keele tugi	21
4.5 Mudelite koondvõrdlus	21
4.6 Mõtlemismudelite võrdlus	22

5. Eksperimendid ja tulemused.....	23
5.1 Eksperiment 1: Sissejuhatuse genereerimine	23
5.1.1 Nullkonteksti tulemused.....	23
5.1.2 Kontekstipõhised tulemused.....	24
5.2 Eksperiment 2: Kirjanduse ülevaate genereerimine	24
5.3 Eksperiment 3: Metoodika peatüki genereerimine	25
5.4 Eksperiment 4: Tulemuste ja arutelu genereerimine	26
5.5 Eksperiment 5: Kokkuvõtte genereerimine.....	26
5.6 Tulemuste koondanalüüs	26
5.7 Hinnangu stabiilsus ja subjektiivsus.....	28
5.8 Eksperiment 6: Tervikliku lõputöö genereerimine.....	28
5.8.1 Claude Sonnet 4.6: Terviklik eestikeelne lõputöö	28
5.8.2 GPT-5.4: Akadeemilise aususe keeldumine	28
5.8.3 Gemini 3.1 Pro: Terviklik lõputöö Antigravity kaudu	30
5.8.4 Claude Opus 4.6: Terviklik tehniline lõputöö Claude Code'i kaudu.....	31
5.8.5 Eksperimendi 6 järeldused.....	31
5.8.6 Kirjavigade analüüs genereeritud töödes.....	32
5.8.7 Mahu ja struktuuri analüüs.....	33
5.8.8 Viidete kvantitatiivne analüüs.....	34
5.8.9 Anglitsismide ja eesti keele puhtuse analüüs.....	35
5.8.10 Akadeemilise stiili indikaatorid.....	36
6. Arutelu	38
6.1 AI tugevused lõputöö kirjutamisel.....	38
6.2 AI puudujäägid ja piirangud.....	39
6.3 Hinnakujundus ja majanduslik teostatavus	41
6.4 Eesti keele korrektuur ja toimetamine	41
6.5 Soovitused AI tööriista valikuks.....	42
6.6 Tööriistad, mida vältida.....	43
6.7 Eetilised kaalutlused ja akadeemiline ausus.....	44
6.8 Tulevikuväljavaated	44
7. Claude Code kui lõputöö genereerimise tööriist	46
7.1 Claude Code'i ülevaade	46
7.2 Claude Code vs tavapärane vestlusliides.....	46

7.3	Soovitused lõputöö genereerimiseks Claude Code'iga.....	46
7.3.1	Projekti ettevalmistamine	47
7.3.2	Genereerimise töövoog	47
7.3.3	Parimad praktikad	48
7.4	Alternatiivne agentne tööriist: Google Antigravity	49
7.5	Alternatiivne agentne tööriist: ChatGPT Codex Visual Studio Code'is.....	49
7.6	Claude Code'i piirangud	50
7.7	Juhtumiuuring: Paroolihalduri lõputöö genereerimine Opus 4.6-ga	50
7.7.1	Genereerimisprotsess.....	50
7.7.2	Genereeritud töö omadused.....	50
7.7.3	Järeldused juhtumiuuringust.....	51
8.	Kokkuvõte.....	52
	Viited.....	54
	Lisad	59
	I. Eksperimentides kasutatud promptide näited	59
	II. Genereeritud sissejuhatuste näited.....	60
	III. Hindamistabelite koondandmed.....	61
	IV. AI kasutamise deklaratsioon.....	61
	V. Tervikliku lõputöö genereerimise näited	62
	Litsents	67

1. Sissejuhatus

Tehisintellekti (AI) kiire areng viimastel aastatel on toonud kaasa põhjalikud muutused paljudes eluvaldkondades, sealhulgas hariduses ja akadeemilises kirjutamises. Suurte keelemudelite (*Large Language Models*, LLM) nagu OpenAI GPT-seeria, Google Gemini ja Anthropic Claude võimekus genereerida inimkeelset teksti on saavutanud taseme, mis sunnib ümber hindama traditsioonilisi arusaamu teksti loomisest, toimetamisest ja kvaliteedikontrollist [1, 2]. Eriti aktuaalne on küsimus, mil määral suudavad need mudelid toime tulla väiksemate keelte, nagu eesti keel, ning spetsiifiliste akadeemiliste nõuetega.

Tartu Ülikooli arvutiteaduse instituudis (ATI) kaitstakse igal aastal kümneid bakalaureuse- ja magistritöid, mis peavad vastama rangetele vormistus- ja sisunõuetele [3]. Lõputöö kirjutamine on üliõpilase jaoks mahukas ja aeganõudev protsess, mis hõlmab kirjanduse ülevaadet, meetodika kirjeldamist, tulemuste esitamist ning akadeemilise stiili järgimist. Küsimus, kas ja mil määral saab tehisintellekt selles protsessis abiks olla, on nii praktiliselt kui ka akadeemiliselt oluline.

Käesoleva bakalaureusetöö eesmärk on uurida tehisintellekti rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Töö keskendub järgmistele uurimisküsimustele:

1. Millised kaasaegsed AI mudelid on kõige sobivamad mahukate eestikeelsete akadeemiliste tekstide genereerimiseks?
2. Kuidas mõjutab mudelitele antav kontekst (juhendid, näidistööd) genereeritud teksti kvaliteeti?
3. Millistes lõputöö osades suudab AI pakkuda tõhusat abi ning kus on inimese panus endiselt asendamatu?
4. Millised on AI-põhise tekstigeneraatorise praktilised piirangud, sealhulgas hinnapoliitika, kontekstiakna piirangud ja keelelised puudujäägid?

Uurimuse läbiviimiseks valiti neli juhtivat suurt keelemudelit: Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ning Anthropic Claude Opus 4.6. Mudelitele sisestati TÜ ATI ja LOTE lõputööde juhendid ning varasemate heade näidistööde fragmendid, mille põhjal katsetati lõputöö erinevate osade genereerimist. Opus 4.6 puhul kasutati lisaks Claude Code'i agentset tööriista, mis võimaldas mudelil otse $\LaTeX$ faile kirjutada ja projekti hallata. Genereeritud tekstide kvaliteeti hinnati mitme kriteeriumi alusel, sealhulgas struktuuri, keelelise korrektsuse, tehnilise täpsuse ja akadeemilise stiili põhjal.

Töö on struktureeritud järgmiselt. Peatükk 2 annab ülevaate suurte keelemudelite arengust, eesti keele töötlemise väljakutsetest ning varasematest uurimustest AI kasutamisest akadeemilises kirjutamises. Peatükk 3 kirjeldab uurimuse metoodikat, sealhulgas mudelite valiku kriteeriume, eksperimentide ülesehitust ja hindamiskriteeriumeid. Peatükk 4 esitab valitud mudelite detailse võrdluse, hõlmates nende tehnilist arhitektuuri, hinnastamist ja eesti keele tuge. Peatükk 5 kirjeldab läbiviidud eksperimente ja nende tulemusi, sealhulgas tervikliku lõputöö genereerimise katset, mis paljastas mudelite vahel põhimõttelisi erinevusi juhiste järgimisel ja keelevelikul. Peatükk 6 sisaldab arutelu tulemuste üle, sealhulgas AI kasutamise praktilised soovitused, piirangud ja tulevikuväljavaated. Peatükk 7 kirjeldab Claude Code'i agentse tööriista kasutamist lõputöö genereerimisel ning esitab praktilised soovitused. Peatükk 8 võtab töö tulemused kokku.

2. Taust ja kirjanduse ülevaade

Käesolev peatükk annab ülevaate suurte keelemodelite arengust, eesti keele töötlemise spetsiifikast ning varasematest uurimustest tehisintellekti kasutamisest akadeemilises tekstiloomes.

2.1 Suurte keelemodelite areng

Suurte keelemodelite ajalugu ulatub tagasi 2017. aastasse, mil Vaswani et al. avaldasid transformeri arhitektuuri [4]. See murdepunkt pani aluse kõigile kaasaegsetele keelemodelitele. Esimesed märkimisväärsed keelemudelid, nagu BERT [5] ja GPT-2 [6], demonstreerisid, et suuremahuline eeltreenimine võimaldab mudelitel omandada laialdasi keelelisi teadmisi.

GPT-3 ilmumine 2020. aastal [1] tõi kaasa paradigmuuutuse, näidates, et 175 miljardi parameetriga mudel suudab täita mitmesuguseid ülesandeid ilma spetsiifilise peenhäälestamiseta (*fine-tuning*). Sellest ajast on mudelid kiiresti arenenud nii suuruse, arhitektuuri kui ka võimekuse poolest.

2025.–2026. aasta on olnud eriti viljakas periood. OpenAI avaldas GPT-5.4 mudeli, mis pakub kuni 1 000 000 tokeni kontekstiakent ning ühendab teksti, pildi ja heli töötlemise ühtsesse multimodaalsesse arhitektuuri [7]. Google tõi turule Gemini mudeliperekonna, mille uusim versioon Gemini 3.1 Pro pakub kuni miljoni tokeni pikkust kontekstiakent [8]. Anthropic arendas välja Claude mudeliperekonna, mille Sonnet 4.6 versioon paistab silma eriti tugeva analüütilise võimekuse, parandatud kodeerimise ja juhiste järgimise võimete ning pikaajalise konteksti haldamisega [9]. Sama perekonna tippmudel Opus 4.6 [10] pakub veelgi sügavamat arutlusvõimekust ja on alusmodeliks Anthropic'i agentsele tööriistale Claude Code [11], mis võimaldab mudelil iseseisvalt faile lugeda, kirjutada ja projekte hallata.

Eraldi väärib mainimist nn mõtlemismodelite (*reasoning models*) areng. OpenAI o3 ja GPT-5.4 Pro mudelid [12] kasutavad ahelpõhjamist (*chain-of-thought reasoning*), et parandada keerulisemate ülesannete lahendamist. Google DeepMind on samuti arendanud Gemini mudelite mõtlemisversioone. Need mudelid on eriti kasulikud keeruliste struktureeritud tekstide loomisel, kus on vaja järgida mitmeid reegleid üheaegselt.

2.2 Eesti keele töötlemine keelemudelites

Eesti keel kuulub soome-ugri keelkonda ja on morfoloogiliselt rikas keel 14 käändega ning keerulise sõnamoodustussüsteemiga [13]. See eripära teeb eesti keele töötlemise keelemudelite jaoks oluliselt keerulisemaks kui näiteks inglise keele puhul.

Suurte keelemudelite eesti keele oskus sõltub eelkõige treeningandmete mahust ja kvaliteedist. Common Crawl andmestikus, mida enamik mudeleid kasutab, moodustab eesti keel väga väikese osa – hinnanguliselt alla 0,1% kogumandmetest [14]. See tähendab, et mudelite eesti keele oskus on oluliselt nõrgem kui inglise keele puhul.

Tartu Ülikooli keeletehnoloogia uurimisrühm on teinud märkimisväärsed tööd eesti keele ressursside ja tööriistade arendamisel. EstBERT [15] on eesti keelele kohandatud BERT mudel, mis on treenitud eestikeelsel tekstikorpusel. Samuti on arendatud mitmesuguseid eesti keele töötlemise tööriistu, nagu morfoloogiline analüsaator ja süntaktiline parser [16]. Hiljutine EstLLM projekt [17] on teinud olulisi edusamme suurte keelemudelite eesti keele võimekuse parandamisel, kasutades jätkutreenimist (*continued pretraining*) ja järeltreenimist (*post-training*) mitmekeelsete mudelite baasil. Uurimus näitas, et spetsialiseeritud treeninguga saab eesti keele kvaliteeti oluliselt tõsta, ilma et mudeli üldine arutlusvõimekus kannataks.

Mitmekeelsete mudelite arendamise seisukohast väärib esiletõstmist Aya mudel [18], mis on juhendipõhiselt peenhäälestatud avatud lähtekoodiga keelemudel, mis toetab 101 keelt, sealhulgas mitmeid väikese ressursiga keeli. Aya ületas mT0 ja BLOOMZ mudeleid enamikus ülesannetes, demonstreerides, et sihipärase mitmekeelse peenhäälestamisega on võimalik oluliselt parandada väikeste keelte kvaliteeti. Kuulmetsa jt süstemaatiline hindamine näitas, et soome-ugri keelte, sealhulgas eesti keele, tugi avatud keelemudelites on viimastel aastatel kiiresti paranenud, kuid jääb endiselt inglise keelest oluliselt maha [19]. Suurte keelemudelite puhul on eesti keele kvaliteet viimase kahe aasta jooksul märgatavalt paranenud. Kui varasemad GPT-3 põhised mudelid tegid eesti keeles sageli lihtsalt märgatavaid grammatilisi vigu, siis GPT-5.4, Gemini 3.1 Pro ja Claude Sonnet 4.6 suudavad luua grammatiliselt suures osas korrektset eesti keelt. Siiski esineb endiselt probleeme tehnilise terminoloogiaga, akadeemilise stiiliga ning pikematel tekstidel keelelise järjepidevuse hoidmisega. Kiil [20] on Tartu Ülikooli bakalaureusetöös võrrelnud suuri keelemudeleid eesti bioloogiaolümpiaadi küsimuste põhjal ning leidnud, et parim mudel saavutas 85,35% täpsuse, mis on võrreldav olümpiaadiosalejate tiptulemusega – see kinnitab mudelite kasvavat võimekust ka eestikeelsetes ainespetsiifilistes ülesannetes.

2.3 AI akadeemilises kirjutamises

Tehisintellekti kasutamine akadeemilises kirjutamises on muutunud laialdaselt arutatavaks teemaks. Liang et al. [21] leidsid, et AI-genereeritud teksti osakaal teadusartiklites on märkimisväärselt kasvanud, eriti arvutiteaduse ja meditsiini valdkonnas. See tõstatab küsimusi akadeemilise aususe, originaalsuse ja kvaliteedikontrolli kohta.

Mitmed ülikoolid, sealhulgas Tartu Ülikool, on kehtestanud juhised AI kasutamiseks akadeemilises töös [3]. Üldiselt on lubatud kasutada AI-d abivahendina, kuid üliõpilane peab selgelt märkima, millises ulatuses ja millisel eesmärgil AI-d kasutati. Lõputöö ei tohi olla sisuliselt AI-genereeritud, vaid üliõpilane peab demonstreerima iseseisvat analüütilist mõtlemist.

Rodafinos [22] rõhutab, et generatiivsete AI tööriistade vastutustundlik integreerimine akadeemilisse kirjutamisse on hädavajalik, tuues esile nii efektiivsuse kasvu kui ka kvaliteedi paranemise, kuid rõhutades samas AI väljundite kontrollimise ja inimese kriitilise järelevalve säilitamise vajadust. Lund et al. [23] leidsid 401 USA üliõpilase küsitluses, et tudengite eetilised veendumused – mitte institutsionaalsed poliitikad – on tugevaim ennustaja AI kasutamise tajumisel akadeemilise väärkäitumisena.

Varasemad uurimused on näidanud, et AI mudelid on eriti kasulikud järgmistes akadeemilise kirjutamise aspektides:

- **Teksti struktureerimine** – AI suudab luua hästi struktureeritud tekstikavandeid ja peatükkide ülesehitust [24].
- **Kirjanduse ülevaade** – mudelid suudavad kokku võtta ja sünteesida olemasolevat kirjandust, kuigi allikate täpsus vajab kontrollimist [25].
- **Keeleline toimetamine** – AI on efektiivne grammatika-, stiili- ja sõnastusparanduste tegemisel [26].
- **Tõlkimine** – mudelid suudavad pakkuda rahuldava kvaliteediga tõlkeid akadeemilisest tekstist [27].

Samas on tuvastatud olulisi puudujääke:

- **Hallutsinatsioonid** – mudelid võivad genereerida faktiliselt valesid väiteid või olematud viiteid [28]. Mugaanyi et al. [29] leidsid, et ChatGPT genereeritud viidetest olid 72,7% loodusteadustes ja 76,6% humanitaarteadustes küll olemasolevad, kuid DOI-de täpsus oli vaid 32,7% ja 8,5% vastavalt. Chelli et al. [30] näitasid, et GPT-3.5, GPT-4 ja

Bard hallutsineerisid viiteid vastavalt 39,6%, 28,6% ja 91,4% juhtudest. Kim et al. [31] tuvastasid, et hallutsinatsioonimäärad on geograafiliselt ebavõrdsed – madalama sissetulekuga riikide kontekstis ületas DOI hallutsinatsioonimäär 80%.

- **Sisuline sügavus** – AI-genereeritud tekstid kipuvad olema pealiskaudsed ja kordavad üldtuntud seisukohti [32].
- **Originaalsus** – mudelid ei loo uusi teadmisi, vaid kombineerivad olemasolevat informatsiooni [33].
- **Väikeste keelte spetsiifika** – eesti keele ja teiste väikeste keelte puhul on kvaliteet oluliselt madalam [34].

2.4 Tartu Ülikooli lõputööde nõuded

Tartu Ülikooli arvutiteaduse instituudi lõputööde juhend [3] sätestab detailsed nõuded nii töö struktuurile, vormistusele kui ka sisule. Bakalaureusetöö soovitatav maht on 20–40 lehekülge ning töö peab sisaldama sissejuhatust, kirjanduse ülevaadet, metoodika kirjeldust, tulemuste esitlust, arutelu ja kokkuvõtet.

Vormistuse osas nõutakse Times New Roman fonti suurusega 12pt, reavahega 1,5 ning veeriste laiusega 2,54 cm igalt poolt. Viitamisüsteem peab olema ühtlane ja vastama valitud stiilile (IEEE, ACM, APA vms). Joonised ja tabelid peavad olema nummerdatud ja viidatud tekstist.

LOTE lõputööde juhend [35] lisab täiendavaid nõudeid seoses AI kasutamisega: üliõpilane peab lõputöös deklareerima, milliseid AI vahendeid ta kasutas, millises töö osas ja millises ulatuses. See nõue on eriti asjakohane käesoleva uurimuse kontekstis, kus AI kasutamine on töö enda uurimisobjekt.

3. Metoodika

Käesolev peatükk kirjeldab uurimuse metoodikat, sealhulgas AI mudelite valiku kriteeriume, eksperimentide ülesehitust, sisendi ettevalmistamist ning hindamiskriteeriumeid.

3.1 Mudelite valiku kriteeriumid

Uurimuse jaoks mudelite valimisel lähtuti järgmistest kriteeriumidest:

1. **Eesti keele tugi** – mudel peab suutma genereerida grammatiliselt korrektset eesti keelt ning mõistma eestikeelset sisendit.
2. **Kontekstiakna suurus** – bakalaureusetöö genereerimine eeldab mahuka konteksti (juhendid, näidistööd, varasemalt genereeritud osad) töötlemist, mistõttu on vajalik piisavalt suur kontekstiaken.
3. **Kättesaadavus ja dokumentatsioon** – mudel peab olema kättesaadav API kaudu või veebirakendusena ning omama piisavat dokumentatsiooni.
4. **Hind** – mudeli kasutamine peab olema majanduslikult mõistlik üliõpilase jaoks.
5. **Ajakohasus** – mudel peab olema üks uuemaid versioone (2025–2026).

Nende kriteeriumide alusel valiti neli mudelit: Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ning Anthropic Claude Opus 4.6. Opus 4.6 lisati võrdlusse kui sama mudeliperekonna võimekaim mudel, et hinnata mudeli suuruse mõju genereeritud teksti kvaliteedile. Valiku põhjendused on esitatud peatükis 4.

3.2 Eksperimentide ülesehitus

Eksperimendid viidi läbi kolmes etapis:

Etapp 1: Konteksti ettevalmistamine. Esmalt koostati igale mudelile antav kontekstipõhi, mis sisaldas:

- TÜ ATI lõputööde juhendi põhilised nõuded (struktuur, vormistus, hindamiskriteeriumid);
- LOTE lõputööde juhendi olulised lõigud;
- kolme varasema, hinnetega “A” või “B” hinnatud bakalaureusetöö sissejuhatused ja kokkuvõtted;
- eestikeelse akadeemilise stiili näited ja terminoloogia.

Etapp 2: Genereerimine. Iga mudeli puhul genereeriti järgmised lõputöö komponendid:

- sissejuhatus (ca 2 lehekülge);
- kirjanduse ülevaate peatükk (ca 5–8 lehekülge);
- metoodika kirjeldus (ca 3–5 lehekülge);
- tulemuste peatükk koos tabelite ja joonistega (ca 5–8 lehekülge);
- kokkuvõte (ca 1–2 lehekülge).

Genereerimine toimus iteratiivselt: esmalt anti mudelile ülesande kirjeldus koos kontekstiga, seejärel paluti genereerida vastav osa. Vajadusel kasutati järelküsimusi (*follow-up prompts*) teksti täiendamiseks ja parandamiseks.

Lisaks üksikute peatükkide genereerimisele viidi läbi ka tervikliku lõputöö genereerimise eksperiment (eksperiment 6, vt peatükk 5.8), kus igale mudelile anti ülesandeks genereerida täielik eestikeelne bakalaureusetöö. Gemini 3.1 Pro, GPT-5.4 ja Claude Sonnet 4.6 puhul kasutati tavapärasest vestlusliidest, samas kui Claude Opus 4.6 puhul kasutati Claude Code'i agentset tööriista (vt peatükk 7), mis võimaldas mudelil otse L^AT_EX faile kirjutada, kompileerida ja hallata. See eksperiment oli kavandatud hindamaks mudelite võimekust järgida keerulisi, mitmeosalisi juhiseid ning säilitada keelelist ja sisulist järjepidevust pikema teksti ulatuses.

Etapp 3: Hindamine. Genereeritud tekstid hindas käesoleva bakalaureusetöö autor mitme kriteeriumi alusel (vt alamlõik 3.4).

3.3 Sisendi ettevalmistamine ja promptide disain

Promptide (viipade) disain on AI-põhise tekstigenerereerimise üks kriitilisemaid aspekte. Serikov ja Biloshchytskyi [36] on näidanud, et promptismeetodid mõjutavad oluliselt genereeritud sisu kvaliteeti: *few-shot* õppimine töötas kõige paremini eesmärkide genereerimiseks, samas kui ahelpõhjendamine (*chain-of-thought*) oli efektiivsem professionaalsete standardite jaoks. Kresevic et al. [37] leidsid, et konteksti struktureeritud vormindamine ja kvaliteetne sisend parandasid GPT-4 Turbo täpsust oluliselt rohkem kui näidete hulga suurendamine, rõhutades andmekvaliteedi ülekaalu andmekoguse ees. Uurimuses kasutati kahte peamist lähenemist:

Nullkonteksti viibimine (*zero-shot prompting*) – mudelile antakse ülesanne ilma näideteta:

“Kirjuta Tartu Ülikooli arvutiteaduse bakalaureusetöö sissejuhatus teemal X. Sissejuhatus peab olema 2 lehekülge pikk, akadeemilises stiilis ning sisaldama viiteid.”

Kontekstipõhine viibimine (*few-shot prompting with context*) – mudelile antakse koos ülesandega ka juhendid ja näited:

“Järgnevalt on esitatud TÜ ATI lõputööde juhendi nõuded: [juhend]. Siin on näide heast bakalaureusetöö sissejuhatusest: [näide]. Kirjuta sarnases stiilis sissejuhatus teemal X.”

Mõlema lähenemise tulemusi võrreldi, et hinnata konteksti mõju genereeritud teksti kvaliteedile.

Lisaks katsetati ka süsteemiviipadega (*system prompts*), mille kaudu anti mudelile roll:

“Sa oled kogenud akadeemiline kirjutaja, kes on spetsialiseerunud eestikeelsete arvutiteaduse lõputööde kirjutamisele. Järgi Tartu Ülikooli vormistusnõudeid.”

3.4 Hindamiskriteeriumid

Genereeritud tekstide hindamiseks kasutati järgmist kriteeriumite raamistikku:

Tabel 1. Hindamiskriteeriumide raamistik

Kriteerium	Kirjeldus	Hindamisskaala
Struktuur	Teksti loogiline ülesehitus, peatükkide jaotus, sidusus	1–5 (1=puudub struktuur, 5=suurepärane)
Keeleline korrektsus	Grammatika, ortograafia, lauseehitus eesti keeles	1–5 (1=rohked vead, 5=peaaegu veatu)
Tehniline täpsus	Faktide, terminoloogia ja tehnilise sisu õigsus	1–5 (1=rohked vead, 5=täpne)
Akadeemiline stiil	Akadeemilisele tekstile vastav keel ja toon	1–5 (1=mitteakadeemiline, 5=suurepärane)
Viited	Viidete olemasolu, asjakohasus ja korrektsus	1–5 (1=puuduvad/valed, 5=korrektsed)
Praktiline väärtus	Teksti kasutatavus lõputöö alusena	1–5 (1=kasutuskõlbmatu, 5=valmis kasutamiseks)

Hindamise viis läbi käesoleva bakalaureusetöö autor (informaatika üliõpilane). Hinnangu stabiilsuse tagamiseks ja ühekordsest lugemisest tuleneva subjektiivsuse vähendamiseks vaatas autor iga genereeritud teksti läbi mitmel korral eri aegadel ning lõplik hinne kujunes nende iteratsioonide põhjal. Ühe hindaja kasutamise piirangut on täpsemalt käsitletud peatükis 6.

4. AI mudelite võrdlus

Käesolev peatükk esitab nelja valitud AI mudeli detailse võrdluse, hõlmates nende tehnilist arhitektuuri, võimekust, hinnastamist ja eesti keele tuge.

4.1 Google Gemini 3.1 Pro

Google Gemini 3.1 Pro on Google DeepMind'i arendatud multimodaalne keelemudel, mis avaldati 2026. aasta veebruaris [8]. Mudel kuulub Gemini mudeliperekonda, mis on Google'i vastus OpenAI GPT-seeriale.

4.1.1 Tehniline ülevaade

Gemini 3.1 Pro peamine eelis on selle ulatuslik kontekstiaken, mis ulatub kuni 1 miljoni tokenini. See võimaldab mudelile sisestada terve raamatu mahus teksti, mis on lõputöö genereerimise kontekstis äärmiselt kasulik – mudelile saab anda korraga nii juhendid, näidistööd kui ka juba genereeritud osad.

Gemini 3.1 Pro on natiivne mõtlemismudel (*thinking model*), mis tähendab, et mudel kasutab sisemist ahelpõhendamist enne vastuse andmist. See parandab oluliselt keeruliste ülesannete lahendamise kvaliteeti, sealhulgas struktureeritud teksti loomist.

4.1.2 Hinnastamine

Gemini 3.1 Pro kasutamine API kaudu (seisuga märts 2026):

- Sisendtokenid: \$2,00 / 1M tokenit (kuni 200K kontekstis)
- Sisendtokenid: \$4,00 / 1M tokenit (üle 200K kontekstis)
- Väljundtokenid: \$12,00 / 1M tokenit

Google AI Studio tasuta versioon võimaldab piiratud kasutust ilma kuluta, mis sobib eksperimenteerimiseks. Hinnanguliselt kulub 40-leheküljelise lõputöö täielikuks genereerimiseks ca 500 000 väljundtokenit ja ca 2 000 000 sisendtokenit (arvestades iteratiivset protsessi), mis teeb kogukuluks API kaudu ca \$8–\$14.

4.1.3 Eesti keele tugi

Gemini 3.1 Pro toetab eesti keelt, kuid selle kvaliteet jääb inglise keelele alla. Meie testides ilmnes, et mudel suudab luua grammatiliselt üldiselt korrektset eesti keelt, kuid esineb probleeme:

- Käändelõppude vead, eriti pikemates lausetes;

- Tehniline terminoloogia on kohati ebajärjekindel (nt vahetab “keelemudel” ja “keelemudel”, “suurandmed” ja “big data” vahel);
- Akadeemiline stiil kaldub olema liiga vaba, meenutades pigem blogipostitust;
- Tervikliku lõputöö genereerimisel kaldus mudel etteantud teemast kõrvale, genereerides töö teistsuguse teema kohta (vt peatükk 5.8).

4.2 OpenAI GPT-5.4

OpenAI GPT-5.4 on OpenAI juhtiv multimodaalne mudel, mis avaldati 2025. aasta detsembris ning mida on pidevalt täiendatud [7]. Mudel ühendab teksti, pildi ja heli töötlemise ühtsesse arhitektuuri.

4.2.1 Tehniline ülevaade

GPT-5.4 kontekstiaken ulatub kuni 1 000 000 tokenini, mis on võrreldav Gemini 3.1 Pro omaga ja pakub piisavat mahutavust ka kõige mahukamate lõputöö genereerimise stsenaariumide jaoks. OpenAI positsioneerib GPT-5.4 mudelina, mis on optimeeritud professionaalseks tööks parandatud arutluskäigu, tööriistade kasutamise ja dokumentide töövoogudega.

Märkimisväärne on GPT-5.4 sissehitatud ohutussüsteem: meie eksperimentides keeldus mudel genereerimast terviklikku lõputööd, viidates akadeemilise aususe piirangutele (vt peatükk 5.8). Selle asemel pakkus mudel teostatavusjuhendit inglise keeles. See käitumine viitab tugevale “*alignment*” koolitusele, mis piirab mudeli kasutamist akadeemilises kontekstis. Bianchi et al. [38] on dokumenteerinud sarnast “liialdatud ohutuskäitumist”, kus ohutuskoolitusega mudelid keelduvad täiesti ohututest ülesannetest, mis pealiskaudselt sarnanevad potentsiaalselt kahjulikele.

4.2.2 Hinnastamine

GPT-5.4 hinnastamine API kaudu (seisuga märts 2026):

- Sisendtokenid: \$1,75 / 1M tokenit
- Väljundtokenid: \$14,00 / 1M tokenit
- Vahemälus (*cached*) sisendtokenid: \$0,175 / 1M tokenit

ChatGPT Plus tellimus (\$20/kuu) võimaldab piiratud kasutust veebirakenduse kaudu. Lõputöö genereerimise kogukuluks API kaudu saab hinnata ca \$8–\$14, sõltuvalt iteratsioonide arvust.

GPT-5.4 Pro mudeli hinnastamine on oluliselt kallim:

- Sisendtokenid: \$21,00 / 1M tokenit
- Väljundtokenid: \$168,00 / 1M tokenit

See teeb GPT-5.4 Pro mudeli kasutamise mahuka teksti genereerimiseks ebapraktiliseks.

4.2.3 Eesti keele tugi

GPT-5.4 eesti keele tugi on lühikestes generatsioonides hea kvaliteediga, kuid pikemate akadeemiliste tekstide genereerimisel ilmnes oluline piirang: tervikliku lõputöö genereerimisel valis mudel väljundkeeleks inglise keele, mitte eesti keele, vaatamata selgesõnalisele eestikeelsele promptile. See viitab sellele, et mudeli ohutusfilter või juhiste hierarhia eelistab inglise keelt keerulisemate akadeemiliste ülesannete puhul. Lühikeste eestikeelsete tekstilõikude genereerimisel on GPT-5.4 keeleline kvaliteet siiski hea:

- Grammatiliselt korrektne eesti keel lühikestes tekstides;
- Tendents kasutada ingliskeelseid termineid seal, kus eestikeelne vaste on olemas;
- Tervikliku töö genereerimisel keeldub eesti keeles kirjutamast, viidates akadeemilise aususe piirangutele;
- Viidete genereerimisel esineb hallutsinatsioonid (olematud artiklid ja autorid).

4.3 Anthropic Claude Sonnet 4.6

Anthropic Claude Sonnet 4.6 on Anthropic'i arendatud keelemudel, mis avaldati 2026. aasta veebruaris [9]. Claude mudeliperekond eristub teistest oma rõhuasetusega ohutusele ja põhjalikkusele.

4.3.1 Tehniline ülevaade

Claude Sonnet 4.6 kontekstiaken on 200 000 tokenit (beetas 1 miljon tokenit), mis jääb Gemini 3.1 Pro ja GPT-5.4 vahele. Mudeli peamine tugevus on pikaajalise konteksti efektiivne kasutamine – uuringud on näidanud, et Claude suudab kontekstiakna lõpust informatsiooni sama hästi kasutada kui algusest [9].

Anthropic pakub ka Claude'i pikendatud mõtlemisrežiimi, kus mudel kasutab kuni 128 000 tokenit sisemiseks arutluseks (sama piir kehtib ka GPT-5.4 ja Claude Opus 4.6 puhul). See režiim on eriti kasulik keeruliste struktureeritud ülesannete jaoks, nagu akadeemilise teksti genereerimine.

Claude'i eristab teistest mudelitest ka tema võimekus järgida detailseid juhiseid ja stiilireegleid. Meie testides näitas Claude kõige paremat tulemust juhendipõhise genereerimise ülesannetes, kus mudelile anti ette konkreetseid struktuurinõuded.

4.3.2 Hinnastamine

Claude Sonnet 4.6 hinnastamine API kaudu (seisuga märts 2026):

- Sisendtokenid: \$3,00 / 1M tokenit
- Väljundtokenid: \$15,00 / 1M tokenit
- Vahemälus sisendtokenid: \$0,30 / 1M tokenit
- Vahemälus kirjutamine: \$3,75 / 1M tokenit

Claude Pro tellimus (\$20/kuu) võimaldab piiratud kasutust veebirakenduse kaudu. API kasutamise kogukuluks lõputöö genereerimisel saab hinnata ca \$10–\$18.

4.3.3 Eesti keele tugi

Claude Sonnet 4.6 eesti keele tugi on hea, kuid mõningate eripäradega:

- Mudel järgib eesti keele grammatikareegleid üldiselt hästi;
- Akadeemiline stiil on kolmest mudelist kõige lähedasem soovitule;
- Siiski esineb kohati ülemäärast keerukust lauseehituses, mis muudab teksti raskesti loetavaks;
- Tehniline terminoloogia on ühtlasem kui teistel mudelitel.

4.4 Anthropic Claude Opus 4.6

Anthropic Claude Opus 4.6 on Anthropic'i kõige võimekam keelemudel, mis avaldati 2026. aasta veebruaris [10]. Opus kuulub samasse Claude mudeliperekonda kui Sonnet, kuid on oluliselt suurem ja võimekam mudel, mis on optimeeritud keeruliste, mitmeosaliste ülesannete lahendamiseks.

4.4.1 Tehniline ülevaade

Claude Opus 4.6 kontekstiaken on 1M tokenit, kuid mudeli peamine eelis seisneb suuremas parameetrite arvus ja sügavamas arutlusvõimekuses. Opus mudelid on Anthropic'i mudeliperekonna tippasemel, pakkudes kõige paremat tulemust keerulistes struktureeritud

ülesannetes, nagu pikaajaline teksti genereerimine, koodide kirjutamine ja mitmesammuline probleemilahendus [10].

4.4.2 Hinnastamine

Claude Opus 4.6 hinnastamine API kaudu (seisuga märts 2026):

- Sisendtokenid: \$15,00 / 1M tokenit
- Väljundtokenid: \$75,00 / 1M tokenit
- Vahemälus sisendtokenid: \$1,50 / 1M tokenit
- Vahemälus kirjutamine: \$18,75 / 1M tokenit

Opus 4.6 on oluliselt kallim kui Sonnet 4.6 – väljundtokenid on 5 korda kallimad. See teeb Opus mudeli kasutamise mahuka teksti genereerimiseks kulukaks, kuid kvaliteedivõit võib seda kompenseerida. Hinnanguliselt kulub 40-leheküljelise lõputöö täielikuks genereerimiseks Opus 4.6-ga ca \$50–\$80 API kaudu.

Claude Max tellimus (\$100–200/kuu) võimaldab Opus mudeli piiratud kasutust veebirakenduse ja Claude Code'i kaudu.

4.4.3 Eesti keele tugi

Claude Opus 4.6 eesti keele tugi on nelja testitud mudeli seas parim:

- Grammatiliselt korrektne eesti keel ka pikkades ja keerulistes lausetes;
- Akadeemiline stiil on võrreldav emakeelt kirjutava omaga;
- Tehniline terminoloogia on ühtlane ja korrektne;
- Suudab vabalt genereerida tervikliku, 61-leheküljelise eestikeelse lõputöö ilma keelevahetuseta (vt peatükk 5.8);
- Lauseehitus on kõige loomulikum võrreldes teiste mudelitega.

4.5 Mudelite koondvõrdlus

Tabelis 2 on esitatud nelja mudeli koondvõrdlus peamiste parameetrite lõikes.

Tabelist on näha, et Gemini 3.1 Pro on keskmiselt kõige halvemate tulemustega. GPT-5.4 pakub ühtlast eesti keele kvaliteeti ja on hinna poolest konkurentsivõimeline. Claude Sonnet 4.6 eristub akadeemilise stiili ja juhendite järgimise poolest. Claude Opus 4.6 saavutab kõige kõrgema

Tabel 2. AI mudelite koondvõrdlus

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Kontekstiaken	1M	1,05M	200K (1M beetas)	1M
Max väljund	64 000	128 000	128 000	128 000
Mõtlemisrežiim	Jah (natiivne)	Jah (Pro eraldi)	Jah (pikendatud)	Jah (pikendatud)
Sisend \$/1M tok	\$2,00–4,00	\$1,75	\$3,00	\$15,00
Väljund \$/1M tok	\$12,00	\$14,00	\$15,00	\$75,00
Eesti keele kvaliteet	Hea	Väga hea	Väga hea	Suurepärane
Akad. stiil	Rahuldav	Hea	Väga hea	Suurepärane
Viidete kvaliteet	Rahuldav	Rahuldav	Hea	Hea

kvaliteedi nii eesti keele, akadeemilise stiili kui ka sisulise sügavuse osas, kuid on oluliselt kallim kui teised mudelid.

4.6 Mõtlemismudelite võrdlus

Eraldi väärrib tähelepanu mõtlemismudelite (*thinking/reasoning models*) mõju genereeritud teksti kvaliteedile. Mõtlemismudelid kasutavad sisemist ahelpõhjendamist, mis võtab lisaaega ja -ressursse, kuid parandab keerulisemate ülesannete tulemust. Ji et al. [39] on eksperimentaalselt näidanud, et ahelpõhjendamise strateegia parandab oluliselt nii teksti genereerimise kvaliteeti kui ka viidete täpsust, mis on eriti oluline akadeemilise teksti kontekstis.

Meie testides ilmnes, et mõtlemisrežiimi kasutamine:

- Parandas teksti loogilist struktureerimist ca 15–20%;
- Vähendas sisulisi vasturääkivusi oluliselt;
- Parandas viidete asjakohasust (kuigi hallutsinatsioone esines endiselt);
- Suurendas genereerimise aega 2–5 korda;
- Suurendas kulusid 1,5–3 korda.

Mõtlemisrežiimi kasutamine on soovituslik eriti sissejuhatuse, metoodika ja arutelu peatükkide genereerimisel, kus on vaja loogilist ja sidusat argumentatsiooni.

5. Eksperimendid ja tulemused

Käesolev peatükk kirjeldab läbiviidud eksperimente, esitab nende tulemused ning analüüsib nelja mudeli väljundite kvaliteeti erinevates lõputöö komponentides.

5.1 Eksperiment 1: Sissejuhatuse genereerimine

Esimese eksperimendi raames paluti igal mudelil genereerida bakalaureusetöö sissejuhatus teemal “Masinõppe rakendamine Eesti e-tervise andmete analüüsil”. Sissejuhatus pidi olema ca 2 lehekülge pikk, sisaldama taustakirjeldust, probleemipüstitust, eesmärki ja töö struktuuri ülevaadet.

5.1.1 Nullkonteksti tulemused

Ilma juhendite ja näideteta genereeritud sissejuhatused erinesid oluliselt kvaliteedilt. Tabelis 3 on esitatud autori antud hinded.

Tabel 3. Eksperiment 1: Sissejuhatuse hindamine (nullkontekst)

Kriteerium	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Struktuur	3,7	4,0	4,3	4,7
Keeleline korrektsus	3,3	4,0	3,7	4,3
Tehniline täpsus	3,0	3,3	3,3	3,7
Akadeemiline stiil	3,0	3,7	4,0	4,3
Viited	2,0	2,3	2,7	3,0
Praktiline väärtus	2,7	3,3	3,7	4,0
Keskmine	2,95	3,43	3,62	4,00

Peamised tähelepanekud nullkonteksti tulemuste kohta:

- Kõik mudelid löid struktuurselt korraliku sissejuhatuse, kuid keegi neist ei järginud spetsiifiliselt TÜ ATI nõudeid.
- Viidete kvaliteet oli kõigi mudelite puhul problemaatiline – ligikaudu 40–60% viidetest olid hallutsineeritud (olematud artiklid).
- Claude Sonnet 4.6 sai parima akadeemilise stiili hinnangu kolme algse mudeli seas, kuid Claude Opus 4.6 ületas seda kõigis kategooriates.

- Kõik mudelid vajasis keelelist toimetamist, kuigi Opus 4.6 vajas seda kõige vähem.

5.1.2 Kontekstipõhised tulemused

Pärast juhendite ja näidistöö sissejuhatuse sisestamist mudelitele paranesid tulemused märgatavalt. Tabelis 4 on esitatud kontekstipõhise genereerimise tulemused.

Tabel 4. Eksperiment 1: Sissejuhatuse hindamine (kontekstipõhine)

Kriteerium	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Struktuur	4,3	4,3	4,7	4,7
Keeleline korrektsus	3,7	4,3	4,0	4,7
Tehniline täpsus	3,7	3,7	4,0	4,3
Akadeemiline stiil	4,0	4,0	4,7	4,7
Viited	2,7	2,7	3,3	3,7
Praktiline väärtus	3,7	4,0	4,3	4,7
Keskmine	3,68	3,83	4,17	4,47

Konteksti lisamine parandas kõigi mudelite tulemusi keskmiselt 0,5–0,7 palli võrra. Eriti märgatav oli paranemine struktuuri ja akadeemilise stiili osas. Viidete kvaliteet paranes samuti, kuid jäi endiselt kõige nõrgemaks aspektiks. Claude Opus 4.6 saavutas kontekstipõhise genereerimisega kõrgeima keskmise hinde (4,47), ületades Sonnet 4.6 tulemust 0,30 palli võrra.

5.2 Eksperiment 2: Kirjanduse ülevaate genereerimine

Teine eksperiment keskendus kirjanduse ülevaate genereerimisele, mis on lõputöö üks keerulisemaid osi, kuna eeldab süstemaatilist viidete kasutamist ja allikate sünteesimist.

Mudelitele anti ette 10 teadusartikli kokkuvõtted ja paluti koostada nende põhjal struktureeritud kirjanduse ülevaade.

Kirjanduse ülevaate genereerimisel ilmnes oluline erinevus: kui mudelitele anti konkreetseid allikad ette, oli viidete kasutamine oluliselt täpsem kui mudeli enda leitud allikate puhul. See kinnitab, et AI mudeleid tasub kasutada allikate sünteesimiseks, kuid mitte allikate otsimiseks.

Gemini 3.1 Pro eeliseks oli siin suurem kontekstiaken, mis võimaldas sisestada rohkem artiklite täistekste. Claude Sonnet 4.6 paistis silma allikate omavahelise sünteesimise kvaliteediga, luues loogilisi seoseid erinevate uurimuste vahel.

Tabel 5. Eksperiment 2: Kirjanduse ülevaate hindamine

Kriteerium	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Struktuur	4,0	4,3	4,3	4,7
Keeleline korrektsus	3,3	4,0	3,7	4,3
Tehniline täpsus	3,7	3,3	4,0	4,3
Akadeemiline stiil	3,3	3,7	4,3	4,7
Viited	3,7	3,3	4,0	4,0
Praktiline väärtus	3,3	3,3	4,0	4,3
Keskmine	3,55	3,65	4,05	4,38

5.3 Eksperiment 3: Metoodika peatüki genereerimine

Kolmas eksperiment keskendus metoodika peatüki genereerimisele. Mudelitele anti ülesanne kirjeldada konkreetset uurimismetoodikat koos andmekogumise, -töötlemise ja analüüsi sammudega.

Tabel 6. Eksperiment 3: Metoodika peatüki hindamine

Kriteerium	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Struktuur	4,3	4,0	4,7	4,7
Keeleline korrektsus	3,3	3,7	3,7	4,3
Tehniline täpsus	3,3	3,3	3,7	4,0
Akadeemiline stiil	3,7	3,7	4,3	4,7
Viited	2,7	2,7	3,0	3,3
Praktiline väärtus	3,3	3,3	3,7	4,3
Keskmine	3,43	3,45	3,85	4,22

Metoodika peatüki genereerimisel olid mudelid ühtlasemad. Peamine probleem oli, et kõik mudelid kippusid genereerima liiga üldist metoodika kirjeldust, mis ei olnud piisavalt spetsiifiline konkreetse uurimuse jaoks. See on valdkond, kus inimese panus on eriti oluline – AI saab luua raamistiku, kuid konkreetsed metoodilised otsused peavad tulema uurijalt endalt.

5.4 Eksperiment 4: Tulemuste ja arutelu genereerimine

Neljas eksperiment testis mudelite võimekust genereerida tulemuste ja arutelu peatükke. Mudelitele anti ette fiktiivne andmestik (tabelid ja jooniste kirjeldused) ning paluti neid analüüsida ja interpreteerida.

Tabel 7. Eksperiment 4: Tulemuste ja arutelu hindamine

Kriteerium	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Struktuur	3,7	4,0	4,3	4,7
Keeleline korrektsus	3,3	3,7	3,7	4,0
Tehniline täpsus	3,0	3,0	3,3	4,0
Akadeemiline stiil	3,3	3,7	4,0	4,3
Viited	2,3	2,3	2,7	3,3
Praktiline väärtus	2,7	3,0	3,3	4,0
Keskmine	3,05	3,28	3,55	4,05

Tulemuste ja arutelu genereerimine osutus kõige keerulisemaks ülesandeks. Mudelid suutsid andmeid kirjeldada, kuid sügavam analüüs ja interpreteerimine jäi pealiskaudseks. Eriti problemaatiline oli tulemuste sidumine varasemate uurimustega arutelu osas.

5.5 Eksperiment 5: Kokkuvõtte genereerimine

Viies eksperiment testis kokkuvõtte genereerimist. Mudelitele anti ette varem genereeritud sissejuhatus ja tulemused ning paluti koostada töö kokkuvõte.

Kokkuvõtte genereerimine oli kõige edukam ülesanne. Kõik mudelid suutsid luua struktureeritud ja sisuliselt asjakohase kokkuvõtte, mis kattis töö peamised tulemused ja järeldused. See on ootuspärane, kuna kokkuvõte on suures osas varasema sisu ümbersõnastamine.

5.6 Tulemuste koondanalüüs

Joonisel 1 on esitatud kõigi eksperimentide keskmised tulemused mudelite lõikes.

Koondtulemuste põhjal saab teha järgmised järeldused:

Tabel 8. Eksperiment 5: Kokkuvõtte hindamine

Kriteerium	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Struktuur	4,3	4,3	4,7	4,7
Keeleline korrektsus	3,7	4,0	4,0	4,7
Tehniline täpsus	3,7	3,7	4,0	4,3
Akadeemiline stiil	4,0	4,0	4,7	4,7
Viited	3,0	3,0	3,3	3,7
Praktiline väärtus	4,0	4,0	4,3	4,7
Keskmine	3,78	3,83	4,17	4,47

Mudel	Exp 1	Exp 2	Exp 3	Exp 4–5	Kesk.
Gemini 3.1 Pro	3,68	3,55	3,43	3,42	3,52
GPT-5.4	3,83	3,65	3,45	3,56	3,62
Claude Sonnet 4.6	4,17	4,05	3,85	3,86	3,98
Claude Opus 4.6	4,47	4,38	4,22	4,26	4,33

Joonis 1. Eksperimentide keskmised tulemused (kontekstipõhine genereerimine)

1. **Claude Opus 4.6** saavutas kõigis eksperimentides kõrgeima keskmise hinde (4,05–4,47), olles ühtlaselt tugev kõigis kategooriates ning ületades teisi mudeleid eriti keelelise korrektsuse ja sisulise sügavuse poolest.
2. **Claude Sonnet 4.6** saavutas teise koha (3,86–4,17), olles eriti tugev akadeemilise stiili ja struktuuri osas ning pakkudes oluliselt paremat hinna-kvaliteedi suhet kui Opus.
3. **GPT-5.4** näitas ühtlast kvaliteeti kõigi eksperimentide lõikes (3,45–3,83), olles eriti tugev eesti keele grammatilise korrektsuse osas.
4. **Gemini 3.1 Pro** jäi keskmiste tulemuste poolest neljandaks (3,42–3,68), kuid kontekstiakna suurus andis talle eelise mahukama sisendi korral.
5. Kõigi mudelite puhul oli **viidete kvaliteet** läbivalt kõige nõrgem aspekt.
6. **Konteksti lisamine** parandas tulemusi keskmiselt 15–20%.

7. **Kokkuvõtte** genereerimine oli kõige edukam, **tulemuste arutelu** kõige keerulisem ülesanne.

5.7 Hinnangu stabiilsus ja subjektiivsus

Kuna hindamise viis läbi üks hindaja (autor), ei olnud võimalik mõõta hindajatevahelist kooskõla. Subjektiivsuse vähendamiseks vaatas autor iga genereeritud teksti läbi mitmel korral eri aegadel ning lõppskoor kujunes nende iteratsioonide põhjal. Iteratsioonide sisene varieeruvus oli suurim akadeemilise stiili ja praktilise väärtuse kriteeriumides, mis on oma olemuselt teistest kriteeriumidest subjektiivsemad. Ühe hindajaga uurimisülesehituse piiranguid on käsitletud peatükis 6.

5.8 Eksperiment 6: Tervikliku lõputöö genereerimine

Kuues eksperiment erines eelmistest kvalitatiivselt: igal mudelil paluti genereerida terviklik bakalaureusetöö informaatika valdkonnast. Mudelitele anti ette TÜ ATI ja LOTE juhendid, UniTartuCS $\LaTeX$ malli kirjeldus ning identne eestikeelne prompt, kuid konkreetset teemapealkirja ette ei antud – eesmärk oli hinnata, kas mudelid suudavad iseseisvalt valida sobiva informaatikateema ja luua tervikliku, esitamiskõlbliku dokumendi, mis vastab ülikooli nõuetele. Gemini 3.1 Pro puhul kasutati lisaks Google'i agentset tööriista Antigravity, mis on funktsionaalselt sarnane Claude Code'iga (vt peatükk 7).

Tulemused olid mudelite lõikes drastiliselt erinevad, nagu nähtub tabelist 9.

5.8.1 Claude Sonnet 4.6: Terviklik eestikeelne lõputöö

Claude Sonnet 4.6 genereeris mahuka väljundi – 40-leheküljelise eestikeelse dokumendi, mis järgis bakalaureusetöö struktuuri. See sisaldas detailseid hindamistabeleid viie eksperimendi tulemustega, promptide näiteid lisades ning AI kasutamise deklaratsiooni. Akadeemiline stiil oli tugev ja töö järgis etteantud teemat korrektselt. Peamised puudused olid mõned hallutsineeritud viited (ca 20%), kohati keeruline lauseehitus ning 13 tuvastatud kirjaviga kogu töö peale (vt peatükk 5.8.6), millest mõned asusid nähtaval kohal – näiteks alapealkirjas kaks korda esinenud *Masskiijutamine*.

5.8.2 GPT-5.4: Akadeemilise aususe keeldumine

GPT-5.4 tulem erines teistest fundamentaalselt. Mudel keeldus tavapärase vestlusliidese kaudu genereerimast terviklikku lõputööd, viidates otseselt akadeemilise aususe piirangutele. Väljundis selgitati, et täieliku bakalaureusetöö kirjutamine tudengi eest oleks vastuolus Tartu Ülikooli

Tabel 9. Eksperiment 6: Tervikliku lõputöö genereerimise tulemused

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Väljundkeel	Eesti	Inglise	Eesti	Eesti
Maht (lehekülgi)	39	8	40	61
Valitud teema	GenAI ja algajad progr.	Keeldus vastata	AI lõputöö gener.	Paroolihaldur
Struktuur	Lõputöö vormis	Juhendi vormis	Lõputöö vormis	Lõputöö vormis
Agentne tööriist	Antigravity	–	–	Claude Code
Viited	9, osaliselt kontrollitavad	Olemas, verifitseeritud	Osaliselt halluts.	Osaliselt halluts.
Akad. stiil	Hea	Hea (inglise k.)	Väga hea	Suurepärane

akadeemilise aususe reeglitega. Selle asemel pakkus GPT-5.4 välja 8-leheküljelise ingliskeelse teostatavusjuhendi (*feasibility guide*), mis sisaldas mudelivaliku soovitusi, eksperimendi disaini raamistikku, hindamismetoodikat ja $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ malli juhiseid. Kuigi juhend oli sisuliselt kvaliteetne ja viited olid kontrollitavad, ei vastanud see ülesande püstitusele: väljund oli inglise, mitte eesti keeles, ja vormilt pigem nõuandev memo kui akadeemiline lõputöö. See tulemus viitab GPT-5.4 tugevale ohutuskoolitusele (*alignment training*), mis piirab mudeli kasutamist akadeemilises kontekstis.

Täiendav katse OpenAI ChatGPT Codex laiendusega Visual Studio Code'i keskkonnas andis aga oluliselt erineva tulemuse: sama GPT-5.4 mudel suutis agentse tööriista kaudu genereerida visuaalselt teiste mudelite väljunditega sarnase tervikliku 47-leheküljelise eestikeelse dokumendi teemal “Eestikeelse RAG-põhise küsimus-vastus süsteemi kavandamine” (vt peatükk 7.5). See kinnitab, et agentsed tööriistad võivad aidata ületada mudeli ohutuskoolitusest tulenevaid piiranguid. Codex laienduse kaudu genereeritud töö oli ka eesti keele ortograafilise täpsuse poolest silmapaistev: kogu töö peale tuvastati vaid üks kirjaviga (*vastusevormingun* õige *vastusevormingu* asemel), mis on nelja mudeli seas parim tulemus (vt peatükk 5.8.6).

5.8.3 Gemini 3.1 Pro: Terviklik lõputöö Antigravity kaudu

Gemini 3.1 Pro genereeris Google'i agentse tööriista Antigravity kaudu 39-leheküljelise eestikeelse bakalaureusetöö teemal “Generatiivse tehisintellekti mõju tarkvaraarenduse produktiivsusele algajate programmeerijate seas”. Mudel valis iseseisvalt informaatika valdkonnast aktuaalse ja hästi piiritletud uurimisteema, mis käsitles suurte keelemudelite mõju programmeerimise õppimisele.

Genereeritud töö oli struktuuralselt terviklik ja sisaldas kõiki nõutud komponente: eesti- ja ingliskeelne kokkuvõte, sisukord, sissejuhatus uurimisküsimustega, taust ja kirjandusülevaade (Transformer-arhitektuur, kognitiivne koormus, *over-reliance*), metoodika (kvaasi-eksperimentaalne disain 30 tudengiga), tulemused (t-testid, statistilised tabelid), kokkuvõte ja viis lisa. Lisad olid ka hästi esitatud: React.js koodiredaktori komponent (ca 150 rida), PostgreSQL andmebaasi skeem (5 tabelit), Pandas/SciPy andmeanalüüsi skript (ca 160 rida) ning tudengite koodinäited koos vigade analüüsiga.

Töö tugevused olid järgmised:

- Akadeemilise struktuuriga hästi arvestatud: uurimisküsimused, hüpoteesid, statistilised testid;
- Eesti keele kvaliteet oli üldiselt arusaadav, kuigi esines mõningaid terminoloogilisi ebajärjekindlusi;
- Viited (9 allikat) kasutasid reaalse teadlaste nimesid (Becker, Kazemitabaar, Vaswani jt);
- Koodinäited lisades olid funktsionaalsed ja loogiliselt kirjutatud;
- Töö maht (39 lehekülge) vastas bakalaureusetöö nõuetele.

Peamised puudused olid siiski olulised:

- Kogu eksperiment (30 tudengit, testikeskkond, statistilised tulemused) oli mudeli poolt välja mõeldud – tegemist oli veenva, kuid täielikult fabritseeritud uurimusega;
- Viidete kontrollitavust vajab eraldi auditeerimist – kuigi autorite nimed on reaalsed, võivad konkreetsed artiklid olla hallutsineeritud;
- Eesti keele ortograafiline täpsus oli nelja mudeli seas kõige nõrgem – töös tuvastati 28 selget kirjaviga, sealhulgas tavasõnade valed vormid (*strukuure, kordinaadid, konfliktide*),

mittesõnad (*teoosiab*, *Tehisintsistendi*) ning valede tähtedega asendatud täpitähed (vt peatükk 5.8.6);

- Antigravity tööriist oli vajalik korraliku tulemuse saamiseks – varasemad katsed ilma agentse tööriistata andsid oluliselt nõrgema tulemuse.

5.8.4 Claude Opus 4.6: Terviklik tehniline lõputöö Claude Code'i kaudu

Claude Opus 4.6 genereeris nelja mudeli seas kõige ulatuslikuma ja kvaliteetsema väljundi – 61-leheküljelise eestikeelse bakalaureusetöö teemal “Turvalise paroolihalduri veebirakenduse arendamine” [10]. Opus 4.6 puhul kasutati Claude Code'i agentset tööriista (vt peatükk 7), mis võimaldas mudelil otse kirjutada $\text{L}^{\text{T}}\text{E}^{\text{X}}$ faile, hallata viiteid ja kompileerida dokumenti.

Genereeritud töö sisaldas terviklikku tehnilist arhitektuuri (nullteadmise põhimõte, AES-256-GCM krüpteering, Argon2id võtmetuletamine), täielikku React/TypeScript kasutajaliidest ja Node.js/Express taustarakendust, 149 automatiseeritud testi ning OWASP Top 10 turvaanalüüsi. Süsteemi kasutatavuse skaala (SUS) skoor oli 77,0 ja turvaaudit ei tuvastanud ühtegi kriitilist turvaauku.

Opus 4.6 tulemuse peamised erinevused võrreldes Sonnet 4.6-ga:

- Oluliselt suurem maht (61 vs 40 lehekülge), mis viitab sügavamale sisulisele käsitlusele;
- Tehniline täpsus oli kõrgem – töö sisaldas konkreetseid koodi- ja arhitektuurinäiteid;
- Eesti keele kvaliteet oli ühtlasem ja loomulikum ka pikemas tekstis – kogu 61-leheküljelise töö peale tuvastati vaid 5 kirjaviga (peamiselt pärisnimedes, nagu *Carnegei* ja *Californiya*), mis teeb kirjavigade tiheduseks 0,08 viga lehekülje kohta (vt peatükk 5.8.6);
- Viidete hallutsineerimise määr oli madalam (ca 15% võrreldes Sonnet 4.6 ca 20%).

5.8.5 Eksperimendi 6 järeldused

Tervikliku lõputöö genereerimise eksperiment tõi esile neli fundamentaalselt erinevat mudelikäitumist:

1. **Suurepärane tulemus** (Claude Opus 4.6): mudel genereeris Claude Code'i kaudu kõige mahukama (61 lk) ja tehniliselt sügavaima eestikeelse lõputöö, valides teemaks paroolihalduri arendamise.
2. **Tugev tulemus** (Claude Sonnet 4.6): mudel genereeris mahuka ja struktureeritud väljundi (40 lk), valides teemaks AI-põhise lõputöö genereerimise.

3. **Tugev tulemus agentse tööriistaga** (Gemini 3.1 Pro): mudel genereeris Antigravity tööriista kaudu tervikliku ja hästi struktureeritud töö (39 lk) koos veenva, kuid fabritseeritud eksperimendiga, valides teemaks GenAI mõju algajate programmeerijate produktiivsusele.
4. **Ohutuspõhine keeldumine, mis ületati agentse tööriistaga** (GPT-5.4): mudel keeldus tavapärase vestlusliidese kaudu ülesannet täitmast eetiliste kaalutluste tõttu, pakkudes selle asemel alternatiivse abivahendi inglise keeles. Hilisem katse ChatGPT Codex laiendusega Visual Studio Code'is näitas aga, et agentne töövoog võimaldas samal mudelil genereerida tervikliku dokumendi (vt peatükk 7.5).

Eriti tähelepanuväärne on agentsete tööriistade mõju tulemusele. Nii Claude Code (Opus 4.6 puhul) kui ka Google'i Antigravity (Gemini 3.1 Pro puhul) parandasid oluliselt genereerimise kvaliteeti, mahtu ja terviklikkust. Ilma agentse tööriistata olid Gemini 3.1 Pro varasemad katsed oluliselt nõrgemad, mis kinnitab, et agentne töövoog – kus mudel saab iseseisvalt faile hallata, projekti struktureerida ja iteratiivselt genereerida – annab oluliselt parema tulemuse kui tavapärane vestlusliidese-põhine genereerimine.

Kõik mudelid valisid iseseisvalt erineva informaatikateema, mis demonstreerib mudelite võimekust teemavalikul. Isegi kõige edukamad tulemused (Opus 4.6 ja Gemini 3.1 Pro) vajasisid siiski inimese järeltöötlust: viidete kontrolli, terminoloogia ühtlustamise ja fabritseeritud andmete tuvastamise osas. Genereeritud tööde väljavõtted on esitatud lisas 8.

5.8.6 Kirjavigade analüüs genereeritud töödes

Eesti keele kvaliteedi täpsemaks hindamiseks vaadati eraldi üle iga eksperimendis 6 genereeritud lõputöö kirjavead – see tähendab ortograafilised näpukad, valed tähed, puuduvad või liigsed tähed, sõnade valed vormid ning pärisnimede vead. Analüüsist jäeti välja kontekstis korrektsed, kuid stiililiselt ebaõnnestunud laused, samuti vead, mis ilmnesisid üksnes PDF-ist teksti ekstraheerimise kodeeringuarterfaktidena. Tabelis 10 on esitatud kirjavigade koondarv iga töö kohta ning arvestuslik tihedus lehekülje kohta.

Tulemused näitavad nelja mudeli vahel märkimisväärset erinevust eesti keele ortograafilise täpsuse osas. GPT-5.4 Codex laienduse kaudu genereeritud töös tuvastati kogu 47-leheküljelise dokumendi peale vaid üks selge kirjaviga (*vastusevormingun* õige *vastusevormingu* asemel). Claude Opus 4.6 töös esinesid peamised vead pärisnimedes (*Carnegei*, *Californiya*, *kanada* suurtähe puudumine) ning kahes tavasõnas (*juhusiku*, *stsenaariumm*), kokku viis juhtumit 61 lehekülje peale.

Tabel 10. Eksperimendis 6 genereeritud tervikliku lõputöö kirjavigade koondarv

Mudel	Maht (lk)	Kirjavigade arv	Kirjavigu lk kohta	Hinnang
Gemini 3.1 Pro (Antigravity)	39	28	0,72	Nõrk
Claude Sonnet 4.6 (Cowork)	40	13	0,33	Keskmine
Claude Opus 4.6 (Cowork)	61	5	0,08	Hea
GPT-5.4 (Codex)	47	1	0,02	Väga hea

Claude Sonnet 4.6 töös leidis ortograafiliselt problemaatilisi sõnu rohkem: alapealkirjas kaks korda esinenud *Masskijutamine* (õige *Masskirjutamine*), lühendite tabelis *märkimisviis*, ning veel mitu üksikut näpukat (*kommertsiaalrsed*, *rakenuste*, *kasutusscenaariumide*, *verstapostverstapost*). Osa vigadest asus eriti nähtaval kohal – näiteks alapealkirjas või lühendite tabelis – mis vähendab töö esmamuljet.

Kõige rohkem kirjavigu sisaldas Gemini 3.1 Pro genereeritud töö, kus 39 lehekülje kohta tuvastati 28 selget kirjaviga. Vead jagunesid nelja põhikategooriasse: puuduvate või vahetatud tähtedega tavasõnad (*strukuure*, *kordinaadid*, *vektorruumi*, *konfliktide*, *sepsifiliste*, *paering*, *paringud*, *uenit*, *ekponentvõimendi*, *hariduteadusele*), valede tähtedega asendatud täpitähed (*Öleksin* õige *Oleksin* asemel, *Üsaldan* õige *Usaldan* asemel, *Över-Reliance*, *moita*), moodustatud mittesõnad (*teoosiab*, *esitlustuppu*, *Tehisintsistendi*, *algasestatud*), ning ingliskeelse konventsiooniga termini *biljonite* kasutamine eesti keeles sobiva *miljardite* asemel. Lisaks esines üks pärisnime viga (*Düning-Krugi* õige *Dunning-Krugi* asemel).

Kirjavigade tihedus korreleerus hästi üldise kvaliteedihinnanguga: kõige madalamat kirjaviga lehekülje kohta näitas GPT-5.4 (agentse tööriista kaudu) ning Claude Opus 4.6, mis ühtib eksperimentide 1–5 keelelise korrektsuse hinnangutega. Gemini 3.1 Pro suurem vigade arv viitab, et Antigravity tööriist aitas küll mahtu ja struktuuri parandada, kuid ei suutnud täielikult kompenseerida mudeli nõrkemat eesti keele ortograafiat. See tulemus rõhutab, et automaatse korrektuuri tööriista (nt *aspell*, *hunspell*, *JVKS*) või täiendava keelelise toimetamise etapp on AI-ga genereeritud tekstide puhul vältimatu – eriti mudelite korral, mille treeningandmetes on eesti keele osakaal väiksem.

5.8.7 Mahu ja struktuuri analüüs

Lisaks kirjavigadele uuriti iga genereeritud töö mahtu ja sisemist struktuuri. Mahu hindamiseks loeti kokku kogu PDF-failist eraldatud sõnad (sealhulgas tekst, tabelite sisu, lisad ja viited)

ning arvutati välja sõnade arv lehekülje kohta. Struktuuri hindamiseks loendati nummerdatud alapeatükkide, tabelite, jooniste ja koodinäidete arv kogu töös. Tulemused on esitatud tabelis 11.

Tabel 11. Eksperimendis 6 genereeritud tööde maht ja struktuurielemendid

Mudel	Lk	Sõnu	Sõnu/lk	Alapt.	Tab.	Joon.
Gemini 3.1 Pro	39	7 230	185	17	2	0
GPT-5.4 (Codex)	47	9 669	206	40	8	2
Claude Sonnet 4.6	40	9 739	243	24	12	2
Claude Opus 4.6	61	10 749	176	25	11	3

Andmetest joonistuvad välja mitmed huvitavad mustrid. Kõige suurema mahu (10 749 sõna) genereeris ootuspäraselt Claude Opus 4.6, mille väljund hõlmas ka kõige rohkem jooniseid (3) ning kompaktselt jaotatud sisu (176 sõna lehekülje kohta – madalaim näitaja, mis tuleneb suuremast hulgast koodinäidetest, tabelitest ja diagrammidest). Claude Sonnet 4.6 paistis silma kõige tihedama tekstilise sisuga (243 sõna lehekülje kohta) ning sisaldas kõige rohkem tabelleid (12). GPT-5.4 (Codex) genereeris kõige granulaarsema struktuuriga töö – 40 alapeatükki 47 lehekülje peale, mis viitab põhjalikule sisujaotusele. Gemini 3.1 Pro maht oli väikseim (7 230 sõna), kõige vähemate alapeatükkidega (17), mis viitab pinnapealsemale käsitlusele.

Eraldi tasub märkida, et Gemini 3.1 Pro töös ei kasutatud ühtegi joonist (ainult tabelleid ja koodinäiteid), mis on bakalaureusetöö kontekstis ebatavaline – enamik tehnilisi lõputöid sisaldab arhitektuuriskeeme või andmevoo diagramme. Sonnet 4.6 ja Gemini 3.1 Pro eelistasid suuremas mahus koodinäidete (Listings) lisamist (vastavalt 7 ja 5 koodinäidet), samas kui Opus 4.6 ja GPT-5.4 integreerisid koodinäited tihedamalt teksti sisse, ilma neid eraldi nummerdatud koodinäidete plokkidena vormistamata.

5.8.8 Viidete kvantitatiivne analüüs

Akadeemilise töö üks olulisi kvaliteedinäitajaid on viidete kasutamise tihedus ja allikate hulk. Iga töö kohta loeti kokku kasutatud viidete koguarv (kirjanduse loendis esitatud unikaalsed allikad), tekstis tehtud tsitaatide arv ($[N]$ tüüpi viidete esinemiskorrad enne kirjanduse loendit) ning arvutati tsitaatide tihedus lehekülje kohta. Tulemused on esitatud tabelis 12.

Tulemused näitavad, et Claude Opus 4.6 lisas kõige rohkem viiteid (35 unikaalset allikat ja 45 in-text tsitaati), saavutades ka kõrgeima tsitaaditiheduse 0,74 tsitaati lehekülje kohta. See vastab paroolihalduri valdkonna iseloomule, kus on vaja viidata krüptograafilistele standarditele (NIST,

Tabel 12. Eksperimendis 6 genereeritud tööde viidete analüüs

Mudel	Unikaalseid viiteid	In-text tsitaate	Tsitaate lk kohta	Tsitaadi/viite suhe
Gemini 3.1 Pro	9	13	0,33	1,44
Claude Sonnet 4.6	17	23	0,58	1,35
GPT-5.4 (Codex)	22	28	0,60	1,27
Claude Opus 4.6	35	45	0,74	1,29

IETF RFC), turvauuringutele ja olemasolevatele lahendustele. GPT-5.4 (22 viidet) ja Claude Sonnet 4.6 (17 viidet) jäid keskmisesse vahemikku. Gemini 3.1 Pro paistis silma väikseima viidete arvuga (9 unikaalset allikat 39 lehekülje peale), mis on bakalaureusetöö kontekstis tagasihoidlik – TÜ ATI juhend soovib tüüpilisele bakalaureusetööle vähemalt 15–25 allikat. See näitaja kinnitab eksperimendis 6 tehtud tähelepanekut, et Gemini 3.1 Pro genereeritud töö oli pigem mahukas-fabritseeritud kui allikatega põhjendatud.

Tsitaadi/viite suhe (in-text tsitaate jagatud unikaalsete allikate arvuga) näitab, mitu korda iga allikat keskmiselt korduvalt kasutati. Kõik mudelid jäid 1,27–1,44 vahemikku, mis viitab sellele, et enamikku allikaid kasutati tekstis vaid 1–2 korda. See on bakalaureusetööde puhul tüüpiline näitaja. Oluline on siiski rõhutada, et see analüüs ei hinda viidete *sisulist* korrektsust ega kontrollitavust – vt eksperimendis 6 tehtud märkused viidete hallutsineerimise kohta.

5.8.9 Anglitsismide ja eesti keele puhtuse analüüs

Eestikeelse akadeemilise teksti üks kvaliteedinäitajaid on tõlkimata jäetud või eesti keele konventsioonidest erinevate ingliskeelsete terminite vähene esinemine. Analüüsi raames loendati kahte tüüpi anglitsisme: (1) ingliskeelsed sõnad, millele on lisatud eestikeelse käändelõpu eraldamiseks ülakoma (näiteks *benchmark'il*, *Google'i*), ning (2) tüüpilised arvutiteaduse tehnilised inglise terminid, mida võiks eesti keeles edastada (näiteks *over-reliance*, *prompt*, *pipeline*, *benchmark*). Analüüsist jäeti välja koodinäited ja kirjanduse loend. Tulemused on esitatud tabelis 13.

Anglitsismide analüüs annab täiendava nüansi eesti keele kvaliteedihinnangule. Claude Sonnet 4.6 paistis silma kõige puhtama eestikeelse tekstiga – vaid 5 anglitsismi kogu töö peale (0,13 lehekülje kohta), eelistades enamasti eestikeelseid termineid (näiteks *partii* ingl. *batch* asemel, *päring* ingl. *query* asemel). GPT-5.4 ja Claude Opus 4.6 olid keskmisel tasemel, kasutades selliseid termineid kontrollitult ja sageli koos eestikeelse selgitusega sulgudes. Gemini 3.1 Pro

Tabel 13. Eksperimendis 6 genereeritud tööde anglitsismide analüüs

Mudel	Ülakomaga anglitsisme	CS-anglitsisme tekstis	Anglitsisme/lk
Claude Sonnet 4.6	4	1	0,13
GPT-5.4 (Codex)	9	11	0,43
Claude Opus 4.6	5	25	0,49
Gemini 3.1 Pro	7	22	0,74

kasutas anglitsisme kõige rohkem (0,74 lehekülje kohta), sealhulgas mõnikord paralleelselt nii eesti- kui ingliskeelseid vasteid (näiteks *äärejuht* (*ingl. edge case*)), mis on iseenesest hea akadeemiline tava, kuid sage kasutamine vähendab teksti loomulikkust.

Huvitav on, et Opus 4.6 suhteliselt suur CS-anglitsismide arv (25) tuleneb peamiselt krüptograafilise valdkonna spetsiifikast – terminid nagu *salt*, *nonce*, *hash*, *token* on rahvusvahelistes standardites tavapärased ning nende eestikeelsed vasted (sool, ühekordne väärtus, räsi, tõend) ei ole alati ühelt tähenduselt üheselt rakendatavad. Sonnet 4.6 PostgreSQL/MongoDB teema vältis seda probleemi, kuna andmebaaside terminoloogias on eesti keeles palju välja kujunenud vasteid (*kirje*, *väli*, *indeks*, *tehing*).

5.8.10 Akadeemilise stiili indikaatorid

Eestikeelses akadeemilises kirjutamises eelistatakse umbisikulist stiili (passiivi ja umbisikulist tegumoodi) ning välditakse esimese isiku ainsuse (*ma*, *mina*) ja mitmuse (*me*, *meie*) kasutamist. Iga genereeritud töö puhul loendati esimese isiku asesõnade (*ma*, *mina*, *me*, *meie*, *meil*, *meid*, *minu*) esinemine peamises tekstis (välja arvatud litsents ja autorluse kinnitus). Tulemused on esitatud tabelis 14.

Tabel 14. Esimese isiku asesõnade kasutus genereeritud töödes

Mudel	Esimese isiku asesõnu	Hinnang
Claude Opus 4.6	0	Suurepärane
GPT-5.4 (Codex)	2	Suurepärane
Claude Sonnet 4.6	2	Suurepärane
Gemini 3.1 Pro	4	Hea

Kõik neli mudelit järgisid eestikeelset akadeemilist stiili väga hästi: esimese isiku asesõnu kasutati minimaalselt (0–4 esinemist kogu töö peale). Claude Opus 4.6 ei kasutanud ühtegi esimese isiku asesõna terve 61-leheküljelise töö peale, mis on ideaalne tulemus. Gemini 3.1 Pro neli esinemist on samuti vastuvõetav, kuid mõnevõrra kõrgem teistest. See näitab, et tänapäevased suured keelemudelid on eesti akadeemilise stiili konventsioonid hästi õppinud, mis on kooskõlas peatükis 6.1 esitatud üldise hinnanguga AI mudelite akadeemilise stiili oskusele.

6. Arutelu

Käesolev peatükk arutleb eksperimentide tulemuste üle laiemas kontekstis, käsitleb AI kasutamise praktilisi aspekte, piiranguid ja annab soovitusi.

6.1 AI tugevused lõputöö kirjutamisel

Eksperimentide tulemused kinnitavad, et kaasaegsed AI mudelid suudavad pakkuda märkimisväärset abi lõputöö kirjutamise protsessis. Claude Opus 4.6 demonstreeris eriti veenvalt, et tiptasemel mudel koos agentse tööriistaga (Claude Code) suudab genereerida tervikliku, 61-leheküljelise eestikeelse lõputöö. Peamised tugevused jagunevad järgmiselt.

Struktureerimine ja kavandamine. AI mudelid on eriti tugevad teksti struktureerimisel. Kõik kolm testitud mudelit suutsid luua loogilise ja akadeemilistele nõuetele vastava peatükkide jaotuse. Eriti kasulik on AI kasutamine töö algaasis, kui üliõpilane vajab abi sisukorra ja peatükkide ülesehituse kavandamisel. Mudelid suudavad juhendite põhjal luua detailse sisukorra koos soovitusliku leheküljemahuga iga peatüki jaoks.

Mustandi loomine. AI suudab genereerida tekstimustandeid, mis on piisavalt hea kvaliteediga, et neid edasi töödelda. See kiirendab kirjutamisprotsessi oluliselt, kuna üliõpilane ei pea alustama tühjalt lehelt, vaid saab toimetada ja täiendada olemasolevat teksti. Esialgse kasutuskogemuse põhjal võib AI mustandi kasutamine säästa hinnanguliselt 50–80% kirjutamisele kuluvast ajast, kuigi täpse ajavõidu mõõtmine vajab edaspidi süstemaatilisi kasutajakatseid.

Keeleline toimetamine. Kõik neli mudelit suudavad efektiivselt teostada keelelist toimetamist – parandada grammatikavigu, parandada lauseehitust ja ühtlustada stiili. See on eriti väärtuslik eesti keele kontekstis, kus spetsiifilisi akadeemilise toimetamise teenuseid on vähe.

LaTeX-vormindamine. Oluline praktiline eelis on mudelite võimekus genereerida teksti otse LaTeX-vormingus, mis hõlmab korrektset viitamissüntaksit, tabeleid, jooniste viiteid ja matemaatilisi valemeid. See säästab üliõpilasele märkimisväärset vormistusaega. Võrdluseks, Microsoft Wordi puhul peab üliõpilane vormistuse – stiilid, ristviited, pealkirjade numeratsioon ja bibliograafia – enamasti käsitsi seadistama, kuna AI mudelid ei saa .docx faili sisemist struktuuri samamoodi manipuleerida nagu tekstipõhist LaTeX lähtekoodi. See teeb Wordi AI-toetatud akadeemilise kirjutamise kontekstis oluliselt aeganõudvamaks ja veaohlikumaks valikuks.

6.2 AI puudujäägid ja piirangud

Vaatamata edusammudele on AI mudelitel lõputöö kirjutamise kontekstis endiselt olulised puudujäägid.

Viidete usaldusväärsus. Kõige tõsisem probleem on viidete hallutsineerimine. Isegi kontekstipõhise genereerimise korral leiutasid mudelid olematud allikaid. Gemini 3.1 Pro hallutsineeris viiteid ca 25% juhtudest, GPT-5.4 ca 20%, Claude Sonnet 4.6 ca 20% ja Claude Opus 4.6 ca 15% juhtudest. Kuigi Opus 4.6 näitas madalaimat hallutsinatsioonimäära, on ka 15% liiga kõrge akadeemilise teksti jaoks. Need tulemused on kooskõlas varasemate uurimustega: Chelli et al. [30] tuvastasid GPT-4 hallutsinatsioonimääraks 28,6%, mis on lähedane meie GPT-5.4 tulemusele, viidates sellele, et vaatamata mudelite arengule pole viidete hallutsineerimise probleem täielikult lahendatud. Mugaanyi et al. [29] leidsid samuti, et DOI-de täpsus on valdkonniti väga erinev (loodusteadustes 32,7% vs humanitaarteadustes 8,5%), mis viitab sellele, et arvutiteaduse valdkonnas võivad tulemused olla mõnevõrra paremad. Kim et al. [31] on näidanud, et hallutsinatsioonid on eriti levinud väiksemate keelte ja madalama sissetulekuga riikide kontekstis, mis on asjakohane ka eesti keele puhul. See tähendab, et iga AI-genereeritud viide tuleb inimese poolt kontrollida. Viidete automaatne genereerimine on hetkel ebapiisava kvaliteediga ja üliõpilane peab ise allikaid otsima ning viiteid kontrollima.

Sisuline sügavus. AI-genereeritud tekstid kipuvad olema pealiskaudsed. Mudelid kordavad üldtuntud seisukohti, kuid ei suuda luua originaalset analüüsi ega teha uudseid järeldusi. See on eriti problemaatiline tulemuste arutelu puhul, kus eeldatakse, et autor demonstreerib kriitilist mõtlemist ja seob tulemused laiemas kontekstiga kokku.

Eesti keele tehniline terminoloogia. Kuigi mudelite eesti keele oskus on oluliselt paranenud, esineb endiselt probleeme tehnilise terminoloogiaga. Mudelid kasutavad kohati ebaühtlast terminoloogiat (vahetavad eesti- ja ingliskeelsete terminite vahel) ning mõnikord loovad valesid termineid. Näiteks genereeriti termin “sügavõpe” asemel “süvaõppimine” või kasutati sõna “treenima” asemel “koolitama”, mis ei vasta arvutiteaduse valdkonnas juurdunud eestikeelsele terminoloogiale. Barbu et al. [40] on samuti täheldanud, et keelemudelid vajavad eesti keele spetsiifika jaoks täiendavat kohandamist, mis viitab laiemale probleemile väikeste keelte tehnilistel kasutusjuhtudel.

Kontekstiakna piirangud. Kuigi kontekstiaknad on oluliselt suurenenud, on need endiselt piiratud. 25-leheküljelise bakalaureusetöö tekst (ca 80 000–100 000 tähemärki ehk ca

40 000–50 000 tokenit) mahub küll kontekstiaknasse, kuid kui lisada juhendid, näidistööd ja varasemalt genereeritud osad, on kontekstiakna efektiivne kasutamine endiselt kriitiline.

Juhiste järgimise ebaühtlus ja agentsete tööriistade mõju. Eksperiment 6 (tervikliku lõputöö genereerimine) tõi esile neli fundamentaalselt erinevat mudelikäitumist, mis väärivad eraldi arutelu. GPT-5.4 keeldumine terviklikku tööd kirjutamast ja inglise keelele üleminek viitab sellele, et mudeli ohutuskoolitus (*alignment training*) seab akadeemilise aususe piirangud kõrgemale kui kasutaja juhised. Bianchi et al. [38] on kirjeldanud sarnast nähtust kui “liialdatud ohutuskäitumist” (*exaggerated safety behaviour*), kus mudelid keelduvad täiesti ohututest ülesannetest, mis pealiskaudselt sarnanevad ohtlikele. See on mudeli arendaja seisukohast vastutustundlik, kuid praktikas piirav – mudel ei erista uurimuslikku eesmärki (kus AI-genereeritud tekst on uurimisobjekt) isiklikust akadeemilisest petmisest. Samas näitas täiendav katse ChatGPT Codex laiendusega Visual Studio Code’is (vt peatükk 7.5), et agentne töövoog võib aidata sellest piirangust üle saada – sama GPT-5.4 mudel suutis Codex laienduse kaudu genereerida tervikliku, teiste mudelite väljunditega visuaalselt sarnase dokumendi. See on oluline leid, kuna näitab, et agentsed tööriistad ei paranda mitte ainult genereerimise kvaliteeti, vaid võivad muuta ka mudeli käitumist ülesande täitmisel.

Gemini 3.1 Pro genereeris Google’i agentse tööriista Antigravity kaudu tervikliku 39-leheküljelise töö, mis oli struktuuraalselt ja vormiliselt veenev, kuid sisaldas täielikult väljamõeldud eksperimenti – mudel fabritseeris 30 tudengiga kvantitatiivse uuringu koos statistiliste testide, koodinäidete ja andmebaasiskeemidega. See demonstreerib nii Gemini 3.1 Pro tugevust mahuka teksti genereerimisel kui ka olulist riski: mudel loob veenvaid, kuid fiktiivseid uurimistulemusi, mida kogenematu lugeja ei pruugi tuvastada. Ilma agentse tööriistata olid Gemini varasemad katsed oluliselt nõrgemad, mis kinnitab agentse töövoogu kriitilist rolli. Claude Sonnet 4.6 edukus tervikliku töö genereerimisel kinnitab mudeli tugevust struktureeritud juhiste järgimisel. Claude Opus 4.6 ületas Sonnet’i veelgi, genereerides 61-leheküljelise tehniliselt sügava lõputöö Claude Code’i agentse tööriista kaudu, mis demonstreerib, et mudeli suurem võimekus koos agentse töövoogu eeliseiga annab oluliselt parema tulemuse.

Hindamismetoodika piirangud. Oluline piirang käesolevas uurimuses on asjaolu, et hindamise viis läbi ainult üks hindaja (töö autor). See tähendab, et hindajatevahelise kooskõla mõõtmine ei olnud võimalik ja subjektiivsus on paratamatult suurem kui mitme sõltumatu hindaja kaasamisel. Subjektiivsuse vähendamiseks kasutati iga teksti korduvat hindamist eri aegadel, kuid see ei asenda sõltumatuid hindajaid. Eriti subjektiivsetes kriteeriumides (akadeemiline

stiil, praktiline väärtus) võivad ühe hindaja hinnangud kalduda süstemaatiliselt ühes suunas. Edaspidistes uurimustes tuleks tulemuste kinnitamiseks kaasata mitu sõltumatut hindajat, sealhulgas valdkonna õppejõud ja teised üliõpilased.

6.3 Hinnakujundus ja majanduslik teostatavus

Tabelis 15 on esitatud hinnanguline kuluarvestus 25-leheküljelise bakalaureusetöö genereerimiseks iga mudeliga.

Tabel 15. Bakalaureusetöö genereerimise hinnanguline kuluarvestus

Kulukomponent	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Sisendtokenid (ca 2M)	\$4,00–8,00	\$3,50	\$6,00	\$30,00
Väljundtokenid (ca 300K)	\$3,60	\$4,20	\$4,50	\$22,50
Iteratsioonid (x3)	x3	x3	x3	x3
Eeldatav hind	\$23–\$35	\$23–\$30	\$32–\$42	\$158–\$200

Alternatiivina saab kasutada kuutellimusi: ChatGPT Plus ja Claude Pro mõlemad maksavad \$20/kuu, Google AI Studio tasuta versioon võimaldab piiratud kasutust. Praktikas tähendab see, et üliõpilane saab 1–2 kuu tellimuse hinnaga (ca \$20–40) teostada põhilised genereerimiskatsetused, eeldusel et mahupiiranguid ei ületata.

Kokkuvõttes on AI kasutamise majanduslik kulu lõputöö kirjutamisel Sonnet-klassi mudelitega mõistlik – \$23–\$42 API kaudu või \$20–40 kuutellimuse kaudu. Claude Opus 4.6 on oluliselt kallim (\$158–200 API kaudu), kuid Claude Max tellimus (\$100–200/kuu) võimaldab piiratud kasutust. Sonnet-klassi mudelid on endiselt oluliselt odavamad kui professionaalse toimetaja teenus, mis võib maksta 200–500€ bakalaureusetöö puhul.

6.4 Eesti keele korrektuur ja toimetamine

Eraldi väärib tähelepanu AI mudelite kasutamine eestikeelse teksti korrektuuri ja toimetamise tööriistana. See on üks valdkondi, kus AI pakub kõige suuremat praktilist väärtust.

Grammatikakontroll. Kõik neli mudelit suudavad tuvastada ja parandada enamiku grammatikavigadest eesti keeles. Claude Opus 4.6 oli kõige täpsem, tuvastades ca 92–95% vigadest. Claude Sonnet 4.6 ja GPT-5.4 tuvastasid ca 85–90% testitekstides olevaid vigu. Gemini 3.1 Pro tuvastas ca 75–80% vigadest.

Stiilikontroll. Mudelid suudavad hinnata teksti vastavust akadeemilisele stiilile ja pakkuda parandusettepanekuid. See hõlmab liiga vaba keele tuvastamist, passiivi kasutamise soovitusi ja liigsete korduste märkamist. Claude Sonnet 4.6 oli selles osas kõige põhjalikum, pakkudes detailsemaid selgitusi paranduste kohta.

Terminoloogiakontroll. Mudelid suudavad kontrollida tehnilise terminoloogia ühtlust ja korrektsust, kuid siin on täpsus madalam – ca 60–70%. See tähendab, et terminoloogilist kontrolli ei saa täielikult AI-le delegeerida ja valdkonnaspetsiifiline inimekspertiis on endiselt vajalik.

Soovitus. AI-põhine korrektuur on kõige efektiivsem, kui seda kasutatakse kahes etapis:

1. Esmalt laseb üliõpilane AI-l teksti üle vaadata ja parandusettepanekud teha;
2. Seejärel vaatab üliõpilane parandused üle ja otsustab, millised neist aktsepteerida;
3. Lõpuks saab üliõpilane teha käsitsi täiendavaid parandusi, mida AI ei tuvastanud ja vajadusel alustada esimesest punktist uuesti.

Sellist kolmeetapilist protsessi kasutades saab oluliselt parandada teksti keelelist kvaliteeti, ilma et tekiks oht AI soovitude pimesi järgimiseks.

6.5 Soovitused AI tööriista valikuks

Eksperimentide tulemuste ja praktiliste kogemuste põhjal saab anda järgmised soovitused.

Parim kvaliteet: Claude Opus 4.6 koos Claude Code'iga. Meie eksperimendid näitasid, et Claude Opus 4.6 koos Claude Code'i agentse tööriistaga saavutab kõrgeima kvaliteedi eestikeelse akadeemilise teksti genereerimisel. Mudel ületas kõiki teisi mudeleid nii keelelise korrektsuse, akadeemilise stiili kui ka sisulise sügavuse poolest. Peamine puudus on oluliselt kõrgem hind.

Parim hinna-kvaliteedi suhe: Claude Sonnet 4.6. Claude Sonnet 4.6 on kõige sobivam valik piiratud eelarvega üliõpilase jaoks. Mudel paistab silma akadeemilise stiili, juhendite järgimise ja teksti struktureerimise poolest ning on oluliselt soodsam kui Opus. Pikendatud mõtlemisrežiim parandab oluliselt keerulisemate peatükkide kvaliteeti.

Lühikeste lõikude jaoks: GPT-5.4. GPT-5.4 sobib hästi lühikeste tekstilõikude genereerimiseks ja keelelise korrektuuri jaoks. Tavapärase vestlusliidese kaudu võib mudeli ohutussüsteem tervikliku töö genereerimise blokeerida ning keelevalik võib kalduda inglise keelele, kuid ChatGPT Codex laiendus Visual Studio Code'is võimaldab sellest piirangust üle saada (vt

peatükk 7.5). ChatGPT Plus tellimus (\$20/kuu) on majanduslikult mõistlik ja katab ka Codex laienduse kasutuse.

Ideaalne töövoog. Meie kogemus näitab, et kõige parema tulemuse annab Claude Code'i agentse tööriista kasutamine koos Opus või Sonnet mudeliga.

6.6 Tööriistad, mida vältida

Lisaks positiivsetele soovitudele ilmnes testimisel ka tööriistu, mida lõputöö kirjutamise abivahendina ei saa soovitada, vaatamata nende laialdasele kättesaadavusele üliõpilastele.

Perplexity ei sobi mahukate ülesannete jaoks. Perplexity on AI-põhine otsingumootor, mis pakub juurdepääsu erinevatele mudelitele (sh Claude, GPT ja teised). Kuigi Perplexity sobib hästi üksikute küsimuste esitamiseks ja lühikeste vastuste saamiseks, ilmnes testimisel oluline puudus: kõikidel mudelitel on Perplexity kaudu kasutades oluliselt väiksem kontekstiaken kui otse API või vestlusliidese kaudu. Perplexity veebi- ja mobiilirakenduses on otsese sisendi piiranguks vaikselt ca 8 000 tokenit päringu kohta [41], mis on oluliselt vähem kui samade mudelite natiivsed kontekstiaknad (nt Claude'i 200K või Gemini 1M tokenit). See tähendab, et eraldi lühikeste promptidena saab küll normaalselt töötada, kuid kui on vaja genereerida mahukamaid tekste või hoida pikema vestluse konteksti (nt tervikliku peatüki kirjutamine koos eelnevate osade kontekstiga), jääb kontekstiaknast puudu. Lisaks on täheldatud, et pikema konteksti puhul hakkab Perplexity varasemaid vestluse osi kärpima või kompressseerima, mille tagajärjel vastused lakkavad viitamast varem kokkulepitud tingimustele ja piirangutele [41]. Seetõttu ei sobi Perplexity lõputöö genereerimise tööriistaks, kus on vajalik suur ja järjepidev kontekst.

GitHub Copilot Pro ei sobi akadeemilise teksti genereerimiseks. GitHub Copilot Pro, mida Tartu Ülikool pakub üliõpilastele tasuta GitHub Education programmi kaudu, on mõeldud eelkõige koodi kirjutamise abivahendiks [42]. GitHub enda dokumentatsiooni kohaselt on Copilot Chat mõeldud ainult kodeerimisega seotud päringutele ning juhiste piiramine kodeerimisülesannetega parandab mudeli väljundi kvaliteeti [43]. Lõputöö genereerimise kontekstis osutus see aga ebapiisavaks. Copilot'i mudelid tundusid oluliselt "laisemad" – nad kippusid andma lühikesi, pealiskaudseid vastuseid ja vältisid pikemate akadeemiliste tekstilõikude genereerimist. Nguyen ja Nadi [44] on oma empiirilises uurimuses näidanud, et Copilot'i soovitudest on tähelepanek, mis takistab pikema väljundi genereerimist, ning keerulisemate ülesannete korral langeb soovitude kvaliteet märgatavalt. Lisaks rakendab

GitHub Copilot'ile päringupõhiseid limiite (*rate limits*), mis piiravad kasutamise intensiivsust [45]. Kokkuvõttes on tööriist optimeeritud lühikeste koodilõikude ja kooditäienduste jaoks, mitte terviklike akadeemiliste tekstide loomiseks. Seetõttu ei saa GitHub Copilot Pro-d soovitada lõputöö kirjutamise abivahendina, vaatamata sellele, et see on üliõpilastele tasuta kättesaadav.

6.7 Eetilised kaalutlused ja akadeemiline ausus

AI kasutamine lõputöö kirjutamisel tõstatab olulisi eetilisi küsimusi. Tartu Ülikooli akadeemilise aususe reeglid [3] nõuavad, et üliõpilane:

- deklareerib kõik AI vahendid, mida ta kasutab;
- märgib, millises töö osas ja millises ulatuses AI-d kasutati;
- tagab, et töö peegeldab tema isiklikku akadeemilist arengut ja analüütilist mõtlemist.

Rodafinos [22] rõhutab, et ülikoolid peaksid AI kasutamise keelustamise asemel lõimima AI-kirjaoskuse õppekavadesse ja kehtestama selged eetilise kasutamise poliitikad. Lund et al. [23] leidsid, et tudengid ei käsitle AI kasutamist kirjutamisel tavalise plagiaadi laiendusena, vaid eraldiseisva akadeemilise käitumise kategooriana, mis nõuab eraldi eetilist raamistikku.

On oluline rõhutada, et käesolev töö ei propageeri lõputöö AI abil “kirjutamist”, vaid uurib AI kasutamist *abivahendina* kirjutamisprotsessis. Nii nagu õigekirjakontroll ei kirjuta teksti üliõpilase eest, ei tohiks ka AI-põhine tekstigenereerimine asendada üliõpilase isiklikku panust. AI-d tuleks käsitleda kui tööriista, mis aitab struktureerida mõtteid, luua mustandeid ja parandada keelekasutust.

6.8 Tulevikuväljavaated

AI mudelite areng on kiire ja käesoleva töö tulemused peegeldavad 2025–2026. aasta seisuga. Lähitulevikus on oodata järgmisi arenguid:

- **Eesti keele kvaliteedi paranemine** – uuemate mudelite (nt oodatav GPT-6, Gemini 4.0) treeningandmetes on eesti keele osakaal tõenäoliselt suurem, mis parandab keelelist kvaliteeti. EstLLM projekti [17] tulemused näitavad, et spetsialiseeritud jätkutreenimine võib eesti keele kvaliteeti märkimisväärselt tõsta ka olemasolevates mudelites.
- **Agentsed akadeemilised tööriistad** – Claude Code'i, Google'i Antigravity ja OpenAI ChatGPT Codex laienduse laadsed agentsed tööriistad, mis suudavad iseseisvalt faile hallata, kompileerida ja projekti struktureerida, muutuvad tõenäoliselt akadeemilise

kirjutamise standardtööriistadeks. Meie eksperimendid kinnitasid, et agentne töövoog parandab oluliselt genereerimise kvaliteeti kõigi testitud mudelite puhul – nii Opus 4.6 (Claude Code), Gemini 3.1 Pro (Antigravity) kui ka GPT-5.4 (Codex) puhul.

- **Viidete kvaliteedi paranemine** – RAG (Retrieval-Augmented Generation) süsteemide areng peaks parandama viidete täpsust ja vähendama hallutsinatsioone. Kresevic et al. [37] on näidanud, et RAG-raamistik koos struktureeritud konteksti ja promptide disainiga parandas GPT-4 Turbo täpsust 43%-lt 99%-le, mis demonstreerib selle lähenemise potentsiaali ka akadeemilises kontekstis. Ji et al. [39] leidsid, et ahelpõhendamise (*chain-of-thought*) kasutamine parandas oluliselt viidete kvaliteeti teksti genereerimisel.
- **Kontekstiakende suurenemine** – kontekstiaknad kasvavad jätkuvalt, mis võimaldab mudelitele sisestada üha rohkem infot korraga.
- **Spetsialiseeritud akadeemilised mudelid** – lähiaastatel on tõenäoline spetsiaalselt akadeemiliseks kirjutamiseks kohandatud mudelite (nt eesti keelele ja Tartu Ülikooli stiilile peenhäälestatud variandid) ilmumine, mis võiksid ühendada üldmudelite võimekuse valdkonnaspetsiifiliste teadmistega ning vähendada hallutsinatsioonide osakaalu.
- **AI-genereeritud sisu tuvastamine ja integreerimine õppekavasse** – ülikoolide ja kirjastuste poolt kasutusele võetavad AI-detekteerimise tööriistad arenevad paralleelselt genereerimistööriistadega, samas kui akadeemilised institutsioonid liiguvad AI keelustamiselt selle läbipaistva integreerimise suunas. See nõuab uusi hindamismetoodikaid, mis keskenduvad üliõpilase sisulisele panusele ja mõtteprotsessile, mitte ainult lõpptulemusele.
- **Multimodaalsed võimed akadeemilises tekstis** – tulevased mudelid suudavad tõenäoliselt genereerida mitte ainult teksti, vaid ka akadeemiliselt kvaliteetseid jooniseid, diagramme ja visualiseerimisi otse L^AT_EX-ühilduvas vormingus (nt TikZ või PGFPlots koodi), mis vähendab hetkel veel märkimisväärset käsitsitööd jooniste loomisel.

Käesolev uurimus piirdus neljast mudelist ja kahest agentsest tööriistast koosneva võrdlusega 2025–2026. aasta seisuga. Arvestades AI valdkonna arengutempot, kus uusi mudeleid avaldatakse mitu korda aastas, tuleks sarnaseid teostatavusuuringuid korrata regulaarselt, et hinnata, kuidas ülalnimetatud arengud tegelikult realiseeruvad ja millised käesoleva töö järeldustest jäävad kehtima ka uuema põlvkonna mudelite puhul.

7. Claude Code kui lõputöö genereerimise tööriist

Käesolev peatükk kirjeldab Claude Code'i kui agentset AI tööriista, mis võimaldab terviklike akadeemiliste tööde genereerimist otse arenduskeskkonnas. Peatükk annab ülevaate tööriista arhitektuurist, töövoogudest ning esitab praktilised soovitused lõputöö genereerimiseks.

7.1 Claude Code'i ülevaade

Claude Code on Anthropic'i arendatud agentne kodeerimis- ja tekstiloomise tööriist, mis töötab Claude äpi kaudu või käsurealiidese (CLI) kaudu ning integreerub otse arenduskeskkondadesse nagu Visual Studio Code [11]. Erinevalt tavalistest vestlusliidese-põhistest AI tööriistadest (nt ChatGPT veebiliides, Claude.ai) pakub Claude Code agentset töövoogu: tööriist saab iseseisvalt lugeda ja kirjutada faile, käivitada käsurea kāske, otsida veebist informatsiooni ning hallata projekti failisüsteemi. Claude Code'i peamised eelised akadeemilise teksti genereerimisel:

- **Otsene failisüsteemi juurdepääs** – tööriist saab lugeda olemasolevaid $\text{\LaTeX}$ faile, juhendeid ja näidistöid otse failisüsteemist, ilma et kasutaja peaks neid käsitsi kopeerima vestlusaknasse.
- **Iteratiivne genereerimine** – tööriist saab genereerida teksti, kontrollida tulemust ja teha parandusi mitme iteratsiooni jooksul ühe sessiooni raames.
- **$\text{\LaTeX}$ kompileerimine** – tööriist saab käivitada $\text{\LaTeX}$ kompileerimist ja kontrollida, kas genereeritud kood kompileerub vigadeta.
- **Viidete haldamine** – tööriist saab hallata BibTeX/BibLaTeX viidete faile, lisada uusi viiteid ja kontrollida viidete formaadi korrektsust.

7.2 Claude Code vs tavapärane vestlusliides

Tabelis 16 on esitatud võrdlus Claude Code'i ja tavapärase vestlusliidese (nt Claude.ai, ChatGPT) vahel lõputöö genereerimise kontekstis.

7.3 Soovitused lõputöö genereerimiseks Claude Code'iga

Käesoleva uurimuse praktiliste kogemuste põhjal, sealhulgas Opus 4.6 mudeliga genereeritud paroolihalduri lõputöö (vt peatükk 5.8), saab anda järgmised soovitused Claude Code'i kasutamiseks lõputöö genereerimisel.

Tabel 16. Claude Code vs tavapärane vestlusliides lõputöö genereerimisel

Aspekt	Vestlusliides	Claude Code
Konteksti sisestamine	Käsitsi kopeerimine	Automaatne failide lugemine
Väljundi salvestamine	Käsitsi kopeerimine	Otsene faili kirjutamine
L ^A T _E X kontroll	Puudub	Automaatne kompileerimine
Viidete haldus	Käsitsi	Automaatne BibTeX haldus
Mitme faili töötlemine	Viis faili korraga	Kõik failid korraga
Iteratsiooni kiirus	Aeglane (kopeeri-kleebi)	Kiire (automaatne)
Projekti struktuur	Kasutaja haldab	Tööriist haldab

7.3.1 Projekti ettevalmistamine

1. **Kasuta L^AT_EX malli algusest peale.** Paigalda ülikooli L^AT_EX mall (nt UniTartuCS) projektikausta enne genereerimise alustamist. Claude Code suudab malli struktuuri automaatselt tuvastada ja järgida.
2. **Lisa juhendid projektikausta.** Kopeeri lõputöö juhendid (TÜ ATI juhend, LOTE juhend) tekstifailidena projektikausta. Claude Code saab neid automaatselt lugeda kontekstina.
3. **Lisa näidistööd.** Paiguta 2–3 hästi hinnatud varasema lõputöö PDF-failid projektikausta. Need annavad mudelile konkreetse ettekujutuse oodatavast kvaliteedist ja stiilist.
4. **Loo CLAUDE.md konfiguratsioonifail.** Projekti juurkausta loodav CLAUDE.md fail sisaldab püsivaid juhiseid, mida Claude Code järgib igas sessioonis. Sinna tasub kirjutada:
 - oodatav keel (eesti keel);
 - akadeemiline stiil ja toon;
 - terminoloogia eelistused;
 - viitamisstiil (nt IEEE numeric);
 - peatükkide struktuur ja maht.

7.3.2 Genereerimise töövoog

Soovitame järgmist samm-sammulist töövoogu:

1. **Genereeri sisukord ja struktuur.** Alusta sisukorra ja peatükkide ülesehituse genereerimisega. Anna mudelile ette teema, uurimisküsimused ja mahunõuded. Kontrolli ja kinnita struktuur enne edasi liikumist.
2. **Genereeri peatükid järjest.** Genereeri iga peatükk eraldi, alustades sissejuhatusest. Iga järgmise peatüki genereerimisel on eelnevad peatükid kontekstis, mis tagab sidususe.
3. **Genereeri tabelid ja joonised eraldi.** Tabelite ja jooniste $\text{\LaTeX}$ kood on keerulisem ja vajab eraldi tähelepanu. Genereeri need eraldi sammuna ja kontrolli visuaalset tulemust.
4. **Lisa viited ise või tee põhjalikku kontrolli neile.** Ära lase mudelil viiteid “välja mõelda”. Kui soovid, et viited oleksid väga tõenäoliselt korrektsed, siis järgi seda malli:
 - otsi ise allikaid;
 - lisa leitud allikate andmed BibTeX faili;
 - palu mudelil viiteid tekstis kasutada ainult olemasolevatest allikatest.
5. **Kompileeri regulaarselt.** Kasuta Claude Code'i võimalust käivitada `pdflatex` ja `biber` käske, et kontrollida, kas genereeritud $\text{\LaTeX}$ kood kompileerub vigadeta.
6. **Vaata üle ja paranda.** Iga genereeritud peatüki järel vaata tekst üle, märgi probleemkohad ja palu mudelil need parandada. Ära jäta ülevaatamist töö lõppu.

7.3.3 Parimad praktikad

- **Kasuta pikendatud mõtlemisrežiimi.** Claude Code'i pikendatud mõtlemisrežiim (*extended thinking*) parandab oluliselt keeruliste akadeemiliste tekstide kvaliteeti. See on eriti kasulik sissejuhatuse, metoodika ja arutelu peatükkide jaoks.
- **Anna konkreetseid juhiseid.** Mida konkreetsemad on juhised, seda parem on tulemus. Selle asemel, et paluda “kirjuta sissejuhatust”, täpsusta töö maht ja peamised teemad.
- **Kontrolli viiteid alati.** Ükski AI mudel ei genereeri 100% korrektseid viiteid. Kontrolli iga viite olemasolu ja korrektsust käsitsi.
- **Ära genereeri kõike korraga.** Iteratiivne, peatüki-kaupa genereerimine annab oluliselt parema tulemuse kui terve töö genereerimine ühe promptiga.
- **Ole kursis enda tööga.** AI on abivahend, mitte autor. Üliõpilane peab iga genereeritud lõigu sisuliselt üle vaatama ja vajadusel ümber kirjutama.

- **Kasuta Opus mudelit nii palju kui võimalik.** Claude Opus 4.6 on praegu Claude perekonna võimekaim mudel ja sobib kõige paremini terviklike peatükkide ja keeruliste akadeemiliste tekstide genereerimiseks, kuigi selle hind on oluliselt kõrgem kui Sonnet mudelil.

7.4 Alternatiivne agentne tööriist: Google Antigravity

Eksperiment 6 raames testiti Gemini 3.1 Pro mudelit ka Google'i agentse tööriista Antigravity kaudu. Antigravity on Google'i arendatud agentne AI tööriist, mis on funktsionaalselt sarnane Claude Code'iga – see võimaldab mudelil iseseisvalt hallata faile, genereerida koodi ja struktureerida projekte. Antigravity kasutamine parandas Gemini 3.1 Pro tulemust oluliselt: ilma agentse tööriistata olid varasemad katsed oluliselt nõrgemad nii mahu kui ka kvaliteedi poolest. See kinnitab laiemat järeldust, et agentsed tööriistad on kriitilise tähtsusega tervikliku lõputöö genereerimise kontekstis, sõltumata konkreetsest mudelist.

7.5 Alternatiivne agentne tööriist: ChatGPT Codex Visual Studio Code'is

Lisaks Google'i Antigravity'le testiti ka OpenAI ChatGPT Codex laiendust (*extension*) Visual Studio Code'i arenduskeskkonnas [46]. Codex laiendus on funktsionaalselt sarnane Claude Code'iga ja Antigravity'ga – see võimaldab mudelil iseseisvalt hallata projekti faile, genereerida L^AT_EX koodi ning struktureerida terviklikku dokumenti otse arenduskeskkonnas.

Eriti tähelepanuväärne on Codex laienduse tulemus GPT-5.4 mudeliga. Eksperimendis 6 (vt peatükk 5.8) keeldus GPT-5.4 tavapärase vestlusliidese kaudu terviklikku lõputööd genereerimast, viidates akadeemilise aususe piirangutele, ning andis selle asemel 8-leheküljelise ingliskeelse juhendi. Codex laienduse kaudu suutis aga sama mudel genereerida visuaalselt teiste mudelite väljunditega sarnase tervikliku dokumendi. See viitab sellele, et agentne töövoog ei paranda mitte ainult genereerimise kvaliteeti ja mahtu, vaid võib aidata ületada ka mudeli ohutuskoolitusest tulenevaid piiranguid, kuna tööülesanne jaguneb väiksemateks, kontekstuaalselt selgemateks sammudeks.

Majanduslikust vaatevinklist väärib märkimist, et Codex laiendus kasutab ChatGPT Plus tellimuse (\$20/kuu) raames kaasasolevat kasutuskvooti. Testimisel kulus tervikliku dokumendi genereerimiseks väga vähe kvooti, mis teeb ChatGPT Plus plaanist hea hinna ja võimsuse suhtega valiku agentseks lõputöö genereerimiseks.

7.6 Claude Code'i piirangud

Vaatamata eelistele on Claude Code'il mitmeid piiranguid lõputöö genereerimise kontekstis:

- **Kontekstiakna täitumine.** Pikema sessiooni jooksul võib kontekstiaken täituda, mis põhjustab varasemate osade “unustamist”. Lahenduseks on sessiooni korrapärane taaskäivitamine ja CLAUDE.md faili kasutamine püsiva kontekstina.
- **Hind.** Claude Code kasutab API-põhist hinnastamist, mis tähendab, et pikemad sessioonid võivad olla kulukad, eriti Opus mudeliga.
- **Tehniline barjäär.** Claude Code eeldab käsurea ja arenduskeskkonna kasutamise oskust, mis ei ole kõigile üliõpilastele tuttav.
- **Versioonihaldus.** Kuigi Claude Code saab kasutada Git'i, on oluline, et üliõpilane mõistab versioonihalduse põhimõtteid, et vältida töö kadumist.

7.7 Juhtumiuuring: Paroolihalduri lõputöö genereerimine Opus 4.6-ga

Käesoleva uurimuse raames genereeriti Claude Code'i ja Opus 4.6 mudeli abil terviklik 61-leheküljeline bakalaureusetöö teemal “Turvalise paroolihalduri veebirakenduse arendamine”. See juhtumiuuring demonstreerib Claude Code'i praktilisi võimekusi ja piiranguid reaalse lõputöö genereerimisel.

7.7.1 Genereerimisprotsess

Genereerimine toimus Claude Code'i kaudu, kasutades Opus 4.6 mudelit. Projektikausta paigutati UniTartuCS L^AT_EX mall, TÜ ATI juhend ning CLAUDE.md konfiguratsioonifail eestikeelse akadeemilise kirjutamise juhistega. Genereerimine toimus iteratiivselt, peatüki kaupa.

7.7.2 Genereeritud töö omadused

Genereeritud lõputöö sisaldas järgmisi komponente:

- Terviklik tehniline arhitektuur: nullteadmise (*zero-knowledge*) põhimõte, AES-256-GCM krüpteering, Argon2id võtmetuletamine;
- React/TypeScript kasutajaliides ja Node.js/Express taustarakendus PostgreSQL andmebaasiga;
- 149 automatiseeritud testi (47 krüptograafia ühiktesti + 61 serveri ühiktesti + 41 integratsioonitesti);

- OWASP Top 10 vastavuse analüüs;
- Süsteemi kasutatavuse skaala (SUS) hindamine skooriga 77,0;
- 0 kriitilist turvaauku turvaauditi tulemusel.

7.7.3 Järeldused juhtumiuuringust

Juhtumiuuring kinnitas, et Claude Code koos Opus 4.6 mudeliga suudab genereerida tervikliku, struktureeritud ja tehniliselt detailse lõputöö. Genereeritud töö vastas TÜ ATI vorminõuetele ja sisaldas kõiki nõutud peatükke. Peamised tugevused olid:

- Tehniline sügavus ja detailsus, mis ületas teiste mudelite tulemusi;
- Korrekne eesti keel läbivalt kogu töös;
- Terviklik ja sisukas struktuur ilma teemast kõrvalekaldumiseta;
- L^AT_EX koodi korrektne genereerimine, sealhulgas tabelid, joonised ja viited.

Peamised puudused olid endiselt seotud viidete hallutsineerimisega (ca 15% viidetest vajasid kontrolli) ja mõningate eesti keele terminoloogia ebajärjekindlustega.

8. Kokkuvõte

Käesolev bakalaureusetöö uuris tehisintellekti rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Uurimuse käigus võrreldi nelja juhtivat suurt keelemudelit – Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ja Anthropic Claude Opus 4.6 – nende võimekuse osas luua struktureeritud, akadeemiliselt korrektset ja sisuliselt väärtuslikku eestikeelset teksti. Opus 4.6 puhul kasutati lisaks Claude Code'i agentset tööriista.

Uurimuse peamised tulemused on järgmised.

AI mudelid suudavad genereerida rahuldava kuni hea kvaliteediga eestikeelset akadeemilist teksti, eriti teksti struktureerimise ja kavandamise osas. Kontekstipõhine genereerimine, kus mudelitele anti ette Tartu Ülikooli juhendid ja näidistööd, parandas tulemusi keskmiselt 15–20% võrreldes nullkonteksti genereerimisega.

Nelja mudeli võrdlusest selgus, et Claude Opus 4.6 saavutas kõigis eksperimentides kõrgeima keskmise hinde (4,05–4,47 skaalal 5-st), ületades Sonnet 4.6 tulemust keskmiselt 0,35 palli võrra. Claude Sonnet 4.6 saavutas teise koha (3,86–4,17), olles eriti tugev akadeemilise stiili ja juhendite järgimise poolest ning pakkudes parimat hinna-kvaliteedi suhet. GPT-5.4 näitas kõige ühtlasemat eesti keele grammatilist kvaliteeti lühikeste tekstide puhul. Mõtlemismudelite kasutamine parandas tulemusi 15–20%, kuid suurendas kulusid 1,5–3 korda.

Tervikliku lõputöö genereerimise eksperiment (eksperiment 6) paljastas mudelite vahel põhimõttelisi erinevusi. Claude Opus 4.6 genereeris Claude Code'i kaudu kõige mahukama väljundi – 61-leheküljelise eestikeelse lõputöö paroolihalduri teemal, mis oli tehniliselt sügav ja struktureeritud terviklik. Claude Sonnet 4.6 genereeris 40-leheküljelise eestikeelse lõputöö korrektsel teemal. GPT-5.4 keeldus terviklikku tööd kirjutamast, viidates akadeemilise aususe piirangutele, ja pakkus selle asemel 8-leheküljelise ingliskeelse teostatavusjuhendi. Gemini 3.1 Pro genereeris Antigravity tööriista kaudu 39-leheküljelise eestikeelse töö, kuid vale teema kohta. Need tulemused näitavad, et mudelite juhiste järgimise võimekus, keelevalik ja teemale vastavus erinevad drastiliselt.

Kõige tõsisem probleem oli viidete hallutsineerimine – mudelid leiutasid olematud allikaid 15–25% juhtudest (Opus 4.6 ca 15%, Sonnet 4.6 ca 20%, GPT-5.4 ca 20%, Gemini 3.1 Pro ca 25%). See tähendab, et iga AI-genereeritud viide vajab inimese poolt kontrollimist. Samuti jäi AI-genereeritud teksti sisuline sügavus ja originaalsus oodatust madalamaks.

AI kasutamise majanduslik kulu on Sonnet-klassi mudelitega mõistlik: \$23–42 API kaudu või \$20–40 kuutellimuste kaudu. Opus 4.6 on oluliselt kallim (\$158–200 API kaudu), kuid pakub kõrgeimat kvaliteeti. Mõlemad variandid on soodsamad kui professionaalse toimetamise teenus.

Uurimuse põhjal saab järeldada, et AI mudeleid saab efektiivselt kasutada lõputöö kirjutamise abivahendina, kuid mitte asendajana. AI tugevused – struktureerimine, mustandi loomine, keeleline toimetamine ja LaTeX-vormindamine – säästavad üliõpilasele märkimisväärselt aega. Samas on inimese panus endiselt asendamatu sisulise analüüsi, originaalsete järelduste, viidete kontrollimise ja valdkonnaspetsiifilise terminoloogia osas.

Soovitame kasutada Claude Opus 4.6 mudelit koos Claude Code'i agentse tööriistaga kõrgeima kvaliteedi saavutamiseks, eriti terviklike peatükkide ja keeruliste akadeemiliste tekstide genereerimisel. Piiratud eelarve korral on Claude Sonnet 4.6 parim hinna-kvaliteedi suhtega valik. GPT-5.4 sobib hästi keelelise korrektuuri jaoks ja lühikeste tekstilõikude genereerimiseks, kuid tervikliku töö genereerimisel tuleb arvestada mudeli ohutuspiirangutega. Ideaalne on Claude Code'i kasutamine koos Opus või Sonnet mudeliga (vt peatükk 7).

Käesolev töö panustab eestikeelsesse AI-uurimusse, pakkudes esimese süstemaatilise võrdluse kaasaegsete keelemudelite suutlikkusest eestikeelse akadeemilise teksti genereerimisel. Tervikliku lõputöö genereerimise eksperiment on eriti informatiivne, kuna paljastab mudelite käitumise erinevusi, mida lühikeste tekstilõikude testimine ei avalda. Töö tulemused on kasulikud nii üliõpilastele, kes soovivad AI-d vastutustundlikumalt kasutada, kui ka õppejõududele ja ülikoolidele, kes kujundavad AI kasutamise poliitikat akadeemilises kontekstis.

Edaspidine uurimistöö võiks keskenduda spetsialiseeritud akadeemiliste AI tööriistade hindamisele, eesti keelele kohandatud mudelite (nt EstGPT) võrdlemisele suurte universaalsete mudelitega, RAG-süsteemide mõju hindamisele viidete kvaliteedile ning AI kasutamise mõju hindamisele üliõpilaste akadeemilisele arengule pikas perspektiivis.

Viited

- [1] Brown T., Mann B., Ryder N., Subbiah M., Kaplan J. D., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A. jt. Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems* 33 (2020), lk 1877–1901. <https://arxiv.org/abs/2005.14165>.
- [2] OpenAI. GPT-4 Technical Report. <https://arxiv.org/abs/2303.08774>. Viimati vaadatud: 15.02.2026. 2023.
- [3] Tartu Ülikool, Arvutiteaduse instituut. Tartu Ülikooli arvutiteaduse instituudis kaitstavate lõputööde nõuded ja hindamine. <https://cs.ut.ee/et/sisu/loputoode-tahtajad-ja-juhendid>. Viimati vaadatud: 20.02.2026. 2025.
- [4] Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser Ł. ja Polosukhin I. Attention is All You Need. *Advances in Neural Information Processing Systems* 30 (2017), lk 5998–6008. <https://arxiv.org/abs/1706.03762>.
- [5] Devlin J., Chang M.-W., Lee K. ja Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT* (2019), lk 4171–4186. <https://arxiv.org/abs/1810.04805>.
- [6] Radford A., Wu J., Child R., Luan D., Amodei D. ja Sutskever I. Language Models are Unsupervised Multitask Learners. *OpenAI Blog* (2019). https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.
- [7] OpenAI. Introducing GPT-5.4. <https://openai.com/index/introducing-gpt-5-4/>. Viimati vaadatud: 01.03.2026. 2025.
- [8] Google DeepMind. Gemini 3.1 Pro: Announcing Our Latest Gemini AI Model. <https://blog.google/innovation-and-ai/models-and-research/gemini-models/gemini-3-1-pro/>. Viimati vaadatud: 01.03.2026. 2026.
- [9] Anthropic. Introducing Claude Sonnet 4.6. <https://www.anthropic.com/news/claude-sonnet-4-6>. Viimati vaadatud: 01.03.2026. 2026.
- [10] Anthropic. Introducing Claude Opus 4.6. <https://www.anthropic.com/news/claude-opus-4-6>. Viimati vaadatud: 10.03.2026. 2026.
- [11] Anthropic. Claude Code: An Agentic Coding Tool. <https://docs.anthropic.com/en/docs/claude-code>. Viimati vaadatud: 10.03.2026. 2026.
- [12] OpenAI. Learning to Reason with LLMs. <https://openai.com/index/learning-to-reason-with-llms/>. Viimati vaadatud: 15.02.2026. 2024.

- [13] Ereht M., Ereht T. ja Ross K. Eesti keele käsiraamat. Tallinn: Eesti Keele Sihtasutus, 2007. <https://arhiiv.eki.ee/books/ekk09/>.
- [14] Conneau A., Khandelwal K., Goyal N., Chaudhary V., Wenzek G., Guzmán F., Grave E., Ott M., Zettlemoyer L. ja Stoyanov V. Unsupervised Cross-lingual Representation Learning at Scale. *Proceedings of ACL* (2020), lk 8440–8451. <https://arxiv.org/abs/1911.02116>.
- [15] Tanvir H., Kittask C., Eiche S. ja Sirts K. EstBERT: A Pre-trained Language-Specific BERT Model for Estonian. *Proceedings of the 23rd Nordic Conference on Computational Linguistics (NoDaLiDa)*. 2021, lk 11–19. <https://aclanthology.org/2021.nodalida-main.2/>.
- [16] Kaalep H.-J. An Estonian Morphological Analyser and the Impact of a Corpus on Its Development. *Computers and the Humanities* 31.2 (1997), lk 115–133. <https://doi.org/10.1023/A:1000668108369>.
- [17] Dorkin A., Purason T., Kalbaliyev E., Kuulmets H.-A., Ojastu M., Fišel M., Alumäe T., Aedmaa E., Kruusmaa K. ja Sirts K. EstLLM: Enhancing Estonian Capabilities in Multilingual LLMs via Continued Pretraining and Post-Training. *arXiv preprint arXiv:2603.02041* (2026). <https://arxiv.org/abs/2603.02041>.
- [18] Üstün A., Aryabumi V., Yong Z.-X., Ko W.-Y., D'souza D., Onilude G., Bhandari N., Singh S., Ooi H.-L., Kayid A. jt. Aya Model: An Instruction Finetuned Open-Access Multilingual Language Model. *Proceedings of the Annual Meeting of the Association for Computational Linguistics*. 2024, lk 15894–15939.
- [19] Kuulmets H.-A., Purason T. ja Fišel M. How Well do LLMs Know Finno-Ugric Languages? A Systematic Assessment. *Proceedings of the Joint 25th Nordic Conference on Computational Linguistics and 11th Baltic Conference on Human Language Technologies (NoDaLiDa/Baltic-HLT 2025)*. 2025. <https://aclanthology.org/2025.nodalida-1.37/>.
- [20] Kiil A. Suurte keelemudelite võrdlev analüüs Eesti bioloogiaolümpiaadide küsimuste põhjal. Magistritöö. Tartu Ülikool, Arvutiteaduse instituut, 2025. <https://hdl.handle.net/10062/117055>.
- [21] Liang W., Zhang Y., Cao H., Wang B., Ding D. Y., Yang X., Vodrahalli K., He S., Smith D. S., Yin Y. jt. Mapping the Increasing Use of LLMs in Scientific Papers. *arXiv preprint arXiv:2404.01268* (2024). <https://arxiv.org/abs/2404.01268>.
- [22] Rodafinos A. The Integration of Generative AI Tools in Academic Writing: Implications for Student Research. *Social Education Research* (2025). <https://doi.org/10.37256/ser.6120255>.

- [23] Lund B. D., Mannuru N. R., Teel Z. A., Lee T. H., Ortega N. J., Simmons S. ja Ward E. Student Perceptions of AI-Assisted Writing and Academic Integrity: Ethical Concerns, Academic Misconduct, and Use of Generative AI in Higher Education. *AI in Education* (2025). <https://doi.org/10.1007/s44163-025-00261-z>.
- [24] Yuan A., Coenen A., Reif E. ja Ippolito D. Wordcraft: Story Writing With Large Language Models. *Proceedings of the 27th International Conference on Intelligent User Interfaces* (2022), lk 841–852. <https://doi.org/10.1145/3490099.3511105>.
- [25] Wang S., Scells H., Koopman B. ja Zuccon G. Can ChatGPT Write a Good Boolean Query for Systematic Review Literature Search? *Proceedings of SIGIR* (2023), lk 1426–1436. <https://doi.org/10.1145/3539618.3591703>.
- [26] Lee M., Srivastava M., Hardy A., Thickstun J., Durmus E., Paranjape A., Gerard-Ursin I., Li X. L., Ladhak F., Rong F., Wang R. E., Kwon M., Park J. S., Cao H., Lee T., Bommasani R., Bernstein M. ja Liang P. Evaluating Human-Language Model Interaction. *Transactions on Machine Learning Research (TMLR)* (2024). Viimati vaadatud: 01.03.2026.
- [27] Hendy A., Abdelrehim M., Sharaf A., Raunak V., Gabr M., Matsushita H., Kim Y. J., Afify M. ja Awadalla H. H. How Good Are GPT Models at Machine Translation? A Comprehensive Evaluation. *arXiv preprint arXiv:2302.09210* (2023). <https://arxiv.org/abs/2302.09210>.
- [28] Ji Z., Lee N., Frieske R., Yu T., Su D., Xu Y., Ishii E., Bang Y. J., Madotto A. ja Fung P. Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys* 55.12 (2023), lk 1–38. <https://doi.org/10.1145/3571730>.
- [29] Mugaanyi J., Cai L., Cheng S., Lu C. ja Huang J. Evaluation of Large Language Model Performance and Reliability for Citations and References in Scholarly Writing: Cross-Disciplinary Study. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/52935>.
- [30] Chelli M., Descamps J., Lavoué V., Trojani C., Azar M., Deckert M., Raynier J.-L., Clowez G., Boileau P. ja Ruetsch-Chelli C. Hallucination Rates and Reference Accuracy of ChatGPT and Bard for Systematic Reviews: Comparative Analysis. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/53164>.
- [31] Kim E., Kipchumba F. ja Min S. Geographic Variation in LLM DOI Fabrication: Cross-Country Analysis of Citation Accuracy Across Four Large Language Models. *Publications* (2025). <https://doi.org/10.3390/publications13020020>.

- [32] Doshi A. R. ja Hauser O. P. Generative AI Enhances Individual Creativity but Reduces the Collective Diversity of Novel Content. *Science Advances* 10.28 (2024). <https://doi.org/10.1126/sciadv.adn5290>.
- [33] Bender E. M., Gebru T., McMillan-Major A. ja Shmitchell S. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of FAccT* (2021), lk 610–623. <https://doi.org/10.1145/3442188.3445922>.
- [34] Tuulik M., Vainik E., Prangel J., Langemets M., Aedmaa E., Koppel K. ja Risberg L. Tähenduste seletamine leksikograafias: kuivõrd on abi suurtest keelemudelitest? *Eesti ja soome-ugri keeleteaduse ajakiri. Journal of Estonian and Finno-Ugric Linguistics* 16.2 (2025). Viimati vaadatud: 01.03.2026. <https://ojs.utlib.ee/index.php/jeful/article/view/24835>.
- [35] Tartu Ülikool, Loodus- ja täppisteaduste valdkond. Loodus- ja täppisteaduste valdkonna lõputööde juhend. <https://reaalteadused.ut.ee/et/loputoode-juhendid>. Viimati vaadatud: 20.02.2026. 2025.
- [36] Serikov A. ja Biloshchytskyi A. Study of the Impact of Prompt Engineering on the Quality of Generated Content for Educational Programs. *Bulletin of D. Serikbayev EKTU* (2025).
- [37] Kresevic S., Giuffrè M., Ajčević M., Accardo A., Crocè L. ja Shung D. Optimization of Hepatological Clinical Guidelines Interpretation by Large Language Models: A Retrieval Augmented Generation-Based Framework. *NPJ Digital Medicine* 7 (2024). <https://doi.org/10.1038/s41746-024-01076-x>.
- [38] Bianchi F., Suzgun M., Attanasio G., Röttger P., Jurafsky D., Hashimoto T. ja Zou J. Safety-Tuned LLaMAs: Lessons From Improving the Safety of Large Language Models that Follow Instructions. *arXiv preprint arXiv:2309.07875* (2023). <https://arxiv.org/abs/2309.07875>.
- [39] Ji B., Liu H., Du M. ja Ng S.-K. Chain-of-Thought Improves Text Generation with Citations in Large Language Models. *Proceedings of the Annual Meeting of the Association for Computational Linguistics*. 2024, lk 18345–18353.
- [40] Barbu E., Muru M.-L. ja Malva S. M. Improving Estonian Text Simplification through Pretrained Language Models and Custom Datasets. *arXiv preprint arXiv:2501.15624* (2025). <https://arxiv.org/abs/2501.15624>.
- [41] DataStudios. Perplexity AI Context Window: Token Limits, Memory Policy, and 2025 Rules. <https://www.datastudios.org/post/perplexity-ai-context-window-token-limits-memory-policy-and-2025-rules>. Viimati vaadatud: 14.03.2026. 2025.

- [42] GitHub. About Individual GitHub Copilot Plans and Benefits. <https://docs.github.com/en/copilot/concepts/billing/individual-plans>. Viimati vaadatud: 14.03.2026. 2026.
- [43] GitHub. Responsible Use of GitHub Copilot Chat in Your IDE. <https://docs.github.com/en/copilot/responsible-use-of-github-copilot-features/responsible-use-of-github-copilot-chat-in-your-ide>. Viimati vaadatud: 14.03.2026. 2026.
- [44] Nguyen N. ja Nadi S. An Empirical Evaluation of GitHub Copilot's Code Suggestions. *Proceedings of the 19th International Conference on Mining Software Repositories (MSR)*. 2022, lk 1–5. <https://doi.org/10.1145/3524842.3528470>.
- [45] GitHub. Rate Limits for GitHub Copilot. <https://docs.github.com/en/copilot/concepts/rate-limits>. Viimati vaadatud: 14.03.2026. 2026.
- [46] OpenAI. Codex: OpenAI's Coding Agent in ChatGPT. <https://openai.com/index/introducing-codex/>. Viimati vaadatud: 16.03.2026. 2025.

Lisad

I. Eksperimentides kasutatud promptide näited

Järgnevalt on esitatud näited eksperimentides kasutatud promptidest.

Prompt 1: Sissejuhatuse genereerimine (nullkontekst)

Sa oled kogenud akadeemiline kirjutaja. Kirjuta Tartu Ülikooli arvutiteaduse bakalaureusetöö sissejuhatus teemal “Masinõppe rakendamine Eesti e-tervise andmete analüüsil”. Sissejuhatus peab olema ca 2 lehekülge pikk (umbes 800–1000 sõna), kirjutatud akadeemilises stiilis eesti keeles. Sissejuhatus peab sisaldama: (1) teema tausta ja olulisuse põhjendust; (2) probleemipüstitust; (3) töö eesmärgi ja uurimisküsimusi; (4) töö struktuuri lühiülevaadet. Lisa ka asjakohased viited.

Prompt 2: Sissejuhatuse genereerimine (kontekstipõhine)

Sa oled kogenud akadeemiline kirjutaja, kes on spetsialiseerunud eestikeelsete arvutiteaduse lõputööde kirjutamisele. Järgnevalt on esitatud Tartu Ülikooli ATI lõputööde juhendi nõuded sissejuhatusele: [juhendi tekst]. Siin on näide heast sissejuhatusest varasemast bakalaureusetööst: [näidistöö sissejuhatus]. Kirjuta sarnases stiilis ja struktuuris sissejuhatus teemal “Masinõppe rakendamine Eesti e-tervise andmete analüüsil”. Järgi rangelt juhendis esitatud nõudeid.

Prompt 3: Kirjanduse ülevaate genereerimine

Kirjuta eestikeelne kirjanduse ülevaate peatükk, kasutades järgnevaid allikaid: [10 artikli kokkuvõtted]. Kirjanduse ülevaade peab olema ca 5–8 lehekülge pikk, struktureeritud teemade kaupa (mitte allikate kaupa) ja sisaldama kriitilist analüüsi. Viita igale allikale korrektselt.

Prompt 4: Korrekatuur

Vaata üle järgnev eestikeelne akadeemiline tekst. Tuvasta ja paranda: (1) grammatikavead; (2) ortograafiavead; (3) stiiliprobleemid (liiga vaba keel, ebajärjekindel terminoloogia); (4) lauseehituse probleemid. Esita parandused koos selgitustega.

II. Genereeritud sissejuhatuste näited

II.1 Gemini 3.1 Pro genereeritud sissejuhatus (lühendatud)

Masinõpe on arvutiteaduse haru, mis tegeleb algoritmidega, mis suudavad andmetest õppida ja teha ennustusi ilma selgesõnalise programmeerimiseta. Viimastel aastatel on masinõppe meetodid leidnud laialdast rakendust meditsiini ja tervishoiu valdkonnas, kus suurte andmemahtude analüüs võimaldab avastada mustreid, mida inimsilm ei suuda tuvastada.

Eesti e-tervise süsteem on üks maailma arenenumaid digitaalse tervishoiu taristuid. Tervise infosüsteem koondab patsientide terviseandmeid, digiretsepte, digiregistratuuri ja muid teenuseid ühtsesse platvormi. See loob ainulaadse võimaluse rakendada masinõppe meetodeid suuremahuliste tervishoiuandmete analüüsimiseks.

Käesoleva bakalaureusetöö eesmärk on uurida masinõppe meetodite rakendamise võimalusi Eesti e-tervise andmete analüüsimisel. [...]

Autori hinnang: Struktuur 4/5, keeleline korrektsus 3/5 (mõned käändevead), akadeemiline stiil 3/5 (kohati liiga populaarteaduslik), viited 2/5 (3 viiest viidest olid hallutsineeritud).

II.2 GPT-5.4 genereeritud sissejuhatus (lühendatud)

Tehisintellekti ja masinõppe kiire areng on viimase kümnendi jooksul avaldanud märkimisväärset mõju erinevatele teadusvaldkondadele, sealhulgas tervishoiule. Eriti oluline on see areng riikides, kus on loodud ulatuslikud digitaalsed tervishoiutaristud, mis võimaldavad suuremate andmemahtude kogumist ja analüüsi.

Eesti on e-riigi kontseptsiooni rakendamisel olnud üks eesrindlikumaid riike maailmas. Eesti tervise infosüsteem koondab rohkem kui 1,3 miljoni elaniku terviseandmed ühtsesse digitaalsesse keskkonda, pakkudes unikaalset võimalust rakendada kaasaegseid andmeanalüüsi meetodeid tervishoiu valdkonnas.

Käesolev bakalaureusetöö keskendub masinõppe meetodite rakendamisele Eesti e-tervise andmete analüüsimisel. Töö eesmärk on välja selgitada, millised masinõppe algoritmid on kõige sobivamad [...]

Autori hinnang: Struktuur 4/5, keeleline korrektsus 4/5 (üksikud sõnajärje probleemid), akadeemiline stiil 4/5 (hea üldine toon), viited 2/5 (2 viiest viidest hallutsineeritud).

II.3 Claude Sonnet 4.6 genereeritud sissejuhatuse (lühendatud)

Masinõppe meetodite rakendamine tervishoiuandmete analüüsil on muutunud üheks keskseks uurimisvaldkonnaks nii arvutiteaduses kui ka biomeditsiinis. Suurte andmemahtude kättesaadavus, arvutusvõimsuse kasv ning algoritmide täiustumine on loonud eeldused, mis võimaldavad tuvastada kompleksseid mustreid patsiendiandmetes – mustreid, mille avastamine traditsioonilistel meetoditel oleks ebapraktiline või võimatu.

Eesti digitaalse tervishoiu taristu pakub selles kontekstis erakordset võimalust. Tervise infosüsteem, mis koondab enam kui 1,3 miljoni inimese terviseandmed alates digiretseptidest kuni haiguslugudeni, moodustab ühe Euroopa kõige terviklikumatest tervishoiu andmekogudest. Selle andmekogumi potentsiaal masinõppe rakendusteks on suur, kuid süstemaatilist uurimust selle potentsiaali realiseerimise kohta on seni tehtud vähe.

Käesoleva bakalaureusetöö eesmärk on süstemaatiliselt uurida masinõppe meetodite rakendamise võimalusi ja väljakutseid Eesti e-tervise andmete kontekstis. [...]

Autori hinnang: Struktuur 5/5, keeleline korrektsus 4/5 (mõned liiga pikad laused), akadeemiline stiil 5/5 (suurepärase akadeemiline toon), viited 3/5 (1 viidest hallutsineeritud).

III. Hindamistabelite koondandmed

Tabelis 17 on esitatud kõigi eksperimentide detailsed tulemused.

IV. AI kasutamise deklaratsioon

Käesoleva bakalaureusetöö kirjutamisel kasutati järgmisi AI vahendeid:

1. **Google Gemini 3.1 Pro** – kasutati eksperimentide läbiviimiseks (teksti genereerimise katsetused) peatükkides 5 ja lisades kirjeldatud ulatuses.
2. **OpenAI GPT-5.4** – kasutati eksperimentide läbiviimiseks (teksti genereerimise katsetused) peatükkides 5 ja lisades kirjeldatud ulatuses.
3. **Anthropic Claude Sonnet 4.6** – kasutati eksperimentide läbiviimiseks (teksti genereerimise katsetused) peatükkides 5 ja lisades kirjeldatud ulatuses. Lisaks kasutati Claude'i keeleliseks korrektuuri abiks töö lõppfaasis.
4. **Anthropic Claude Opus 4.6** – kasutati eksperimentide läbiviimiseks peatükkides 5 ja 7 kirjeldatud ulatuses. Opus 4.6 mudelit kasutati Claude Code'i agentse tööriista kaudu, mis

võimaldas mudelil otse L^AT_EX faile kirjutada ja projekti hallata. Tervikliku paroolihalduri lõputöö genereerimine (eksperiment 6) teostati täielikult Claude Code'i kaudu.

5. **Claude Code (Cowork)** – Anthropic'i agentne kodeerimistööriist, mida kasutati Opus 4.6 mudeliga lõputöö genereerimiseks eksperimentis 6 ning käesoleva töö vormistamisel ja täiendamisel. Claude Code võimaldas mudelil iseseisvalt lugeda ja kirjutada L^AT_EX faile, hallata BibTeX viiteid, otsida veebist teadusallikaid ning kompileerida dokumenti.

Töö sisuline analüüs, järeldused ja argumentatsioon on autori isiklik panus. AI-genereeritud tekstinäidised lisades on selgelt märgistatud.

V. Tervikliku lõputöö genereerimise näited (Eksperiment 6)

Järgnevalt on esitatud väljavõtted eksperimentis 6 genereeritud terviklikest lõputöödest. Iga mudeli väljundist on toodud sissejuhatuse algus, et illustreerida erinevusi keeles, stiilis ja teemale vastavuses.

V.1 Claude Sonnet 4.6 – sissejuhatuse väljavõte (40 lk, eesti keeles, korrektne teema)

Tehisintellekti (AI) kiire areng viimastel aastatel on toonud kaasa põhjalikud muutused paljudes eluvaldkondades, sealhulgas hariduses ja akadeemilises kirjutamises. Suurte keelemudelite (Large Language Models, LLM) nagu OpenAI GPT-seeria, Google Gemini ja Anthropic Claude võimekus genereerida inimkeelset teksti on saavutanud taseme, mis sunnib ümber hindama traditsioonilisi arusaamu teksti loomisest, toimetamisest ja kvaliteedikontrollist. Eriti aktuaalne on küsimus, mil määral suudavad need mudelid toime tulla väiksemate keelte, nagu eesti keel, ning spetsiifiliste akadeemiliste nõuetega.

[...] Käesoleva bakalaureusetöö eesmärk on uurida tehisintellekti rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel.

Hinnang: Töö järgib teemat korrektselt, on eestikeelne, akadeemilises stiilis. Struktuur vastab TÕ nõuetele (7 peatükki + lisad + litsents). Sisaldab 25 viidet, millest ca 80% on kontrollitavad. Peamine puudus: mõned viited on hallutsineeritud; lauseehitus on kohati ülemääraselt keerukas.

V.2 GPT-5.4 – väljundi väljavõte (8 lk, inglise keeles, teostatavusjuhend)

“A complete, submission-ready bachelor's thesis written end-to-end on your behalf is not something I can produce. That would materially enable academic misconduct

(submitting work largely authored by a third party). What I can provide—aligned with the University of Tartu’s own principles for using generative AI in coursework—is a deep-research ‘thesis kit’: a rigorously sourced background review, a defensible experimental design, an evaluation rubric, and a UniTartuCS-template-aligned LaTeX project skeleton with chapter-by-chapter writing prompts and clearly marked placeholders that you must complete, verify, and take responsibility for.”

Hinnang: GPT-5.4 keeldus ülesannet täitmast ja valis väljundkeeleks inglise keele. Pakkus selle asemel teostatavusjuhendit, mis sisaldas mudelivaliku soovitusi (GPT-5.4, Gemini 1.5 Pro, tartuNLP EstLLM), eksperimendi disaini raamistikku ja LaTeX malli juhiseid. Viited on verifitseeritud ja sisukad. Akadeemilise aususe teadlikkus on silmapaistvalt tugev.

V.3 Gemini 3.1 Pro – sissejuhatuse väljavõte (39 lk, eesti keeles, vale teema)

“Generatiivse tehisintellekti (GenAI) ja suurte keelemudelite (LLM), nagu OpenAI GPT-seeria, Anthropic Claude ja spetsiifiliste koodiassistentide (GitHub Copilot, Cursor) tormiline areng ja kättesaadavus on toonud kaasa ajaloolise paradigma muutuse globaalses tarkvaraarenduses.”

“Käesoleva ulatusliku uurimuse peamine eesmärk on lahti mõtestada ja dekonstrueerida tehisintellekti tegelik, mitmetahuline ja sageli vastuoluline mõju tarkvaraarenduse produktiivsusele.”

Hinnang: Mudel genereeris sisulise ja vormiliselt korrektse töö, kuid vale teema kohta. Selle asemel, et kirjutada AI abil lõputöö genereerimise teostatavusuuringust, kirjutas mudel AI mõjust tarkvaraarenduse produktiivsusele Tartumaa IT-ettevõtetes. Eestikeelne tekst on ladus, kuid sisaldab kohati liiga ambitsioonikat stiili. Sisaldab viiteid kohalikele ettevõtetele (Nortal, Playtech, Datafox) ja globaalsetele raamistikele (DORA, SPACE, METR 2025). Teemast kõrvalekaldumine on põhimõtteline puudujääk.

V.4 Claude Opus 4.6 – sissejuhatuse väljavõte (61 lk, eesti keeles, korrektne teema, Claude Code)

Paroolide turvaline haldamine on kaasaegse digiühiskonna üks fundamentaalsemaid väljakutseid. Keskmise internetikasutaja haldab kümneid kuni sadu kontosid erinevates veebiteenustes, mis loob vajaduse usaldusväärse ja kasutajasõbraliku paroolihaldussüsteemi järele. Kuigi turukitsenduste tõttu domineerivad valdkonda suletud lähtekoodiga kommertslahendused nagu

1Password, LastPass ja Bitwarden, jääb avatud ja läbipaistev alternatiiv, mis pakub nullteadmise (zero-knowledge) arhitektuuri koos kaasaegse krüptograafilise kaitsetasemega, endiselt aktuaalseks uurimisteenaks.

Käesoleva bakalaureusetöö eesmärk on projekteerida ja arendada turvaline paroolihalduri veebirakendus, mis rakendab nullteadmise arhitektuuri, kasutades AES-256-GCM krüpteeringut ja Argon2id võtmetuletamist. [...]

Hinnang: Opus 4.6 genereeris Claude Code'i kaudu kõige mahukama ja tehniliselt sügavaima töö. 61-leheküljeline lõputöö sisaldas terviklikku tehnilist arhitektuuri, koodinäiteid, 149 automatiseeritud testi tulemusi, OWASP Top 10 analüüsi ja SUS kasutatavusuuringut (skoor 77,0). Eestikeelne akadeemiline stiil oli läbivalt suurepärase. Struktuur vastas TÜ nõuetele. Viidete hallutsineerimise määr oli madalaim (ca 15%). Peamine eelis teiste mudelite ees: tehniline detailsus, $\text{\LaTeX}$ koodi otsene genereerimine failidesse ja võime hallata terviklikku projektistruktuuri.

V.5 Genereeritud tööde võrdlev kokkuvõte

Tabel 17. Kõigi eksperimentide koondtulemused

Eksperiment	Kriteerium	Gemini	ChatGPT	Sonnet	Opus
Sissejuhatus	Struktuur	4,3	4,3	4,7	4,7
Sissejuhatus	Keel	3,7	4,3	4,0	4,7
Sissejuhatus	Tehnika	3,7	3,7	4,0	4,3
Sissejuhatus	Stiil	4,0	4,0	4,7	4,7
Sissejuhatus	Viited	2,7	2,7	3,3	3,7
Kirjandus	Struktuur	4,0	4,3	4,3	4,7
Kirjandus	Keel	3,3	4,0	3,7	4,3
Kirjandus	Tehnika	3,7	3,3	4,0	4,3
Kirjandus	Stiil	3,3	3,7	4,3	4,7
Kirjandus	Viited	3,7	3,3	4,0	4,0
Metoodika	Struktuur	4,3	4,0	4,7	4,7
Metoodika	Keel	3,3	3,7	3,7	4,3
Metoodika	Tehnika	3,3	3,3	3,7	4,0
Metoodika	Stiil	3,7	3,7	4,3	4,7
Metoodika	Viited	2,7	2,7	3,0	3,3
Tulemused	Struktuur	3,7	4,0	4,3	4,7
Tulemused	Keel	3,3	3,7	3,7	4,0
Tulemused	Tehnika	3,0	3,0	3,3	4,0
Tulemused	Stiil	3,3	3,7	4,0	4,3
Tulemused	Viited	2,3	2,3	2,7	3,3
Kokkuvõte	Struktuur	4,3	4,3	4,7	4,7
Kokkuvõte	Keel	3,7	4,0	4,0	4,7
Kokkuvõte	Tehnika	3,7	3,7	4,0	4,3
Kokkuvõte	Stiil	4,0	4,0	4,7	4,7
Kokkuvõte	Viited	3,0	3,0	3,3	3,7

Tabel 18. Tervikliku lõputöö genereerimise koondvõrdlus

Kriteerium	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Keel	Eesti	Inglise	Eesti	Eesti
Maht	39 lk	8 lk	40 lk	61 lk
Teema	Vale	Osaline	Korrektne	Korrektne
Struktuur	Lõputöö	Juhend	Lõputöö	Lõputöö
Tööriist	Antigravity	Vestlusliides	Vestlusliides	Claude Code
Juhiste järgimine	Nõrk	Keeldumine	Tugev	Suurepärane
Akad. stiil	3/5	4/5 (ingl.)	4,5/5	5/5
Viidete kvaliteet	3/5 (vale teema)	4/5	3/5	3,5/5
Praktiline kasutus	Madal	Keskmine	Kõrge	Väga kõrge

Litsents

Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks

Mina, Uku Renek Kronbergs,

1. annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) minu loodud teose

“Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine”,

mille juhendaja on Alo Peets (MSc),

reprodutseerimiseks eesmärgiga seda säilitada, sealhulgas lisada digitaalarhiivi DSpace kuni autoriõiguse kehtivuse lõppemiseni.

2. Annan Tartu Ülikoolile loa teha punktis 1 nimetatud teos üldsusele kättesaadavaks Tartu Ülikooli veebikeskkonna, sealhulgas digitaalarhiivi DSpace kaudu Creative Commons'i litsentsiga CC BY NC ND 3.0, mis lubab autorile viidates teost reprodutseerida, levitada ja üldsusele suunata ning keelab luua tuletatud teost ja kasutada teost ärieesmärgil, kuni autoriõiguse kehtivuse lõppemiseni.
3. Olen teadlik, et punktides 1 ja 2 nimetatud õigused jäävad alles ka autorile.
4. Kinnitan, et lihtlitsentsi andmisega ei riku ma teiste isikute intellektuaalomandi ega isikuandmete kaitse õigusaktidest tulenevaid õigusi.

Uku Renek Kronbergs

[kuupäev]