

TARTU ÜLIKOOL
Arvutiteaduse instituut
Informaatika õppekava

Uku Renek Kronbergs

**Teostatavusuuring: Tehisintellekti abil
eestikeelse tehnilise informaatika alase
lõputöö genereerimine**

Bakalaureusetöö (9 EAP)

Juhendaja:
Alo Peets, MSc

Tartu 2026

Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine

Lühikokkuvõte:

Käesolev bakalaureusetöö uurib tehisintellekti (TI) rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Töös võrreldakse nelja suurt keelemudelit koos agentsete tööriistadega: Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ja Anthropic Claude Opus 4.6. Kõigile kombinatsioonidele anti sama lühike eestikeelne viip, mis palus luua Tartu Ülikooli arvutiteaduse instituudi nõuetele vastava LaTeX-vormingus bakalaureusetöö, valida ise informaatikaga seotud teema ning kasutada UniTartuCS malli. Väljundeid hinnati struktuuri, mahu, kirjavigade, viidete kontrollitavuse, eestikeelse akadeemilise stiili ja juhiste järgimise põhjal. Tulemused näitavad, et agentsed tööriistad võimaldavad mudelitel luua vormilt terviklikke eestikeelseid lõputöid, kuid kvaliteet ja ohukohad erinevad märkimisväärselt. Parima tulemuse andis selles katses Claude Opus 4.6 + Cowork, samas kui Gemini 3.1 Pro + Antigravity töö sisaldas täielikult fabritseeritud empiirilist osa. GPT-5.4 käitumine sõltus oluliselt kasutatud liidesest. Peamised piirangud olid hallutsineeritud viited, kontrollimata empiirilised väited ja vähene sisuline originaalsus. Antud bakalaureusetöö järeldeb, et TI sobib lõputöö kirjutamisel abivahendiks, kuid mitte iseseisvaks autoriks.

Võtmesõnad: tehisintellekt, keelemudelid, lõputöö genereerimine, eesti keel, teostatavusuuring

CERCS: P170 Arvutiteadus

Feasibility Study: Generating an Estonian-Language Technical Computer Science Thesis Using Artificial Intelligence

Abstract:

This bachelor's thesis investigates the feasibility of using artificial intelligence (AI) to generate an Estonian-language technical computer science thesis. The study compares four large language models paired with agentic tools: Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6, and Anthropic Claude Opus 4.6. Each combination received the same short Estonian-language prompt asking it to produce a LaTeX-formatted bachelor's thesis that follows the requirements of the University of Tartu's Institute of Computer Science, chooses its own computer-science-related topic, and uses the UniTartuCS template. The outputs were assessed by structure, orthographic accuracy, citation verifiability, Estonian academic style, and instruction following. The results show that agentic tools can help models produce formally complete Estonian-language theses, but quality and risks vary substantially. The strongest result in this experiment came from Claude Opus 4.6 + Cowork, while the Gemini 3.1 Pro + Antigravity output contained a wholly fabricated empirical section. GPT-5.4 behaved very differently depending on the interface used. The main limitations were hallucinated citations, unverified empirical claims, and limited substantive originality. The thesis concludes that AI is useful as an assistive tool in thesis writing, but not as an independent author.

Keywords: artificial intelligence, language models, thesis generation, Estonian language, feasibility study

CERCS: P170 Computer science

Sisukord

1. Sissejuhatus	6
2. Taust ja kirjanduse ülevaade.....	8
2.1 Suurte keelemudelite areng.....	8
2.2 Eesti keele töötlemine keelemudelites	8
2.3 TI akadeemilises kirjutamises.....	9
3. Metoodika	12
3.1 Mudelite ja tööriistade valiku kriteeriumid.....	12
3.2 Eksperimendi ülesehitus.....	13
3.3 Hindamiskriteeriumid	16
4. TI mudelite võrdlus	17
4.1 Google Gemini 3.1 Pro	17
4.2 OpenAI GPT-5.4.....	17
4.3 Anthropic Claude Sonnet 4.6.....	18
4.4 Anthropic Claude Opus 4.6.....	18
4.5 Mudelite koondvõrdlus	19
5. Eksperiment ja tulemused.....	21
5.1 Eksperimendi ülesehitus.....	21
5.2 Claude Sonnet 4.6 (Cowork).....	22
5.3 GPT-5.4 (Codex)	23
5.4 Gemini 3.1 Pro (Antigravity).....	24
5.5 Claude Opus 4.6 (Cowork)	25
5.6 Kombinatsioonikäitumise üldised järeldused	27
5.7 Kirjavigade ja keeleliste vigade analüüs	28
5.8 Mahu ja struktuuri analüüs.....	29
5.9 Viidete kvantitatiivne analüüs.....	30
5.10 Anglitsismid ja eesti keele puhtus.....	31
5.11 Akadeemilise stiili indikaatorid.....	32
5.12 Hinnangu stabiilsus ja subjektiivsus.....	33
6. Käesoleva bakalaureusetöö enda kirjutamise töövoog	34
6.1 Kasutatud TI tööriist ja mudel	34
6.2 Etapp 1: algne ühe kasutajaviibaga katse sisukorra kavandamiseks	35
6.3 Etapp 2: iteratiivne kirjutamine ja toimetamine	35

6.4 Allikate otsimine ja bibliograafia haldamine.....	36
6.5 Kvantitatiivse analüüsi ja andmete kogumise töövoog.....	37
6.6 Kompileerimine, vormistuse kontroll ja kvaliteedi hindamine.....	37
6.7 Versioonihaldus GitHubi abil	38
6.8 Rollijaotus autori ja TI vahel	39
6.9 Piirangud ja saadud kogemused	39
6.10 Erinevus peaeksperimendi töövoost	41
7. Arutelu	42
7.1 TI tugevused lõputöö kirjutamisel	42
7.2 TI puudujäägid ja piirangud	43
7.3 Hinnakujundus ja majanduslik teostatavus	45
7.4 Eesti keele korrektuur ja toimetamine	46
7.5 Soovitused TI tööriista valikuks.....	46
7.6 Soovitused lõputöö genereerimiseks Claude Code'iga.....	47
7.6.1 Projekti ettevalmistamine	47
7.6.2 Genereerimise töövoog	48
7.6.3 Parimad praktikad.....	49
7.7 Tööriistad, mida vältida	49
7.8 Eetilised kaalutlused ja akadeemiline ausus.....	50
7.9 Tulevikuväljavaated	51
8. Kokkuvõte.....	53
Viited.....	55
Lisad	61
I. Eksperimendis kasutatud viip	61
III. Tervikliku lõputöö genereerimise näited	62
Litsents	66

1. Sissejuhatus

Suured keelemudelid (*Large Language Models*, LLM) on kahe-kolme aasta jooksul muutnud tehnoloogiaentusiastide mänguasjast igapäevaseks töövahendiks, mida kasutatakse tõsisemate tekstide koostamisel nii ettevõtetes kui ka kõrgkoolides [1]. OpenAI GPT-seeria, Google'i Gemini ning Anthropicu Claude'i mudelid suudavad tänaseks koostada sidusat akadeemilist teksti, toimetada olemasolevaid dokumente ja genereerida ka pikemaid struktureeritud kirjalikke töid [2, 3]. Väiksemate keelte, sealhulgas eesti keele, puhul on mudelite kvaliteet ebaühtlasem ning selle süstemaatiline hindamine on seni jäänud tagasihoidlikuks [4, 5].

Bakalaureusetöö on Tartu Ülikooli arvutiteaduse instituudis (ATI) esimene suurem iseseisev akadeemiline kirjatöö, mille üliõpilane peab vormistama kehtestatud juhendi kohaselt [6]. Töö valmimine nõuab tavaliselt ühte semestrit, mille käigus tuleb süveneda kirjandusse, kirjeldada metoodikat, esitada tulemused ja järgida akadeemilist stiili. Üliõpilaste seas on viimastel aastatel laialdaselt levinud TI mudelite kasutamine lõputöö kirjutamise abivahendina, kuid senised juhendid ja uurimused ei anna selget pilti sellest, kui usaldusväärselt TI mudelid sellise ülesandega eesti keeles toime tulevad [7, 8]. See küsimus on nii praktiliselt oluline (üliõpilane vajab tõenduspõhist otsust tööriista valikul) kui ka akadeemiliselt oluline (juhendajad ja ülikoolid peavad kujundama selged reeglid TI kasutamiseks).

Käesoleva bakalaureusetöö eesmärk on hinnata, kas ja kuidas tuleksid kaasaegsed TI mudelid koos tänapäevaste agentsete tööriistadega toime eestikeelse tehnilise informaatika lõputöö genereerimisega. Töö keskendub järgmistele uurimisküsimustele:

1. Millised kaasaegsete TI mudelite ja agentsete tööriistade kombinatsioonid tulevad toime mahukate eestikeelsete akadeemiliste tekstide genereerimisega?
2. Kuidas erinevad nende kombinatsioonide väljundid, kui kõigile antakse üks ja sama lühike kasutajaviip – kas ja kuidas erinevad need mudel-tööriista paarid ülesande, keelevaliku ja iseseisvalt valitud teema tajumisel?
3. Millistes lõputöö osades suudab TI pakkuda tõhusat abi ning kus on inimese panus endiselt asendamatu?
4. Millised on TI-põhise tekstigenereerimise praktilised piirangud, sealhulgas hinnapoliitika, kontekstiajna piirangud ja keelelised puudujäägid?

Uurimuse läbiviimiseks valiti antud hetkel neli juhtivat suurt keelemudelit – Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ja Anthropic Claude Opus 4.6 – ning nende juurde sobivad agentsed tööriistad. Igale mudel-tööriista kombinatsioonile anti sama lühike eestikeelne viip, mis palus genereerida UniTartuCS malli kasutava LaTeX-vormingus bakalaureusetöö. Mudelitele ei antud täiendavaid juhendeid, näidistöid ega iteratiivseid paranduspalveid. Väljundeid hinnati struktuuri, kirjavigade, viidete kontrollitavuse, eestikeelse akadeemilise stiili ja juhiste järgimise alusel.

Töö on struktureeritud järgmiselt. Peatükk 2 annab ülevaate suurte keelemudelite arengust, eesti keele töötlemise väljakutsetest ning varasematest uurimustest TI kasutamisest akadeemilises kirjutamises. Peatükk 3 kirjeldab uurimuse metoodikat ja hindamisraamistikku. Peatükk 4 võrdleb valitud mudeleid tehniliste parameetrite, kuluaspektide ja eesti keele toe lõikes. Peatükk 5 esitab ühe kasutajaviibaga genereerimise tulemused. Peatükk 6 kirjeldab käesoleva bakalaureusetöö enda kirjutamise töövoogu. Peatükk 7 tõlgendab tulemusi, käsitleb piiranguid ja annab soovitusel. Peatükk 8 võtab töö tulemused kokku.

2. Taust ja kirjanduse ülevaade

Käesolev peatükk annab ülevaate suurte keelemodelite arengust, eesti keele töötlemise spetsiifikast ning varasematest uurimustest tehisintellekti kasutamisest akadeemilises tekstiloomes.

2.1 Suurte keelemodelite areng

Suurte keelemodelite ajalugu ulatub tagasi 2017. aastasse, mil Vaswani et al. avaldasid transformeri arhitektuuri [9]. See murdepunkt pani aluse kõigile kaasaegsetele keelemodelitele. Esimesed märkimisväärsed keelemudelid, nagu BERT [10] ja GPT-2 [11], demonstreerisid, et suuremahuline eeltreenimine võimaldab mudelitel omandada laialdasi keelelisi teadmisi.

GPT-3 ilmumine 2020. aastal [2] tõi kaasa paradigmuuutuse, näidates, et 175 miljardi parameetriga mudel suudab täita mitmesuguseid ülesandeid ilma spetsiifilise peenhäälestamiseta (*fine-tuning*). Sellest ajast on mudelid kiiresti arenenud nii suuruse, arhitektuuri kui ka võimekuse poolest.

2.2 Eesti keele töötlemine keelemudelites

Eesti keel kuulub soome-ugri keelkonda ja on morfoloogiliselt rikas keel 14 käändega ning keerulise sõnamoodustuse süsteemiga [12]. See eripära teeb eesti keele töötlemise keelemodelite jaoks oluliselt keerulisemaks kui näiteks inglise keele puhul.

Suurte keelemodelite eesti keele oskus sõltub muu hulgas treeningandmete mahust ja kvaliteedist. Common Crawl'i 2026. aasta statistika järgi moodustas eesti keel HTML-lehtede põhikeelena viimastes crawl'ides ligikaudu 0,14%, samal ajal kui inglise keele osakaal oli üle 40% [13]. LLM-ide treeninguks puhastatud CulturaX andmestikus on vahe samas suurusjärgus: eesti keelt on 8,8 miljardit tokenit ehk 0,14%, inglise keelt aga 2,85 triljonit tokenit ehk 45,13% [14].

Tartu Ülikooli keeletehnoloogia uurimisrühm on teinud märkimisväärsed tööd eesti keele ressursside ja tööriistade arendamisel. EstBERT [15] on eesti keelele kohandatud BERT mudel, mis on treenitud eestikeelse tekstikorpusel. Hiljutine EstLLM projekt [5] on teinud olulisi edusamme suurte keelemodelite eesti keele võimekuse parandamisel, kasutades jätkutreenimist (*continued pretraining*) ja järeltreenimist (*post-training*) mitmekeelsete mudelite baasil. Uurimus näitas, et spetsialiseeritud treeninguga saab eesti keele kvaliteeti oluliselt tõsta, ilma et mudeli üldine arutlusvõimekus kannataks.

Mitmekeelsete mudelite arendamise seisukohast väärrib esiletõstmist Aya mudel [16], mis on juhendipõhiselt peenhäälestatud avatud lähtekoodiga keelemudel, mis toetab 101 keelt, sealhulgas mitmeid väikese ressursiga keeli. Aya ületas mT0 ja BLOOMZ mudeleid enamikus ülesannetes, demonstreerides, et sihipärase mitmekeelse peenhäälestamisega on võimalik oluliselt parandada väikeste keelte kvaliteeti. Kuulmets et al. [4] süstemaatiline hindamine näitas, et soome-ugri keelte, sealhulgas eesti keele, tugi avatud keelemudelites on viimastel aastatel kiiresti paranenud, kuid jääb endiselt inglise keelest oluliselt maha. Suurte keelemudelite puhul on ka eesti keele kvaliteet viimase kahe aasta jooksul märgatavalt paranenud. Kui varasemad GPT-3-põhised mudelid tegid eesti keeles sageli lihtsalt märgatavaid grammatilisi vigu, siis GPT-5.4, Gemini 3.1 Pro, Claude Sonnet 4.6 ja Claude Opus 4.6 suudavad luua grammatiliselt suures osas korrektset eesti keelt. Siiski esineb endiselt probleeme tehnilise terminoloogiaga, akadeemilise stiiliga ning pikematel tekstidel keelelise järjepidevuse hoidmisega. Kiil [17] on Tartu Ülikooli bakalaureusetöös võrrelnud suuri keelemudeleid eesti bioloogiaolümpiaadi küsimuste põhjal. Parim mudel saavutas 85,35% täpsuse, mis on võrreldav olümpiaadiosalejate tipptulemusega. See kinnitab mudelite kasvavat võimekust ka eestikeelsetes ainespetsiifilistes ülesannetes.

2.3 TI akadeemilises kirjutamises

Tehisintellekti kasutamine akadeemilises kirjutamises on muutunud väga aktuaalseks teemaks. Liang et al. [1] leidsid, et TI-genereeritud teksti osakaal teadusartiklites on märkimisväärselt kasvanud, eriti arvutiteaduse ja meditsiini valdkonnas. See tõstatab küsimusi akadeemilise aususe, originaalsuse ja kvaliteedikontrolli kohta.

Mitmed ülikoolid, sealhulgas Tartu Ülikool, on kehtestanud juhised TI kasutamiseks akadeemilises töös [6]. Üldiselt on lubatud kasutada TI-d abivahendina, kuid üliõpilane peab selgelt märkima, millises ulatuses ja millisel eesmärgil TI kasutati. Lõputöö ei tohi olla sisuliselt TI-genereeritud, vaid üliõpilane peab demonstreerima iseseisvat analüütilist mõtlemist.

Rodafinos [8] rõhutab, et generatiivsete TI tööriistade vastutustundlik integreerimine akadeemilisse kirjutamisse on hädavajalik, tuues esile nii efektiivsuse kasvu kui ka kvaliteedi paranemise. Rõhutades samas TI väljundite kontrollimise ja inimese järelevalve säilitamise vajadusest. Lund et al. [7] leidsid 401 USA üliõpilase küsitluses, et tudengite eetilised veendumused, mitte institutsionaalsed poliitikad, on tugevaim ennustaja TI kasutamise tajumisel akadeemilise väärkäitumisena.

Varasemad uurimused on näidanud, et TI mudelid on eriti kasulikud järgmistes akadeemilise kirjutamise aspektides:

- **Teksti struktureerimine** – mudelid aitavad koostada tekstikavandeid, peatükkide ülesehitust ja kavandipõhist mustandit; Lee et al. [18] näitasid, et eksplitsiitsed kavandid parandavad eri LLM-ide loodud tekstide kvaliteeti.
- **Kirjanduse ülevaade** – mudelid suudavad toetada kirjanduse kogumist, organiseerimist, kokkuvõtmist ja sünteesimist, kuigi allikate täpsus vajab kontrollimist [19, 20].
- **Keeleline toimetamine** – ChatGPT, Claude'i, Gemini ja Copiloti tüüpi tööriistad võivad aidata grammatika, sõnastuse, sidususe ja loetavuse parandamisel, kuid nende väljund ei ole inimtoimetajaga samaväärselt usaldusväärne [21].
- **Tõlkimine** – GPT-, Claude'i, Gemini ja DeepSeeki tüüpi mudelid suudavad pakkuda kasutatava kvaliteediga tõlkeid akadeemilisest ja tehnilisest tekstist, kuid valdkonnaspetsiifiline järeldoimetamine jääb vajalikuks [22].

Samas on tuvastatud olulisi puudujääke:

- **Hallutsinatsioonid** – mudelid võivad genereerida faktiliselt valesid väiteid või olematuid viiteid. Mugaanyi et al. [23] leidsid, et ChatGPT 3.5 genereeritud viidetest olid 72,7% loodusteadustes ja 76,6% humanitaarteadustes küll olemasolevad, kuid DOI-de ehk digitaalsete objektiidentifikaatorite (*Digital Object Identifier*) täpsus oli vaid 32,7% ja 8,5% vastavalt. Uuemad hindamised näitavad, et probleem püsib ka kirjanduse ülevaate koostamise ja veebipõhiste agentsete töövoogude puhul: Tang et al. [19] tuvastasid hallutsineeritud viiteid ka arenenud mudelite loodud kirjandusülevaadetes ning Rao ja Callison-Burch [24] hindasid GPT-5, Claude Sonnet 4.6 ja Gemini 3 Flashi veebipõhiseid väljundeid ning leidsid, et loodud BibTeX-kirjetest olid täielikult korrektsed vaid 50,9% (üldine täpsus oli 83,6%). Kim et al. [25] tuvastasid lisaks, et hallutsinatsioonimäärad on geograafiliselt ebavõrdsed – madalama sissetulekuga riikide kontekstis ületas DOI hallutsinatsioonimäär 80%.
- **Sisuline sügavus** – TI-genereeritud tekstid kipuvad olema pealiskaudsed ja väga üldistavad. Peters ja Chin-Yee [26] näitasid 4900 teaduskokkuvõtte põhjal, et ChatGPT-4o, ChatGPT-4.5, DeepSeek, LLaMA 3.3 70B ja Claude 3.7 Sonnet kaldusid teadustulemusi üleüldistama; DeepSeek, ChatGPT-4o ja LLaMA 3.3 70B puhul esines seda 26–73% juhtudest.

- **Originaalsus** – keelemudelid ei loo iseseisvalt uusi teadmisi, vaid kombineerivad olemasolevat informatsiooni. Doshi ja Hauser [27] leidsid, et generatiivne TI võib suurendada üksiku teksti loomingulisust, kuid vähendada samal ajal tekstikorpuse mitmekesisust. See toetab varasemat kriitikat mudelite tuletusliku olemuse kohta [28].
- **Väikeste keelte spetsiifika** – eesti keele ja teiste väikeste keelte puhul on kvaliteet ebaühtlasem kui inglise keeles. Kuulmets et al. [4] näitasid, et soome-ugri keelte tugi avatud keelemudelites on paranenud, kuid jääb suurtes keeltest korralikult maha. Lillepalu ja Alumäe [29] rõhutavad emakeelsete eesti keele testide vajalikkust ning EstLLM projekt [5] näitab, et eesti keele kvaliteet paraneb märgatavalt alles sihipärase jätkutreenimise ja järeltreenimisega.

3. Metoodika

Käesolev peatükk kirjeldab uurimuse metoodikat, sealhulgas TI mudelite ja agentsete tööriistade valiku kriteeriume, eksperimendi ülesehitust, ühe kasutajaviibaga (*single-prompt*) lähenemise sisu ning hindamiskriteeriumeid.

Terminoloogilise täpsuse huvides tuleb märkida, et käesolev katse ei ole *one-shot*-lähenemine selle tavapärasel masinõppe tähenduses, sest mudelile ei antud ühtegi näidislahendust. Mudelile anti üks lühike kasutajaviip ilma näideteta – seetõttu on viiba sisu mõttes täpsem kirjeldada katset kui ühe kasutajaviibaga *zero-shot* ehk *single-turn zero-shot prompting* lähenemist. Samas ei olnud kõik katsed täielikult mälukontekstist isoleeritud: kuna kasutatud tööriistade või kasutajakonto püsiv mälu võis säilitada varasemate katsete kohta infot, tuleb tulemusi käsitleda mitte rangelt sõltumatute *clean-context* katsetena, vaid praktilise kasutusolukorra simulatsioonina. Agentse tööriista sees võis mudel teha mitu sammu, näiteks faile lugeda, kirjutada, L^AT_EX-i kompileerida ja vigu parandada, kuid kasutajapoolne sekkumine piirdus ühe algse viibaga.

3.1 Mudelite ja tööriistade valiku kriteeriumid

Uurimuse jaoks mudelite valimisel lähtuti järgmistest kriteeriumidest:

1. **Eesti keele tugi** – mudel peab suutma genereerida grammatiliselt korrektset eesti keelt ning mõistma eestikeelset sisendit.
2. **Kontekstiakna suurus** – bakalaureusetöö genereerimine eeldab mahuka konteksti (juhendid, varasemalt genereeritud osad, L^AT_EX mall) töötlemist, mistõttu on vajalik piisavalt suur kontekstiaken.
3. **Agentsus ja dokumentatsioon** – mudel-tööriista kombinatsioon peab võimaldama agentset töövoogu ning omama piisavat dokumentatsiooni. Agentsuse all mõistetakse siin võimet täita kasutaja eesmärki mitmes järjestikuses sammus, kasutades vajadusel tööriistu ja failisüsteemi: lugeda olemasolevaid faile, luua või muuta L^AT_EX faile, käivitada kompileerimist ning parandada tekkinud vigu ilma iga sammu jaoks eraldi kasutajaviipa vajamata.
4. **Väljundi kvaliteet** – mudel peab suutma genereerida akadeemilisele tekstile omast stiili, struktuuri ja sisu, mis vastab Tartu Ülikooli bakalaureusetöö nõuetele.
5. **Väljundi järjepidevus** – mudel peab suutma hoida järjepidevat stiili, teemat ja struktuuri kogu töö ulatuses, mis on eriti oluline pikemate tekstide puhul.

6. **Hallutsinatsioonide tase** – mudel peab suutma genereerida võimalikult vähe faktivigu ja olematuid viiteid, mis on akadeemilises tekstis eriti problemaatiline.

7. **Hind** – mudeli kasutamine peab olema majanduslikult mõistlik üliõpilase jaoks.

Nende kriteeriumide alusel valiti neli mudelit: Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ning Anthropic Claude Opus 4.6. Opus 4.6 lisati võrdlusse kui sama mudeliperekonna võimekaim mudel, et hinnata mudeli suuruse mõju genereeritud teksti kvaliteedile. Valiku põhjendused on esitatud peatükis 4.

Lisaks valitud mudelitele testis autor ettevalmistavas faasis ka teisi keelemudeleid, sealhulgas xAI Grok 4.1 ja Moonshot AI Kimi 2.5. Samuti katsetati valitud mudelite kasutamist erinevates keskkondades ja tööriistades, näiteks Google AI Studios, Claude'i veebiliideses, ChatGPT veebiliideses ja Google Gemini veebiliideses. Need eelkatsed näitasid, et sama mudeli käitumine sõltub oluliselt kasutatavast liidest ja sellest, kas tööriist võimaldab agentset failipõhist töövoogu. Grok 4.1 ja Kimi 2.5 jäeti peaaeksperimenti võrdlusest välja, kuna autor ei suutnud erinevate viibavariantidega saada nendelt ülesandele vastavat väljundit. Genereeritud tekstide vormistus oli järjekindlalt ebakorrekne ning väljund ei vastanud bakalaureusetöö struktuurile. Seetõttu keskenduti neljale eelnimetatud mudelile ja nende tööriistadele, mis suutsid tervikliku ja kompilleeruva lõputöö genereerida.

Kuna käesolev eksperiment nõudis failisüsteemi ligipääsu ja L^AT_EX kompileerimist, ei saanud mudeleid kasutada puhta vestlusliidese kaudu. Iga mudeli kohta kasutati selle mudeli pakkuja ametlikku või laialt kasutatavat agentset tööriista: Claude Sonnet 4.6 ja Opus 4.6 puhul Anthropicu Claude Cowork, Gemini 3.1 Pro puhul Google'i Antigravity ning GPT-5.4 puhul ChatGPT Codex-it Visual Studio Code laiendusena. Oluline on rõhutada, et eksperimentis võrreldud üksused ei ole niivõrd “mudelid iseenesest”, vaid rohkem *mudeli ja agentse tööriista kombinatsioonid*. Seetõttu tuleb tulemusi tõlgendada konkreetsete mudel-tööriista paaride, mitte puhaste mudeli võimekuste näitajatena – süsteemijuhised, faili ligipääs, automaatne kompileerimine ja liidese ohutuspoliitika erinevad tööriistade lõikes ning mõjutavad väljundit. Seda piirangut on täiendavalt käsitletud peatükis 7.2.

3.2 Eksperimenti ülesehitus

Uurimus piirdus ühe eksperimentiga: igale mudel-tööriista kombinatsioonile anti üks ja sama lühike eestikeelne kasutajaviip ning lasti agentsel töövool genereerida terviklik bakalaureusetöö ilma järelküsimuste, iteratiivse suunamise või peatükkide kaupa juhendamiseta. Selline ühe

kasutajaviibaga lähenemine valiti teadlikult kahel põhjusel. Esimene põhjus on see, et lähenemine kajastab kõige ausamalt seda, kuidas keelemudelit kasutaks üliõpilane, kes soovib lõputöö kirjutamist TI-le täielikult delegeerida – see on stsenaarium, mida akadeemilise aususe kontekstis on oluline hinnata. Teine põhjus on see, et identne minimaalne sisend võimaldab nelja mudel-tööriista kombinatsiooni väljundeid kõige otsesemalt võrrelda, kuna ühtegi kombinatsiooni ei eelistata täiendava konteksti, viipade disaini (*prompt engineering*) ega iteratiivse parandamise kaudu. Kuna iga kombinatsiooni kohta tehti üks jooks, on saadud näitajad eksploratiivsed – need iseloomustavad konkreetset katset, mitte üldist mudelivõimekust.

Kasutatud viip. Kõigile mudelitele anti järgmine eestikeelne viip (täistekst on esitatud lisas I):

“Sa oled kogenud akadeemiline kirjutaja. Loo täielik bakalaureusetöö LaTeX-vormingus (lisisin töökausta vajaliku malli), mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele. Teema peab olema informaatikaga seotud ja vali ise. Autor on Uku Renek Kronbergs ja juhendaja Alo Peets (MSc).”

Viip on teadlikult lühike ja sisaldab vaid kolme sisulist piirangut: (1) väljund peab olema LaTeX-vormingus ja kasutama töökaustas olevat UniTartuCS malli; (2) töö peab vastama Tartu Ülikooli arvutiteaduse instituudi nõuetele; (3) teema peab olema informaatikaga seotud, kuid konkreetse teemavaliku teeb mudel ise. Autori ja juhendaja nimed anti tiitellehe täitmiseks. Ülikooli lõputööde juhendeid (TÜ ATI ega LOTE juhendit), varasemaid näidistöid ega muud täiendavat konteksti viibasse ei lisatud.

Agentsete tööriistade kasutamine. Kuna viip nõuab LaTeX-malli kasutamist, mitme faili haldamist ja kompileeritavat väljundit, ei saanud eksperimenti läbi viia puhta vestlusliidese kaudu, kus mudel ei suuda ise failisüsteemile ligi pääseda. Veebipõhistes vestlusliidestest piiravad sellist ülesannet ka failide koguse limiidid: Gemini Apps lubab samas viibas üles laadida kuni 10 toetatud faili, erandina ühe koodikausta või GitHubi repositooriumi kuni 5000 failiga [30]. Claude'i chat lubab kuni 20 faili vestluse kohta [31] ChatGPT piirab tavapäraseid ChatGPT üleslaadimisi kuni 80 faili kolme tunni jooksul või tasuta kontol 3 faili päevas [32]. Seetõttu kasutati iga mudeliga sellele mudelile omast agentset töövoogu:

- **Claude Sonnet 4.6** ja **Claude Opus 4.6** – Anthropicu *Cowork* agentne tööriist (mitte segi ajada sama ettevõtte eraldi tootega Claude Code), mis suudab lugeda, kirjutada ja kompileerida projekti $\text{\LaTeX}$ faile otse failisüsteemis.

- **Google Gemini 3.1 Pro** – Google'i *Antigravity* agentne arenduskeskkond, mis pakub funktsionaalselt sarnast võimekust.
- **OpenAI GPT-5.4** – OpenAI *ChatGPT Codex* laiendusega Visual Studio Code'is.

Kõigi nelja mudeli puhul piirduti ühe viibaga – pärast viiba esitamist ei antud mudelile täiendavaid juhiseid, ei parandatud genereeritud teksti ega palutud mudelil varasemaid valikuid üle vaadata. Kui mudel ise tegi agentse tööriista raames mitu sisemist sammu (failide loomine, kompileerimine, vigade parandamine), loeti see üheks genereerimistsükliks, kuna kogu töövoog algatas sama algviip.

Metoodika eelkatsed. Peaeksperimendi metoodika täpsustamiseks tegi autor enne lõpliku eksperimendi läbiviimist ulatuslikke ettevalmistavaid katseid, et leida sobivaim viip, töövoog ja agentsete tööriistade seadistus. Kokku genereeris autor näidis-lõputöid ligikaudu 25 korda, varieerides selleks viiba sõnastust, malli kasutust ja töövoogu. Lõpliku eksperimendi metoodika valiti nende eelkatsete põhjal kui kõige järjepidevama väljundi andev variant. Eelkatsed hõlmasid muu hulgas katsetusi ilma UniTartuCS LaTeX-mallita – ilma mallita jäi väljundi vormistus järjekindlalt ebakorrektses, mistõttu mall jäi viiba lahutamatuks osaks. Ebaõnnestunud eelkatsete üks korduv probleem oli ka väljundi keelevalik: peatükkide pealkirjad olid üldjuhul inglise keeles ning osa põhitekstist genereeriti samuti inglise keeles, kuigi kasutajaviip ise oli eestikeelne. Samuti testis autor alguses lõputöö genereerimist peatükkide kaupa (mudelilt paluti esmalt sissejuhatus, seejärel taust peatükk jne), kuid jõudis kiiresti järeldusele, et terve töö korraga genereerimine ja sellele järgnev iteratiivne käsitsi täiendamine annab oluliselt parema tulemuse nii teksti järjepideva stiili kui ka ajakulu poolest. Käesolevas eksperimendis kasutati selle järelduse põhjal terve lõputöö korraga genereerimist. Mudelite ja tööriistade võrdluse huvides hilisemat iteratiivset suunamist eksperimendi raames ei rakendatud.

Genereeritud väljundid. Eksperimendi tulemusena valis autor neli PDF-failiks kompileeritud bakalaureusetööd (vt peatükk 5):

- Sonnet_4.6_Cowork.pdf – 40 lk;
- Opus_4.6_Cowork.pdf – 61 lk;
- Gemini_3.1_Pro_Antigravity.pdf – 39 lk;
- GPT_5.4_Visual_Studio_Codex.pdf – 47 lk.

Lisaks salvestati GPT-5.4 tavapärase vestlusliidese kaudu saadud keelduv väljund (8-leheküljeline ingliskeelne teostatavusjuhend) võrdluseks.

3.3 Hindamiskriteeriumid

Kuna eksperiment tootis neli tervikdokumenti, keskenduti hindamisel kvantitatiivselt mõõdetavatele tunnustele, mida on võimalik genereeritud PDF-idest objektiivselt tuletada. Need täiendavad töö autori kvalitatiivset üldhinnangut ning vähendavad ühe hindaja subjektiivsusest tulenevat moonutust. Tabelis 1 on esitatud hindamisraamistik.

Tabel 1. Hindamiskriteeriumide raamistik

Kriteerium	Kirjeldus	Hindamisviis
Struktuur ja teemale vastavus	Kas töö järgib bakalaureusetöö ülesehitust (tiitelleht, kokkuvõte, sissejuhatus, peatükid, kokkuvõte, viited) ning kas valitud teema on informaatikaga seotud	Kvalitatiivne kirjeldus
Maht	Lehekülgede arv, sõnade arv ja sõnade tihedus lehekülje kohta	Kvantitatiivne mõõtmine
Keeleline korrektsus	Kirjavigade koguarv ja tihedus lehekülje kohta	Kvantitatiivne loendamine
Viidete kvaliteet	Unikaalsete allikate arv, in-text tsitaatide arv, tsitaatide tihedus lehekülje kohta ning hallutsineeritud viidete hinnanguline osakaal	Kvantitatiivne loendamine + kontroll
Akadeemiline stiil	Ülakomaga anglitsismide arv, arvutiteaduse ingliskeelsete terminite kasutus ning esimese isiku asesõnade esinemine	Kvantitatiivne loendamine
Juhiste järgimine	Väljundkeel (eesti/inglise), L ^A T _E X-vormingu kasutamine, UniTartuCS malli rakendamine, tiitellehe andmed	Binaarne/kvalitatiivne kontroll

Iga kriteeriumi kvantitatiivsed mõõtmised teostati genereeritud PDF-failidest teksti ekstraheerimise teel, jättes välja tiitellehe, kirjanduse loendi ning koodinäited juhtudel, kus see oli metoodiliselt põhjendatud. Hindamise viis läbi käesoleva bakalaureusetöö autor. Ühe hindaja kasutamise piirangut on täpsemalt käsitletud peatükis 7.

4. TI mudelite võrdlus

Käesolev peatükk esitab nelja valitud TI mudeli võrdluse, keskendudes nende tehnilistele parameetritele, agentse töövoog jaoks olulistele omadustele ja kulule. Mudelite koondvõrdlus on esitatud kolme tabelina alapeatükis 4.5: tabel 2 võrdleb tehnilisi parameetreid, tabel 3 võrdleb API hinnakirja näitajaid ning tabel 4 võrdleb lõppkasutaja kuutellimusi. Järgnevad hinnad on kõik Eestis kehtestatud 24% käibemaksuga ja Eesti hinnastusega.

4.1 Google Gemini 3.1 Pro

Google Gemini 3.1 Pro on Google DeepMind'i arendatud multimodaalne keelemudel, mis avaldati 2026. aasta veebruaris [33]. Antud mudel kuulub Gemini mudeliperekonda.

Gemini 3.1 Pro mudelil on kontekstiaken 1 miljon tokenit. Lisaks on Gemini 3.1 Pro natiivne mõtlemismudel (*thinking model*), mis tähendab, et mudel kasutab sisemist ahelpõhjamist enne vastuse andmist; see parandab oluliselt keeruliste ülesannete lahendamise kvaliteeti, sealhulgas struktureeritud teksti loomist.

Kuluaspektist oli Gemini 3.1 Pro API baasmäärade poolest üks soodsamaid võrreldud mudeleid (vt tabel 3). Sisendhind on astmeline ja sõltub konkreetse päringus kasutatava konteksti pikkusest – lühema konteksti puhul (kuni 200 000 tokenit) on sisendhind ca €2,12/MTok ja väljundi hind ca €12,70/MTok, pikema konteksti puhul vastavalt €4,23/MTok ja €19,05/MTok. Lõppkasutajale pakub Google API kõrval ka kuutellimusi: Google AI Studio Plus (7,99€) ning Google AI Pro (Gemini Advanced) hinnaga €21,99 kuus ja Google AI Ultra (274,99€) üksikasjad on koondatud tabelis 4. Kuna agentne töövoog võib sama faili mitu korda lugeda, kirjutada ja kompileerida, käsitletakse tegelikku kogukulu koondina peatükis 7.3.

4.2 OpenAI GPT-5.4

OpenAI GPT-5.4 on OpenAI juhtiv multimodaalne mudel, mis avaldati 2025. aasta detsembris [34].

GPT-5.4 kontekstiaken Codexi laiendusena ja rakenduses on 256 000 tokenit. Mudel pakub ka mõtlemisrežiimi (*reasoning*), mille intensiivsust saab reguleerida (madal/keskmine/kõrge, väga kõrge), võimaldades kasutajal valida kiiruse ja kvaliteedi vahel.

Kuluaspektist paiknes GPT-5.4 API baasmäärade poolest Sonnet 4.6-ga samasse suurusjärku (vt tabel 3): sisend €2,64/MTok ja väljund €15,87/MTok. Lisaks pakub OpenAI Pakett-API-d (*Batch API*), mis annab asünkroonsete päringute eest ligikaudu 50% allahindlust, kuid pole

interaktiivse agentse töövoo jaoks kasutatav, kuna vastuse ooteaeg võib ulatuda mitme tunnini. Kuutellimustena pakub OpenAI ChatGPT Go (8€), GPT Plus (€23) ning Pro 5x (103€) ja Pro 20x (206€) ja.

4.3 Anthropic Claude Sonnet 4.6

Anthropic Claude Sonnet 4.6 on Anthropicu arendatud keelemudel, mis avaldati 2026. aasta veebruaris [35]. Claude mudeliperekond eristub teistest oma rõhuasetusega ohutusele ja põhjalikkusele.

Claude Sonnet 4.6 kontekstiaken on 200 000 tokenit (API kaudu eraldi 1M tokeni režiim, mida autor ei kasutanud), mis on neljast võrreldud keelemudelist kõige väiksem.

Kuluaspektist oli Claude Sonnet 4.6 API baasmääradega võrreldav GPT-5.4 ja Gemini 3.1 Pro-ga (vt tabel 3): sisend €3,17/MTok ja väljund €15,87/MTok. Kuutellimuste osas pakub Anthropic Eesti regioonis kolme taset: Claude Pro (€22) Claude Max 5× (€106) ja Claude Max 20× (€212).

4.4 Anthropic Claude Opus 4.6

Claude Opus 4.6 on Anthropicu kõige võimekam keelemudel, mis avaldati 2026. aasta veebruaris [36]. Opus kuulub samasse Claude mudeliperekonda kui Sonnet, kuid on oluliselt suurem ja võimekam mudel. Claude Opus 4.6 kontekstiaken on 1M tokenit, kuid mudeli peamine eelis seisneb suuremas parameetrite arvus ja sügavamas arutlusvõimekuses.

Opus 4.6 jagab Sonnet 4.6-ga samu agentseid omadusi – pikendatud mõtlemisrežiim, tööriistakasutus, arvutikasutus, selgesõnaline promptide vahemälustamine ning teksti-, pildi- ja PDF-sisendi tugi. Suurema kontekstiakna tõttu (1M vs Sonnet'i 200K) sobib Opus paremini juhtudel, kus tervet projekti tuleb hoida samaaegselt mudeli kontekstis – näiteks kui agentne tööriist loeb iga sammu juures kõiki olemasolevaid $\text{\LaTeX}$ -faile uuesti.

Kuluaspektist oli Claude Opus 4.6 võrreldud mudelitest kõige kallim (vt tabel 3) – sisend €5,29/MTok ja väljund €26,45/MTok ehk ligikaudu 1,7 korda kallim sisendi ja väljundi pealt kui Sonnet 4.6, kuid sellega kaasnes ka kõige parem väljund. Kuutellimustega pakub Anthropic Opus 4.6-le sama Pro/Max 5×/Max 20× tasemestruktuuri kui Sonnet'ile (vt tabel 4), kuid kuna Opus tarbib päringu kohta rohkem ressursi, on Opus 4.6 mõistlikuks praktiliseks kasutuseks reeglina vaja vähemalt Max 5× tellimust. Selle kompromissi praktiline tõlgendus on esitatud peatükis 7.3.

4.5 Mudelite koondvõrdlus

Tabelites 2, 3 ja 4 on esitatud nelja mudeli koondvõrdlus, mis on jagatud kolme ossa loetavuse huvides: tehnilised parameetrid, API hinnakiri ning lõppkasutaja kuutellimused. Tabeli 2 read tuginevad mudelite pakkujate ametlikele tooteteadele [33–36] ning tabelite 3 ja 4 read tuginevad 2026. aasta mai ametlikele hinnakirjadele [37–39]. API hinnad on pakkujate poolt avaldatud USA dollarites tabelis 3 ja need on teisendatud eurodesse 2026. aasta mai vahetuskursi alusel ($1 \text{ EUR} = 1,17 \text{ USD}$ ehk $1 \text{ USD} \approx 0,853 \text{ EUR}$). Kõik hinnad sisaldavad Eesti 24% käibemaksu.

Tabel 2. TI mudelite tehniliste parameetrite võrdlus

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Avaldatud	02/2026	12/2025	02/2026	02/2026
Kontekstiaken	1M	256K (1,05M API)	200K (1M API)	1M
Max väljund (tokenites)	64 000	128 000	128 000	128 000
Mõtlemisrežiim	Jah (natiivne)	Jah (reguleeritav)	Jah (pikendatud)	Jah (pikendatud)
Max mõtlemise tokenid	natiivne	128 000	64 000	64 000
Sisendmodaalsused	Tekst, pilt, heli, video	Tekst, pilt, heli	Tekst, pilt, PDF	Tekst, pilt, PDF
Tööriistakasutus	Jah	Jah	Jah	Jah

Tabel 3. TI mudelite API hinnakirja võrdlus (EUR 1M tokeni kohta, koos 24% käibemaksuga)

Hinnakomponent	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Sisend (tavahind)	€2,12–4,23	€2,64	€3,17	€5,29
Sisend (vahemälust loetud)	€0,21–0,42	€0,26	€0,32	€0,53
Väljund	€12,70–19,05	€15,87	€15,87	€26,45

Lisaks API-le pakuvad kõik kolm pakkujat lõppkasutajatele kuutellimusi, mis võimaldavad fikseeritud kuumaksu eest mudelit kasutada vestlusliideses ja sageli ka agentses tööriistas (Codex, Cowork, Antigravity). Tellimuste koondvõrdlus on esitatud tabelis 4.

Tabel 4. Lõppkasutaja kuutellimused Eesti regioonis (EUR/kuu, koos 24% käibemaksuga)

Pakkuja	Tellimus	Hind/kuu	Olulisemad piirangud ja juurdepääs
Google	Google AI Pro (Gemini Advanced)	€21,99	Gemini 3.1 Pro vestlusliideses; piiratud Antigravity kasutus
Google	Google AI Ultra	€274,99	Kõrgeimad Gemini 3.1 Pro, AI Studio ja Antigravity limiidid; 30 TB salvestusruumi
OpenAI	ChatGPT Go	ca €8	GPT-5.3 Instant laiendatud kasutusega; rohkem faile, pildiloomet ja mälu kui tasuta plaanis
OpenAI	ChatGPT Plus	ca €23	GPT-5.4 piiratud kasutusega; Codex laienduse piiratud kvoot
OpenAI	ChatGPT Pro	ca €229	GPT-5.4 oluliselt suuremate kasutuspiirangutega; kõrgem mõtlemisrežiimi intensiivsus
Anthropic	Claude Pro	ca €22	Sonnet 4.6 + Opus 4.6 piiratult; Cowork piiratud kvoodiga
Anthropic	Claude Max 5×	ca €106	5× Pro plaani kasutuspiirangud; laiem Opus 4.6 ligipääs
Anthropic	Claude Max 20×	ca €212	20× Pro plaani kasutuspiirangud; täielik Opus 4.6 ligipääs

5. Eksperiment ja tulemused

Käesolev peatükk kirjeldab läbiviidud eksperimenti, esitab nelja mudeli genereeritud bakalaureusetööde tulemused ning analüüsib nende kvaliteeti erinevatest aspektidest lähtuvalt.

5.1 Eksperimendi ülesehitus

Eksperimendis paluti igal mudel-tööriista kombinatsioonil genereerida terviklik bakalaureusetöö informaatika valdkonnast ühe kasutajaviibiga, ilma järelküsimumste ega iteratiivse suunamiseta. Mudelitele anti identne lühike eestikeelne viip (vt peatükk 3.2 ja lisa I), mis palus mudelil luua LaTeX-vormingus bakalaureusetöö, mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele, kasutades töökausta paigutatud UniTartuCS malli. Konkreetset teemapealkirja ette ei antud – mudel pidi ise valima informaatikaga seotud teema. Autori (Uku Renek Kronbergs) ja juhendaja (Alo Peets, MSc) nimed anti tiitellehe täitmiseks.

Viip on teadlikult lühike, kuna üks uurimisküsimustest on, kuidas mudel-tööriista kombinatsioonid reageerivad minimaalsele juhisele ning kas nad suudavad iseseisvalt valida sobiva teema, keele ja struktuuri. Kuna ülesanne nõuab failihaldust, mitme $\text{\LaTeX}$ faili loomist ja kompileerimist, kasutati iga mudeliga agentset töövoogu. Sonnet 4.6 ja Opus 4.6 puhul kasutati Anthropicu Cowork'i, Gemini 3.1 Pro puhul Google'i Antigravity ning GPT-5.4 ChatGPT Codex laiendust Visual Studio Code'is.

Tulemused olid kombinatsioonide lõikes drastiliselt erinevad, nagu on näha tabelist 5. Oluline tõlgenduslik märkus veelkord: järgnevas analüüsis tuleb tulemusi vaadelda mudeli ja agentse tööriista paaride, mitte puhaste mudeli võimekuste näitajatena – iga jook tehti üks kord, mistõttu näitajad on eksploratiivsed ja võivad kordusjooksudel drastiliselt erineda.

Tabel 5. Tervikliku lõputöö genereerimise tulemuste koondülevaade

Parameeter	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Väljundkeel	Eesti	Eesti	Eesti	Eesti
Maht (lehekülgi)	39	47	40	61
Valitud teema	GenAI ja algajad progr.	RAG-põhine QA-süsteem	LLM koodiülevaatuses	Paroolihaldur
Struktuur	Lõputöö vormis	Lõputöö vormis	Lõputöö vormis	Lõputöö vormis
Agentne tööriist	Antigravity	Codex VS Code'is	Cowork	Cowork
Viited	9, 1 viga (11%)	22, 0 viga (0%)	23, 5 viga (22%)	35, 2 viga (6%)
Akad. stiil	Hea	Hea	Väga hea	Suurepärase

5.2 Claude Sonnet 4.6 (Cowork)

Claude Sonnet 4.6 + Cowork kombinatsioon genereeris 40-leheküljelise eestikeelse dokumendi, mis järgis bakalaureusetöö struktuuri. Kombinatsioon valis teemaks “Suurkeelemudelite kasutamine automaatses koodiülevaatuses” – empiirilise võrdluse GPT-4, Claude 3 Opuse ja Code Llama 70B vahel, mis põhines väidetavalt 120-st koodifragmendist koosneval testkogumil neljas veakategoorias (loogilised vead, turvaaugud, jõudlusprobleemid, stiilirikkumised) Pythoni ja Java keeles. Töö sisaldas detailseid hindamistabeleid täpsuse, saagise ja F1-mõõdiku numbritega ning kõigi mudelite kohta esitatud konkreetseid numbrid (nt GPT-4 üldine F1 = 82,5%, Claude 3 Opus 77,9%, Code Llama 70B 70,0%). Sarnaselt Gemini 3.1 Pro fabritseeritud uuringule (vt alapeatükk 5.4) on ka neid empiirilisi näitajaid tulnud käsitleda kontrollimata väidetena, kuna ühtegi sellist kontrollitud katset käesoleva uurimuse autor läbi ei viinud. Akadeemiline stiil oli tugev ja töö järgis LaTeX-malli korrektselt. Olulise vorminguveana paistis silma ka asjaolu, et tiitellehel kasutas mudel autorinime kärbitud kujul (“Uku Renek”), juhendaja nimena kohatäidet (“Prof. Vanem Juhendaja, PhD”) ning aastana “2025” (mitte 2026).

Peamised puudused olid hallutsineeritud viited (5 viga 23-st 22%), kohati keeruline lauseehitus ning 37 keele- ja kirjaviga kogu töö peale (vt peatükk 5.7), sealhulgas terminoloogilised eksimused (*finantreenimine*, *looduskeel*), näpukad (*deviatsioonid*, *annotatsioonid*) ja sõnavormivead (*hallutsinesid*). Viidete hallutsinatsioonid olid huvitavad: artiklite pealkirjad ja arXiv-identifikaatorid olid enamasti korrektsed, kuid mudel “täitis” autoriloendeid välja mõeldud

nimedega. Näiteks paberis “Towards Automating Code Review Activities” (ICSE 2021) olid loetletud autorid “Tufano M., Ni S. Y., Chromik S., Brunner R., Svyatkovskiy A., Clement C. B., Sundaresan N.”, samas kui tegelikud autorid on Rosalia Tufano, Luca Pascarella, Michele Tufano, Denys Poshyvanyk ja Gabriele Bavota. Teises näites (“Impact of Code Language Models on Automated Program Repair”, arXiv:2302.05020) loetles mudel autorid “Jiang J., Huang L., Liu Z., Lo D., Xia X.”, kuid tegelikud autorid on Nan Jiang, Kevin Liu, Thibaud Lutellier ja Lin Tan. Kõige tähelepanuväärsem juhtum oli viide “JITBot” (Pornprasit ja Tantithamthavorn, ASE 2022), kus mudel kombineeris kahe eri paberi metaandmed: JITBot eksisteerib, kuid ASE 2020 ja täiesti teiste autoritega; Pornprasit ja Tantithamthavorn kirjutasid hoopis paberi nimega “JITLine” (MSR 2021).

5.3 GPT-5.4 (Codex)

GPT-5.4 tulem erines teistest fundamentaalselt, kusjuures erinevus ei tulenenud mitte mudelist, vaid liidesest, mille kaudu mudelit kasutati. Tavapärase ChatGPT vestlusliidese kaudu keeldus mudel genereerimast terviklikku lõputööd, viidates otseselt akadeemilise aususe piirangutele. Väljundis selgitati, et täieliku bakalaureusetöö kirjutamine tudengi eest oleks vastuolus Tartu Ülikooli akadeemilise aususe reeglitega. Selle asemel pakkus GPT-5.4 välja 8-leheküljelise ingliskeelse teostatavusjuhendi (*feasibility guide*), mis sisaldas mudelivaliku soovitusi, eksperimendi disaini raamistikku, hindamismetoodikat ja $\text{\LaTeX}$ malli juhiseid. Kuigi juhend oli sisuliselt kvaliteetne ja viited olid kontrollitavad, ei vastanud see ülesande püstitusele: väljund oli inglise, mitte eesti keeles, ja vormilt pigem nõuandev memo kui akadeemiline lõputöö. See käitumine viitab sellele, et ChatGPT vestlusliidese süsteemijuhised ja ohutuspoliitika tõlgendavad “tervikliku bakalaureusetöö genereerimine” tüüpi ülesandeid vaikimisi akadeemilise aususe piirangu alla kuuluvana ning eelistavad sellistes olukordades keeldumist või nõuandvat vastust.

Täiendav katse OpenAI ChatGPT Codex laiendusega Visual Studio Code'i keskkonnas andis aga identsest viibast hoolimata oluliselt erineva tulemuse. Sama GPT-5.4 mudel suutis agentse tööriista kaudu genereerida visuaalselt teiste kombinatsioonide väljunditega sarnase tervikliku 47-leheküljelise eestikeelse dokumendi teemal “Eestikeelse RAG-põhise küsimus-vastus süsteemi kavandamine”. See erinevus näitab, et agentne töövoog muudab ülesande konteksti ja tööjaotust – ülesanne jaotub väiksemateks faili- ja kompileerimispõhisteks sammudeks ning liidese süsteemijuhised ja ohutuspoliitika on erinevad. Ehk sama mudel käitub erinevas liideses väga erinevalt. Codex laienduse kaudu genereeritud töö oli ortograafilise täpsuse poolest

silmapaistev: kogu töö peale tuvastati kolm ristkontrollitud kirjaviga (*vastusevormingun, lekita, dokumentikorpused*), mis oli nelja kombinatsiooni seas parim tulemus (vt peatükk 5.7). Lisaks oli see ainus kombinatsioon, mille kõik 22 viidet (peamiselt arXiv- ja ACL Anthology paberid) olid täielikult kontrollitavad ja korrektsete metaandmetega – ühtegi hallutsineeritud autorit, pealkirja ega aastat ei tuvastatud.

Olulise akadeemilise aususe näitajana paistab silma ka asjaolu, et Codex-laiendusega genereeritud töö ei kasutanud tiitellehel, litsentsis ega allkirjas viibas etteantud autori (Uku Renek Kronbergs) ega juhendaja (Alo Peets, MSc) nime, vaid kohatäidet *Näidisüliõpilane* ja *Juhendaja nimi, PhD*. See viitab sellele, et ka agentse töövoo kaudu säilitas mudel teatava ettevaatuse, vältides reaalse isiku nime alla allakirjastatud akadeemilise teksti otsest tootmist.

5.4 Gemini 3.1 Pro (Antigravity)

Gemini 3.1 Pro + Antigravity kombinatsioon genereeris 39-leheküljelise eestikeelse bakalaureusetöö teemal “Generatiivse tehisintellekti mõju tarkvaraarenduse produktiivsusele algajate programmeerijate seas”. Kombinatsioon valis iseseisvalt informaatika valdkonnast aktuaalse ja hästi piiritletud uurimisteema, mis käsitles suurte keelemudelite mõju programmeerimise õppimisele.

Genereeritud töö oli struktuuralselt terviklik ja sisaldas kõiki nõutud komponente. Taust ja kirjandusülevaate peatükk sisaldas transformer-arhitektuuri, kognitiivne koormust, *over-reliance*). Metoodikas oli väidetavalt 2026. aasta märtsis Tartu Ülikooli Delta õppehoone arvutiklassis läbi viidud kvaasi-eksperimentaalne katse 30 informaatika esmakursuslasega. 16 meest ja 14 naist vanuses 18–22 aastat, kes jagati 15-liikmeliseks katse- ja kontrollrühmaks ning nad kasutasid Tartu Ülikooli HPC klastris jooksatud lokaalset LLaMA-3-8B-Instruct mudelit. Lisad olid ka hästi esitatud: tagasisideküsimustik, React.js koodiredaktori komponent (ca 150 rida), PostgreSQL andmebaasi skeem (5 tabelit), Pandas/SciPy andmeanalüüsi skript (ca 160 rida) ning tudengite koodinäited koos vigade analüüsiga.

Töö tugevused olid järgmised:

- Akadeemilise struktuuriga hästi arvestatud: uurimisküsimused, hüpoteesid, statistilised testid;
- Eesti keele kvaliteet oli üldiselt hea, kuigi esines mõningaid terminoloogilisi ebajärjekindlusi;

- Viited (9 allikat) kasutasid reaalsete teadlaste nimesid (Becker, Kazemitabaar, Vaswani jt), aga lingid olid puudu.
- Koodinäited lisades olid funktsionaalsed ja loogiliselt kirjutatud;
- Töö maht (39 lehekülge) vastas bakalaureusetöö nõuetele.

Peamised puudused olid siiski suured, kusjuures esimene neist ei ole käsitletav tavapärase kvaliteedipuudusena, vaid akadeemilise väärkasutuse kõrge riskiga juhtumina:

- **Fabritseeritud empiiriline uurimus.** Kombinatsioon esitas väidetavalt 2026. aasta märtsis Tartu Ülikooli Delta õppehoones läbi viidud kvaasi-eksperimenti 30 informaatikatudengiga, sealhulgas osalejate jaotuse 15-liikmeliseks katse- ja kontrollrühmaks, konkreetset Welch'i t-testid ja standardhälbed, numbrilised tulemused (näiteks Ülesande 1 puhul katsegrupi 14,2 vs kontrollgrupi 27,5 minutit, $p < 0,001$; testide läbivuse osas 64% vs 82%) ning kirjeldatud testikeskkonna tehnilise arhitektuuri (React/TypeScript klient Monaco Editor'i baasil, Node.js/Express server, Docker liivakast koodi käivitamiseks ning kohaliku LLaMA-3-8B-Instruct mudeli kasutamine TÜ HPC klastris). Seda uurimust tegelikult ei toimunud – tudengeid, nende koode, katsekeskkonda ega statistilisi tulemusi ei eksisteeri. Lugeja, kes ei kontrolli andmeid, saab äärmiselt veenva, kuid tegelikkuses olematu uuringu.
- Viidete kontrolli järgi olid 9-st viitest 8 täielikult korrektsed ning ühel juhul oli vale 6. autor (viide [1] Becker jt 2023 “Programming Is Hard” loetles autorina “Reeves E. A.”, kuigi tegelik 6. autor on Eddie Antonio Santos – Brent N. Reeves on hoopis seotud paberiga “It’s Weird That it Knows What I Want”). Hallutsineerimismäär oli seega ca 11%.
- Eesti keele ortograafiline täpsus oli selgelt probleemne – töös tuvastati 24 riskikontrollitud kirjaviga, sealhulgas tavasõnade valed vormid (*struktuure*, *kordinaadid*, *konfliktide*), mittedõnad (*teoosiab*, *Tehisintsistendi*) ning valede tähtedega asendatud täpitähed ja nimed (vt peatükk 5.7);
- Antigravity tööriist oli vajalik käesolevas katses saadud tulemuseni jõudmiseks – autori varasemad katsed ilma agentse tööriistata andsid oluliselt nõrgema tulemuse.

5.5 Claude Opus 4.6 (Cowork)

Claude Opus 4.6 + Cowork kombinatsioon andis selles eksperimentis kõige ulatuslikuma ja kvaliteetsema väljundi – 61-leheküljelise eestikeelse bakalaureusetöö teemal “Turvalise

paroolihalduri veebirakenduse arendamine”. Cowork’i agentne tööriist võimaldas mudelil otse kirjutada L^AT_EX faile, hallata viiteid ja kompileerida dokumenti.

Genereeritud töö sisaldas terviklikku tehnilist arhitektuuri (nullteadmise põhimõte, AES-256-GCM krüpteering, Argon2id võtmetuletamine) ning täielikku React/TypeScript kasutajaliidest ja Node.js/Express taustarakendust. Lisaks *väärtis* töö, et rakendus läbis 149 automatiseeritud testi, OWASP Top 10 vastavuse analüüsi ning süsteemi kasutatavuse skaala (SUS) hindamise skooriga 77,0, ja et turvaaudit ei tuvastanud ühtegi kriitilist turvaauku. Olulise metoodilise märkusena tuleb rõhutada, et käesoleva eksperimendi autor ei teostanud nende testide, auditi ega kasutajauuringu iseseisvat läbiviimist – need näitajad on kirjas Opus 4.6 + Cowork kombinatsiooni enda genereeritud väljundis ning kuuluvad samasse kategooriasse empiiriliste väidetega, mida TI-loodud töödes tuleb inimese poolt eraldi kontrollida (vrd Gemini 3.1 Pro fabritseeritud eksperiment alapeatükis 5.4). Opus 4.6 kirjeldatud arhitektuur ja koodinäited olid siiski tunduvalt detailsemad ja sisemiselt sidusamad kui Gemini 3.1 Pro töös esitatud statistilised tulemused. Vormingulise piiranguna paistis silma asjaolu, et kõik kolm joonist (süsteemi arhitektuur, andmebaasi ER-diagramm ja võtmetuletuse skeem) on PDF-is jäetud kohatäidetena – jooniste asemel on “*Siia tuleb arhitektuuridiagramm...*” tüüpi tekstid –, mis viitab sellele, et agentne tööriist suutis küll kavandada jooniste paigutuse ja kirjeldada nende sisu, kuid ei loonud tegelikke graafilisi diagramme.

Opus 4.6 + Cowork tulemuse peamised erinevused võrreldes Sonnet 4.6 + Cowork tulemusega:

- Oluliselt suurem maht (61 vs 40 lehekülge), mis viitab sügavamale sisulisele käsitlelusele;
- Tehniline detailsus oli kõrgem – töö sisaldas konkreetseid koodi- ja arhitektuurinäiteid;
- Eesti keele kvaliteet oli ühtlasem ja loomulikum ka pikemas tekstis – kogu 61-leheküljelise töö peale tuvastati 15 ristkontrollitud keele- ja kirjaviga (näiteks *Carnegei*, *Californiya*, *taaskasutatavarteks*, *mälusest*), mis teeb kirjavigade tiheduseks 0,25 viga lehekülje kohta (vt peatükk 5.7);
- Viidete hallutsineerimise määr oli oluliselt madalam: 35-st viitest oli 33 täielikult korrektsed, kahes oli väike metaandmete viga (Hunt 2019 viites oli URL-i kuju vigane ning Gosney 2019 viites oli pealkirjas ekslikult “GTX 1080 Ti” samas kui viidatud GitHub-i gist sisaldab “GTX 1080” (ilma Ti) eelarvustuste tulemusi 2016. aastast). Hallutsineerimismäär oli seega 6% võrreldes Sonnet 4.6 22%-ga, kusjuures Sonnet’i puhul olid vead sisulisemad (välja mõeldud autorid), samas kui Opus’e vead olid puhtalt metaandmete tasemel.

5.6 Kombinatsioonikäitumise üldised järeldused

Tervikliku lõputöö genereerimise eksperiment tõi esile neli fundamentaalselt erinevat käitumismustrit, mis iseloomustasid konkreetseid mudel-tööriista kombinatsioone:

1. **Selles katses suurepärane tulemus** (Claude Opus 4.6 + Cowork): kombinatsioon genereeris kõige mahukama (61 lk) ja tehniliselt sügavaima eestikeelse lõputöö, valides teemaks paroolihalduri arendamise.
2. **Selles katses tugev tulemus** (Claude Sonnet 4.6 + Cowork): kombinatsioon genereeris mahuka ja struktureeritud väljundi (40 lk), valides teemaks suurkeelemudelite kasutamise automaatses koodiülevaatuses.
3. **Selles katses tugev tulemus, kuid fabritseeritud empiirikaga** (Gemini 3.1 Pro + Antigravity): kombinatsioon genereeris tervikliku ja hästi struktureeritud töö (39 lk) koos veenva, kuid fabritseeritud eksperimendiga, valides teemaks GenAI mõju algajate programmeerijate produktiivsusele.
4. **Liidesesõltuv käitumine** (GPT-5.4): tavapärase ChatGPT vestlusliidese kaudu keeldus mudel ülesannet täitmast akadeemilise aususe põhjendusel ja andis selle asemel 8-leheküljelise ingliskeelse teostatavusjuhendi; ChatGPT Codex laiendusega Visual Studio Code'is genereeris aga sama mudel sama viibaga tervikliku 47-leheküljelise eestikeelse dokumendi (vt peatükk 5.3). See erinevus on järgneva arutelu keskne leid ja illustreerib seda, et liidese süsteemijuhised, ohutuspoliitika ja kasutuskontekst mõjutavad väljundit sama mudeli puhul oluliselt.

Eriti tähelepanuväärne on agentsete tööriistade ja liideste mõju tulemusele. Nii Cowork (Opus 4.6 ja Sonnet 4.6 puhul), Google'i Antigravity (Gemini 3.1 Pro puhul) kui ka ChatGPT Codex (GPT-5.4 puhul) andsid oluliselt erineva tulemuse kui puhas vestlusliides – seda kinnitas kõige ilmekamalt GPT-5.4 kahe stsenaariumi vastandlik tulemus. Kõik kombinatsioonid valisid iseseisvalt erineva informaatikateema, mis näitab, kui erinevalt samale lühikesele viibale reageeritakse. Isegi kõige edukamad tulemused (Opus 4.6 + Cowork, GPT-5.4 + Codex ja Gemini 3.1 Pro + Antigravity) vajasis inimese järeltöötlust: viidete kontrolli, terminoloogia ühtlustamise ja fabritseeritud andmete tuvastamise osas. Kuna iga kombinatsiooni kohta tehti vaid üks jook, ei saa ühe jooksu põhjal väita, et üks mudel on üldiselt parem kui teine – saab väita üksnes, et selles eksploratiivses katses andis konkreetne mudel-tööriista kombinatsioon konkreetse tulemuse. Genereeritud tööde väljavõtted on esitatud lisas III.

5.7 Kirjavigade ja keeleliste vigade analüüs

Eesti keele kvaliteedi täpsemaks hindamiseks vaadati eraldi üle iga genereeritud lõputöö keele- ja kirjavead – see tähendab ortograafilised näpukad, valed tähed, puuduvad või liigsed tähed, sõnade valed vormid, terminoloogilised väärvormid ning pärisnimede vead. Analüüsist jäeti välja kontekstis korrektsed, kuid stiililiselt ebaõnnestunud laused, samuti vead, mis ilmnesisid üksnes PDF-ist teksti ekstraheerimise kodeeringuartefaktidena. Sama vormi kordumine mitmel leheküljel koondati ristkontrollitud loendis ühele reale. Tabelis 6 on esitatud vigade koondarv iga töö kohta ning arvestuslik tihedus lehekülje kohta.

Tabel 6. Genereeritud tervikliku lõputöö keele- ja kirjavigade koondarv

Mudel	Maht (lk)	Keele- ja kirjavigade arv	Vigu lk kohta
Gemini 3.1 Pro (Antigravity)	39	24	0,62
Claude Sonnet 4.6 (Cowork)	40	37	0,93
Claude Opus 4.6 (Cowork)	61	15	0,25
GPT-5.4 (Codex)	47	3	0,06

Tulemused näitavad nelja mudeli vahel märkimisväärt erinevust eesti keele täpsuse osas. GPT-5.4 Codex laienduse kaudu genereeritud töös tuvastati kogu 47-leheküljelise dokumendi peale kolm selget kirjaviga: *vastusevormingun*, *lekita* ja *dokumentikorpused*. See jäi ristkontrollitud loendi põhjal nelja kombinatsiooni madalaimaks veamääraks.

Claude Opus 4.6 töös tuvastati 61 lehekülje peale 15 keele- ja kirjaviga. Lisaks pärisnimede vigadele (*Carnegei*, *Californiya*) esines tavasõnade ja liitvormide eksimusi, näiteks *taaskasutatavarteks*, *juhusiku*, *mälusest*, *konteineriena*, *mõnasekundi* ja *stsenaariumm*. Opuse veamäär jäi siiski madalaks, sest töö oli võrdluse kõige mahukam.

Claude Sonnet 4.6 töös oli ristkontrollitud loendi järgi kõige suurem keeleliste vigade koondarv: 37 leidu 40 lehekülje kohta. Vead olid muustriliselt mitmekesised. Korduvad topelttähed avaldusid sõnades *deviatsiooonid*, *annotatsiooonid* ja *genereeeritud*; lühitähed olid puudu või asendunud vormides *Eeltrenimine*, *kategoriad*, *kodile treenitud* ja *suurkeel mudeli*. Lisaks esines terminoloogilisi või tõlkevaldkonna eksimusi, näiteks *finantreenimine*, *looduskeel*, *informeerimise taastamine* ja *kaksikeliigsust*. Mõned vead olid pigem sõnavaliku- või grammatikavead, näiteks *kasumlikkusest* õige *kasulikkusest* asemel ning *tööriistad ületas* õige *tööriistad ületasid* asemel.

Gemini 3.1 Pro genereeritud töös tuvastati 39 lehekülje kohta 24 ristkontrollitud kirjaviga. Vead jagunesid mitmesse põhikategooriasse. Levinuima kategooria moodustasid puuduvate või vahetatud tähtedega tavasõnad (*strukuure, kordinaadid, vektorruumi, konfliktide, sepsifüiliste, uenit, ekponentvõimendi, hariduteadusele*). Teise rühma kuulusid valede tähtedega asendatud täpitähed või häälikud (*narvivõrgu, moita*). Kolmandana esinesid moodustatud mittesõnad või tugevalt vigased vormid (*teoosiab, Tehisintsistendi, algasestatud, vetiaknakujuline*). Lisaks esines pärisnime viga *Düning-Krugi* õige *Dunningi-Krugi* asemel.

Kokkuvõttes näitas madalaimat veatihedust GPT-5.4 agentse tööriista kaudu, sellele järgnes Claude Opus 4.6. Sonnet 4.6 suurem koondarv tulenes osaliselt sellest, et ristkontrollis arvestati lisaks ortograafilistele näpukatele ka terminoloogilisi ja sõnavormivigu. Gemini 3.1 Pro puhul oli probleem teistsugune: vigu oli vähem kui Sonneti koondloendis, kuid need olid sagedamini silmatorkavad ortograafilised vead ja mittesõnad. See tulemus rõhutab, et automaatse korrektuuri tööriista (nt `aspell`, `hunspell`, `JVKS`) või täiendava keelelise toimetamise etapp on TI-ga genereeritud tekstide puhul vältimatu – eriti mudelite korral, mille treeningandmetes on eesti keele osakaal väiksem.

5.8 Mahu ja struktuuri analüüs

Lisaks keele- ja kirjavigadele uuriti iga genereeritud töö mahtu ja sisemist struktuuri. Mahu hindamiseks loeti kokku kogu PDF-failist eraldatud sõnad (sealhulgas tekst, tabelite sisu, lisad ja viited) ning arvutati välja sõnade arv lehekülje kohta. Struktuuri hindamiseks loendati nummerdatud alapeatükkide, tabelite, jooniste ja koodinäidete arv kogu töös. Tulemused on esitatud tabelis 7.

Tabel 7. Genereeritud tööde maht ja struktuurielemendid

Mudel	Lk	Sõnu	Sõnu/lk	Alapt.	Tab.	Joon.
Gemini 3.1 Pro	39	7 230	185	20	2	0
GPT-5.4 (Codex)	47	9 669	206	49	7	2
Claude Sonnet 4.6	40	9 739	243	32	7	0
Claude Opus 4.6	61	10 749	176	27	11	3

Andmetest joonistuvad välja mitmed huvitavad mustrid. Kõige suurema mahu (10 749 sõna) genereeris ootuspäraselt Claude Opus 4.6, mille väljund hõlmas ka kõige rohkem jooniseid (3) ning kompaktselt jaotatud sisu (176 sõna lehekülje kohta – madalaim näitaja, mis tuleneb

suuremast hulgast koodinäidetest, tabelitest ja diagrammidest). Claude Sonnet 4.6 paistis silma kõige tihedama tekstilise sisuga (243 sõna lehekülje kohta), kuid kasutas struktuuri rikastamiseks vähem tabelleid (7) kui GPT-5.4 (7) ja Opus 4.6 (11) ning erinevalt teistest kombinatsioonidest ei sisaldanud ühtegi joonist. Kõige granulaarsema struktuuriga töö genereeris GPT-5.4 (Codex) – 49 alapeatükki 47 lehekülje peale –, kus iga alapeatükk käsitles selgelt eristatud arhitektuurilist või hindamistasandi küsimust. Gemini 3.1 Pro maht oli väikseim (7 230 sõna) ja sõnatihedus mõõdukas (185 sõna lehekülje kohta), mis koos jooniste puudumisega viitab pinnapealsemale käsitlusele.

Eraldi tasub märkida, et Gemini 3.1 Pro töös ei kasutatud ühtegi joonist (ainult tabelleid ja koodinäiteid), mis on bakalaureusetöö kontekstis ebatavaline – enamik tehnilisi lõputöid sisaldab arhitektuuriskeeme või andmevoo diagramme. Sonnet 4.6 ja Gemini 3.1 Pro eelistasid suuremas mahus koodinäidete (Listings) lisamist (vastavalt 7 ja 5 koodinäidet), samas kui Opus 4.6 ja GPT-5.4 integreerisid koodinäited tihedamalt teksti sisse, ilma neid eraldi nummerdatud koodinäidete plokkidena vormistamata.

5.9 Viidete kvantitatiivne analüüs

Akadeemilise töö üks olulisi kvaliteedinäitajaid on viidete kasutamise tihedus ja allikate hulk. Iga töö kohta loeti kokku kasutatud viidete koguarv (kirjanduse loendis esitatud unikaalsed allikad), tekstis tehtud tsitaatide arv ($[N]$ tüüpi viidete esinemiskorrad enne kirjanduse loendit) ning arvutati tsitaatide tihedus lehekülje kohta. Tulemused on esitatud tabelis 8.

Tabel 8. Genereeritud tööde viidete analüüs

Mudel	Unikaalseid viiteid	In-text tsitaate	Tsitaate lk kohta	Tsitaadi/viite suhe
Gemini 3.1 Pro	9	13	0,33	1,44
Claude Sonnet 4.6	17	23	0,58	1,35
GPT-5.4 (Codex)	22	28	0,60	1,27
Claude Opus 4.6	35	45	0,74	1,29

Tulemused näitavad, et Claude Opus 4.6 lisis kõige rohkem viiteid (35 unikaalset allikat ja 45 in-text tsitaati), saavutades ka kõrgeima tsitaaditiheduse 0,74 tsitaati lehekülje kohta. See vastab paroolihalduri valdkonna iseloomule, kus on vaja viidata krüptograafilistele standarditele (NIST, IETF RFC), turvauuringutele ja olemasolevatele lahendustele. GPT-5.4 (22 viidet) ja Claude

Sonnet 4.6 (17 viidet) jäid keskmisesse vahemikku. Gemini 3.1 Pro paistis silma väikseima viidete arvuga (9 unikaalset allikat 39 lehekülje peale), mis on bakalaureusetöö kontekstis tagasihoidlik – tüüpilistes arvutiteaduse bakalaureusetöös on allikate arv sageli kõrgem kui kümme, eriti kirjanduse ülevaadet sisaldavate tööde puhul. See näitaja kinnitab üldist tähelepanekut, et Gemini 3.1 Pro genereeritud töö oli pigem mahukas-fabritseeritud kui allikatega põhjendatud.

Tsitaadi/viite suhe (in-text tsitaate jagatud unikaalsete allikate arvuga) näitab, mitu korda iga allikat keskmiselt korduvalt kasutati. Kõik mudelid jäid 1,27–1,44 vahemikku, mis viitab sellele, et enamikku allikaid kasutati tekstis vaid 1–2 korda. See on bakalaureusetööde puhul tüüpiline näitaja. Oluline on siiski rõhutada, et see analüüs ei hinda viidete *sisulist* korrektsust ega kontrollitavust – osa viidetest olid hallutsineeritud, eriti Sonnet 4.6 (ca 20%) ja Opus 4.6 (ca 15%) töödes.

5.10 Anglitsismid ja eesti keele puhtus

Eestikeelse akadeemilise teksti üks kvaliteedinäitajaid on tõlkimata jäetud või eesti keele konventsioonidest erinevate ingliskeelsete terminite vähene esinemine. Tartu Ülikooli ATI lõputööde juhend [6] rõhutab, et “firmade, toodete ja programmide nimed ei ole terminid” ning võõrkeelsed erialaterminid tuleks esimesel esinemisel tuua koos eestikeelse vaste ja kursiivis originaaliga. Selle põhjal on käesolevas analüüsis oluline eristada kolme erinevat tüüpi ingliskeelseid sõnu:

1. **Vältimatud valdkonnaspetsiifilised tehnilised terminid** – rahvusvaheliselt juurdunud standardi- või spetsifikatsiooniterminid, millel puudub ühtne ja üheselt arusaadav eestikeelne vaste (nt *salt*, *nonce*, *hash*, *token*, *RAG*, *transformer*). Need esinevad ka Eesti arvutiteaduse erialases kirjanduses ning nende säilitamine originaalkujul koos eestikeelse selgitusega on üldiselt aktsepteeritud.
2. **Toote-, firma- ja tehnoloogianimed** – nt *Google*, *Claude Code*, *Cowork*, *Antigravity*, *OWASP*. Juhendi järgi ei ole need sisuliselt terminid ega anglitsismid, vaid pärisnimed ning ülakoma kasutamine käändelõppude eraldamiseks (*Google'i*) on kooskõlas eesti keele konventsiooniga.
3. **Välditavad inglismõjud** – arvutiteaduse ingliskeelsed sõnad, millel on juurdunud eestikeelne vaste ja mis seetõttu on stiilivalikuna tõlgitavad (nt *prompt*, *pipeline*, *benchmark*, *over-reliance*, *feature branch* ilma selgituseta). Need on kitsamas tähenduses “anglitsismid”, mille hulk iseloomustab kõige otsesemalt eestikeelse stiili puhtust.

Käesoleva analüüsi raames loendati esialgselt unikaalsed ülakomaga käändelõppudega vormistatud ingliskeelsed sõnad ja arvutiteaduse tehnilised terminid eristamata, ilma neid kolme kategooriasse süstemaatiliselt jaotamata; tulemused sellisel kujul on esitatud tabelis 9. Analüüsist jäeti välja koodinäited ja kirjanduse loend.

Tabel 9. Genereeritud tööde anglitsismide analüüs (kategooriad eristamata)

Mudel+tööriist	Unikaalseid ülakomaga anglitsisme	CS-anglitsisme tekstis	Anglitsisme/lk
Claude Sonnet 4.6 + Cowork	5	1	0,15
GPT-5.4 + Codex	4	11	0,32
Claude Opus 4.6 + Cowork	3	25	0,46
Gemini 3.1 Pro + Antigravity	6	22	0,72

Mõõdiku piirang ja tõlgendus. Tabeli 9 “Anglitsismide/lk” näitaja koondab eeltoodud kolme kategooriat üheks arvuks ning on seetõttu tõlgenduslikult ebatäpne – see karistab ühtmoodi nii välditavaid inglismõjusid kui ka vältimatuid standardtermineid ja pärisnimesid. Praktikas tähendab see, et valdkonnas, kus standardsed terminid on originaalkujul (krüptograafia, standardid, turvalisus), tõuseb mõõdik, kuigi tekst järgib aktsepteeritud akadeemilist konventsiooni. Claude Opus 4.6 + Cowork kombinatsiooni suhteliselt kõrge CS-anglitsismide arv (25) tuleneb suures osas just sellistest vältimatutest terminitest: *hash*, *token*, *AES-256-GCM*, *Argon2id*, *HKDF*, *PBKDF2* on IETF/NIST standardites kinnistunud ega oma üheseid eestikeelseid vasteid, mida paroolihalduri kontekstis kasutatakse. Claude Sonnet 4.6 + Cowork TI-teema vältis seda probleemi osaliselt, kuna selle valdkonna terminoloogias on eesti keeles juba mitmeid kinnistunud vasteid. Gemini 3.1 Pro + Antigravity kasutab anglitsisme kõige rohkem (0,72/lk), sealhulgas paralleelselt nii eesti- kui ingliskeelseid vasteid (näiteks *äärejuht* (*ingl. edge case*)). Täpsem kolmekategooriline loendus, mis eristaks välditavaid inglismõjusid vältimatutest terminitest ja pärisnimedest, annaks täpsema pildi ja on edasiste uurimuste oluline meetodiline täiendus; käesoleva töö tulemusi tuleks tõlgendada seda piirangut arvestades.

5.11 Akadeemilise stiili indikaatorid

Eestikeelses akadeemilises kirjutamises eelistatakse umbisikulist stiili (passiivi ja umbisikulist tegumoodi) ning välditakse esimese isiku ainsuse (*ma*, *mina*) ja mitmuse (*me*, *meie*) kasutamist.

Iga genereeritud töö puhul loendati esimese isiku asesõnade (*ma, mina, me, meie, meil, meid, minu*) esinemine peamises tekstis (välja arvatud litsents ja autorluse kinnitus). Tulemused on esitatud tabelis 10.

Tabel 10. Esimese isiku asesõnade kasutus genereeritud töödes

Mudel	Esimese isiku asesõnu	Hinnang
Claude Opus 4.6	0	Suurepärane
GPT-5.4 (Codex)	2	Suurepärane
Claude Sonnet 4.6	2	Suurepärane
Gemini 3.1 Pro	4	Hea

Kõik neli mudelit järgisid eestikeelset akadeemilist stiili väga hästi: esimese isiku asesõnu kasutati minimaalselt (0–4 esinemist kogu töö peale). Claude Opus 4.6 ei kasutanud ühtegi esimese isiku asesõna terve 61-leheküljelise töö peale, mis on ideaalne tulemus. Gemini 3.1 Pro neli esinemist on samuti vastuvõetav, kuid mõnevõrra kõrgem teistest. See näitab, et tänapäevased suured keelemudelid on eesti akadeemilise stiili konventsioonid hästi õppinud, mis on kooskõlas peatükis 7.1 esitatud üldise hinnanguga TI mudelite akadeemilise stiili oskusele.

5.12 Hinnangu stabiilsus ja subjektiivsus

Kuna hindamise viis läbi üks hindaja (autor), ei olnud võimalik mõõta hindajatevahelist kooskõla. Subjektiivsuse vähendamiseks tugineti võimalikult palju kvantitatiivselt mõõdetavatele tunnustele (keele- ja kirjavigade arv, lehekülgede ja sõnade arv, viidete arv, anglitsismide arv, esimese isiku asesõnade arv), mille korral ühe hindaja otsustusruum on piiratud ja mille tulemused on põhimõtteliselt reprodutseeritavad. Kvalitatiivsete hinnangute osas (näiteks teksti sisuline sügavus ja akadeemiline stiil) vaatas autor iga teksti läbi mitmel korral eri aegadel. Ühe hindajaga uurimisüleschituse piiranguid on käsitletud peatükis 7.

6. Käesoleva bakalaureusetöö enda kirjutamise töövoog

Peatükis 5 kirjeldatud eksperiment uuris ühe kasutajaviibaga (*single-prompt*) tervikliku töö genereerimist. Käesolev bakalaureusetöö ise ei ole ühe viiba tulemus: selline lähenemine ei vastaks akadeemilise aususe põhimõtetele (vt peatükk 7.8) ega annaks ka soovitud kvaliteeti. Selle asemel kasutati etapiviisilist, inimese juhitud töövoogu, mis järgib peatükis 7.6 esitatud soovitusi. Käesolev peatükk kirjeldab selle töövoogu konkreetseid samme, kasutatud tööriistu, autori ja TI rollijaotust ning saadud praktilisi kogemusi, et pakkuda läbipaistvat ülevaadet sellest, kuidas TI-d lõputöö kirjutamise protsessis vastutustundlikult rakendati.

6.1 Kasutatud TI tööriist ja mudel

Käesoleva bakalaureusetöö kirjutamise käigus kasutati agentse TI tööriistana Anthropicu **Claude Code**'i – agentset kodeerimis- ja tekstiloomise tööriista, mis integreerub otse arenduskeskkondadesse nagu Visual Studio Code [40] ning erinevalt vestlusliidese-põhistest tööriistadest saab iseseisvalt lugeda ja kirjutada faile, käivitada käsurea kāske ning hallata projekti failisüsteemi. Tööriist töötas otse autori kohaliku arenduskeskkonnaga (Visual Studio Code Windowsi platvormil) ning omas ligipääsu projektikaustale $\text{\LaTeX}$ allikfailide, bibliograafia, jooniste ja kompileeritud PDF-i näol. Peamise mudelina kasutati Claude Opus 4.6 pikendatud mõtlemisrežiimiga, kuna mahuka eestikeelse akadeemilise teksti toimetamisel eristus see mudel selgelt kvaliteedi poolest (vt peatükk 4.4). Kiiremate või vähem keerulise sisuga sammude jaoks (nt lühike kirjavigade kontroll, ühe lõigu sõnastuse parandus) piisas ka Claude Sonnet 4.6 mudelist, mis oli oluliselt odavam. Peaeksperimentis kasutatud tööriist Cwork (vt peatükk 5.5) on Claude Code'i lähedane sugulane ning mõlemad oleksid käesoleva töö kirjutamise jaoks sobinud; Claude Code valiti selle tiheda lõimingu tõttu Visual Studio Code arenduskeskkonna ja Giti tööriistadega.

Claude Code'i oli töö kirjutamise ajal võimalik kasutada nii Visual Studio Code laiendusena kui ka eraldiseisva töölaarakendusena. Autori praktilise kogemuse põhjal olid vastused töölaarakenduse kaudu otse kasutades märgatavalt kiiremad kui VS Code laienduse kaudu – sama mudeli ja sama päringu puhul reageeris töölaarakendus tajutavalt kohesemalt, mis oli eriti märgatav pikemate parandusvoorude ja kompileerimistsüklike puhul. Seetõttu kasutati pikematele parandusvoorudele Claude Code'i töölaarakendust, samas kui VS Code laiendus jäi kasutusse siis, kui samas sessioonis oli vaja otse toimetada koodi või $\text{\LaTeX}$ vorminduse üksikasju arenduskeskkonnas.

Täiendavalt kasutati järgmisi abivahendeid: Zotero (lõputöö algfaasis allikate kogumiseks ja BibTeX-i ekspordiks), Overleaf ja kohalik TeX Live (L^AT_EX kompileerimiseks), GitHub (versioonihalduseks) ning veebibrauser iga viidatava allika käsitsi kontrollimiseks.

6.2 Etapp 1: algne ühe kasutajaviibaga katse sisukorra kavandamiseks

Töö algetapis teostati sama ühe kasutajaviibaga katse, mida rakendati peaeksperimentis, et kaardistada võimalikku struktuuri ja teemade jaotust. Katse väljundit kasutati üksnes kavandamise abina: see aitas näha, milliseid peatükke mudel ise oluliseks peab, kuid peatükid kirjutati hiljem uuesti autori poolt, tuginedes loetud kirjandusele ja eksperimendi tulemustele. Algset mustandteksti käesolevasse töösse ei kopeeritud; võimalikke üldsõnalisi kattuvusi kontrolliti ja sõnastati ümber.

6.3 Etapp 2: iteratiivne kirjutamine ja toimetamine

Pärast esialgset kaardistust mindi üle iteratiivsele kirjutamisele, kus autor hoidis sisulist kontrolli ja TI tööriist tegutses keelelise ning vormistusliku abivahendina. Iteratsiooni üldised sammud olid järgmised.

1. **Autori sisuline kirjutamine ja eksperimendi läbiviimine.** Sisulised otsused, uurimisküsimuste sõnastus, eksperimendi disain, nelja genereeritud tervikliku töö hindamine, kvantitatiivsed mõõtmised (kirjavigade loendus, viidete analüüs, anglitsismide loendus, esimese isiku asesõnade loendus) ja tulemuste tõlgendamine tegi autor iseseisvalt. TI-le ei antud ülesandeks ise järeldusi teha ega andmeid tõlgendada.
2. **Peatüki mustandi koostamine autori poolt.** Iga peatüki esimene versioon kirjutati autori poolt käsitsi, tuginedes loetud kirjandusele ja eksperimendi tulemustele. Sellega tagati, et argumentatsiooni loogika ja peamised väited lähtuvad autori enda mõttekäigust.
3. **Manuaalne ülevaatus.** Autor luges iga peatüki kriitiliselt üle, tuvastas probleemid (kohmakad laused, ebatäpsed väited, numbriliste andmete ebakõlad, puuduvad viited, korduvused) ja märkis kohad, mida tuleb parandada.
4. **Konkreetsed parandusepalved TI-le.** Autor palus agentsel TI tööriistal teha konkreetseid, kitsalt piiritletud parandusi, näiteks kirjavigade ja näpukate otsimine ning parandamine, liiga pikkade lausete tükeldamine, lauseehituse ühtlustamine akadeemilisele stiilile, sektsioonidevaheliste vastuolude ja numbriliste ebakõlade tuvastamine, viidete formaadi ja järjekorra kontroll ning L^AT_EX vormistuse parandamine. Üldisi palveid stiilis “kirjuta

see peatükk ümber” teadlikult välditi, kuna need on seotud suurema riskiga, et TI lisab alusetut sisu või muudab autori mõtet.

5. **Autori otsus iga muudatuse kohta.** TI soovitatud muudatused vaatas autor enne vastuvõtmist üle; osa soovitusi lükati tagasi, kui need kaldusid autori mõttest kõrvale, lisasid alusetut sisu või muutsid sõnastust ebatäpsemaks. Eriti jälgiti seda, et TI ei lisaks omaalgatuslikult uusi faktiväiteid, mida autor ei saaks allikast kinnitada.
6. **Korduv iteratsioon.** Samme 3–5 korrati iga peatüki puhul mitu korda, kuni tekst vastas soovitud kvaliteedile. Keskmiselt läbis iga peatükk mitu selget redaktsioonivooru, millest osa keskendus sisule ja struktuurile ning osa vormistusele ja keelekorrekturele.

6.4 Allikate otsimine ja bibliograafia haldamine

Allikate kogumine ja kontrollimine toimus teadlikult eraldiseisva töövooguna, et vältida peaeksperimendis täheldatud hallutsineeritud viidete probleemi (vt peatükk 5.9). TI-le ei delegeritud viidete “välja mõtlemist”; selle asemel järgiti järgmist distsipliini.

- **Allikate otsimine toimus inimese juhtimisel.** Autor otsis iga väite kinnitamiseks allikaid käsitsi Google Scholaris, arXivis, ACL Anthology ja ACM Digital Library kaudu, eelistades eelretsenseeritud ajakirju, konverentsiartikleid ja mudelite ametlikke dokumentatsioonilehti.
- **Iga viide lisati BibTeX-faili käsitsi,** kasutades Zotero-st saadud ekspordikirjet või väljaandja veebilehelt saadud viitekirjet. Enne lisamist kontrolliti, et DOI või URL viiks olemasolevale tööle.
- **TI roll piirdus formaadi kontrolliga.** Claude Code’il paluti kontrollida, kas kõik tekstis esinevad `\cite{}` võtmed leiduvad BibTeX-failis, kas BibTeX-kirjed on süntaktiliselt korrektsed ja kas välju (`url`, `doi`, `howpublished`) on täidetud ühtselt. TI-l ei lubatud uusi viiteid ise juurde lisada ega olemasolevaid muuta ilma autori eelkinnitusega.
- **Viidete sisulise kontrolli tegi autor.** Iga tsiteeritud väite puhul avas autor allika ja veendus, et allikas tegelikult toetab väidet, mille kõrval viide seisab. See takistas nii hallutsinatsioonide kui ka valede parafraside levimist.

Selle töövoogu tulemusena sisaldab käesoleva töö bibliograafia vaid olemasolevaid ja kontrollitud allikaid, erinevalt peaeksperimendi genereeritud töödest, kus 0–22% viidetest olid

hallutsineeritud (kõige levinumalt välja mõeldud autorid või kombineeritud metaandmed kahest eri paberist).

6.5 Kvantitatiivse analüüsi ja andmete kogumise töövoog

Peatükkides 5.7–5.11 esitatud arvulised tulemused (keele- ja kirjavigade arv, viidete arv, anglitsismide arv, esimese isiku asesõnade arv) koguti järgmise protseduuri alusel.

1. **PDF-ist teksti ekstraheerimine.** Iga genereeritud tervikliku töö PDF-fail (vt lisa II) muudeti tekstiks, jättes välja tiitellehe ja kirjanduse loendi juhtudel, kus see oli metoodiliselt põhjendatud.
2. **Automaatne eelotsing TI abiga.** Claude Code'il paluti otsida eraldatud tekstist konkreetseid mustreid: tõenäolised kirjavead, ülakomaga võõrsõnad ($[a-zA-Z]^+ [a-zõäöü]$), tüüpilised arvutiteaduse ingliskeelsed terminid (*prompt*, *pipeline*, *benchmark*, *over-reliance* jt) ning esimese isiku asesõnad. Iga leid esitati autorile koos konteksti reaga.
3. **Inimese lõplik otsus iga leiu kohta.** Autor otsustas iga TI tuvastatud kandidaadi kohta eraldi, kas tegemist on tõepoolest kirjaveaga, anglitsismiga või esimese isiku asesõnaga, või näiteks kontekstis sobiva tsitaadi või pärisnimega. See kaheetapiline lähenemine (masin tuvastab kandidaadid, inimene kinnitab) vähendas nii väärnegatiivide kui ka väärpositiivide hulka võrreldes puhtalt käsitsi loendusega.
4. **Tulemuste ristkontroll.** Kogunenud arvulisi tulemusi võrreldi korduvalt tabelite (nt tab. 6, tab. 9, tab. 10) vahel, et tagada iga peatüki sees ja peatükkide vahel ühtsed arvud. Claude Code'ilt paluti ka selle ristkontrolli jaoks abi, lastes mudelil hoiatada vastuoludest (nt kui sama mudeli kohta on eri tabelites erinev veaarv).

Selline tööjaotus vähendas analüüsile kulunud aega, kuid säilitas autori täieliku kontrolli iga arvu üle, mida töös esitatakse.

6.6 Kompileerimine, vormistuse kontroll ja kvaliteedi hindamine

L^AT_EX töös tähendab kirjutamine pidevat kompileerimist ning vigade ja hoiatuste lahendamist. Käesoleva töö puhul seati sisse järgmine kompileerimistsüklkel, mis toimis kogu kirjutamise jooksul.

- Kohalik kompileerimine toimus `latexmk`-i ja `lualatex`-iga (vt `.latexmkrc` repositooriumi juurkaustas), koos `biber`-iga bibliograafia jaoks. Varu- ja võrdluskompilatsioon tehti aeg-ajalt ka Overleafi kaudu.

- Kompileerimisvigade (nt tabelite ülevalg, lahtiste rühmade ebakõla, puuduvad `\cite` võtmed) diagnostika tehti valdavalt koos Claude Code'iga – autor andis talle `thesis.log` faili sisu või vigaste ridade väljavõtte ja palus pakkuda minimaalset parandust. Muudatus rakendati failile alles siis, kui autor oli selle üle vaadanud.
- Kvaliteedi hindamiseks vaadati iga olulisema muudatuse järel kompileeritud PDF üle, pöörates tähelepanu sisukorra järjepidevusele, tabelite mahtumisele leheküljele, jooniste paigutusele ning ristviidete (`\ref`) töötamisele.

Kompileerimisvigade parandamine oli üks valdkond, kus TI pakkus kõige otsesemat produktiivsuse kasvu – peenete $\text{\LaTeX}$ vigade jahtimine, mis vastasel juhul oleks võtnud tunde käsitsi otsingut, lahendati sageli mõne minutiga, kui vealoog anti mudelile analüüsimiseks.

6.7 Versioonihaldus GitHubi abil

Kogu töö kirjutamise protsessi jooksul hoiti lähtekoodi ($\text{\LaTeX}$ failid, viidete baas, joonised) GitHubi repositooriumis. Versioonihalduse kasutamine täitis mitut eesmärki, mis on TI-toetatud kirjutamise kontekstis eriti olulised.

- **Varasemate versioonide taastamise võimalus.** Iga oluline muudatus (uus peatükk, suurem toimetamine, TI-põhine parandusvoor) salvestati eraldi commit'ina. Kui TI tööriist tegi soovimatuid muudatusi või eemaldas juhuslikult autori sisulise lõigu, sai muudatuse kergesti tagasi pöörata (`git revert`) või taastada varasema versiooni konkreetse faili jaoks (`git checkout`). See pakkus turvavõrku, ilma milleta oleks iteratiivne töövoog olnud oluliselt riskantsem.
- **TI tehtud muudatuste kontrollitavus.** Enne iga TI-põhise parandusvooru commit'iti eelmine seis, mis võimaldas pärast muudatuste tegemist vaadata diff'i ja kontrollida täpselt, mida TI muutis. See on oluline, sest agentne tööriist võib teha muudatusi failides, mida autor ei pruugi koheselt märgata – diff muudab muudatused täielikult läbipaistvaks.
- **Varundus.** Kaugserveris hoitav koopia kaitses töö kadumise eest kohaliku masina rikke või kogemata kustutamise korral.
- **Harude kasutamine suuremate toimetamiste jaoks.** Suuremaid, kogu tööd haaravaid parandusvoore (nt “kirjavigade ja sõnastuse parandamine”) tehti eraldi arendusharus (*feature branch*) ning liideti peaharusse alles pärast tervikpildi üle vaatamist pull request'i

kaudu. See eraldas eksperimenteerivad muudatused stabiilsest peaharust ning võimaldas vajadusel terve parandusvooru maha visata ilma varasemat tööd kahjustamata.

- **Commit-sõnumite kaudu kirjutamisprotsessi dokumenteerimine.** Sisukad commit-sõnumid (näiteks “Lisatud anglitsismide analüüsi tabel”, “Ühtsustatud valuuta vormingut”, “‘AI’ asendada ‘TI’-ga ja dollarid eurodeks”) pakuvad kronoloogilist ülevaadet tehtud muudatustest, mis aitab hiljem mõista, miks üks või teine redaktsioon tehti. Commit-sõnumite koostamisel rakendati head tava märkida eraldi Co-Authored-By väljaga juhud, kus Claude Code tegi muudatustele sisulise panuse, tagades läbipaistva autorluse dokumenteerimise.

GitHubi kasutamine koos agentse TI tööriistaga lõi distsiplineeritud töövoog: enne iga suuremat TI-põhist muudatust commit’iti eelnev seis, seejärel tehti muudatus, vaadati diff üle ja alles siis aktsepteeriti muudatus järgmise commit’iga. Kui tulemus ei rahuldanud, sai muudatusest täies mahus loobuda. Selline töövoog on soovituslik igale üliõpilasele, kes kasutab lõputöö kirjutamisel agentseid TI tööriistu, sest see vähendab oluliselt töö kadumise või ebaõnnestunud iteratsioonide riski.

6.8 Rollijaotus autori ja TI vahel

Töövoog läbipaistvuse huvides on tabelis 11 esitatud, millised kirjutamise ülesanded tegi autor ja millistel täitis TI abistavat rolli. Piiritlemisel lähtuti põhimõttest, et iga sisulise väite ja iga tsiteeritud allika eest vastutab autor ning TI saab osaleda üksnes nendes sammudes, mille tulemust autor ise hindab ja kinnitab.

Tabelist nähtub, et sisulist vastutust nõudvad ülesanded (teemavalik, eksperimendi disain, allikate valik, tulemuste tõlgendamine, järeldused) jäid täielikult autori kanda. TI roll piirdus rutiinsete, madala sisulise riskiga sammudega (kandidaatide tuvastamine, formaadi kontroll, sõnastusettepanekud), kus iga ettepanek läbis enne rakendamist autori hindamise.

6.9 Piirangud ja saadud kogemused

Iteratiivne TI-toetatud kirjutamise töövoog tõi esile ka mitmeid praktilisi piiranguid, mida tasub tulevastel üliõpilastel arvestada.

- **Kontekstiakna täitumine pikemate sessioonide jooksul** tingis vajaduse sessiooni korrapärase taaskäivitamise ja CLAUDE .md faili kasutamise järele püsiva kontekstina.

Tabel 11. Autori ja TI rollijaotus käesoleva töö kirjutamisel

Ülesanne	Autor	TI (Claude Code)
Teema valik ja uurimisküsimuste sõnastus	Täielik	–
Eksperimendi disain ja läbiviimine	Täielik	–
Kirjanduse lugemine ja sünteesimine	Täielik	–
Peatüki mustandi kirjutamine	Põhiautor	Üksikute lõikude sõnastusettepanekud
Allikate otsimine ja valimine	Täielik	–
Viidete sisuline kontroll	Täielik	–
BibTeX-kirjete süntaksi kontroll	Järelkontroll	Automaatne kontroll
Kirjavigade otsimine ja parandamine	Lõplik otsus	Kandidaatide tuvastamine
Lauseehituse ja stiili ühtlustamine	Lõplik otsus	Ettepanekud
L ^A T _E X kompileerimisvigade diagnoosimine	Lõplik otsus	Põhjuse analüüs
Tabelite ja jooniste vormistus	Lõplik otsus	Vormingu ettepanekud
Kvantitatiivsete tulemuste tõlgendamine	Täielik	–
Järelduste ja soovitude sõnastamine	Täielik	Sõnastusettepanekud

Pikema mustandi töö puhul osutus mõistlikuks jagada ülesanne peatükipõhisteks sessioonideks.

- **TI kalduvus “parandada” õiget teksti.** Mõnel juhul palus autor parandada ühte konkreetset viga, kuid tööriist muutis samal ajal ka ümbritsevat korrektset teksti. GitHubi `git diff` käsk oli hädavajalik, et selliseid soovimatuid muudatusi tuvastada ja tagasi pöörata.
- **Eestikeelsete erisõnade ja terminite käsitus.** Keeleteaduslikult keerulised sõnad (nt liitsõnade silbitus või harvemad käändelõpud) vajasis autori eraldi tähelepanu, kuna TI-l ilmnesis kohati samad terminoloogilised vead, mida peaeksperimendis täheldati teistes mudelites.
- **Ajainvesteering.** Kuigi TI abil kiirenes vormistus- ja korrektuurifaas märgatavalt, ei vähendanud see sisulise töö (lugemise, mõtlemise, allikate kontrolli, tulemuste analüüsi)

mahtu – see jäi autori vastutusele ja moodustas suurema osa tegelikust ajakulust. TI peamine võit oli mehhaanilise töö vähenemine, mitte intellektuaalse töö asendamine.

- **Kulud.** TI-teenuste tellimused moodustasid üliõpilase eelarves tuntava, kuid professionaalse toimetamise teenusega võrreldes siiski väiksema kulu (vt peatükk 7.3). Läbipaistvuse huvides tuleb märkida, et autor kulutas kogu uurimisperioodi jooksul erinevate TI-teenuste tellimustele ligikaudu 360 € omavahendeid. See summa kattis nii peaeksperimendi läbiviimist kui ka käesoleva töö kirjutamise abivahendeid.

6.10 Erinevus peaeksperimendi töövoost

Käesoleva töö kirjutamise töövoog erineb peaeksperimendi ühe kasutajaviiba lähenemisest põhimõtteliselt. Sisu kavandas, uuris ja kirjutas autor ise; TI roll piirdus keelelise toimetamise, vormistuse ühtlustamise ja sisemise järjepidevuse kontrolliga. Selline rollijaotus vastab peatükis 7.8 kirjeldatud vastutustundliku TI kasutuse põhimõtetele, kus TI-d käsitletakse abivahendina, mitte teksti algautorina. Iteratiivne töövoog koos GitHubi versioonihaldusega osutus oluliselt tõhusamaks kui peaeksperimendis katsetatud ühe kasutajaviibaga lähenemine – sisuline täpsus, viidete kontrollitavus ja akadeemiline usaldusväärsus jäid autori vastutusele, samas kui TI aitas olulisel määral vähendada kirjutamise, toimetamise ja vormistamise ajakulu. Lisaks demonstreerib see, et sama agentse tööriista peret, mida peaeksperimendis hinnati “täisdelegeerimise” stsenaariumis, saab kasutada ka vastutustundliku ja akadeemiliselt aktsepteeritava töövoos raames – oluline ei ole niivõrd tööriista enda olemus, kuivõrd see, kuidas inimene selle töövoosse integreerib.

7. Arutelu

Käesolev peatükk arutleb eksperimendi tulemuste üle laiemas kontekstis, käsitleb TI kasutamise praktilisi aspekte, piiranguid ja annab soovitusi.

7.1 TI tugevused lõputöö kirjutamisel

Eksperimendi tulemused kinnitavad, et kaasaegsed TI mudelid koos agentsete tööriistadega suudavad pakkuda märkimisväärset abi lõputöö kirjutamise protsessis. Selle katse jooksul demonstreeris Claude Opus 4.6 + Cowork kombinatsioon eriti veenvalt, et tiptasemel mudel koos agentse tööriistaga suudab genereerida tervikliku 61-leheküljelise eestikeelse lõputöö ka ühe kasutajaviibaga ilma iteratiivse suunamiseta. Peamised tugevused jagunevad järgmiselt.

Struktureerimine ja kavandamine. TI mudelid on eriti tugevad teksti struktureerimisel. Kõik neli testitud kombinatsiooni (arvestades GPT-5.4 Codex-laienduse kaudu saadud tulemust) suutsid luua loogilise ja akadeemilistele nõuetele vastava peatükkide jaotuse ainuüksi ühe kasutajaviibaga. Eriti kasulik on TI kasutamine töö algfaasis, kui üliõpilane vajab abi sisukorra ja peatükkide ülesehituse kavandamisel. Mudelid suudavad vaid minimaalse juhise põhjal luua detailse sisukorra koos soovitusliku leheküljemahuga iga peatüki jaoks.

Mustandi loomine. TI suudab genereerida tekstimustandeid, mis on piisavalt hea kvaliteediga, et neid edasi töödelda. See kiirendab kirjutamisprotsessi oluliselt, kuna üliõpilane ei pea alustama tühjalt lehelt, vaid saab toimetada ja täiendada olemasolevat teksti. Esialgse kasutuskogemuse põhjal võib TI mustandi kasutamine säästa hinnanguliselt 50–80% kirjutamisele kuluvast ajast, kuigi täpse ajavõidu mõõtmine vajab edaspidi süstemaatilisi kasutajakatseid.

Keeleline toimetamine. Kõik neli mudelit suudavad efektiivselt teostada keelelist toimetamist – parandada grammatikavigu, parandada lauseehitust ja ühtlustada stiili. See on eriti väärtuslik eesti keele kontekstis, kus spetsiifilisi akadeemilise toimetamise teenuseid on vähe.

LaTeX-vormindamine. Oluline praktiline eelis on mudelite võimekus genereerida teksti otse LaTeX-vormingus, mis hõlmab korrektset viitamissüntaksit, tabeleid, jooniste viiteid ja matemaatilisi valemeid. See säästab üliõpilasele märkimisväärset vormistusaega. Võrdluseks, Microsoft Wordi puhul peab üliõpilane vormistuse – stiilid, ristviited, pealkirjade numeratsioon ja bibliograafia – enamasti käsitsi seadistama, kuna TI mudelid ei saa .docx faili sisemist struktuuri samamoodi manipuleerida nagu tekstipõhist L^AT_EX lähtekoodi. See teeb Wordi TI-toetatud akadeemilise kirjutamise kontekstis oluliselt aeganõudvamaks ja veaohhtikumaks valikuks.

7.2 TI puudujäägid ja piirangud

Vaatamata edusammudele on TI mudelitel lõputöö kirjutamise kontekstis endiselt olulised puudujäägid. Tulemuste tõlgendamisel tuleb eriti arvestada kahte metoodilist piirangut: eksperimendis võrreldi *mudeli ja agentse tööriista kombinatsioone*, mitte mudeleid isoleeritult, ning iga kombinatsiooni kohta tehti vaid üks jook. Seetõttu näitavad tulemused konkreetsete töövoogude käitumist selles katses, mitte lõplikku mudelite üldist paremusjärjestust. Süstemaatiline hinnang nõuaks iga kombinatsiooni kohta mitut kordusjooksu ning suuremat valimit.

Viidete usaldusväärsus. Üks tõsisemaid probleeme on viidete hallutsineerimine, kuid katsetulemused näitavad, et hallutsineerimismäärad varieeruvad mudelite vahel oluliselt. Käesolevas eksperimendis verifitseeris töö autor iga viite käsitsi, kontrollides, kas allikas tegelikult eksisteerib ning kas pealkiri, autorid, väljaandmise aasta ja URL/DOI vastavad tegelikkusele. Tulemused olid järgmised: GPT-5.4 + Codex 0% (kõik 22 viidet täielikult korrektsed), Opus 4.6 + Cwork 6% (35-st 2 viidet väikese metaandmete veaga), Gemini 3.1 Pro + Antigravity 11% (9-st 1 viidet vale autoriga) ning Sonnet 4.6 + Cwork 22% (23-st 5 viidet välja mõeldud autoriloendiga). Sonnet 4.6 hallutsinatsioonimuster oli muistliliselt eriline – artiklite pealkirjad ja arXiv-identifikaatorid olid valdavalt korrektsed, kuid mudel “täitis” autoriloendeid välja mõeldud nimedega või kombineeris kahe eri paberi metaandmed (näiteks viide “JITBot” Pornprasi ja Tantithamthavorn 2022, kus tegelikult oli paber “JITLine” MSR 2021 või JITBot ASE 2020 hoopis teiste autoritega). Need tulemused on kooskõlas varasemate uurimustega: Chelli et al. [41] tuvastasid GPT-4 hallutsinatsioonimääraks 28,6%; Mugaanyi et al. [23] leidsid, et DOI-de täpsus on valdkonniti väga erinev (loodusteadustes 32,7% vs humanitaarteadustes 8,5%), mis viitab sellele, et arvutiteaduse valdkonnas võivad tulemused olla mõnevõrra paremad. Kim et al. [25] on näidanud, et hallutsinatsioonid on eriti levinud väiksemate keelte kontekstis. Iga TI-genereeritud viide tuleb seega inimese poolt kontrollida – ka madala üldise hallutsinatsioonimääraga mudelite puhul, sest pealkirja olemasolu ei tähenda, et autorid või muud metaandmed oleksid samuti korrektsed.

Sisuline sügavus. TI-genereeritud tekstid kipuvad olema pealiskaudsed. Mudelid kordavad üldtuntud seisukohti, kuid ei suuda luua originaalset analüüsi ega teha uudseid järeldusi. See on eriti problemaatiline tulemuste arutelu puhul, kus eeldatakse, et autor demonstreerib kriitilist mõtlemist ja seob tulemused laiemas kontekstiga kokku.

Eesti keele tehniline terminoloogia. Kuigi mudelite eesti keele oskus on oluliselt paranenud, esineb endiselt probleeme tehnilise terminoloogiaga. Mudelid kasutavad kohati ebaühtlast terminoloogiat (vahetavad eesti- ja ingliskeelsete terminite vahel) ning mõnikord loovad valesid termineid. Näiteks genereeriti juurdunud termini “süvaõpe” asemel “süvaõppimine” või kasutati sõna “treenima” asemel “koolitama”, mis ei vasta arvutiteaduse valdkonnas juurdunud eesti keelsele terminoloogiale. Barbu et al. [42] on samuti täheldanud, et keelemudelid vajavad eesti keele spetsiifika jaoks täiendavat kohandamist, mis viitab laiemale probleemile väikeste keelte tehnilistel kasutusjuhtudel.

Kontekstiakna piirangud. Kuigi kontekstiaknad on oluliselt suurenenud, on need endiselt piiratud. 25-leheküljelise bakalaureusetöö tekst (ca 80 000–100 000 tähemärki ehk ca 40 000–50 000 tokenit) mahub küll kontekstiaknasse, kuid kui lisada juhendid, näidistööd ja varasemalt genereeritud osad, on kontekstiakna efektiivne kasutamine endiselt kriitiline.

Juhiste järgimise ebaühtlus ning liidese ja agentsete tööriistade mõju. Peatükis 5 kirjeldatud tulemused näitavad, et sama mudel võib eri liideses käituda sisuliselt erinevalt. GPT-5.4 vestlusliidese keeldumine ja Codex-laienduse kaudu õnnestunud failipõhine genereerimine viitavad sellele, et väljundit ei määra ainult alusmudel, vaid ka süsteemijuhised, ohutuspoliitika ja töövoogu ülesehitus. Bianchi et al. [43] kirjeldatud “liialdatud ohutuskäitumine” aitab seda nähtust tõlgendada: liides võib uurimusliku ülesande tõlgendada akadeemilise väärkasutuse riskina. Agentne tööriist ei tähenda seejuures ohutuspriirangutest möödumist, vaid teistsugust ülesande konteksti, kus töö jaotub väiksemateks faili- ja kompileerimispõhisteks sammudeks.

Sama oluline on eristada vormilist veenvust sisulisest usaldusväärsusest. Gemini 3.1 Pro + Antigravity töö näitas kõige selgemalt, et korrektselt vormistatud ja statistiliste tabelitega tekst võib sisaldada täielikult fabritseeritud empiirikat. Opus 4.6 + Cowork andis selles katses tugevama ja tehniliselt sügavama väljundi, kuid ka seal tuli kontrollimata testitulemusi ja viiteid käsitleda riskina. Seega ei piisa agentse tööriista edukast $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ -vormistusest: sisulise vastutuse, andmete olemasolu ja viidete kontroll peab jääma inimesele.

Hindamismetoodika piirangud. Oluline piirang käesolevas uurimuses on asjaolu, et hindamise viis läbi ainult üks hindaja (töö autor). See tähendab, et hindajatevahelise kooskõla mõõtmine ei olnud võimalik ja subjektiivsus on paratamatult suurem kui mitme sõltumatu hindaja kaasamisel. Subjektiivsuse vähendamiseks kasutati iga teksti korduvat hindamist eri aegadel, kuid see ei asenda sõltumatuid hindajaid. Eriti subjektiivsetes kriteeriumides (akadeemiline stiil, praktiline väärtus) võivad ühe hindaja hinnangud kalduda süstemaatiliselt ühes suunas.

Edaspidistes uurimustes tuleks tulemuste kinnitamiseks kaasata mitu sõltumatut hindajat, sealhulgas valdkonna õppejõud ja teised üliõpilased.

7.3 Hinnakujundus ja majanduslik teostatavus

Tabelis 12 on esitatud hinnanguline kuluarvestus 25-leheküljelise bakalaureusetöö genereerimiseks iga mudeliga.

Tabel 12. Bakalaureusetöö genereerimise hinnanguline kuluarvestus (EUR, koos 24% käibemaksuga)

Kulukomponent	Gemini 3.1 Pro	GPT-5.4	Claude Sonnet 4.6	Claude Opus 4.6
Sisendtokenid (ca 2M)	€4,23–8,47	€5,29	€6,35	€10,58
Väljundtokenid (ca 300K)	€3,81–5,71	€4,76	€4,76	€7,93
Agentse tööriista sisend/väljundkorrad	mitmekordne	mitmekordne	mitmekordne	mitmekordne
Eeldatav hind	€25–40	€26–33	€33–45	€56–74

Hinnad on esitatud eurodes, lähtudes mudelite pakkujate 2026. aasta mai ametlikest USD-hinnakirjadest [37–39] ja teisendatud kursi 1 EUR = 1,17 USD järgi (vt peatükk 4.5). Esitatud summad sisaldavad Eesti standardset 24% käibemaksu, mis vastab eraisikust üliõpilase tegelikule kulule. EL-i pöördmaksustamise korras (kehtiv VAT-numbriga ärikasutajatele) saab käibemaksu maha arvata ja tegelik kulu on ligikaudu 19% madalam.

Kuutellimused muudavad kulupildi mõnevõrra teistsuguseks: ChatGPT Plus ja Claude Pro maksavad Eesti regioonis ca €22–23 kuus (koos käibemaksuga), Google AI Pro €21,99 kuus ning Google AI Studio võimaldab piiratud tasuta kasutust (vt tabel 4). Praktikas võib üliõpilane teha põhilised katsetused 1–2 kuu tellimuse hinnaga, kui mahupiiranguid ei ületata.

Kokkuvõttes on TI kasutamise majanduslik kulu Sonnet-klassi kombinatsioonidega mõistlik (€33–45 ühe lõputöö kohta), samas kui Opus-klassi mudeli kasutamine on ligikaudu 1,7 korda kallim (€56–74) ja vajab teadlikku kvaliteedi-kulu kaalumist. Kõik testitud TI-variandid jäävad siiski üldjuhul odavamaks kui professionaalse toimetaja teenus, mis võib bakalaureusetöö puhul maksta mitusada eurot.

7.4 Eesti keele korrektuur ja toimetamine

Eraldi väärib tähelepanu TI mudelite kasutamine eestikeelse teksti korrektuuri ja toimetamise tööriistana. See on üks valdkondi, kus TI pakub kõige suuremat praktilist väärtust.

Järgmised hinnangud põhinevad autori mitteformaalsetel katsetel, mis jäid peaeksperimendi raamistikust välja ning mille täpsem metoodika vajab edaspidi süstemaatilist vormistamist. Need on esitatud suunavate tähelepanekutena.

Grammatikakontroll. Kõik neli mudelit suudavad tuvastada ja parandada enamiku grammatikavigadest eesti keeles. Claude Opus 4.6 oli kõige täpsem, tuvastades enamiku sisestatud vigadest; Sonnet 4.6 ja GPT-5.4 tuvastasid enamiku, kuid jätsid osa keerulisemaid vigu märkamata; Gemini 3.1 Pro tulemus oli nõrgim, jättes tuvastamata ka lihtsamaid morfoloogiavigu.

Stiilikontroll. Mudelid suudavad hinnata teksti vastavust akadeemilisele stiilile ja pakkuda parandusettepanekuid. See hõlmab liiga vaba keele tuvastamist, passiivi kasutamise soovitusi ja liigsete korduste märkamist. Claude Sonnet 4.6 oli selles osas kõige põhjalikum, pakkudes detailsemaid selgitusi paranduste kohta.

Terminoloogiakontroll. Mudelid suudavad kontrollida tehnilise terminoloogia ühtlust ja korrektsust, kuid siin on täpsus oluliselt madalam kui grammatikakontrollis. Terminoloogilist kontrolli ei saa täielikult TI-le delegeerida ja valdkonnaspetsiifiline inimekspertiis on endiselt vajalik.

Soovitus. TI-põhine korrektuur on kõige efektiivsem, kui seda kasutatakse kahes etapis:

1. Esmalt laseb üliõpilane TI-l teksti üle vaadata ja parandusettepanekud teha;
2. Seejärel vaatab üliõpilane parandused üle ja otsustab, millised neist aktsepteerida;
3. Lõpuks saab üliõpilane teha käsitsi täiendavaid parandusi, mida TI ei tuvastanud ja vajadusel alustada esimesest punktist uuesti.

Sellist kolmeetapilist protsessi kasutades saab oluliselt parandada teksti keelelist kvaliteeti, ilma et tekiks oht TI soovitude pimesi järgimiseks.

7.5 Soovitused TI tööriista valikuks

Eksperimendi tulemuste ja praktiliste kogemuste põhjal saab anda järgmised soovitused.

Selle katse kõrgeim kvaliteet: Claude Opus 4.6 koos Cowork'iga. Käesolev eksperiment näitas, et Claude Opus 4.6 + Cowork kombinatsioon saavutas selles katses kõrgeima kvaliteedi eestikeelse akadeemilise teksti genereerimisel. Kombinatsioon ületas teisi keelelise korrektsuse, akadeemilise stiili ja sisulise sügavuse poolest. Peamine puudus on oluliselt kõrgem hind. Kuna iga kombinatsiooni kohta tehti vaid üks jooks ja keelemudelid on mitteterministlikud, tuleb seda soovitus võtta eksploratiivse viitena, mitte lõpliku kvaliteedipingerea kinnituseks.

Parim hinna-kvaliteedi suhe: Claude Sonnet 4.6 koos Cowork'iga. Claude Sonnet 4.6 + Cowork kombinatsioon on kõige sobivam valik piiratud eelarvega üliõpilase jaoks. Kombinatsioon paistis silma akadeemilise stiili, juhiste järgimise ja teksti struktureerimise poolest ning on oluliselt soodsam kui Opus. Pikendatud mõtlemisrežiim parandab keerulisemate peatükkide kvaliteeti.

Lühikeste lõikude jaoks: GPT-5.4. GPT-5.4 sobib hästi lühikeste tekstilõikude genereerimiseks ja keelelise korrektuuri jaoks. Kui soov on genereerida tervikdokumenti, siis ChatGPT vestlusliidese süsteemijuhised ja ohutuspoliitika võivad selle blokeerida või suunata ingliskeelsele väljundile, samas kui ChatGPT Codex laiendus Visual Studio Code'is andis käesolevas katses sama viibaga tervikliku eestikeelse dokumendi (vt peatükk 5.3).

Ideaalne töövoog. Käesoleva töö kogemus näitab, et kõige parema tulemuse andis Cowork'i agentne tööriist koos Opus või Sonnet mudeliga.

7.6 Soovitused lõputöö genereerimiseks Claude Code'iga

Käesoleva uurimuse praktiliste kogemuste põhjal, sealhulgas Opus 4.6 mudeliga Cowork'i kaudu genereeritud paroolihalduri lõputöö (vt peatükk 5.5), saab anda järgmised soovitused Claude Code'i kasutamiseks lõputöö genereerimisel. Samad soovitused kehtivad suures osas ka Cowork'i kohta, kuna tööriistad on ülesehituselt sarnased.

7.6.1 Projekti ettevalmistamine

1. **Kasuta L^AT_EX malli algusest peale.** Paigalda ülikooli L^AT_EX mall (nt UniTartuCS) projektikausta enne genereerimise alustamist. Claude Code suudab malli struktuuri automaatselt tuvastada ja järgida.
2. **Lisa juhendid projektikausta.** Kopeeri lõputöö juhendid (TÜ ATI juhend, LOTE juhend) tekstifailidena projektikausta. Claude Code saab neid automaatselt lugeda kontekstina.

3. **Lisa näidistööd.** Paiguta 2–3 hästi hinnatud varasema lõputöö PDF-failid projektikausta. Need annavad mudelile konkreetse ettekujutuse oodatavast kvaliteedist ja stiilist.
4. **Loo CLAUDE.md konfiguratsioonifail.** Projekti juurkausta loodav CLAUDE.md fail sisaldab püsivaid juhiseid, mida Claude Code järgib igas sessioonis. Sinna tasub kirjutada:
 - oodatav keel (eesti keel);
 - akadeemiline stiil ja toon;
 - terminoloogia eelistused;
 - viitamisstiil (nt IEEE numeric);
 - peatükkide struktuur ja maht.

7.6.2 Genereerimise töövoog

Soovitame järgmist samm-sammulist töövoogu:

1. **Genereeri sisukord ja struktuur.** Alusta sisukorra ja peatükkide ülesehituse genereerimisega. Anna mudelile ette teema, uurimisküsimused ja mahunõuded. Kontrolli ja kinnita struktuur enne edasi liikumist.
2. **Genereeri peatükid järjest.** Genereeri iga peatükk eraldi, alustades sissejuhatusest. Iga järgmise peatüki genereerimisel on eelnevad peatükid kontekstis, mis tagab sidususe.
3. **Genereeri tabelid ja joonised eraldi.** Tabelite ja jooniste $\text{\LaTeX}$ kood on keerulisem ja vajab eraldi tähelepanu. Genereeri need eraldi sammuna ja kontrolli visuaalset tulemust.
4. **Lisa viited ise või tee põhjalikku kontrolli neile.** Ära lase mudelil viiteid “välja mõelda”. Kui soovid, et viited oleksid väga tõenäoliselt korrektsed, siis järgi seda malli:
 - otsi ise allikaid;
 - lisa leitud allikate andmed BibTeX faili;
 - palu mudelil viiteid tekstis kasutada ainult olemasolevatest allikatest.
5. **Kompileeri regulaarselt.** Kasuta Claude Code'i võimalust käivitada `pdflatex` ja `biber` käske, et kontrollida, kas genereeritud $\text{\LaTeX}$ kood kompileerub vigadeta.
6. **Vaata üle ja paranda.** Iga genereeritud peatüki järel vaata tekst üle, märgi probleemkohad ja palu mudelil need parandada. Ära jäta ülevaatamist töö lõppu.

7.6.3 Parimad praktikad

- **Kasuta pikendatud mõtlemisrežiimi.** Claude Code'i pikendatud mõtlemisrežiim (*extended thinking*) parandab oluliselt keeruliste akadeemiliste tekstide kvaliteeti. See on eriti kasulik sissejuhatuse, metoodika ja arutelu peatükkide jaoks.
- **Anna konkreetseid juhiseid.** Mida konkreetsemad on juhised, seda parem on tulemus. Selle asemel, et paluda "kirjuta sissejuhatus", täpsusta töö maht ja peamised teemad.
- **Kontrolli viiteid alati.** Ükski TI mudel ei genereeri 100% korrektseid viiteid. Kontrolli iga viite olemasolu ja korrektsust käsitsi.
- **Ära usalda ühe kasutajaviibaga (*single-prompt*) tulemust pimesi ilma kriitilise ülevaatamiseta.** Käesoleva uurimuse eksperimendis andis see lähenemine mõnel juhul tugeva vormilise tulemuse, kuid sisaldas endiselt hallutsineeritud viiteid ja kontrollimata empiirilisi väiteid (vt peatükk 5). Parima kvaliteedi saavutamiseks on mõistlik kombineerida ühe viibaga genereerimist iteratiivsete paranduste ja kasutaja järelevalvega.
- **Ole kursis enda tööga.** TI on abivahend, mitte autor. Üliõpilane peab iga genereeritud lõigu sisuliselt üle vaatama ja vajadusel ümber kirjutama.
- **Kasuta keeruliste peatükkide jaoks tugevamat mudelit.** Käesoleva töö kirjutamise ajal (märts 2026) andis Claude Opus 4.6 kõige parema tulemuse terviklike peatükkide ja keeruliste akadeemiliste tekstide toimetamisel. Lihtsamate korrektuuri- ja vormistusülesannete jaoks piisas sageli Sonnet-klassi mudelist. Kuna mudeliperekonnad muutuvad kiiresti, tasub soovitusel rakendamisel kontrollida, milline Opus-tasemel mudel on parajasti kättesaadav.

7.7 Tööriistad, mida vältida

Lisaks peaeksperimendis osalenud nelja mudeli võrdlusele testis autor lühemate mitteformaalsete katsete raames ka mõnda teist tööriista, mida lõputöö kirjutamise abivahendina ei saa soovitada, vaatamata nende laialdasele kättesaadavusele üliõpilastele. Järgmised hinnangud ei põhine käesoleva uurimuse formaalsel võrdlusel, vaid autori praktilisel kasutuskogemusel ning nende arendajate avalikul dokumentatsioonil.

Perplexity ei sobi mahukate ülesannete jaoks. Perplexity on TI-põhine otsingumootor, mis pakub juurdepääsu erinevatele mudelitele (sh Claude, GPT ja teised). Kuigi Perplexity sobib

hästi üksikute küsimuste esitamiseks ja lühikeste vastuste saamiseks, ilmnes testimisel oluline puudus: Perplexity vahendab mudeleid oma teenusekonfiguratsiooni ja päringuloogika kaudu, mistõttu kasutatav kontekst ei kattu alati mudelite natiivsete piiridega. Perplexity ametlik API-dokumentatsioon eristab otsingukonteksti mudeli kontekstiaknast ning näitab, et vahendatud mudelite piirangud sõltuvad konkreetsest Perplexity teenusest ja mudelikonfiguratsioonist [44, 45]. Autori testimisel ilmnes veebiliideses praktiliselt väiksem otsese sisendi piirang; DataStudioli ülevaade kirjeldab selleks vaiksime ca 8 000 tokenit päringu kohta [46], mis on oluliselt vähem kui samade mudelite natiivsed kontekstiaknad (nt Claude'i või Gemini 1M tokenit). See tähendab, et eraldi lühikeste viipadena saab küll normaalselt töötada. Mahukamate tekstide genereerimisel või pikema vestluse konteksti hoidmisel (nt tervikliku peatüki kirjutamine koos eelnevate osade kontekstiga) jääb kontekstiaknast aga puudu. Lisaks on täheldatud, et pikema konteksti puhul hakkab Perplexity varasemaid vestluse osi kärpima või kompresserima, mille tagajärjel vastused lakkavad viitamast varem kokkulepitud tingimustele ja piirangutele [46]. Seetõttu ei sobi Perplexity lõputöö genereerimise tööriistaks, kus on vajalik suur ja järjepidev kontekst.

GitHub Copilot Pro ei sobi akadeemilise teksti genereerimiseks. GitHub Copilot Pro, mida Tartu Ülikool pakub üliõpilastele tasuta GitHub Education programmi kaudu, on mõeldud eelkõige koodi kirjutamise abivahendiks [47]. GitHubi enda dokumentatsiooni kohaselt on Copilot Chat mõeldud ainult kodeerimisega seotud päringutele ning juhiste piiramine kodeerimisülesannetega parandab mudeli väljundi kvaliteeti [48]. Lõputöö genereerimise kontekstis osutus see aga ebapiisavaks. Copilot'i mudelid tundusid oluliselt "laisemad" – nad kippusid andma lühikesi, pealiskaudseid vastuseid ja vältisid pikemate akadeemiliste tekstilõikude genereerimist. Nguyen ja Nadi [49] on oma empiirilises uurimuses näidanud, et Copilot'i soovitusel on tähelepanekude pikkuse piirang, mis takistab pikema väljundi genereerimist, ning keerulisemate ülesannete korral langeb soovitude kvaliteet märgatavalt. Lisaks rakendab GitHub Copilot'ile päringupõhiseid limiite (*rate limits*), mis piiravad kasutamise intensiivsust [50]. Kokkuvõttes on tööriist optimeeritud lühikeste koodilõikude ja kooditäienduste jaoks, mitte terviklike akadeemiliste tekstide loomiseks. Seetõttu ei saa GitHub Copilot Pro-d soovitada lõputöö kirjutamise abivahendina, vaatamata sellele, et see on üliõpilastele tasuta kättesaadav.

7.8 Eetilised kaalutlused ja akadeemiline ausus

TI kasutamine lõputöö kirjutamisel tõstatab olulisi eetilisi küsimusi. Tartu Ülikooli akadeemilise aususe reeglid [6] nõuavad, et üliõpilane:

- deklareerib kõik TI vahendid, mida ta kasutab;
- märgib, millises töö osas ja millises ulatuses TI-d kasutati;
- tagab, et töö peegeldab tema isiklikku akadeemilist arengut ja analüütilist mõtlemist.

Rodafinos [8] rõhutab, et ülikoolid peaksid TI kasutamise keelustamise asemel lõimima TI-kirjaoskuse õppekavadesse ja kehtestama selged eetilise kasutamise poliitikad. Lund et al. [7] leidsid, et tudengid ei käsitle TI kasutamist kirjutamisel tavalise plagiaadi laiendusena, vaid eraldiseisva akadeemilise käitumise kategooriana, mis nõuab eraldi eetilist raamistikku.

On oluline rõhutada, et käesolev töö ei propageeri lõputöö TI abil “kirjutamist”, vaid uurib TI kasutamist *abivahendina* kirjutamisprotsessis. Nii nagu õigekirjakontroll ei kirjuta teksti üliõpilase eest, ei tohiks ka TI-põhine tekstigenerereerimine asendada üliõpilase isiklikku panust. TI-d tuleks käsitleda kui tööriista, mis aitab struktureerida mõtteid, luua mustandeid ja parandada keelekasutust.

7.9 Tulevikuväljavaated

TI mudelite areng on kiire ja käesoleva töö tulemused peegeldavad 2025–2026. aasta seisuga. Lähitulevikus on oodata järgmisi arenguid:

- **Eesti keele kvaliteedi paranemine** – uuemate mudelite (nt oodatav GPT-6, Gemini 4.0) treeningandmetes on eesti keele osakaal tõenäoliselt suurem, mis parandab keelelist kvaliteeti. EstLLM projekti [5] tulemused näitavad, et spetsialiseeritud jätkutreenimine võib eesti keele kvaliteeti märkimisväärselt tõsta ka olemasolevates mudelites.
- **Agentsed akadeemilised tööriistad** – Claude Code’i, Cowork’i, Google’i Antigravity ja OpenAI ChatGPT Codex laienduse laadsed agentsed tööriistad, mis suudavad iseseisvalt faile hallata, kompileerida ja projekti struktureerida, muutuvad tõenäoliselt akadeemilise kirjutamise standardtööriistadeks. Meie eksperiment kinnitas, et agentne töövoog parandab oluliselt genereerimise kvaliteeti kõigi testitud mudelite puhul – nii Opus 4.6 ja Sonnet 4.6 (Cowork), Gemini 3.1 Pro (Antigravity) kui ka GPT-5.4 (Codex) puhul.
- **Viidete kvaliteedi paranemine** – RAG (Retrieval-Augmented Generation) süsteemide areng peaks parandama viidete täpsust ja vähendama hallutsinatsioone. Kresevic et al. [51] on näidanud, et RAG-raamistik koos struktureeritud konteksti ja viipade disainiga parandas GPT-4 Turbo täpsust 43%-lt 99%-le, mis demonstreerib selle lähenemise potentsiaali ka

akadeemilises kontekstis. Ji et al. [52] leidsid, et ahelpõhjendamise (*chain-of-thought*) kasutamine parandas oluliselt viidete kvaliteeti teksti genereerimisel.

- **Kontekstiakende suurenemine** – kontekstiaknad kasvavad jätkuvalt, mis võimaldab mudelitele sisestada üha rohkem infot korraga.
- **Spetsialiseeritud akadeemilised mudelid** – lähiaastatel on tõenäoline spetsiaalselt akadeemiliseks kirjutamiseks kohandatud mudelite (nt eesti keelele ja Tartu Ülikooli stiilile peenhäälestatud variandid) ilmumine, mis võiks ühendada üldmudelite võimekuse valdkonnaspetsiifiliste teadmistega ning vähendada hallutsinatsioonide osakaalu.
- **TI-genereeritud sisu tuvastamine ja integreerimine õppekavasse** – ülikoolide ja kirjastuste poolt kasutusele võetavad TI-detekteerimise tööriistad arenevad paralleelselt genereerimistööriistadega, samas kui akadeemilised institutsioonid liiguvad TI keelustamiselt selle läbipaistva integreerimise suunas. See nõuab uusi hindamismetoodikaid, mis keskenduvad üliõpilase sisulisele panusele ja mõtteprotsessile, mitte ainult lõpptulemusele.
- **Multimodaalsed võimed akadeemilises tekstis** – tulevased mudelid suudavad tõenäoliselt genereerida mitte ainult teksti, vaid ka akadeemiliselt kvaliteetseid jooniseid, diagramme ja visualiseerimisi otse L^AT_EX-ühilduvas vormingus (nt TikZ või PGFPlots koodi), mis vähendab hetkel veel märkimisväärset käsitsitööd jooniste loomisel.

Käesolev uurimus piirdus neljast mudelist ja kolmest agentsest tööriistast koosneva võrdlusega 2025–2026. aasta seisuga. Arvestades TI valdkonna arengutempot, kus uusi mudeleid avaldatakse mitu korda aastas, tuleks sarnaseid teostatavusuuringuid korrata regulaarselt, et hinnata, kuidas ülalnimetatud arengud tegelikult realiseeruvad ja millised käesoleva töö järeldustest jäävad kehtima ka uuema põlvkonna mudelite puhul.

8. Kokkuvõte

Käesolev bakalaureusetöö uuris tehisintellekti rakendamise teostatavust eestikeelse tehnilise informaatika lõputöö genereerimisel. Selleks võrreldi nelja suurt keelemudelit koos agentsete tööriistadega: Google Gemini 3.1 Pro, OpenAI GPT-5.4, Anthropic Claude Sonnet 4.6 ja Anthropic Claude Opus 4.6. Kõigile kombinatsioonidele anti sama lühike eestikeelne viip, mis palus luua UniTartuCS malli kasutava tervikliku bakalaureusetöö. Kuna iga kombinatsiooni kohta tehti üks jooks, tuleb tulemusi käsitleda eksploraatiivselt.

Katse näitas, et agentsed tööriistad võimaldavad suurtel keelemudelitel luua vormilt terviklikke eestikeelseid akadeemilisi dokumente ka minimaalse juhendamisega. Samas erinesid kombinatsioonid märgatavalt keelevaliku, juhiste järgimise, viidete kvaliteedi, sisulise sügavuse ja riskide poolest. Parima tulemuse andis selles katses Claude Opus 4.6 + Cowork, piiratud eelarve korral osutus praktiliselt tugevaks valikuks Claude Sonnet 4.6 + Cowork. GPT-5.4 puhul oli keskne leid liidesesõltuvus: vestlusliides ja Codex-laiendus andsid sama ülesande puhul erineva käitumise. Gemini 3.1 Pro + Antigravity näitas omakorda, et vormiliselt veenev töö võib sisaldada täielikult fabritseeritud empiirilist osa.

Kõige tõsisem probleem oli viidete hallutsineerimine: kõikides genereeritud töödes leidis olematuid või valede metaandmetega allikaid. Lisaks ilmnas, et mudelid võivad esitada kontrollimata empiirilisi väiteid, näiteks väljamõeldud osalejaid, statistilisi tulemusi või testiraporteid. Seetõttu ei saa TI loodud akadeemilist teksti käsitleda usaldusväärse lõppversioonina enne, kui inimene on kontrollinud viiteid, andmeid, metoodikat ja järeldusi.

Majanduslikult on Sonnet-klassi kombinatsioonid üliõpilase jaoks realistlikumad kui Opus-klassi mudeli kasutamine, kuigi kallim mudel andis selles katses ka tugevama tulemuse. Hinnangute põhjal on TI kasutamine siiski üldjuhul odavam kui professionaalne toimetamisteenus, kuid kulu ei ole ainus otsustuskriteerium: olulisem on töövoog, kus TI roll on abistav ja inimese sisuline kontroll säilib.

Uurimuse põhjal saab järeldada, et TI mudeleid saab kasutada lõputöö kirjutamise abivahendina, kuid mitte asendajana. TI tugevused on struktuuri kavandamine, mustandi loomine, keeleline toimetamine ja $\text{\LaTeX}$ -vormindus. Inimese panus jääb asendamatuks uurimisküsimuste sõnastamisel, kirjanduse sisulisel mõtestamisel, andmete ja viidete kontrollimisel ning originaalsete järelduste tegemisel.

Praktilise soovitusena sobib agentne tööriist kõige paremini etapiviisilisse töövoogu, kus üliõpilane annab mudelile kitsalt piiritletud ülesandeid, kontrollib iga muudatust versioonihalduse abil ja ei lase mudelil iseseisvalt allikaid või empiirilisi tulemusi välja mõelda. Käesoleva katse põhjal on terviklike peatükkide ja keerulise akadeemilise teksti puhul tugevaim valik Opus-tasemel mudel koos agentse tööriistaga, samas kui Sonnet-klassi mudel pakub paremat hinnakvaliteedi suhet. Neid soovitusi tuleb siiski võtta konkreetse eksploratiivse katse tulemusena, mitte lõpliku mudelipingereana.

Edaspidine uurimistöö võiks keskenduda korduskatsetele, spetsialiseeritud akadeemiliste TI tööriistade hindamisele, eesti keelele kohandatud mudelite võrdlemisele suurte universaalsete mudelitega ning RAG-süsteemide mõjule viidete kvaliteedis. Samuti vajab süstemaatilist uurimist see, kuidas TI kasutamine mõjutab üliõpilaste akadeemilist arengut ja juhendamispädevusi.

Viited

- [1] Liang W., Zhang Y., Wu Z., Lepp H., Ji W., Zhao X., Cao H., Liu S., He S., Huang Z., Yang D., Potts C., Manning C. D. ja Zou J. Y. Mapping the Increasing Use of LLMs in Scientific Papers. *arXiv preprint arXiv:2404.01268* (2024). <https://arxiv.org/abs/2404.01268>.
- [2] Brown T., Mann B., Ryder N., Subbiah M., Kaplan J. D., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A. jt. Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems* 33 (2020), lk 1877–1901. <https://arxiv.org/abs/2005.14165>.
- [3] OpenAI. GPT-4 Technical Report. <https://arxiv.org/abs/2303.08774>. Viimati vaadatud: 15.02.2026. 2023.
- [4] Kuulmets H.-A., Purason T. ja Fišel M. How Well do LLMs Know Finno-Ugric Languages? A Systematic Assessment. *Proceedings of the Joint 25th Nordic Conference on Computational Linguistics and 11th Baltic Conference on Human Language Technologies (NoDaLiDa/Baltic-HLT 2025)*. 2025. <https://aclanthology.org/2025.nodalida-1.37/>.
- [5] Dorkin A., Purason T., Kalbaliyev E., Kuulmets H.-A., Ojastu M., Fišel M., Alumäe T., Aedmaa E., Kruusmaa K. ja Sirts K. EstLLM: Enhancing Estonian Capabilities in Multilingual LLMs via Continued Pretraining and Post-Training. *arXiv preprint arXiv:2603.02041* (2026). <https://arxiv.org/abs/2603.02041>.
- [6] Tartu Ülikool, Arvutiteaduse instituut. Tartu Ülikooli arvutiteaduse instituudis kaitstavate lõputööde nõuded ja hindamine. https://cs.ut.ee/sites/default/files/2026-02/2026_02_03_%20ATI_loputoode_nouded_ja_hindamiskriteeriumid.docx.pdf. Kinnitatud 03.02.2026; viimati vaadatud: 30.04.2026. 2026.
- [7] Lund B. D., Mannuru N. R., Teel Z. A., Lee T. H., Ortega N. J., Simmons S. ja Ward E. Student Perceptions of AI-Assisted Writing and Academic Integrity: Ethical Concerns, Academic Misconduct, and Use of Generative AI in Higher Education. *AI in Education* 1.1 (2025), lk 2. <https://doi.org/10.3390/aieduc1010002>.
- [8] Rodafinos A. The Integration of Generative AI Tools in Academic Writing: Implications for Student Research. *Social Education Research* 6.2 (2025), lk 250–258. <https://doi.org/10.37256/ser.6220256517>.
- [9] Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser Ł. ja Polosukhin I. Attention is All You Need. *Advances in Neural Information Processing Systems* 30 (2017), lk 5998–6008. <https://arxiv.org/abs/1706.03762>.

- [10] Devlin J., Chang M.-W., Lee K. ja Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT* (2019), lk 4171–4186. <https://arxiv.org/abs/1810.04805>.
- [11] Radford A., Wu J., Child R., Luan D., Amodei D. ja Sutskever I. Language Models are Unsupervised Multitask Learners. *OpenAI Blog* (2019). https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.
- [12] Ereht M., Ereht T. ja Ross K. Eesti keele käsiraamat. Tallinn: Eesti Keele Sihtasutus, 2007. <https://arhiiv.eki.ee/books/ekk09/>.
- [13] Common Crawl Foundation. Statistics of Common Crawl Monthly Archives: Distribution of Languages. <https://commoncrawl.github.io/cc-crawl-statistics/plots/languages>. Viimati vaadatud: 30.04.2026. 2026.
- [14] Nguyen T., Nguyen C. V., Lai V. D., Man H., Ngo N. T., Dernoncourt F., Rossi R. A. ja Nguyen T. H. CulturaX: A Cleaned, Enormous, and Multilingual Dataset for Large Language Models in 167 Languages. *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. 2024, lk 4226–4237. <https://aclanthology.org/2024.lrec-main.377>.
- [15] Tanvir H., Kittask C., Eiche S. ja Sirts K. EstBERT: A Pretrained Language-Specific BERT for Estonian. *Proceedings of the 23rd Nordic Conference on Computational Linguistics (NoDaLiDa)*. 2021, lk 11–19. <https://aclanthology.org/2021.nodalida-main.2/>.
- [16] Üstün A., Aryabumi V., Yong Z., Ko W.-Y., D'souza D., Onilude G., Bhandari N., Singh S., Ooi H.-L., Kayid A. jt. Aya Model: An Instruction Finetuned Open-Access Multilingual Language Model. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2024, lk 15894–15939. DOI: [10.18653/v1/2024.acl-long.845](https://doi.org/10.18653/v1/2024.acl-long.845). <https://aclanthology.org/2024.acl-long.845/>.
- [17] Kiil A. Suurte keelemudelite võrdlev analüüs Eesti bioloogiaolümpiaadide küsimuste põhjal. Magistritöö. Tartu Ülikool, Arvutiteaduse instituut, 2025. <https://hdl.handle.net/10062/117055>.
- [18] Lee Y., Ka S., Son B., Kang P. ja Kang J. Navigating the Path of Writing: Outline-guided Text Generation with Large Language Models. *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 3: Industry Track)*. Albuquerque, New Mexico:

- Association for Computational Linguistics, 2025, lk 233–250. DOI: [10.18653/v1/2025.naacl-industry.20](https://doi.org/10.18653/v1/2025.naacl-industry.20). <https://aclanthology.org/2025.naacl-industry.20/>.
- [19] Tang X., Duan X. ja Cai Z. Large Language Models for Automated Literature Review: An Evaluation of Reference Generation, Abstract Writing, and Review Composition. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*. Suzhou, China: Association for Computational Linguistics, 2025, lk 1602–1617. DOI: [10.18653/v1/2025.emnlp-main.83](https://doi.org/10.18653/v1/2025.emnlp-main.83). <https://aclanthology.org/2025.emnlp-main.83/>.
- [20] Usher M. ja Amzalag M. From Prompt to Polished: Exploring Student–Chatbot Interactions for Academic Writing Assistance. *Education Sciences* 15.3 (2025), lk 329. DOI: [10.3390/educsci15030329](https://doi.org/10.3390/educsci15030329). <https://doi.org/10.3390/educsci15030329>.
- [21] Nadra S. ja Purdy J. P. Is GenAI a Good Editor of Academic Writing? *Computers and Composition* 80, 102993 (2026). DOI: [10.1016/j.compcom.2026.102993](https://doi.org/10.1016/j.compcom.2026.102993). <https://doi.org/10.1016/j.compcom.2026.102993>.
- [22] Pinto M. M., Araújo E. E. R., Rahhal Z., Stanbouly D. ja Grillo R. AI-Assisted Translation in Oral and Maxillofacial Surgery: A Comparative Evaluation. *Journal of Stomatology, Oral and Maxillofacial Surgery* 127.3, 102717 (2026). DOI: [10.1016/j.jormas.2026.102717](https://doi.org/10.1016/j.jormas.2026.102717). <https://doi.org/10.1016/j.jormas.2026.102717>.
- [23] Mugaanyi J., Cai L., Cheng S., Lu C. ja Huang J. Evaluation of Large Language Model Performance and Reliability for Citations and References in Scholarly Writing: Cross-Disciplinary Study. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/52935>.
- [24] Rao D. ja Callison-Burch C. BibTeX Citation Hallucinations in Scientific Publishing Agents: Evaluation and Mitigation. *arXiv preprint arXiv:2604.03159* (2026). DOI: [10.48550/arXiv.2604.03159](https://doi.org/10.48550/arXiv.2604.03159). <https://arxiv.org/abs/2604.03159>.
- [25] Kim E., Kipchumba F. ja Min S. Geographic Variation in LLM DOI Fabrication: Cross-Country Analysis of Citation Accuracy Across Four Large Language Models. *Publications* 13.4 (2025), lk 49. DOI: [10.3390/publications13040049](https://doi.org/10.3390/publications13040049). <https://doi.org/10.3390/publications13040049>.
- [26] Peters U. ja Chin-Yee B. Generalization Bias in Large Language Model Summarization of Scientific Research. *Royal Society Open Science* 12.4 (2025), lk 241776. DOI: [10.1098/rsos.241776](https://doi.org/10.1098/rsos.241776). <https://doi.org/10.1098/rsos.241776>.

- [27] Doshi A. R. ja Hauser O. P. Generative AI Enhances Individual Creativity but Reduces the Collective Diversity of Novel Content. *Science Advances* 10.28 (2024). <https://doi.org/10.1126/sciadv.adn5290>.
- [28] Bender E. M., Gebru T., McMillan-Major A. ja Shmitchell S. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of FAccT* (2021), lk 610–623. <https://doi.org/10.1145/3442188.3445922>.
- [29] Lillepalu H. G. ja Alumäe T. Estonian Native Large Language Model Benchmark. *arXiv preprint arXiv:2510.21193* (2025). Viimati muudetud 19.02.2026; vastu võetud konverentsile LREC 2026. <https://arxiv.org/abs/2510.21193>.
- [30] Google. Upload and Analyse Files in Gemini Apps. <https://support.google.com/gemini/answer/14903178>. Viimati vaadatud: 02.05.2026. 2026.
- [31] Anthropic. Upload Files to Claude. <https://support.claude.com/en/articles/8241126-upload-files-to-claude>. Viimati vaadatud: 02.05.2026. 2026.
- [32] OpenAI. File Uploads FAQ. <https://help.openai.com/en/articles/8555545-file-uploads-faq>. Viimati vaadatud: 02.05.2026. 2026.
- [33] Google DeepMind. Gemini 3.1 Pro: A smarter model for your most complex tasks. <https://blog.google/innovation-and-ai/models-and-research/gemini-models/gemini-3-1-pro/>. Viimati vaadatud: 01.03.2026. 2026.
- [34] OpenAI. Introducing GPT-5.4. <https://openai.com/index/introducing-gpt-5-4/>. Viimati vaadatud: 01.03.2026. 2025.
- [35] Anthropic. Introducing Claude Sonnet 4.6. <https://www.anthropic.com/news/claude-sonnet-4-6>. Viimati vaadatud: 01.03.2026. 2026.
- [36] Anthropic. Introducing Claude Opus 4.6. <https://www.anthropic.com/news/claude-opus-4-6>. Viimati vaadatud: 10.03.2026. 2026.
- [37] OpenAI. API Pricing. <https://openai.com/api/pricing/>. Viimati vaadatud: 24.04.2026. 2026.
- [38] Anthropic. Claude API Pricing. <https://www.anthropic.com/pricing>. Viimati vaadatud: 24.04.2026. 2026.
- [39] Google. Gemini API Pricing. <https://ai.google.dev/gemini-api/docs/pricing>. Viimati vaadatud: 24.04.2026. 2026.
- [40] Anthropic. Claude Code: An Agentic Coding Tool. <https://docs.anthropic.com/en/docs/claude-code>. Viimati vaadatud: 10.03.2026. 2026.

- [41] Chelli M., Descamps J., Lavoué V., Trojani C., Azar M., Deckert M., Raynier J.-L., Clowez G., Boileau P. ja Ruetsch-Chelli C. Hallucination Rates and Reference Accuracy of ChatGPT and Bard for Systematic Reviews: Comparative Analysis. *Journal of Medical Internet Research* 26 (2024). <https://doi.org/10.2196/53164>.
- [42] Barbu E., Muru M.-L. ja Malva S. M. Improving Estonian Text Simplification through Pretrained Language Models and Custom Datasets. *arXiv preprint arXiv:2501.15624* (2025). <https://arxiv.org/abs/2501.15624>.
- [43] Bianchi F., Suzgun M., Attanasio G., Röttger P., Jurafsky D., Hashimoto T. ja Zou J. Safety-Tuned LLaMAs: Lessons From Improving the Safety of Large Language Models that Follow Instructions. *arXiv preprint arXiv:2309.07875* (2023). <https://arxiv.org/abs/2309.07875>.
- [44] Perplexity. Pricing. <https://docs.perplexity.ai/docs/getting-started/pricing>. Viimati vaadatud: 30.04.2026. 2026.
- [45] Perplexity. Models. <https://docs.perplexity.ai/docs/agent-api/models>. Viimati vaadatud: 30.04.2026. 2026.
- [46] DataStudios. Perplexity AI Context Window: Token Limits, Memory Policy, and 2025 Rules. <https://www.datastudios.org/post/perplexity-ai-context-window-token-limits-memory-policy-and-2025-rules>. Viimati vaadatud: 14.03.2026. 2025.
- [47] GitHub. About Individual GitHub Copilot Plans and Benefits. <https://docs.github.com/en/copilot/concepts/billing/individual-plans>. Viimati vaadatud: 14.03.2026. 2026.
- [48] GitHub. Responsible use of GitHub Copilot Chat in your IDE. <https://docs.github.com/en/copilot/responsible-use/chat-in-your-ide>. Viimati vaadatud: 30.04.2026. 2026.
- [49] Nguyen N. ja Nadi S. An Empirical Evaluation of GitHub Copilot's Code Suggestions. *Proceedings of the 19th International Conference on Mining Software Repositories (MSR)*. 2022, lk 1–5. <https://doi.org/10.1145/3524842.3528470>.
- [50] GitHub. Usage limits for GitHub Copilot. <https://docs.github.com/en/copilot/concepts/usage-limits>. Viimati vaadatud: 30.04.2026. 2026.
- [51] Kresevic S., Giuffrè M., Ajčević M., Accardo A., Crocè L. ja Shung D. Optimization of Hepatological Clinical Guidelines Interpretation by Large Language Models: A Retrieval Augmented Generation-Based Framework. *NPJ Digital Medicine* 7 (2024), lk 102. DOI: [10.1038/s41746-024-01091-y](https://doi.org/10.1038/s41746-024-01091-y). <https://doi.org/10.1038/s41746-024-01091-y>.
- [52] Ji B., Liu H., Du M. ja Ng S.-K. Chain-of-Thought Improves Text Generation with Citations in Large Language Models. *Proceedings of the AAAI Conference on Artificial*

Intelligence. Kd 38. 16. 2024, lk 18345–18353. <https://doi.org/10.1609/aaai.v38i16.2979>
4.

Lisad

I. Eksperimendis kasutatud viip

Käesoleva uurimuse eksperimendis kasutati kõigi nelja mudel-tööriista kombinatsiooni puhul üht ja sama lühikest eestikeelset viipa ehk ühe kasutajaviibaga (*single-prompt*) lähenemist. Viipa ei muudetud ega iteratiivselt täiendatud. Täisviip oli järgmine:

“Sa oled kogenud akadeemiline kirjutaja. Loo täielik bakalaureusetöö LaTeX-vormingus (lisasin töökausta vajaliku malli), mis vastab Tartu Ülikooli arvutiteaduse instituudi nõuetele. Teema peab olema informaatikaga seotud ja vali ise. Autor on Uku Renek Kronbergs ja juhendaja Alo Peets (MSc).”

Viiba sisulised elemendid:

- **Mudeli roll** – “kogenud akadeemiline kirjutaja” kui üldine stiiliviide.
- **Ülesanne** – täieliku bakalaureusetöö loomine.
- **Vorm** – LaTeX-vorming koos viitega töökausta paigutatud UniTartuCS mallile.
- **Nõue** – vastavus Tartu Ülikooli arvutiteaduse instituudi nõuetele.
- **Teema** – informaatikaga seotud, valitakse mudeli poolt iseseisvalt.
- **Tiitellehe andmed** – autor Uku Renek Kronbergs, juhendaja Alo Peets (MSc).

Viibasse ei lisatud:

- TÜ ATI ega LOTE lõputööde juhendite teksti;
- varasemate bakalaureusetööde näiteid;
- detailseid juhiseid peatükkide struktuuri, mahu või sisu kohta;
- viitamisstiili juhiseid;
- keelelisi korrektuureegleid.

Sellise minimaalse viiba eesmärk oli hinnata, kuidas mudelid interpreteerivad võimalikult lühikest juhust ning millistele eelteadmistele nad toetuvad eestikeelse akadeemilise lõputöö loomisel.

III. Tervikliku lõputöö genereerimise näited

Järgnevalt on esitatud väljavõtted eksperimendis genereeritud terviklikest lõputöödest. Iga mudeli väljundist on toodud sissejuhatuse algus, et illustreerida erinevusi keeles, stiilis ja teemale vastavuses.

III.1 Claude Sonnet 4.6 (Cowork) – sissejuhatuse väljavõte (40 lk)

“Kaasaegne tarkvaraarendus on olemuselt meeskonnatöö. Isegi suurima kogemusega programmeerijad teevad vigu, ning keerukad süsteemid sisaldavad sageli turvaauke, jõudlusprobleeme või loogilisi vigu, mida üks inimene ei suuda leida.”

“Käesoleva bakalaureusetöö peamine eesmärk on hinnata suurkeelemudelite sobivust automaatse koodiülevaatuse tööriistadena ning võrrelda eri mudeleid nende tulemuslikkuse alusel. Töö käigus viiakse läbi empiiriline katse, milles kolme LLM-i — GPT-4, Claude 3 Opus ja Code Llama 70B — rakendatakse 120 koodifragmendi analüüsimiseks.”

Hinnang: Töö järgib Tartu Ülikooli struktuurinõudeid ja on eestikeelne, akadeemilises stiilis. Sisaldab 23 viidet, millest 5 (22%) olid hallutsineeritud autoriloendiga – pealkirjad ja arXiv-identifikaatorid olid valdavalt korrektsed, kuid mudel “täitis” autorinimekirju välja mõeldud nimedega (kõige nähtavamad näited: Towards Automating Code Review Activities ICSE 2021 ning Impact of Code Language Models on Automated Program Repair; vt peatükk 5.2). Sarnaselt Gemini 3.1 Pro tööle on ka selle kombinatsiooni esitatud katsed (120 koodifragmendi testkogum, F1-mõõdikud GPT-4 / Claude 3 Opus / Code Llama 70B kohta) tegelikkuses kontrollimata empiirilised väited. Tiitellehel kasutab mudel autorinime kärbitud kujul (“Uku Renek”), juhendaja nimena kohatäidet (“Prof. Vanem Juhendaja, PhD”) ning aastaks “2025”. Ristkontrollis tuvastati 37 keele- ja kirjaviga. Peamine puudus: viidete autorite hallutsineerimine, kontrollimata empiirilised väited ning kohati ülemäära keerukas lauseehitus.

III.2 GPT-5.4 (vestlusliides) – väljundi väljavõte (8 lk, teostatavusjuhend)

“A complete, submission-ready bachelor’s thesis written end-to-end on your behalf is not something I can produce. That would materially enable academic misconduct (submitting work largely authored by a third party). What I can provide—aligned with the University of Tartu’s own principles for using generative AI in coursework—is a deep-research ‘thesis kit’: a rigorously sourced background review, a defensible

experimental design, an evaluation rubric, and a UniTartuCS-template-aligned LaTeX project skeleton with chapter-by-chapter writing prompts and clearly marked placeholders that you must complete, verify, and take responsibility for.”

Hinnang: GPT-5.4 keeldus ülesannet täitmast ja valis väljundkeeleks inglise keele. Pakkus selle asemel teostatavusjuhendit, mis sisaldas mudelivaliku soovitusi, eksperimendi disaini raamistikku ja LaTeX malli juhiseid. Viited on verifitseeritud ja sisukad. Akadeemilise aususe teadlikkus on silmapaistvalt tugev. Sama mudel sama viibaga Codex-laienduse kaudu Visual Studio Code’is genereeris aga tervikliku 47-leheküljelise eestikeelse töö – vt III.3.

III.3 GPT-5.4 (Codex VS Code’is) – sissejuhatuse väljavõte (47 lk)

“Suurte keelemudelite kiire areng on muutnud loomulikus keeles suhtlevad tarkvarasüsteemid tavapäraseks osaks nii õppetöös, ettevõtluses kui ka avalikes teenustes. [...] Käesolev töö keskendub eestikeelsele dokumentide põhisele küsimus-vastus süsteemile.”

“Töö eesmärk on analüüsida RAG-lahenduste teaduskirjandust ning selle põhjal kavandada eestikeelse dokumentide põhise küsimus-vastus süsteemi arhitektuur, mis oleks läbipaistev, ajakohastatav ja hinnatav.”

Hinnang: Sama mudel ja sama viip kui vestlusliideses, kuid agentse töövoos kaudu andis täiesti erineva tulemuse. Keelevalik eesti keel, struktuur vastab bakalaureusetöö vormile (8 nummerdatud peatükki, 49 alapeatükki, 7 tabelit, 2 joonist), ortograafiline täpsus silmapaistvalt kõrge (3 kirjaviga kogu töö peale). Kõik 22 unikaalset viidet olid täielikult kontrollitavad ja korrektsete metaandmetega – ainus genereeritud töö, kus ühtegi hallutsineeritud viidet ei tuvastatud. Tähelepanuväärne kõrvalleid: tiitellehel, litsentsis ja allkirjas kasutas mudel viibas etteantud nimede asemel kohatäiteid (Näidisüliõpilane, Juhendaja nimi, PhD), vältides reaalse tudengi nime alla allakirjastatud akadeemilise teksti otsest tootmist.

III.4 Gemini 3.1 Pro (Antigravity) – sissejuhatuse väljavõte (39 lk)

“Tarkvaraarenduse valdkond on viimaste aastate jooksul teinud läbi märkimisväärse arengutõuke tänu erinevate tehisintellekti vormide laialdasele levikule ja kättesaadavusele. Üha enam integreeritakse generatiivset tehisintellekti (GenAI) igapäevastesse tööriistadesse ja arenduskeskkondadesse (IDE).”

“Käesoleva bakalaureusetöö eesmärk on just selle andmelünga osaline täitmine kohalikus kontekstis. Töö keskendub Eesti informaatikaliõpilastele ja püüab

selgitada välja, kuidas täpselt mõjutab lokaalse tehisintellekti viipeassistendi kasutamine algaja programmeerija produktiivsust esimesel õppeaastal.”

Hinnang: Gemini 3.1 Pro + Antigravity kombinatsioon genereeris vormiliselt korrektse töö generatiivse TI mõjust tarkvaraarendusele – väidetavalt 2026. aasta märtsis Tartu Ülikooli Delta õppehoone arvutiklassis läbi viidud kvaasi-eksperimendi näitel, milles osales 30 informaatika esmakursuslast (16 meest, 14 naist; 18–22 aastat). Kuigi teema on informaatikaga seotud ja seega viibale vastav, on kogu selles kirjeldatud empiiriline osa – 30 tudengiga kvaasi-eksperiment, testikeskkond Monaco Editor’i ja Docker’i liivakastiga, kohaliku LLaMA-3-8B-Instruct mudeli kasutamine TÜ HPC klastris ning kõik statistilised tulemused – fabritseeritud: reaalseid tudengeid, katseid ega andmeid ei eksisteeri. Eestikeelne tekst on ladus, kuid sisaldab palju ilmseid kirjavigu (24 ristkontrollitud leidu). Seda juhtumit käsitletakse töös akadeemilise väärkasutuse kõrge riskiga juhtumina (vt peatükk 5.4).

III.5 Claude Opus 4.6 (Cowork) – sissejuhatuse väljavõte (61 lk)

“Tänapäeva digimaailmas on igapäevaelu lahutamatu seotud veebiteenustega. Inimesed kasutavad regulaarselt kümneid, sageli isegi sadu erinevaid platvorme — alates e-postist ja sotsiaalmeediast kuni pangateenuste ja tervishoiuportaalideni.”

“Käesoleva bakalaureusetöö eesmärk on kavandada ja arendada turvaline paroolihalduri veebirakendus, mis põhineb null-teadmise arhitektuuril. Rakendus kasutab kaasaegseid krüptograafilisi algoritme — AES-256-GCM sümmeetrilist krüpteerimist ja Argon2id võtmetuletust — ning on loodud avatud lähtekoodina, et tagada läbipaistvus ja auditeeritavus.”

Hinnang: Opus 4.6 + Cowork kombinatsioon genereeris kõige mahukama ja tehniliselt sügavaima töö. 61-leheküljeline lõputöö sisaldas terviklikku tehnilist arhitektuuri ja koodinäiteid; lisaks väitis töö, et rakendus läbis 149 automatiseeritud testi, OWASP Top 10 analüüsi ja SUS kasutatavusuuringu (skoor 77,0). Neid teste, auditit ega kasutajauuringut ei teostanud käesoleva uurimuse autor iseseisvalt – tegemist on kombinatsiooni enda genereeritud empiiriliste väidetega, mis tuleb inimese poolt kontrollida samamoodi nagu viited. Eestikeelne akadeemiline stiil oli läbivalt suurepärase (0 esimese isiku asesõna terve töö peale); ristkontrollis tuvastati 15 keele- ja kirjavigu. Struktuur vastas TÜ nõuetele. 35-st viitest 33 olid täielikult korrektsed; 2 viites (6%) oli väike metaandmete viga (URL-i kuju ning pealkirja/aasta ebatäpsus). Peamine eelis teiste kombinatsioonide ees: tehniline detailsus, $\text{\LaTeX}$ koodi otsene genereerimine failidesse ja võime hallata terviklikku projektistruktuuri.

III.6 Genereeritud tööde võrdlev kokkuvõte

Tabel 13. Tervikliku lõputöö genereerimise koondvõrdlus

Kriteerium	Gemini 3.1 Pro + Antigravity	GPT-5.4 + Codex	Claude Sonnet 4.6 + Cowork	Claude Opus 4.6 + Cowork
Keel	Eesti	Eesti	Eesti	Eesti
Maht	39 lk	47 lk	40 lk	61 lk
Valitud teema	GenAI ja progr.	RAG QA-süsteem	LLM koodiülevaatuses	Paroolihaldur
Struktuur	Lõputöö	Lõputöö	Lõputöö	Lõputöö
Keele- ja kirjavigu (kogu töö peale)	24	3	37	15
Unikaalseid viiteid	9	22	23	35
Hallutsineeritud viiteid	1 (11%)	0 (0%)	5 (22%)	2 (6%)
Esimese isiku asesõnu	4	2	2	0
Praktiline kasutus alus põhjana	Madal (fabritseeritud empiirika)	Kõrge	Kõrge	Väga kõrge (kontrollimata empiiriliste väidetega)

Litsents

Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks

Mina, Uku Renek Kronbergs,

1. annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) minu loodud teose

“Teostatavusuuring: Tehisintellekti abil eestikeelse tehnilise informaatika alase lõputöö genereerimine”,

mille juhendaja on Alo Peets (MSc),

reprodutseerimiseks eesmärgiga seda säilitada, sealhulgas lisada digitaalarhiivi DSpace kuni autoriõiguse kehtivuse lõppemiseni.

2. Annan Tartu Ülikoolile loa teha punktis 1 nimetatud teos üldsusele kättesaadavaks Tartu Ülikooli veebikeskkonna, sealhulgas digitaalarhiivi DSpace kaudu Creative Commons'i litsentsiga CC BY NC ND 3.0, mis lubab autorile viidates teost reprodutseerida, levitada ja üldsusele suunata ning keelab luua tuletatud teost ja kasutada teost ärieesmärgil, kuni autoriõiguse kehtivuse lõppemiseni.
3. Olen teadlik, et punktides 1 ja 2 nimetatud õigused jäävad alles ka autorile.
4. Kinnitan, et lihtlitsentsi andmisega ei riku ma teiste isikute intellektuaalomandi ega isikuandmete kaitse õigusaktidest tulenevaid õigusi.

Uku Renek Kronbergs

[kuupäev]